مدل‌سازی شناختی

جزوه‌ی کامل درس

۱۶ هفته · ۶ فصل

فهرست مطالب

طرح درس ۱

۱.۰.۰ شرح درس ۱

۲.۰.۰ اهداف یادگیری ۱

۳.۰.۰ سرفصل‌ها ۲

۴.۰.۰ برنامه‌ی هفتگی ۲

۵.۰.۰ ارزشیابی (از ۲۰) ۳

۶.۰.۰ قوانین (خلاصه) ۴

۷.۰.۰ نرم‌افزار ۴

۸.۰.۰ منابع ۴

نقشه‌ی دوره ۵

۹.۰.۰ اصول طراحی ۶

۱۰.۰.۰ برنامه‌ی هفتگی ۶

۱۱.۰.۰ نمره‌دهی (از ۲۰) ۱۲

۱۲.۰.۰ پروژه‌ی پایانی (نمای کلی؛ شرح کامل و روبریک در فایل `assessments/project_brief.md`) ۱۳

۱۳.۰.۰ محاسبه روی لپ‌تاپ دانشجویان ۱۳

۱ مبانی مدل‌سازی شناختی ۱۴

۱.۱ هفته‌ی ۱: مدل شناختی چیست؟ ۱۴

۱.۱.۱ واژه‌های کلیدی ۱۴

۲.۱.۱ اهداف یادگیری ۱۵

۳.۱.۱ مقدمه ۱۶

۴.۱.۱ جزوه‌ی درس ۱۷

۵.۱.۱ مثال حل‌شده ۲۵

۶.۱.۱ lab (۲ ساعت) ۲۶

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها ۳۱

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست ۳۲

۹.۱.۱ خودآزمایی . . . ۳۲
۱۰.۱.۱ تکلیف . . . ۳۳
۱۱.۱.۱ مطالعه‌ی بیشتر . . . ۳۴
۲.۱ هفته‌ی ۲: کالبدشکافی یک مدل: تشخیص علامت و منحنی‌های فراموشی . . . ۳۴
۱.۲.۱ واژه‌های کلیدی . . . ۳۴
۲.۲.۱ اهداف یادگیری . . . ۳۵
۳.۲.۱ مقدمه . . . ۳۶
۴.۲.۱ جزوه‌ی درس . . . ۳۶
۵.۲.۱ مثال حل‌شده . . . ۴۲
۶.۲.۱ lab (۲ ساعت) . . . ۴۶
۷.۲.۱ ارتباط با هوش مصنوعی و LLMها . . . ۵۱
۸.۲.۱ اشتباهات رایج و برداشت‌های نادرست . . . ۵۲
۹.۲.۱ خودآزمایی . . . ۵۲
۱۰.۲.۱ تکلیف . . . ۵۳
۱۱.۲.۱ مطالعه‌ی بیشتر . . . ۵۴

۲ روش‌های برآورد پارامتر ۵۵
۱.۲ هفته‌ی ۳: برازش مدل با کمترین مربعات: سطح خطا و بهینه‌سازی . . . ۵۵
۱.۱.۲ واژه‌های کلیدی . . . ۵۵
۲.۱.۲ اهداف یادگیری . . . ۵۶
۳.۱.۲ مقدمه . . . ۵۷
۴.۱.۲ جزوه‌ی درس . . . ۵۷
۵.۱.۲ مثال حل‌شده . . . ۶۳
۶.۱.۲ lab (۲ ساعت) . . . ۶۴
۷.۱.۲ ارتباط با هوش مصنوعی و LLMها . . . ۶۹
۸.۱.۲ اشتباهات رایج و برداشت‌های نادرست . . . ۶۹
۹.۱.۲ خودآزمایی . . . ۷۰
۱۰.۱.۲ تکلیف . . . ۷۱
۱۱.۱.۲ مطالعه‌ی بیشتر . . . ۷۱
۲.۲ هفته‌ی ۴: برآورد بیشینه درست‌نمایی (Maximum Likelihood) . . . ۷۱
۱.۲.۲ واژه‌های کلیدی . . . ۷۱
۲.۲.۲ اهداف یادگیری . . . ۷۳
۳.۲.۲ مقدمه . . . ۷۳
۴.۲.۲ جزوه‌ی درس . . . ۷۴
۵.۲.۲ مثال حل‌شده . . . ۷۸

۶.۲.۲ lab (۲ ساعت) . . . ۷۹
۷.۲.۲ ارتباط با هوش مصنوعی و LLMها . . . ۸۳
۸.۲.۲ اشتباهات رایج و برداشت‌های نادرست . . . ۸۳
۹.۲.۲ خودآزمایی . . . ۸۴
۱۰.۲.۲ تکلیف . . . ۸۴
۱۱.۲.۲ مطالعه‌ی بیشتر . . . ۸۵
۳.۲ هفته‌ی ۵: عدم قطعیت برآوردها و برازش برای چند شرکت‌کننده . . . ۸۵
۱.۳.۲ واژه‌های کلیدی . . . ۸۶
۲.۳.۲ اهداف یادگیری . . . ۸۷
۳.۳.۲ مقدمه . . . ۸۷
۴.۳.۲ جزوه‌ی درس . . . ۸۸
۵.۳.۲ مثال حل‌شده . . . ۹۲
۶.۳.۲ lab (۲ ساعت) . . . ۹۳
۷.۳.۲ ارتباط با هوش مصنوعی و LLMها . . . ۹۶
۸.۳.۲ اشتباهات رایج و برداشت‌های نادرست . . . ۹۷
۹.۳.۲ خودآزمایی . . . ۹۷
۱۰.۳.۲ تکلیف . . . ۹۸
۱۱.۳.۲ مطالعه‌ی بیشتر . . . ۹۸

۳ ارزیابی مدل‌های شناختی ۹۹
۱.۳ هفته‌ی ۶: ارزیابی مدل‌ها ۱: نیکویی برازش، overfitting و cross-validation . . . ۹۹
۱.۱.۳ واژه‌های کلیدی . . . ۹۹
۲.۱.۳ اهداف یادگیری . . . ۱۰۰
۳.۱.۳ مقدمه . . . ۱۰۱
۴.۱.۳ جزوه‌ی درس . . . ۱۰۱
۵.۱.۳ مثال حل‌شده . . . ۱۰۵
۶.۱.۳ lab (۲ ساعت) . . . ۱۰۶
۷.۱.۳ ارتباط با هوش مصنوعی و LLMها . . . ۱۱۱
۸.۱.۳ اشتباهات رایج و برداشت‌های نادرست . . . ۱۱۲
۹.۱.۳ خودآزمایی . . . ۱۱۲
۱۰.۱.۳ تکلیف . . . ۱۱۳
۱۱.۱.۳ مطالعه‌ی بیشتر . . . ۱۱۴
۲.۳ هفته‌ی ۷: ارزیابی مدل‌ها ۲: معیارهای اطلاعاتی، بازیابی پارامتر و بازیابی مدل . . . ۱۱۴
۱.۲.۳ واژه‌های کلیدی . . . ۱۱۴
۲.۲.۳ اهداف یادگیری . . . ۱۱۶

۳.۲.۳ مقدمه . . . ۱۱۶
۴.۲.۳ جزوه‌ی درس . . . ۱۱۷
۵.۲.۳ مثال حل‌شده . . . ۱۲۱
۶.۲.۳ lab (۲ ساعت) . . . ۱۲۱
۷.۲.۳ ارتباط با هوش مصنوعی و LLMها . . . ۱۲۵
۸.۲.۳ اشتباهات رایج و برداشت‌های نادرست . . . ۱۲۵
۹.۲.۳ خودآزمایی . . . ۱۲۶
۱۰.۲.۳ تکلیف . . . ۱۲۶
۱۱.۲.۳ مطالعه‌ی بیشتر . . . ۱۲۷
۳.۳ هفته‌ی ۸: مرور میان‌ترم: کل مسیر مدل‌سازی در یک مطالعه‌ی موردی . . . ۱۲۷
۱.۳.۳ واژه‌های کلیدی . . . ۱۲۷
۲.۳.۳ اهداف یادگیری . . . ۱۲۹
۳.۳.۳ مقدمه . . . ۱۲۹
۴.۳.۳ جزوه‌ی درس . . . ۱۲۹
۵.۳.۳ مثال حل‌شده . . . ۱۳۲
۶.۳.۳ lab (۲ ساعت): آزمون میان‌ترم + مشاوره‌ی پروژه . . . ۱۳۴
۷.۳.۳ ارتباط با هوش مصنوعی و LLMها . . . ۱۳۶
۸.۳.۳ اشتباهات رایج و برداشت‌های نادرست (۱۰ مورد اول از هفته‌های ۱ تا ۷) . . . ۱۳۶
۹.۳.۳ خودآزمایی (سؤال‌های تمرینی به سبک آزمون) . . . ۱۳۷
۱۰.۳.۳ تکلیف . . . ۱۳۸
۱۱.۳.۳ مطالعه‌ی بیشتر . . . ۱۳۸

۴ مدل‌سازی بیزی ۱۳۹
۱.۴ هفته‌ی ۹: مدل‌سازی بیزی ۱: پیشین، پسین و تقریب شبکه‌ای . . . ۱۳۹
۱.۱.۴ واژه‌های کلیدی . . . ۱۳۹
۲.۱.۴ اهداف یادگیری . . . ۱۴۰
۳.۱.۴ مقدمه . . . ۱۴۱
۴.۱.۴ جزوه‌ی درس . . . ۱۴۱
۵.۱.۴ مثال حل‌شده . . . ۱۴۵
۶.۱.۴ lab (۲ ساعت) . . . ۱۴۷
۷.۱.۴ ارتباط با هوش مصنوعی و LLMها . . . ۱۴۹
۸.۱.۴ اشتباهات رایج و برداشت‌های نادرست . . . ۱۵۰
۹.۱.۴ خودآزمایی . . . ۱۵۰
۱۰.۱.۴ تکلیف . . . ۱۵۱
۱۱.۱.۴ مطالعه‌ی بیشتر . . . ۱۵۱

۲.۴ هفته‌ی ۱۰: مدل‌سازی بیزی ۲: بررسی پیش‌بینی پسین و Bayes factor ۱۵۲
۱.۲.۴ واژه‌های کلیدی ۱۵۲
۲.۲.۴ اهداف یادگیری ۱۵۳
۳.۲.۴ مقدمه ۱۵۳
۴.۲.۴ جزوه‌ی درس ۱۵۴
۵.۲.۴ مثال حل‌شده ۱۵۸
۶.۲.۴ lab (۲ ساعت) ۱۵۹
۷.۲.۴ ارتباط با هوش مصنوعی و LLMها ۱۶۲
۸.۲.۴ اشتباهات رایج و برداشت‌های نادرست ۱۶۳
۹.۲.۴ خودآزمایی ۱۶۳
۱۰.۲.۴ تکلیف ۱۶۴
۱۱.۲.۴ مطالعه‌ی بیشتر ۱۶۴

۵ برآورد پارامتر با MCMC ۱۶۵

۱.۵ هفته‌ی ۱۱: روش‌های Monte Carlo و الگوریتم Metropolis–Hastings ۱۶۵
۱.۱.۵ واژه‌های کلیدی ۱۶۵
۲.۱.۵ اهداف یادگیری ۱۶۶
۳.۱.۵ مقدمه ۱۶۷
۴.۱.۵ جزوه‌ی درس ۱۶۷
۵.۱.۵ مثال حل‌شده ۱۷۱
۶.۱.۵ lab (۲ ساعت) ۱۷۳
۷.۱.۵ ارتباط با هوش مصنوعی و LLMها ۱۷۶
۸.۱.۵ اشتباهات رایج و برداشت‌های نادرست ۱۷۶
۹.۱.۵ خودآزمایی ۱۷۷
۱۰.۱.۵ تکلیف ۱۷۷
۱۱.۱.۵ مطالعه‌ی بیشتر ۱۷۸
۲.۵ هفته‌ی ۱۲: نمونه‌گیری Gibbs و تشخیص همگرایی ۱۷۸
۱.۲.۵ واژه‌های کلیدی ۱۷۸
۲.۲.۵ اهداف یادگیری ۱۷۹
۳.۲.۵ مقدمه ۱۷۹
۴.۲.۵ جزوه‌ی درس ۱۸۰
۵.۲.۵ مثال حل‌شده ۱۸۴
۶.۲.۵ lab (۲ ساعت) ۱۸۵
۷.۲.۵ ارتباط با هوش مصنوعی و LLMها ۱۸۸
۸.۲.۵ اشتباهات رایج و برداشت‌های نادرست ۱۸۸

۹.۲.۵ خودآزمایی ۱۸۹
۱۰.۲.۵ تکلیف ۱۸۹
۱۱.۲.۵ مطالعه‌ی بیشتر ۱۹۰
۳.۵ هفته‌ی ۱۳: برنامه‌نویسی احتمالاتی و مدل‌های سلسله‌مراتبی ۱۹۰
۱.۳.۵ واژه‌های کلیدی ۱۹۰
۲.۳.۵ اهداف یادگیری ۱۹۲
۳.۳.۵ مقدمه ۱۹۲
۴.۳.۵ جزوه‌ی درس ۱۹۳
۵.۳.۵ مثال حل‌شده ۱۹۶
۶.۳.۵ lab (۲ ساعت) ۱۹۷
۷.۳.۵ ارتباط با هوش مصنوعی و LLMها ۲۰۰
۸.۳.۵ اشتباهات رایج و برداشت‌های نادرست ۲۰۱
۹.۳.۵ خودآزمایی ۲۰۲
۱۰.۳.۵ تکلیف ۲۰۲
۱۱.۳.۵ مطالعه‌ی بیشتر ۲۰۲

۶ کاربردها در علوم شناختی ۲۰۴
۱.۶ هفته‌ی ۱۴: مدل‌سازی در علوم شناختی ۱: دسته‌بندی (GCM) و تصمیم‌گیری (Drift-Diffusion) ۲۰۴
۱.۱.۶ واژه‌های کلیدی ۲۰۴
۲.۱.۶ اهداف یادگیری ۲۰۵
۳.۱.۶ مقدمه ۲۰۶
۴.۱.۶ جزوه‌ی درس ۲۰۶
۵.۱.۶ مثال حل‌شده ۲۱۱
۶.۱.۶ lab (۲ ساعت) ۲۱۲
۷.۱.۶ ارتباط با هوش مصنوعی و LLMها ۲۱۵
۸.۱.۶ اشتباهات رایج و برداشت‌های نادرست ۲۱۵
۹.۱.۶ خودآزمایی ۲۱۶
۱۰.۱.۶ تکلیف ۲۱۶
۱۱.۱.۶ مطالعه‌ی بیشتر ۲۱۶
۲.۶ هفته‌ی ۱۵: مدل‌سازی در علوم شناختی ۲: یادگیری تقویتی، شناخت بیزی و هوش مصنوعی ۲۱۷
۱.۲.۶ واژه‌های کلیدی ۲۱۷
۲.۲.۶ اهداف یادگیری ۲۱۸
۳.۲.۶ مقدمه ۲۱۹
۴.۲.۶ جزوه‌ی درس ۲۱۹
۵.۲.۶ مثال حل‌شده ۲۲۳

۶.۲.۶ lab (۲ ساعت) . . . ۲۲۵
۷.۲.۶ ارتباط با هوش مصنوعی و LLMها . . . ۲۲۸
۸.۲.۶ اشتباهات رایج و برداشت‌های نادرست . . . ۲۲۸
۹.۲.۶ خودآزمایی . . . ۲۲۹
۱۰.۲.۶ تکلیف . . . ۲۲۹
۱۱.۲.۶ مطالعه‌ی بیشتر . . . ۲۳۰
۳.۶ هفته‌ی ۱۶: ارائه‌های پروژه‌ی پایانی و شیوه‌ی خوب مدل‌سازی . . . ۲۳۰
۱.۳.۶ واژه‌های کلیدی . . . ۲۳۰
۲.۳.۶ اهداف یادگیری . . . ۲۳۱
۳.۳.۶ مقدمه . . . ۲۳۲
۴.۳.۶ جزوه‌ی درس . . . ۲۳۲
۵.۳.۶ مثال حل‌شده: نقد یک مطالعه‌ی مدل‌سازی . . . ۲۳۵
۶.۳.۶ lab (۲ ساعت): ارائه‌ها و بازخورد همتایان . . . ۲۳۶
۷.۳.۶ ارتباط با هوش مصنوعی و LLMها . . . ۲۳۶
۸.۳.۶ اشتباهات رایج و برداشت‌های نادرست (در ارائه‌ها و گزارش‌های پروژه) . . . ۲۳۷
۹.۳.۶ خودآزمایی (پرسش‌های مرور یکپارچه برای امتحان پایانی) . . . ۲۳۷
۱۰.۳.۶ تکلیف . . . ۲۳۸
۱۱.۳.۶ مطالعه‌ی بیشتر . . . ۲۳۸

واژه‌نامه **۲۳۹**

۱۲.۳.۶ اصطلاحات هوش مصنوعی و LLM (از بخش‌های «ارتباط با هوش مصنوعی و LLMها») . . . ۲۴۶

فهرست مطالعه **۲۴۸**

۱۳.۳.۶ منابع درس (طبق مشخصات درس) . . . ۲۴۸
۱۴.۳.۶ راهنمای فصل‌ها به تفکیک هفته . . . ۲۴۹
۱۵.۳.۶ منابع اختیاری خارج از فهرست درس . . . ۲۵۰

طرح درس

نام درس	مدل‌سازی شناختی (درس اختیاری تخصصی)
واحد	۲ واحد: ۱ واحد نظری (۱۶ ساعت) + ۱ واحد عملی (۳۲ ساعت) = ۴۸ ساعت
شکل برگزاری	۱۶ هفته × (۱ ساعت درس + ۲ ساعت lab عملی)
مخاطبان	دانشجویان کارشناسی ارشد و سال آخر کارشناسی در علوم شناختی، روان‌شناسی، علوم کامپیوتر و هوش مصنوعی
پیش‌نیازها	روش‌های آماری در علوم شناختی؛ روش‌های آزمایشی در روان‌شناسی شناختی. فرض بر این است که دانشجو با احتمال، آمار و برنامه‌نویسی مقدماتی آشناست؛ آشنایی با آمار بیزی لازم نیست.
مدرس	[نام، اتاق، ایمیل، ساعت حضور]
دستیار آموزشی	[نام، ایمیل، ساعت‌های *lab*]
صفحه‌ی درس	[لینک سامانه‌ی آموزشی *(LMS)*]

۱.۰.۰ شرح درس

مدل‌های شناختی توصیف‌های صریح، ریاضی یا محاسباتی، از فرایندهایی هستند که پشت رفتار قرار دارند. در این درس یاد می‌گیریم چنین مدل‌هایی را بسازیم، روی داده‌های آزمایشی برازش (fit) کنیم، ارزیابی کنیم، و تفسیر کنیم که درباره‌ی ذهن چه می‌گویند. مسیر درس از شهود به فرمول، از فرمول به کد، و از کد به تفسیر است: از منطق یک مدل، با گذر از برآورد کمترین مربعات (least squares) و بیشینه درست‌نمایی (maximum likelihood)، ارزیابی مدل و استنباط بیزی، تا Markov chain Monte Carlo (MCMC) و مدل‌های سلسله‌مراتبی (hierarchical). درس را با مدل‌هایی از حوزه‌های حافظه، ادراک، دسته‌بندی (categorization)، تصمیم‌گیری و یادگیری، و ارتباط آن‌ها با هوش مصنوعی تمام می‌کنیم. هر هفته یک lab دوساعته با Python داریم که در آن دانشجویان یک مدل را روی داده‌ی آزمایشی (شبیه‌سازی‌شده یا واقعی) برازش، ارزیابی و تفسیر می‌کنند.

۲.۰.۰ اهداف یادگیری

اهداف کلی. در پایان درس، دانشجویان با موارد زیر آشنا خواهند بود: ۱. رویکردها و مدل‌های مختلف مدل‌سازی شناختی؛ ۲. چگونگی طراحی یک مدل برای حل یک مسئله‌ی شناختی؛ ۳. کاربردهای مدل‌سازی در علوم شناختی و هوش مصنوعی.

اهداف ویژه. دانشجویان مهارت‌های زیر را کسب می‌کنند: ۱. پیاده‌سازی روش‌های مدل‌سازی روی داده‌های آزمایشی؛ ۲. تفسیر نتایج پژوهشی به‌دست‌آمده با مدل‌های شناختی.

۳.۰.۰ سرفصل‌ها

۱. مبانی مدل‌سازی شناختی
۲. روش‌های برآورد پارامتر (کمترین مربعات / میانگین مربعات خطا یا MSE، بیشینه درست‌نمایی)
۳. ارزیابی مدل‌های شناختی
۴. مدل‌سازی بیزی
۵. برآورد پارامتر با روش‌های داده‌محور (Monte Carlo)، نمونه‌گیری Metropolis–Hastings و Gibbs، (MCMC)
۶. نمونه‌هایی از مدل‌سازی در حوزه‌های مختلف علوم شناختی

۴.۰.۰ برنامه‌ی هفتگی

هفته	فصل	درس نظری	lab	موعد تحویل
۱	۱	مدل شناختی چیست؟ سطوح تحلیل Marr؛ نمادگذاری	نصب محیط نرم‌افزاری درس؛ شبیه‌سازی random walk	—
۲	۱	کالبدشکافی یک مدل: SDT و منحنی‌های فراموشی	SDT و ROC/zROC؛ منحنی فراموشی با نویز دوجمله‌ای	A0
۳	۲	کمترین مربعات، سطح خطا و بهینه‌سازی	جستجوی شبکه‌ای (grid search)، Nelder–Mead، L-BFGS-B؛ حالت‌های شکست	—
۴	۲	بیشینه درست‌نمایی	MLE دوجمله‌ای؛ G^2؛ SDT چندشرطی	A1
۵	۲	عدم قطعیت؛ برازش برای چند شرکت‌کننده	بازه‌های اطمینان Hessian، profile و bootstrap؛ خطاهای ناشی از میانگین‌گیری	—
۶	۳	برازش در برابر تعمیم‌پذیری؛ cross-validation	overfitting؛ K-fold CV؛ معیار تعمیم	A2
۷	۳	AIC/BIC، LRT؛ بازیابی پارامتر و مدل	مطالعات بازیابی؛ confusion matrix	تشکیل گروه‌های پروژه
۸	۱–۳	مرور میان‌ترم: کل مسیر مدل‌سازی	**آزمون میان‌ترم** (۹۰ دقیقه) + مشاوره‌ی پروژه	—

هفته	فصل	درس نظری	lab	موعد تحویل
۹	۴	مدل‌سازی بیزی ۱: پیشین، پسین، شبکه	Beta-binomial؛ پسین شبکه‌ای دوبعدی برای SDT؛ بررسی پیش‌بینی پیشین	A3، پیشنهاد پروژه
۱۰	۴	مدل‌سازی بیزی ۲: PPC و Bayes factor	PPC؛ Bayes factor با شبکه و Savage–Dickey؛ حساسیت به پیشین	—
۱۱	۵	Monte Carlo و Metropolis–Hastings	Metropolis از صفر؛ تنظیم (tuning)	—
۱۲	۵	نمونه‌گیری Gibbs؛ تشخیص همگرایی	Gibbs از صفر؛ R-hat و ESS؛ ArviZ	A4
۱۳	۵	برنامه‌نویسی احتمالاتی؛ مدل‌های سلسله‌مراتبی	SDT سلسله‌مراتبی در PyMC	گزارش پیشرفت
۱۴	۶	دسته‌بندی (GCM) و تصمیم‌گیری (drift-diffusion)	GCM در برابر prototype؛ EZ-diffusion	A5
۱۵	۶	یادگیری تقویتی، شناخت بیزی و هوش مصنوعی	برازش و بازیابی Q-learning؛ مشاهده‌گر ایده‌آل	—
۱۶	—	جمع‌بندی و اصول مدل‌سازی خوب	**ارائه‌ی پروژه‌ها**	ارائه‌ها
دوره‌ی امتحانات	۱–۶	—	**آزمون پایان‌ترم** (۱۲۰ دقیقه)	گزارش + کد (پیش از آزمون)

مواد کامل هر هفته در فایل‌های `weekNN_*.md` است.

۵.۰.۰ ارزشیابی (از ۲۰)

بخش	نمره
تأیید تمرین‌های lab (تمرین‌های هفتگی سر کلاس)	۰.۲
تکالیف A1 تا A5 (هرکدام ۰.۱؛ A0 الزامی ولی بدون نمره)	۰.۵
کوییزهای سر کلاس (حدود ۱۰ کوییز؛ ۲ نمره‌ی پایین حذف می‌شود)	۰.۱
آزمون میان‌ترم (هفته‌ی ۸)	۰.۳
پروژه‌ی پایانی: پیشنهاد ۰.۱ · ارائه ۰.۲ · گزارش + کد ۰.۳	۰.۶

بخش	نمره
آزمون پایان‌ترم (جامع، با تأکید بر فصل‌های ۴ تا ۶)	۰.۳
جمع	**۰.۲۰**

جزئیات، روبریک‌ها و قوانین در پوشه‌ی `assessments/README.md` آمده است.

۶.۰.۰ قوانین (خلاصه)

- **تأخیر در تحویل:** ٪۱۰ کسر نمره برای هر روز، حداکثر ۳ روز.
- **همکاری:** گفت‌وگو آزاد است، ولی کد و متن را خودتان بنویسید (برای گروه‌های دونفره، پروژه کار مشترک گروه است). گفت‌وگوها و کدهای استفاده‌شده‌ی دیگران را ذکر کنید.
- **ابزارهای هوش مصنوعی:** برای رفع اشکال (debugging)، توضیح مفاهیم و ویرایش زبانی مجاز است. نحوه‌ی استفاده را بنویسید؛ باید بتوانید همه‌ی آن‌چه تحویل می‌دهید را توضیح دهید.
- **آزمون‌ها:** کتاب‌بسته، برگه‌ی فرمول داده می‌شود، ماشین‌حساب غیربرنامه‌پذیر مجاز است.
- **حضور:** بیشترِ یادگیری در lab اتفاق می‌افتد؛ تأیید تمرین‌های lab به حضور (یا یک جایگزین توافق‌شده) نیاز دارد.
- **دسترس‌پذیری:** دانشجویانی که به شرایط ویژه نیاز دارند در دو هفته‌ی اول با مدرس تماس بگیرند.

۷.۰.۰ نرم‌افزار

Python ۱۱.۳ یا بالاتر با کتابخانه‌های numpy، scipy، pandas، matplotlib، JupyterLab، PyMC و ArviZ که در هفته‌ی ۱ روی لپ‌تاپ خود دانشجویان نصب می‌شود؛ Miniforge/conda-forge) توصیه می‌شود؛ Google Colab گزینه‌ی جایگزین است). فایل‌های `environment.yml` و `requirements.txt` (در پوشه‌ی اصلی) و lab هفته‌ی ۱ را ببینید.

۸.۰.۰ منابع

منابع اصلی (برای ارتباط فصل‌ها با هفته‌ها فایل `reading_list.md` را ببینید):

- Lewandowsky, S.& Farrell, S., (۲۰۱۸). *Computational modeling of cognition and behavior.* Cambridge University Press. **(کتاب اصلی، هفته‌های ۱ تا ۸)**
- Wagenmakers, E.-J. & Lee, M. D., (۲۰۱۴). *Bayesian cognitive modeling: A practical course.* Cambridge University Press. **(کتاب اصلی، هفته‌های ۹ تا ۱۴)**
- Kruschke, J. K. (۲۰۱۴). *Doing Bayesian data analysis: A tutorial with R, JAGS, and Stan* (2nd ed.). Academic Press.
- Martin, O. A., (۲۰۲۱). *Bayesian modeling and computation in Python.* Chapman and Hall/CRC.
- Lao, J. & Kumar, R., (۲۰۱۴). *Computational neuroscience and cognitive modelling: A student's introduction to methods and procedures.* MIT Press.
- Anderson, B. (۲۰۲۲). *Introduction to modeling cognitive processes.* SAGE.
- Verguts, T. (۱۴۰۱). مبانی روش‌های مستقیم در بهینه‌سازی غیرخطی. (ز. احمدی، ا. عظیمی‌فر، Trans.). قدوسیان، ع.
- احمدی، ا. (۱۳۹۶). شناسایی آماری الگو: یادگیری نظری مقدماتی، جلد ۱.

نقشه‌ی دوره

واحد: ۲ واحد (۱ نظری + ۱ عملی)، در مجموع ۴۸ ساعت · **شکل برگزاری:** هر هفته ۱ ساعت درس + ۲ ساعت lab **مخاطبان:** دانشجویان کارشناسی ارشد و سال آخر کارشناسی · **پیش‌نیازها:** روش‌های آماری در علوم شناختی؛ روش‌های آزمایشی در روان‌شناسی شناختی **زبان / ابزار:** Python ۳ (numpy، scipy، pandas، matplotlib؛ و از هفته‌ی ۱۳ به بعد PyMC + (ArviZ، روی لپ‌تاپ خود دانشجویان

۹.۰.۰ اصول طراحی

- **یک مسیر مدل‌سازی ثابت برای کل ترم.** همه‌ی labها همین مراحل را دنبال می‌کنند: شبیه‌سازی *(simulate)* ← برازش *(fit)* ← ارزیابی *(evaluate)* ← بازیابی *(recover)* ← تفسیر *(interpret)*.
- **چند مجموعه‌داده‌ی ثابت که مدام تکرار می‌شوند.** منحنی‌های فراموشی و نظریه‌ی تشخیص علامت (SDT) از هفته‌ی ۲ تا ۱۳ ادامه دارند، تا روش‌های جدید روی داده‌های آشنا مقایسه شوند. فصل ۶ دسته‌بندی (GCM)، زمان واکنش (drift-diffusion) و یادگیری تقویتی (reinforcement learning) را اضافه می‌کند.
- **«اول خودت بنویس، بعد از کتابخانه استفاده کن.»** دانشجویان کمترین مربعات، بیشینه درست‌نمایی، پسین شبکه‌ای، Metropolis–Hastings، Gibbs و R-hat را دستی می‌نویسند و بعد سراغ `scipy.optimize`، PyMC یا ArviZ می‌روند.
- **وزن فصل‌ها.** فصل ۱: ۲ هفته · فصل ۲: ۳ · فصل ۳: ۲ · فصل ۴: ۲ · فصل ۵: ۳ · فصل ۶: ۲. سه هفته‌ی دیگر هم به معارفه، میان‌ترم و ارائه‌ی پروژه‌ها اختصاص دارد.
- «Metropolis–Gibbs» **یعنی دو الگوریتم جدا:** Metropolis–Hastings (هفته‌ی ۱۱) و نمونه‌گیری Gibbs (هفته‌ی ۱۲). روش MH-within-Gibbs در یک کادر «پیشرفته» آمده است.

۱۰.۰.۰ برنامه‌ی هفتگی

هفته	فصل	درس (۱ ساعت)	lab (۲ ساعت)	اهداف یادگیری	منابع	تکلیف / نقطه‌ی عطف
۱	۱	**معارفه: مدل شناختی چیست؟** چرا مدل می‌سازیم؛ نظریه‌ی کلامی در برابر فرمال؛ سه سطح Marr؛ خانواده‌های مدل (نمادین، پیوندگرا یا connectionist، تصادفی/پویا، بیزی)؛ نقشه‌ی درس؛ **جدول نمادگذاری**	**نصب روی لپ‌تاپ** (محیط Miniforge/conda با همه‌ی ابزارهای درس از جمله *PyMC*، اجرای اسکریپت بررسی نصب؛ Colab به‌عنوان جایگزین)؛ شبیه‌سازی random walk تا رسیدن به مرز و رسم «داده»ی شبیه‌سازی‌شده	تمایز مدل‌های توصیفی، فرایندی و هنجاری؛ توضیح اینکه چرا نظریه‌های کلامی ناقص‌اند؛ اجرا و رسم شبیه‌سازی یک مدل	F&L فصل ۱–۲؛ Verguts، فصل مقدمه [بررسی شود]؛ Anderson، فصل مقدمه [بررسی شود]	A0 (بدون نمره): بررسی نصب + یادداشتی یک‌صفحه‌ای: «یک نظریه‌ی کلامی انتخاب کنید و بنویسید چه چیزهایی را مشخص نکرده است»
۲	۱	**کالبدشکافی یک مدل:** داده، پارامتر آزاد در برابر ثابت، معادلات مدل، مدل نویز (noise/data model)؛ شبیه‌سازی به‌عنوان ابزار فکر کردن؛ اولین مدل‌ها: SDT (d'، c) و فراموشی نمایی در برابر توانی	پیاده‌سازی SDT (d'، c، منحنی ROC؛ شبیه‌سازی فراموشی نمایی و توانی؛ بررسی اثر هر پارامتر روی پیش‌بینی‌ها	شناسایی اجزای یک مدل فرمال؛ محاسبه‌ی d' و c؛ پیش‌بینی اثر پارامترها روی خروجی مدل	F&L فصل ۲؛ L&W فصل ۱۱ (پیش‌نمایش SDT)	**انتشار** :A1 «از کلامی به فرمال» (موعد: هفته‌ی ۴)

هفته	فصل	درس (۱ ساعت)	lab (۲ ساعت)	اهداف یادگیری	منابع	تکلیف / نقطه‌ی عطف
۳	۲	**کمترین مربعات و بهینه‌سازی:** SSE، MSE، RMSD؛ سطح خطا؛ جستجوی شبکه‌ای، Nelder–Mead، روش‌های گرادیانی؛ کمینه‌ی محلی، مقدار شروع، کران‌ها و reparameterization	برازش منحنی فراموشی با جستجوی شبکه‌ای و سپس با `scipy.optimize.minimize`؛ رسم سطح خطا؛ برازش چندشروعی (multi-start)	پیاده‌سازی برازش LS از صفر؛ مقایسه‌ی بهینه‌سازها؛ تشخیص برازش‌های ناموفق	F&L فصل ۳؛ قدوسیان (روش‌های جستجوی مستقیم)	—
۴	۲	**بیشینه درست‌نمایی:** احتمال در برابر درست‌نمایی؛ log-likelihood؛ درست‌نمایی برنولی، دوجمله‌ای و گاوسی؛ LS به‌عنوان MLE تحت نویز گاوسی	MLE برای داده‌ی فراموشی (تعداد یادآوری دوجمله‌ای) و برای SDT؛ مقایسه‌ی برآوردهای MLE و LS	استخراج درست‌نمایی؛ پیاده‌سازی کمینه‌سازی NLL؛ توضیح اینکه LS و MLE کی یکسان‌اند	F&L فصل ۴؛ عظیمی‌فر و احمدی (برآورد (ML	**موعد** A1 · **انتشار** :A2 LS در برابر MLE (موعد: هفته‌ی ۶)
۵	۲	**عدم قطعیت و چند شرکت‌کننده:** خطای استاندارد از Hessian، profile likelihood، bootstrap پارامتری؛ برازش فردی در برابر تجمیعی؛ خطاهای ناشی از میانگین‌گیری	بازه‌ی اطمینان bootstrap؛ میانگین‌گیری از یادگیرنده‌های نمایی یک «قانون توانی تمرین» کاذب می‌سازد؛ برازش‌های فردی	سنجش عدم قطعیت برآورد؛ توضیح خطای میانگین‌گیری؛ انتخاب سطح برازش	F&L فصل ۵	—

هفته	فصل	درس (۱ ساعت)	lab (۲ ساعت)	اهداف یادگیری	منابع	تکلیف / نقطه‌ی عطف
۶	۳	**ارزیابی ۱، برازش در برابر تعمیم‌پذیری:** R^2، RMSD و deviance و محدودیت‌هایشان؛ انعطاف‌پذیری و overfitting؛ اعتبارسنجی hold-out، k-fold و LOO	نمایش overfitting با چندجمله‌ای؛ مقایسه‌ی سه مدل فراموشی با cross-validation	توضیح اینکه چرا برازش خوب ≠ مدل خوب؛ پیاده‌سازی k-fold CV؛ تفسیر نتایج CV	F&L فصل ۱۰؛ عظیمی‌فر و احمدی (تعمیم‌پذیری)	**موعد A2 · انتشار A3:** مقایسه + بازیابی (موعد: هفته‌ی ۹)
۷	۳	**ارزیابی ۲، انتخاب و بازیابی:** آزمون نسبت درست‌نمایی؛ AIC، AICc، BIC و وزن‌های Akaike؛ بازیابی پارامتر و مدل؛ identifiability و trade-off پارامترها	مطالعه‌ی بازیابی: نمودار پارامتر واقعی در برابر بازیابی‌شده؛ confusion matrix بازیابی مدل (AIC/BIC)	تفسیر معیارهای اطلاعاتی؛ طراحی مطالعه‌ی بازیابی؛ تشخیص non-identifiability	F&L فصل ۱۰	**تشکیل گروه‌های پروژه (۱ تا ۲ نفر)؛ انتشار راهنمای پیشنهاد پروژه**
۸	۱–۳	**مرور میان‌ترم:** یک مطالعه‌ی موردی یکپارچه از کل مسیر	**آزمون میان‌ترم** (در زمان lab، ۹۰ دقیقه): سؤال مفهومی + خواندن و تفسیر کد، فصل‌های ۱ تا ۳	—	مرور هفته‌های ۱ تا ۷	**میان‌ترم**

هفته	فصل	درس (۱ ساعت)	lab (۲ ساعت)	اهداف یادگیری	منابع	تکلیف / نقطه‌ی عطف
۹	۴	**مدل‌سازی بیزی ۱:** پیشین، درست‌نمایی، پسین، شواهد (evidence)؛ conjugacy؛ beta-binomial؛ تقریب شبکه‌ای؛ خلاصه‌های پسین و HDI؛ credible interval در برابر بازه‌ی اطمینان	پسین شبکه‌ای برای احتمال یادآوری؛ شبکه‌ی دوبعدی برای SDT؛ تغییر پیشین و حجم نمونه؛ شبیه‌سازی پیش‌بینی پیشین	محاسبه‌ی پسین شبکه‌ای؛ توضیح نقش پیشین؛ تفسیر credible interval	K فصل ۵–۶؛ L&W فصل ۱ و ۳؛ MKL فصل ۱؛ F&L فصل ۶؛ عظیمی‌فر و احمدی (برآورد بیزی)	**موعد A3 · موعد پیشنهاد پروژه**
۱۰	۴ (+۳)	**مدل‌سازی بیزی ۲:** بررسی پیش‌بینی پسین (PPC)؛ marginal likelihood و Bayes factor؛ Savage–Dickey؛ حساسیت به پیشین؛ BIC به‌عنوان تقریب	PPC برای مدل فراموشی؛ Bayes factor Savage–Dickey برای $d' > 0$؛ Bayes factor بین مدل‌های فراموشی با انتگرال‌گیری شبکه‌ای	انجام PPC؛ محاسبه و تفسیر Bayes factor؛ ارزیابی حساسیت به پیشین	L&W فصل ۷؛ F&L فصل ۱۱؛ K فصل ۱۰	**انتشار :A4** تحلیل بیزی با شبکه (موعد: هفته‌ی ۱۲)
۱۱	۵	**Monte Carlo و Metropolis–Hastings:** انتگرال‌گیری Monte Carlo؛ زنجیره‌ی مارکوف؛ MH؛ تنظیم proposal، نرخ پذیرش، burn-in	MH **از صفر** برای مدل فراموشی؛ trace plot؛ مقایسه با پسین شبکه‌ای	توضیح اینکه چرا MCMC کار می‌کند؛ پیاده‌سازی MH؛ تنظیم proposal	K فصل ۷؛ F&L فصل ۷	—

هفته	فصل	درس (۱ ساعت)	lab (۲ ساعت)	اهداف یادگیری	منابع	تکلیف / نقطه‌ی عطف
۱۲	۵	**نمونه‌گیری Gibbs و تشخیص همگرایی:** full conditionalها؛ Gibbs برای مدل نرمال؛ MH-within-Gibbs (پیشرفته)؛ چند زنجیره، R-hat، ESS، خودهمبستگی	**Gibbs از صفر؛** پیاده‌سازی R-hat و ESS و مقایسه با ArviZ؛ خراب کردن عمدی همگرایی و تشخیص آن	پیاده‌سازی Gibbs؛ تفسیر R-hat، ESS و trace plot؛ قضاوت درباره‌ی قابل‌اعتماد بودن زنجیره	K فصل ۷؛ MKL فصل ۲؛ F&L فصل ۷	**موعد A4 · انتشار A5:** MCMC + تشخیص همگرایی (موعد: هفته‌ی ۱۴)
۱۳	۵	**برنامه‌نویسی احتمالاتی و مدل‌های سلسله‌مراتبی:** PyMC؛ HMC/NUTS در سطح مفهومی (پیشرفته)؛ partial pooling و shrinkage (مرتبط با هفته‌ی ۵)	**سلسله‌مراتبی در PyMC:** SDT تشخیص با ArviZ، PPC، مقایسه با برازش‌های MLE فردی؛ (پیشرفته) LOO/WAIC	تعریف مدل در PyMC؛ توضیح partial pooling؛ گزارش یک گردش کار (workflow) بیزی کامل	L&W فصل ۱۱؛ K فصل ۹؛ F&L فصل ۹؛ MKL فصل ۲ و ۱۰	**گزارش پیشرفت پروژه** (فقط بازخورد)
۱۴	۶	**مدل‌سازی در علوم شناختی ۱:** دسته‌بندی prototype) در برابر exemplar؛ GCM)؛ انتخاب/زمان واکنش (drift-diffusion، EZ-diffusion)	برازش GCM با MLE روی داده‌ی ساختار دسته‌بندی ۵-۴؛ EZ-diffusion روی زمان‌های واکنش شبیه‌سازی‌شده؛ تفسیر پارامترها	برازش یک مدل exemplar؛ نگاشت پارامترهای DDM به سازه‌های شناختی	L&W فصل ۱۷؛ F&L فصل ۱۴ [بررسی شود]؛ Verguts (فصل‌های مرتبط [بررسی شود])	**موعد A5**

هفته	فصل	درس (۱ ساعت)	lab (۲ ساعت)	اهداف یادگیری	منابع	تکلیف / نقطه‌ی عطف
۱۵	۶	**مدل‌سازی در علوم شناختی ۲:** Rescorla–Wagner و Q-learning با softmax؛ مدل‌های بیزی شناخت در برابر تحلیل داده‌ی بیزی؛ مدل‌های پیوندگرا و ارتباط با هوش مصنوعی	برازش Q-learning (α، β) روی داده‌ی bandit شبیه‌سازی‌شده؛ بازیابی پارامتر؛ (پیشرفته) نسخه‌ی سلسله‌مراتبی در PyMC	برازش یک مدل RL؛ ارزیابی identifiability؛ مقایسه‌ی شناخت بیزی با آمار بیزی	Verguts (فصل‌های یادگیری/RL [بررسی شود])؛ F&L فصل ۱۳ [بررسی شود]؛ Anderson (فصل‌های مرتبط [بررسی شود])	کار روی پروژه‌ی پایانی
۱۶	—	**ارائه‌ی پروژه‌های پایانی؛** جمع‌بندی اصول مدل‌سازی خوب	ادامه‌ی ارائه‌ها؛ بازخورد همتایان	ارائه و نقد یک مطالعه‌ی مدل‌سازی	—	**ارائه‌ها** · گزارش + کد پیش از آزمون پایانی
دوره‌ی امتحانات	۱–۶	**آزمون پایان‌ترم** (کتبی، جامع، با تأکید بر فصل‌های ۴ تا ۶؛ برگه‌ی فرمول داده می‌شود؛ خواندن و تفسیر کد، بدون لپ‌تاپ)	—	—	—	**آزمون پایان‌ترم**

اختصارها: F&L = Lewandowsky & Farrell (۲۰۱۸) · L&W = Wagenmakers & Lee (۲۰۱۴) · K = Kruschke (۲۰۱۴) · MKL = Lao & Martin, Kumar (۲۰۲۱). شماره‌ی فصل‌ها از حافظه نوشته شده‌اند. آن‌هایی که [بررسی شود] دارند کمتر قطعی‌اند؛ لطفاً همه را با خود کتاب‌ها مقایسه کنید.

۱۱.۰.۰ نمره‌دهی (از ۲۰)

بخش	نمره
تأیید تمرین‌های lab (تمرین‌های هفتگی سر کلاس)	۰.۲
تکالیف A1 تا A5 (هرکدام ۰.۱)	۰.۵
کوییزهای کوتاه سر کلاس (حدود ۱۰ کوییز، ۲ نمره‌ی پایین حذف)	۰.۱
آزمون میان‌ترم (هفته‌ی ۸)	۰.۳
پروژه‌ی پایانی: پیشنهاد ۰.۱ · ارائه ۰.۲ · گزارش + کد بازتولیدپذیر ۰.۳	۰.۶
آزمون پایان‌ترم (جامع)	۰.۳
جمع	**۰.۲۰**

۱۲.۰.۰ پروژه‌ی پایانی (نمای کلی؛ شرح کامل و روبریک در فایل `assessments/project_brief.md`)

- **گروه‌های ۱ یا ۲ نفره.** حجم کار با تعداد اعضا بیشتر می‌شود. همه حداقل دو مدل رقیب را برازش می‌کنند، یک مقایسه‌ی مدل و یک تحلیل بازیابی پارامتر انجام می‌دهند. **گروه‌های دونفره علاوه بر این** یک تحلیل بیزی/MCMC (یا یک مدل سلسله‌مراتبی) انجام می‌دهند و بیانیه‌ی سهم فردی تحویل می‌دهند.
- **داده:** داده‌ی شبیه‌سازی‌شده، یک مجموعه‌داده‌ی باز، یا داده‌ی آزمایشی خود دانشجو.
- **نقاط عطف:** تشکیل گروه (هفته‌ی ۷) ← پیشنهاد (هفته‌ی ۹) ← گزارش پیشرفت (هفته‌ی ۱۳) ← ارائه (هفته‌ی ۱۶) ← گزارش + کد (پیش از آزمون پایانی).

۱۳.۰.۰ محاسبه روی لپ‌تاپ دانشجویان

- کل محیط نرم‌افزاری، از جمله PyMC، در **هفته‌ی ۱** نصب می‌شود تا مشکلات نصب روی Windows/macOS خیلی پیش از هفته‌ی ۱۳ حل شوند.
- مسیر پیشنهادی: Miniforge (conda-forge) با فایل `environment.yml` درس، و فایل `requirements.txt` برای pip به‌عنوان جایگزین.
- **جایگزین:** همه‌ی notebookها روی Google Colab هم اجرا می‌شوند.

فصل ۱

مبانی مدل‌سازی شناختی

۱.۱ هفته‌ی ۱: مدل شناختی چیست؟

فصل ۱: مبانی مدل‌سازی شناختی · درس ۱ ساعت · lab ۲ ساعت **مدل اصلی این هفته:** یک مدل ساده‌ی random walk (گام تصادفی) برای تصمیم‌های دوگزینه‌ای.

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
cognitive model	مدل شناختی	توصیف دقیق و ریاضی یا محاسباتی از یک فرایند ذهنی
random walk	گام تصادفی	جمع شدن گام‌به‌گام شواهد تا رسیدن به یک مرز
verbal theory	نظریه‌ی کلامی	نظریه‌ای که فقط با کلمات بیان شده و پیش‌بینی دقیق نمی‌دهد
Marr’s levels	سطوح تحلیل Marr	سطح محاسباتی، الگوریتمی و پیاده‌سازی
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
noise	نویز	تغییرات تصادفی در شواهد یا در داده
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
drift rate	نرخ رانش	سرعت میانگین جمع شدن شواهد؛ نشانه‌ی کیفیت شواهد

English	فارسی	توضیح کوتاه
boundary separation	فاصله‌ی مرزها	مقدار شواهد لازم برای پاسخ؛ نشانه‌ی احتیاط
evidence	شواهد	اطلاعاتی که برای تصمیم جمع می‌شود
accuracy	دقت	نسبت پاسخ‌های درست
response time (RT)	زمان واکنش	فاصله‌ی ارائه‌ی محرک تا پاسخ
formalize / formal model	مدل فرمال / فرمال کردن	نوشتن نظریه به شکل معادله یا الگوریتم
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
inverse problem / forward	مسئله‌ی مستقیم / معکوس	شبیه‌سازی (پارامتر ← داده) در برابر برآورد (داده ← پارامتر)
non-decision time	زمان غیرتصمیمی	زمان دیدن محرک و اجرای حرکت پاسخ
speed–accuracy trade-off	بده‌بستان سرعت و دقت	سریع‌تر پاسخ دادن به قیمت خطای بیشتر
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
probabilistic programming	برنامه‌نویسی احتمالاتی	تعریف مدل با کد و نمونه‌گیری خودکار (PyMC)
temperature	دما (temperature)	پارامتر نویز در انتخاب token؛ $1/T = \beta$
random seed	seed تصادفی	عدد شروع مولد اعداد تصادفی برای تکرارپذیری
quantile	چندک (quantile)	مقداری که درصد مشخصی از داده زیر آن است
large language model (LLM)	مدل بزرگ زبانی	شبکه‌ی عصبی‌ای که کلمه‌ی بعدی متن را پیش‌بینی می‌کند
token	token (واحد متن)	کلمه یا بخشی از کلمه که مدل زبانی پیش‌بینی می‌کند

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. مدل شناختی را **تعریف کنند** و آن را از یک نظریه‌ی کلامی و از یک مدل صرفاً آماری داده‌ها **متمایز کنند**.
۲. مدل‌ها را بر اساس هدف (توصیفی، فرایندی، هنجاری) و خانواده (نمادین، پیوندگرا یا connectionist، تصادفی/پویا، بیزی) **دسته‌بندی کنند** و جایشان را در سه سطح Marr **مشخص کنند**.
۳. **توضیح دهند** که چطور پارامترهای آزاد، یک هسته‌ی قطعی و یک مدل نویز (noise model) با هم یک مدل را به یک ماشین تولید داده تبدیل می‌کنند.
۴. یک مدل تصمیم‌گیری random walk را در Python **پیاده‌سازی** و **شبیه‌سازی کنند** و شبیه‌سازی را با پیش‌بینی‌های تحلیلی **بررسی کنند**.
۵. **تفسیر کنند** که تغییر پارامترهای مدل drift)، مرز) با کدام سازه‌های روان‌شناختی (کیفیت شواهد، احتیاط) متناظر است.

۳.۱.۱ مقدمه

یک نظریه‌ی کلامی آشنا درباره‌ی تصمیم‌های ساده را در نظر بگیرید:

> «آدم‌ها وقتی تصمیم می‌گیرند، آن‌قدر شواهد جمع می‌کنند تا کافی شود و بعد پاسخ می‌دهند.»

کامل به نظر می‌رسد، ولی سعی کنید از آن یک پیش‌بینی بیرون بکشید:

- اگر به شرکت‌کننده‌ها بگوییم دقیق باشید به‌جای سریع باشید، چقدر کندتر می‌شوند؟ دو برابر؟ ۵۰ میلی‌ثانیه؟
- آیا **خطاها** سریع‌تر از پاسخ‌های درست‌اند، کندتر، یا همان‌قدر؟
- توزیع زمان واکنش (RT) باید متقارن باشد یا چوله (skewed)؟
- اگر دیدن محرک سخت‌تر شود، آیا زمان واکنش همان‌طور تغییر می‌کند که با دستور «دقیق باشید»؟

این نظریه‌ی کلامی **به هیچ‌کدام از این سؤال‌ها نمی‌تواند جواب دهد**. هر جواب به تصمیم‌هایی بستگی دارد که نظریه هرگز نگرفته است: «شواهد» یعنی چه؟ پیوسته می‌رسد یا تکه‌تکه؟ «کافی» یعنی چقدر؟ آستانه برای هر دو پاسخ یکی است؟

به‌محض اینکه نظریه را به شکل یک مدل بنویسیم، مثلاً یک random walk که گام‌به‌گام بالا یا پایین می‌رود تا به یک مرز برسد، هر کدام از این سؤال‌ها جواب مشخصی پیدا می‌کند. بعضی از این جواب‌ها غلط از آب درمی‌آیند، و این خوب است: مدلی که می‌تواند غلط باشد، مدلی است که می‌شود از آن یاد گرفت. این پیام اصلی این درس است:

> مدل‌های فرمال (formal) ما را مجبور می‌کنند فرض‌هایمان را صریح کنیم، پیش‌بینی‌های دقیق می‌دهند، و سؤال «آیا این نظریه درست است؟» را به سؤال «این مدل داده‌ها را چقدر خوب، و چرا، توضیح می‌دهد؟» تبدیل می‌کنند.

این موضوع کجا به کار می‌رود؟ مدل‌هایی مثل random walk این هفته فقط مثال کلاسی نیستند. هر روز در پژوهش و کار عملی از آن‌ها استفاده می‌شود:

- **روان‌شناسی بالینی و روان‌پزشکی.** بیماران افسرده، مبتلا به ADHD یا اضطراب اغلب در تکلیف‌های ساده «کندتر» هستند. مدل‌های تصمیم نشان می‌دهند چرا: کیفیت پایین‌تر شواهد، احتیاط بیشتر، یا پاسخ حرکتی کندتر. این سه توضیح به مداخله‌های متفاوتی نیاز دارند.
- **پژوهش درباره‌ی سالمندی.** افراد مسن‌تر کندتر پاسخ می‌دهند. برازش مدل‌های تصمیم نشان داده که بخش زیادی از این کندی از احتیاط بیشتر و کندی حرکت می‌آید، نه از ضعف در پردازش اطلاعات.
- **علوم اعصاب.** نرخ شلیک نورون‌های بعضی نواحی مغز پیش از تصمیم کم‌کم بالا می‌رود تا به یک آستانه برسد؛ خیلی شبیه random walk که به مرز می‌رسد. از پارامترهای مدل برای وصل کردن رفتار و فعالیت مغز استفاده می‌شود.
- **کاربردهای عملی.** تصمیم شاهد عینی، خواندن تصویر پزشکی و کنترل کیفیت، همه تصمیم‌گیری با شواهد پرنویز هستند. همین مدل «شواهد چقدر خوب است» را از «تصمیم‌گیرنده چقدر محتاط است» جدا می‌کند.
- **هوش مصنوعی.** ایده‌های مدل‌های شناختی (جمع شدن شواهد، یادگیری از خطا، استنباط احتمالاتی) در سیستم‌های هوش مصنوعی به کار رفته‌اند، و امروز مدل‌های هوش مصنوعی هم با روش‌های همین درس آزموده می‌شوند (بخش هوش مصنوعی و LLMها را ببینید).

۴.۱.۱ جزوه‌ی درس

به زبان ساده نظریه یک حرف را با کلمات می‌زند («آدم‌ها شواهد جمع می‌کنند تا به اندازه‌ی کافی برسد»). مدل همان حرف را آن‌قدر دقیق می‌زند که کامپیوتر بتواند اجرایش کند. وقتی مدل اجرا شود، پیش‌بینی دقیق می‌دهد: آدم‌ها چند درصد مواقع درست جواب می‌دهند، چقدر طول می‌کشد، و این دو با تغییر تکلیف چطور عوض می‌شوند. مدل این هفته ساده‌ترین مدل تصمیم ممکن است. یک مهره روی یک خط عددی را تصور کنید. در هر لحظه یک قدم بالا می‌رود (کمی شاهد به نفع جواب درست) یا یک قدم پایین (کمی شاهد به نفع جواب غلط). وقتی به خط بالا برسد، فرد درست جواب می‌دهد؛ وقتی به خط پایین برسد، خطا می‌کند. فقط سه عدد همه‌چیز را کنترل می‌کنند: قدم‌ها چقدر به سمت بالا تمایل دارند (drift، کیفیت شواهد)، دو خط چقدر از هم فاصله دارند (**فاصله‌ی مرزها**، میزان احتیاط فرد)، و مهره از کجا شروع می‌کند (**نقطه‌ی شروع**، سوگیری). با چند بار اجرای این ماشین کوچک می‌بینیم که بده‌بستان سرعت و دقت خودبه‌خود ظاهر می‌شود، بدون اینکه آن را در مدل گذاشته باشیم.

واژه‌های روان‌شناسی به زبان ساده

- **شرکت‌کننده** (participant) **یا** (subject): کسی که در آزمایش شرکت می‌کند.
- **محرک** (stimulus)**، جمع** (stimuli): هر چیزی که به شرکت‌کننده نشان داده یا پخش می‌شود؛ مثلاً یک تصویر، یک کلمه یا یک صدا.
- **تکلیف** (task): کاری که شرکت‌کننده باید انجام دهد؛ مثلاً «اگر نقطه‌ها به چپ می‌روند کلید چپ و اگر به راست می‌روند کلید راست را بزن». **تکلیف دوگزینه‌ای** دقیقاً دو پاسخ ممکن دارد.
- **کوشش** (trial): یک بار انجام تکلیف: یک محرک، یک پاسخ. هر آزمایش معمولاً برای هر شرکت‌کننده صدها trial دارد.
- **زمان واکنش** (RT): فاصله‌ی زمانی از ظاهر شدن محرک تا زدن کلید، معمولاً بر حسب میلی‌ثانیه (ms).
- **دقت** (accuracy): نسبت پاسخ‌های درست.
- **شرط یا دست‌کاری** (condition / manipulation): تغییری که آزمایشگر عمداً ایجاد می‌کند (مثلاً دستورالعمل «سریع باش!» در برابر «دقیق باش!»، یا محرک آسان در برابر سخت) تا ببیند رفتار چطور تغییر می‌کند.
- **سازه** (construct): یک کمیت روان‌شناختی که مستقیم دیده نمی‌شود؛ مثلاً احتیاط، توجه یا قدرت حافظه. یک پارامتر خوب مدل، یک سازه را اندازه می‌گیرد.
- **داده‌ی رفتاری:** چیزی که می‌توانیم ثبت کنیم: انتخاب‌ها و زمان‌های واکنش (نه سیگنال‌های مغزی).

زمان‌بندی پیشنهادی (۶۰ دقیقه): انگیزه ۱۰ · چیستی و چرایی ۱۰ · انواع مدل + Marr ۱۵ · مدل به‌عنوان ماشین تولید داده + مسیر مدل‌سازی ۱۰ · اولین مدل (random walk) ۱۲ · نمادگذاری و نکات اجرایی درس ۳.

۱. مدل شناختی چیست؟

مدل شناختی توصیفی صریح، معمولاً ریاضی یا محاسباتی، از فرایندها یا بازنمایی‌هایی است که فرض می‌کنیم رفتار را تولید می‌کنند. سه جزء دارد:

جزء	به چه سؤالی جواب می‌دهد	مثال در random walk
فرض‌ها / ساختار	چه سازوکاری را فرض می‌کنیم؟	شواهد در گام‌های گسسته بین دو مرز انباشته می‌شود
پارامترها	کدام کمیت‌ها می‌توانند بین افراد یا شرایط تغییر کنند؟	drift v، فاصله‌ی مرزها a، نقطه‌ی شروع z
نگاشت به داده	سازوکار چگونه پاسخ‌های قابل مشاهده تولید می‌کند؟	مرزی که به آن می‌رسیم انتخاب را تعیین می‌کند؛ تعداد گام‌ها زمان واکنش را

سه اصطلاح مرتبط که به‌راحتی با هم قاطی می‌شوند:

- **نظریه** مجموعه‌ای از ادعاهای کلامی (اغلب غیررسمی) درباره‌ی ذهن است.
- **مدل** یک نمونه‌ی فرمال مشخص از یک نظریه است. یک نظریه را می‌شود به شکل‌های مختلفی فرمال کرد.
- **مدل آماری** (مثل t-test یا رگرسیون) هم مدل است، ولی مدلِ داده‌ها. پارامترهایش (میانگین‌ها، شیب‌ها) معمولاً داده‌ها را توصیف می‌کنند، نه یک فرایند شناختی را. در مدل شناختی، پارامترها قرار است **کمیت‌های روان‌شناختی پنهان را اندازه بگیرند**، مثل زوال حافظه، احتیاط یا توجه.

جمله‌ی معروف George Box که «همه‌ی مدل‌ها غلط‌اند، ولی بعضی‌شان مفیدند» نگرش این درس را خلاصه می‌کند. ما هیچ‌وقت نمی‌پرسیم یک مدل درست است یا نه. می‌پرسیم مفید است یا نه: آیا الگوهای مهم را نشان می‌دهد، به داده‌ی جدید تعمیم پیدا می‌کند، و پارامترهای قابل تفسیر دارد؟

۲. چرا اصلاً مدل فرمال بسازیم؟

۱. **دقت.** نوشتن مدل فرض‌های پنهان را آشکار می‌کند (مثل مثال بخش انگیزه).
۲. **پیش‌بینی کمّی.** مدل‌ها می‌گویند چقدر، نه فقط آیا.
۳. **کشف پیامدهای غیرمنتظره.** شهود ما درباره‌ی سیستم‌های پیچیده ضعیف است. مثلاً میانگین‌گیری از منحنی‌های یادگیری نمایی افراد، منحنی‌ای می‌سازد که شبیه قانون توانی است (هفته‌ی ۵).
۴. **اندازه‌گیری.** پارامترهای برازش‌شده اندازه‌گیری سازه‌های پنهان‌اند. d' در نظریه‌ی تشخیص علامت (هفته‌ی ۲) حساسیت را جدا از سوگیری پاسخ اندازه می‌گیرد؛ کاری که درصد پاسخ درست به‌تنهایی نمی‌تواند بکند.
۵. **مقایسه‌ی نظریه‌ها.** دو نظریه‌ی کلامی که «هر دو داده‌ها را توضیح می‌دهند» بعد از فرمال شدن قابل رقابت با هم‌اند (هفته‌های ۶–۷ و ۱۰).
۶. **پلی به هوش مصنوعی.** همین صورت‌بندی‌ها (مدل‌های احتمالاتی، قواعد یادگیری، شبکه‌های عصبی) برای ساختن عامل‌های مصنوعی هم به کار می‌روند (هفته‌ی ۱۵).

۳. انواع مدل‌های شناختی

بر اساس هدف:

نوع	سؤال	مثال	هفته‌ها
توصیفی (descriptive)	شکل داده‌ها چیست؟	قانون توانی تمرین؛ منحنی فراموشی نمایی	۲–۷
فرایندی (process) / mechanistic)	ذهن چگونه رفتار را تولید می‌کند؟	random walk / drift-diffusion؛ مدل exemplar (GCM)	۱، ۱۴
هنجاری (normative) / rational)	یک عامل ایده‌آل باید چه کند؟	مشاهده‌گر ایده‌آل بیزی برای ترکیب سرنخ‌ها	۱۵

مرزها مبهم‌اند: مدل SDT تا حدی توصیفی و تا حدی فرایندی است.

بر اساس خانواده:

خانواده	ایده‌ی اصلی	مثال
نمادین / مبتنی بر قاعده	شناخت به‌عنوان دست‌کاری نمادها و قواعد تولید (production rules)	سیستم‌های تولید ACT-R
پیوندگرا (connectionist)	بازنمایی‌های توزیع‌شده، یادگیری با تغییر وزن‌ها	شبکه‌های قاعده‌ی دلتا، شبکه‌های عمیق
تصادفی / پویا (stochastic / dynamical)	فرایندهای پرنویز که در زمان پیش می‌روند	random walk، drift-diffusion، Rescorla–Wagner
بیزی (احتمالاتی)	شناخت به‌عنوان استنباط احتمالاتی	مدل‌های مشاهده‌گر بیزی

> **مراقب باشید:** «مدل‌سازی بیزی» در این درس دو معنای متفاوت دارد. (الف) **مدل‌های بیزی شناخت** ادعا می‌کنند که ذهن استنباط بیزی انجام می‌دهد (هفته‌ی ۱۵). (ب) **تحلیل داده‌ی بیزی** روشی است که ما پژوهشگران با آن پارامترهای هر مدلی را، بیزی یا غیربیزی، برآورد می‌کنیم (هفته‌های ۹–۱۳). هفته‌های ۹–۱۳ بیشتر درباره‌ی (ب) هستند.

۴. سه سطح تحلیل Marr

David Marr پیشنهاد کرد که یک سیستم پردازش اطلاعات را در سه سطح مکمل تحلیل کنیم:

سطح	سؤال	مثال تصمیم‌گیری
محاسباتی (computational)	چه مسئله‌ای حل می‌شود و چرا؟	انتخاب گزینه‌ی درست با برقراری تعادل بین سرعت و دقت
الگوریتمی / بازنمایی (algorithmic)	چه بازنمایی‌ها و رویه‌هایی آن را حل می‌کنند؟	انباشت شواهد پرنویز تا رسیدن به یک مرز
پیاده‌سازی (implementational)	به‌طور فیزیکی چگونه محقق می‌شود؟	نرخ شلیک نورون‌ها که تا یک آستانه بالا می‌رود

مدل‌های هنجاری معمولاً در سطح محاسباتی‌اند، مدل‌های فرایندی در سطح الگوریتمی، و مدل‌های علوم اعصاب محاسباتی در سطح پیاده‌سازی. بیشتر مدل‌های این درس **در سطح الگوریتمی** هستند.

۵. مدل یک ماشین تولید داده است

مهم‌ترین ایده برای ادامه‌ی درس: **مدل یک توزیع احتمال روی داده‌های ممکن تعریف می‌کند.**

$$\mathbf{y} \sim p(\mathbf{y} \mid \boldsymbol{\theta}, \mathcal{M})$$

این را این‌طور بخوانید: «تحت مدل $\mathcal{M}$ با پارامترهای $\boldsymbol{\theta}$، داده‌ی $\mathbf{y}$ از توزیع p تولید می‌شود.» بسیاری از مدل‌ها این را به یک هسته‌ی قطعی به‌علاوه‌ی نویز تقسیم می‌کنند، مثلاً $y_i = f(x_i; \boldsymbol{\theta}) + \varepsilon_i$ (هفته‌ی ۲). بعضی دیگر، مثل random walk، از اول تا آخر تصادفی‌اند.

این دو جهت استدلال به ما می‌دهد:

جهت	داده‌شده	خواسته‌شده	نام	هفته‌ها
مستقیم (forward)	$\boldsymbol{\theta}$	داده‌های ممکن $\mathbf{y}$	شبیه‌سازی / پیش‌بینی	۱–۲
معکوس (inverse)	$\mathbf{y}$ مشاهده‌شده	$\boldsymbol{\theta}$ محتمل	برآورد پارامتر / برازش	۳–۵، ۹–۱۳

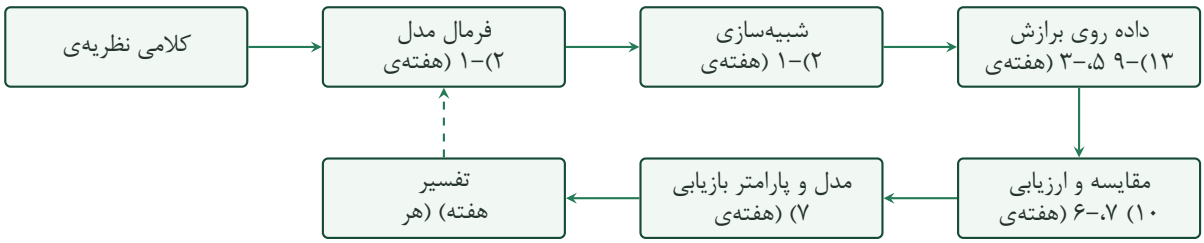
مسئله‌ی معکوس سخت‌تر است و همان چیزی است که منظورمان از «برازش مدل روی داده» است. چون همیشه می‌توان مدل را در جهت مستقیم اجرا کرد، می‌توانیم روش‌های برازشمان را هم آزمون کنیم: از پارامترهای **معلوم** $\boldsymbol{\theta}^*$ داده شبیه‌سازی کنیم، برازش کنیم، و ببینیم آیا $\boldsymbol{\theta}^*$ را پس می‌گیریم (بازیابی پارامتر یا parameter recovery، هفته‌ی ۷).

خواندن ریاضی $\mathbf{y} \sim p(\mathbf{y} \mid \boldsymbol{\theta}, \mathcal{M})$ این‌طور خوانده می‌شود: «داده‌ی $\mathbf{y}$ از توزیع احتمال p تولید می‌شود، به شرط مقادیر پارامتر $\boldsymbol{\theta}$ و مدل $\mathcal{M}$.»

- $\mathbf{y}$ (پررنگ) یک فهرست از مشاهده‌هاست؛ مثلاً ۲۰۰ پاسخ یک شرکت‌کننده.
- علامت $\sim$ یعنی «به‌طور تصادفی تولید می‌شود از». یادآوری می‌کند که یک مدل با پارامترهای ثابت هر بار داده‌ی متفاوتی می‌دهد، همان‌طور که یک آدم هم در هر trial دقیقاً یکسان پاسخ نمی‌دهد.
- خط عمودی $\mid$ یعنی «به شرطِ» یا «با فرضِ». هر چیزی سمت راستش ثابت است: معادله‌های مدل ($\mathcal{M}$) و عددهایی که در آن‌ها می‌گذاریم ($\boldsymbol{\theta}$).
- $\boldsymbol{\theta}$ (تتا، پررنگ) همه‌ی پارامترها را کنار هم می‌گذارد؛ مثلاً برای random walk داریم $\boldsymbol{\theta} = (v, a, z)$.

مثال. برای سکه‌ای با $P(\text{heads}) = 0.6$، مدل این است: «هر پرتاب با احتمال θ شیر می‌آید»، $\boldsymbol{\theta} = 0.6$، و $\mathbf{y}$ می‌تواند (شیر، خط، شیر، شیر، خط) باشد. دوباره اجرا کنید، دنباله‌ی دیگری می‌گیرید. جهت مستقیم: θ را انتخاب کن و $\mathbf{y}$ را شبیه‌سازی کن. جهت معکوس (برازش، هفته‌های ۳ تا ۵): $\mathbf{y}$ را ببین و یک θ خوب پیدا کن.

۶. مسیر مدل‌سازی (نقشه‌ی راه ما)



شکل ۱.۱: چرخه‌ی مدل‌سازی شناختی، بازطراحی شده از نمودار هفته‌ی اول

هر lab در این درس نسخه‌ای از این چرخه را اجرا می‌کند. امروز روی **فرمال‌سازی** ← **شبیه‌سازی** ← **تفسیر** تمرکز می‌کنیم، به‌علاوه‌ی پیش‌نمایش کوچکی از **برازش**.

۷. اولین مدل ما: random walk تا رسیدن به مرز

از کلامی به فرمال. شواهد یک عدد واحد X است که از z شروع می‌شود. در هر گام زمانی **یک واحد بالا** می‌رود (شواهد به نفع پاسخ درست) یا **یک واحد پایین** (شواهد به نفع پاسخ غلط). وقتی X به مرز بالا a (پاسخ درست) یا مرز پایین 0 (خطا) برسد، حرکت متوقف می‌شود.

$$X_0 = z, \qquad X_n = X_{n-1} + \delta_n, \qquad \delta_n = \begin{cases} +1 & \text{with probability } \frac{1+v}{2} \\ -1 & \text{with probability } \frac{1-v}{2} \end{cases}$$

- $v \in (-1, 1)$ همان drift است، یعنی میانگین گام $\mathbb{E}[\delta_n] = v$. نماینده‌ی **کیفیت شواهد** است: محرک‌های آسان v بزرگ می‌دهند.
- a **فاصله‌ی مرزها** (boundary separation) است و نماینده‌ی **احتیاط**: فاصله‌ی بیشتر یعنی شواهد بیشتری لازم است.
- z **نقطه‌ی شروع** است ($0 < z < a$). با $z = a/2$ تصمیم‌گیرنده بی‌سوگیری است.
- تعداد گام‌ها تا رسیدن به مرز، T، از این راه به زمان واکنش نگاشت می‌شود:

$$\mathrm{RT} = t_0 + T\,\Delta t,$$

که در آن t_0 (non-decision time: non-decision time) رمزگذاری به‌علاوه‌ی اجرای حرکتی) و Δt مدت هر گام است.

پیش‌بینی‌های تحلیلی. فرض کنید $r = \frac{1-v}{1+v}$. برای $v \neq 0$، احتمال پاسخ درست و میانگین تعداد گام‌ها برابرند با:

$$P_c = \frac{1 - r^z}{1 - r^a}, \qquad \mathbb{E}[T] = \frac{a\,P_c - z}{v}.$$

همین دو معادله سؤال‌های بخش انگیزه را حل می‌کنند:

- افزایش a هم P_c **و هم** $\mathbb{E}[T]$ را بالا می‌برد: یک trade-off **سرعت–دقت** (speed–accuracy trade-off).
- افزایش v احتمال P_c را بالا می‌برد ولی $\mathbb{E}[T]$ را **پایین** می‌آورد: محرک‌های آسان‌تر هم سریع‌ترند و هم دقیق‌تر.

پس این دو دست‌کاری ردپای متفاوتی در داده‌ها می‌گذارند. همین است که به ما اجازه می‌دهد احتیاط و کیفیت شواهد را جداگانه اندازه بگیریم.

پیشرفته: فرمول‌ها از کجا می‌آیند. P_c همان نتیجه‌ی کلاسیک ورشکستگی قمارباز (gambler's ruin) است. فرض کنید $h(x)$ احتمال رسیدن به a پیش از 0 با شروع از x باشد. شرطی کردن روی گام اول می‌دهد $h(x) = \frac{1+v}{2}h(x+1) + \frac{1-v}{2}h(x-1)$ با $h(0) = 0$ و $h(a) = 1$. حل این معادله‌ی تفاضلی می‌دهد $h(x) = (1 - r^x)/(1 - r^a)$. برای $\mathbb{E}[T]$ از اتحاد ***Wald*** استفاده کنید: موقعیت نهایی در $\mathbb{E}[X_T] = z + v\,\mathbb{E}[T]$ صدق می‌کند. چون X_T با احتمال P_c برابر a و در غیر این صورت 0 است، $\mathbb{E}[X_T] = aP_c$، و مرتب کردن معادله می‌دهد $\mathbb{E}[T] = (aP_c - z)/v$. وقتی اندازه‌ی گام و Δt با هم کوچک شوند، random walk به **مدل** drift-diffusion (هفته‌ی ۱۴) تبدیل می‌شود.

پیشرفته: ویژگی‌ای که نقطه‌ضعف از آب درمی‌آید. با شروع بی‌سوگیری ($z = a/2$)، random walk ساده پیش‌بینی می‌کند که پاسخ‌های درست و غلط **توزیع زمان واکنش یکسانی** دارند. در داده‌های واقعی، وقتی بر دقت تأکید می‌شود خطاها اغلب کندتر از پاسخ‌های درست‌اند و گاهی تحت تأکید بر سرعت سریع‌تر. مدل ساده هیچ‌کدام از این الگوها را نمی‌تواند تولید کند. اضافه کردن تغییرپذیری drift یا نقطه‌ی شروع از trialای به trial دیگر می‌تواند (تمرین ۵ در lab). پیدا کردن جایی که مدل شکست می‌خورد دقیقاً همان راه بهتر شدن مدل‌هاست.

خواندن ریاضی **قاعده‌ی به‌روزرسانی.** $X_n = X_{n-1} + \delta_n$ یعنی: شواهد الان = شواهد یک قدم قبل + یک قدم جدید. قدم δ_n برابر $+1$ یا -1 است. احتمال $+1$ برابر $\frac{1+v}{2}$ است. با $v = 0$ این احتمال 0.5 است (سکه‌ی سالم: هیچ اطلاعاتی نیست). با $v = 0.2$ برابر 0.6 است، پس مسیر به‌طور میانگین رو به بالا می‌رود. میانگین قدم برابر $v = 0.2 = (+1)(0.6) + (-1)(0.4)$ است؛ به همین دلیل به v می‌گوییم drift (رانش).

فرمول دقت. $P_c = \dfrac{1-r^z}{1-r^a}$ با $r = \dfrac{1-v}{1+v}$.

- r نسبت «احتمال قدم پایین / احتمال قدم بالا» است. با $v = 0.2$ داریم $r = 0.4/0.6 = 2/3$. هرچه r کوچک‌تر باشد، مسیر تقریباً همیشه بالا می‌رود.
- وقتی z و a بزرگ باشند، r^z و r^a عددهای کوچکی می‌شوند و P_c به ۱ نزدیک می‌شود. این همان ریاضیِ پشت جمله‌ی «احتیاط بیشتر (یعنی a بزرگ‌تر) دقت بیشتری می‌دهد» است.
- لازم نیست فرمول را اثبات کنید (کادر پیشرفته را ببینید). کافی است عدد بگذارید و آن را با شبیه‌سازی مقایسه کنید، همان کاری که در lab می‌کنیم.

فرمول زمان. $\mathbb{E}[T] = \dfrac{aP_c - z}{v}$. $\mathbb{E}[\cdot]$ یعنی «میانگین روی تعداد زیادی trial». صورت کسر مسافتی است که مسیر به‌طور میانگین طی می‌کند (با احتمال P_c در a و در غیر این صورت در 0 تمام می‌شود و از z شروع کرده بود). تقسیم بر سرعت میانگین v تعداد میانگین قدم‌ها را می‌دهد؛ درست مثل زمان = مسافت / سرعت.

زمان واکنش. $\mathrm{RT} = t_0 + T\,\Delta t$: یک بخش ثابت t_0 (دیدن محرک و فشار دادن کلید) به‌علاوه‌ی زمان تصمیم، یعنی تعداد قدم‌ها ضرب در مدت هر قدم.

برای یک مهندس شما این مدل را با نام دیگری می‌شناسید.

- **آشکارسازی ترتیبی** (sequential detection). random walk نسخه‌ی گسسته‌ی **آزمون نسبت احتمال ترتیبی** Wald (SPRT) است: نسبت لگاریتم درست‌نمایی مشاهده‌ها را جمع کن و به محض اینکه از یک آستانه‌ی بالا یا پایین گذشت، تصمیم بگیر. تحت بعضی فرض‌ها، SPRT برای احتمال خطای مشخص، کمترین تعداد میانگین مشاهده را لازم دارد؛ یکی از دلایلی که ممکن است مغز از این راهبرد استفاده کند.
- drift ≈ **نسبت سیگنال به نویز.** هر قدم «سیگنال + نویز» است. drift v میانگین قدم است و تصادفی بودن قدم همان نویز است، پس v نقش SNR هر نمونه را دارد. محرک واضح‌تر یعنی SNR بالاتر.
- **فاصله‌ی مرزها** ≈ **آستانه‌ی تصمیم.** بالا بردن آستانه احتمال خطا را کم ولی تأخیر آشکارسازی را زیاد می‌کند: همان بده‌بستان کلاسیک بین نرخ خطا و تأخیر در آشکارسازی ترتیبی. در روان‌شناسی به این **بده‌بستان سرعت و دقت** می‌گویند.
- **نقطه‌ی شروع** ≈ prior. شروع از نزدیکی یکی از مرزها مثل این است که نسبت لگاریتم درست‌نمایی اولیه صفر نباشد؛ یعنی یک prior به نفع یکی از فرضیه‌ها.
- non-decision time ≈ **تأخیر ثابت پردازش.** تأخیر حسگر/رمزگذاری به‌علاوه‌ی تأخیر عملگر (حرکت دست) که به هر پاسخ اضافه می‌شود.
- **چیزی که برای یک مهندس تازه است:** در مهندسی ما آشکارساز را طراحی می‌کنیم. اینجا یک آشکارساز انسانی را مشاهده می‌کنیم و سعی می‌کنیم پارامترهایش (SNR، آستانه) را از روی تصمیم‌ها و زمان تصمیم‌هایش **استنباط** کنیم. این مسئله‌ی معکوس موضوع کل این درس است.

۸. نمادگذاری کل درس

این جدول در **همه‌ی** هفته‌ها استفاده می‌شود. وقتی هفته‌ای نمادی را معرفی می‌کند، همان معنای این جدول را دارد.

داده و طرح آزمایش

نماد	معنا	اولین استفاده
y_i، $\mathbf{y} = (y_1, \dots, y_N)$	مشاهده‌ی i؛ بردار همه‌ی مشاهدات	هفته‌ی ۱
N	تعداد مشاهدات (trial)ها	هفته‌ی ۱

نماد	معنا	اولین استفاده
x_i	شرط آزمایشی / متغیر مستقل مشاهده‌ی i	هفته‌ی ۲
$j = 1, \ldots, J$	اندیس شرکت‌کننده؛ تعداد شرکت‌کنندگان	هفته‌ی ۵

مدل‌ها و پارامترها

نماد	معنا	اولین استفاده
$\mathcal{M}$، $\mathcal{M}_1, \mathcal{M}_2$	یک مدل؛ مدل‌های رقیب	هفته‌ی ۱
$\boldsymbol{\theta}$	بردار پارامترهای آزاد	هفته‌ی ۱
k	تعداد پارامترهای آزاد	هفته‌ی ۱
$\boldsymbol{\theta}^*$	مقادیر واقعی (تولیدکننده‌ی داده) پارامترها در شبیه‌سازی	هفته‌ی ۱
$\hat{\boldsymbol{\theta}}$	برآورد $\boldsymbol{\theta}$	هفته‌ی ۳
$f(x; \boldsymbol{\theta})$	بخش قطعی پیش‌بینی مدل	هفته‌ی ۲
$\hat{y}_i$	پیش‌بینی مدل برای مشاهده‌ی i	هفته‌ی ۳
ε_i	جمله‌ی نویز (خطا)	هفته‌ی ۲

احتمال

نماد	معنا
$P(\cdot)$	احتمال یک رویداد
$p(\cdot)$	تابع جرم یا چگالی احتمال
$y \sim \mathcal{D}$	«y توزیع $\mathcal{D}$ دارد»
$\mathcal{N}(\mu, \sigma)$	توزیع نرمال با میانگین μ و **انحراف معیار** σ (مثل scipy و PyMC)
$\text{Bernoulli}(\theta)$، $\text{Binomial}(n, \theta)$	توزیع‌های برنولی و دوجمله‌ای با احتمال موفقیت θ
$\text{Beta}(a_0, b_0)$، $\text{Uniform}(l, u)$	توزیع‌های Beta و یکنواخت
Φ، Φ^{-1}	تابع توزیع تجمعی (CDF) نرمال استاندارد و معکوس آن
$\mathbb{E}[\cdot]$، $\text{Var}[\cdot]$	امید ریاضی و واریانس

برازش، ارزیابی و استنباط بیزی

نماد	معنا	اولین استفاده
SSE، MSE، RMSD	مجموع مربعات خطا، میانگین مربعات خطا، ریشه‌ی میانگین مربع انحراف	هفته‌ی ۳
$L(\boldsymbol{\theta}) = p(\mathbf{y} \mid \boldsymbol{\theta}, \mathcal{M})$	درست‌نمایی (likelihood)	هفته‌ی ۴

نماد	معنا	اولین استفاده
$\ell(\boldsymbol{\theta}) = \ln L(\boldsymbol{\theta})$؛ NLL $= -\ell$	لگاریتم درست‌نمایی (log-likelihood)؛ منفی لگاریتم درست‌نمایی	هفته‌ی ۴
K	تعداد بخش‌ها (folds) در cross-validation (با k یکی نیست!)	هفته‌ی ۶
AIC، BIC	معیارهای اطلاعاتی آکائیکه و بیزی	هفته‌ی ۷
$p(\boldsymbol{\theta})$، $p(\boldsymbol{\theta} \mid \mathbf{y})$	پیشین (prior)؛ پسین (posterior)	هفته‌ی ۹
$p(\mathbf{y} \mid \mathcal{M})$	marginal likelihood (شواهد یا evidence)	هفته‌ی ۱۰
BF_{12}	Bayes factor برای $\mathcal{M}_1$ در برابر $\mathcal{M}_2$	هفته‌ی ۱۰
$\boldsymbol{\theta}^{(s)}$، $s = 1, \ldots, S$	نمونه‌ی s-ام MCMC؛ تعداد نمونه‌ها	هفته‌ی ۱۱
C	تعداد زنجیره‌های MCMC	هفته‌ی ۱۲
$\hat{R}$، ESS	ضریب کاهش مقیاس بالقوه (R-hat)؛ اندازه‌ی مؤثر نمونه	هفته‌ی ۱۲

نمادهای مخصوص هر مدل

مدل	نمادها	اولین استفاده
drift-diffusion / random walk	drift rate v؛ فاصله‌ی مرزها a؛ z نقطه‌ی شروع؛ non-decision time t_0؛ مدت هر گام Δt؛ تعداد گام‌ها T	هفته‌ی ۱ و ۱۴
نظریه‌ی تشخیص علامت	نرخ hit H؛ نرخ false alarm F؛ d' حساسیت؛ ملاک (criterion) c	هفته‌ی ۲
منحنی‌های فراموشی	فاصله‌ی نگهداری (retention interval)؛ t سطح اولیه A؛ نرخ زوال λ؛ نمای زوال توانی d	هفته‌ی ۲
GCM (دسته‌بندی)	وزن‌های توجه w_m؛ حساسیت c	هفته‌ی ۱۴
یادگیری تقویتی	نرخ یادگیری α؛ inverse temperature β؛ ارزش گزینه‌ی $Q_t(o)$ در trial t	هفته‌ی ۱۵

نمادهای دومعنایی (چون در منابع رایج‌اند نگه داشته شده‌اند): c ملاک SDT است، جز در هفته‌ی ۱۴ که حساسیت GCM است. t در مدل‌های فراموشی فاصله‌ی نگهداری و در یادگیری تقویتی اندیس trial است. α فقط به معنای نرخ یادگیری در یادگیری تقویتی است. هیچ‌وقت α را برای سطح معناداری به کار نمی‌بریم.

برای مدرس

- **با سؤال‌ها شروع کنید، نه با مدل.** نظریه‌ی کلامی را بلند بخوانید و از دانشجوها بخواهید به چهار سؤال بخش مقدمه جواب دهند. با هم اختلاف نظر پیدا می‌کنند. همین اختلاف، دلیل وجود مدل‌های فرمال است.

- random walk **را اجرا کنید.** روی تخته یک خط عمودی بکشید، با یک خط بالا («درست») و یک خط پایین («خطا»). یک دانشجو تاس بیندازد: ۱ تا ۴ یعنی بالا، ۵ و ۶ یعنی پایین ($v \approx 0.33$). قدم‌ها را تا رسیدن به یکی از خط‌ها بشمارید. سه بار تکرار کنید و سه trial با زمان‌های واکنش متفاوت دارید. بعد خط‌ها را از هم دورتر کنید و دوباره امتحان کنید.
- **در این هفته ریاضی را سبک نگه دارید.** دانشجوها فقط باید فرمول‌های P_c و $\mathbb{E}[T]$ را استفاده کنند، نه اثبات. در lab نشان دهید که عددها با شبیه‌سازی جور درمی‌آیند؛ پیام اصلی همین است (شبیه‌سازی و تحلیل با هم توافق دارند).
- **سؤال‌های رایج دانشجوها.**
  - «آیا شواهد واقعاً قدم‌های گسسته است؟» نه، این یک ساده‌سازی است. هفته‌ی ۱۴ نسخه‌ی پیوسته (drift-diffusion) را نشان می‌دهد که پیش‌بینی‌های مشابهی دارد.
  - «چرا میانگین زمان واکنش را با *t-test* مقایسه نکنیم؟» t-test می‌گوید گروه‌ها فرق دارند؛ مدل می‌گوید چطور فرق دارند (احتیاط در برابر کیفیت شواهد).
  - «کدام مدل درست است؟» هیچ‌کدام. همه‌ی مدل‌ها ساده‌سازی‌اند؛ می‌پرسیم کدام مفید است (جمله‌ی Box).
- **مدیریت زمان.** بخش‌های ۳ و ۴ (انواع مدل، Marr) را در صورت نیاز می‌شود به ۱۰ دقیقه کوتاه کرد. بخش ۷ را حذف نکنید: کل lab به آن وابسته است.

۵.۱.۱ مثال حل‌شده

شرایط. یک تصمیم‌گیرنده‌ی بی‌سوگیری با drift $v = 0.2$، فاصله‌ی مرزها $a = 6$ و نقطه‌ی شروع $z = 3$. non-decision time $t_0 = 300$ ms؛ هر گام $\Delta t = 20$ ms طول می‌کشد.

قدم ۱: احتمال گام‌ها. $P(\delta = +1) = (1 + 0.2)/2 = 0.6$ و $P(\delta = -1) = 0.4$.

قدم ۲: شبیه‌سازی دستی یک trial. اعداد تصادفی یکنواخت u_n بکشید. اگر $u_n < 0.6$ بالا بروید، وگرنه پایین.

گام n	u_n	δ_n	X_n
۰	—	—	۳
۱	۰.۳۱	+۱	۴
۲	۰.۷۲	−۱	۳
۳	۰.۵۵	+۱	۴
۴	۰.۱۲	+۱	۵
۵	۰.۴۸	+۱	**۶** = a ← توقف

مسیر به مرز بالا می‌رسد: یک پاسخ **درست** بعد از $T = 5$ گام، پس $\text{RT} = 300 + 5 \times 20 = 400$ ms.

قدم ۳: دقت تحلیلی. $r = (1 - 0.2)/(1 + 0.2) = 2/3$، پس $r^3 = 8/27 \approx 0.296$ و $r^6 = 64/729 \approx 0.088$.

$$P_c = \frac{1 - 8/27}{1 - 64/729} = \frac{1}{1 + 8/27} = \frac{27}{35} \approx 0.771.$$

(وقتی $z = a/2$، فرمول به $P_c = 1/(1 + r^{a/2})$ ساده می‌شود.)

قدم ۴: میانگین تحلیلی زمان واکنش.

$$\mathbb{E}[T] = \frac{6 \times 0.771 - 3}{0.2} = \frac{57/35}{0.2} \approx 8.14 \text{ steps}, \qquad \mathbb{E}[\text{RT}] = 300 + 8.14 \times 20 \approx 462.9 \text{ ms}.$$

قدم ۵: دو دست‌کاری، دو ردپا.

شرط	v	a $(z = a/2)$	P_c	$\mathbb{E}[T]$	$\mathbb{E}[\text{RT}]$ (ms)
پایه	۲.۰	۶	۷۷۱.۰	۱۴.۸	۹.۴۶۲
«دقیق باشید!» (احتیاط بیشتر)	۲.۰	۱۰	۸۸۴.۰	۱۸.۱۹	۶.۶۸۳
محرک آسان‌تر (شواهد بهتر)	۳.۰	۶	۸۶۵.۰	۳۰.۷	۰.۴۴۶

تفسیر. دستور «دقیق باشید» حدود ۱۱ درصد دقت بیشتر می‌خرد، به قیمت حدود ۲۲۰ ms. محرک آسان‌تر افزایش دقت مشابهی می‌دهد، در حالی که پاسخ‌ها را کمی سریع‌تر هم می‌کند. پژوهشگری که فقط به دقت نگاه کند نمی‌تواند این دو وضعیت را از هم تشخیص دهد. مدل، با استفاده‌ی هم‌زمان از دقت و زمان واکنش، آن‌ها را به دو علت روان‌شناختی متفاوت نسبت می‌دهد (احتیاط در برابر کیفیت شواهد).

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. نصب یک محیط نرم‌افزاری سالم روی لپ‌تاپ خودتان، از جمله ابزارهای بیزی که در هفته‌ی ۱۳ لازم‌اند.
۲. تمرین کار پایه با numpy/matplotlib: اعداد تصادفی، برداری‌سازی (vectorization)، رسم نمودار.
۳. پیاده‌سازی مدل random walk، شبیه‌سازی یک آزمایش، و **وارسی** شبیه‌سازی با فرمول‌های تحلیلی.
۴. استفاده از مدل برای **تفسیر** trade-off سرعت–دقت.
۵. اولین تجربه‌ی **برازش**: بازیابی پارامترهای پنهان یک «شرکت‌کننده‌ی مرموز»، **ارزیابی** برازش و **تفسیر** نتیجه.

زمان‌بندی: بخش A ۳۵ دقیقه · بخش B ۱۵ دقیقه · بخش C ۳۰ دقیقه · بخش D ۱۵ دقیقه · بخش E ۲۵ دقیقه. تمرین‌هایی که در lab تمام نشوند در خانه تمام می‌شوند.

بخش A: نصب محیط نرم‌افزاری (۳۵ دقیقه)

از Miniforge استفاده می‌کنیم، یک نصب‌کننده‌ی رایگان برای `conda` که از کانال `conda-forge` استفاده می‌کند. این مطمئن‌ترین راه نصب PyMC روی Windows، macOS و Linux است.

۱. Miniforge را از سایت conda-forge دانلود و نصب کنید (سیستم‌عامل خود را انتخاب کنید؛ گزینه‌های پیش‌فرض را نگه دارید).
۲. فایل زیر را با نام `environment.yml` در پوشه‌ی درس ذخیره کنید:

```
# Cognitive Modeling course environment (same as environment.yml in the
↪  course repository)
name: cogmod
channels:
  - conda-forge
dependencies:
  - python=3.12
  - numpy>=1.26
  - scipy>=1.11
  - pandas>=2.1
  - matplotlib>=3.8
  - jupyterlab
  - pymc>=6.3    # Bayesian modeling (needed from Week 13)
  - arviz>=1.3   # MCMC diagnostics
```

۳. Miniforge Prompt (در Windows) یا یک terminal (در macOS/Linux) را باز کنید، به پوشه‌ی درس بروید و محیط را بسازید. بار اول ۵ تا ۱۵ دقیقه طول می‌کشد.

```
conda env create -f environment.yml
```

```
conda activate cogmod
```

۴. این اسکریپت را با نام `check_install.py` ذخیره کنید و با `pythoncheck_install.py` اجرا کنید. با افزودن `sample--` یک مدل کوچک PyMC هم اجرا می‌شود؛ اجرای اول حدود یک دقیقه طول می‌کشد چون PyMC کامپایل می‌کند.

> · Code · **کد:** `code/check_install.py` (save and run it as a separate script ·
> به‌صورت یک اسکریپت جدا اجرا شود)

۵. JupyterLab را با `jupyterlab` اجرا کنید و یک notebook با نام `week01_lab.ipynb` بسازید. بقیه‌ی کدها را در همین notebook، هر بلوک در یک cell، اجرا کنید.

> **اگر اسکریپت هشداری مثل** «g++ not available» **نشان داد:** PyMC باز هم کار می‌کند ولی خیلی کندتر. معمولاً یعنی PyMC با `pip` نصب شده، نه از محیط conda-forge بالا. نصب conda-forge معمولاً compiler مورد نیاز PyMC را هم می‌آورد [پیش از هفته‌ی ۱ روی یک کامپیوتر Windows در lab بررسی شود]. محیط را دوباره با `condaenvcreate-fenvironment.yml` بسازید.

اگر نصب شکست خورد: lab امروز را در Google Colab انجام دهید (numpy، scipy، pandas و matplotlib در آن از قبل نصب‌اند) و نصب محلی را پیش از هفته‌ی ۳ با کمک مدرس درست کنید. نصب PyMC باید تا هفته‌ی ۱۲ کار کند.

بخش B: گرم کردن با Python (۱۵ دقیقه)

کد: Code · سلول ۱ · cell ۱، `code/week01.py`

خروجی مورد انتظار: نسبتی نزدیک به ۰.۶ (با این seed برابر ۰.۵۷۴) و منحنی نسبت تجمعی که اول نوسان دارد و بعد نزدیک خط‌چین آرام می‌گیرد.

بخش C: پیاده‌سازی، شبیه‌سازی و وارسی random walk (۳۰ دقیقه)

کد: Code · سلول ۲ · cell ۲، `code/week01.py`

اول ببینید مدل چه می‌کند: چند مسیر شواهد را رسم کنید.

کد: Code · سلول ۳ · cell ۳، `code/week01.py`

حالا یک آزمایش کامل را شبیه‌سازی کنید و نتیجه را با پیش‌بینی‌های تحلیلی مقایسه کنید. **همیشه شبیه‌سازی را با چیزی که جوابش را می‌دانید مقایسه کنید**؛ این عادت در این ترم بارها نجاتتان می‌دهد.

کد: Code · سلول ۴ · cell ۴، `code/week01.py`

کد: Code · سلول ۵ · cell ۵، `code/week01.py`

خروجی مورد انتظار (seed ۴۲):

```
Accuracy   simulated 0.764 | analytic 0.771
Mean steps simulated 8.27  | analytic 8.14
Mean RT    simulated 465.3 ms | analytic 462.9 ms

Mean RT by response (1 = correct, 0 = error):
        count   mean
choice
0        1180  466.1
1        3820  465.1
```

به این‌ها دقت کنید: - شبیه‌سازی در حد نویز نمونه‌گیری با مقادیر تحلیلی جور است. - توزیع‌های زمان واکنش **چوله به راست** هستند (یک دنباله‌ی بلند از پاسخ‌های کند)؛ این شکل معمول توزیع‌های واقعی زمان واکنش است. - زمان واکنش پاسخ‌های درست و غلط تقریباً یکسان است (کادر «پیشرفته» در بخش ۷ جزوه را ببینید).

بخش D: تفسیر trade-off سرعت–دقت (۱۵ دقیقه)

Code · **کد:** `code/week01.py`، cell ۶ · سلول ۶

خروجی مورد انتظار: سه منحنی که از پایین سمت چپ به سمت ۰.۱ بالا می‌روند. حرکت روی یک منحنی (افزایش a) سرعت را با دقت معاوضه می‌کند. حرکت بین منحنی‌ها (افزایش v) دقت را با زمان واکنش برابر یا کمتر بالا می‌برد. جدول مثال حل‌شده را بازتولید می‌کند: مثلاً $v = 0.2, a = 10$ دقت ۸۸۴۰. و میانگین زمان واکنش ۶۶۸۳ ms می‌دهد.

با بغل‌دستی‌تان بحث کنید: پژوهشگری می‌بیند که یک دارو شرکت‌کننده‌ها را کندتر و دقیق‌تر می‌کند. به کدام پارامتر مشکوک می‌شوید؟ اگر دارو آن‌ها را کندتر و کم‌دقت‌تر می‌کرد چه؟

بخش E: اولین برازش، ارزیابی و تفسیر (۲۵ دقیقه)

مدرس فایل `week01_mystery.csv` را به شما می‌دهد که داده‌های یک «شرکت‌کننده‌ی مرموز» است (۱۰۰۰ trial، ستون‌های `choice` و `rt`). اگر فایل را ندارید، کد زیر یک مجموعه‌داده‌ی معادل با پارامترهایی که پشت یک seed پنهان شده‌اند می‌سازد. **دزدکی نگاه نکنید**: سعی کنید آن‌ها را بازیابی کنید.

فرض می‌کنیم $t_0 = 300$ ms و $\Delta t = 20$ ms معلوم‌اند و $z = a/2$. فقط v و a آزادند ($k = 2$).

Code · **کد:** `code/week01.py`، cell ۷ · سلول ۷

برازش با جستجوی شبکه‌ای .(grid search) برای هر ترکیب v و a روی یک شبکه، دقت و میانگین زمان واکنش پیش‌بینی‌شده را حساب کنید و فاصله‌شان با مقادیر مشاهده‌شده را بسنجید. هر اختلاف بر حسب واحد خطای استاندارد بیان می‌شود تا دقت و زمان واکنش مقیاس قابل مقایسه‌ای داشته باشند. هفته‌ی ۳ این ایده را به‌طور کامل توضیح می‌دهد.

Code · **کد:** `code/week01.py`، cell ۸ · سلول ۸

ارزیابی برازش. فقط دو آماره‌ی خلاصه (دقت و میانگین زمان واکنش) را برازش کردیم. آزمون قوی‌تر این است که ببینیم مدل چیزی را که برازش نکرده‌ایم هم بازتولید می‌کند یا نه: **شکل** توزیع زمان واکنش. quantileهای زمان واکنش پاسخ‌های درست در داده را با quantileهای یک شبیه‌سازی بزرگ با بهترین پارامترها مقایسه می‌کنیم.

Code ۰ **کد:** `code/week01.py`، cell ۹ ۰ سلول ۹

خروجی مورد انتظار (داده‌ی جایگزین). فقط بعد از اجرای برازش باز کنید.

```
Observed: accuracy = 0.836, mean RT = 746.4 ms (N = 1000)
Best fit: v = 0.15, a = 10 (pred. accuracy 0.819, pred. RT 725.7 ms,
↪  discrepancy 5.78)

   quantile  observed   model
0       0.1     440.0   440.0
1       0.3     520.0   520.0
2       0.5     640.0   640.0
3       0.7     800.0   800.0
4       0.9    1200.0  1160.0
```

مقادیر پنهان $v^* = 0.16$ و $a^* = 10$ بودند. جستجوی شبکه‌ای a را دقیقاً و v را با فاصله‌ی یک گام شبکه (۱۵.۰) بازیابی کرد. این اختلاف کوچک باگ نیست: با ۱۰۰۰ trial، دقت و میانگین زمان واکنش مشاهده‌شده به خاطر نویز نمونه‌گیری با مقادیر واقعی فرق دارند، پس بهترین پارامترها هم کمی فرق می‌کنند. (هفته‌ی ۵ نشان می‌دهد چطور برای چنین برآوردهایی بازه‌ی عدم قطعیت بسازیم.) زمان‌های واکنش مضرب ۲۰ ms هستند و به همین دلیل بسیاری از quantileها دقیقاً برابرند. مدل شکل توزیع را خوب بازتولید می‌کند و فقط دنباله‌ی کند را کمی کمتر برآورد می‌کند (quantile ۹.۰).

سؤال‌های تفسیری (برای هرکدام ۲ تا ۳ جمله در notebook بنویسید): ۱. به زبان روان‌شناختی، v و a بازیابی‌شده درباره‌ی این شرکت‌کننده چه می‌گویند؟ ۲. برازش فقط از دو عدد داده استفاده کرد. چرا مقایسه‌ی quantileها بررسی قانع‌کننده‌تری از خود مقدار ناهمخوانی (discrepancy) است؟ ۳. اگر این شرکت‌کننده دوباره با دستور «تا جای ممکن سریع باشید» آزمون شود، طبق مدل کدام پارامتر باید تغییر کند و کدام ثابت بماند؟

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆ (نویز نمونه‌گیری). مدل پایه ($v = 0.2$، $a = 6$) را با $N = 20$، 100 و 1000 trial، هرکدام با پنج seed مختلف، شبیه‌سازی کنید. جدولی از دقت‌های مشاهده‌شده بسازید. پراکندگی‌شان را با خطای استاندارد $\sqrt{P_c(1-P_c)/N}$ مقایسه کنید. انتظار: با $N = 20$ دقت به‌راحتی بین حدود ۶.۰ تا ۹۵.۰ تغییر می‌کند. پراکندگی تقریباً به نسبت $1/\sqrt{N}$ کم می‌شود.

تمرین ۲ ⋆ (دو شرط). یک شرط «سرعت» ($a = 4$) و یک شرط «دقت» ($a = 10$) با $v = 0.2$ یکسان و هرکدام ۱۰۰۰ trial شبیه‌سازی کنید. دقت و میانگین زمان واکنش هر شرط را گزارش کنید و هر دو توزیع زمان واکنش را رسم کنید. کدام جنبه‌ی توزیع زمان واکنش بیشتر تغییر می‌کند: کمینه، مُد، یا دنباله؟

تمرین ۳ ⋆⋆ (سوگیری پاسخ). قرار دهید $a = 8$ و $z = 5$ (شروع نزدیک‌تر به مرز درست). P_c را تحلیلی و با شبیه‌سازی حساب کنید. بعد میانگین زمان واکنش پاسخ‌های درست و غلط را مقایسه کنید. نتیجه را بر اساس فاصله‌ی هر مرز از نقطه‌ی شروع توضیح دهید. $z = 3$ چه می‌کرد؟

تمرین ۴ ⋆⋆ (بررسی یک ویژگی مدل). برای $z = a/2$، با شبیه‌سازی (۲۰ ۰۰۰ trial) نشان دهید که *quantile*های زمان واکنش پاسخ‌های درست و غلط در حد نویز نمونه‌گیری برابرند. داده‌های واقعی اغلب در شرایط سخت و با تأکید بر دقت، خطاهای کندتری نشان می‌دهند. آیا چنین داده‌هایی random walk ساده را رد می‌کنند؟ چه چیزی را تغییر می‌دادید؟

تمرین ۵ ⋆⋆⋆ (پیشرفته: تغییرپذیری drift بین trialها). `simulate_trial` را طوری تغییر دهید که در هر trial drift از $v_i \sim \mathcal{N}(v, \eta)$ کشیده شود و به $[-0.95, 0.95]$ محدود شود. از $v = 0.2$، $\eta = 0.2$، $a = 8$ استفاده کنید. نشان دهید که **حالا خطاها کندتر از پاسخ‌های درست‌اند** (انتظار با ۲۰ ۰۰۰ trial: دقت $\approx$ ۷۵.۰، حدود ۱۲ گام برای پاسخ‌های درست در برابر

۱۴ گام برای خطاها) و توضیح دهید چرا. راهنمایی: کدام trialها بیشترین احتمال را دارند که به خطا ختم شوند، و آن trialها چقدر طول می‌کشند؟

lab check-off (جزو نمره‌ی lab حساب می‌شود)

به مدرس یا دستیار آموزشی نشان دهید: (۱) خروجی `check_install.py` که همه‌ی بسته‌ها در آن `[OK]` باشند، (۲) نمودار سرعت–دقت از بخش D، و (۳) بهترین پارامترهای برازش و نمودار quantileها از بخش E.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

سطوح Marr برای یک chatbot. یک مدل بزرگ زبانی (LLM) را می‌شود در هر سه سطح Marr توصیف کرد، و این سطوح، درست مثل آدم‌ها، می‌توانند از هم جدا شوند. محاسباتی: مدل آموزش دیده که کلمه‌ی (token) بعدی یک متن را پیش‌بینی کند. الگوریتمی: یک شبکه‌ی transformer برای هر token ممکن بعدی یک امتیاز («logit») حساب می‌کند و امتیازها را به احتمال تبدیل می‌کند. اجرایی: ضرب ماتریس‌ها روی GPUها. ادعایی مثل LLM» سؤال را می‌فهمد» معمولاً در سطح محاسباتی مطرح می‌شود، در حالی که شواهد (خروجی‌هایش) را الگوریتم تولید می‌کند. وقتی چنین ادعاهایی را می‌خوانید، سطوح را از هم جدا نگه دارید.

یک قاعده‌ی تصمیم آشنا. گام آخر یک LLM یک قاعده‌ی انتخاب با یک پارامتر نویز است، درست مثل مدل‌های شناختی این درس. احتمال token i یک softmax با **دما** (temperature) T است: $P(i) = e^{z_i/T} / \sum_j e^{z_j/T}$. پایین T انتخاب‌های تقریباً قطعی و T بالا انتخاب‌های تصادفی‌تر می‌دهد. این همان قاعده‌ی softmax هفته‌ی ۱۵ است، با $\beta = 1/T$.

Code · کد: `code/week01.py`، cell ۱۰ · سلول ۱۰

خروجی مورد انتظار:

```
T = 0.2: P(A, B, C) = [0.993 0.007 0.   ], sampled shares = [0.994 0.006
↪  0.   ]
T = 1.0: P(A, B, C) = [0.652 0.24  0.108], sampled shares = [0.662 0.235
↪  0.103]
T = 2.0: P(A, B, C) = [0.497 0.301 0.202], sampled shares = [0.52  0.281
↪  0.199]
```

امتحانش کنید (بدون نیاز به API). - ⋆ بزرگ‌ترین دمایی را پیدا کنید که در آن «A» هنوز دست‌کم ۹۰٪ مواقع انتخاب می‌شود. - ⋆ دمای LLM به نویزی random walk نزدیک‌تر است یا به مرز آن (هفته‌ی ۱، بخش C؟ توضیح دهید. - ⋆⋆ بحث: کسی می‌گوید chatbot» وقتی دوباره پرسیدم جواب دیگری داد، پس جواب را نمی‌داند.» با استفاده از این کادر توضیح دهید چه چیز دیگری ممکن است در کار باشد.

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **«مدلی که خوب برازش می‌شود درست است.»** برازش خوب لازم است ولی کافی نیست. یک مدل منعطف تقریباً هر چیزی، از جمله نویز، را برازش می‌کند (هفته‌ی ۶). برازش تا وقتی ندانید مدل چه چیزی را نمی‌توانست برازش کند، حرف زیادی نمی‌زند.

۲. **«پارامتر بیشتر یعنی مدل بهتر.»** پارامتر بیشتر مدل را منعطف‌تر می‌کند، که با بهتر بودن یکی نیست. انعطاف را صریحاً جریمه خواهیم کرد (AIC/BIC، cross-validation، Bayes factor).

۳. **قاطی کردن شبیه‌سازی با برازش.** شبیه‌سازی از پارامتر به داده می‌رود؛ برازش از داده به پارامتر. دانشجوها اغلب با دست‌کاری پارامترها تا وقتی نمودار قشنگ شود «برازش» می‌کنند. این یک کاوش مشروع است، ولی روش برآورد نیست.

۴. **پارامترها را مستقیماً قابل مشاهده دانستن.** v و a کمیت‌هایی استنباط‌شده‌اند که مقدارشان به فرض‌های مدل بستگی دارد (مثلاً اینکه t_0 معلوم است). مدل را عوض کنید، ممکن است معنای «همان» پارامتر هم عوض شود.

۵. **فراموش کردن seed تصادفی.** شبیه‌سازی بدون seed قابل بازتولید نیست و هر بار که notebook را اجرا کنید نتایج فرق می‌کند. از `np.random.default_rng(seed)` استفاده کنید.

۶. **وارسی نکردن شبیه‌سازی‌ها.** باگ در شبیه‌ساز نتیجه‌گیری‌های غلطی می‌سازد که به نظر معقول‌اند. با یک نتیجه‌ی تحلیلی، یک حالت حدی (مثلاً $v \to 0$ باید $P_c \to z/a$ بدهد) یا یک مقدار منتشرشده مقایسه کنید.

۷. **قاطی کردن دو معنای «بیزی».** مدل‌های بیزی شناخت (ادعایی درباره‌ی ذهن) در برابر تحلیل داده‌ی بیزی (روشی برای پژوهشگران).

۸. **سطوح Marr را رقیب هم دانستن.** آن‌ها توصیف‌های مکمل یک سیستم واحدند، نه نظریه‌های رقیب.

۹.۱.۱ خودآزمایی

۱. هرکدام را در یک جمله تعریف کنید: نظریه، مدل شناختی و مدل آماری. **پاسخ** نظریه مجموعه‌ای از ادعاهای (معمولاً کلامی) درباره‌ی فرایندهای ذهنی است. مدل شناختی نمونه‌ی فرمال و صریحی از چنین ادعاهایی است که می‌تواند پیش‌بینی تولید کند و پارامترهایش کمیت‌های روان‌شناختی را نشان می‌دهند. مدل آماری ساختار داده‌ها (مثلاً میانگین گروه‌ها، شیب‌ها) را توصیف می‌کند بی‌آنکه به یک سازوکار شناختی متعهد باشد.

۲. هرکدام را توصیفی، فرایندی یا هنجاری دسته‌بندی کنید: (الف) $\mathrm{RT} = A\,N^{-b}$ به‌عنوان تابعی از تعداد trialهای تمرین N؛ (ب) مدل random walk؛ (ج) مشاهده‌گر ایده‌آلی که سرنخ‌های دیداری و لامسه‌ای را با وزن قابلیت اطمینانشان ترکیب می‌کند. **پاسخ** (الف) توصیفی: شکل داده‌ها را خلاصه می‌کند بی‌آنکه بگوید چرا. (ب) فرایندی: سازوکاری را مشخص می‌کند که انتخاب‌ها و زمان‌های واکنش را تولید می‌کند. (ج) هنجاری: رفتار بهینه را با توجه به اطلاعات موجود مشخص می‌کند.

۳. مدل random walk عمدتاً در کدام سطح Marr قرار دارد؟ یک مثال از ادعایی درباره‌ی همان تصمیم در سطح پیاده‌سازی بزنید. **پاسخ** سطح الگوریتمی/بازنمایی: یک رویه را توصیف می‌کند (انباشت شواهد تا رسیدن به مرز). یک ادعای سطح پیاده‌سازی مثلاً این است: «شواهد انباشته‌شده با نرخ شلیک نورون‌های یک ناحیه‌ی مشخص مغز حمل می‌شود و وقتی این نرخ به یک آستانه برسد پاسخ داده می‌شود.»

۴. تفاوت مسئله‌ی مستقیم و معکوس چیست؟ در بخش E lab کدام را حل کردیم؟ **پاسخ** مستقیم: با داشتن پارامترها، داده تولید (پیش‌بینی) کنیم، یعنی شبیه‌سازی. معکوس: با داشتن داده، پارامترها را استنباط کنیم، یعنی برازش. بخش E یک مسئله‌ی معکوس را حل کرد (با جستجوی شبکه‌ای)، ولی برای این کار مسئله‌ی مستقیم را بارها، یک بار برای هر نقطه‌ی شبکه، حل کرد.

۵. با استفاده از فرمول‌ها، وقتی $v = 0$ باشد چه بر سر P_c می‌آید؟ (راهنمایی: به حد یا به تقارن حرکت فکر کنید.) **پاسخ** بدون drift حرکت متقارن است و احتمال رسیدن به مرز بالا برابر z/a است (حد فرمول وقتی $v \to 0$). با شروع بی‌سوگیری، $z = a/2$، دقت ۵۰٪ است، یعنی در حد شانس. این منطقی است: بدون شواهد، تصمیم‌گیرنده حدس می‌زند.

۶. دو گروه در دقت فرق دارند (۸۰٪ در برابر ۹۰٪). چرا فقط از روی دقت نمی‌توانیم بگوییم تفاوت در احتیاط است یا در کیفیت شواهد؟ چه داده‌ی اضافه‌ای مسئله را حل می‌کند؟ **پاسخ** هم مرز بزرگ‌تر a و هم drift بزرگ‌تر v دقت را بالا می‌برند، پس دقت

به‌تنهایی این دو را از هم جدا نمی‌کند. زمان واکنش مسئله را حل می‌کند: احتیاط بیشتر پاسخ‌ها را کندتر و شواهد بهتر آن‌ها را سریع‌تر می‌کند (مثال حل‌شده، قدم ۵). برازش هم‌زمان مدل روی دقت و زمان واکنش این دو را جدا می‌کند.

۷. چرا پیش از اعتماد به روش برازش، از پارامترهای معلوم داده شبیه‌سازی کردیم؟ **پاسخ** فقط با مقادیر واقعی معلوم می‌توان بررسی کرد که آیا روش جواب درست را برمی‌گرداند (بازیابی پارامتر). اگر روشی نتواند پارامترها را از داده‌ای که خود مدل تولید کرده بازیابی کند، برآوردهایش از داده‌ی واقعی قابل تفسیر نیستند. این موضوع در هفته‌ی ۷ کامل بررسی می‌شود.

۱۰.۱.۱ تکلیف

A0: نصب و «ممیزی نظریه‌ی کلامی» (بدون نمره ولی الزامی؛ موعد: ابتدای هفته‌ی ۲)

A0 نمره ندارد ولی الزامی است: اگر A0 ناقص باشد، باید پیش از lab check-off هفته‌ی ۲ اصلاح شود.

بخش ۱: محیط نرم‌افزاری (الزامی). خروجی متنی `pythoncheck_install.py--sample` را تحویل دهید که در آن همه‌ی بسته‌ها `[OK]` باشند و میانگین پسین PyMC دیده شود. اگر PyMC کار نکرد، پیام خطا و کارهایی را که امتحان کرده‌اید تحویل دهید؛ دستیار آموزشی کمک می‌کند.

بخش ۲: ممیزی نظریه‌ی کلامی (حداکثر ۱ صفحه). یک نظریه‌ی کلامی از درس‌های قبلی‌تان انتخاب کنید، مثلاً «سطوح پردازش»، «توجه به‌عنوان نورافکن»، «تمرین کامل می‌کند»، «نظریه‌های دوفرایندی استدلال» یا «تداخل باعث فراموشی می‌شود».

۱. نظریه را در ۱ تا ۲ جمله بیان کنید.
۲. **دست‌کم پنج** تصمیمی را فهرست کنید که نظریه نامشخص گذاشته و یک مدل فرمال باید بگیرد (مثلاً شکل تابعی، چه چیزی پرنویز است، پارامترهای آزاد کدام‌اند، حالت‌های درونی چگونه به رفتار اندازه‌گیری‌شده نگاشت می‌شوند).
۳. برای **دو** تا از این تصمیم‌ها یک انتخاب فرمال مشخص پیشنهاد کنید (یک معادله یا یک گام الگوریتمی).
۴. **یک** پیش‌بینی را توصیف کنید که بسته به انتخاب شما فرق می‌کند، و آزمایشی که بتواند آن‌ها را از هم جدا کند.

معیارهای بازخورد (قبول / نیاز به اصلاح):

معیار	قبول	نیاز به اصلاح
محیط نرم‌افزاری	همه‌ی بسته‌ها `[OK]`، یا گزارش روشن خطا همراه با تلاش‌های انجام‌شده	خروجی‌ای تحویل نشده
نامشخص بودن نظریه	≥ 5 تصمیم متمایز و واقعاً نامشخص	کمتر از ۵، یا تکرار خود نظریه
فرمال‌سازی	دو انتخاب فرمال مشخص و بدون ابهام	مبهم («از یک تابع استفاده کن»)
پیش‌بینی متفاوت	یک پیش‌بینی مشخص به‌علاوه‌ی آزمایشی که انتخاب‌ها را از هم جدا کند	بدون پیش‌بینی، یا پیش‌بینی‌ای که به انتخاب بستگی ندارد

بهترین ممیزی‌ها در ابتدای درس هفته‌ی ۲ به‌طور مختصر بحث می‌شوند.

۱۱.۱.۱ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل‌های ۱–۲.** مقدمه‌ای بر مدل‌سازی محاسباتی و گذر از نظریه‌های کلامی به مدل‌های فرمال. (منبع اصلی این هفته.)
- Verguts **(۲۰۲۲)، فصل مقدمه [بررسی شود].** انگیزه‌ای کوتاه و قابل فهم برای مدل‌سازی فرایندهای شناختی.
- Anderson **(۲۰۱۴)، فصل مقدمه [بررسی شود].** مدل‌سازی شناختی را کنار علوم اعصاب محاسباتی قرار می‌دهد؛ زمینه‌ای مفید برای سطح پیاده‌سازی Marr.
- کلاسیک اختیاری (خارج از فهرست درس): Marr, D. (۱۹۸۲). *Vision*. W. H. Freeman. منبع اصلی سه سطح تحلیل.

پیش‌نمایش هفته‌ی ۲: نظریه‌ی تشخیص علامت و منحنی‌های فراموشی را به مدل‌های Python تبدیل می‌کنیم و بررسی می‌کنیم هر پارامتر چگونه پیش‌بینی‌ها را شکل می‌دهد. تکلیف A1 منتشر می‌شود.

۲.۱ هفته‌ی ۲: کالبدشکافی یک مدل: تشخیص علامت و منحنی‌های فراموشی

فصل ۱: مبانی مدل‌سازی شناختی · درس ۱ ساعت · lab ۲ ساعت **مدل‌های اصلی این هفته:** نظریه‌ی تشخیص علامت گاوسی با واریانس برابر (SDT)؛ منحنی‌های فراموشی نمایی و توانی. هر دو در هفته‌های ۳ تا ۱۳ دوباره می‌آیند.

۱.۲.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
signal detection theory (SDT)	نظریه‌ی تشخیص علامت	مدلی که حساسیت را از سوگیری پاسخ جدا می‌کند
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
deterministic core	هسته‌ی قطعی	بخش بدون تصادف مدل که پیش‌بینی میانگین را می‌دهد
noise	نویز	تغییرات تصادفی در شواهد یا در داده
linking assumption	فرض پیوند	اینکه کمیت‌های مدل چطور به رفتار قابل مشاهده وصل می‌شوند
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز

English	فارسی	توضیح کوتاه
hit	اصابت (hit)	پاسخ «بله» وقتی علامت وجود دارد
response bias	سوگیری پاسخ	تمایل به یک پاسخ، مستقل از محرک
binomial distribution	توزیع دوجمله‌ای	توزیع تعداد موفقیت در n کوشش
noise model	مدل نویز	توزیع داده حول پیش‌بینی مدل
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
zROC curve / ROC	منحنی zROC / ROC	نرخ hit در برابر نرخ false alarm با تغییر ملاک
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
criterion (c)	ملاک	آستانه‌ی تصمیم؛ نشان‌دهنده‌ی سوگیری پاسخ
formalize / formal model	مدل فرمال / فرمال کردن	نوشتن نظریه به شکل معادله یا الگوریتم
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
false alarm	هشدار کاذب (false alarm)	پاسخ «بله» وقتی علامت وجود ندارد
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
correct rejection / miss	از دست دادن / رد درست	پاسخ «نه» با وجود علامت / پاسخ «نه» بدون علامت
conservative / liberal	آسان‌گیر / محافظه‌کار	تمایل به گفتن «بله» / «نه»
free parameter	پارامتر آزاد	پارامتری که از روی داده برآورد می‌شود
verbal theory	نظریه‌ی کلامی	نظریه‌ای که فقط با کلمات بیان شده و پیش‌بینی دقیق نمی‌دهد

۲.۲.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. یک مدل شناختی را به اجزایش **تجزیه کنند**: طرح آزمایش، پارامترهای آزاد و ثابت، هسته‌ی قطعی، مدل نویز (داده)، و فرض‌های پیوند (linking assumptions).
۲. d' و c را از یک جدول ۲×۲ شمارش‌ها **حساب کنند**، از جمله با تصحیح برای نرخ hit یا false alarm برابر ۰ یا ۱، و **توضیح دهند** چرا d' حساسیت را از سوگیری جدا می‌کند.
۳. مدل‌های فراموشی نمایی و توانی را با مدل نویز دوجمله‌ای **پیاده‌سازی کنند** و به‌طور کیفی **پیش‌بینی کنند** که هر پارامتر منحنی‌ها را چگونه تغییر می‌دهد.
۴. با شبیه‌سازی و نمودارهای تشخیصی (ROC/zROC)، نمودارهای نیمه‌لگاریتمی و لگاریتمی–لگاریتمی) **ارزیابی کنند** که آیا ردپای کیفی یک مدل در داده‌ها دیده می‌شود.
۵. پارامترهای برازش‌شده را به زبان روان‌شناختی **تفسیر کنند** و محدودیت‌های روش «برازش خط راست روی داده‌ی تبدیل‌شده» را **شناسایی کنند**.

۳.۲.۱ مقدمه

دو رادیولوژیست. رادیولوژیست R1 در ٪۹۳ از تصویرهایی که واقعاً تومور دارند تومور گزارش می‌کند، ولی در ٪۳۱ از تصویرهای سالم هم. رادیولوژیست R2 فقط ٪۶۹ از تومورها را گزارش می‌کند، ولی فقط در ٪۷ از تصویرهای سالم اشتباه می‌کند. درصد پاسخ درست هر دو یکسان است (٪۸۱). کدام تشخیص‌دهنده‌ی بهتری است؟

درصد پاسخ درست نمی‌تواند به این سؤال جواب دهد، چون دو چیز متفاوت را قاطی می‌کند: اینکه فرد **چقدر خوب** تومور را از بافت سالم تشخیص می‌دهد (حساسیت)، و اینکه **چقدر آمادگی** دارد بگوید «تومور هست» (سوگیری). نظریه‌ی تشخیص علامت یک مدل کوچک دوپارامتری است که این دو را از هم جدا می‌کند. همان‌طور که مثال حل‌شده نشان می‌دهد، R1 و R2 در واقع حساسیت **یکسانی** دارند؛ فقط ملاک‌شان را در جای متفاوتی گذاشته‌اند. این اولین ثمره‌ی مدل‌سازی است: پارامترهای مدل می‌توانند سازه‌های پنهانی را **اندازه بگیرند** که نمره‌های خام آن‌ها را قاطی می‌کنند.

منحنی ابینگهاوس. از زمان آزمایش‌هایی که ابینگهاوس در دهه‌ی ۱۸۸۰ روی خودش انجام داد می‌دانیم فراموشی اول سریع است و بعد کند می‌شود. «اول سریع، بعد کند» توصیفی کلامی است که هم تابع **نمایی** و هم تابع **توانی** با آن جور درمی‌آیند. ولی این دو معناهای متفاوتی دارند: نمایی یعنی یک خاطره در هر روز نسبت ثابتی از قدرتش را از دست می‌دهد، در هر سنی؛ توانی یعنی خاطره‌های قدیمی‌تر مقاوم‌تر می‌شوند. انتخاب بین این دو سؤالی درباره‌ی ماهیت حافظه است و به یک مدل فرمال نیاز دارد.

این موضوع کجا به کار می‌رود؟

- **تشخیص پزشکی.** رادیولوژیست‌ها، پاتولوژیست‌ها و برنامه‌های غربالگری با SDT و منحنی ROC ارزیابی می‌شوند تا پزشکی که «بهتر می‌بیند» از پزشکی که فقط بیشتر می‌گوید «غیرطبیعی است» جدا شود.
- **پژوهش حافظه.** در آزمون بازشناسی، کلمه‌های مطالعه‌شده «علامت» و کلمه‌های جدید «نویز» هستند. d' قدرت حافظه را جدا از تمایل به گفتن «قبلاً دیده‌ام» اندازه می‌گیرد.
- **شناسایی توسط شاهد عینی.** روش‌های مختلف صف شناسایی (line-up) در پلیس با تحلیل ROC مقایسه می‌شوند: بعضی روش‌ها دقت را بیشتر نمی‌کنند و فقط شاهد را محتاط‌تر می‌کنند.
- **آزمون‌های ادراک و شنوایی.** آستانه‌ی دیدن یا شنیدن محرک‌های ضعیف با SDT اندازه‌گیری می‌شود تا یک شنونده‌ی محتاط با کسی که کم‌شنواست اشتباه گرفته نشود.
- **یادگیری ماشین.** هر طبقه‌بند دودویی (فیلتر spam، آشکارساز تقلب، آشکارساز متن هوش مصنوعی) یک نرخ hit و یک نرخ false alarm دارد و با منحنی ROC و مساحت زیر آن (AUC) ارزیابی می‌شود. این همان نظریه است.
- **منحنی‌های فراموشی** برای زمان‌بندی یادگیری استفاده می‌شوند: اپلیکیشن‌های تکرار فاصله‌دار (مثلاً برای لغت) از روی مدلی از سرعت فراموشی تصمیم می‌گیرند کِی یک آیتم را دوباره نشان دهند.

۴.۲.۱ جزوه‌ی درس

به زبان ساده این هفته یک ایده‌ی اصلی دارد: هر مدل **اجزایی** دارد و هر جزء یک فرض جداست. دو مدل کوچک را می‌بینیم. **نظریه‌ی تشخیص علامت** (SDT) تصمیم‌های بله/نه در شرایط عدم قطعیت را توضیح می‌دهد. هر trial به مشاهده‌گر یک «حس وجود علامت» پرنویز می‌دهد. اگر این حس از یک آستانه‌ی شخصی قوی‌تر باشد، مشاهده‌گر می‌گوید «بله». دو عدد مشاهده‌گر را توصیف می‌کنند: حس «علامت هست» و «علامت نیست» به‌طور میانگین چقدر از هم فاصله دارند (**حساسیت**، d')، و آستانه کجاست (**ملاک**، c). دو نفر می‌توانند درصد پاسخ درست یکسانی داشته باشند به دلایل کاملاً متفاوت، و SDT نشان می‌دهد کدام دلیل. **منحنی فراموشی** نشان می‌دهد یادآوری با گذشت زمان چطور کم می‌شود. دو فرمول، نمایی و توانی، هر دو شکل «اول

سریع، بعد آهسته» دارند، ولی درباره‌ی حافظه حرف‌های متفاوتی می‌زنند. انتخاب بین آن‌ها از جنس سؤال‌هایی است که بقیه‌ی درس یاد می‌دهد با داده جواب دهیم.

واژه‌های آماری به زبان ساده

- **توزیع** :(distribution) توصیف اینکه یک کمیت تصادفی چه مقدارهایی می‌گیرد و هرکدام چقدر رایج است. هیستوگرام تعداد زیادی اندازه‌گیری تقریبی از آن است.
- **توزیع نرمال (گاوسی)** $\mathcal{N}(\mu, \sigma)$: منحنی زنگوله‌ای با میانگین μ (مرکز) و انحراف معیار σ (پهنا). حدود ٪۶۸ مقدارها در $\mu \pm \sigma$ و ٪۹۵ در $\mu \pm 1.96\sigma$ قرار می‌گیرند.
- **نرمال استاندارد:** توزیع نرمال با $\mu = 0$ و $\sigma = 1$. مقداری که روی این مقیاس سنجیده شود z-score نام دارد: «چند انحراف معیار بالاتر از میانگین».
- $\Phi(x)$ **(تابع توزیع تجمعی یا** CDF**):** احتمال اینکه یک مقدار نرمال استاندارد کمتر از x باشد. $\Phi(0) = 0.5$، $\Phi(1) \approx 0.84$، $\Phi(1.96) \approx 0.975$. در Python: `norm.cdf(x)`.
- $\Phi^{-1}(p)$ **(معکوس** CDF**، «تبدیل** z**»):** سؤال برعکس: نسبت p از مقدارها زیر چه عددی هستند؟ $\Phi^{-1}(0.84) \approx 1$. در Python: `norm.ppf(p)`.
- **توزیع دوجمله‌ای** $\text{Binomial}(n, p)$: تعداد موفقیت‌ها در n تلاش مستقل که هرکدام با احتمال p موفق است (مثلاً تعداد کلمه‌های به‌یادآمده از ۵۰). میانگین آن np و واریانس آن $np(1-p)$ است.
- **نسبت در برابر احتمال:** نسبت چیزی است که مشاهده می‌کنیم (۳۰ از ۵۰ = ۶۰.۰)؛ احتمال مقدار زیربنایی مدل است که نسبت آن را برآورد می‌کند.

زمان‌بندی پیشنهادی (۶۰ دقیقه): کالبدشکافی مدل ۱۵ · SDT ۲۰ · منحنی‌های فراموشی ۱۵ · شبیه‌سازی به‌عنوان ابزار فکر کردن + پیش‌نمایش ۱۰.

۱. کالبدشکافی یک مدل

در هفته‌ی ۱ مدل را یک ماشین تولید داده نوشتیم، $\mathbf{y} \sim p(\mathbf{y} \mid \boldsymbol{\theta}, \mathcal{M})$. در عمل تقریباً هر مدلی که در این درس می‌بینید را می‌شود به پنج تکه تقسیم کرد:

جزء	سؤال	SDT	فراموشی (نمایی)
۱. طرح آزمایش x_i	چه چیزی دست‌کاری و اندازه‌گیری می‌شود؟	نوع trial (علامت/نویز)؛ پاسخ بله/نه	فاصله‌ی نگهداری t_i؛ تعداد آیتم‌های یادآوری‌شده از n آیتم
۲. پارامترها $\boldsymbol{\theta}$	چه چیزی آزاد است؟ چه چیزی ثابت؟	آزاد: d'، c. ثابت: هر دو انحراف معیار = ۱، میانگین نویز = ۰	آزاد: A، λ. ثابت: n
۳. هسته‌ی قطعی $f(x; \boldsymbol{\theta})$	مدل به‌طور میانگین چه پیش‌بینی می‌کند؟	$H = \Phi(d'/2 - c)$، $F = \Phi(-d'/2 - c)$	$f(t) = Ae^{-\lambda t}$
۴. مدل نویز	مشاهدات چگونه حول پیش‌بینی پراکنده می‌شوند؟	hitها $\sim \text{Binomial}(n_s, H)$؛ false alarmها $\sim \text{Binomial}(n_n, F)$	یادآوری‌شده‌ها $\sim \text{Binomial}(n, f(t))$
۵. فرض‌های پیوند	کمیت‌های مدل چگونه به رفتار نگاشت می‌شوند؟	اگر شواهد درونی از ملاک بیشتر باشد «بله»	احتمال یادآوری برابر قدرت حافظه $f(t)$ است

چند نکته درباره‌ی هر جزء:

- **پارامترهای آزاد در برابر ثابت.** پارامترهای ثابت «بی‌اهمیت» نیستند؛ آن‌ها فرض هستند. در هفته‌ی ۱، $t_0 = 300$ ms را ثابت گرفتیم. در SDT، ثابت گرفتن میانگین نویز روی ۰ و هر دو انحراف معیار روی ۱ است که اصلاً برآورد d' و c را ممکن می‌کند: جابه‌جا کردن یا کشیدن کل محور هیچ پیش‌بینی‌ای را عوض نمی‌کند. به چنین ثابت‌هایی **قیدهای مقیاس** (scaling constraints) می‌گویند.
- **دامنه‌ی پارامترها.** هر پارامتر دامنه‌ی معناداری دارد: $0 \le A \le 1$، $\lambda > 0$، و برای مشاهده‌گری که برعکس پاسخ نمی‌دهد $d' \ge 0$. رعایت این دامنه‌ها در برازش مهم است (هفته‌ی ۳).
- **مدل نویز جزئی از مدل است.** دو پژوهشگر با $f(t)$ یکسان ولی مدل نویز متفاوت (دوجمله‌ای در برابر گاوسی) مدل‌های متفاوتی دارند و برآوردهای پارامتر متفاوتی می‌گیرند (هفته‌ی ۴). توزیع دوجمله‌ای برای شمارش‌ها طبیعی است: واریانسش $f(1-f)/n$ در $f = 0.5$ بیشینه است و نزدیک ۰ و ۱ کم می‌شود.

۲. نظریه‌ی تشخیص علامت (SDT)

تکلیف آزمایشی. در هر trial محرک یا علامت است (مثلاً یک تومور، یک کلمه‌ی مطالعه‌شده، یک صدای ضعیف) یا نویز. مشاهده‌گر پاسخ «بله» (علامت) یا «نه» می‌دهد. نتیجه‌ها یک جدول ۲×۲ می‌سازند:

	پاسخ «بله»	پاسخ «نه»
trial **علامت**	hit	از دست دادن (miss)
trial **نویز**	false alarm (FA)	رد درست (correct rejection)، CR

با نرخ hit $H = \frac{\text{hits}}{\text{hits+misses}}$ و نرخ false alarm $F = \frac{\text{FAs}}{\text{FAs+CRs}}$.

مدل (شهودی). هر trial یک مقدار **شواهد** درونی تولید می‌کند. این مقدار پرنویز است: حتی trialهای نویز خالص هم گاهی شبیه علامت به نظر می‌رسند. trialهای علامت به‌طور میانگین شواهد بیشتری تولید می‌کنند. مشاهده‌گر هر وقت شواهد از یک **ملاک** (criterion) بیشتر باشد می‌گوید «بله».

مدل (فرمال)، SDT گاوسی با واریانس برابر:

$$\text{noise trials: } X \sim \mathcal{N}(0,1), \qquad \text{signal trials: } X \sim \mathcal{N}(d',1), \qquad \text{respond "yes" iff } X > k.$$

- d' **حساسیت** است: فاصله‌ی دو توزیع بر حسب واحد انحراف معیار.
- k محل مطلق ملاک است. راحت‌تر است ملاک را نسبت به نقطه‌ی میانی دو توزیع بسنجیم: $c = k - d'/2$. با $c = 0$ مشاهده‌گر بی‌سوگیری است، $c < 0$ یعنی liberal (راحت «بله» می‌گوید)، و $c > 0$ یعنی **محافظه‌کار** (conservative).

پیش‌بینی‌ها. با استفاده از CDF نرمال استاندارد Φ:

$$H = P(X > k \mid \text{signal}) = \Phi\left(\tfrac{d'}{2} - c\right), \qquad F = P(X > k \mid \text{noise}) = \Phi\left(-\tfrac{d'}{2} - c\right).$$

معکوس کردن مدل. با اعمال Φ^{-1} (که اغلب z نوشته می‌شود) روی هر دو معادله و حل آن‌ها، فرمول‌های آشنا به دست می‌آیند:

$$d' = \Phi^{-1}(H) - \Phi^{-1}(F), \qquad c = -\tfrac{1}{2}\left[\Phi^{-1}(H) + \Phi^{-1}(F)\right].$$

دقت کنید چه اتفاقی افتاد: این اولین **برآورد پارامتر** ماست. دو پارامتر آزاد و دو داده (H، F) داریم، پس مدل را می‌شود دقیقاً

حل کرد. وقتی تعداد داده‌ها از تعداد پارامترها بیشتر باشد، معمولاً جواب دقیق وجود ندارد و به روش‌های برازش هفته‌های ۳–۴ نیاز داریم.

مشکل نرخ‌های حدی. اگر $H = 1$ یا $F = 0$ باشد، Φ^{-1} برابر $\pm\infty$ و d' بی‌نهایت می‌شود. با تعداد trial کم این اتفاق زیاد می‌افتد. راه‌حل استاندارد **تصحیح** log-linear است: پیش از محاسبه‌ی نرخ‌ها به هر خانه‌ی جدول ۰.۵ اضافه کنید (یعنی ۰.۵ به hitها و false alarmها و ۱ به تعداد trialهای هر نوع). در lab به‌طور پیش‌فرض از آن استفاده می‌کنیم.

منحنی ROC: نشانه‌ی اصلی. در SDT d' را ثابت نگه دارید و بگذارید c تغییر کند. جفت (F, H) یک منحنی رسم می‌کند به نام **منحنی مشخصه‌ی عملکرد گیرنده** (ROC). همه‌ی نقاط یک ROC حساسیت یکسان ولی سوگیری متفاوت دارند. رسم $\Phi^{-1}(H)$ در برابر $\Phi^{-1}(F)$ منحنی zROC را می‌دهد که در SDT با واریانس برابر یک خط راست است:

$$\Phi^{-1}(H) = d' + 1 \cdot \Phi^{-1}(F).$$

پس مدل یک پیش‌بینی قابل آزمون دارد: zROC **خطی با شیب ۱ است.** ROC را می‌شود با درجه‌بندی اطمینان (confidence ratings) اندازه گرفت (هر سطح اطمینان مثل یک ملاک جداگانه عمل می‌کند). در حافظه‌ی بازشناسی، شیب zROC معمولاً کمتر از ۱ است و همین انگیزه‌ی مدل با واریانس نابرابر در ادامه است.

> **پیشرفته: SDT با واریانس نابرابر.** اگر در trialهای علامت $X \sim \mathcal{N}(\mu_s, \sigma_s)$ باشد، zROC هنوز خطی است ولی شیبش $1/\sigma_s$ است. در این حالت d' که از یک جفت (H, F) حساب می‌شود با ملاک تغییر می‌کند، پس دیگر یک معیار خالص حساسیت نیست. یک شاخص جایگزین رایج $d_a = \mu_s\sqrt{2/(1+\sigma_s^2)}$ است. برآورد σ_s به بیش از یک ملاک، یعنی داده‌ی درجه‌بندی، نیاز دارد. این اثر را مستقیماً در بخش B lab می‌بینید.

خواندن ریاضی دو منحنی زنگوله‌ای. دو منحنی نرمال را روی یک محور بکشید: منحنی «نویز» با مرکز ۰ و منحنی «علامت» با مرکز d'. پهنای هر دو ۱ است. یک خط عمودی در محل ملاک k بکشید. هر چیزی سمت راست خط یعنی «بله».

- H = مساحت منحنی **علامت** در سمت راست خط. F = مساحت منحنی **نویز** در سمت راست خط.
- چرا $H = \Phi(d'/2 - c)$؟ ملاک در $k = d'/2 + c$ است (نقطه‌ی وسط به‌علاوه‌ی c). مرکز منحنی علامت d' است، پس خط به اندازه‌ی $k - d' = c - d'/2$ انحراف معیار از مرکز آن فاصله دارد. مساحت سمت راست این نقطه $1 - \Phi(c - d'/2) = \Phi(d'/2 - c)$ است، چون منحنی نرمال متقارن است.
- **مثال عددی.** $d' = 2$ و $c = 0$: $H = \Phi(1) = 0.84$ و $F = \Phi(-1) = 0.16$. حالا مشاهده‌گر را آسان‌گیر (liberal) کنید، $c = -0.5$: $H = \Phi(1.5) = 0.93$ و $F = \Phi(-0.5) = 0.31$. هر دو نرخ بالا رفتند و حساسیت تغییر نکرد. این همان رادیولوژیست R1 در مثال حل‌شده است.

معکوس کردن. $d' = \Phi^{-1}(H) - \Phi^{-1}(F)$: هر نرخ را به z-score تبدیل کنید و از هم کم کنید. برای R1: $1.476 - (-0.496) = 1.97$. c منفیِ میانگین دو z-score است: اگر هر دو نرخ بالا باشند (هر دو z-score مثبت)، c منفی است، یعنی آسان‌گیر.

خط zROC. $\Phi^{-1}(H) = d' + \Phi^{-1}(F)$ همان معادله‌ی قبلی است که مرتب شده. در واحد z، جابه‌جا کردن ملاک هر دو z-score را به یک اندازه تغییر می‌دهد، پس نقطه‌ها روی خطی با شیب ۱ و عرض از مبدأ d' قرار می‌گیرند.

برای یک مهندس SDT همان نظریه‌ی آشکارسازی رادار و مخابرات است که در دهه‌ی ۱۹۵۰ وارد روان‌شناسی شد.

	روان‌شناسی	مخابرات / رادار
trial نویز / trial علامت	فرضیه‌ی H_0 (فقط نویز) / H_1 (سیگنال + نویز)	
شواهد درونی X	آماره‌ی آزمون، مثلاً خروجی فیلتر منطبق (matched filter)	
ملاک k (یا c)	آستانه‌ی آشکارسازی	
نرخ hit یعنی H	احتمال آشکارسازی P_D	
نرخ false alarm یعنی F	احتمال هشدار کاذب P_{FA}	
حساسیت d'	انحراف (deflection) $(\mu_1-\mu_0)/\sigma$؛ d'^2 نقش SNR را دارد	
منحنی ROC	receiver operating characteristic (همان نام، همان نمودار)	
مشاهده‌گر آسان‌گیر / محافظه‌کار	آستانه‌ی پایین / بالا (P_{FA} بالا / پایین)	

تفاوت در تأکید: مهندس معمولاً آستانه را انتخاب می‌کند (مثلاً Neyman–Pearson: P_{FA} را ثابت کن و P_D را بیشینه کن). روان‌شناس P_D و P_{FA} یک آدم را مشاهده می‌کند و هم SNR (d') و هم آستانه‌ای (c) را که آن فرد به کار برده استنباط می‌کند. ملاک c از نقطه‌ی وسط دو میانگین سنجیده می‌شود، پس $c=0$ یعنی «بدون سوگیری». آستانه‌ی **بهینه** دقیقاً مثل آشکارسازی بیزی به احتمال‌های پیشین و هزینه‌ها بستگی دارد، و آدم‌ها وقتی پاداش‌ها تغییر می‌کنند معمولاً ملاکشان را در جهت درست جابه‌جا می‌کنند (هفته‌ی ۴).

۳. منحنی‌های فراموشی

داده. در هر فاصله‌ی نگهداری t_i (مثلاً به روز)، شرکت‌کننده با n آیتم آزمون می‌شود و y_i تا را به یاد می‌آورد.

دو هسته‌ی قطعی رقیب:

	نمایی	توانی
معادله	$f(t)=A\,e^{-\lambda t}$	$f(t)=A\,(1+t)^{-d}$
پارامترها	A: سطح اولیه؛ λ: نرخ زوال	A: سطح اولیه؛ d: نمای زوال
نمودار خطی‌کننده	$\ln f$ در برابر t خطی راست با شیب $-\lambda$ است	$\ln f$ در برابر $\ln(1+t)$ خطی راست با شیب $-d$ است
نرخ نسبی فراموشی $-f'(t)/f(t)$	λ (ثابت)	$d/(1+t)$ (با گذشت زمان کاهشی)
خوانش روان‌شناختی	خاطره در هر واحد زمان نسبت یکسانی از قدرتش را از دست می‌دهد، هر سنی که داشته باشد	خاطره‌های قدیمی‌تر کندتر قدرت از دست می‌دهند؛ مقاوم‌تر می‌شوند

نرخ نسبی فراموشی (که در تحلیل بقا به آن *hazard* می‌گویند) تفاوت کلیدی در تفسیر است. به همین دلیل انتخاب بین این دو تابع یک سؤال نظری است، نه یک جزئیات منحنی‌برازی.

مدل نویز. تعداد یادآوری‌ها دوجمله‌ای است:

$$y_i \sim \mathrm{Binomial}\big(n, f(t_i;\boldsymbol{\theta})\big).$$

با $n=50$ آیتم و $f=0.5$، انحراف معیار نسبت مشاهده‌شده $\sqrt{0.5\cdot 0.5/50}\approx 0.07$ است. این در مقایسه با تفاوت مدل‌ها

در فاصله‌های کوتاه بزرگ است؛ اولین نشانه‌ی اینکه **طرح آزمایش** (کدام فاصله‌ها، چند آیتم) تعیین می‌کند داده‌ها می‌توانند بین مدل‌ها تمایز بگذارند یا نه.

> **پیشرفته: «+۱» در مدل توانی بی‌خطر نیست.** $A\,t^{-d}$ در $t=0$ بی‌نهایت است، پس یک جابه‌جایی اضافه می‌شود. ولی $(1+t)$ به **واحد** t بستگی دارد: اندازه‌گیری به ساعت به‌جای روز، شکل منحنی را عوض می‌کند، نه فقط مقیاس محور را. به همین دلیل بعضی نویسندگان $A\,(1+bt)^{-d}$ را با پارامتر مقیاس آزاد b می‌نویسند؛ این یک پارامتر سوم اضافه می‌کند و سؤال‌های مقایسه‌ی مدل هفته‌های ۶–۷ را پیش می‌آورد. در طول این درس واحد را ثابت (روز) نگه دارید.

خواندن ریاضی

- $f(t)=Ae^{-\lambda t}$: A میزان یادآوری درست بعد از مطالعه ($t=0$) است و λ می‌گوید با چه سرعتی کم می‌شود. با $\lambda=0.1$ در روز، یادآوری هر روز در $e^{-0.1}\approx 0.905$ ضرب می‌شود: هر روز حدود ۹۵٪ از آنچه مانده از دست می‌رود، چه روز اول و چه روز صدم.
- $f(t)=A(1+t)^{-d}$: رفتن از روز ۰ به روز ۱ یادآوری را در 2^{-d} ضرب می‌کند؛ رفتن از روز ۹ به روز ۱۰ فقط در $(10/11)^d$ که نزدیک ۱ است. خاطره‌های قدیمی دیگر تقریباً تغییر نمی‌کنند.
- **نرخ نسبی فراموشی** $-f'(t)/f(t)$: «چه کسری از حافظه‌ی باقی‌مانده همین الان در هر روز از دست می‌رود». برای تابع نمایی ثابت است (λ) و برای تابع توانی کم می‌شود ($d/(1+t)$). همین یک عدد، تفاوت روان‌شناختی دو مدل است.
- $y_i \sim \text{Binomial}(n, f(t_i))$: در تأخیر t_i، شرکت‌کننده y_i آیتم از n آیتم را به یاد می‌آورد و هر آیتم با احتمال $f(t_i)$ به یاد آورده می‌شود. نسبت مشاهده‌شده‌ی y_i/n با انحراف معیار $\sqrt{f(1-f)/n}$ حول $f(t_i)$ پراکنده است؛ برای $n=50$ حدود ۰.۰۷.

برای یک مهندس

- منحنی **نمایی** همان پاسخ پله‌ی یک سیستم مرتبه‌ی اول است (دشارژ یک مدار RC): $\tau=1/\lambda$ یک ثابت زمانی. ثابت بودن نرخ نسبی فراموشی همان ویژگی «بی‌حافظگی» است که از طول عمر نمایی در نظریه‌ی قابلیت اطمینان می‌شناسید.
- منحنی **توانی** یک ثابت زمانی واحد ندارد. تصویر مفید: جمع تعداد زیادی منحنی نمایی با ثابت‌های زمانی متفاوت (مؤلفه‌های سریع و کند) شبیه یک قانون توانی می‌شود. هفته‌ی ۵ این را دقیقاً نشان می‌دهد و این یکی از توضیح‌های ممکن برای فراموشی توانی است.
- روی نمودار **لگاریتمی–لگاریتمی** قانون توانی یک خط راست است؛ روی نمودار **نیمه‌لگاریتمی** تابع نمایی خط راست است. مهندس‌ها از همین ترفند برای تشخیص مرتبه‌ی سیستم و نویز $1/f$ استفاده می‌کنند.
- مدل نویز دوجمله‌ای همان آمار شمارش یک آشکارساز است: مثل شمردن خطاهای بیتی از n بیت، عدم قطعیت یک نسبت با $1/\sqrt{n}$ کم می‌شود.

۴. شبیه‌سازی به‌عنوان ابزار فکر کردن

پیش از برازش هر چیزی، شبیه‌سازی کنید. شبیه‌سازی به سؤال‌هایی مثل این‌ها جواب می‌دهد:

- **مدل چه چیزی را می‌تواند تولید کند، و چه چیزی را نمی‌تواند؟** SDT با واریانس برابر و $d'>0$ هرگز نمی‌تواند $H<F$ تولید کند، و هرگز شیب zROC غیر از ۱ نمی‌دهد. منحنی‌های نمایی و توانی هر دو همیشه نزولی‌اند، پس نمی‌توانند بازیادآوری (reminiscence)، بهتر شدن یادآوری با گذشت زمان) را نشان دهند. مجموعه‌ی کارهایی که یک مدل **نمی‌تواند** انجام دهد همان چیزی است که آن را قابل آزمون می‌کند.
- **کدام پارامتر کجا اهمیت دارد؟** A کل منحنی فراموشی را جابه‌جا می‌کند؛ λ یا d شکل را کنترل می‌کند.

- **آیا طرح آزمایش می‌تواند بین مدل‌ها تمایز بگذارد؟** اگر دو مدل در فاصله‌هایی که می‌خواهیم آزمون کنیم پیش‌بینی‌های تقریباً یکسانی بدهند، هیچ روش برازشی نمی‌تواند آن‌ها را از هم جدا کند (تمرین ۴ lab؛ تکلیف .(A1

۵. پیش‌نمایش: برآورد با خطی‌سازی، و چرا کافی نیست

یک روش سنتی برای برازش منحنی فراموشی این است که از نسبت‌های مشاهده‌شده لگاریتم بگیریم و با رگرسیون معمولی یک خط راست برازش کنیم. سریع و شهودی است و در lab امتحانش می‌کنیم. سه مشکل دارد که انگیزه‌ی هفته‌های ۳–۴ است:

۱. $\ln(0)$ تعریف‌نشده است، پس فاصله‌ای با یادآوری صفر روش را از کار می‌اندازد.
۲. تبدیل لگاریتمی نویز را تحریف می‌کند: پراکندگی $\ln \hat{p}$ برای نسبت‌های کوچک خیلی بیشتر است، ولی رگرسیون با همه‌ی نقاط مثل هم رفتار می‌کند.
۳. خط روی مقیاس لگاریتمی برازش می‌شود، ولی ما به خطا روی مقیاس اصلی (نسبت) اهمیت می‌دهیم.

جایگزین اصولی این است که مدل را مستقیماً روی داده‌ی تبدیل‌نشده برازش کنیم: با کمینه کردن مربع خطا (هفته‌ی ۳) یا بیشینه کردن درست‌نمایی دوجمله‌ای (هفته‌ی ۴).

برای مدرس

- **با معمای رادیولوژیست‌ها شروع کنید** (بخش مقدمه) و پیش از نشان دادن هر فرمولی، بگذارید دانشجوها رأی بدهند کدام بهتر است. بیشترشان بر اساس درصد پاسخ درست انتخاب می‌کنند و بعد می‌فهمند که دو عدد یکسان است.
- **رسم کنید، اثبات نکنید.** دو منحنی زنگوله‌ای هم‌پوشان با یک خط عمودی متحرک، H، F، d' و c را بهتر از هر فرمولی توضیح می‌دهند. خط را روی تخته به چپ و راست ببرید و بپرسید H و F چه می‌شوند؛ بعد منحنی‌ها را از هم دور کنید و دوباره بپرسید.
- **از جدول Φ یا Python به‌طور زنده استفاده کنید.** d' رادیولوژیست R1 را جلوی کلاس با `norm.ppf` حساب کنید. دانشجوهایی که آمار برایشان تازه است باید ببینند Φ^{-1} «فقط یک جدول‌خوانی» است.
- **به چیزی که می‌شناسند وصل کنید:** یک تست کرونا یا بارداری نرخ hit (sensitivity) و نرخ false alarm (یک منهای specificity) دارد. «sensitivity» در پزشکی همان نرخ hit است، نه d': به این تشابه اسمی اشاره کنید.
- **سؤال‌های رایج.**
  - «چرا توزیع نرمال فرض می‌کنیم؟» فرضی راحت و اغلب کافی است؛ آزمون zROC (شیب ۱) آن را بررسی می‌کند و مدل واریانس نابرابر آن را آزادتر می‌کند.
  - «آیا ملاک آسان‌گیر بد است؟» نه؛ بهترین ملاک به هزینه‌ها و نرخ‌های پایه بستگی دارد.
  - «نمایی یا توانی، کدام درست است؟» در بسیاری از داده‌ها تابع توانی بهتر برازش می‌شود، ولی میانگین‌گیری روی افراد می‌تواند شکل توانی بسازد (هفته‌ی ۵). سؤال را باز نگه دارید.

۵.۲.۱ مثال حل‌شده

بخش ۱: دو رادیولوژیست (و یک سومی)

هر رادیولوژیست ۱۰۰ تصویر با تومور و ۱۰۰ تصویر سالم را می‌خواند.

مشاهده‌گر	H	F	$\Phi^{-1}(H)$	$\Phi^{-1}(F)$	d'	c	درصد درست
R0 (خنثی)	۸۴.۰	۱۶.۰	۹۹۴.۰	۹۹.۱	۰۰.۰	۸۴٪	
R1 (liberal)	۹۳.۰	۳۱.۰	۴۷۶.۱	۹۷.۱	۴۹.۰	۸۱٪	
R2 (محافظه‌کار)	۶۹.۰	۰۷.۰	۴۹۶.۰	۹۷.۱	۴۹.۰	۸۱٪	

قدم‌به‌قدم برای R1: ۱. $\Phi^{-1}(0.93) = 1.476$ و $\Phi^{-1}(0.31) = -0.496$ (`scipy.stats.norm.ppf`). ۲. $d' = 1.476 - (-0.496) = 1.972$. ۳. $c = -\frac{1}{2}(1.476 + (-0.496)) = -0.490$، که منفی است، پس R1 liberal است. ۴. بررسی با جای‌گذاری: $H = \Phi(1.972/2 + 0.490) = \Phi(1.476) = 0.93$ ✓.

تفسیر. هر سه رادیولوژیست در عمل حساسیت یکسانی دارند ($d' \approx 2$). R1 و R2 درصد درست یکسان ولی سوگیری مخالف دارند. اینکه کدام سوگیری بهتر است سؤالی درباره‌ی ادراک نیست، بلکه درباره‌ی هزینه‌هاست: از دست دادن یک تومور معمولاً خیلی بدتر از یک false alarm است، پس شاید ملاک liberal همان ملاک مطلوب باشد. SDT به ما اجازه می‌دهد «آیا می‌بینند؟» و «چقدر آماده‌اند بگویند؟» را جداگانه بپرسیم.

تصحیح نرخ حدی. یک شرکت‌کننده ۵۰/۵۰ hit و ۳/۵۰ false alarm دارد. پس $H = 1$ و $d' = \infty$. با تصحیح log-linear: $H = 50.5/51 = 0.990$، $F = 3.5/51 = 0.069$، پس $d' = 2.33 - (-1.49) = 3.82$.

بخش ۲: فراموشی نمایی در برابر توانی

برای هر دو مدل $A = 0.95$ بگیرید، برای مدل نمایی $\lambda = 0.25$ در روز و برای مدل توانی $d = 0.6$.

t (روز)	۰	۱	۲	۷	۱۴	۳۰
نمایی $0.95\,e^{-0.25t}$	۹۵۰.۰	۷۴۰.۰	۵۷۶.۰	۱۶۵.۰	۰۲۹.۰	۰۰۱.۰
توانی $0.95\,(1+t)^{-0.6}$	۹۵۰.۰	۶۲۷.۰	۴۹۱.۰	۲۷۳.۰	۱۸۷.۰	۱۲۱.۰

نیمه‌عمر (زمانی که یادآوری به نصف سطح اولیه می‌رسد): - نمایی: $e^{-\lambda t} = 1/2 \Rightarrow t_{1/2} = \ln 2/\lambda = 0.693/0.25 =$ 2.77 روز. - توانی: $(1+t)^{-d} = 1/2 \Rightarrow t_{1/2} = 2^{1/d} - 1 = 2^{1.667} - 1 = 2.17$ روز.

تفسیر. در دو روز اول منحنی‌ها نسبتاً شبیه‌اند: حدود ۱.۰ با هم فرق دارند که با $n = 50$ آیتم فقط حدود ۵.۱ انحراف معیار دوجمله‌ای است. بعد از یک ماه کاملاً با هم اختلاف دارند: مدل نمایی می‌گوید تقریباً همه چیز فراموش شده (۰٪.۱)، در حالی که مدل توانی می‌گوید ۱۲٪ هنوز باقی است. **فاصله‌های نگهداری طولانی جایی است که این مدل‌ها از هم تشخیص داده می‌شوند؛** درسی درباره‌ی طراحی آزمایش که در تکلیف A1 از آن استفاده می‌کنید.

۶.۲.۱ lab (۲ ساعت)

اهداف

۱. پیاده‌سازی SDT به‌عنوان یک مدل مولد (generative)، شبیه‌سازی آزمایش‌های بله/نه، و برآورد d' و c.
۲. استفاده از نمودارهای ROC و zROC برای **ارزیابی** فرض واریانس برابر.
۳. پیاده‌سازی فراموشی نمایی و توانی با نویز دوجمله‌ای و بررسی پارامترهایشان.
۴. **برازش** هر دو مدل فراموشی با خطی‌سازی، **ارزیابی** آن‌ها با باقی‌مانده‌ها (residuals)، و **تفسیر** نتیجه.

زمان‌بندی: بخش A ۳۰ دقیقه · بخش B ۲۵ دقیقه · بخش C ۳۰ دقیقه · بخش D ۲۵ دقیقه · زمان باقی‌مانده: تمرین‌ها.

آماده‌سازی

Code · **کد:** `code/week02.py`، cell ۱ · سلول ۱

بخش A: SDT به‌عنوان یک مدل مولد (۳۰ دقیقه)

Code · **کد:** `code/week02.py`، cell ۲ · سلول ۲

یک شرکت‌کننده را شبیه‌سازی کنید و پارامترها را بازیابی کنید:

Code · **کد:** `code/week02.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
Counts: {'hits': 68, 'misses': 32, 'fas': 11, 'crs': 89}
Predicted H = 0.674, F = 0.147
Estimated d' = 1.67 (true 1.5),  c = 0.37 (true 0.3)
```

یک شرکت‌کننده‌ی شبیه‌سازی‌شده چیز زیادی درباره‌ی کیفیت برآوردگر نمی‌گوید. آزمایش را چندین بار تکرار کنیم: این پیش‌نمایشی از منطق **بازیابی پارامتر** در هفته‌ی ۷ است.

Code · **کد:** `code/week02.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
            d_hat         c_hat
             mean    std   mean    std
n_per_type
20          1.500  0.449  0.296  0.224
50          1.489  0.290  0.295  0.143
200         1.502  0.142  0.299  0.071
```

به این دقت کنید: برآوردها حول مقادیر واقعی پراکنده‌اند و پراکندگی با افزایش تعداد trialها کم می‌شود. با ۲۰ trial از هر نوع، انحراف معیار $\hat{d}'$ حدود ۴۵.۰ است، پس برآوردهای تکی اغلب $\pm$۵.۰ یا بیشتر خطا دارند، و برای نصف کردن پراکندگی تقریباً ۴ برابر trial لازم است. اینجا به‌طور میانگین برآوردها درست سر هدف‌اند. ولی با d' بالاتر و trialهای کم، نرخ‌های حدی رایج می‌شوند و آن‌وقت تصحیح، برآوردها را به سمت ۰ می‌کشد (`true_d=3` را با ۲۰ trial امتحان کنید). هر وقت d' گروه‌هایی را مقایسه می‌کنید که با تعداد trial متفاوت آزمون شده‌اند، این را در نظر داشته باشید.

بخش B: منحنی‌های ROC و فرض واریانس برابر (۲۵ دقیقه)

اول، ROCهای پیش‌بینی‌شده‌ی مدل:

Code · **کد:** `code/week02.py`، cell ۵ · سلول ۵

حالا یک آزمایش **درجه‌بندی اطمینان** را شبیه‌سازی کنید. پاسخ‌ها روی یک مقیاس ۶ درجه‌ای داده می‌شوند (۱ = «مطمئنم نویز است» . . . ۶ = «مطمئنم علامت است») که معادل پنج ملاک هم‌زمان است. داده‌ها را از یک مشاهده‌گر با واریانس برابر و از یک مشاهده‌گر با **واریانس نابرابر** که توزیع علامتش انحراف معیار ۵.۱ دارد تولید می‌کنیم.

Code · **کد:** `code/week02.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
sigma_signal = 1.0: zROC slope = 0.96 (predicted 1.00); d' at each
↪  criterion = [1.52 1.48 1.48 1.43 1.43]
sigma_signal = 1.5: zROC slope = 0.67 (predicted 0.67); d' at each
↪  criterion = [1.46 1.34 1.16 0.96 0.84]
```

ارزیابی و تفسیر. برای مشاهده‌گر با واریانس برابر، شیب zROC نزدیک ۱ است و d' در همه‌ی ملاک‌ها تقریباً یکسان است: فرض مدل برقرار است. برای مشاهده‌گر با واریانس نابرابر، شیب نزدیک $1/1.5 = 0.67$ است و d' **به‌طور نظام‌مند با ملاک تغییر می‌کند.** اگر از چنین مشاهده‌گری فقط داده‌ی بله/نه جمع کرده بودیم، تفاوت گروه‌ها در «d'» می‌توانست صرفاً از تفاوت در سوگیری بیاید. بررسی پیش‌بینی امضایی یک مدل (اینجا: شیب zROC ≈ ۱) شکل پایه‌ای از **ارزیابی مدل** است.

بخش C: منحنی‌های فراموشی با نویز دوجمله‌ای (۳۰ دقیقه)

Code · **کد:** `code/week02.py`، cell ۷ · سلول ۷

پارامترها را بررسی کنید: A و پارامتر زوال هر منحنی را چگونه تغییر می‌دهند؟

Code · **کد:** `code/week02.py`، cell ۸ · سلول ۸

حالا یک **آزمایش شبیه‌سازی‌شده** بسازید. داده‌ها از مدل توانی می‌آیند، با ۵۰ آیتم که در هر یک از ۸ فاصله‌ی نگهداری آزمون می‌شوند:

Code · **کد:** `code/week02.py`، cell ۹ · سلول ۹

خروجی مورد انتظار:

```
       t  recalled   n  p_obs
0   0.25        42  50   0.84
1   1.00        30  50   0.60
2   2.00        26  50   0.52
3   4.00        25  50   0.50
4   7.00        13  50   0.26
5  14.00        13  50   0.26
6  21.00        13  50   0.26
7  30.00        14  50   0.28
```

بخش D: برازش با خطی‌سازی، ارزیابی، تفسیر (۲۵ دقیقه)

برازش. هر مدل را با رگرسیون خط راست روی مقیاس لگاریتمی برازش کنید (بخش ۵ جزوه).

Code · **کد:** `code/week02.py`، cell ۱۰ · سلول ۱۰

ارزیابی. به منحنی‌های برازش‌شده و باقی‌مانده‌ها نگاه کنید. یک مدل خوب باقی‌مانده‌هایی به جا می‌گذارد که به‌طور تصادفی حول صفر پراکنده‌اند؛ یک الگوی نظام‌مند یعنی شکل مدل غلط است.

> Code · کد: `code/week02.py`، cell ۱۱ · سلول ۱۱

خروجی مورد انتظار:

```
exp: A = 0.550, rate = 0.032, RMSD = 0.1308
pow: A = 0.797, rate = 0.370, RMSD = 0.0628
true (power): A = 0.9, d = 0.5
```

تفسیر (برای هرکدام ۲ تا ۳ جمله در notebook بنویسید):

۱. کدام مدل داده‌ها را بهتر توصیف می‌کند، و الگوی باقی‌مانده‌های مدل دیگر چه شکلی دارد؟ (دنبال شکل U یا U وارونه بگردید: مدل نمایی در فاصله‌های میانی بیش‌برآورد و در فاصله‌های طولانی کم‌برآورد می‌کند، یا برعکس.)
۲. با پارامترهای برازش‌شده، نرخ نسبی فراموشی هر مدل بعد از ۱ روز و بعد از ۲۰ روز چقدر است؟ این برای حافظه چه معنایی دارد؟
۳. اینجا مدل توانی مدل واقعی است، ولی برآوردهایش ($\hat{A} \approx 0.80$، $\hat{d} \approx 0.37$) آشکارا با مقادیر واقعی ($A^* = 0.9$، $d^* = 0.5$) فاصله دارند. دو دلیل نام ببرید. (راهنمایی: به سه نقطه‌ی آخر نگاه کنید؛ فکر کنید تبدیل لگاریتمی با وزن نسبت‌های کوچک چه می‌کند.) در هفته‌ی ۳ همین داده‌ها را روی مقیاس اصلی دوباره برازش و مقایسه می‌کنیم.

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆ (نرخ‌های حدی). یک شرکت‌کننده ۴۰/۴۰ hit و ۰/۴۰ false alarm دارد. d' را بدون تصحیح و با تصحیح log-linear حساب کنید. d' تصحیح‌شده نماینده‌ی چیست، و چرا باید تصحیحی را که استفاده کرده‌اید گزارش کنید؟

تمرین ۲ ⋆ (نیمه‌عمرها). با پارامترهای برازش‌شده از بخش D، نیمه‌عمر هر مدل را حساب کنید. بعد حساب کنید چقدر طول می‌کشد تا یادآوری به ۱۰٪ سطح اولیه برسد. مدل‌ها کجا بیشترین اختلاف را دارند؟

تمرین ۳ ⋆⋆ (داده‌های ابینگهاوس). داده‌های کلاسیک savings از آزمایش‌های ابینگهاوس روی خودش در ۱۸۸۵ اغلب این‌طور گزارش می‌شوند [پیش از استفاده در کلاس با منبع اصلی تطبیق داده شود]:

	فاصله	۲۰ دقیقه	۱ ساعت	۸.۸ ساعت	۱ روز	۲ روز	۶ روز	۳۱ روز
Savings (٪)	۲.۵۸	۲.۴۴	۸.۳۵	۷.۳۳	۸.۲۷	۴.۲۵	۱.۲۱	

فاصله‌ها را به روز تبدیل کنید، هر دو مدل را با خطی‌سازی برازش کنید و باقی‌مانده‌هایشان را مقایسه کنید. کدام شکل بهتر برازش می‌شود؟ بعد تحلیل را با زمان بر حسب **ساعت** تکرار کنید. آیا برازش توانی تغییر می‌کند؟ با استفاده از کادر «پیشرفته» در بخش ۳ جزوه توضیح دهید.

تمرین ۴ ⋆⋆ **(کدام طرح آزمایش مدل‌ها را از هم جدا می‌کند؟).** (A, λ) و (A, d) را طوری انتخاب کنید که دو مدل در $t = 1$ و $t = 7$ روز یادآوری یکسانی پیش‌بینی کنند. (راهنمایی: برای هر مدل دو معادله و دو مجهول؛ لگاریتم بگیرید.) بعد هر دو منحنی را از $t = 0$ تا 60 روز رسم کنید و جاهایی را که اختلافشان با $n = 50$ از ۲ انحراف معیار دوجمله‌ای بیشتر است علامت بزنید. کدام فاصله‌های نگهداری را آزمون می‌کردید؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: شمارش صفر).** از مدل نمایی با $A = 0.9$، $\lambda = 0.3$ در فاصله‌های بخش C و با $n = 20$ آیتم داده تولید کنید. چند بار (از ۱۰۰۰ مجموعه‌داده‌ی شبیه‌سازی‌شده) دست‌کم یک فاصله یادآوری صفر دارد که `fit_linearized` را از کار می‌اندازد؟ یک راه‌حل سریع (مثلاً افزودن ۰.۵ به شمارش‌ها) پیشنهاد و پیاده‌سازی کنید و بررسی کنید آیا برآورد λ را سوگیر می‌کند. توضیح دهید چرا این نشان می‌دهد به روشی نیاز داریم که روی مقیاس اصلی کار کند (هفته‌های ۳–۴).

lab check-off

به مدرس یا دستیار آموزشی نشان دهید: (۱) جدول بازیابی SDT از بخش A، (۲) دو zROC تجربی با شیب‌هایشان از بخش B، و (۳) نمودار باقی‌مانده‌ها از بخش D با یک جمله تفسیر.

۷.۲.۱ ارتباط با هوش مصنوعی و LLMها

آشکارسازهای متن هوش مصنوعی، مشاهده‌گرهایی در یک تکلیف SDT هستند. دانشگاه‌ها روزبه‌روز بیشتر از ابزارهایی استفاده می‌کنند که به یک متن امتیاز «چقدر محتمل است که هوش مصنوعی نوشته باشد» می‌دهند. هر متن یا با هوش مصنوعی نوشته شده («علامت») یا با انسان («نویز»)، و ابزار وقتی امتیاز از یک آستانه بیشتر شود می‌گوید «هوش مصنوعی». این دقیقاً موقعیت SDT این هفته است: ابزار یک **حساسیت** d' دارد (امتیاز چقدر خوب دو نوع متن را از هم جدا می‌کند) و یک **ملاک** c (آستانه‌ای که کاربر انتخاب می‌کند). یک false alarm یعنی دانشجویی به‌اشتباه متهم شود، پس انتخاب ملاک یک تصمیم اخلاقی است، نه فقط فنی.

Code · کد: `code/week02.py`، cell ۱۲ · سلول ۱۲

خروجی مورد انتظار:

```
threshold 0.0: H = 0.84, F = 0.49, d' = 1.03, c = -0.50
threshold 0.6: H = 0.70, F = 0.28, d' = 1.11, c = 0.03
threshold 1.2: H = 0.51, F = 0.09, d' = 1.35, c = 0.66
```

جابه‌جا کردن آستانه c را خیلی تغییر می‌دهد (از -۰.۵۰ تا ۰.۶۶)، در حالی که d' نزدیک مقدار واقعی‌اش یعنی ۲.۱ می‌ماند. تغییرات d' نویز نمونه‌گیری ناشی از ۲۰۰ متن در هر گروه است.

امتحانش کنید (بدون نیاز به API). - ⋆ فرض کنید ۱۰٪ مقاله‌های تحویلی با هوش مصنوعی نوشته شده‌اند. در آستانه‌ی ۲.۱، $P(\text{AI-written} \mid \text{flagged})$ چقدر است؟ (از قاعده‌ی بیز با H و F استفاده کنید.) آیا بر اساس یک هشدار اقدام می‌کنید؟ - ⋆⋆ ROC آشکارساز (همه‌ی آستانه‌ها از -۲ تا ۳) و zROC آن را رسم کنید. آیا شیب نزدیک ۱ است؟ با امتیازهای متن انسانی با انحراف معیار ۵.۱ (آشکارسازی با واریانس نابرابر) تکرار کنید. - ⋆⋆ بحث: گزارش شده که آشکارسازها متن‌های نویسندگان

غیربومی انگلیسی را بیشتر علامت می‌زنند [بررسی شود: Liang et al., ۲۰۲۳، *Patterns*]. به زبان SDT این یعنی چه، و یک دانشگاه چه باید بکند؟

۸.۲.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **«درصد پاسخ درست کافی است.»** حساسیت و سوگیری را قاطی می‌کند (رادیولوژیست‌ها را ببینید). هر وقت پاسخ‌ها ممکن است سوگیری داشته باشند از d' و c استفاده کنید.

۲. **محاسبه‌ی d' به شکل $\Phi^{-1}(H-F)$ یا از روی درصدها.** فرمول $\Phi^{-1}(H) - \Phi^{-1}(F)$ است، با نرخ‌ها به‌صورت نسبت بین ۰ و ۱.

۳. **فراموش کردن مشکل نرخ‌های حدی.** $H = 1$ یا $F = 0$ یک d' بی‌نهایت می‌دهد و Python بدون هیچ خطایی `inf` برمی‌گرداند. همیشه از یک تصحیح استفاده کنید (و آن را گزارش کنید).

۴. **فرض اینکه d' در هر حالتی مستقل از سوگیری است.** فقط تحت مدل واریانس برابر مستقل از ملاک است. اگر شیب zROC با ۱ فرق کند، d' یک جفت (H, F) به سوگیری بستگی دارد.

۵. **«نمایی و توانی فقط دو شکل منحنی‌اند.»** آن‌ها ادعاهای متفاوتی درباره‌ی چگونگی فراموشی دارند (نرخ نسبی ثابت در برابر کاهشی).

۶. **قضاوت درباره‌ی مدل فقط با آماره‌ی برازش.** RMSD کوچک همراه با الگوی نظام‌مند در باقی‌مانده‌ها یعنی شکل مدل غلط است. همیشه باقی‌مانده‌ها را رسم کنید.

۷. **نادیده گرفتن مدل نویز.** مدل فقط $f(x;\boldsymbol{\theta})$ نیست. نویز دوجمله‌ای نسبت‌های یادآوری جزئی از مدل است و به شما می‌گوید کدام تفاوت‌ها معنادارند.

۸. **تغییر واحد t در مدل توانی جابه‌جاشده** و انتظار شکل یکسان.

۹.۲.۱ خودآزمایی

۱. پنج جزء یک مدل را نام ببرید و نسخه‌ی SDT هرکدام را بگویید. **پاسخ** طرح آزمایش (trial)های علامت در برابر نویز؛ پاسخ‌های بله/نه)؛ پارامترها (آزاد: d'، c؛ ثابت: میانگین نویز ۰، هر دو انحراف معیار ۱)؛ هسته‌ی قطعی ($H = \Phi(d'/2 - c)$، $F = \Phi(-d'/2 - c)$)؛ مدل نویز (شمارش hitها و false alarmها دوجمله‌ای است)؛ فرض پیوند (وقتی شواهد از ملاک بیشتر است پاسخ «بله»).

۲. چرا میانگین نویز و انحراف معیارها در SDT ثابت‌اند و آزاد نیستند؟ **پاسخ** چون identifiable نیستند: جابه‌جا کردن هر دو توزیع و ملاک به یک اندازه، یا کشیدن کل محور، هیچ پیش‌بینی‌ای را عوض نمی‌کند. ثابت کردن آن‌ها (قیدهای مقیاس) واحدهایی را تعریف می‌کند که d' و c با آن اندازه‌گیری می‌شوند.

۳. یک مشاهده‌گر $H = 0.80$ و $F = 0.20$ دارد. d' و c را حساب کنید. **پاسخ** ($\Phi^{-1}(0.80) = 0.842$) $d' = 0.842 - (-0.842) = 1.68$؛ $c = -\frac{1}{2}(0.842 - 0.842) = 0$، پس مشاهده‌گر بی‌سوگیری است.

۴. SDT با واریانس برابر درباره‌ی zROC چه پیش‌بینی می‌کند، و اگر شیب تجربی ۰.۷ باشد یعنی چه؟ **پاسخ** یک خط راست با شیب ۱. شیب ۰.۷ نشان می‌دهد توزیع علامت از توزیع نویز متغیرتر است ($\sigma_s \approx 1/0.7 \approx 1.4$). در این صورت d' تک‌نقطه‌ای به ملاک بستگی دارد و باید از مدل واریانس نابرابر (یا d_a) استفاده کرد.

۵. نرخ نسبی فراموشی هر مدل چیست، و چرا از نظر روان‌شناختی مهم است؟ **پاسخ** نمایی: λ، ثابت. توانی: $d/(1+t)$، با گذشت زمان کاهشی. مدل نمایی می‌گوید خاطره‌ها در هر سنی روزانه نسبت یکسانی از قدرتشان را از دست می‌دهند؛ تابع توانی می‌گوید خاطره‌های قدیمی‌تر در برابر فراموشی بیشتر مقاوم‌تر می‌شوند.

۶. برای اینکه سریع ببینید داده‌های فراموشی نمایی به نظر می‌رسند چه نموداری رسم می‌کنید؟ و برای توانی؟ **پاسخ** نمایی: $\ln(\text{recall})$ در برابر t (نیمه‌لگاریتمی) که باید خط راست باشد. توانی: $\ln(\text{recall})$ در برابر $\ln(1+t)$ (لگاریتمی–لگاریتمی) که باید خط راست باشد.

۷. دو دلیل بیاورید که چرا برازش خط راست روی نسبت‌های لگاریتمی‌شده روش برآورد ضعیفی است. **پاسخ** (۱) وقتی یک نسبت مشاهده‌شده ۰ باشد از کار می‌افتد. (۲) نویز را تحریف می‌کند: نسبت‌های کوچک روی مقیاس لگاریتمی خیلی متغیر می‌شوند ولی با وزن برابر در نظر گرفته می‌شوند، و خطاهایی که کمینه می‌شوند روی مقیاس غلط (لگاریتمی) هستند. برازش روی مقیاس اصلی با کمترین مربعات یا بیشینه درست‌نمایی از این مشکلات جلوگیری می‌کند.

۱۰.۲.۱ تکلیف

A1: از کلامی به فرمال (۰.۱ نمره از ۲۰؛ انتشار هفته‌ی ۲، موعد ابتدای درس هفته‌ی ۴)

سناریو. دو گروه پژوهشی فراموشی واژه‌هایی را که در یک کلاس زبان خارجی یاد گرفته شده‌اند مطالعه می‌کنند. - **گروه C** می‌گوید: «خاطره‌ها با نرخ ثابتی زوال پیدا می‌کنند.» - **گروه R** می‌گوید: «خاطره‌ها با بالا رفتن سن در برابر فراموشی مقاوم‌تر می‌شوند.»

هر دو گروه ادعا می‌کنند داده‌های منتشرشده (یادآوری سریع افت می‌کند و بعد ثابت می‌شود) از دیدگاهشان حمایت می‌کند.

کارها. یک Jupyter notebook به‌همراه خروجی PDF آن تحویل دهید.

۱. **فرمال‌سازی (گروه C و گروه R).** هر ادعای کلامی را به‌صورت یک مدل فرمال با هر پنج جزء بخش ۱ جزوه بنویسید: طرح آزمایش، پارامترهای آزاد/ثابت با دامنه‌شان، هسته‌ی قطعی، مدل نویز دوجمله‌ای، و فرض پیوند. در ۲ تا ۳ جمله توجیه کنید چرا هر معادله ادعای کلامی‌اش را نشان می‌دهد (از نرخ نسبی فراموشی استفاده کنید).

۲. **پیاده‌سازی.** توابع Python بنویسید که (الف) احتمال‌های یادآوری پیش‌بینی‌شده را برگردانند و (ب) برای فاصله‌ها و تعداد آیتم n داده‌شده، شمارش‌های یادآوری دوجمله‌ای را شبیه‌سازی کنند.

۳. **کالیبراسیون.** هر دو گروه قبول دارند که یادآوری **بعد از ۱ روز ۶۰.۰** و **بعد از ۷ روز ۳۵.۰** است. پارامترهای هر مدل را که دقیقاً این دو مقدار را بازتولید می‌کنند، دستی و به‌صورت بسته به دست آورید. محاسبه را نشان دهید (لگاریتم بگیرید) و آن را عددی بررسی کنید.

۴. **پیدا کردن جای اختلاف.** با پارامترهای کالیبره‌شده، هر دو منحنی پیش‌بینی‌شده را از ۰ تا ۹۰ روز رسم کنید. برای $n = 40$ آیتم، در هر فاصله یک شاخص تمایزپذیری $D(t) = \big(f_C(t) - f_R(t)\big)^2 / \mathrm{Var}(t)$ حساب کنید که در آن $\mathrm{Var}(t) = \bar{f}(1-\bar{f})/n$ و $\bar{f}$ میانگین دو پیش‌بینی است. $D(t)$ را رسم کنید.

۵. **طراحی آزمایش.** می‌توانید هر شرکت‌کننده را فقط در **۴** فاصله‌ی نگهداری آزمون کنید که از میان $\{۰.۵، ۱، ۲، ۴، ۷، ۱۴، ۳۰، ۶۰، ۹۰\}$ روز انتخاب می‌شوند. مجموعه‌ای را انتخاب کنید که مجموع $D(t)$ را بیشینه کند، توضیح دهید چرا منطقی است، و با طرح خود یک مجموعه‌داده از هر مدل شبیه‌سازی کنید. دو مجموعه‌داده را روی یک نمودار نشان دهید.

۶. **تفسیر (حداکثر ۳۰۰ کلمه).** کدام داده‌ها به نفع گروه C و کدام به نفع گروه R هستند؟ تحلیل شما درباره‌ی اینکه چرا هر دو گروه می‌توانند ادعا کنند «داده‌های منتشرشده» از آن‌ها حمایت می‌کند چه می‌گوید؟ یک فرض مدل‌هایتان را که ممکن است غلط باشد نام ببرید و بگویید چطور نتیجه‌گیری‌تان را تغییر می‌دهد.

روبریک نمره‌دهی (۱۰ امتیاز، معادل ۰.۱ از نمره‌ی نهایی):

معیار	امتیاز	شرط نمره‌ی کامل
فرمال‌سازی (کار ۱)	۲	هر پنج جزء برای هر دو مدل؛ دامنه‌ی درست پارامترها؛ ارتباط معادله و ادعای کلامی با نرخ نسبی فراموشی توضیح داده شده
کد (کار ۲)	۲	درست، با توضیح (comment)، قابل بازتولید (seed ثابت)؛ توابع برداری‌شده یا با حلقه‌ی روشن
کالیبراسیون (کار ۳)	۲	استخراج بسته‌ی درست و بررسی عددی برای هر دو مدل
اختلاف و طراحی (کارهای ۴–۵)	۵.۲	$D(t)$ درست؛ طرح انتخاب‌شده توجیه شده و واقعاً معیار را بیشینه می‌کند؛ نمودارهای روشن
تفسیر (کار ۶)	۵.۱	روشن، مشخص، با ارجاع به نتایج خودتان؛ یک محدودیت واقعی را نام می‌برد

برای تحویل با تأخیر، روزی ٪۱۰ کسر می‌شود (حداکثر ۳ روز).

۱۱.۲.۱ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۲.** ساختن مدل از یک نظریه‌ی کلامی؛ اجزای مدل و نقش پارامترها. (منبع اصلی.)
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۱۱.** نظریه‌ی تشخیص علامت به‌عنوان یک مدل شناختی (بیزی)؛ در هفته‌های ۹ و ۱۳ به آن برمی‌گردیم. بخش مقدمه را الان بخوانید و از کد بگذرید.
- Verguts **(۲۰۲۲)** و Anderson **(۲۰۱۴)**: فصل‌های مربوط به ساختن مدل و پارامترها [شماره‌ی فصل‌ها بررسی شود].
- پیش‌زمینه درباره‌ی منحنی‌های فراموشی: Wagenmakers & Lee (۲۰۱۴)، فصل ۱۰ (نگهداری حافظه) از یک مدل نگهداری نمایی نزدیک استفاده می‌کند که آن را در هفته‌های ۹–۱۱ به روش بیزی برازش می‌کنیم.

پیش‌نمایش هفته‌ی ۳: خطی‌سازی را کنار می‌گذاریم و مدل‌ها را مستقیماً با کمینه کردن مربع خطا برازش می‌کنیم؛ یعنی یاد می‌گیریم الگوریتم‌های بهینه‌سازی چطور فضای پارامتر را جستجو می‌کنند.

فصل ۲

روش‌های برآورد پارامتر

۱.۲ هفته‌ی ۳: برازش مدل با کمترین مربعات: سطح خطا و بهینه‌سازی

فصل ۲: روش‌های برآورد پارامتر · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی این هفته:** آزمایش فراموشی شبیه‌سازی‌شده از هفته‌ی ۲ (مدل توانی، $A^* = 0.9$، $d^* = 0.5$، $n = 50$ آیتم در ۸ فاصله). آن را درست برازش می‌کنیم و با برازش‌های خطی‌شده‌ی هفته‌ی قبل مقایسه می‌کنیم.

۱.۱.۲ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
least squares	کمترین مربعات	روش برازش با کمینه کردن مجموع مربع خطاها
error surface	سطح خطا	خطا به‌عنوان تابعی از پارامترها
optimizer	بهینه‌ساز	الگوریتمی که کمینه‌ی تابع را پیدا می‌کند
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری

English	فارسی	توضیح کوتاه
RMSD / SSE	مجموع مربعات خطا / ریشه‌ی میانگین مربع انحراف	معیارهای فاصله‌ی داده و پیش‌بینی
noise	نویز	تغییرات تصادفی در شواهد یا در داده
parameter trade-off	بده‌بستان پارامترها	تغییر یک پارامتر که با پارامتر دیگر جبران می‌شود
grid approximation	تقریب شبکه‌ای (grid)	محاسبه‌ی پسین روی شبکه‌ای از مقادیر
Nelder–Mead	روش Nelder–Mead	بهینه‌ساز بدون نیاز به مشتق
Bayes factor (BF)	عامل بیز (Bayes factor)	نسبت درست‌نمایی‌های حاشیه‌ای دو مدل
local minimum	کمینه‌ی محلی	نقطه‌ای پایین‌تر از اطراف ولی نه بهترین نقطه
constraints / bounds	کران‌ها / قیدها	محدودیت‌های مجاز برای مقدار پارامترها
reparameterization	بازپارامتری‌سازی	نوشتن پارامتر در مقیاس دیگر، مثلاً $\lambda = e^{\eta}$
multi-start	شروع چندگانه (multi-start)	اجرای بهینه‌ساز از چند نقطه‌ی شروع
maximum likelihood estimate (MLE)	برآورد بیشینه‌ی درست‌نمایی	پارامترهایی که داده را محتمل‌ترین می‌کنند
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
gradient	گرادیان	جهت و شیب تغییر تابع
convergence	همگرایی	رسیدن زنجیره‌ها به توزیع هدف
large language model (LLM)	مدل بزرگ زبانی	شبکه‌ی عصبی‌ای که کلمه‌ی بعدی متن را پیش‌بینی می‌کند
scaling law	قانون مقیاس	رابطه‌ی توانی بین اندازه‌ی مدل و خطا

۲.۱.۲ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. SSE، MSE و RMSD را به‌عنوان توابع ناهمخوانی (discrepancy functions) **تعریف کنند** و **توضیح دهند** که کمینه کردن آن‌ها چه فرضی درباره‌ی نویز دارد.
۲. سطح خطای یک مدل دوپارامتری را **رسم کنند** و شکل آن (کمینه، دره، فلات) را بر حسب trade-off پارامترها **تفسیر کنند**.
۳. برازش کمترین مربعات را با جستجوی شبکه‌ای و با `scipy.optimize.minimize` (Nelder–Mead و L-BFGS-B) **پیاده‌سازی کنند** و نقاط قوت و حالت‌های شکست الگوریتم‌ها را **مقایسه کنند**.
۴. شکست‌های رایج برازش را **تشخیص دهند** و **رفع کنند**: مقدار شروع بد، فلات‌ها، کمینه‌های محلی، و پارامترهای خارج از دامنه (با کران، reparameterization و multi-start).
۵. یک برازش کمترین مربعات را با RMSD و باقی‌مانده‌ها **ارزیابی کنند** و پارامترهای برازش‌شده را **تفسیر کنند**.

۳.۱.۲ مقدمه

هفته‌ی قبل منحنی‌های فراموشی را با کشیدن یک خط راست از میان نسبت‌های لگاریتمی‌شده برازش کردیم. مدل توانی مدل واقعی بود، ولی برآوردهایش آشکارا خطا داشتند ($\hat{A} = 0.80$، $\hat{d} = 0.37$ به‌جای 0.9 و 0.5). این روش هر وقت یک شمارش صفر باشد از کار می‌افتد، و خطاها را روی مقیاس غلط (لگاریتمی) کمینه می‌کند.

راه‌حل از نظر مفهومی ساده است: **پارامترهایی را انتخاب کن که پیش‌بینی‌های مدل را، روی مقیاس خود داده، تا جای ممکن به داده نزدیک کنند.** «تا جای ممکن نزدیک» به یک عدد نیاز دارد: یک تابع ناهمخوانی. «پارامترها را انتخاب کن» به یک رویه‌ی جستجو نیاز دارد: یک الگوریتم بهینه‌سازی. این هفته هر دو را پوشش می‌دهد.

دلیل عمیق‌تری هم هست که این برای علوم شناختی مهم است. پارامترهای مدل اندازه‌گیری‌های ما از سازه‌های پنهان‌اند (نرخ زوال، احتیاط، حساسیت). رویه‌ی برازش ضعیف اندازه‌گیری‌های ضعیف می‌دهد، و هر نتیجه‌ای که از آن‌ها گرفته شود (تفاوت گروه‌ها، همبستگی با فعالیت مغز، مقایسه‌ی مدل‌ها) آن خطا را به ارث می‌برد. بدتر اینکه، همان‌طور که خواهیم دید، یک بهینه‌ساز می‌تواند «موفقیت» گزارش کند در حالی که جواب بی‌معنی برمی‌گرداند.

این موضوع کجا به کار می‌رود؟

- **هر مطالعه‌ی مبتنی بر مدل در روان‌شناسی** یک مرحله‌ی برازش دارد. منحنی‌های یادگیری، منحنی‌های فراموشی، تابع‌های روان‌سنجی (psychometric function:) اینکه تشخیص با قوی‌تر شدن محرک چطور بهتر می‌شود) و منحنی‌های دوز–پاسخ در روان‌داروشناسی همه با کمینه کردن یک معیار خطا برازش می‌شوند.
- **پژوهش‌های بالینی و رشدی** پارامترهای برازش‌شده را بین گروه‌ها مقایسه می‌کنند (مثلاً نرخ فراموشی بیماران در برابر گروه کنترل). اگر برازش بد باشد یا روی یک کران گیر کرده باشد، مقایسه‌ی گروه‌ها غلط است.
- **علوم اعصاب** منحنی‌های تنظیم (tuning curve) نورون‌ها و تابع پاسخ همودینامیک در fMRI را با همین بهینه‌سازها برازش می‌کند.
- **یادگیری ماشین** مدل‌ها را با کمینه کردن یک تابع زیان (loss) با روش‌های گرادیانی آموزش می‌دهد؛ واژه‌ها (سطح زیان، نرخ یادگیری، کمینه‌ی محلی) همان واژه‌های این هفته‌اند.

۴.۱.۲ جزوه‌ی درس

به زبان ساده مدل چند پیچ تنظیم (پارامتر) دارد. برازش یعنی چرخاندن پیچ‌ها تا منحنی مدل تا جای ممکن از نزدیک نقطه‌های داده بگذرد. برای اینکه کامپیوتر این کار را بکند دو چیز لازم داریم. اول، یک عدد که بگوید برازش فعلی چقدر بد است: **مجموع مربعات خطا** (SSE)، یعنی جمع مربع فاصله‌ی عمودی نقطه‌های داده از منحنی. دوم، روشی برای چرخاندن پیچ‌ها که این عدد را کم کند: یک **بهینه‌ساز** (optimizer). SSE را مثل یک منظره روی همه‌ی تنظیم‌های ممکن پیچ‌ها تصور کنید، با تپه‌ها (برازش بد) و دره‌ها (برازش خوب)؛ بهینه‌ساز یک کوهنورد است که دنبال پایین‌ترین نقطه می‌گردد. مشکل وقتی پیش می‌آید که منظره یک دره‌ی دراز و صاف داشته باشد (دو پیچ می‌توانند اثر هم را جبران کنند)، یک فلات صاف (کوهنورد نمی‌فهمد کدام طرف سرازیری است)، یا چند دره‌ی جدا (کوهنورد ممکن است در دره‌ی اشتباه بایستد). بیشتر این هفته درباره‌ی تشخیص این موقعیت‌ها و محافظت از خودمان در برابر آن‌هاست.

زمان‌بندی پیشنهادی (۶۰ دقیقه): توابع ناهمخوانی ۱۰ · سطح خطا ۱۰ · الگوریتم‌های بهینه‌سازی ۲۰ · مشکلات عملی و چک‌لیست برازش ۱۵ · پیش‌نمایش ۵.

۱. توابع ناهمخوانی

برای مشاهدات y_i و پیش‌بینی‌های مدل $\hat{y}_i = f(x_i;\boldsymbol{\theta})$، $i = 1,\dots,N$:

$$\mathrm{SSE}(\boldsymbol{\theta}) = \sum_{i=1}^{N} \big(y_i - f(x_i;\boldsymbol{\theta})\big)^2, \qquad \mathrm{MSE} = \frac{\mathrm{SSE}}{N}, \qquad \mathrm{RMSD} = \sqrt{\mathrm{MSE}}.$$

- هر سه **کمینه‌کننده‌ی یکسانی** دارند: تبدیل‌های یکنوای همدیگرند. SSE را کمینه و RMSD را گزارش می‌کنیم، چون RMSD بر حسب واحد داده است (اینجا: نسبت یادآوری)، پس «RMSD = ۰.۰۵۷» یعنی پیش‌بینی‌ها به‌طور میانگین حدود ۰.۰۶ خطا دارند.
- **برآورد کمترین مربعات** این است:

$$\hat{\boldsymbol{\theta}}_{\mathrm{LS}} = \arg\min_{\boldsymbol{\theta}} \mathrm{SSE}(\boldsymbol{\theta}).$$

چرا مربع؟ مربع کردن همه‌ی خطاها را مثبت می‌کند، خطاهای بزرگ را به‌شدت جریمه می‌کند، و تابعی هموار (مشتق‌پذیر) می‌دهد که بهینه‌سازها راحت با آن کار می‌کنند. در سطحی عمیق‌تر، کمینه کردن SSE دقیقاً همان برآورد بیشینه درست‌نمایی است، **اگر** نویز گاوسی و با واریانس یکسان برای همه‌ی مشاهدات باشد (هفته‌ی ۴). این «اگر» فرض پنهان کمترین مربعات است.

وقتی فرض برقرار نیست. نسبت‌های یادآوری دوجمله‌ای‌اند: واریانسشان $f(1-f)/n$ به f بستگی دارد. نقاط نزدیک ۰.۵ پرنویزتر از نقاط نزدیک ۰ یا ۱ هستند، ولی SSE ساده با همه‌شان مثل هم رفتار می‌کند. **کمترین مربعات وزنی** (weighted least squares) این را با وزن دادن به هر مربع خطا بر اساس معکوس واریانسش درست می‌کند:

$$\mathrm{WSSE}(\boldsymbol{\theta}) = \sum_{i} \frac{\big(y_i - \hat{y}_i\big)^2}{\mathrm{Var}(y_i)}.$$

این را در تمرین ۳ امتحان می‌کنید. هفته‌ی بعد، بیشینه درست‌نمایی این مسئله را طبیعی‌تر حل می‌کند.

> **نکته:** بعضی کتاب‌ها به RMSD می‌گویند «RMSE». هر دو یک کمیت‌اند.

خواندن ریاضی

- $\sum_{i=1}^{N}$ یعنی «روی همه‌ی N نقطه‌ی داده جمع بزن». $y_i - f(x_i;\boldsymbol{\theta})$ **باقی‌مانده** (residual) نقطه‌ی i است: مقدار مشاهده‌شده منهای مقدار پیش‌بینی‌شده. مربع کردن و جمع زدن برای هر تنظیم پارامتر $\boldsymbol{\theta}$ یک عدد می‌دهد.
- $\arg\min_{\boldsymbol{\theta}} \mathrm{SSE}(\boldsymbol{\theta})$ این‌طور خوانده می‌شود: «مقداری از $\boldsymbol{\theta}$ که در آن SSE کمترین است». به تفاوت دقت کنید: $\min$ کوچک‌ترین مقدار *SSE* است و $\arg\min$ مقدار پارامتری که به آن می‌رسد. ما $\arg\min$ را می‌خواهیم.
- **مثال کوچک.** داده‌ی $y = (0.62, 0.41)$ و پیش‌بینی $(0.66, 0.44)$: باقی‌مانده‌ها $(-0.04, -0.03)$، $\mathrm{SSE} = 0.0016 + 0.0009 = 0.0025$، $\mathrm{MSE} = 0.00125$ و $\mathrm{RMSD} \approx 0.035$: منحنی به‌طور میانگین حدود ۰.۳۵ درصد از نقطه‌ها فاصله دارد.
- در WSSE هر مربع باقی‌مانده بر واریانس همان نقطه تقسیم می‌شود، پس نقطه‌ی پرنویز وزن کمتری دارد. برای داده‌ی دوجمله‌ای واریانس برابر $f(1-f)/n$ است.

۲. سطح خطا (error surface)

برای مدلی با k پارامتر، $\mathrm{SSE}(\boldsymbol{\theta})$ یک سطح روی فضای پارامتر k بعدی است. با $k = 2$ می‌توانیم آن را به شکل نقشه‌ی تراز (contour map) رسم کنیم: مسئله‌ی برازش می‌شود «پایین‌ترین نقطه‌ی این منظره را پیدا کن.»

ویژگی‌هایی که باید بشناسید:

ویژگی	ظاهرش	معنایش
یک کاسه‌ی گرد	خطوط تراز هم‌مرکز و تقریباً دایره‌ای	پارامترها به‌خوبی تعیین می‌شوند و تقریباً مستقل‌اند؛ هر الگوریتم معقولی کمینه را پیدا می‌کند
دره‌ی بلند و مورب	خطوط تراز کشیده و کج	trade-off **پارامترها**: افزایش یک پارامتر را می‌شود با تغییر دیگری جبران کرد. برآوردها در امتداد دره همبسته و نامطمئن خواهند بود (هفته‌ی ۵، هفته‌ی ۷)
فلات (plateau)	خطوط تراز خیلی دور از هم	پیش‌بینی‌های مدل با پارامترها تقریباً تغییر نمی‌کنند (مثلاً نرخ زوال آن‌قدر بزرگ که منحنی پیش‌بینی‌شده همه‌جا ۰ است). روش‌های گرادیانی گیر می‌کنند
چند حوضه‌ی جدا	بیش از یک مجموعه‌ی بسته از خطوط تراز	**کمینه‌های محلی**: جواب الگوریتم به نقطه‌ی شروع بستگی دارد

در فراموشی نمایی، A و λ با هم trade-off دارند: سطح شروع بالاتر با زوال سریع‌تر می‌تواند تقریباً همان مقادیر میانی را پیش‌بینی کند که سطح پایین‌تر با زوال کندتر. به همین دلیل دره مورب است (در lab می‌بینید).

۳. الگوریتم‌های بهینه‌سازی

همه‌ی الگوریتم‌های زیر از مقادیر اولیه‌ی $\boldsymbol{\theta}^{(0)}$ شروع می‌کنند و دنباله‌ای $\boldsymbol{\theta}^{(1)}, \boldsymbol{\theta}^{(2)}, \ldots$ می‌سازند که (امیدواریم) به کمینه پایین برود.

۱.۳ جستجوی شبکه‌ای (grid search)

SSE را در همه‌ی نقاط یک شبکه‌ی منظم حساب کنید و بهترین را نگه دارید.

- **مزایا:** فوق‌العاده ساده؛ گول کمینه‌های محلی روی شبکه را نمی‌خورد؛ تصویری از کل سطح می‌دهد.
- **معایب:** دقت محدود به فاصله‌ی نقاط شبکه است؛ هزینه با تعداد پارامترها **به‌طور نمایی** بالا می‌رود. با ۱۰۰ مقدار برای هر پارامتر: $k = 2$ به 10^4 ارزیابی و $k = 5$ به 10^{10} ارزیابی نیاز دارد. این همان **نفرین ابعاد** (curse of dimensionality) است.
- **کاربرد:** رسم سطح‌های ۱ یا ۲ پارامتری، و تولید مقادیر شروع خوب.

۲.۳ سیمپلکس Nelder–Mead (بدون مشتق)

یک **سیمپلکس** مجموعه‌ای از $k+1$ نقطه در فضای k بعدی است (برای $k = 2$ یک مثلث). هر تکرار سعی می‌کند **بدترین** رأس $\boldsymbol{\theta}_w$ را با حرکت دادنش از میان مرکز ثقل $\bar{\boldsymbol{\theta}}$ بقیه‌ی رأس‌ها جایگزین کند:

حرکت	فرمول (ضرایب استاندارد)	چه وقت
بازتاب (reflect)	$\boldsymbol{\theta}_r = \bar{\boldsymbol{\theta}} + (\bar{\boldsymbol{\theta}} - \boldsymbol{\theta}_w)$	همیشه اول امتحان می‌شود
گسترش (expand)	$\boldsymbol{\theta}_e = \bar{\boldsymbol{\theta}} + 2(\bar{\boldsymbol{\theta}} - \boldsymbol{\theta}_w)$	نقطه‌ی بازتاب‌شده از بهترین فعلی بهتر است؛ جلوتر برو

	حرکت	فرمول (ضرایب استاندارد)	چه وقت
انقباض (contraction)	$\boldsymbol{\theta}_c = \bar{\boldsymbol{\theta}} + \frac{1}{2}(\boldsymbol{\theta}_w - \bar{\boldsymbol{\theta}})$ (داخلی)، یا همین گام در سمت بازتاب (خارجی)	نقطه‌ی بازتاب‌شده از دومین بدترین رأس بهتر نیست	
جمع‌شدن (shrink)	همه‌ی رأس‌ها را تا نیمه به سمت بهترین ببر	انقباض هم شکست خورد	

نقطه‌ی بازتاب‌شده **پذیرفته می‌شود** وقتی از دومین بدترین رأس بهتر باشد ولی از بهترین بهتر نباشد. سیمپلکس سرازیر «غلت می‌خورد»، در امتداد دره‌ها کشیده می‌شود و دور کمینه جمع می‌شود.

- **مزایا:** فقط به مقادیر SSE نیاز دارد (بدون مشتق)؛ در برابر توابع هدف پرنویز یا ناهموار مقاوم است؛ ابزار پیش‌فرض و پرکاربرد در مدل‌سازی شناختی.
- **معایب:** در ابعاد بالا ممکن است کند باشد؛ در دره‌های بلند و باریک ممکن است گیر کند؛ هیچ تضمینی برای پیدا کردن کمینه‌ی سراسری ندارد.

روش‌های جستجوی مستقیم مثل Nelder–Mead در کتاب قدوسیان درباره‌ی روش‌های مستقیم در بهینه‌سازی غیرخطی به‌تفصیل بررسی شده‌اند (مطالعه‌ی بیشتر را ببینید).

۳.۳ روش‌های گرادیانی

گرادیان $\nabla \mathrm{SSE}(\boldsymbol{\theta})$ به سمت سربالایی اشاره می‌کند، پس ما خلافش گام برمی‌داریم:

$$\boldsymbol{\theta}^{(m+1)} = \boldsymbol{\theta}^{(m)} - \eta \, \nabla \mathrm{SSE}\big(\boldsymbol{\theta}^{(m)}\big), \qquad \frac{\partial \,\mathrm{SSE}}{\partial \theta} = -2 \sum_i \big(y_i - \hat{y}_i\big) \, \frac{\partial \hat{y}_i}{\partial \theta},$$

با اندازه‌ی گام (نرخ یادگیری) η. برای مدل نمایی، $\partial \hat{y}/\partial A = e^{-\lambda t}$ و $\partial \hat{y}/\partial \lambda = -A\,t\,e^{-\lambda t}$.

در عمل از روش‌های **شبه‌نیوتنی** (quasi-Newton) مثل BFGS استفاده می‌کنیم. این روش‌ها انحنای سطح را هم تخمین می‌زنند و اندازه‌ی گام را خودکار انتخاب می‌کنند، پس نزدیک کمینه خیلی سریع‌تر همگرا می‌شوند. L-BFGS-B نسخه‌ای است که **کران** پارامترها را می‌پذیرد. اگر گرادیان را ندهید، scipy آن را عددی با تفاضل‌های متناهی تقریب می‌زند.

- **مزایا:** روی سطوح هموار سریع و دقیق‌اند؛ برای تعداد پارامتر زیاد خوب مقیاس‌پذیرند (شبکه‌های عصبی همین‌طور آموزش می‌بینند).
- **معایب:** به تابع هدف هموار نیاز دارند؛ هر جا گرادیان (تقریباً) صفر باشد گیر می‌کنند، هم در فلات‌ها و هم در کمینه‌ها؛ به مقدار شروع حساس‌اند.

پیشرفته: چرا فلات‌ها روش‌های گرادیانی را به دام می‌اندازند. اگر λ خیلی بزرگ باشد، $e^{-\lambda t} \approx 0$ در همه‌ی tهای مشاهده‌شده، پس هر دو مشتق جزئی بالا $0 \approx$ هستند. روش گرادیانی یک «کف صاف» می‌بیند و متوقف می‌شود و گاهی همگرایی موفق گزارش می‌کند. Nelder–Mead مقادیر تابع را در نقاط دور مقایسه می‌کند و می‌تواند از فلات بیرون بیاید. هر دو رفتار را در بخش D lab می‌بینید.

خلاصه:

روش	نیاز به مشتق	کران	کاربرد معمول
جستجوی شبکه‌ای	ندارد	ذاتی	رسم، مقدار شروع، $k \le 2$
Nelder–Mead	ندارد	دارد (scipy ۷.۱ $\ge$)	پیش‌فرض برای مدل‌های شناختی کوچک؛ توابع هدف پرنویز
BFGS	عددی یا تحلیلی	ندارد	توابع هدف هموار، پارامترهای بدون قید
L-BFGS-B	عددی یا تحلیلی	دارد	توابع هدف هموار با پارامترهای کران‌دار

خواندن ریاضی گام گرادیانی $\boldsymbol{\theta}^{(m+1)} = \boldsymbol{\theta}^{(m)} - \eta\,\nabla\mathrm{SSE}(\boldsymbol{\theta}^{(m)})$ این‌طور خوانده می‌شود: حدس جدید = حدس قبلی − اندازه‌ی گام × شیب. بالانویس (m) شماره‌ی تکرار است، نه توان. $\nabla\mathrm{SSE}$ بردار مشتق‌های جزئی است (برای هر پارامتر یک شیب). علامت منفی گام را به سمت سرازیری می‌برد.

فرمول مشتق $\partial\,\mathrm{SSE}/\partial\theta = -2\sum_i (y_i - \hat{y}_i)\,\partial\hat{y}_i/\partial\theta$ از قاعده‌ی زنجیره‌ای می‌آید. می‌گوید: نقطه‌هایی که باقی‌مانده‌شان بزرگ است و پیش‌بینی در آن‌ها به θ حساس است، θ را قوی‌تر از بقیه می‌کشند. در نقطه‌ی کمینه این کشش‌ها همدیگر را خنثی می‌کنند و جمع صفر می‌شود.

برای یک مهندس

- **کمترین مربعات** همان معیار تخمین کانال و برازش منحنی است؛ تفاوت اینجا این است که مدل‌ها نسبت به پارامترها **غیرخطی**‌اند ($e^{-\lambda t}$)، پس جواب بسته‌ای از معادله‌های نرمال وجود ندارد و به جست‌وجوی تکراری نیاز داریم.
- **کمترین مربعات وزنی** همان سفید کردن نویز (noise whitening) است: تقسیم بر واریانس همان کاری است که وقتی نویز سفید نیست (نویز ناهمسان‌واریانس) پیش از LS انجام می‌دهید.
- **گرادیان نزولی با اندازه‌ی گام** η همان ایده‌ی steepest descent در فیلتر تطبیقی LMS است. BFGS یک روش شبه‌نیوتنی است (تقریبی از Hessian می‌سازد)، نزدیک به Gauss–Newton / Levenberg–Marquardt در LS غیرخطی.
- **یک دره‌ی دراز مورب** در سطح خطا یعنی مسئله **بدحالت** (ill-conditioned) است: نسبت مقدار ویژه‌های Hessian بزرگ است، مثل وقتی که رگرسورها به‌شدت همبسته‌اند. پارامترها در یک جهت خوب و در جهت دیگر بد تعیین می‌شوند.
- reparameterization ($\lambda = e^{\eta}$) یک تغییر متغیر است که مسئله‌ی مقید را به مسئله‌ی بدون قید تبدیل می‌کند و اغلب حالت (conditioning) مسئله را هم بهتر می‌کند.
- **تفاوت با کار مهندسی:** مجموعه داده‌ها کوچک‌اند (۸ نقطه، هرکدام ۵۰ آیتم)، نویز زیاد است، و پارامترها باید از نظر روان‌شناختی تفسیر شوند. پس کافی نیست منحنی پیش‌بینی‌شده خوب به نظر برسد؛ تک‌تک مقدارهای پارامتر باید قابل اعتماد باشند.

۴. مشکلات عملی و راه‌حل‌ها

۱. مقادیر شروع. از شروع‌های آگاهانه استفاده کنید: از روی نمودار بخوانید، یک برازش خطی‌شده‌ی سریع (هفته‌ی ۲) بگیرید، یا بهترین نقطه‌ی یک شبکه‌ی درشت را بردارید.

۲. کمینه‌های محلی ← multi-start. بهینه‌ساز را از تعداد زیادی نقطه‌ی شروع تصادفی اجرا کنید و بهترین جواب را نگه دارید. اگر شروع‌های زیادی روی یک کمینه توافق کنند، می‌توانید نسبتاً مطمئن باشید که کمینه‌ی سراسری است. multi-start بیمه‌ی ارزانی است؛ برای مدل‌های بیش از دو پارامتر همیشه از آن استفاده کنید.

۳. کران پارامترها. بسیاری از پارامترها دامنه‌ی طبیعی دارند ($0 \le A \le 1$، $\lambda > 0$). بدون قید، بهینه‌سازها با خیال راحت $A = 29.6$ برمی‌گردانند. سه رویکرد:

رویکرد	چطور	توضیح
بهینه‌ساز کران‌دار	`method="L-BFGS-B"` یا `"Nelder-Mead"` با `bounds=`	ساده‌ترین؛ پیش‌فرض توصیه‌شده
reparameterization	روی η بدون قید بهینه کنید و تبدیل کنید: $\lambda = e^{\eta}$ (مثبت)، $A = 1/(1+e^{-\alpha_A})$ (بین ۰ و ۱)	با هر بهینه‌سازی کار می‌کند؛ در مدل‌سازی بیزی هم استفاده می‌شود (هفته‌ی ۱۳)
جریمه	وقتی پارامتر خارج از دامنه است یک SSE خیلی بزرگ برگردانید	ناپیوستگی می‌سازد؛ از آن پرهیز کنید

۴. non-identifiability. گاهی چند ترکیب پارامتر به یک اندازه خوب برازش می‌شوند. مثالش مدلی دوجزئی است که برچسب دو جزئش قابل جابه‌جایی است. این ویژگی خود مدل است، نه شکست بهینه‌ساز، و multi-start آن را آشکار می‌کند (بخش D lab).

۵. اعتماد کن، ولی بررسی کن. `result.success==True` فقط یعنی قاعده‌ی توقف الگوریتم برقرار شده است. همیشه (۱) منحنی برازش‌شده را روی داده رسم کنید، (۲) به باقی‌مانده‌ها نگاه کنید، و (۳) بررسی کنید برآوردها در دامنه‌ی معقول باشند.

چک‌لیست برازش (از این به بعد در هر lab از آن استفاده کنید):

۱. داده‌ها را رسم کنید.
۲. مدل و تابع ناهمخوانی را بنویسید؛ آن‌ها را روی چند مقدار پارامتر دلخواه آزمون کنید.
۳. کران‌ها و مقادیر شروع معقول انتخاب کنید.
۴. بهینه کنید، ترجیحاً با multi-start.
۵. پیام همگرایی، نمودار، باقی‌مانده‌ها و دامنه‌ی پارامترها را بررسی کنید.
۶. یک بررسی بازیابی انجام دهید: از پارامترهای برازش‌شده داده شبیه‌سازی کنید، دوباره برازش کنید و مقایسه کنید (هفته‌ی ۷ این را نظام‌مند می‌کند).

> **پیشرفته: پارامترهای شرطاً خطی.** در $f(t) = A\,e^{-\lambda t}$، برای هر λ ثابت بهترین A فرم بسته دارد، چون مدل نسبت به A خطی است: $\hat{A}(\lambda) = \sum_i y_i g_i / \sum_i g_i^2$ با $g_i = e^{-\lambda t_i}$. جای‌گذاری آن مسئله را به یک مسئله‌ی یک‌بعدی فقط بر حسب λ تبدیل می‌کند. این ترفند (حذف پارامترهای خطی یا ***variable projection***) برازش را سریع‌تر و پایدارتر می‌کند، و تابع یک‌بعدی حاصل با ***profile likelihood*** هفته‌ی ۵ مرتبط است.

برای مدرس

- **اول منظره را نشان دهید.** نمودار تراز SSE روی (A, λ) (بخش B lab) همه‌ی ایده‌های بعدی را ملموس می‌کند: کمینه، دره‌ی مورب، فلات. آن را زود روی پروژکتور بیاورید و مدام به آن برگردید.
- **Nelder–Mead را اجرا کنید.** یک مثلث روی نمودار تراز بکشید و یک بازتاب (reflection) را با دست انجام دهید (قدم ۲ مثال حل‌شده). دانشجوها «مثلثی که قل می‌خورد» را خیلی بهتر از جدول حرکت‌ها به خاطر می‌سپارند.

- **نقطه‌ی قوت شما:** شما gradient descent و کمترین مربعات را می‌شناسید. وقت کمتری روی الگوریتم‌ها و وقت بیشتری روی حالت‌های شکست بگذارید (بخش D lab: بهینه‌سازی که در $A = 29.6$ اعلام موفقیت می‌کند، به‌یادماندنی‌ترین درس این هفته است.
- **سؤال‌های رایج.**
  - «از کدام بهینه‌ساز استفاده کنم؟» برای مدل‌های شناختی کوچک: Nelder–Mead یا L-BFGS-B با کران، همیشه همراه با multi-start.
  - «چرا همیشه از *grid* استفاده نکنیم؟» هزینه با تعداد پارامترها به‌طور نمایی زیاد می‌شود.
  - «آیا *SSE* معیار درستی است؟» فقط اگر نویز گاوسی و با واریانس برابر باشد؛ هفته‌ی بعد درست‌نمایی جای آن را می‌گیرد.

۵.۱.۲ مثال حل‌شده

داده. یک شرکت‌کننده نسبت‌های $y = (0.62, 0.41, 0.19)$ را در $t = (1, 3, 7)$ روز به یاد می‌آورد. مدل: $f(t) = A\,e^{-\lambda t}$.

قدم ۱: یک جستجوی شبکه‌ای کوچک با دست

برای $(A, \lambda) = (0.8, 0.2)$: پیش‌بینی‌ها $0.8e^{-0.2} = 0.655$، $0.8e^{-0.6} = 0.439$، $0.8e^{-1.4} = 0.197$، پس

$$\text{SSE} = (0.62-0.655)^2 + (0.41-0.439)^2 + (0.19-0.197)^2 = 0.00123 + 0.00084 + 0.00005 \approx 0.00212.$$

با تکرار این کار برای یک شبکه‌ی ۲ × ۳:

	$\lambda = 0.15$	$\lambda = 0.20$	$\lambda = 0.25$
$A = 0.8$	۰۲۲۸۱.۰	**۰۰۲۱۲.۰**	۰۰۳۶۴.۰
$A = 0.9$	۰۶۶۳۸.۰	۰۲۱۷۲.۰	۰۰۷۹۱.۰

بهترین نقطه‌ی شبکه $(0.8, 0.20)$ است. به کجی دقت کنید: $(0.9, 0.25)$ خیلی بهتر از $(0.9, 0.15)$ است. A بزرگ‌تر یک λ بزرگ‌تر «می‌خواهد»؛ این همان دره‌ی trade-off است.

قدم ۲: یک تکرار Nelder–Mead با دست

با سیمپلکس (مثلث) سه نقطه‌ی شبکه شروع کنید:

رأس	(A, λ)	SSE	رتبه
$\boldsymbol{\theta}_b$	(۰.۸، ۰.۲۵)	۰۰۳۶۴.۰	بهترین
$\boldsymbol{\theta}_g$	(۰.۸، ۰.۱۵)	۰۲۲۸۱.۰	دومین بدترین
$\boldsymbol{\theta}_w$	(۰.۹، ۰.۱۵)	۰۶۶۳۸.۰	بدترین

۱. **مرکز ثقل** همه‌ی رأس‌ها جز بدترین: $\bar{\boldsymbol{\theta}} = \big((0.8+0.8)/2,\ (0.25+0.15)/2\big) = (0.8, 0.20)$.
۲. **بازتاب** بدترین رأس از میان مرکز ثقل: $\boldsymbol{\theta}_r = (0.8, 0.20) + \big((0.8, 0.20) - (0.9, 0.15)\big) = (0.7, 0.25)$.
۳. **ارزیابی:** پیش‌بینی‌ها $(0.545, 0.331, 0.122)$، پس $\mathrm{SSE}(\boldsymbol{\theta}_r) = 0.01657$.
۴. **تصمیم:** $0.00364 \le 0.01657 < 0.02281$. نقطه‌ی بازتاب‌شده از دومین بدترین بهتر است ولی از بهترین بهتر نیست، پس **بازتاب را می‌پذیریم** (بدون گسترش).
۵. **سیمپلکس جدید:** $\{(0.8, 0.25),\ (0.7, 0.25),\ (0.8, 0.15)\}$، و بدترین SSE از ۰.۰۶۶ به ۰.۰۲۳ کم شده است.

قدم ۳: بگذارید کامپیوتر تمامش کند

اجرای `scipy.optimize.minimize(...,method="Nelder-Mead")` از $(0.8, 0.2)$ به $\hat{A} = 0.754$، $\hat{\lambda} = 0.200$ با $\mathrm{RMSD\ SSE} = 3.7 \times 10^{-5}$ ($= 0.0035$) همگرا می‌شود.

تفسیر. مدل برازش‌شده می‌گوید این شرکت‌کننده بلافاصله بعد از یادگیری حدود ۷۵٪ را به یاد می‌آورد و هر روز حدود ۱۸٪ از باقی‌مانده را از دست می‌دهد ($1 - e^{-0.2} = 0.181$)، با نیمه‌عمر $\ln 2 / 0.2 \approx 3.5$ روز. با فقط سه داده و دو پارامتر، برازش تقریباً کامل چیز زیادی درباره‌ی درست بودن مدل نمایی نمی‌گوید. هر منحنی نزولی دوپارامتری معقولی سه نقطه را خوب برازش می‌کند (هفته‌ی ۶).

۶.۱.۲ lab (۲ ساعت)

اهداف

۱. نوشتن یک تابع SSE و بررسی سطح خطای دو مدل فراموشی.
۲. برازش با جستجوی شبکه‌ای، سپس با Nelder–Mead و L-BFGS-B؛ مقایسه با برازش‌های خطی‌شده‌ی هفته‌ی قبل.
۳. ایجاد و رفع شکست‌های برازش: فلات‌ها، کمینه‌های محلی و برآوردهای خارج از دامنه.
۴. **ارزیابی** برازش‌ها (RMSD)، باقی‌مانده‌ها، مقایسه با مقادیر واقعی) و **تفسیر** پارامترها.

زمان‌بندی: بخش A ۱۵ دقیقه · بخش B ۲۵ دقیقه · بخش C ۲۵ دقیقه · بخش D ۳۵ دقیقه · بخش E ۲۰ دقیقه.

آماده‌سازی و داده

Code · **کد:** `code/week03.py`، cell ۱ · سلول ۱

بخش A: آشنایی با تابع ناهمخوانی (۱۵ دقیقه)

Code · **کد:** `code/week03.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
theta = (0.9, 0.5):  power SSE = 0.0349   exponential SSE = 0.4511
theta = (0.8, 0.4):  power SSE = 0.0328   exponential SSE = 0.4145
theta = (0.9, 0.1):  power SSE = 0.9047   exponential SSE = 0.2192
theta = (0.6, 0.05):  power SSE = 0.3303   exponential SSE = 0.1145
```

پیش از اجرای بخش‌های بعد **پیش‌بینی کنید**: کدام مقادیر پارامتر کمترین SSE را برای هر مدل می‌دهند؟ حدستان را یادداشت کنید.

بخش B: جستجوی شبکه‌ای و سطح خطا (۲۵ دقیقه)

Code · **کد:** `code/week03.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
exp: grid minimum A = 0.655, rate = 0.0560, SSE = 0.10607  (42300
↪  evaluations)
pow: grid minimum A = 0.870, rate = 0.4239, SSE = 0.02592  (42300
↪  evaluations)
```

به این دقت کنید: هر دو سطح یک حوضه دارند، ولی یک **دره‌ی کشیده و مورب**: A بالاتر با زوال بیشتر همراه است. این همان trade-off پارامترهاست. برای مدل توانی، مقدار واقعی (× سفید) داخل دره است ولی در ته آن نیست: با داده‌ی محدود، بهترین برازش هیچ‌وقت دقیقاً همان مقدار واقعی نیست.

بخش C: برازش با یک بهینه‌ساز (۲۵ دقیقه)

Code · **کد:** `code/week03.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
model            method      A   rate    SSE   RMSD  f_evals success
  exp         L-BFGS-B 0.6568 0.0566 0.1061 0.1151     39.0    True
  exp       Nelder-Mead 0.6568 0.0566 0.1061 0.1151     69.0    True
  exp              grid 0.6550 0.0560 0.1061 0.1151  42300.0    True
  exp linearized (Wk 2) 0.5500 0.0320 0.1373 0.1310      NaN     NaN
  pow         L-BFGS-B 0.8712 0.4251 0.0259 0.0569     36.0    True
  pow       Nelder-Mead 0.8711 0.4251 0.0259 0.0569     71.0    True
  pow              grid 0.8700 0.4239 0.0259 0.0569  42300.0    True
  pow linearized (Wk 2) 0.7970 0.3700 0.0315 0.0628      NaN     NaN
```

Code · **کد:** `code/week03.py`، cell ۵ · سلول ۵

به این‌ها دقت کنید: – Nelder–Mead و L-BFGS-B تا سه یا چهار رقم اعشار با هم توافق دارند؛ شبکه در حد فاصله‌ی نقاطش (۰۰۵.۰ برای A) با آن‌ها فرق دارد. بهینه‌سازها فقط ۳۶ تا ۷۱ ارزیابی تابع لازم داشتند، به‌جای ۴۲ ۳۰۰. – کمترین مربعات SSE **کمتری** از برازش‌های خطی‌شده‌ی هفته‌ی ۲ می‌دهد (دقیقاً همین کمیت را کمینه می‌کند)، و برآوردهای مدل توانی خیلی به مقدار واقعی نزدیک‌ترند. – مسیر اول سریع وارد دره می‌شود و بعد آرام در امتدادش می‌خزد؛ یک الگوی معمول.

بخش D: وقتی برازش خراب می‌شود (۳۵ دقیقه)

D1. **یک فلات و یک «موفقیت» کاذب.** برازش نمایی را با یک نرخ زوال بی‌معنی، $\lambda = 20$ در روز، شروع کنید:

Code · **کد:** `code/week03.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
BFGS         A =   29.571  lambda =  14.244  SSE = 1.1616  success =
 ↪  True  (Optimization terminated successfully.)
L-BFGS-B     A =   29.905  lambda =  14.289  SSE = 1.1616  success =
 ↪  True  (CONVERGENCE: NORM_OF_PROJECTED_GRADIENT_<=_PGTOL)
Nelder-Mead  A =    0.657  lambda =   0.057  SSE = 0.1061  success =
 ↪  True  (Optimization terminated successfully.)
```

(متن پیام L-BFGS-B بین نسخه‌های SciPy کمی فرق می‌کند.) دو روش گرادیانی **موفقیت** گزارش می‌کنند ولی برازشی بی‌معنی برمی‌گردانند: A حدود ۳۰ است (احتمال یادآوری ٪۳۰۰۰!) و منحنی پیش‌بینی‌شده عملاً در همه‌ی فاصله‌ها صفر است. آن‌ها روی فلاتی شروع کردند که گرادیان در آن تقریباً صفر است (کادر «پیشرفته» بخش ۳.۳ جزوه). Nelder–Mead فرار کرد. درس‌ها: (۱) همیشه برآوردها و نمودارها را بررسی کنید، نه فقط `success` را؛ (۲) از کران استفاده کنید؛ (۳) از مقادیر شروع معقول یا متعدد استفاده کنید.

D2. reparameterization. پارامترها را بدون قید کنید تا هر بهینه‌سازی دامنه‌های $0 < A < 1$ و $\lambda > 0$ را رعایت کند:

Code · **کد:** `code/week03.py`، cell ۷ · سلول ۷

خروجی مورد انتظار:

```
BFGS on reparameterized power model: A = 0.8712, d = 0.4251, SSE =
↪  0.02592
```

همان جواب بخش C، و تضمین می‌شود که برآوردها در دامنه باشند.

D3. **کمینه‌های محلی و** multi-start. یک ایده‌ی رایج در پژوهش‌های حافظه این است که فراموشی بازتاب دو رد حافظه (memory trace) است: یک جزء **سریع** که زود زوال پیدا می‌کند و یک جزء **کند** که می‌ماند:

$$f(t) = A_1 e^{-\lambda_1 t} + A_2 e^{-\lambda_2 t}.$$

این مدل $k = 4$ پارامتر دارد و سطح خطایش چند حوضه دارد. آن را از ۵۰ نقطه‌ی شروع تصادفی برازش کنید:

Code · **کد:** `code/week03.py`، cell ۸ · سلول ۸

خروجی مورد انتظار:

```
Distinct final SSE values (rounded) and how often each was reached:
  SSE = 0.0201: 42 starts
  SSE = 0.0203: 1 starts
  SSE = 0.0337: 1 starts
  SSE = 0.0340: 1 starts
  SSE = 0.0359: 1 starts
  SSE = 0.1064: 1 starts
  SSE = 0.2010: 1 starts
  SSE = 0.2456: 1 starts
  SSE = 0.9092: 1 starts
Best 3 solutions (A1, lam1, A2, lam2):
   [0.58  0.36  0.264 0.   ] SSE = 0.02013
   [0.264 0.    0.58  0.36 ] SSE = 0.02013
   [0.264 0.    0.58  0.36 ] SSE = 0.02013
```

به این‌ها دقت کنید: - حدود ۴۰ شروع از ۵۰ در همان بهترین حوضه تمام می‌شوند، ولی بقیه (حدود ۱ از ۶) در **کمینه‌های محلی بدتر** گیر می‌کنند؛ بعضی با SSE چند برابر بزرگ‌تر. (تعداد دقیق بین نسخه‌های SciPy کمی فرق دارد؛ با SciPy ۱۸.۱ برابر ۴۱ از ۵۰ است.) یک اجرای تنها از یک شروع بدشانس جواب غلطی می‌داد، بدون هیچ هشداری. - در میان بهترین جواب‌ها، اجزای سریع و کند ممکن است **با برچسب‌های جابه‌جا** ظاهر شوند ($A_1, \lambda_1 \leftrightarrow A_2, \lambda_2$). هر دو همان منحنی را توصیف می‌کنند. این یک non-identifiability ذاتی مدل است، و راه‌حل رایج اعمال قید ترتیبی مثل $\lambda_1 > \lambda_2$ است. - در بهترین جواب، یکی از اجزا نرخ دقیقاً ۰ دارد (یک جزء ثابت و بدون زوال به اندازه‌ی ۰.۲۶۴). پس مدل دوردی برازش‌شده به مدل نمایی با مجانب تمرین ۴ تبدیل شده، با همان SSE (۰.۰۲۰۱). آیا این یک «حافظه‌ی دائمی» معنادار است یا فقط پارامترهای اضافه نویز را جذب کرده‌اند؟ یادتان باشد داده‌ها از یک مدل توانی آمده‌اند. برازش به‌تنهایی نمی‌تواند جواب دهد (هفته‌های ۶–۷).

بخش E: ارزیابی و تفسیر (۲۰ دقیقه)

Code · **کد:** `code/week03.py`، cell ۹ · سلول ۹

خروجی مورد انتظار:

```
Power model: relative loss rate at t =  1 days: 0.213 per day
Power model: relative loss rate at t = 20 days: 0.020 per day
Exponential model: constant relative loss rate 0.057 per day
```

تفسیر (برای هرکدام ۲ تا ۳ جمله در notebook بنویسید):

۱. الگوهای باقی‌مانده‌ها را مقایسه کنید. کدام مدل الگوی نظام‌مند نشان می‌دهد، و آن الگو درباره‌ی شکل فراموشی در این داده‌ها چه می‌گوید؟
۲. نرخ نسبی فراموشی مدل توانی از حدود ۲۱.۰ در روز بعد از ۱ روز به حدود ۰۲.۰ در روز بعد از ۲۰ روز می‌رسد. به زبان ساده توضیح دهید این چه ادعایی درباره‌ی حافظه دارد.
۳. برآوردهای کمترین مربعات ($\hat{A} \approx 0.87$، $\hat{d} \approx 0.43$) از برآوردهای خطی‌شده‌ی هفته‌ی قبل به مقدار واقعی نزدیک‌ترند ولی هنوز با آن برابر نیستند. آیا این شکست روش است؟ (راهنمایی: اگر آزمایش را با یک نمونه‌ی تصادفی جدید تکرار می‌کردید چه می‌شد؟)

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆ **(کمینه‌کننده‌ی یکسان).** مدل توانی را یک بار با کمینه کردن SSE، یک بار MSE و یک بار RMSD برازش کنید. نشان دهید برآوردها (در حد تلرانس بهینه‌ساز) یکسان‌اند. چرا باز هم ترجیح می‌دهیم RMSD را گزارش کنیم؟

تمرین ۲ ⋆ **(ابینگهاوس با کمترین مربعات).** داده‌های savings ابینگهاوس از تمرین ۳ هفته‌ی ۲ (مقادیر با علامت [بررسی شود]) را برای هر دو مدل با کمترین مربعات دوباره برازش کنید. پارامترها و RMSD را با برازش‌های خطی‌شده‌ی هفته‌ی ۲ مقایسه کنید.

تمرین ۳ ⋆⋆ **(کمترین مربعات وزنی).** نسبت‌های دوجمله‌ای واریانس $f(1-f)/n$ دارند. WSSE (بخش ۱ جزوه) را با استفاده از f **پیش‌بینی‌شده** در واریانس پیاده‌سازی کنید، مدل توانی را دوباره برازش کنید و برآوردها را با کمترین مربعات ساده مقایسه کنید. کدام نقاط داده تأثیر بیشتری پیدا می‌کنند و کدام کمتر؟ (هفته‌ی بعد می‌بینید که بیشینه درست‌نمایی این وزن‌دهی را خودکار انجام می‌دهد.)

تمرین ۴ ⋆⋆ **(پارامتر بیشتر، برازش بهتر؟).** مدل سه‌پارامتری **نمایی با مجانب** $f(t) = B + (A-B)e^{-\lambda t}$ را که در آن B مجانب بلندمدت است، با کران‌های $0 \le B \le A \le 1$ برازش کنید (راهنمایی: reparameterize کنید، یا قید را بعد از برازش بررسی کنید). انتظار: SSE $\approx$ ۰۲۰.۰ که **کمتر** از SSE $\approx$ ۰۲۶.۰ مدل توانی است، با اینکه داده‌ها از مدل توانی تولید شده‌اند! این درباره‌ی استفاده از SSE برای انتخاب بین مدل‌هایی با تعداد پارامتر متفاوت چه می‌گوید؟ (در هفته‌های ۶–۷ جواب درست این را می‌دهیم.)

تمرین ۵ ⋆⋆⋆ **(پیشرفته: Nelder–Mead از صفر).** Nelder–Mead را برای $k = 2$ با حرکت‌های بخش ۲.۳ جزوه (بازتاب، گسترش، انقباض داخلی/خارجی، جمع‌شدن) و یک قاعده‌ی توقف بر اساس پراکندگی مقادیر SSE در سیمپلکس پیاده‌سازی کنید. آن را روی مدل توانی از $(0.8, 0.2)$ اجرا کنید، سیمپلکس را هر چند تکرار یک بار روی سطح خطا رسم کنید، و نتیجه و تعداد ارزیابی‌های تابع را با `scipy` مقایسه کنید.

lab check-off

به مدرس یا دستیار آموزشی نشان دهید: (۱) نمودارهای سطح خطا با کمینه‌های شبکه (بخش B، (۲) جدول مقایسه از بخش C، (۳) هیستوگرام multi-start (بخش D3) با یک جمله درباره‌ی آنچه نشان می‌دهد، و (۴) جوابتان به سؤال تفسیری ۱ (بخش E).

۷.۱.۲ ارتباط با هوش مصنوعی و LLMها

قانون‌های مقیاس (scaling laws) **همان برازش منحنی‌اند.** یکی از تأثیرگذارترین نتایج هوش مصنوعی امروز این است که خطای آزمون (test loss) مدل‌های زبانی با اندازه‌ی مدل N، اندازه‌ی داده و محاسبات به‌طور هموار کم می‌شود و از یک **قانون توانی** با مجانب پیروی می‌کند: $L(N) = E + B\,N^{-\alpha}$ (Kaplan et al., ۲۰۲۰؛ Hoffmann et al., ۲۰۲۲). شرکت‌ها از چنین برازش‌هایی استفاده می‌کنند تا تصمیم بگیرند مدل بعدی چقدر بزرگ باشد. از نظر ریاضی، این همان مسئله‌ی برازش منحنی فراموشی است: یک مدل غیرخطی با سه پارامتر که با کمترین مربعات، یک بهینه‌ساز عددی و چند نقطه‌ی شروع برازش می‌شود. دام‌هایش هم همان‌اند: برون‌یابی (extrapolation) خیلی دورتر از داده، و trade-off پارامترها (اینجا E و α).

Code · **کد:** `code/week03.py`، cell ۱۰ · سلول ۱۰

خروجی مورد انتظار:

```
E = 1.70, B = 3.22, alpha = 0.358, SSE = 0.00424
Extrapolated loss at N = 1e11: 1.754
```

امتحانش کنید (بدون نیاز به API). ⋆ - یک قانون توانی خالص بدون مجانب ($E = 0$) برازش کنید. SSE و برون‌یابی تا $N = 10^{11}$ را مقایسه کنید. کدام نتیجه‌گیری درباره‌ی «بزرگ‌تر بهتر است» عوض می‌شود؟ - ⋆⋆ فقط چهار مدل کوچک‌تر را برازش کنید و تا چهار مدل بزرگ‌تر برون‌یابی کنید. پیش‌بینی چقدر خطا دارد؟ با seedهای مختلف تکرار کنید تا ببینید برون‌یابی چقدر پایدار است. - ⋆⋆ سطح SSE را روی E و α رسم کنید (با B در بهترین مقدارش برای هر جفت). آیا مثل lab هفته‌ی ۳ یک ridge وجود دارد؟

مطالعه‌ی اختیاری: Kaplan, J., et al. (2020). Scaling laws for neural language models. *arXiv:2001.08361*.
Hoffmann, J., et al. (2022). Training compute-optimal large language models. *arXiv:2203.15556*.

۸.۱.۲ اشتباهات رایج و برداشت‌های نادرست

۱. **«`success=True` یعنی برازش خوب است.»** فقط یعنی یک قاعده‌ی توقف برقرار شده است (بخش D1). همیشه برآوردها، نمودارها و باقی‌مانده‌ها را وارسی کنید.
۲. **یک شروع کافی است.** برای هر مدلی فراتر از مدل‌های ساده‌ی دوپارامتری multi-start اجرا کنید. هزینه‌اش کم است؛ خطر گزارش یک کمینه‌ی محلی کم نیست.
۳. **نادیده گرفتن دامنه‌ی پارامترها.** بهینه‌سازهای بدون کران می‌توانند مقادیر ناممکن برگردانند (نرخ منفی، احتمال بیشتر از ۱). از کران یا reparameterization استفاده کنید.

۴. **مقایسه‌ی SSE بین مدل‌هایی با تعداد پارامتر متفاوت.** مدل منعطف‌تر تقریباً همیشه در SSE برنده است (تمرین ۴). این سؤالی درباره‌ی ارزیابی مدل است، نه برآورد (هفته‌های ۶–۷).
۵. **مقایسه‌ی SSE بین مجموعه‌داده‌هایی با اندازه‌ی متفاوت.** SSE با N بزرگ می‌شود؛ برای مقایسه از RMSD استفاده کنید.
۶. **کمینه‌کننده را همان مقدار واقعی دانستن.** $\hat{\theta}$ برآوردی با خطای نمونه‌گیری است. نمونه‌ی دیگر برآورد دیگری می‌دهد (هفته‌ی ۵ این را کمّی می‌کند).
۷. **فراموش کردن فرض کمترین مربعات.** SSE ساده نویز گاوسی و برابر برای همه‌ی مشاهدات فرض می‌کند. نسبت‌ها، شمارش‌ها و زمان‌های واکنش معمولاً این فرض را نقض می‌کنند.
۸. **استفاده از جستجوی شبکه‌ای برای تعداد پارامتر زیاد.** هزینه منفجر می‌شود (100^k ارزیابی). شبکه را فقط برای رسم و مقادیر شروع به کار ببرید.

۹.۱.۲ خودآزمایی

۱. چرا SSE، MSE و RMSD کمینه‌کننده‌ی یکسانی دارند؟ کدام را گزارش می‌کنید و چرا؟ **پاسخ** SSE/N = MSE و RMSD = $\sqrt{\text{MSE}}$ تبدیل‌های اکیداً صعودی SSE هستند (N ثابت است)، پس همان پارامترها هر سه را کمینه می‌کنند. RMSD را گزارش کنید، چون بر حسب واحد داده است و بین مجموعه‌داده‌هایی با اندازه‌ی متفاوت قابل مقایسه است.

۲. trade-off پارامترها چیست و روی سطح خطا چگونه دیده می‌شود؟ **پاسخ** تغییر یک پارامتر را می‌شود با تغییر پارامتر دیگری جبران کرد، طوری که پیش‌بینی‌ها (و SSE تقریباً عوض نشوند). روی سطح به شکل یک دره‌ی کشیده و مورب با SSE پایین دیده می‌شود. در این حالت برآوردها همبسته‌اند و در جهت دره ضعیف تعیین می‌شوند.

۳. با ۵۰ مقدار شبکه برای هر پارامتر، جستجوی شبکه‌ای برای یک مدل ۶ پارامتری به چند ارزیابی SSE نیاز دارد؟ این یعنی چه؟ **پاسخ** $50^6 \approx 1.56 \times 10^{10}$ ارزیابی. جستجوی شبکه‌ای فراتر از ۲ تا ۳ پارامتر عملی نیست (نفرین ابعاد)؛ به بهینه‌سازهای تکراری نیاز داریم.

۴. در یک تکرار Nelder–Mead، نقطه‌ی بازتاب‌شده از بهترین رأس فعلی بهتر است. الگوریتم بعد چه می‌کند؟ **پاسخ** یک گسترش امتحان می‌کند: نقطه‌ای در همان جهت با فاصله‌ی دو برابر از مرکز ثقل. اگر نقطه‌ی گسترش‌یافته از نقطه‌ی بازتاب‌شده بهتر باشد آن را نگه می‌دارد، وگرنه نقطه‌ی بازتاب‌شده را.

۵. چرا یک بهینه‌ساز گرادیانی ممکن است روی فلات متوقف شود و موفقیت گزارش کند؟ **پاسخ** قاعده‌ی توقفش بر اساس نزدیک به صفر بودن گرادیان (یا اندازه‌ی گام) است. روی فلات گرادیان نزدیک صفر است با اینکه آن نقطه کمینه نیست، پس معیار همگرایی برقرار می‌شود.

۶. دو راه برای مثبت نگه داشتن یک پارامتر نرخ زوال در حین برازش بگویید. **پاسخ** (۱) استفاده از بهینه‌ساز کران‌دار (مثلاً L-BFGS-B یا Nelder–Mead با `bounds=[(1e-6,None)]`). (۲) reparameterization: η را روی کل اعداد حقیقی بهینه کنید و قرار دهید $\lambda = e^{\eta}$.

۷. برازش‌های multi-start مدل دوجزئی با $(A_1, \lambda_1, A_2, \lambda_2) = (0.58, 0.36, 0.26, 0.00)$ و $(0.26, 0.00, 0.58, 0.36)$ به یک SSE کمینه‌ی یکسان می‌رسند. آیا این مشکل بهینه‌ساز است؟ **پاسخ** نه. این جابه‌جایی برچسب (label switching) است: جابه‌جا کردن دو جزء دقیقاً همان منحنی را می‌دهد، پس مدل بدون یک قید ترتیبی (مثلاً $\lambda_1 > \lambda_2$) identifiable نیست. بهینه‌ساز به‌درستی دو کمینه‌ی سراسری معادل را پیدا کرده است.

۱۰.۱.۲ تکلیف

این هفته تکلیف نمره‌دار جدیدی منتشر نمی‌شود. A1 **(از کلامی به فرمال) در ابتدای درس هفته‌ی ۴ تحویل داده می‌شود.** lab امروز همه‌ی چیزهایی را که برای مرحله‌ی کالیبراسیون A1 لازم است به شما می‌دهد، اگر بخواهید استخراج بسته‌ی خود را عددی بررسی کنید.

تمرین اختیاری (بدون نمره، پیش از هفته‌ی ۴ توصیه می‌شود): تمرین‌های ۳ و ۴ lab را کامل کنید. تمرین ۳ (کمترین مربعات وزنی) پلی به بیشینه درست‌نمایی است، و تمرین ۴ پیش‌نمایشی از مسئله‌ی اصلی ارزیابی مدل است. راه‌حل‌ها در ابتدای lab هفته‌ی ۴ به‌طور مختصر بحث می‌شوند.

۱۱.۱.۲ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۳.** برآورد پایه‌ی پارامتر: توابع ناهمخوانی، سطوح خطا، الگوریتم سیمپلکس و مسائل عملی مثل کمینه‌های محلی و مقادیر شروع. (منبع اصلی.)
- **قدوسیان (۱۴۰۱)**، مبانی روش‌های مستقیم در بهینه‌سازی غیرخطی: روش‌های جستجوی مستقیم برای بهینه‌سازی غیرخطی، از جمله روش‌های نوع سیمپلکس. برای دانشجویانی که نظریه‌ی پشت Nelder–Mead را می‌خواهند توصیه می‌شود [شماره‌ی فصل بررسی شود].
- Verguts **(۲۰۲۲)**: فصل بهینه‌سازی و گرادیان نزولی، مفید برای نگاه گرادیانی که در هفته‌ی ۱۵ (مدل‌های یادگیری) برمی‌گردد [شماره‌ی فصل بررسی شود].

پیش‌نمایش هفته‌ی ۴: به‌جای پرسیدن «کدام پارامترها مربع خطا را کمینه می‌کنند؟» می‌پرسیم «کدام پارامترها داده‌ی مشاهده‌شده را محتمل‌ترین می‌کنند؟» این بیشینه درست‌نمایی است. داده‌های دوجمله‌ای را درست مدیریت می‌کند و پایه‌ی AIC/BIC (هفته‌ی ۷) و استنباط بیزی (هفته‌های ۹–۱۳) است.

۲.۲ هفته‌ی ۴: برآورد بیشینه درست‌نمایی (Maximum Likelihood)

فصل ۲: روش‌های برآورد پارامتر · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** آزمایش فراموشی هفته‌های ۲–۳ (شمارش‌های یادآوری دوجمله‌ای)، به‌علاوه‌ی یک آزمایش SDT جدید با سه شرط پاداش .(payoff)

۱.۲.۲ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها

English	فارسی	توضیح کوتاه
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
binomial distribution	توزیع دوجمله‌ای	توزیع تعداد موفقیت در n کوشش
signal detection theory (SDT)	نظریه‌ی تشخیص علامت	مدلی که حساسیت را از سوگیری پاسخ جدا می‌کند
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
least squares	کمترین مربعات	روش برازش با کمینه کردن مجموع مربع خطاها
maximum likelihood estimate (MLE)	برآورد بیشینه‌ی درست‌نمایی	پارامترهایی که داده را محتمل‌ترین می‌کنند
noise	نویز	تغییرات تصادفی در شواهد یا در داده
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
deviance (G^2)	انحراف (deviance)	معیار عدم برازش نسبت به مدل اشباع‌شده
constraints / bounds	کران‌ها / قیدها	محدودیت‌های مجاز برای مقدار پارامترها
response bias	سوگیری پاسخ	تمایل به یک پاسخ، مستقل از محرک
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
optimizer	بهینه‌ساز	الگوریتمی که کمینه‌ی تابع را پیدا می‌کند
RMSD / SSE	مجموع مربعات خطا / ریشه‌ی میانگین مربع انحراف	معیارهای فاصله‌ی داده و پیش‌بینی
saturated model	مدل اشباع‌شده	مدلی که داده را دقیقاً بازتولید می‌کند
likelihood-ratio test (LRT)	آزمون نسبت درست‌نمایی	مقایسه‌ی دو مدل تودرتو
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
conservative / liberal	آسان‌گیر / محافظه‌کار	تمایل به گفتن «بله» / «نه»
token	token (واحد متن)	کلمه یا بخشی از کلمه که مدل زبانی پیش‌بینی می‌کند
perplexity	perplexity (سردرگمی)	e به توان NLL هر token

۲.۲.۲ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. احتمال (داده متغیر، پارامترها ثابت) را از درست‌نمایی (داده ثابت، پارامترها متغیر) **متمایز کنند**.
۲. درست‌نمایی و لگاریتم درست‌نمایی را برای مدل‌های داده‌ی دوجمله‌ای (برنولی) و گاوسی **استخراج کنند** و **نشان دهند** که کمترین مربعات همان بیشینه درست‌نمایی تحت نویز گاوسی با واریانس برابر است.
۳. برآورد بیشینه درست‌نمایی (MLE) را با کمینه کردن منفی لگاریتم درست‌نمایی (NLL) در Python، برای منحنی‌های فراموشی و یک مدل SDT چندشرطی، **پیاده‌سازی کنند**.
۴. برازش مطلق را با انحراف (deviance) G^2 **ارزیابی کنند** و MLE را با برآوردهای کمترین مربعات **مقایسه کنند**.
۵. مدل‌های مقیدشده (مثلاً «پاداش سوگیری را تغییر می‌دهد، نه حساسیت را») را به‌عنوان فرضیه‌های روان‌شناختی واقعی **تفسیر کنند**.

۳.۲.۲ مقدمه

در هفته‌ی ۳، کمترین مربعات با همه‌ی نقاط داده به یک اندازه قابل اعتماد رفتار کرد. ولی نسبت یادآوری ۵۰.۰ که روی ۵۰ آیتم اندازه‌گیری شده پرنویزتر از نسبت ۹۵.۰ است: واریانس دوجمله‌ای $f(1-f)/n$ به f بستگی دارد. کمترین مربعات همچنین درباره‌ی داده‌هایی که اعداد پیوسته نیستند، مثل یک پاسخ بله/نه، یک انتخاب بین چند گزینه یا یک درجه‌ی اطمینان، حرفی برای گفتن ندارد.

بیشینه درست‌نمایی «پیش‌بینی‌ها را به داده نزدیک کن» را با سؤالی دقیق‌تر جایگزین می‌کند:

> **کدام مقادیر پارامتر داده‌ای را که واقعاً مشاهده کردیم محتمل‌ترین می‌کنند؟**

برای جواب دادن، مدل باید بگوید هر مجموعه‌داده‌ی ممکن چقدر محتمل است، و این دقیقاً همان مدل نویز است (جزء ۴ در کالبدشکافی هفته‌ی ۲). وقتی آن را داشته باشیم، MLE با شمارش‌ها، انتخاب‌ها، زمان‌های واکنش و ترکیب‌هایشان به یک شکل کار می‌کند. همچنین بدون هزینه‌ی اضافه یک معیار مطلق عدم برازش (deviance)، پایه‌ی خطاهای استاندارد (هفته‌ی ۵)، معیارهای اطلاعاتی (هفته‌ی ۷) و جمله‌ی درست‌نمایی در قاعده‌ی بیز (هفته‌های ۹–۱۳) را به ما می‌دهد. **درست‌نمایی مهم‌ترین مفهوم این درس است.**

این موضوع کجا به کار می‌رود؟

- **تقریباً هر مدل شناختی منتشرشده** با بیشینه‌ی درست‌نمایی یا نسخه‌ی بیزی آن (هفته‌های ۹ تا ۱۳) برازش می‌شود. وقتی مقاله‌ای «برازش مدل»، «AIC» یا «log-likelihood» گزارش می‌کند، MLE پشت آن است.
- **داده‌ی انتخاب:** اینکه آدم کدام گزینه را انتخاب می‌کند (در آزمون حافظه، یک قمار، یک تکلیف یادگیری) یک عدد پیوسته نیست، پس کمترین مربعات کار نمی‌کند. درست‌نمایی به‌طور طبیعی با انتخاب‌ها کار می‌کند.
- **روان‌فیزیک** (psychophysics): تابع روان‌سنجی (احتمال تشخیص یک محرک بر حسب شدت آن) در هر آزمایشگاه بینایی و شنوایی با MLE دوجمله‌ای برازش می‌شود.
- **آزمودن فرضیه‌ها داخل یک مدل:** «آیا پاداش حساسیت را عوض می‌کند یا فقط سوگیری را؟» به مقایسه‌ی دو درست‌نمایی تبدیل می‌شود (بخش ۶).
- **هوش مصنوعی:** مدل‌های بزرگ زبانی با بیشینه کردن درست‌نمایی متن آموزش می‌بینند (بخش هوش مصنوعی و LLMها را ببینید).

۴.۲.۲ جزوه‌ی درس

به زبان ساده تصور کنید مقدارهای مختلف پارامتر را یکی‌یکی امتحان می‌کنید. برای هر مقدار از مدل بپرسید: «اگر این مقدار واقعی بود، داده‌ای که واقعاً جمع کرده‌ام چقدر محتمل بود؟» این عدد **درست‌نمایی** (likelihood) آن مقدار پارامتر است. **برآورد بیشینه‌ی درست‌نمایی** (MLE) مقداری از پارامتر است که تحت آن، داده‌ی مشاهده‌شده محتمل‌ترین بود. مثال: کسی ۷ کلمه از ۱۰ کلمه را به یاد می‌آورد. اگر احتمال واقعی یادآوری او ۵.۰ بود، به دست آمدن دقیقاً ۷ نسبتاً بعید بود (۱۱۷.۰)؛ اگر ۷.۰ بود، محتمل‌تر بود (۲۶۷.۰). پس ۷.۰ توضیح بهتری است و در واقع MLE برابر ۷/۱۰ است. در عمل با **لگاریتم** درست‌نمایی کار می‌کنیم (تا ضرب‌ها به جمع تبدیل شوند) و از کامپیوتر می‌خواهیم منفی آن (NLL) را با بهینه‌سازهای هفته‌ی ۳ کمینه کند. دو جایزه هم می‌گیریم: معلوم می‌شود کمترین مربعات حالت خاصی از MLE است، و درست‌نمایی یک آزمون مطلق برای عدم برازش (G^2) می‌دهد.

زمان‌بندی پیشنهادی (۶۰ دقیقه): احتمال در برابر درست‌نمایی ۱۰ · MLE دوجمله‌ای ۱۵ · لگاریتم درست‌نمایی و NLL ۱۰ · حالت گاوسی (LS) = (MLE ۱۰ · برازش مطلق G^2 ۱۰ · مدل‌های مقیدشده ۵.

۱. احتمال در برابر درست‌نمایی

تابع یکسان $p(\mathbf{y} \mid \boldsymbol{\theta})$ را می‌شود به دو شکل خواند:

	خوانش	ثابت	متغیر	نام	جمع/انتگرالش ۱ است؟
پیش از آزمایش	$\boldsymbol{\theta}$	$\mathbf{y}$		احتمال (جرم/چگالی) داده	بله، روی $\mathbf{y}$
پس از آزمایش	$\mathbf{y}$ (مشاهده‌شده)	$\boldsymbol{\theta}$		**درست‌نمایی** $L(\boldsymbol{\theta}) = p(\mathbf{y} \mid \boldsymbol{\theta}, \mathcal{M})$	**نه**، روی $\boldsymbol{\theta}$ نه

درست‌نمایی احتمال درست بودن پارامترها **نیست**. احتمال داده تحت هر مقدار ممکن پارامتر است. (تبدیل آن به یک توزیع احتمال روی $\boldsymbol{\theta}$ به یک پیشین نیاز دارد: بیز، هفته‌ی ۹.)

مثال. یک شرکت‌کننده $y = 7$ از $n = 10$ آیتم را به یاد می‌آورد. تحت یک مدل دوجمله‌ای با احتمال یادآوری θ:

$$L(\theta) = \binom{10}{7} \theta^7 (1-\theta)^3.$$

$L(0.5) = 0.117$، $L(0.7) = 0.267$: داده‌های مشاهده‌شده اگر $\theta = 0.7$ باشد حدود ۳.۲ برابر محتمل‌ترند تا اگر $\theta = 0.5$ باشد.

خواندن ریاضی $L(\theta) = \binom{10}{7}\theta^7(1-\theta)^3$:

- θ^7: احتمال اینکه ۷ آیتم مشخص به یاد آورده شوند (هرکدام با احتمال θ).
- $(1-\theta)^3$: احتمال اینکه ۳ آیتم دیگر فراموش شوند.
- $\binom{10}{7} = 120$ («ترکیب ۷ از ۱۰»): تعداد راه‌های مختلف برای انتخاب اینکه کدام ۷ آیتم از ۱۰ آیتم به یاد آمده‌اند. به θ بستگی ندارد، پس هیچ‌وقت محل بیشینه را عوض نمی‌کند.
- با $\theta = 0.7$: $120 \times 0.7^7 \times 0.3^3 = 120 \times 0.0824 \times 0.027 = 0.267$.

تغییر نگاه اصلی: در احتمال، θ ثابت است و درباره‌ی داده‌های مختلف می‌پرسیم؛ در درست‌نمایی، داده ثابت است (آن را داریم) و θهای مختلف را مقایسه می‌کنیم.

۲. برآورد بیشینه درست‌نمایی

$$\hat{\boldsymbol{\theta}}_{\text{ML}} = \arg\max_{\boldsymbol{\theta}} L(\boldsymbol{\theta}) = \arg\max_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}), \qquad \ell(\boldsymbol{\theta}) = \ln L(\boldsymbol{\theta}).$$

چرا لگاریتم؟ ۱. با مشاهدات مستقل، درست‌نمایی یک **حاصل‌ضرب** است، $L = \prod_i p(y_i \mid \boldsymbol{\theta})$، که در کامپیوتر حتی برای چند صد trial به ۰ سرریز (underflow) می‌کند. لگاریتم آن را به یک **مجموع** تبدیل می‌کند، $\ell = \sum_i \ln p(y_i \mid \boldsymbol{\theta})$. ۲. لگاریتم اکیداً صعودی است، پس بیشینه‌کننده‌ی یکسانی دارد. ۳. مشتق گرفتن از مجموع راحت‌تر است.

بهینه‌سازها کمینه می‌کنند، پس در کد **منفی لگاریتم درست‌نمایی**، $\text{NLL}(\boldsymbol{\theta}) = -\ell(\boldsymbol{\theta})$، را کمینه می‌کنیم.

مثال تحلیلی (دوجمله‌ای). $\ell(\theta) = \text{const} + y\ln\theta + (n-y)\ln(1-\theta)$ با صفر قرار دادن مشتق:

$$\frac{d\ell}{d\theta} = \frac{y}{\theta} - \frac{n-y}{1-\theta} = 0 \quad \Rightarrow \quad \hat{\theta} = \frac{y}{n}.$$

MLE یک احتمال همان نسبت مشاهده‌شده است، که خیال‌مان را راحت می‌کند. در مدل‌های شناختی، احتمال پیش‌بینی‌شده تابعی از پارامترهاست، $\theta_i = f(x_i; \boldsymbol{\theta})$، و معمولاً به یک بهینه‌ساز عددی نیاز داریم.

۳. درست‌نمایی دوجمله‌ای برای منحنی‌های فراموشی

با y_i آیتم یادآوری‌شده از n_i در فاصله‌ی t_i و فاصله‌های مستقل:

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^{N} \Big[\ln \binom{n_i}{y_i} + y_i \ln f(t_i;\boldsymbol{\theta}) + (n_i - y_i)\ln\big(1 - f(t_i;\boldsymbol{\theta})\big) \Big].$$

- ضریب دوجمله‌ای به $\boldsymbol{\theta}$ بستگی ندارد، پس روی MLE اثری ندارد (ولی اگر می‌خواهید لگاریتم درست‌نمایی را بین کدگذاری‌های مختلف داده مقایسه کنید نگهش دارید؛ `scipy.stats.binom.logpmf` آن را شامل می‌شود).
- مشاهداتی که پیش‌بینی می‌شود نزدیک ۰ یا ۱ باشند واریانس کمی دارند، پس پیش‌بینی‌ای که آن‌ها را از دست بدهد بیشتر جریمه می‌شود. MLE همان وزن‌دهی واریانسی کمترین مربعات وزنی هفته‌ی ۳ را خودکار انجام می‌دهد.
- **ایمنی عددی:** اگر مدل جایی که $y > 0$ است $f = 0$ پیش‌بینی کند، $\ln 0 = -\infty$ می‌شود. پیش‌بینی‌ها را به $[\epsilon, 1-\epsilon]$ محدود (clip) کنید، مثلاً با $\epsilon = 10^{-10}$.

برنولی در برابر دوجمله‌ای. اگر پاسخ‌های تکی ۰/۱ را نگه داریم، $\ell = \sum_{\text{trials}} [y\ln f + (1-y)\ln(1-f)]$ این فقط با ضرایب دوجمله‌ای ثابت با نسخه‌ی دوجمله‌ای فرق دارد، پس همان MLE را می‌دهد.

خواندن ریاضی لگاریتم درست‌نمایی فراموشی همان لگاریتم درست‌نمایی یک نسبت (بخش ۲) است که برای هر فاصله‌ی زمانی یک بار نوشته و جمع شده است:

- برای فاصله‌ی i: جمله‌ی $y_i \ln f(t_i)$ به پیش‌بینی احتمال یادآوری بالا در جایی که آیتم‌های زیادی به یاد آمده‌اند پاداش می‌دهد؛ $(n_i - y_i)\ln(1 - f(t_i))$ به پیش‌بینی احتمال پایین در جایی که آیتم‌های زیادی فراموش شده‌اند پاداش می‌دهد.
- جمع زدن روی فاصله‌ها مجاز است چون فرض می‌کنیم فاصله‌ها **مستقل**‌اند: لگاریتم حاصل‌ضرب احتمال‌ها برابر جمع لگاریتم‌هاست.

- چرا وزن‌دهی خودکار است: اگر مدل $f = 0.95$ پیش‌بینی کند ولی فقط ۴۰ از ۵۰ به یاد آمده باشد، جمله‌ی $10\ln(0.05) \approx -30$ خیلی پرهزینه است. نزدیک $f = 0.5$ همان مقدار خطا هزینه‌ی خیلی کمتری دارد. به نقطه‌هایی که باید دقیق باشند بیشتر اعتماد می‌شود.

۴. حالت گاوسی: کمترین مربعات همان بیشینه درست‌نمایی است

فرض کنید $y_i = f(x_i;\boldsymbol{\theta}) + \varepsilon_i$ با $\varepsilon_i \sim \mathcal{N}(0,\sigma)$، مستقل و با σ **یکسان**. آن‌وقت

$$\ell(\boldsymbol{\theta},\sigma) = \sum_{i=1}^{N} \ln\left[\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{(y_i - f(x_i;\boldsymbol{\theta}))^2}{2\sigma^2}\right)\right] = -\frac{N}{2}\ln(2\pi\sigma^2) - \frac{\mathrm{SSE}(\boldsymbol{\theta})}{2\sigma^2}.$$

برای هر σ ثابت، بیشینه کردن ℓ روی $\boldsymbol{\theta}$ یعنی کمینه کردن SSE. پس **کمترین مربعات = MLE تحت نویز گاوسی مستقل و با واریانس برابر**. بیشینه کردن روی σ هم $\hat\sigma^2 = \mathrm{SSE}/N$ را می‌دهد.

این توضیح می‌دهد کمترین مربعات کی مناسب است (نویز پیوسته، تقریباً متقارن، با واریانس ثابت) و کی نیست (شمارش‌ها، نسبت‌ها، انتخاب‌ها، زمان‌های واکنش چوله).

> **پیشرفته: ویژگی‌های MLE.** تحت شرایط منظم بودن (مدل identifiable، پارامترهای واقعی نه روی مرز، N بزرگ)، MLE سازگار (consistent: به مقدار واقعی همگرا می‌شود)، به‌طور مجانبی نرمال و به‌طور مجانبی کارا است (هیچ برآوردگر سازگاری در حد واریانس کمتری ندارد). واریانس نمونه‌گیری آن با معکوس **اطلاع فیشر** (Fisher information)، یعنی انحنای $-\ell$ در کمینه‌اش، تقریب زده می‌شود. هفته‌ی ۵ دقیقاً از همین برای محاسبه‌ی خطاهای استاندارد استفاده می‌کند. در نمونه‌های کوچک MLE ممکن است سوگیری داشته باشد (مثلاً $\hat\sigma^2 = \mathrm{SSE}/N$ واریانس σ^2 را کمتر برآورد می‌کند).

۵. برازش مطلق: انحراف G^2

مقدار لگاریتم درست‌نمایی به‌تنهایی معنای مطلقی ندارد. برای قضاوت درباره‌اش، مدل را با **مدل اشباع‌شده** (saturated) مقایسه کنید که برای هر خانه‌ی داده یک احتمال آزاد دارد و بنابراین هر نسبت مشاهده‌شده را دقیقاً بازتولید می‌کند ($\hat f_i = y_i/n_i$). **انحراف** (deviance) برابر است با

$$G^2 = 2\big[\ell_{\text{saturated}} - \ell(\hat{\boldsymbol{\theta}})\big] = 2\sum_{i}\left[y_i\ln\frac{y_i}{n_i\hat f_i} + (n_i - y_i)\ln\frac{n_i - y_i}{n_i(1-\hat f_i)}\right],$$

با $0\ln 0 = 0$. اگر مدل درست باشد و شمارش‌ها خیلی کوچک نباشند، G^2 تقریباً توزیع χ^2 با k = (تعداد خانه‌ها) $-$ df دارد. G^2 بزرگ (p کوچک) یعنی عدم برازش مدل بیش از آن است که نویز نمونه‌گیری بتواند توضیح دهد.

هشدارها: با N خیلی بزرگ، هر عدم برازش کوچکی «معنادار» می‌شود؛ با N کوچک، عدم برازش واقعی ممکن است دیده نشود. یک G^2 غیرمعنادار **ثابت نمی‌کند** که مدل درست است (هفته‌ی ۶).

خواندن ریاضی

- **مدل اشباع‌شده** (saturated) مدل «تقلب‌کننده»‌ای است که هر نسبت مشاهده‌شده را دقیقاً پیش‌بینی می‌کند. لگاریتم درست‌نمایی آن بهترین مقداری است که هر مدلی ممکن است روی این داده به دست آورد.
- $G^2 = 2(\ell_{\text{saturated}} - \ell(\hat{\boldsymbol{\theta}}))$ اندازه می‌گیرد مدل ما چقدر از این سقف فاصله دارد. $G^2 = 0$ یعنی برازش کامل.
- **درجه‌ی آزادی** (df) = تعداد خانه‌های داده − تعداد پارامترهای برازش‌شده. با ۸ فاصله و ۲ پارامتر، df = ۶.

- اگر مدل درست باشد، G^2 مثل یک متغیر χ^2 با همان df رفتار می‌کند که میانگینش df است. پس $G^2 \approx 6$ با $\text{df} = ۶$ مقدار عادی عدم برازش است (فقط نویز)؛ $G^2 = 26$ با $\text{df} = ۶$ ($p = .0002$) یعنی مدل به‌طور نظام‌مند داده را از دست می‌دهد.

۶. مدل‌های مقیدشده به‌عنوان فرضیه

MLE برازش **چند شرط هم‌زمان با بعضی پارامترهای مشترک** را آسان می‌کند. مثال: یک آزمایش SDT با سه شرط پاداش (پاداش برای پاسخ «بله»، خنثی، پاداش برای «نه»).

مدل	پارامترهای آزاد	k	فرضیه
حساسیت مشترک	d'؛ c_1, c_2, c_3	۴	پاداش فقط سوگیری را تغییر می‌دهد
جداگانه	d'_1, d'_2, d'_3؛ c_1, c_2, c_3	۶	پاداش ممکن است حساسیت را هم تغییر دهد (این مدل اشباع‌شده برای ۶ نرخ است)

لگاریتم درست‌نمایی مشترک، مجموع لگاریتم درست‌نمایی‌های دوجمله‌ای hitها و false alarmها در همه‌ی شرایط است. مقایسه‌ی لگاریتم درست‌نمایی بیشینه‌ی دو مدل یک سؤال واقعی را آزمون می‌کند. برای مدل‌های nested مثل این‌ها، $2(\ell_6 - \ell_4)$ تقریباً χ^2 با ۲ درجه‌ی آزادی است: **آزمون نسبت درست‌نمایی** که در هفته‌ی ۷ کامل می‌شود.

> **پیشرفته: MLE در SDT و فرمول‌ها.** برای یک شرط تنها، MLE (d', c) از شمارش‌ها دقیقاً همان چیزی است که فرمول‌های هفته‌ی ۲ بدون تصحیح می‌دهند، چون مدل اشباع‌شده است (۲ پارامتر، ۲ نرخ) و MLE نرخ‌های مشاهده‌شده را بازتولید می‌کند. تصحیح log-linear، MLE نیست؛ بیشتر به یک برآورد بیزی با پیشین ضعیف شبیه است (هفته‌ی ۹).

برای یک مهندس

- این دقیقاً همان **تخمین بیشینه‌ی درست‌نمایی** در نظریه‌ی تخمین است (تخمین ML کانال یا فرکانس، آشکارسازی دنباله با ML). تنها تفاوت مدل نویز است: شمارش دوجمله‌ای به جای AWGN.
- **تحت** AWGN ML = LS (بخش ۴) نتیجه‌ای است که قبلاً از آن استفاده کرده‌اید: با نویز سفید گاوسی با واریانس معلوم و برابر، تخمین‌گر ML خطای مربعی را کمینه می‌کند.
- **اطلاعات فیشر** (Fisher information) و واریانس مجانبی MLE (کادر پیشرفته) همان کمیت‌های **کران پایین** Cramér–Rao هستند. هفته‌ی ۵ از آن‌ها برای محاسبه‌ی خطای استاندارد استفاده می‌کند.
- مقایسه‌ی یک مدل مقید و یک مدل آزاد با $2(\ell_{\text{free}} - \ell_{\text{constrained}})$ همان **آزمون نسبت درست‌نمایی تعمیم‌یافته** (GLRT) است: هر دو فرضیه پارامترهای مجهول دارند که با تخمین ML جایگزین می‌شوند.
- **پاداش‌ها و جابه‌جایی ملاک:** در آشکارسازی بیزی، آستانه‌ی بهینه با هزینه‌ها و احتمال‌های پیشین جابه‌جا می‌شود. بخش ۶ می‌آزماید که آیا آدم‌ها وقتی پاداش‌ها عوض می‌شوند فقط آستانه‌شان (c) را جابه‌جا می‌کنند و «SNR»شان (d') ثابت می‌ماند.

برای مدرس

- **جمله‌ای که باید تکرار کنید:** «درست‌نمایی احتمال داده‌ای است که مشاهده کرده‌ایم، به‌عنوان تابعی از پارامترها». آن را روی تخته بنویسید و تا آخر جلسه نگه دارید.
- **رسمش کنید.** $L(\theta)$ را برای ۷ از ۱۰ (مثال حل‌شده، بخش ۱) به شکل منحنی روی θ از ۰ تا ۱ بکشید. بپرسید: قله کجاست؟ آیا مساحت زیر منحنی ۱ است؟ (نه.) بعد آن را برای ۷۰ از ۱۰۰ بکشید: همان قله، منحنی خیلی باریک‌تر. این باریکی همان دقت (precision) است، موضوع هفته‌ی ۵.
- **از پیش‌زمینه‌ی خودتان استفاده کنید.** خیلی از دانشجوها MLE را انتزاعی می‌دانند؛ شما می‌توانید آن را به‌عنوان «روش تخمینی که مهندس‌ها وقتی نویز گاوسی نیست به کار می‌برند» معرفی کنید.
- **سؤال‌های رایج.**
  - «آیا درست‌نمایی احتمال درست بودن θ است؟» نه. برای آن به prior نیاز داریم (هفته‌ی ۹).
  - «چرا NLL را کمینه می‌کنیم به جای اینکه L را بیشینه کنیم؟» جواب یکی است، ولی جمع لگاریتم‌ها از underflow عددی جلوگیری می‌کند و بهینه‌سازها برای کمینه کردن نوشته شده‌اند.
  - «آیا G^2 غیرمعنادار ثابت می‌کند مدل درست است؟» نه؛ فقط یعنی عدم برازش بیشتر از نویز نیست، و با داده‌ی کم ممکن است عدم برازش واقعی پنهان بماند.
- **مدیریت زمان.** بخش ۴ (حالت گاوسی) را می‌شود سریع به‌عنوان LS» حالت خاصی است» نشان داد. وقت صرفه‌جویی‌شده را روی بخش ۵ (G^2) بگذارید.

۵.۲.۲ مثال حل‌شده

بخش ۱: درست‌نمایی یک نسبت تنها

$y = 7$ یادآوری از $n = 10$:

θ	۵.۰	۶.۰	**۷.۰**	۸.۰
$L(\theta) = \binom{10}{7}\theta^7(1-\theta)^3$	۱۱۷.۰	۲۱۵.۰	**۲۶۷.۰**	۲۰۱.۰
$\ell(\theta)$	۱۴۴.۲−	۵۳۷.۱−	**۳۲۱.۱−**	۶۰۳.۱−

بیشینه در $\hat{\theta} = 7/10 = 0.7$ است. دقت کنید که مقادیر درست‌نمایی روی θ جمعشان ۱ نمی‌شود: درست‌نمایی توزیع احتمال روی پارامترها نیست.

بخش ۲: یک آزمایش فراموشی دوفاصله‌ای

$y = (30, 13)$ آیتم یادآوری‌شده از $n = 50$ در $t = (1, 7)$ روز. مدل: $f(t) = Ae^{-\lambda t}$.

قدم ۱: NLL برای یک نامزد. برای $(A, \lambda) = (0.70, 0.15)$: $f(1) = 0.7e^{-0.15} = 0.6025$، $f(7) = 0.7e^{-1.05} = 0.2450$.

$$\ell = \ln \mathrm{Binom}(30; 50, 0.6025) + \ln \mathrm{Binom}(13; 50, 0.2450) = -2.167 + (-2.088) = -4.255,$$

پس $\text{NLL} = 4.255$.

قدم ۲: مقایسه. برای $(0.70, 0.12)$: $f = (0.621, 0.302)$ و $\text{NLL} = 4.488$ که بدتر است. نامزد اول داده‌ها را محتمل‌تر می‌کند.

قدم ۳: MLE. با ۲ پارامتر و ۲ داده، مدل می‌تواند هر دو نسبت مشاهده‌شده را دقیقاً بازتولید کند: $Ae^{-\lambda} = 0.60$ و $Ae^{-7\lambda} = 0.26$. تقسیم این دو می‌دهد $e^{6\lambda} = 0.60/0.26$، پس $\hat{\lambda} = \ln(2.308)/6 = 0.139$ و $\hat{A} = 0.60\,e^{0.139} = 0.690$، با $\text{NLL} = 4.225$ (کمینه). یک بهینه‌ساز عددی همین مقادیر را می‌دهد.

تفسیر. MLE می‌گوید این شرکت‌کننده در شروع حدود ۶۹٪ را به یاد می‌آورد و هر روز حدود ۱۳٪ از باقی‌مانده را از دست می‌دهد ($1 - e^{-0.139}$). چون اینجا $k = N$ است، $G^2 = 0$: مدل نمی‌تواند بد برازش شود، پس این برازش کامل هیچ شاهدی برای شکل نمایی نیست. فقط داده‌هایی با تعداد خانه‌ی بیشتر از تعداد پارامترها می‌توانند یک مدل را آزمون کنند.

۶.۲.۲ lab (۲ ساعت)

اهداف

۱. رسم یک تابع درست‌نمایی و دیدن اینکه چرا با لگاریتم درست‌نمایی کار می‌کنیم.
۲. برازش مدل‌های فراموشی نمایی و توانی با MLE؛ مقایسه با کمترین مربعات؛ ارزیابی با G^2.
۳. وارسی عددی اینکه MLE گاوسی با کمترین مربعات برابر است.
۴. برازش یک مدل SDT چندشرطی مقیدشده و **تفسیر** آنچه درباره‌ی پاداش‌ها می‌گوید.

زمان‌بندی: بخش A ۱۵ دقیقه · بخش B ۳۵ دقیقه · بخش C ۱۵ دقیقه · بخش D ۳۵ دقیقه · بخش E ۲۰ دقیقه (تمرین‌ها).

آماده‌سازی

Code · **کد:** `code/week04.py`، cell ۱ · سلول ۱

بخش A: تابع درست‌نمایی (۱۵ دقیقه)

Code · **کد:** `code/week04.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
Area under L(theta): 0.091 (not 1: L is not a distribution over theta)
Product of 2000 trial probabilities: 0.0
Sum of their logs: -1239.52
```

بخش B: MLE برای منحنی‌های فراموشی (۳۵ دقیقه)

Code · کد: `code/week04.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
model method      A   rate     NLL    SSE
  exp    MLE 0.6377 0.0458 29.8123 0.1100
  exp     LS 0.6568 0.0566 30.6983 0.1061
  pow    MLE 0.8773 0.4214 19.8303 0.0262
  pow     LS 0.8712 0.4251 19.8585 0.0259
True (power): A = 0.9, d = 0.5
```

به این‌ها دقت کنید: - هر روش در معیار خودش برنده است: MLE کمترین NLL و LS کمترین SSE را دارد. - برای مدل توانی (مدل واقعی) دو روش خیلی به هم نزدیک‌اند. - برای مدل نمایی دو روش بیشتر با هم فرق دارند (نرخ زوال ۰۴۶.۰ در برابر ۰۵۷.۰). درست‌نمایی دوجمله‌ای به نقاطی که نزدیک کف دقیق اندازه‌گیری شده‌اند (فاصله‌های طولانی) وزن بیشتری می‌دهد، پس منحنی ML کندتر زوال پیدا می‌کند تا به آن‌ها نزدیک‌تر بماند.

> **هشدار: یک دام واقعی بهینه‌ساز.** در برازش ML بالا `"L-BFGS-B"` را با `"Nelder-Mead"` عوض کنید (با نگه داشتن `bounds=bounds`) و دوباره اجرا کنید. برای مدل نمایی، Nelder–Mead کران‌دار scipy روی کران `A=1` فرو می‌ریزد و با NLL = ۵.۷۹ «`success`» گزارش می‌کند؛ خیلی بدتر از کمینه‌ی واقعی ۸.۲۹ (حتی بدتر از NLL برآورد .(LS روش‌های سیمپلکس کران‌دار وقتی رأس‌ها روی یک کران فشرده شوند ممکن است تباهیده (degenerate) شوند. دو بررسی سریع این را لو می‌دهند: برآوردی که دقیقاً روی یک کران نشسته، و یک «MLE» که NLL آن از مقادیر پارامتر دیگری که امتحان کرده‌اید بیشتر است. multi-start (هفته‌ی ۳) درمان کلی آن است.

حالا برازش مطلق را با انحراف ارزیابی کنید:

Code · کد: `code/week04.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
exp: G2 =  26.27, df = 6, p = 0.0002
pow: G2 =   6.31, df = 6, p = 0.3895
```

تفسیر: عدم برازش مدل نمایی خیلی بیشتر از آن است که نویز دوجمله‌ای اجازه می‌دهد ($p = .0002$): می‌توانیم آن را به‌عنوان توصیف این داده‌ها **رد کنیم**. عدم برازش مدل توانی با نویز نمونه‌گیری سازگار است. این ثابت نمی‌کند که مدل درستی است؛ یعنی این داده‌ها دلیلی برای رد آن نمی‌دهند.

Code · **کد:** `code/week04.py`، cell ۵ · سلول ۵

بخش C: MLE گاوسی همان کمترین مربعات است (۱۵ دقیقه)

نسبت‌ها را پیوسته در نظر بگیرید و نویز گاوسی با σ آزاد (پارامتر سوم) فرض کنید. برآوردهای A و d باید با کمترین مربعات یکی باشند و $\hat{\sigma}$ باید برابر $\sqrt{\mathrm{SSE}/N}$ باشد.

Code · **کد:** `code/week04.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
Gaussian MLE: A = 0.8712, d = 0.4251, sigma = 0.0569
Least squares: A = 0.8711, d = 0.4251, sqrt(SSE/N) = 0.0569
```

بخش D: یک مدل SDT چندشرطی مقیدشده (۳۵ دقیقه)

آزمایش. شرکت‌کننده‌ها یک صدای ضعیف را تحت سه طرح پاداش تشخیص می‌دهند: liberal (پاداش برای hit)، **خنثی** و **محافظه‌کار** (جریمه برای false alarm). در هر شرط ۸۰ trial علامت و ۸۰ trial نویز. یک شرکت‌کننده را شبیه‌سازی می‌کنیم که حساسیتش در همه‌ی شرایط یکسان است و ملاکش با پاداش جابه‌جا می‌شود.

Code · **کد:** `code/week04.py`، cell ۷ · سلول ۷

خروجی مورد انتظار:

```
      condition  hits  n_signal  fas  n_noise
0       liberal    73        80   33       80
1       neutral    58        80   16       80
2  conservative    44        80    7       80

Shared d':   d' = 1.496, c = [-0.555  0.124  0.618], NLL = 13.134
Separate d': d' = [1.577 1.439 1.482], c = [-0.568  0.122  0.615], NLL =
↪  13.043

Likelihood-ratio statistic = 0.18, df = 2, p = 0.913
```

دقت کنید که `d'` برآوردشده (حدود ۵.۱) از مقدار تولیدکننده‌ی ۲.۱ بیشتر است. با ۸۰ trial در هر خانه این یک خطای نمونه‌گیری عادی است. هفته‌ی ۵ نشان می‌دهد چطور دور آن بازه‌ی اطمینان بسازیم.

تفسیر (در notebook بنویسید): ۱. آیا مقید کردن d' به برابری در همه‌ی شرایط پاداش درست‌نمایی زیادی را هزینه می‌کند؟ درباره‌ی اثر پاداش‌ها چه نتیجه‌ای می‌گیرید؟ ۲. برآوردهای d' جداگانه چند دهم با هم فرق دارند. چرا این شاهدی بر اینکه پاداش حساسیت را تغییر می‌دهد نیست؟ ۳. بررسی کنید که مدل d' جداگانه نرخ‌های hit و false alarm مشاهده‌شده را دقیقاً بازتولید می‌کند. چرا باید این‌طور باشد؟

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. MLE θ را برای یک دنباله‌ی برنولی با y موفقیت در n trial با دست استخراج کنید و آن را برای $y = 13$، $n = 40$ با `minimize_scalar` عددی بررسی کنید.

تمرین ۲ ⋆. در بخش B، هر دو مدل را با درست‌نمایی **برنولی** روی داده‌ی سطح آیتم دوباره برازش کنید (هر شمارش را به پاسخ‌های ۰/۱ باز کنید). نشان دهید برآوردها با برازش‌های دوجمله‌ای یکسان‌اند و NLLها به اندازه‌ی یک ثابت فرق دارند. آن ثابت چیست؟

تمرین ۳ ⋆⋆ **(شمارش صفر).** دو شمارش آخر را ۰ کنید (`recalled[-2:]=0`). کدام روش‌های برازش هفته‌های ۲–۴ هنوز کار می‌کنند؟ هر دو مدل را با MLE برازش کنید و درباره‌ی آنچه بر سر برآوردها و G^2 می‌آید توضیح دهید.

تمرین ۴ ⋆⋆ **(یک مدل SDT سوم).** مدلی را برازش کنید که در آن ملاک در همه‌ی شرایط یکسان است ولی d' فرق دارد ($k = 4$). NLL آن را با مدل d' مشترک مقایسه کنید. هر دو $k = 4$ دارند؛ چرا اینجا می‌توانید مستقیماً با NLL مقایسه کنید؟ کدام برای یک دست‌کاری پاداش از نظر روان‌شناختی معقول‌تر است؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: LS در برابر MLE با شبیه‌سازی).** ۵۰۰ مجموعه‌داده از مدل توانی ($A = 0.9$، $d = 0.5$، همان ۸ فاصله، $n = 50$) شبیه‌سازی کنید، هرکدام را با LS و با MLE برازش کنید و دو برآوردگر d را مقایسه کنید: میانگین (سوگیری)، انحراف معیار، و ریشه‌ی میانگین مربع خطا. کدام اینجا بهتر است؟ با $n = 10$ تکرار کنید. (آمادگی خوبی برای A2 است.)

lab check-off

نشان دهید: (۱) جدول LS در برابر MLE و نتایج G^2 از بخش B، (۲) مقایسه‌ی گاوسی در برابر LS از بخش C، و (۳) پاسخ‌هایتان به سؤال‌های تفسیری بخش D.

۷.۲.۲ ارتباط با هوش مصنوعی و LLMها

LLMها با بیشینه‌ی درست‌نمایی آموزش می‌بینند. «cross-entropy loss» که برای آموزش همه‌ی مدل‌های زبانی استفاده می‌شود، همان منفی لگاریتم درست‌نمایی token بعدی است که روی یک corpus متنی عظیم میانگین گرفته شده. پس آموزش یک LLM یک مسئله‌ی MLE با میلیاردها پارامتر است که به جای Nelder–Mead با gradient descent حل می‌شود. دو کمیتی که در مقاله‌های هوش مصنوعی می‌بینید همان کمیت‌های این هفته در لباس دیگرند: loss = NLL برای هر token، و perplexity = $e^{\text{NLL per token}}$، یعنی تعداد مؤثر گزینه‌های هم‌احتمالی که مدل بینشان «سردرگم» است.

ساده‌ترین مدل زبانی، یعنی **مدل** bigram، یک MLE بسته دارد: $P(w_2 \mid w_1) = \text{count}(w_1 w_2)/\text{count}(w_1)$. این مدل یک مشکل آشنا را نشان می‌دهد. هر جفت کلمه‌ای که در آموزش دیده نشده احتمال ۰ می‌گیرد، پس فقط یک جفت تازه درست‌نمایی کل جمله را ۰ می‌کند (NLL = ∞). هموارسازی (smoothing) این را حل می‌کند، همان‌طور که تصحیح log-linear هفته‌ی ۲ مشکل نرخ hit ۱ را حل کرد.

> **کد:** Code · `code/week04.py`، cell ۸ · سلول ۸

خروجی مورد انتظار:

```
P(cat | the) = 0.333
'the dog sat on the mat .'   MLE      NLL =  3.584  perplexity =   1.82
'the dog sat on the mat .'   add-one  NLL =  9.537  perplexity =   4.90
'the dog saw the cat .'      MLE      NLL =    inf  perplexity =    inf
'the dog saw the cat .'      add-one  NLL =  9.624  perplexity =   6.85
```

امتحانش کنید (بدون نیاز به API). ⋆ - کدام جفت کلمه در «the dog saw the cat .» هرگز در corpus دیده نشده؟ با دست بررسی کنید که MLE برای $P(\text{cat} \mid \text{the})$ برابر ۱/۳ است. ⋆⋆ - هموارسازی جمله‌ی آموزشی را کم‌احتمال‌تر می‌کند (NLL از ۶.۳ به ۵.۹) ولی جمله‌ی تازه را ممکن می‌کند. add-one را با $k$add- عوض کنید و k را با cross-validation leave-one-sentence-out انتخاب کنید (پیش‌نمایشی از هفته‌ی ۶). ⋆⋆ بحث: MLE یک مدل bigram corpus آموزشی را تا جای ممکن بازتولید می‌کند. چرا «بیشینه کردن درست‌نمایی روی متن اینترنت» با «یاد گرفتن راست‌گویی» یکی نیست؟

۸.۲.۲ اشتباهات رایج و برداشت‌های نادرست

۱. **«درست‌نمایی احتمال درست بودن پارامترهاست.»** احتمال (چگالی) داده به شرط پارامترهاست. انتگرالش روی $\boldsymbol{\theta}$ برابر ۱ نیست.

۲. **ضرب کردن احتمال‌ها به‌جای جمع کردن لگاریتم‌ها.** حاصل‌ضرب برای تعداد trial واقعی به ۰ سرریز می‌کند (بخش A).

۳. **بیشینه کردن وقتی بهینه‌ساز کمینه می‌کند.** `minimize` به **منفی** لگاریتم درست‌نمایی نیاز دارد. فراموش کردن علامت منفی بهینه‌ساز را به بدترین پارامترها می‌فرستد.

۴. **محدود نکردن احتمال‌ها.** احتمال‌های پیش‌بینی‌شده‌ی دقیقاً ۰ یا ۱ لگاریتم درست‌نمایی $-\infty$ می‌دهند و بهینه‌ساز را از کار می‌اندازند.

۵. **مقایسه‌ی NLL بین مجموعه‌داده‌ها یا کدگذاری‌های مختلف.** NLL به تعداد مشاهدات و ثابت‌ها (مثلاً ضرایب دوجمله‌ای) بستگی دارد. فقط مدل‌هایی را مقایسه کنید که روی همان داده با همان کدگذاری برازش شده‌اند.

۶. **استفاده‌ی پیش‌فرض از کمترین مربعات برای انتخاب‌ها یا شمارش‌ها.** ساختار نویز داده را نادیده می‌گیرد. از درست‌نمایی‌ای استفاده کنید که با نحوه‌ی تولید داده جور باشد.

۷. **خواندن G^2 غیرمعنادار به‌عنوان اثبات درستی مدل.** فقط می‌گوید عدم برازش با این حجم نمونه به‌طور قابل تشخیصی از نویز نمونه‌گیری بیشتر نیست.

۸. **فراموش کردن اینکه مدل اشباع‌شده یا دقیقاً تعیین‌شده همیشه کامل برازش می‌شود** (مثال حل‌شده، مدل d' جداگانه در بخش D). در این حالت برازش کامل بی‌اطلاع است.

۹.۲.۲ خودآزمایی

۱. هرکدام در یک جمله: در یک توزیع احتمال در برابر یک تابع درست‌نمایی چه چیزی متغیر و چه چیزی ثابت است؟ **پاسخ** احتمال: پارامترها ثابت، داده متغیر، و جمع/انتگرالش روی داده ۱ است. درست‌نمایی: داده روی مقادیر مشاهده‌شده ثابت، پارامترها متغیر، و لازم نیست انتگرالش روی پارامترها ۱ باشد.

۲. دو دلیل برای کار با لگاریتم درست‌نمایی بیاورید. **پاسخ** (۱) عددی: حاصل‌ضرب احتمال‌های زیاد سرریز می‌کند ولی مجموع لگاریتم‌ها نه. (۲) لگاریتم monotone است، پس بیشینه‌کننده عوض نمی‌شود، و مشتق‌گیری و بهینه‌سازی مجموع‌ها راحت‌تر است.

۳. تحت چه فرض‌هایی کمترین مربعات با بیشینه درست‌نمایی معادل است؟ گام کلیدی را نشان دهید. **پاسخ** خطاهای گاوسی مستقل با واریانس برابر σ^2. آن‌وقت $\ell = -\frac{N}{2}\ln(2\pi\sigma^2) - \mathrm{SSE}/(2\sigma^2)$، پس برای هر σ، بیشینه کردن ℓ روی $\boldsymbol{\theta}$ همان کمینه کردن SSE است.

۴. یک مدل ۲ پارامتری روی ۸ خانه‌ی دوجمله‌ای برازش شده و $G^2 = 4.1$ می‌دهد. درجه‌ی آزادی چند است و چه نتیجه‌ای می‌گیرید؟ **پاسخ** $\mathrm{df} = 8 - 2 = 6$. میانگین χ^2_6 برابر ۶ است، پس ۱.۴ کاملاً در دامنه‌ی مورد انتظار از نویز نمونه‌گیری است ($p \approx 0.66$). شاهدی بر عدم برازش نیست، ولی این درستی مدل را ثابت نمی‌کند.

۵. چرا MLE با درست‌نمایی دوجمله‌ای نقاط داده را متفاوت از کمترین مربعات ساده وزن می‌دهد؟ **پاسخ** لگاریتم درست‌نمایی دوجمله‌ای واریانس $f(1-f)/n$ را منعکس می‌کند: نقاطی که پیش‌بینی می‌شود نزدیک ۰ یا ۱ باشند (واریانس کم) دقیق‌تر برازش می‌شوند، و نقاط با n بزرگ‌تر بیشتر حساب می‌شوند. کمترین مربعات ساده همه‌ی مربع خطاها را یکسان وزن می‌دهد.

۶. در آزمایش پاداش، مدل d' مشترک چه فرضیه‌ی روان‌شناختی را بیان می‌کند و چطور آزمونش می‌کنید؟ **پاسخ** اینکه پاداش‌ها فقط سوگیری پاسخ (ملاک) را تغییر می‌دهند، نه حساسیت ادراکی را. با مقایسه‌ی لگاریتم درست‌نمایی بیشینه با مدل d' جداگانه آزمونش کنید: $2(\ell_6 - \ell_4) \sim \chi^2_2$ تقریبی (آزمون نسبت درست‌نمایی)، یا با AIC/BIC (هفته‌ی ۷).

۷. مدلی را برازش می‌کنید و بهینه‌ساز NLL = −۲.۳۵ (منفی) برمی‌گرداند. آیا اشکالی هست؟ **پاسخ** نه لزوماً. برای داده‌ی پیوسته، چگالی‌ها می‌توانند از ۱ بیشتر باشند (مثلاً یک گاوسی باریک)، پس لگاریتم چگالی می‌تواند مثبت و NLL منفی باشد. برای داده‌ی گسسته (دوجمله‌ای) احتمال‌ها ≤ 1 هستند، پس NLL باید ≥ 0 باشد و مقدار منفی نشانه‌ی باگ است.

۱۰.۲.۲ تکلیف

A2: کمترین مربعات در برابر بیشینه درست‌نمایی (۰.۱ نمره از ۲۰؛ انتشار هفته‌ی ۴، موعد ابتدای درس هفته‌ی ۶)

داده. مجموعه‌داده را دقیقاً با این کد بسازید (همه داده‌ی یکسانی می‌گیرند):

کد: Code · سلول ۹ · cell ۹، `code/week04.py`

کارها.

۱. **برازش (۲ امتیاز).** مدل‌های نمایی و توانی را روی این داده‌ها با (الف) کمترین مربعات روی نسبت‌ها و (ب) MLE دوجمله‌ای برازش کنید. همه‌ی برآوردها را با SSE و NLL در یک جدول گزارش کنید.
۲. **ارزیابی (۲ امتیاز).** G^2، درجه‌ی آزادی و p را برای برازش MLE هر مدل حساب کنید. داده‌ها را با بازه‌های ٪۹۵ دوجمله‌ای، هر دو منحنی برازش‌شده، و باقی‌مانده‌ها رسم کنید. کدام مدل (اگر هست) قابل رد است؟
۳. **مطالعه‌ی شبیه‌سازی (۳ امتیاز).** مدل توانی با $A = 0.95$، $d = 0.7$ را مدل واقعی در نظر بگیرید. ۵۰۰ مجموعه‌داده با همین طرح شبیه‌سازی کنید، هرکدام را با LS و MLE برازش کنید و سوگیری، انحراف معیار و RMSE برآورد $\hat{d}$ را برای هر روش گزارش کنید. هیستوگرام‌ها را نشان دهید. با $n = 100$ آیتم تکرار کنید و بگویید چه تغییر می‌کند.
۴. **تفسیر (۲ امتیاز، حداکثر ۳۰۰ کلمه).** برای داده‌های یادآوری کدام برآوردگر را توصیه می‌کنید و چرا؟ جوابتان را به ساختار نویز داده‌های دوجمله‌ای و به شمارش‌های نزدیک به کف (۱ تا ۲ از ۲۰) در طولانی‌ترین فاصله‌ها ربط دهید. اگر یکی از آن شمارش‌ها ۰ بود، چه بر سر روش خطی‌سازی هفته‌ی ۲ می‌آمد؟
۵. **کیفیت کد (۱ امتیاز).** notebook قابل بازتولید و با توضیح؛ seedها ثابت؛ توابع دوباره استفاده شوند نه کپی.

برای تحویل با تأخیر، روزی ٪۱۰ کسر می‌شود (حداکثر ۳ روز).

۱۱.۲.۲ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۴.** برآورد پارامتر با بیشینه درست‌نمایی: توابع درست‌نمایی برای انواع رایج داده، لگاریتم درست‌نمایی و برازش در عمل. (منبع اصلی.)
- **عظیمی‌فر و احمدی (۱۳۹۶)**، شناسایی آماری الگو، جلد ۱: بخش برآورد پارامتر با بیشینه درست‌نمایی، با نگاه یادگیری آماری [شماره‌ی فصل بررسی شود].
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۳.** استنباط با توزیع دوجمله‌ای. الان برای چیدمان دوجمله‌ای بخوانید؛ در هفته‌ی ۹ از سمت بیزی دوباره به آن برمی‌گردیم.

پیش‌نمایش هفته‌ی ۵: برآورد بدون عدم قطعیت نصف یک نتیجه است. خطاهای استاندارد و بازه‌های اطمینان را از انحنای درست‌نمایی و با bootstrap حساب می‌کنیم، و کشف می‌کنیم که چطور میانگین‌گیری از شرکت‌کننده‌ها می‌تواند «قانونی» بسازد که هیچ فردی از آن پیروی نمی‌کند.

۳.۲ هفته‌ی ۵: عدم قطعیت برآوردها و برازش برای چند شرکت‌کننده

فصل ۲: روش‌های برآورد پارامتر · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌های فراموشی هفته‌های ۲–۴ (برآوردهای ما چقدر قطعی‌اند؟) و یک آزمایش **تمرین** (practice) شبیه‌سازی‌شده‌ی جدید با ۲۰ شرکت‌کننده (قانون توانی تمرین).

۱.۳.۲ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
power law of practice	قانون توانی تمرین	کاهش توانی زمان واکنش با تمرین
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
sampling distribution	توزیع نمونه‌گیری	توزیع برآورد در تکرارهای فرضی آزمایش
standard error (SE)	خطای استاندارد	پراکندگی برآورد در تکرارهای فرضی آزمایش
confidence interval (CI)	بازه‌ی اطمینان	بازه‌ای که با روش مشخص پارامتر واقعی را در بر می‌گیرد
Hessian	ماتریس Hessian	ماتریس مشتق‌های دوم؛ انحنای درست‌نمایی
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
Wald interval	بازه‌ی Wald	برآورد $\pm$ ۹۶.۱ SE
profile likelihood	درست‌نمایی نیم‌رخ (profile)	درست‌نمایی یک پارامتر با بهینه کردن بقیه
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
bootstrap	bootstrap (بازنمونه‌گیری)	تخمین عدم قطعیت با شبیه‌سازی یا بازنمونه‌گیری
parameter trade-off	بده‌بستان پارامترها	تغییر یک پارامتر که با پارامتر دیگر جبران می‌شود
aggregation artifact	خطای ناشی از میانگین‌گیری	الگویی در میانگین که در هیچ فردی نیست
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
constraints / bounds	کران‌ها / قیدها	محدودیت‌های مجاز برای مقدار پارامترها
accuracy	دقت	نسبت پاسخ‌های درست
partial pooling / no / complete	ادغام کامل / بدون ادغام / ادغام جزئی (pooling)	یک پارامتر برای همه / جدا برای هر فرد / سلسله‌مراتبی
individual differences	تفاوت‌های فردی	فرق پارامترها بین افراد
noise	نویز	تغییرات تصادفی در شواهد یا در داده

English	فارسی	توضیح کوتاه
benchmark	benchmark (مجموعه‌آزمون استاندارد)	مجموعه سؤال برای مقایسه‌ی مدل‌های هوش مصنوعی

۲.۳.۲ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. توزیع نمونه‌گیری (sampling distribution) یک برآوردگر را **توضیح دهند** و خطای استاندارد (SE) را از انحراف معیار داده‌ها **متمایز کنند**.
۲. خطاهای استاندارد و بازه‌های اطمینان پارامترهای مدل را به سه روش **حساب کنند**: از Hessian تابع NLL (روش Wald)، از profile likelihood و با bootstrap پارامتری؛ و این سه روش را **مقایسه کنند**.
۳. trade-off پارامترها را از همبستگی برآوردشده بین پارامترها **تشخیص دهند**.
۴. با شبیه‌سازی **نشان دهند** که میانگین‌گیری از منحنی‌های فردی می‌تواند شکل تابعی‌ای (یک «قانون توانی») بسازد که هیچ فردی از آن پیروی نمی‌کند.
۵. بین برازش تجمیعی، فردی و (پیش‌نمایش) سلسله‌مراتبی **انتخاب کنند** و انتخابشان را **توجیه کنند**.

۳.۳.۲ مقدمه

«$\hat{d} = 0.42$» نصف یک نتیجه است. هفته‌ی قبل MLE مدل توانی برای داده‌های هفته‌ی ۲ برابر $\hat{d} = 0.42$ بود (مقدار واقعی ۰.۵). آیا ۴۲.۰ با ۰.۵ سازگار است؟ با ۳.۰؟ با ۶.۰؟ بدون یک معیار عدم قطعیت نمی‌توانیم بگوییم دو شرکت‌کننده، دو گروه یا دو شرط واقعاً با هم فرق دارند یا نه. از این به بعد هر برآورد پارامتری که گزارش می‌کنیم با یک بازه‌ی اطمینان همراه است.

قانونی که هیچ‌کس از آن پیروی نمی‌کند. قانون توانی تمرین (power law of practice) یکی از پرارجاع‌ترین یافته‌ها در روان‌شناسی شناختی است: زمان واکنش با تمرین تقریباً به شکل تابع توانی از تعداد trialها کم می‌شود. بعضی پژوهشگران استدلال کرده‌اند که شکل توانی می‌تواند از **میانگین‌گیری** روی افرادی (یا آیتم‌هایی) بیاید که هرکدام به‌طور نمایی ولی با نرخ‌های متفاوت بهتر می‌شوند (مطالعه‌ی بیشتر را ببینید). اگر این‌طور باشد، «قانون» میانگین را توصیف می‌کند ولی هیچ یادگیرنده‌ی تکی را نه، و نظریه‌ای که برای توضیح یک تابع توانی در ذهن هر فرد ساخته شود در واقع یک خطای ناشی از میانگین‌گیری را توضیح می‌دهد. این هفته این اثر را با داده‌ی شبیه‌سازی‌شده نشان می‌دهیم و یاد می‌گیریم کی باید افراد را برازش کرد نه میانگین گروه را.

این موضوع کجا به کار می‌رود؟

- **هر ادعای تفاوت** («بیماران سریع‌تر از گروه کنترل فراموش می‌کنند»، «آموزش حساسیت را بالا برد») به برآورد عدم قطعیت نیاز دارد. بدون آن، تفاوت ۰.۵۰ در یک پارامتر ممکن است فقط نویز باشد.
- **ارزیابی بالینی یک فرد:** برای اینکه بگوییم سرعت فراموشی یک بیمار غیرعادی است، به خطای استاندارد برآورد همان بیمار نیاز داریم، نه فقط میانگین گروه.

- **پژوهش یادگیری و مهارت:** «قانون توانی تمرین» مدت‌ها یک قانون همگانی حساب می‌شد. خطای ناشی از میانگین‌گیری این هفته نشان می‌دهد چرا امروز پژوهشگرها یادگیرنده‌ها را جداگانه برازش می‌کنند (و چرا همین احتیاط درباره‌ی منحنی‌های میانگین گروه در آموزش، علوم ورزشی و ارگونومی هم لازم است).
- **تکرار پژوهش و فراتحلیل** (meta-analysis) برآوردهای چند مطالعه را با وزن دادن به هر کدام بر اساس دقتش $(1/\mathrm{SE}^2)$ ترکیب می‌کنند.

۴.۳.۲ جزوه‌ی درس

به زبان ساده اگر همان آزمایش را دوباره روی همان آدم اجرا کنید، داده‌ی کمی متفاوت و در نتیجه برآورد پارامتر کمی متفاوتی می‌گیرید. **خطای استاندارد** (SE) می‌گوید برآورد بین چنین تکرارهایی چقدر بالا و پایین می‌پرد؛ **بازه‌ی اطمینان** محدوده‌ای است که از روی آن ساخته می‌شود (تقریباً برآورد $\pm$ ۲ .SE). نمی‌توانیم آزمایش را بارها تکرار کنیم، پس این پرش را به سه روش تخمین می‌زنیم: (۱) از اینکه قله‌ی درست‌نمایی چقدر تیز است (قله‌ی تیز یعنی داده پارامتر را دقیق تعیین می‌کند؛ این روش Wald با استفاده از Hessian است)، (۲) با دنبال کردن اینکه وقتی یک پارامتر را جابه‌جا می‌کنیم برازش با چه سرعتی بدتر می‌شود (profile likelihood)، و (۳) با شبیه‌سازی تعداد زیادی آزمایش ساختگی از مدل برازش‌شده و برازش دوباره‌ی هرکدام (bootstrap). نیمه‌ی دوم هفته درباره‌ی یک دام هشدار می‌دهد: میانگین گرفتن داده‌ها روی افراد می‌تواند شکلی از منحنی بسازد که **هیچ فردی** آن را ندارد. اگر هر یادگیرنده به‌طور نمایی ولی با سرعتی متفاوت بهتر شود، میانگین گروه شبیه قانون توانی می‌شود.

زمان‌بندی پیشنهادی (۶۰ دقیقه): توزیع‌های نمونه‌گیری ۱۰ · خطای استاندارد از Hessian ۱۵ · profile likelihood ۸ · bootstrap ۱۰ · چند شرکت‌کننده و میانگین‌گیری ۱۷.

۱. برآوردها توزیع نمونه‌گیری دارند

اگر همان آزمایش را روی همان شرکت‌کننده (با همان $\boldsymbol{\theta}^*$ واقعی) تکرار می‌کردیم، داده‌ی متفاوت و در نتیجه $\hat{\boldsymbol{\theta}}$ متفاوتی می‌گرفتیم. توزیع $\hat{\boldsymbol{\theta}}$ روی تکرارهای فرضی، **توزیع نمونه‌گیری** آن است.

- **خطای استاندارد** (SE) یک پارامتر، انحراف معیار توزیع نمونه‌گیری‌اش است: اینکه برآورد بین تکرارها چقدر تغییر می‌کند.
- یک **بازه‌ی اطمینان ٪۹۵** با رویه‌ای ساخته می‌شود که در تکرارها، در ٪۹۵ موارد θ^* را در بر می‌گیرد. (این نه به معنای «احتمال ٪۹۵ که θ^* در همین بازه‌ی مشخص باشد» است؛ آن یک credible interval بیزی است، هفته‌ی ۹.)

نمی‌توانیم آزمایش را بارها تکرار کنیم، پس توزیع نمونه‌گیری را به سه روش تقریب می‌زنیم.

۲. خطای استاندارد از انحنای درست‌نمایی (Wald)

شهود. اگر NLL یک کمینه‌ی تیز و باریک داشته باشد، تغییرات کوچک در $\boldsymbol{\theta}$ داده‌ها را خیلی کم‌احتمال‌تر می‌کنند، پس داده‌ها $\boldsymbol{\theta}$ را دقیق تعیین می‌کنند. یک کمینه‌ی پهن و تخت یعنی مقادیر زیادی تقریباً به یک اندازه خوب برازش می‌شوند، پس عدم قطعیت زیاد است. انحنا با مشتق‌های دوم اندازه‌گیری می‌شود.

صورت‌بندی. Hessian تابع NLL در نقطه‌ی MLE ماتریس مشتق‌های دوم است،

$$\mathbf{H}_{mn} = \left.\frac{\partial^2 \,\mathrm{NLL}(\boldsymbol{\theta})}{\partial\theta_m\,\partial\theta_n}\right|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}},$$

که به آن **اطلاع فیشر مشاهده‌شده** (observed Fisher information) هم می‌گویند. برای نمونه‌های بزرگ:

$$\widehat{\mathrm{Cov}}(\hat{\boldsymbol{\theta}}) \approx \mathbf{H}^{-1}, \qquad \mathrm{SE}(\hat{\theta}_m) = \sqrt{[\mathbf{H}^{-1}]_{mm}}, \qquad 95\%\ \text{Wald CI: } \hat{\theta}_m \pm 1.96\,\mathrm{SE}(\hat{\theta}_m).$$

عناصر غیرقطری $\mathbf{H}^{-1}$، وقتی به همبستگی تبدیل شوند، trade-off **پارامترها** را نشان می‌دهند: همبستگی -۹.۰ بین دو برآورد یعنی خطاهایشان تا حد زیادی همدیگر را جبران می‌کنند (همان دره‌ی مورب هفته‌ی ۳).

بررسی درستی (دوجمله‌ای). برای یک نسبت، $\mathrm{NLL}''(\theta) = y/\theta^2 + (n-y)/(1-\theta)^2$. در $\hat{\theta} = y/n$ این برابر $n/[\hat{\theta}(1-\hat{\theta})]$ است، پس $\mathrm{SE} = \sqrt{\hat{\theta}(1-\hat{\theta})/n}$؛ همان فرمول آشنای کتاب‌های درسی.

در عمل: $\mathbf{H}$ را عددی با تفاضل‌های متناهی حساب کنید (بخش A lab). `hess_inv` که BFGS برمی‌گرداند فقط یک تقریب خام است، پس برای SE از آن استفاده نکنید.

وقتی Wald جواب نمی‌دهد: نمونه‌های کوچک، برآوردهای نزدیک یک کران (مثلاً سطح یادآوری $\hat{A}$ نزدیک ۱)، درست‌نمایی‌هایی که شدیداً غیرمربعی‌اند، یا پارامترهایی با توزیع نمونه‌گیری چوله (نرخ‌ها، واریانس‌ها). در این حالت‌ها بازه‌ی متقارن $\mathrm{SE} \pm 1.96$ ممکن است تا مقادیر ناممکن کشیده شود.

> **پیشرفته: چرا این کار می‌کند.** نزدیک کمینه، هر NLL همواری تقریباً مربعی است (بسط تیلور مرتبه‌ی دوم). یک NLL مربعی دقیقاً NLL یک توزیع نرمال چندمتغیره است که معکوس کوواریانسش همان Hessian است. همراه با نرمال بودن مجانبی MLE (هفته‌ی ۴)، این نتیجه را می‌دهد. همین تقریب مربعی، به نام تقریب *Laplace*، در مقایسه‌ی بیزی مدل‌ها (هفته‌ی ۱۰) دوباره ظاهر می‌شود.

خواندن ریاضی

- $\mathbf{H}_{mn} = \partial^2 \mathrm{NLL}/\partial\theta_m \partial\theta_n$ در نقطه‌ی $\hat{\boldsymbol{\theta}}$: ماتریس مشتق‌های دوم، یعنی **انحنای** کاسه‌ی NLL در کف آن. درایه‌های قطری: کاسه در امتداد هر پارامتر چقدر شیب‌دار است. درایه‌های غیرقطری: آیا کاسه کج است (پارامترها trade-off دارند).
- $\widehat{\mathrm{Cov}}(\hat{\boldsymbol{\theta}}) \approx \mathbf{H}^{-1}$: کاسه‌ی خیلی خمیده ($\mathbf{H}$ بزرگ) کوواریانس کوچک می‌دهد، یعنی برآورد دقیق. معکوس گرفتن همان چیزی است که «شیب‌داری» را به «عدم قطعیت» تبدیل می‌کند.
- $\mathrm{SE}(\hat{\theta}_m) = \sqrt{[\mathbf{H}^{-1}]_{mm}}$: درایه‌ی قطری mام ماتریس معکوس را بردارید و از آن جذر بگیرید.
- **بررسی با یک پارامتر:** برای یک نسبت، $\mathrm{NLL}'' = n/[\hat{\theta}(1-\hat{\theta})]$، پس $\mathrm{SE} = \sqrt{\hat{\theta}(1-\hat{\theta})/n}$. با ۳۰ از ۵۰: $\sqrt{0.6 \times 0.4/50} = 0.069$ و بازه‌ی ۹۵٪ برابر $0.60 \pm 1.96 \times 0.069 = [0.46, 0.74]$ است.
- **همبستگی از کوواریانس:** $\mathrm{corr} = \mathrm{Cov}_{12}/(\mathrm{SE}_1 \mathrm{SE}_2)$. مقداری مثل -۹.۰ یعنی دو برآورد به‌شدت trade-off دارند.

۳. بازه‌های profile likelihood

برای پارامتر مورد نظر ψ (مثلاً d)، NLL profile با ثابت گرفتن ψ روی یک شبکه و کمینه کردن NLL روی همه‌ی پارامترهای دیگر در هر نقطه‌ی شبکه به دست می‌آید:

$$\mathrm{NLL}_{\mathrm{prof}}(\psi) = \min_{\text{other params}} \mathrm{NLL}(\psi, \text{others}).$$

بازه‌ی نسبت درست‌نمایی (profile) ۹۵٪، مجموعه‌ی مقادیری از ψ است که خیلی بدتر از بهترین نیستند:

$$\left\{\psi : 2\left[\mathrm{NLL}_{\mathrm{prof}}(\psi) - \mathrm{NLL}_{\min}\right] \le 3.84\right\}, \qquad 3.84 = \chi^2_{1,\,0.95}.$$

بازه‌های profile شکل واقعی درست‌نمایی را دنبال می‌کنند، پس می‌توانند **نامتقارن** باشند و کران‌های طبیعی را رعایت کنند. در نمونه‌های کوچک معمولاً از بازه‌های Wald دقیق‌ترند.

خواندن ریاضی

- $\mathrm{NLL}_{\mathrm{prof}}(\psi)$: پارامتر مورد نظر ψ را روی یک مقدار ثابت کنید، بگذارید بهینه‌ساز بهترین مقدار همه‌ی پارامترهای دیگر را انتخاب کند، و NLL حاصل را ثبت کنید. برای مقدارهای زیادی از ψ تکرار کنید. نتیجه یک منحنی یک‌بعدی است.
- بازه هر ψای را نگه می‌دارد که NLL نیم‌رخ آن حداکثر $3.84/2 = 1.92$ واحد بالاتر از کمینه باشد. عدد ۸۴.۳ نقطه‌ی ٪۹۵ توزیع χ^2 با ۱ درجه‌ی آزادی است و از آزمون نسبت درست‌نمایی می‌آید (هفته‌ی ۷).
- برخلاف Wald، این منحنی مجبور نیست سهمی متقارن باشد، پس بازه می‌تواند نامتقارن باشد و هیچ‌وقت تا مقدارهای ناممکن کشیده نمی‌شود.

۴. bootstrap پارامتری

جوابی شبیه‌سازی‌محور به «اگر آزمایش را تکرار می‌کردیم چه؟»:

۱. مدل را روی داده برازش کنید: $\hat{\boldsymbol{\theta}}$.
۲. B مجموعه‌داده‌ی جدید از مدل با $\hat{\boldsymbol{\theta}}$ و با همان طرح آزمایش واقعی شبیه‌سازی کنید.
۳. هر مجموعه‌داده را دوباره برازش کنید: $\hat{\boldsymbol{\theta}}^{*(1)}, \ldots, \hat{\boldsymbol{\theta}}^{*(B)}$.
۴. انحراف معیار برآوردهای bootstrap تقریب SE است. صدک‌های ۵.۲ و ۵.۹۷ یک **بازه‌ی اطمینان صدکی** (percentile CI) می‌دهند.

bootstrap به مشتق نیاز ندارد، برای هر آماره‌ای کار می‌کند (مثلاً نیمه‌عمر یا تفاوت دو شرط)، و شکل کامل و همبستگی‌های توزیع نمونه‌گیری را نشان می‌دهد. هزینه‌اش B بار برازش است ($B \approx 500$ تا 2000). bootstrap **ناپارامتری** به‌جای شبیه‌سازی از مدل، trialهای مشاهده‌شده را با جایگذاری بازنمونه‌گیری می‌کند.

مقایسه:

روش	هزینه	متقارن؟	کران را رعایت می‌کند؟	نیاز دارد به
Wald (Hessian)	یک Hessian	همیشه	نه	NLL هموار، N بزرگ
profile likelihood	یک برازش برای هر نقطه‌ی شبکه	می‌تواند نامتقارن باشد	بله	یک درست‌نمایی
bootstrap پارامتری	B برازش	می‌تواند نامتقارن باشد	بله	مدلی که بتوانید شبیه‌سازی کنید

۵. برازش برای چند شرکت‌کننده

آزمایش‌های واقعی J شرکت‌کننده دارند (اندیس j). سه راهبرد کلی وجود دارد:

راهبرد	چه چیزی برازش می‌شود	مزایا	معایب
تجمیعی (complete pooling)	یک مدل روی داده‌های میانگین‌گیری‌شده	پایدار؛ با trialهای کم برای هر نفر هم کار می‌کند	فرض می‌کند همه یکسان‌اند؛ **می‌تواند شکل تابعی را تحریف کند**
فردی (no pooling)	یک مدل برای هر شرکت‌کننده؛ بعد تحلیل J مجموعه برآورد	تفاوت‌های فردی را رعایت می‌کند؛ روش استاندارد	با trial کم برآوردها پرنویزند؛ تحلیل مرحله‌ی دوم عدم قطعیت برآورد را نادیده می‌گیرد
سلسله‌مراتبی (partial pooling)	پارامترهای فردی از یک توزیع گروهی، که با هم برآورد می‌شوند	بهترینِ هر دو؛ shrinkage اصولی	پیچیده‌تر؛ معمولاً بیزی (هفته‌ی ۱۳)

خطاهای ناشی از میانگین‌گیری. میانگین منحنی‌های غیرخطی معمولاً منحنی‌ای از همان خانواده **نیست**. مثلاً میانگین منحنی‌های نمایی با نرخ‌های متفاوت نمایی نمی‌شود: یادگیرنده‌های سریع زود به پایان می‌رسند، پس نرخ نسبی تغییر میانگین با گذشت زمان کند می‌شود؛ و این دقیقاً ویژگی تعریف‌کننده‌ی تابع توانی است (هفته‌ی ۲، نرخ نسبی فراموشی).

پیشرفته: یک نتیجه‌ی دقیق. فرض کنید هر شرکت‌کننده از $e^{-\lambda_j t}$ پیروی کند و نرخ‌ها بین افراد توزیع Gamma داشته باشند، $\lambda_j \sim \mathrm{Gamma}(\text{shape } s, \text{rate } b)$. آن‌وقت منحنی میانگین گروه برابر است با

$$\mathbb{E}\left[e^{-\lambda t}\right] = \left(1 + \frac{t}{b}\right)^{-s},$$

که دقیقاً یک تابع توانی جابه‌جاشده است (این تابع مولد گشتاور توزیع Gamma در نقطه‌ی $-t$ است). همه به‌طور نمایی فراموش می‌کنند، ولی میانگین با یک قانون توانی با نمای برابر با پارامتر شکل Gamma یعنی s فراموش می‌کند. این را در تمرین ۴ عددی بررسی می‌کنید.

راهنمای عملی. هر وقت هر شرکت‌کننده داده‌ی کافی برای مقید کردن مدل دارد، افراد را برازش کنید؛ داده‌ی تجمیعی را فقط به‌عنوان خلاصه به کار ببرید، هرگز به‌عنوان شاهدی درباره‌ی شکل یک فرایند در سطح فرد. وقتی داده‌های فردی کم است، از مدل‌های سلسله‌مراتبی استفاده کنید (هفته‌ی ۱۳).

برای یک مهندس

- SE **روش** Wald **از** Hessian = معکوس اطلاعات فیشر، یعنی همان CRLB که در نقطه‌ی برآورد محاسبه شده. MLE به‌طور مجانبی به این کران می‌رسد، پس برای N بزرگ بازه‌ی Wald همان بازه‌ی مبتنی بر CRLB است.
- bootstrap **پارامتری** همان ارزیابی کارایی با Monte Carlo است که برای یک تخمین‌گر یا گیرنده انجام می‌دهید (مثلاً شبیه‌سازی تعداد زیادی تحقق نویز برای به دست آوردن واریانس تخمین‌گر یا منحنی BER، فقط در مقدارهای برازش‌شده‌ی پارامتر.
- profile likelihood همان کاری است که با پارامترهای مزاحم *(nuisance parameters)* می‌کنید: آن‌ها را بهینه کنید و کنار بگذارید و به درست‌نمایی پارامتری که برایتان مهم است نگاه کنید.
- **خطای ناشی از میانگین‌گیری** = تفاوت **میانگین آنسامبل** و **یک تحقق تنها**. میانگین گرفتن از افت‌های نمایی با ثابت‌های زمانی مختلف یک افت کندتر با دنباله‌ی سنگین می‌دهد؛ همان‌طور که میانگین تعداد زیادی تحقق کانال شبیه هیچ تحقق تکی نیست. فرایند «بین افراد ارگودیک» نیست: میانگین گروه، فرد را توصیف نمی‌کند.
- partial pooling (پیش‌نمایش هفته‌ی ۱۳) شبیه تخمین SNR هر کاربر با ترکیب چند اندازه‌گیری خودش و توزیع SNR در کل سلول است: یک برآورد empirical Bayes.

برای مدرس

- **با سؤال «آیا ۴۲.۰ با ۵.۰ فرق دارد؟» شروع کنید** (بخش مقدمه). دانشجوها جواب بله/نه می‌خواهند؛ نشان دهید جواب کاملاً به SE بستگی دارد.
- **سه روش را کنار هم نشان دهید** روی همان داده (جدول بخش C lab). پیام این نیست که «کدام درست است»، بلکه «وقتی درست‌نمایی خوش‌رفتار است با هم توافق دارند و نزدیک کران‌ها یا با داده‌ی کم فرق می‌کنند».
- **نمایش میانگین‌گیری نقطه‌ی اوج جلسه است.** ۵ منحنی نمایی فردی و میانگین آن‌ها را روی نمودار لگاریتمی–لگاریتمی رسم کنید: میانگین تقریباً یک خط راست است (قانون توانی) در حالی که هر منحنی فردی خمیده است. از کلاس بپرسید پژوهشگری که فقط میانگین را دیده چه نتیجه‌ای می‌گیرد.
- **سؤال‌های رایج.**
  - «فرق *SD* و *SE* چیست؟» SD پراکندگی داده‌ها را توصیف می‌کند؛ SE پراکندگی یک برآورد در تکرارهای آزمایش را. SE با داده‌ی بیشتر کم می‌شود؛ SD نه.
  - «آیا یک بازه‌ی اطمینان ۹۵٪ با احتمال ۹۵.۰ مقدار واقعی را دارد؟» این بازه‌ی مشخص نه؛ ۹۵٪ بازه‌هایی که به این روش ساخته می‌شوند آن را دارند. credible interval) بیزی هفته‌ی ۹ همین تفسیر مستقیم را دارد.)
  - «آیا همیشه باید افراد را جداگانه برازش کنم؟» بله، اگر هر نفر داده‌ی کافی دارد؛ وگرنه از مدل‌های سلسله‌مراتبی استفاده کنید (هفته‌ی ۱۳).

۵.۳.۲ مثال حل‌شده

بخش ۱: سه بازه برای یک احتمال یادآوری

یک شرکت‌کننده $y = 30$ از $n = 50$ آیتم را به یاد می‌آورد؛ $\hat{\theta} = 0.60$.

Wald. $\text{SE} = \sqrt{0.6 \times 0.4/50} = 0.0693$، پس بازه‌ی اطمینان ۹۵٪ برابر $0.60 \pm 1.96 \times 0.0693 = [0.464, 0.736]$ است.

profile (نسبت درست‌نمایی). معادله‌ی $2[\ell(0.6) - \ell(\theta)] = 3.84$ را در دو طرف ۶.۰ عددی حل کنید. بازه‌ی ۹۵٪ برابر $[0.462, 0.728]$ است که کمی **نامتقارن** است: ۱۳۸.۰ پایین‌تر از برآورد و ۱۲۸.۰ بالاتر از آن می‌رود، چون درست‌نمایی به سمت ۵.۰، جایی که واریانس دوجمله‌ای بیشینه است، چوله است.

تفسیر. با ۵۰ آیتم، یک احتمال یادآوری فقط تا حدود $\pm$۱۳.۰ معلوم است. تفاوت ۱۰.۰ بین دو شرط با این اندازه به‌تنهایی قانع‌کننده نیست.

بخش ۲: میانگین‌گیری از دو یادگیرنده‌ی نمایی

شرکت‌کننده‌ی ۱ با $\lambda = 0.1$ و شرکت‌کننده‌ی ۲ با $\lambda = 1.0$ فراموش می‌کند. منحنی میانگین $\bar{f}(t) = (e^{-0.1t} + e^{-t})/2$:

t	۰	۱	۲	۵	۱۰
$\bar{f}(t)$	۱۰۰۰	۶۳۶.۰	۴۷۷.۰	۳۰۷.۰	۱۸۴.۰
نرخ نسبی فراموشی $-\bar{f}'(t)/\bar{f}(t)$	۵۵.۰	۳۶.۰	۲۳.۰	۱۱.۰	۱۰.۰

هر شرکت‌کننده یک نرخ نسبی ثابت دارد (۱.۰ و ۰.۱)، ولی نرخ میانگین از ۵۵.۰ به ۱۰.۰ **کاهش** می‌یابد؛ نشانه‌ی یک منحنی شبه‌توانی. دلیل: در زمان‌های بعدی، فراموش‌کننده‌ی کند که نرخش پایین است بر میانگین غالب است. **تفسیر:** پژوهشگری که فقط میانگین را برازش کند نتیجه می‌گیرد که «خاطره‌ها با بالا رفتن سن مقاوم‌تر می‌شوند»؛ ادعایی که درباره‌ی هیچ‌کدام از دو شرکت‌کننده درست نیست.

۶.۳.۲ lab (۲ ساعت)

اهداف

۱. محاسبه‌ی بازه‌های Wald، profile و bootstrap برای مدل توانی برازش‌شده روی داده‌های هفته‌ی ۲ و مقایسه‌ی آن‌ها.
۲. نمایش trade-off پارامترها از طریق همبستگی برآوردشده و ابر نقاط bootstrap.
۳. شبیه‌سازی ۲۰ یادگیرنده‌ی نمایی، برازش مدل‌های نمایی و توانی روی **میانگین** و روی **هر فرد**، و تفسیر تناقض.

زمان‌بندی: بخش A ۲۰ دقیقه · بخش B ۱۵ دقیقه · بخش C ۲۵ دقیقه · بخش D ۴۰ دقیقه · بخش E ۲۰ دقیقه.

آماده‌سازی

Code · **کد:** `code/week05.py`، cell ۱ · سلول ۱

بخش A: خطای استاندارد Wald از یک Hessian عددی (۲۰ دقیقه)

Code · **کد:** `code/week05.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
   estimate      SE   lower   upper
A    0.8773  0.0626  0.7546  1.0000
d    0.4214  0.0532  0.3171  0.5257
Estimated correlation between A-hat and d-hat: 0.751
```

تفسیر: هر دو بازه‌ی ۹۵٪ مقادیر واقعی ($A^* = 0.9$، $d^* = 0.5$) را در بر دارند، پس «خطایی» که در هفته‌های ۳–۴ نگرانش بودیم کاملاً در حد خطای نمونه‌گیری است. دقت کنید که بازه‌ی Wald برای A اتفاقاً درست روی ۱.۰۰۰، یعنی مرز مقادیر ممکن، تمام می‌شود. با داده‌ای کمی پرنویزتر، بازه‌ی متقارن Wald مقادیر ناممکن (احتمال بیشتر از ۱) را هم شامل می‌شد، در حالی که بازه‌ی bootstrap نمی‌تواند. همبستگی مثبت همان دره‌ی trade-off هفته‌ی ۳ است: وقتی برآورد A زیادی بالاست، برآورد d هم معمولاً زیادی بالاست.

بخش B: بازه‌ی profile likelihood برای d (۱۵ دقیقه)

Code · **کد:** `code/week05.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
Profile 95% CI for d: [0.320, 0.525]  (grid step 0.005)
```

بخش C: bootstrap پارامتری (۲۵ دقیقه)

Code · **کد:** `code/week05.py`، cell ۴ · سلول ۴

خروجی مورد انتظار (حدود ۳۰ تا ۶۰ ثانیه طول می‌کشد):

```
   boot SE    2.5%  97.5%
A   0.0563  0.7724  1.000
d   0.0501  0.3304  0.528
Bootstrap correlation: 0.703
```

مقایسه کنید: بازه‌های Wald، profile و bootstrap برای d را کنار هم بگذارید. شبیه هم‌اند؟ کدام نامتقارن است؟ با این داده‌ها (۸ خانه × ۵۰ آیتم) هر سه روش باید نسبتاً با هم توافق داشته باشند. با آیتم‌های کمتر یا برآوردهای نزدیک کران بیشتر از هم فاصله می‌گیرند (تمرین ۵).

بخش D: قانون توانی تمرین به‌عنوان خطای میانگین‌گیری (۴۰ دقیقه)

طرح. $J = 20$ شرکت‌کننده هرکدام ۶۰ بلوک تمرین در یک تکلیف جستجوی دیداری انجام می‌دهند. هر شرکت‌کننده به‌طور **نمایی** بهتر می‌شود:

$$\mathrm{RT}_j(m) = E + B\,e^{-r_j (m-1)} + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, 40\ \mathrm{ms}),$$

با مجانب $E = 400$ ms، بهبود اولیه‌ی $B = 600$ ms و نرخ‌های یادگیری فردی $r_j \sim \mathrm{Gamma}(\text{shape} = 0.7, \text{scale} = 0.5)$ (میانگین ۳۵.۰ در هر بلوک؛ توزیعی چوله با چند یادگیرنده‌ی خیلی سریع و چند یادگیرنده‌ی خیلی کند). اینجا m شماره‌ی بلوک تمرین و ε نویز میانگین زمان واکنش هر بلوک است.

Code · **کد:** `code/week05.py`، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
True learning rates: [1.000e-03 7.000e-03 7.000e-03 2.000e-02 3.000e-02
 ↪  4.500e-02 1.220e-01
 1.490e-01 1.720e-01 2.360e-01 2.820e-01 3.260e-01 3.870e-01 3.950e-01
 5.340e-01 7.100e-01 7.900e-01 1.002e+00 1.869e+00 2.534e+00]
Average curve, exp: E = 507.5, B = 423.8, r = 0.205, RMSD = 19.26 ms
Average curve, pow: E = 419.2, B = 579.4, r = 0.529, RMSD = 10.16 ms
```

Code · **کد:** `code/week05.py`، cell ۶ · سلول ۶

خروجی مورد انتظار (خط خلاصه):

```
Which model fits each participant better? {'exp': 20}
(with SciPy 1.18: {'exp': 19, 'pow': 1}; one participant with a
 ↪  near-zero learning rate is fitted differently)
```

Code · **کد:** `code/week05.py`، cell ۷ · سلول ۷

بخش E: تفسیر (۲۰ دقیقه)

Code · **کد:** `code/week05.py`، cell ۸ · سلول ۸

خروجی مورد انتظار:

```
Mean of true individual rates:      0.481
Mean of estimated individual rates: 0.449 (SD 0.626)
Exponential rate fitted to the average curve: 0.205
Correlation of true and estimated individual rates: 0.971
(with SciPy 1.18: estimated mean 0.457 (SD 0.621), correlation 0.968,
 ↪  because of the same participant)
```

برای هرکدام ۲ تا ۳ جمله بنویسید: ۱. منحنی میانگین با تابع توانی بهتر توصیف می‌شود (RMSD حدود ۱۰ در برابر ۱۹ ms، ولی همه‌ی ۲۰ فرد (یا بسته به نسخه‌ی SciPy، ۱۹ نفر) با تابع نمایی بهتر توصیف می‌شوند. کدام گزاره درباره‌ی یادگیری موجه است و کدام نیست؟ ۲. چرا نرخ نمایی برازش‌شده روی منحنی میانگین از میانگین نرخ‌های فردی کوچک‌تر است؟ (راهنمایی: در اواخر تمرین کدام شرکت‌کننده‌ها بر میانگین غالب‌اند؟) ۳. اینجا با ۶۰ بلوک برای هر نفر، برازش‌های فردی نرخ‌های واقعی را خوب بازیابی می‌کنند. با فقط ۱۰ بلوک برای هر نفر چه تغییر می‌کرد و آن‌وقت چه می‌کردید؟ (پیش‌نمایش هفته‌ی ۱۳.)

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. بازه‌های اطمینان ٪۹۵ Wald را برای MLE مدل نمایی روی داده‌های هفته‌ی ۲ حساب کنید. آیا مقادیر معقولی در بر دارند؟ بعد آن‌ها را در «برآورد» ساختگی `(A,lam)=(1.0,0.107)` از هشدار Nelder–Mead کران‌دار هفته‌ی قبل حساب کنید. در نقطه‌ای که کمینه نیست چه بر سر Hessian می‌آید؟

تمرین ۲ ⋆. bootstrap را با $B = 50, 200, 1000$ و seedهای مختلف دوباره اجرا کنید. حدود صدکی چقدر پایدارند؟ برای یک بازه‌ی ٪۹۵، B چقدر باید بزرگ باشد؟

تمرین ۳ ⋆⋆ **(یک کمیت مشتق‌شده).** با نمونه‌های bootstrap بخش C یک بازه‌ی ٪۹۵ برای **نیمه‌عمر** مدل توانی، $t_{1/2} = 2^{1/d} - 1$، حساب کنید. چرا این کار با bootstrap آسان و با Hessian دست‌وپاگیر است؟

تمرین ۴ ⋆⋆ **(نتیجه‌ی Gamma–توانی).** ۱۰۰ ۰۰۰ نرخ $\lambda \sim \mathrm{Gamma}(\text{shape } s = 0.8, \text{rate } b = 2)$ بکشید، $e^{-\lambda t}$ را روی آن‌ها برای $t \in [0, 30]$ میانگین بگیرید و منحنی تحلیلی $(1 + t/b)^{-s}$ را روی آن رسم کنید (کادر «پیشرفته» بخش ۵ جزوه). بعد توابع نمایی و توانی را روی منحنی میانگین برازش کنید.

تمرین ۵ ⋆⋆⋆ **(پیشرفته: پوشش).** بازه‌های ٪۹۵ واقعاً چند وقت یک بار مقدار واقعی را در بر می‌گیرند؟ ۳۰۰ مجموعه‌داده از مدل توانی ($A = 0.9$، $d = 0.5$) با $n = 10$ آیتم در هر فاصله شبیه‌سازی کنید و برای هرکدام بازه‌های Wald و profile d را حساب کنید. پوشش (نسبت بازه‌هایی که ۵.۰ را در بر دارند) هر روش را گزارش کنید. کدام به ٪۹۵ نزدیک‌تر است؟ با $n = 50$ تکرار کنید.

lab check-off

نشان دهید: (۱) جدولی که بازه‌های ٪۹۵ Wald، profile و bootstrap برای d را مقایسه می‌کند؛ (۲) نمودار پراکنش bootstrap با یک جمله درباره‌ی trade-off؛ (۳) مقایسه‌ی فردی در برابر میانگین و پاسخ شما به سؤال تفسیری ۱.

۷.۳.۲ ارتباط با هوش مصنوعی و LLMها

نمره‌های benchmark هم خطای استاندارد دارند. مدل‌های هوش مصنوعی روی benchmarkها مقایسه می‌شوند، و جدول‌های رتبه‌بندی (leaderboard) اغلب مدل‌هایی را رتبه‌بندی می‌کنند که یکی دو درصد با هم فرق دارند. یک benchmark یک نمونه از آیتم‌هاست، پس دقتش، درست مثل برآورد یک پارامتر، خطای نمونه‌گیری دارد. دو درس این هفته مستقیماً به کار می‌آیند: ۱. **عدم قطعیت را گزارش کنید.** bootstrap روی آیتم‌ها یک بازه‌ی اطمینان برای دقت و برای تفاوت دو مدل می‌دهد. ۲. **به طرح احترام بگذارید.** هر دو مدل به همان آیتم‌ها جواب داده‌اند، پس مقایسه جفتی است، مثل یک طرح درون‌آزمودنی. نمونه‌گیری مجدد مستقل از دو مدل، دشواری مشترک آیتم‌ها را نادیده می‌گیرد و بازه‌هایی بیش از حد پهن می‌دهد.

دشواری آیتم‌ها هم خیلی متفاوت است، که نسخه‌ی سطح آیتمِ ناهمگنی شرکت‌کننده‌ها در بخش D است: یک دقت میانگین واحد آن را پنهان می‌کند.

Code ۰۹ · سلول ۹ cell ،`code/week05.py` :کد

خروجی مورد انتظار:

```
Accuracy A = 0.74, B = 0.67, difference = 0.07
95% CI, paired bootstrap:   [-0.03, 0.17]
95% CI, unpaired bootstrap: [-0.06, 0.20]
```

۷ درصد برتری روی ۱۰۰ آیتم به‌وضوح با صفر فرق ندارد. جدول رتبه‌بندی‌ای که A را بدون بازه بالای B می‌گذارد، بیش از حد مطمئن است.

امتحانش کنید (بدون نیاز به API). ⋆ - اگر تفاوت واقعی ثابت بماند، benchmark به چند آیتم نیاز دارد تا بازه‌ی جفتی ۰ را شامل نشود؟ با شبیه‌سازی پیدا کنید. ⋆⋆ - SE والد (Wald) هر دقت، $\sqrt{p(1-p)/n}$، را حساب کنید و با SE حاصل از bootstrap مقایسه کنید. ⋆⋆ - بحث: مقاله‌ای «مدل A: ۷۴٪، مدل B: ۶۷٪» را بدون بازه گزارش می‌کند و نتیجه می‌گیرد که A «بهتر استدلال می‌کند». فهرست کنید از نویسندگان چه می‌پرسید.

۸.۳.۲ اشتباهات رایج و برداشت‌های نادرست

۱. **قاطی کردن SE با SD.** SD پراکندگی داده‌ها را توصیف می‌کند؛ SE عدم قطعیت یک برآورد را توصیف می‌کند و با بزرگ شدن داده‌ها کوچک می‌شود.

۲. **«با احتمال ۹۵٪ مقدار واقعی در بازه‌ی اطمینان من است.»** در بازه‌ی اطمینان فراوانی‌گرا، ۹۵٪ به رفتار بلندمدت رویه برمی‌گردد. این گزاره‌ی احتمالاتی مال credible intervalهای بیزی است (هفته‌ی ۹).

۳. **استفاده از `hess_inv` در BFGS برای خطای استاندارد.** یک محصول جانبی خام بهینه‌ساز است. Hessian را درست حساب کنید.

۴. **اعتماد به بازه‌های Wald نزدیک کران‌ها.** اگر $\hat{\theta}$ روی کران یا نزدیک آن است، یا بازه از مقادیر ناممکن عبور می‌کند، از بازه‌های profile یا bootstrap استفاده کنید.

۵. **گزارش پارامترها بدون عدم قطعیت.** مقایسه‌ی دو برآورد نقطه‌ای («شرکت‌کننده‌ی ۱ دارای $d = 0.42$ و شرکت‌کننده‌ی ۲ دارای $d = 0.51$ است») بدون بازه بی‌معنی است.

۶. **استنباط فرایندهای سطح فرد از داده‌های میانگین‌گیری‌شده.** میانگین منحنی‌های غیرخطی شکل تابعی را عوض می‌کند (بخش D). این برای آیتم‌ها، trialها و شرکت‌کننده‌ها یکسان صادق است.

۷. **با برآوردهای فردی مثل داده رفتار کردن.** آزمون t مرحله‌ی دوم روی پارامترهای برازش‌شده نادیده می‌گیرد که بعضی برآوردها خیلی پرنویزتر از بقیه‌اند. مدل‌های سلسله‌مراتبی این را درست می‌کنند (هفته‌ی ۱۳).

۹.۳.۲ خودآزمایی

۱. توزیع نمونه‌گیری یک برآوردگر چیست و چرا نمی‌توانیم مستقیماً آن را ببینیم؟ **پاسخ** توزیع برآوردهایی که در تکرارهای فرضی بسیار زیاد آزمایش با همان پارامترهای واقعی می‌گرفتیم. فقط یک مجموعه‌داده داریم، پس آن را با Hessian (نظریه‌ی مجانبی)، profile likelihood یا شبیه‌سازی (bootstrap) تقریب می‌زنیم.

۲. NLL در یک جهت از فضای پارامتر کمینه‌ی خیلی تختی دارد. این درباره‌ی خطاهای استاندارد و همبستگی برآوردها چه می‌گوید؟ **پاسخ** انحنای کم یعنی درایه‌ی کوچک Hessian در آن جهت، پس واریانس بزرگ در $\mathbf{H}^{-1}$: SEهای بزرگ. اگر جهت تخت مورب باشد، برآوردها به‌شدت همبسته‌اند (trade-off).

۳. SE روش Wald را برای یک نسبت دوجمله‌ای از مشتق دوم NLL به دست آورید. **پاسخ** $\text{NLL}''(\theta) = y/\theta^2 + (n-y)/(1-\theta)^2$. در $\hat{\theta} = y/n$ این برابر $n/\hat{\theta} + n/(1-\hat{\theta}) = n/[\hat{\theta}(1-\hat{\theta})]$ است. معکوس کردن و جذر گرفتن می‌دهد $\text{SE} = \sqrt{\hat{\theta}(1-\hat{\theta})/n}$.

۴. مراحل یک bootstrap پارامتری برای بازه‌ی اطمینان یک پارامتر مدل را بنویسید. **پاسخ** مدل را برازش کنید تا $\hat{\boldsymbol{\theta}}$ به دست آید. B مجموعه‌داده از مدل با $\hat{\boldsymbol{\theta}}$ و طرح آزمایش اصلی شبیه‌سازی کنید. هرکدام را دوباره برازش کنید. انحراف معیار برآوردهای جدید را SE و صدک‌های ۵.۲ و ۵.۹۷ آن‌ها را بازه‌ی ۹۵٪ در نظر بگیرید.

۵. چرا بازه‌ی profile likelihood می‌تواند نامتقارن باشد ولی بازه‌ی Wald نمی‌تواند؟ **پاسخ** بازه‌ی Wald یک NLL مربعی (توزیع نمونه‌گیری نرمال) فرض می‌کند که ذاتاً متقارن است. بازه‌ی profile از درست‌نمایی واقعی استفاده می‌کند که ممکن است چوله باشد، مثلاً نزدیک یک کران یا برای پارامترهای نرخ.

۶. بیست شرکت‌کننده هرکدام با نرخ متفاوت به‌طور نمایی یاد می‌گیرند. منحنی میانگین با تابع توانی بهتر برازش می‌شود. آیا باید نتیجه بگیریم که یادگیری از قانون توانی پیروی می‌کند؟ **پاسخ** نه. شکل توانی خطای ناشی از میانگین‌گیری است: میانگین توابع نمایی با نرخ‌های ناهمگن منحنی‌ای می‌سازد که نرخ نسبی تغییرش با زمان کم می‌شود. نتیجه‌گیری درباره‌ی شکل یادگیری فردی باید از برازش‌های فردی (یا سلسله‌مراتبی) بیاید.

۷. یک مزیت و یک عیب برازش جداگانه‌ی هر شرکت‌کننده بگویید. **پاسخ** مزیت: تفاوت‌های فردی را رعایت می‌کند و از خطای میانگین‌گیری دوری می‌کند. عیب: با trialهای کم برای هر نفر، برآوردها پرنویزند (و گاهی حدی یا روی کران)، و تحلیل آن‌ها در مرحله‌ی دوم عدم قطعیت‌های متفاوتشان را نادیده می‌گیرد.

۱۰.۳.۲ تکلیف

این هفته تکلیف نمره‌دار جدیدی نداریم. A2 (LS) **در برابر** (MLE) **در ابتدای درس هفته‌ی ۶ تحویل داده می‌شود.** بخش A lab امروز نشان می‌دهد چطور به برآوردهای A2 خود خطای استاندارد اضافه کنید. این کار الزامی نیست ولی تفسیرتان را قوی‌تر می‌کند.

تمرین اختیاری (بدون نمره): تمرین ۵ (پوشش) بهترین آمادگی برای مطالعات بازیابی هفته‌ی ۷ است.

۱۱.۳.۲ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۵.** ترکیب اطلاعات چند شرکت‌کننده: برازش تجمیعی در برابر فردی و خطرات میانگین‌گیری. (منبع اصلی.)
- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۴** (بخش‌های مربوط به عدم قطعیت پارامتر و Hessian، مرور از هفته‌ی قبل.
- اختیاری، خارج از فهرست درس: Mewhort, D. J. K. & Heathcote, A., Brown, S., (۲۰۰۰). The power law repealed: The case for an exponential law of practice. *Psychonomic Bulletin & Review*، ۷، ۱۸۵–۲۰۷. تحلیل کلاسیک خطاهای میانگین‌گیری در داده‌های تمرین.

پیش‌نمایش هفته‌ی ۶: تمرین ۴ هفته‌ی ۳ نشان داد که یک مدل سه‌پارامتری در SSE از مدل واقعی جلو می‌زند. هفته‌ی بعد مستقیماً با این روبه‌رو می‌شویم: چرا برازش خوب کافی نیست، و چطور cross-validation چیزی را که واقعاً می‌خواهیم، یعنی پیش‌بینی داده‌ی جدید، اندازه می‌گیرد.

فصل ۳

ارزیابی مدل‌های شناختی

۱.۳ هفته‌ی ۶: ارزیابی مدل‌ها ۱: نیکویی برازش، overfitting و cross-validation

فصل ۳: ارزیابی مدل‌های شناختی · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌های فراموشی هفته‌های ۲–۵، این بار با چهار مدل رقیب: نمایی ($k = 2$)، توانی ($k = 2$)، نمایی با مجانب ($k = 3$) و دوردی ($k = 4$).

۱.۱.۳ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
goodness of fit	نیکویی برازش	اینکه مدل داده‌ی موجود را چقدر خوب توصیف می‌کند
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
overfitting	بیش‌برازش (overfitting)	برازش نویز نمونه به‌جای الگوی واقعی
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
trace plot	نمودار trace	مقدار نمونه‌ها در برابر شماره‌ی تکرار
complexity / model flexibility	انعطاف‌پذیری / پیچیدگی مدل	دامنه‌ی الگوهایی که مدل می‌تواند تولید کند
test data / training	داده‌ی آموزش / آزمون	داده‌ی برازش / داده‌ی کنارگذاشته برای سنجش

English	فارسی	توضیح کوتاه
cross-validation (CV)	اعتبارسنجی متقابل (cross-validation)	برازش روی بخشی از داده و آزمون روی بخش کنارگذاشته
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
generalization	تعمیم	پیش‌بینی خوب داده‌ی جدید
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
RMSD / SSE	مجموع مربعات خطا / ریشه‌ی میانگین مربع انحراف	معیارهای فاصله‌ی داده و پیش‌بینی
noise	نویز	تغییرات تصادفی در شواهد یا در داده
response bias	سوگیری پاسخ	تمایل به یک پاسخ، مستقل از محرک
criterion (c)	ملاک	آستانه‌ی تصمیم؛ نشان‌دهنده‌ی سوگیری پاسخ
bias–variance trade-off	بده‌بستان سوگیری و واریانس	مدل ساده سوگیر، مدل منعطف پرواریانس
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
data leakage	نشت داده	رسیدن اطلاعات داده‌ی آزمون به برازش
BIC / AIC	معیار اطلاعاتی آکائیکه / بیزی	برازش به‌علاوه‌ی جریمه برای تعداد پارامتر
benchmark	benchmark (مجموعه‌آزمون استاندارد)	مجموعه سؤال برای مقایسه‌ی مدل‌های هوش مصنوعی
benchmark contamination	آلودگی benchmark	بودن سؤال‌های آزمون در داده‌ی آموزش مدل
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند

۲.۱.۳ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. با استفاده از مفاهیم انعطاف‌پذیری و overfitting **توضیح دهند** که چرا برازش خوب شاهد لازم ولی ناکافی برای یک مدل است.
۲. با شبیه‌سازی overfitting را **نشان دهند**: خطای آموزش با پیچیدگی مدل یکنواخت کم می‌شود ولی خطای پیش‌بینی نه.

۳. اعتبارسنجی hold-out، K-fold و leave-one-out را با امتیاز لگاریتم درست‌نمایی خارج از نمونه **پیاده‌سازی کنند** و داده‌های آموزش و آزمون را درست جدا نگه دارند.
۴. بر اساس ادعای تعمیمی که مطرح است، **انتخاب کنند** چه چیزی را کنار بگذارند (trial)ها، شرایط، شرکت‌کننده‌ها).
۵. نتایج cross-validation، از جمله عدم قطعیتشان، را برای مقایسه‌ی مدل‌های شناختی **تفسیر کنند**.

۳.۱.۳ مقدمه

در تمرین ۴ هفته‌ی ۳، مدل سه‌پارامتری نمایی با مجانب داده‌های هفته‌ی ۲ را بهتر از مدل توانی برازش کرد ($\text{SSE} \approx 0.020$ در برابر 0.026)، با اینکه داده‌ها از مدل توانی تولید شده بودند. در بخش D3 هفته‌ی ۳، یک مدل دوردی چهارپارامتری هم همین‌قدر خوب بود. اگر مدل‌ها را بر اساس برازش انتخاب کنیم، مدل غلط را انتخاب می‌کنیم و تا ابد پارامتر اضافه می‌کنیم.

این مشکل مخصوص منحنی‌های فراموشی نیست. یک مدل به اندازه‌ی کافی منعطف می‌تواند هر داده‌ای، از جمله نویز، را برازش کند. Roberts و Pashler به‌طور معروفی پرسیدند که یک برازش خوب واقعاً چقدر قانع‌کننده است (مطالعه‌ی بیشتر را ببینید). جوابشان: نه خیلی، مگر اینکه بدانیم مدل چه چیزی را نمی‌توانست برازش کند.

راه خروج این است که یادمان بیاید **چرا** مدل برازش می‌کنیم. می‌خواهیم فرایندی را که داده را تولید کرده بگیریم، و مدلی که فرایند را گرفته باشد باید **داده‌ی جدید** از همان فرایند را **پیش‌بینی کند**. نویز طبق تعریف تکرار نمی‌شود. پس سؤال از «مدل این داده‌ها را چقدر خوب برازش می‌کند؟» به «مدل داده‌هایی را که ندیده چقدر خوب پیش‌بینی می‌کند؟» تغییر می‌کند. cross-validation مستقیماً با همین داده‌هایی که داریم به این سؤال جواب می‌دهد.

این موضوع کجا به کار می‌رود؟

- **انتخاب بین نظریه‌ها.** هر وقت دو مدل حافظه، تصمیم یا یادگیری مقایسه می‌شوند، برازش خوب به‌تنهایی قانع‌کننده نیست؛ داوران مقاله‌ها cross-validation یا معیاری می‌خواهند که انعطاف را جریمه کند.
- **پیش‌بینی در روان‌شناسی بالینی و روان‌پزشکی:** مدل‌هایی که عود بیماری، پاسخ به درمان یا تشخیص را پیش‌بینی می‌کنند باید روی بیماران جدید اعتبارسنجی شوند، نه روی بیمارانی که با آن‌ها برازش شده‌اند. بسیاری از پیش‌بینی‌کننده‌های منتشرشده دقیقاً در همین آزمون شکست می‌خورند.
- **یادگیری ماشین:** تقسیم train/validation/test و cross-validation با k بخش، روش استاندارد انتخاب مدل و hyperparameterهاست؛ overfitting خطر اصلی است.
- **ارزیابی سیستم‌های هوش مصنوعی:** نمره‌ی benchmark فقط وقتی معنا دارد که آیتم‌های آزمون در داده‌ی آموزش نبوده باشند (بخش هوش مصنوعی و LLMها را ببینید).

۴.۱.۳ جزوه‌ی درس

به زبان ساده مدلی که پیچ‌های کافی داشته باشد می‌تواند از همه‌ی نقطه‌های داده بگذرد، حتی از نویز تصادفی. این آن را مدل خوبی نمی‌کند: نویز دفعه‌ی بعد فرق می‌کند، پس مدلی که نویز را کپی کرده داده‌ی جدید را بد پیش‌بینی می‌کند. این overfitting **(بیش‌برازش)** است. راه‌حل این است که مدل‌ها را با این بسنجیم که داده‌ای را که **ندیده‌اند** چقدر خوب پیش‌بینی می‌کنند. cross-validation این کار را با همان داده‌ای که داریم انجام می‌دهد: بخشی از داده را پنهان کن، مدل را روی بقیه برازش کن، بخش پنهان را پیش‌بینی کن، و تکرار کن تا هر بخش یک بار پنهان شده باشد. مدلی که بهترین پیش‌بینی را روی داده‌ی پنهان دارد برنده است. پیام اصلی هفته: برازش بهتر به همان داده دلیلی بر مدل بهتر نیست؛ پیش‌بینی بهتر داده‌ی جدید دلیل است.

زمان‌بندی پیشنهادی (۶۰ دقیقه): معیارهای برازش و محدودیت‌هایشان ۱۰ · overfitting و انعطاف‌پذیری ۱۵ · منطق تعمیم ۵ · cross-validation ۲۰ · چه چیزی را کنار بگذاریم ۱۰.

۱. معیارهای نیکویی برازش

معیار	تعریف	مقیاس	توضیح
RMSD	$\sqrt{\mathrm{SSE}/N}$	واحد داده	راحت خوانده می‌شود؛ وزن برابر فرض می‌کند
R^2	$1 - \mathrm{SSE}/\sum_i (y_i - \bar{y})^2$	۰ تا ۱ (برای مدل‌های خطی)	محبوب ولی برای مدل‌های غیرخطی گمراه‌کننده: می‌تواند منفی شود، انعطاف را پاداش می‌دهد، و تحت سلطه‌ی واریانس بزرگ بین شرایط است (برازش یک افت یکنوا تقریباً خودکار R^2 بالا می‌دهد)
لگاریتم درست‌نمایی $\ell(\hat{\boldsymbol{\theta}})$، NLL	هفته‌ی ۴	nat	معیار طبیعی برای مدل‌های مبتنی بر درست‌نمایی
انحراف G^2	$2(\ell_{\mathrm{sat}} - \ell)$	$\chi^2 \approx$	آزمون مطلق عدم برازش (هفته‌ی ۴)

همه‌ی این‌ها **کفایت توصیفی** را می‌سنجند: اینکه مدل داده‌هایی را که رویشان برازش شده چقدر خوب بازتولید می‌کند. هیچ‌کدام در نظر نمی‌گیرند که مدل چقدر راحت می‌توانست آن داده‌ها را تولید کند.

۲. overfitting و انعطاف‌پذیری

هر مشاهده را به شکل **علامت + نویز** بنویسید: $y_i = g(x_i) + \varepsilon_i$ که در آن g فرایند واقعی است. مدل برازش‌شده سعی می‌کند y_i را بازتولید کند، ولی فقط بخش g است که در داده‌ی جدید دوباره ظاهر می‌شود.

- مدلی که **خیلی ساده** باشد بخشی از g را از دست می‌دهد: عدم برازش نظام‌مند، یا **کم‌برازش** (underfitting)، سوگیری بالا).
- مدلی که **خیلی منعطف** باشد خم می‌شود تا ε_i خاص این نمونه را دنبال کند: overfitting (واریانس بالا). برازشش روی نمونه بهتر و پیش‌بینی‌اش برای داده‌ی جدید بدتر می‌شود.

با افزایش پیچیدگی، خطای آموزش همیشه کم می‌شود، در حالی که خطای مورد انتظار پیش‌بینی اول کم و بعد زیاد می‌شود: یک شکل U (بخش .A lab).

انعطاف‌پذیری چیزی بیش از تعداد پارامترهاست. دو مدل با k یکسان می‌توانند از نظر انعطاف، یعنی دامنه‌ی الگوهای داده‌ای که می‌توانند تولید کنند، خیلی فرق داشته باشند. پارامتری که به‌صورت نما یا جابه‌جایی وارد می‌شود معمولاً انعطاف بیشتری می‌خرد تا پارامتری که فقط منحنی را مقیاس می‌دهد. مدل دوردی می‌تواند منحنی‌های نمایی، شبه‌توانی و مجانبی را تقلید کند، و دقیقاً به همین دلیل برازش خوبش چشمگیر نیست. معیارهای اطلاعاتی (هفته‌ی ۷) پارامترها را می‌شمارند؛ cross-validation و Bayes factor (هفته‌ی ۱۰) به انعطاف واقعی پاسخ می‌دهند.

پیشرفته: تجزیه‌ی سوگیری–واریانس. برای مربع خطا، خطای مورد انتظار پیش‌بینی در نقطه‌ی x (روی مجموعه‌داده‌های جدید و نویز جدید) این‌طور تجزیه می‌شود:

$$\mathbb{E}\big[(y_{\text{new}} - \hat{f}(x))^2\big] = \underbrace{\sigma^2}_{\text{irreducible noise}} + \underbrace{\big(g(x) - \mathbb{E}[\hat{f}(x)]\big)^2}_{\text{bias}^2} + \underbrace{\text{Var}[\hat{f}(x)]}_{\text{variance}}.$$

افزودن پارامتر سوگیری را کم و واریانس را زیاد می‌کند. بهترین مدل برای پیش‌بینی این دو را متعادل می‌کند، و وقتی داده کم است لزوماً مدل واقعی نیست. این تجزیه در کتاب عظیمی‌فر و احمدی به‌تفصیل آمده است (مطالعه‌ی بیشتر را ببینید).

خواندن ریاضی تجزیه‌ی bias–variance (کادر پیشرفته) میانگین خطای مربعی پیش‌بینی را به سه بخش تقسیم می‌کند:

- σ^2، **نویز کاهش‌ناپذیر**: حتی فرایند واقعی هم نمی‌تواند بخش تصادفی داده‌ی جدید را پیش‌بینی کند. هیچ مدلی از این پایین‌تر نمی‌رود.
- $\text{bias}^2 := (g(x) - \mathbb{E}[\hat{f}(x)])^2$ پیش‌بینی میانگین مدل (میانگین روی مجموعه داده‌های ممکن) چقدر از حقیقت دور است. مدل‌های خیلی ساده bias بزرگی دارند.
- $\text{variance} := \text{Var}[\hat{f}(x)]$ منحنی برازش‌شده از یک مجموعه داده به مجموعه داده‌ی دیگر چقدر بالا و پایین می‌پرد. مدل‌های خیلی منعطف variance بزرگی دارند، چون دنبال نویز هر مجموعه داده می‌دوند.

اضافه کردن پارامتر، خطا را از جمله‌ی bias به جمله‌ی variance منتقل می‌کند. بهترین پیش‌بینی‌کننده جایی است که جمع این دو کمترین باشد؛ به همین دلیل وقتی داده کم است، یک مدل ساده و کمی غلط می‌تواند بهتر از مدل درست ولی پیچیده پیش‌بینی کند.

۳. تعمیم به‌عنوان معیار

مدلی را ترجیح می‌دهیم که **داده‌ی جدید از همان فرایند** را بهتر پیش‌بینی کند. سه نوع «جدید» با سه ادعای علمی متناظرند:

داده‌ی جدید یعنی...	ادعایی که آزمون می‌شود	کنار بگذارید...
trialهای جدید از همان شرکت‌کننده در همان شرایط	مدل فرایند این فرد را گرفته است	trialها یا آیتم‌های تصادفی
شرایط جدید (مثلاً فاصله‌های طولانی‌تر، محرک‌های جدید)	مدل سازوکار را گرفته، پس می‌تواند برون‌یابی کند	کل شرایط (رویکرد معیار تعمیم)
شرکت‌کننده‌های جدید	مدل آنچه را بین آدم‌ها مشترک است گرفته است	کل شرکت‌کننده‌ها

همیشه بگویید ارزیابی‌تان کدام نوع تعمیم را هدف گرفته است.

۴. cross-validation (CV)

اعتبارسنجی hold-out. داده را به یک مجموعه‌ی آموزش (برای برازش) و یک مجموعه‌ی آزمون (برای ارزیابی) تقسیم کنید. ساده ولی پرهدر و پرنویز است: نتیجه به یک تقسیم خاص بستگی دارد.

اعتبارسنجی K-fold. داده را به K بخش (fold) تقریباً برابر تقسیم کنید. برای هر بخش $k = 1, \dots, K$: ۱. مدل را روی

همه‌ی داده‌ها **جز** بخش k برازش کنید و $\hat{\boldsymbol{\theta}}_{(-k)}$ را بگیرید. ۲. پیش‌بینی‌هایش برای بخش k را امتیاز دهید.

امتیازها را روی بخش‌ها جمع کنید. هر مشاهده یک بار برای آزمون استفاده می‌شود و مدل هرگز روی داده‌ای که با آن آموزش دیده آزمون نمی‌شود. مقادیر معمول $K = 5$ یا 10 است. Leave-one-out (LOO) حالت خاصی است که هر مشاهده خودش یک بخش است.

امتیاز. برای مدل‌های مبتنی بر درست‌نمایی از **لگاریتم درست‌نمایی خارج از نمونه** (امتیاز پیش‌بینی لگاریتمی) استفاده کنید:

$$\text{CV-NLL} = -\sum_{k=1}^{K} \sum_{i \in \text{fold } k} \ln p\big(y_i \mid \hat{\boldsymbol{\theta}}_{(-k)}, \mathcal{M}\big).$$

کمتر بهتر است. برای مدل‌های گاوسی، مربع خطای خارج از نمونه گزینه‌ی معادلی است.

قواعد CV صادقانه: ۱. **هر چیزی** که از داده یاد گرفته می‌شود، از جمله برآورد پارامترها، انتخاب مقدار شروع از شبکه‌ها و تبدیل‌های داده‌محور، باید داخل هر بخش آموزش انجام شود. وگرنه اطلاعات از مجموعه‌ی آزمون «نشت» می‌کند (data leakage). ۲. در امتداد واحد درست تقسیم کنید (بخش ۳). برای CV در سطح trial با شمارش‌های دوجمله‌ای، **آیتم‌ها** را داخل هر شرط تقسیم کنید تا هر بخش آموزش هنوز همه‌ی شرایط را داشته باشد. ۳. برآوردهای CV پرنویزند. با چند تقسیم تصادفی تکرار کنید و میانگین و پراکندگی، یا SE تفاوت مدل‌ها بین بخش‌ها، را گزارش کنید. ۴. با تقسیم در سطح آیتم، CV مدل‌هایی را مقایسه می‌کند که روی $(K-1)/K$ داده برازش شده‌اند، پس مدل‌هایی را که داده‌ی زیادی لازم دارند کمی جریمه می‌کند.

> **پیشرفته: LOO، AIC و بیز.** برای مدل‌های منظم و N بزرگ، LOO با امتیاز لگاریتمی و AIC (هفته‌ی ۷) به‌طور مجانبی یک مدل را انتخاب می‌کنند. در مدل‌سازی بیزی، تقریبی کارا از LOO (PSIS-LOO) از نمونه‌های پسین محاسبه می‌شود. در هفته‌ی ۱۳ با ArviZ با آن آشنا می‌شوید.

خواندن ریاضی $\text{CV-NLL} = -\sum_k \sum_{i \in \text{fold } k} \ln p(y_i \mid \hat{\boldsymbol{\theta}}_{(-k)}, \mathcal{M})$:

- $\hat{\boldsymbol{\theta}}_{(-k)}$: پارامترهایی که **بدون** بخش k برآورد شده‌اند (علامت منفی در زیرنویس یعنی «کنار گذاشتن»).
- $\ln p(y_i \mid \hat{\boldsymbol{\theta}}_{(-k)})$: مدلی که بدون این مشاهده‌ها آموزش دیده، آن‌ها را چقدر محتمل می‌داند. مدلی که آن‌ها را خوب پیش‌بینی کرده، احتمال بالایی به آن‌ها می‌دهد.
- جمع دوگانه این مقدار را روی همه‌ی بخش‌ها و همه‌ی نقطه‌های کنارگذاشته جمع می‌کند؛ علامت منفی آن را به کمیتی برای کمینه کردن تبدیل می‌کند، مثل NLL هفته‌ی ۴. همان NLL است، ولی هر مشاهده با مدلی سنجیده می‌شود که هرگز آن را ندیده.

۵. تفسیر یک مقایسه‌ی مدل

- تفاوت‌های CV-NLL بر حسب nat هستند. به‌عنوان راهنمای تقریبی، تفاوت‌های کمتر از حدود ۱ تا ۲ nat، یا کمتر از دو برابر SE آن‌ها بین بخش‌ها یا تکرارها، نباید بیش از حد تفسیر شوند.
- مدلی که در CV برنده می‌شود بهترین **پیش‌بینی‌کننده** در میان مدل‌های مقایسه‌شده، برای این نوع تعمیم و این مقدار داده، است. «مدل واقعی» نیست. با داده‌ی بیشتر، مدل‌های پیچیده‌تر اغلب شروع به بردن می‌کنند، چون واریانسشان کم می‌شود.
- CV را با بررسی‌های کیفی‌ای که می‌شناسید ترکیب کنید: الگوی باقی‌مانده‌ها، معقول بودن پارامترها، و قابل تفسیر بودن مدل.

برای یک مهندس

- overfitting همان مشکل آشنای برازش یک چندجمله‌ای با درجه‌ی بالا یا یک فیلتر با تعداد tap زیاد روی یک سیگنال کوتاه و پرنویز است: خطای آموزش به صفر می‌رسد و خطای پیش‌بینی منفجر می‌شود.
- **trade-off بین bias و variance** همان چیزی است که هنگام انتخاب مرتبه‌ی مدل (مرتبه‌ی AR، تعداد tapهای فیلتر) یا پنجره‌ی هموارسازی می‌بینید: درجه‌ی آزادی کم bias می‌دهد و درجه‌ی آزادی زیاد variance.
- cross-validation نسخه‌ی داده‌محور انتخاب مرتبه‌ی مدل است. معیارهایی از نوع AIC/MDL (هفته‌ی ۷) میان‌برهای تحلیلی‌اند که شاید از انتخاب مرتبه‌ی مدل AR بشناسید.
- **آموزش روی داده‌ی آزمون** مثل این است که یک گیرنده را روی همان تحقق نویزی تنظیم کنید که بعداً BER آن را رویش اندازه می‌گیرید: کارایی گزارش‌شده خوش‌بینانه است.
- nat نسخه‌ی لگاریتم طبیعی bit است: تفاوت ۱ nat یعنی نسبت درست‌نمایی $e \approx 2.7$.

برای مدرس

- **با مثال حل‌شده‌ی چندجمله‌ای روی تخته شروع کنید.** چهار نقطه، چهار مدل. بگذارید دانشجوها بهترین مدل را با SSE آموزش انتخاب کنند (مکعبی را انتخاب می‌کنند)، بعد بپرسید پیش‌بینی آن در ۱۶ روز چیست (-8.5). خنده‌ی کلاس همان درس است.
- **leave-one-out را برای یک نقطه با دست انجام دهید** (نقطه‌ی ۸ روز را با دست بپوشانید، خط را با چشم دوباره برازش کنید و پیش‌بینی کنید). بعد دانشجوها می‌فهمند کد lab چه می‌کند.
- **روی «چه چیزی کنار گذاشته می‌شود» تأکید کنید.** سه نوع داده‌ی «جدید» (بخش ۳) را روی تخته بنویسید؛ بیشتر اشتباه‌های پروژه‌های دانشجویی از کنار گذاشتن چیز اشتباه می‌آید.
- **سؤال‌های رایج.**
  - «اگر مدل درست کمتر *overfit* می‌کند، چرا یک مدل غلط می‌تواند در *CV* برنده شود؟» با داده‌ی کم، یک مدل ساده‌ی غلط ممکن است variance کمتری داشته باشد. CV بهترین پیش‌بینی‌کننده را انتخاب می‌کند، نه مدل درست را.
  - «چند بخش *(fold)*؟» ۵ یا ۱۰ استاندارد است؛ برای داده‌های خیلی کوچک LOO.
  - «آیا $R^2 = 0.98$ خوب است؟» برای یک منحنی نزولی، تقریباً هر مدل یکنوایی R^2 بالا می‌گیرد؛ چیز زیادی نمی‌گوید.

۵.۱.۳ مثال حل‌شده

داده. چهار نسبت یادآوری $y = (0.62, 0.50, 0.47, 0.27)$ در $t = (1, 2, 4, 8)$ روز. چندجمله‌ای‌هایی با درجه‌ی رو به افزایش را به‌عنوان «مدل» مقایسه می‌کنیم.

قدم ۱: برازش روی همه‌ی داده‌ها

مدل	k	برازش‌شده معادله‌ی	آموزش SSE
ثابت	۱	$\hat{y} = 0.465$	۰۶۳۳.۰
خطی	۲	$\hat{y} = 0.637 - 0.046\,t$	۰۰۳۲.۰
دو درجه‌ی	۳	$\hat{y} = 0.647 - 0.053\,t + 0.0008\,t^2$	۰۰۳۱.۰
سه درجه‌ی	۴	می‌گذرد نقطه ۴ هر از دقیقاً	۰۰۰۰.۰

مدل	k	معادله‌ی برازش‌شده	SSE آموزش

بر اساس SSE آموزش، چندجمله‌ای درجه‌ی سه «کامل» است. ولی از آن بخواهید یادآوری را در $t = 16$ روز پیش‌بینی کند: -8.5 پیش‌بینی می‌کند، یعنی منفی ۸۵۰٪ یادآوری. مدل خطی -0.10 پیش‌بینی می‌کند (آن هم ناممکن ولی کمتر پوچ) و مدل ثابت ۴۷.۰.

قدم ۲: اعتبارسنجی leave-one-out

هر بار یک نقطه را کنار بگذارید، روی سه نقطه‌ی باقی‌مانده دوباره برازش کنید و نقطه‌ی کنارگذاشته را پیش‌بینی کنید.

t کنارگذاشته	مشاهده‌شده	پیش‌بینی ثابت	پیش‌بینی خطی	پیش‌بینی درجه‌ی دو
۱	۶۲.۰	۴۱۳.۰	۵۶۰.۰	۴۹۸.۰
۲	۵۰.۰	۴۵۳.۰	۵۷۰.۰	۵۷۰.۰
۴	۴۷.۰	۴۶۳.۰	۴۴۸.۰	۳۳۰.۰
۸	۲۷.۰	۵۳۰.۰	۲۷۵.۰	**۲۵۰.۱**
SSE در LOO		**۱۱۲۵.۰**	**۰۰۹۰.۰**	**۰۰۰۰.۱**

(چندجمله‌ای درجه‌ی سه اینجا قابل اعتبارسنجی نیست: سه نقطه چهار پارامتر را تعیین نمی‌کنند.)

تفسیر. SSE آموزش مدل درجه‌ی دو عملاً با مدل خطی برابر است، ولی خطای LOO آن بیش از ۱۰۰ برابر بزرگ‌تر است. وقتی نقطه‌ی ۸ روزه را نمی‌بینند، انحنایش را طوری خم می‌کند که سه فاصله‌ی کوتاه را برازش کند و در ۸ روز یادآوری بیشتر از ۱ پیش‌بینی می‌کند. پارامتر اضافه نویز را برازش کرد، نه فراموشی را. مدل خطی از میان این سه بهترین تعمیم را دارد. (هیچ‌کدام از این چندجمله‌ای‌ها مدل شناختی معقولی برای فراموشی نیستند، چون هیچ‌کدام دامنه‌ی ۰ تا ۱ را رعایت نمی‌کنند؛ دقیقاً به همین دلیل به‌جایشان از مدل‌های نمایی و توانی استفاده می‌کنیم.)

۶.۱.۳ lab (۲ ساعت)

اهداف

۱. دیدن overfitting در عمل: خطای آموزش در برابر خطای آزمون با افزایش درجه‌ی چندجمله‌ای.
۲. پیاده‌سازی K-fold CV در سطح آیتم با لگاریتم درست‌نمایی دوجمله‌ای خارج از نمونه، و مقایسه‌ی چهار مدل فراموشی.
۳. اجرای یک آزمون **معیار تعمیم**: آموزش روی فاصله‌های کوتاه، پیش‌بینی فاصله‌های طولانی.
۴. **تفسیر** اینکه کدام مدل تعمیم پیدا می‌کند و چرا مدلی که بهترین برازش را دارد بهترین پیش‌بینی‌کننده نیست.

زمان‌بندی: بخش A ۲۵ دقیقه · بخش B ۴۵ دقیقه · بخش C ۲۵ دقیقه · بخش D ۲۵ دقیقه.

آماده‌سازی: داده و چهار مدل

Code · کد: code/week06.py، cell ۱ · سلول ۱

خروجی مورد انتظار:

```
exp      k = 2  training NLL = 29.812  params = [0.638 0.046]
pow      k = 2  training NLL = 19.830  params = [0.877 0.421]
expasym  k = 3  training NLL = 18.919  params = [0.861 0.38  0.308]
two      k = 4  training NLL = 18.919  params = [0.265 0.    0.596 0.38 ]
```

بر اساس NLL آموزش، مدل‌های پیچیده‌تر برنده‌اند. دقت کنید که بهترین برازش مدل دوردی یک جزء کند با نرخ ۰ دارد: مثل هفته‌ی ۳ به مدل نمایی با مجانب تبدیل شده است (با NLL یکسان). حالا ببینیم آیا پیش‌بینی بهتری هم دارند.

بخش A: overfitting با چندجمله‌ای‌ها (۲۵ دقیقه)

چندجمله‌ای‌هایی بر حسب $x = \ln(1 + t)$ را به‌عنوان مدل‌های منعطفِ عمداً «بی‌فکر» به کار می‌بریم. داده‌های **آزمون** ۵۰۰ مجموعه‌داده‌ی تازه‌اند که با همان طرح از مدل توانی واقعی شبیه‌سازی شده‌اند.

Code · کد: code/week06.py، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
 degree  k  train_MSE  test_MSE
      0  1    0.03980   0.05072
      1  2    0.00663   0.00787
      2  3    0.00204   0.00634
      3  4    0.00202   0.00640
      4  5    0.00173   0.00661
      5  6    0.00087   0.00750
      6  7    0.00087   0.00750
      7  8    0.00000   0.00833
```

به این دقت کنید: خطای آموزش با هر پارامتر اضافه کم می‌شود و در $k = 8$ به ۰ می‌رسد (درون‌یابی). خطای آزمون در یک پیچیدگی میانی کمترین است و بعد بالا می‌رود: پارامترهای اضافه دنبال نویز می‌دوند. حتی بهترین چندجمله‌ای هم بدتر از مدل توانی واقعی پیش‌بینی می‌کند؛ MSE آزمون آن را می‌توانید به‌عنوان تمرین حساب کنید.

بخش K-fold B: cross-validation روی آیتم‌ها (۴۵ دقیقه)

در هر فاصله ۵۰ آیتم آزمون شده است. هر آیتم را داخل هر فاصله به یکی از $K = 5$ بخش اختصاص می‌دهیم تا هر مجموعه‌ی آموزش همه‌ی ۸ فاصله را داشته باشد.

Code · **کد:** `code/week06.py`، cell ۳ · سلول ۳

خروجی مورد انتظار (حدود ۱ تا ۲ دقیقه):

```
         k  train_NLL  CV_NLL_mean  CV_NLL_sd
exp      2     29.812      256.458      1.058
pow      2     19.830      245.791      0.734
expasym  3     18.919      247.370      1.574
two      4     18.919      247.531      1.172

CV-NLL difference to the power model (mean, SD over repeats):
         exp  pow  expasym    two
mean  10.667  0.0    1.579  1.740
std    1.137  0.0    1.807  1.349
```

دقت کنید که NLL آموزش (دوجمله‌ای، با ضرایب دوجمله‌ای) و CV-NLL (برنولی، در سطح آیتم) مقیاس‌های متفاوتی دارند. مدل‌ها را **داخل** هر ستون مقایسه کنید، نه بین ستون‌ها.

تفسیر: ۱. کدام مدل آیتم‌های کنارگذاشته را بهتر پیش‌بینی می‌کند؟ آیا برتری‌اش بر نفر دوم از تغییرپذیری بین تکرارهای CV بیشتر است؟ ۲. مدل دوردی بهترین برازش آموزش را دارد. در CV چه بر سرش می‌آید و چرا؟ ۳. آیا CV با این داده‌ها می‌تواند مدل توانی و مدل نمایی با مجانب را از هم جدا کند؟ چه چیزی کمک می‌کرد؟

بخش C: معیار تعمیم: پیش‌بینی فاصله‌های طولانی‌تر (۲۵ دقیقه)

مدلی که فهمیده فراموشی چگونه کار می‌کند باید بتواند برون‌یابی کند. روی پنج فاصله‌ی کوتاه‌تر ($t \leq 7$ روز) آموزش دهید و سه فاصله‌ی طولانی‌تر (۱۴، ۲۱، ۳۰ روز) را که مدل‌ها هرگز ندیده‌اند پیش‌بینی کنید.

Code · **کد:** `code/week06.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
         test_NLL_long_delays  pred_t14  pred_t21  pred_t30
model
exp                    72.550     0.086     0.028     0.007
pow                     9.627     0.228     0.186     0.156
expasym                 6.268     0.260     0.257     0.257
two                    46.072     0.131     0.057     0.020
observed: {14: 0.26, 21: 0.26, 30: 0.28}
```

به این دقت کنید: اینجا مدل **نمایی با مجانب** بهترین برون‌یابی را دارد، نه مدل توانی واقعی. سه نقطه‌ی کنارگذاشته اتفاقاً صاف‌اند (۲۶.۰، ۲۶.۰، ۲۸.۰) و منحنی‌ای که ثابت می‌شود آن‌ها را خوب پیش‌بینی می‌کند. مدل توانی، مثل فرایند واقعی، به افت ادامه می‌دهد، ولی در این نمونه نویز فاصله‌های طولانی یادآوری را صاف نشان داده است. مدل نمایی خالص و مدل دوردی (که برازش فاصله‌های کوتاهش هیچ قیدی روی جزء کند نمی‌گذارد) بد برون‌یابی می‌کنند. درس‌ها: (۱) معیارهای تعمیم مختلف می‌توانند مدل‌ها را متفاوت رتبه‌بندی کنند؛ (۲) یک آزمون روی سه نقطه‌ی داده خودش پرنویز است، پس برد یک مدل در یک مجموعه‌ی آزمون اثبات نیست؛ (۳) توافق چند معیار (بخش B، بخش C، و AIC/BIC هفته‌ی ۷) قانع‌کننده‌تر از هر یک از آن‌هاست.

بخش D: کنار هم گذاشتن (۲۵ دقیقه)

این جدول را در notebook از روی بخش‌های B و C پر کنید و یک پاراگراف کوتاه (۵ تا ۸ جمله) در جواب این سؤال بنویسید:
کدام مدل را به‌عنوان بهترین توضیح این داده‌های فراموشی توصیه می‌کنید و چقدر مطمئنید؟

مدل	k	NLL آموزش	CV-NLL پنج‌بخشی (میانگین $\pm$ SD)	NLL آزمون فاصله‌های طولانی	الگوی باقی‌مانده‌ها (هفته‌ی ۴)	پارامترها معقول‌اند؟
exp						
pow						
expasym						
two						

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. در بخش A، مدل توانی واقعی با پارامترهای واقعی را به‌عنوان یک «مدل» اضافه کنید (هیچ پارامتر برازش‌شده‌ای ندارد). MSE آزمون آن را حساب کنید و با بهترین چندجمله‌ای مقایسه کنید. خطای کاهش‌ناپذیر چقدر است؟

تمرین ۲ ⋆. بخش B را با $K = 2$، $K = 10$ و leave-one-item-out ($K = 50$) دوباره اجرا کنید. آیا رتبه‌بندی تغییر می‌کند؟ کدام K پایدارترین نتایج را بین تکرارها می‌دهد؟

تمرین ۳ ⋆⋆ **(نشت داده).** یک CV «غلط» بنویسید که در آن مقادیر شروع هر بخش از برازش روی کل مجموعه‌داده گرفته شود، و یکی دیگر که در آن آیتم‌های آزمون هر بخش اشتباهاً در آموزش هم باشند. نتایج را با CV درست مقایسه کنید. کدام اشتباه مهم‌تر است و چرا؟

تمرین ۴ ⋆⋆ **(داده‌ی بیشتر).** یک مجموعه‌داده‌ی جدید از مدل توانی واقعی با $n = 500$ آیتم در هر فاصله شبیه‌سازی کنید و بخش‌های B و C را دوباره اجرا کنید. آیا رتبه‌بندی روشن‌تر می‌شود؟ آیا مدل دوردی هیچ‌وقت برنده می‌شود؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته:** leave-one-participant-out**).** از مولد داده‌ی تمرین بخش D هفته‌ی ۵ با ۲۰ شرکت‌کننده استفاده کنید. CV ای پیاده‌سازی کنید که هر بخش آن یک شرکت‌کننده را کنار بگذارد: یک مدل تجمیعی (میانگین گروه) را روی ۱۹ شرکت‌کننده برازش کنید و پیش‌بینی منحنی شرکت‌کننده‌ی کنارگذاشته را با لگاریتم درست‌نمایی گاوسی امتیاز دهید. مدل‌های نمایی و توانی را مقایسه کنید. بعد همین کار را با برازش‌های سطح فرد انجام دهید. توضیح دهید چرا این دو طرح CV به دو سؤال علمی متفاوت جواب می‌دهند.

lab check-off

نشان دهید: (۱) نمودار آموزش در برابر آزمون از بخش A، (۲) جدول خلاصه‌ی CV از بخش B، و (۳) پاراگراف بخش D.

۷.۱.۳ ارتباط با هوش مصنوعی و LLMها

آلودگی (contamination) benchmark **همان نشت داده است.** LLMها روی حجم عظیمی از متن اینترنت آموزش می‌بینند. اگر سؤال‌های یک benchmark (یا جواب‌هایشان) آنلاین منتشر شده باشند، ممکن است در داده‌ی آموزشی باشند، پس مدل روی آیتم‌هایی آزموده می‌شود که قبلاً دیده. این دقیقاً مسئله‌ی نشت در cross-validation است: مجموعه‌ی آزمون دیگر از مجموعه‌ی آموزش مستقل نیست، پس نمره علاوه بر تعمیم، حفظ کردن را هم می‌سنجد. این یکی از جدی‌ترین مشکلات ارزیابی سیستم‌های هوش مصنوعی است، از جمله ادعاهایی که می‌گویند LLMها روی تکلیف‌های کلاسیک روان‌شناسی، که مواد آن‌ها همه‌جا منتشر شده، توانایی‌های شناختی انسان‌گونه نشان می‌دهند.

Code · **کد:** `code/week06.py`، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
Reported accuracy (all items): 0.73
Accuracy on leaked items:      0.96  (n = 120)
Accuracy on clean items:       0.63  (n = 280)
```

نمره‌ی گزارش‌شده (۷۳.۰) توانایی حل مسئله‌های تازه (۶۳.۰) را بیش از واقع نشان می‌دهد. راه‌حل همان است که در lab این هفته دیدید: ارزیابی روی آیتم‌هایی که مطمئنیم در برازش استفاده نشده‌اند، مثلاً آیتم‌های تازه‌نوشته، یا گونه‌های نظام‌مند تکلیف‌های کلاسیک.

امتحانش کنید (بدون نیاز به API). ⋆ سهم آیتم‌های نشت‌کرده را از ۰ تا ۹.۰ تغییر دهید و دقت گزارش‌شده را رسم کنید. آیا فقط از روی دقت گزارش‌شده می‌توانید بگویید چقدر نشت کرده؟ ⋆⋆ در عمل نمی‌دانیم کدام آیتم‌ها نشت کرده‌اند. فرض کنید برای هر آیتم یک گونه‌ی «تازه» (همان منطق، عبارت‌بندی تازه) داریم. گونه‌های تازه را با $P(\text{correct}) = 0.60$ شبیه‌سازی کنید و اثر نشت را به‌صورت تفاوت دقت آیتم‌های اصلی و تازه، با یک بازه‌ی bootstrap جفتی (هفته‌ی ۵) برآورد کنید. ⋆⋆ بحث: یک LLM معمای استدلالی معروفی از یک مقاله‌ی روان‌شناسی دهه‌ی ۱۹۷۰ را حل می‌کند. چرا این شاهد ضعیفی است بر اینکه «مثل انسان استدلال می‌کند»؟ چه آزمونی قوی‌تر است؟

۸.۱.۳ اشتباهات رایج و برداشت‌های نادرست

۱. **«مدلی که بهترین برازش را دارد بهترین مدل است.»** برازش انعطاف را پاداش می‌دهد. همیشه بپرسید مدل داده‌ی جدید را چقدر خوب پیش‌بینی می‌کند.
۲. **«انعطاف = تعداد پارامترها.»** شکل تابعی هم مهم است. مدل‌هایی با k برابر می‌توانند در آنچه می‌توانند برازش کنند خیلی فرق داشته باشند.
۳. **نشت اطلاعات آزمون به آموزش،** مثلاً انتخاب مقدار شروع، کران یا تبدیل از روی کل داده، یا نرمال‌سازی با آماره‌های کل داده.
۴. **تقسیم در امتداد واحد غلط.** اگر ادعا درباره‌ی شرکت‌کننده‌های جدید است، کنار گذاشتن trialهای تصادفی تعمیم را بیش از حد برآورد می‌کند.
۵. **بیش‌تفسیر تفاوت‌های کوچک** CV. برآوردهای CV پرنویزند. تقسیم‌ها را تکرار کنید و به تغییرپذیری تفاوت‌ها نگاه کنید.
۶. **مدل واقعی را انتخاب کرد.»** CV بهترین پیش‌بینی‌کننده را برای این مقدار داده انتخاب می‌کند. با داده‌ی کم، یک مدل ساده‌تر (حتی غلط) می‌تواند بهتر از مدل واقعی پیش‌بینی کند.
۷. **استفاده از R^2 برای مقایسه‌ی مدل‌های شناختی غیرخطی.** بین مدل‌ها قابل مقایسه نیست و انعطاف را پاداش می‌دهد.

۹.۱.۳ خودآزمایی

۱. چرا وقتی به یک مدل nested پارامتر اضافه می‌کنیم، خطای آموزش همیشه کم می‌شود (یا ثابت می‌ماند)؟ **پاسخ** مدل بزرگ‌تر مدل کوچک‌تر را به‌عنوان حالت خاص در بر دارد (مثلاً با صفر گذاشتن پارامتر اضافه)، پس بهترین برازشش هرگز بدتر نیست. بهینه‌ساز همیشه می‌تواند برازش مدل کوچک‌تر را بازتولید کند و معمولاً با برازش نویز آن را بهتر می‌کند.

۲. overfitting را بر حسب علامت و نویز تعریف کنید. **پاسخ** داده = علامت (فرایند نظام‌مند) + نویز (تغییرات تصادفی). مدلی که overfitting می‌کند خودش را با نویز نمونه‌ی خاص تطبیق می‌دهد. این برازشش روی این داده‌ها را بهتر و پیش‌بینی داده‌ی جدید را، که نویزش متفاوت است، بدتر می‌کند.

۳. K-fold cross-validation را در چهار قدم توضیح دهید. **پاسخ** (۱) داده را به K بخش تقسیم کنید. (۲) برای هر بخش، مدل را روی $K-1$ بخش دیگر برازش کنید. (۳) پیش‌بینی‌های مدل برازش‌شده را برای بخش کنارگذاشته امتیاز دهید (مثلاً با لگاریتم درست‌نمایی). (۴) امتیازها را روی بخش‌ها جمع یا میانگین کنید؛ در صورت امکان با تقسیم‌های تصادفی جدید تکرار کنید.

۴. در آزمایش فراموشی، چرا آیتم‌ها را داخل هر فاصله‌ی نگهداری به بخش‌ها اختصاص می‌دهیم به‌جای اینکه کل فاصله‌ها را کنار بگذاریم؟ **پاسخ** تقسیم داخل فاصله پیش‌بینی trialهای جدید در همان شرایط را آزمون می‌کند، و هر بخش آموزش هنوز همه‌ی شرایط را دارد. کنار گذاشتن کل فاصله‌ها ادعای دیگری را آزمون می‌کند: برون‌یابی به شرایط جدید (معیار تعمیم، بخش C).

۵. CV-NLL مدل A به‌طور میانگین ۱.۲ nat کمتر از مدل B است، ولی این تفاوت بین تکرارهای CV با SD برابر ۰.۳ تغییر می‌کند. چه نتیجه‌ای می‌گیرید؟ **پاسخ** شاهد ضعیف است. به‌طور دقیق، SD بین تکرارها تغییرپذیری بین تقسیم‌ها را نشان می‌دهد نه عدم قطعیت نمونه‌گیری داده را، ولی در هر حال یک تفاوت ۲ nat با این همه ناپایداری نباید بیش‌تفسیر شود. داده‌ی بیشتری جمع کنید یا مدل‌ها را تقریباً هم‌ارز در پیش‌بینی گزارش کنید.

۶. چرا یک مدل ساده‌تر و «غلط» گاهی در CV از مدل واقعی و پیچیده‌تر بهتر عمل می‌کند؟ **پاسخ** با داده‌ی محدود، پارامترهای مدل پیچیده با واریانس بالا برآورد می‌شوند و این واریانس بیشتر از سوگیری مدل ساده‌تر به پیش‌بینی آسیب می‌زند (trade-off سوگیری–واریانس). با داده‌ی بیشتر واریانس مدل واقعی کم می‌شود و بالاخره برنده می‌شود.

۷. دانشجویی $R^2 = 0.97$ را برای یک مدل غیرخطی فراموشی گزارش می‌کند و نتیجه می‌گیرد مدل درست است. دو اعتراض بیاورید. **پاسخ** (۱) R^2 برای تقریباً هر منحنی نزولی یکنوایی بالاست، چون بیشترِ واریانس داده‌های فراموشی همان افت کلی است. (۲) برازش خوب چیزی درباره‌ی تعمیم یا انعطاف نمی‌گوید؛ الگوی باقی‌مانده‌ها، CV و مقایسه با مدل‌های جایگزین لازم است.

۱۰.۱.۳ تکلیف

A3: مقایسه و بازیابی مدل (۱۰.۱ نمره از ۲۰؛ انتشار هفته‌ی ۶، موعد ابتدای درس هفته‌ی ۹)

A3 این هفته و هفته‌ی بعد را در بر می‌گیرد: کارهای ۱ تا ۳ از مطالب این هفته و کارهای ۴ تا ۶ از مطالب هفته‌ی ۷ (AIC/BIC، بازیابی پارامتر و مدل) استفاده می‌کنند.

داده. یک آزمایش فراموشی با ۱۲ شرکت‌کننده که با این کد تولید می‌شود:

> Code · **کد:** `code/week06.py`، cell ۶ · سلول ۶

کارها.

۱. **برازش‌های فردی (۵.۱ امتیاز).** مدل‌های نمایی، توانی و نمایی با مجانب را برای هر شرکت‌کننده با MLE چندشروعی برازش کنید. جدولی از پارامترها و NLLها گزارش کنید؛ برآوردهای روی کران را مشخص کنید.

۲. **برازش مطلق (۱ امتیاز).** G^2 را برای هر شرکت‌کننده و مدل حساب کنید. هر مدل برای چند شرکت‌کننده برازش ناموفق دارد ($p < .05$)؟

۳. cross-validation **(۲ امتیاز).** برای هر شرکت‌کننده، CV پنج‌بخشی در سطح آیتم (۵ بار تکرار) را برای سه مدل اجرا کنید. گزارش کنید هر مدل برای چند شرکت‌کننده برنده است، و مجموع CV-NLL روی شرکت‌کننده‌ها را با تغییرپذیری‌اش.

۴. **معیارهای اطلاعاتی (۵.۱ امتیاز، هفته‌ی ۷).** AIC، AICc و BIC را برای هر شرکت‌کننده و مدل و وزن‌های آکائیکه را حساب کنید. آیا معیارها با CV توافق دارند؟

۵. **بازیابی (۵.۲ امتیاز، هفته‌ی ۷).** (الف) بازیابی پارامتر برای مدل توانی در این طرح: ۲۰۰ شبیه‌سازی با پارامترهایی از دامنه‌های معقول؛ مقادیر واقعی در برابر بازیابی‌شده را رسم کنید، همبستگی‌ها را گزارش کنید و درباره‌ی هر trade-offای توضیح دهید. (ب) بازیابی مدل برای سه مدل با AIC و BIC: یک confusion matrix ۳ × ۳ از ۱۰۰ شبیه‌سازی برای هر مدل تولیدکننده.

۶. **تفسیر (۵.۱ امتیاز، حداکثر ۴۰۰ کلمه).** کدام مدل فراموشی را در این مطالعه بهتر توصیف می‌کند، شواهد چقدر قوی است، و تحلیل بازیابی چطور نتیجه‌گیری شما را مقید می‌کند؟

روبریک (۱۰ امتیاز، معادل ۰.۱): امتیاز هر کار در بالا آمده است. داخل هر کار: درستی ٪۶۰، وضوح جدول‌ها و نمودارها ٪۲۰، تفسیر ٪۲۰. برای تحویل با تأخیر، روزی ٪۱۰ کسر می‌شود (حداکثر ۳ روز).

۱۱.۱.۳ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۱۰.** مقایسه‌ی مدل‌ها: چرا برازش کافی نیست، انعطاف‌پذیری، و cross-validation در کنار دیگر روش‌های مقایسه. (منبع اصلی.)
- **عظیمی‌فر و احمدی (۱۳۹۶)**، جلد ۱: مطالب مربوط به تعمیم‌پذیری، overfitting و trade-off سوگیری–واریانس از دیدگاه شناسایی الگو [شماره‌ی فصل بررسی شود].
- کلاسیک‌های اختیاری، خارج از فهرست درس: Pashler, H. & Roberts, S., (۲۰۰۰). How persuasive is a good fit? A comment on theory testing. *Psychological Review,* ۱۰۷، ۳۵۸–۳۶۷. Busemeyer, J. & Wang, Y.-M. (۲۰۰۰). Model comparisons and model selections based on generalization criterion methodology. *Journal of Mathematical Psychology,* ۴۴، ۱۷۱–۱۸۹.

پیش‌نمایش هفته‌ی ۷: cross-validation کلی است ولی از نظر محاسباتی پرهزینه. معیارهای اطلاعاتی (AIC، BIC) تعمیم را از یک برازش واحد تخمین می‌زنند. و پیش از اعتماد به هر مقایسه‌ای، باید بررسی کنیم آیا روش ما می‌تواند پارامترها و مدل‌هایی را که واقعاً داده را تولید کرده‌اند بازیابی کند.

۲.۳ هفته‌ی ۷: ارزیابی مدل‌ها ۲: معیارهای اطلاعاتی، بازیابی پارامتر و بازیابی مدل

فصل ۳: ارزیابی مدل‌های شناختی · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌ها و مدل‌های فراموشی هفته‌های ۲–۶، به‌علاوه‌ی مطالعات شبیه‌سازی بزرگ با همان طرح آزمایش.

۱.۲.۳ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
criterion (c)	ملاک	آستانه‌ی تصمیم؛ نشان‌دهنده‌ی سوگیری پاسخ
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
model recovery	بازیابی مدل	آیا مقایسه‌ی مدل، مدل مولد را درست انتخاب می‌کند
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
research design	طرح آزمایش	شرایط، تعداد کوشش‌ها و نمونه‌ها
likelihood-ratio test (LRT)	آزمون نسبت درست‌نمایی	مقایسه‌ی دو مدل تودرتو
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
nested models	مدل‌های تودرتو (nested)	یک مدل حالت خاص مدل دیگر است
BIC / AIC	معیار اطلاعاتی آکائیکه / بیزی	برازش به‌علاوه‌ی جریمه برای تعداد پارامتر
response bias	سوگیری پاسخ	تمایل به یک پاسخ، مستقل از محرک
confusion matrix	ماتریس درهم‌ریختگی (confusion matrix)	P(مدل انتخاب‌شده
inversion matrix	ماتریس معکوس (inversion matrix)	P(مدل مولد
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
identifiability	شناسایی‌پذیری	آیا داده پارامترها را به‌طور یکتا تعیین می‌کند
parameter trade-off	بده‌بستان پارامترها	تغییر یک پارامتر که با پارامتر دیگر جبران می‌شود
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
Akaike weights	وزن‌های آکائیکه	پشتیبانی نسبی از هر مدل
cross-validation (CV)	اعتبارسنجی متقابل (cross-validation)	برازش روی بخشی از داده و آزمون روی بخش کنارگذاشته
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
model mimicry	تقلید مدل	تولید داده‌ای که شبیه داده‌ی مدل دیگر است
in-context learning	یادگیری درون‌متنی	یادگیری از مثال‌های داخل prompt

۲.۲.۳ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. آزمون نسبت درست‌نمایی را برای مدل‌های nested **انجام دهند** و **توضیح دهند** چرا نمی‌تواند مدل‌های non-nested را مقایسه کند.
۲. AIC، AICc، BIC و وزن‌های آکائیکه/BIC را **حساب و تفسیر کنند** و اهداف متفاوت AIC و BIC را **توضیح دهند**.
۳. یک مطالعه‌ی بازیابی پارامتر را **طراحی و اجرا کنند** و پارامترهای سوگیر، پرنویز یا دارای trade-off را **تشخیص دهند**.
۴. یک مطالعه‌ی بازیابی مدل را **طراحی و اجرا کنند** و ماتریس‌های درهم‌ریختگی و معکوس را **تفسیر کنند**.
۵. **ارزیابی کنند** که آیا یک طرح آزمایش و روش مقایسه‌ی مشخص می‌تواند از نتیجه‌گیری‌هایی که پژوهشگر می‌خواهد بگیرد پشتیبانی کند.

۳.۲.۳ مقدمه

cross-validation (هفته‌ی ۶) کلی ولی پرهزینه است: هر بخش یعنی یک برازش دوباره، و برازش دوباره‌ی مدل‌های پیچیده با multi-start ممکن است ساعت‌ها طول بکشد. **معیارهای اطلاعاتی** عملکرد خارج از نمونه را از یک برازش واحد تخمین می‌زنند؛ با افزودن یک جریمه‌ی پیچیدگی به برازش آموزش.

ولی سؤال بنیادی‌تری هست که هیچ معیاری به‌تنهایی به آن جواب نمی‌دهد: **آیا روش ما اصلاً با این طرح آزمایش می‌تواند کار کند؟** فرض کنید نتیجه بگیریم «شرکت‌کننده‌ها با یک قانون توانی با نمای زوال ۴۲.۰ فراموش می‌کنند». برای اینکه این حرف معنایی داشته باشد دو چیز باید درست باشد:

۱. اگر داده‌ها از یک مدل توانی با $d = 0.42$ آمده بودند، رویه‌ی برازش ما چیزی نزدیک به ۴۲.۰ برمی‌گرداند (**بازیابی پارامتر**).
۲. اگر داده‌ها از یک مدل نمایی آمده بودند، روش مقایسه‌ی ما می‌گفت «نمایی»، نه «توانی» (**بازیابی مدل**).

هر دو را می‌شود با شبیه‌سازی بررسی کرد، چون برای داده‌ی شبیه‌سازی‌شده حقیقت را می‌دانیم. راهنماهای امروزی مدل‌سازی محاسباتی این بررسی‌ها را ضروری می‌دانند؛ نادیده گرفتنشان مثل اجرای آزمایش بدون وارسی سالم بودن تجهیزات است. این هفته بخش «شبیه‌سازی ← برازش ← ارزیابی ← **بازیابی**» مسیر مدل‌سازی ما را کامل می‌کند.

این موضوع کجا به کار می‌رود؟

- **جدول‌های مقایسه‌ی مدل با** AIC/BIC تقریباً در هر مقاله‌ی مدل‌سازی در روان‌شناسی، علوم اعصاب، بوم‌شناسی و اقتصاد دیده می‌شوند.
- **روان‌پزشکی محاسباتی:** پیش از ادعای اینکه بیماران نرخ یادگیری پایین‌تری دارند، پژوهشگرها باید با بازیابی پارامتر نشان دهند که نرخ یادگیری در طرح آزمایش آن‌ها قابل برآورد است. داوران مقاله‌ها روزبه‌روز بیشتر این را می‌خواهند.
- **طراحی آزمایش:** شبیه‌سازی‌های بازیابی پیش از جمع‌آوری داده اجرا می‌شوند تا تعداد trialها و شرایط انتخاب شود (نسخه‌ی مدل‌سازی تحلیل توان آماری یا power analysis).
- **هر مطالعه‌ای که می‌گوید «مدل X داده را بهتر از همه توضیح می‌دهد»** باید بازیابی مدل را گزارش کند؛ وگرنه ممکن است برنده فقط سوگیری معیار مقایسه را نشان دهد.

۴.۲.۳ جزوه‌ی درس

به زبان ساده **معیارهای اطلاعاتی** (AIC و BIC) فرمول‌های سریعی‌اند که برازش هر مدل را می‌گیرند و برای هر پارامتر یک جریمه کم می‌کنند؛ پس مدلی برنده می‌شود که پارامترهای اضافه‌اش برازش را بیش از «هزینه‌شان» بهتر کنند. هدف AIC بهترین پیش‌بینی‌کننده و هدف BIC مدل درست است، و جریمه‌ی BIC بزرگ‌تر است. نیمه‌ی دوم هفته که مهم‌تر است می‌پرسد آیا روش‌های ما اصلاً کار می‌کنند. آن‌ها را روی داده‌ی ساختگی امتحان می‌کنیم که در آن حقیقت را می‌دانیم. **بازیابی پارامتر:** داده را با پارامترهای معلوم شبیه‌سازی کن، برازش کن، و بررسی کن که مقدارهای برازش‌شده نزدیک مقدارهای واقعی برگردند. **بازیابی مدل:** داده را از هر مدل نامزد شبیه‌سازی کن و بررسی کن که روش مقایسه همان مدلی را انتخاب کند که داده را تولید کرده. اگر روشی نتواند حقیقت را در داده‌ی شبیه‌سازی‌شده پیدا کند، جوابش روی داده‌ی واقعی بی‌معناست.

زمان‌بندی پیشنهادی (۶۰ دقیقه): آزمون نسبت درست‌نمایی ۸ · AIC و BIC ۲۰ · بازیابی پارامتر ۱۴ · بازیابی مدل ۱۴ · identifiability ۴.

۱. آزمون نسبت درست‌نمایی (مدل‌های nested)

مدل $\mathcal{M}_0$ در $\mathcal{M}_1$ nested است اگر $\mathcal{M}_0$ حالت خاصی از $\mathcal{M}_1$ باشد که با ثابت کردن بعضی پارامترها به دست می‌آید. مثال: مدل نمایی همان مدل نمایی با مجانب با $s = 0$ (مجانب در ۰) است. تحت فرض صفر که $\mathcal{M}_0$ درست است،

$$\Lambda = 2\big[\ell_1(\hat{\boldsymbol{\theta}}_1) - \ell_0(\hat{\boldsymbol{\theta}}_0)\big] \overset{\cdot}{\sim} \chi^2_{\Delta k},$$

که در آن Δk تفاوت تعداد پارامترهای آزاد است. Λ بزرگ یعنی پارامترهای اضافه برازش را بیشتر از آنچه شانس توضیح می‌دهد بهتر کرده‌اند.

محدودیت‌ها: فقط برای مدل‌های nested کار می‌کند (توانی در برابر نمایی را نمی‌شود این‌طور آزمون کرد)؛ آزمون فرض صفر است (می‌تواند مدل ساده‌تر را رد کند ولی هرگز از آن حمایت نمی‌کند)؛ و وقتی مقدار ثابت‌شده‌ی پارامتر روی مرز فضای پارامتر است (مثل $s = 0$) تقریبی است.

> **پیشرفته: فرض صفر روی مرز.** وقتی مقدار صفر روی مرز است (واریانس ۰، مجانب ۰، وزن آمیخته‌ی ۰)، توزیع Λ تحت فرض صفر آمیزه‌ای ۵۰:۵۰ از χ^2_0 (یک جرم نقطه‌ای در ۰) و χ^2_1 است. در این حالت استفاده از χ^2_1 محافظه‌کارانه است: مقدار p درست نصف مقدار ساده است.

۲. معیارهای اطلاعاتی

معیارهای اطلاعاتی بین برازش و پیچیدگی trade-off برقرار می‌کنند. با لگاریتم درست‌نمایی بیشینه $\hat{\ell}$، k پارامتر آزاد و N مشاهده:

$$\mathrm{AIC} = -2\hat{\ell} + 2k, \qquad \mathrm{AICc} = \mathrm{AIC} + \frac{2k(k+1)}{N-k-1}, \qquad \mathrm{BIC} = -2\hat{\ell} + k\ln N.$$

کمتر بهتر است. فقط **تفاوت‌ها** بین مدل‌هایی که روی داده‌ی یکسان برازش شده‌اند معنادارند.

	AIC (و AICc)	BIC
هدف	بهترین **پیش‌بینی** داده‌ی جدید (کمینه کردن واگرایی Kullback–Leibler مورد انتظار نسبت به حقیقت)	انتخاب مدل **واقعی** اگر میان نامزدها باشد (سازگاری)؛ تقریبی از Bayes factor
جریمه‌ی هر پارامتر	۲	$\ln N$ (از $N \geq 8$ بیشتر از ۲)
وقتی $N \to \infty$	ممکن است همچنان مدل‌های بیش از حد پیچیده را انتخاب کند	مدل واقعی را با احتمال $\to 1$ انتخاب می‌کند
تصحیح نمونه‌ی کوچک	AICc (وقتی $N/k < 40$)	—

N چیست؟ تعداد مشاهدات مستقلی که وارد درست‌نمایی می‌شوند. برای داده‌ی یادآوری دوجمله‌ای این تعداد پاسخ‌های آیتم است (اینجا $400 = 50 \times 8$)، نه تعداد خانه‌ها (۸). این انتخاب روی BIC (از راه $\ln N$) و AICc اثر دارد. آن را گزارش کنید.

وزن‌ها. با $\Delta_i = \mathrm{IC}_i - \min_j \mathrm{IC}_j$،

$$w_i = \frac{\exp(-\Delta_i/2)}{\sum_j \exp(-\Delta_j/2)}.$$

وزن‌های آکائیکه احتمال اینکه مدل i بهترین پیش‌بینی‌کننده در میان نامزدها باشد را تخمین می‌زنند. **وزن‌های** BIC احتمال‌های پسین مدل‌ها را تحت بخت‌های پیشین برابر تقریب می‌زنند (هفته‌ی ۱۰).

قواعد سرانگشتی برای Δ: ۰ تا ۲، پشتیبانی عملاً برابر؛ ۴ تا ۷، پشتیبانی به‌طور قابل توجهی کمتر؛ بیشتر از ۱۰، عملاً بدون پشتیبانی. این‌ها قرارداد هستند، نه قانون.

محدودیت مشترک AIC و BIC: هر دو پارامترها (k) را می‌شمارند، پس به تفاوت **انعطاف شکل تابعی** بین مدل‌هایی با k یکسان کورند (هفته‌ی ۶). cross-validation و Bayes factor (هفته‌ی ۱۰) این‌طور نیستند.

> **پیشرفته: جریمه‌ی AIC از کجا می‌آید.** لگاریتم درست‌نمایی بیشینه برآوردی خوش‌بینانه و سوگیر از لگاریتم درست‌نمایی مورد انتظار داده‌ی جدید است، چون همان داده برای انتخاب $\hat{\boldsymbol{\theta}}$ به کار رفته است. آکائیکه نشان داد که برای مدل‌های منظم و N بزرگ، این سوگیری تقریباً k است. تصحیح $\mathrm{AIC} = -2(\hat{\ell} - k)$ را می‌دهد. به همین دلیل است که AIC و LOO-CV به‌طور مجانبی با هم توافق دارند.

خواندن ریاضی

- $-2\hat{\ell}$ بخش **عدم برازش** است (دو برابر NLL کمینه‌شده)؛ $2k$ یا $k \ln N$ بخش **جریمه** است. AIC/BIC کمتر بهتر است.
- هر پارامتر اضافه باید $-2\hat{\ell}$ را بیش از ۲ (برای AIC یا بیش از $\ln N$ (برای BIC کم کند تا ارزشش را داشته باشد. با $N = 400$، $\ln N \approx 6$: یک پارامتر باید NLL را حدود ۳ واحد بهتر کند تا از BIC بگذرد، ولی برای AIC فقط ۱ واحد.
- **وزن‌ها:** $\exp(-\Delta_i/2)$ تفاوت AIC را به درست‌نمایی نسبی تبدیل می‌کند. $\Delta = 2$ می‌دهد $e^{-1} = 0.37$، پس مدلی که ۲ واحد AIC بدتر است حدود یک‌سوم پشتیبانی دارد. تقسیم بر جمع، وزن‌ها را طوری می‌کند که جمعشان ۱ شود.
- **عددهای مثال حل‌شده:** AIC مدل توانی $2(19.830) + 2(2) = 43.66$؛ مدل نمایی با مجانب $+ 2(18.919) = 2(3) = 43.84$. مدل مجانب بهتر برازش می‌شود (NLL کمتر) ولی هزینه‌ی یک پارامتر بیشتر را می‌دهد، پس دو مدل تقریباً مساوی می‌شوند.

۳. بازیابی پارامتر

سؤال: با این طرح آزمایش، آیا رویه‌ی برازش پارامترهایی را که داده را تولید کرده‌اند برمی‌گرداند؟

رویه: ۱. مجموعه‌ای از مقادیر واقعی پارامتر $\boldsymbol{\theta}^*$ انتخاب کنید که دامنه‌ی معقول را پوشش دهد (یک شبکه، یا نمونه‌های تصادفی از دامنه‌های معقول، مثلاً حول برآوردهای داده‌ی واقعی). ۲. برای هر $\boldsymbol{\theta}^*$ یک مجموعه‌داده با **دقیقاً همان طرح واقعی** (همان شرایط، همان تعداد trial) شبیه‌سازی کنید. ۳. مدل را با **دقیقاً همان رویه‌ی برازش واقعی** (همان بهینه‌ساز، شروع‌ها، کران‌ها) برازش کنید. ۴. $\hat{\boldsymbol{\theta}}$ را با $\boldsymbol{\theta}^*$ مقایسه کنید: نمودار پراکنش واقعی در برابر بازیابی‌شده؛ همبستگی؛ سوگیری (میانگین $\hat{\theta} - \theta^*$)؛ RMSE. ۵. پارامترهای بازیابی‌شده را **در برابر هم** هم رسم کنید. همبستگی قوی بین مثلاً $\hat{\lambda}$ و $\hat{s}$ که در مقادیر واقعی نیست، یک trade-off را آشکار می‌کند.

خواندن نتایج: نقاط روی خط همانی یعنی بازیابی خوب؛ ابری موازی با محور افقی یعنی پارامتر با این طرح قابل بازیابی نیست؛ منحنی‌ای که در دو انتها کج می‌شود یعنی سوگیری نزدیک کران‌ها. اگر بازیابی شکست بخورد، آن پارامتر را تفسیر نکنید. طرح آزمایش را عوض کنید (trial بیشتر، شرایط دیگر) یا مدل را ساده کنید.

۴. بازیابی مدل

سؤال: اگر مدل $\mathcal{M}_a$ داده را تولید کرده باشد، آیا روش مقایسه‌ی ما $\mathcal{M}_a$ را انتخاب می‌کند؟

رویه: ۱. برای هر مدل نامزد $\mathcal{M}_a$: مجموعه‌داده‌های زیادی با طرح واقعی و با پارامترهایی از دامنه‌های معقول شبیه‌سازی کنید. ۲. **همه‌ی** مدل‌های نامزد را روی هر مجموعه‌داده برازش کنید. ۳. با معیار انتخاب‌شده (AIC، BIC، CV، . . .) یک برنده انتخاب کنید. ۴. confusion matrix $P(\text{selected} = b \mid \text{generated} = a)$ را جدول کنید.

یک روش خوب ماتریسی با درایه‌های قطری بزرگ می‌دهد. جرم خارج از قطر **تقلید مدل** (model mimicry) را نشان می‌دهد: یک مدل می‌تواند داده‌هایی بسازد که شبیه داده‌های مدل دیگر است.

چیزی که در تفسیر داده‌ی واقعی واقعاً لازم داریم برعکس است: با فرض اینکه مدل b برنده شد، چقدر محتمل است که b داده را تولید کرده باشد؟ این inversion matrix $P(\text{generated} = a \mid \text{selected} = b)$ است که با نرمال کردن هر ستون شمارش‌های درهم‌ریختگی به دست می‌آید (با فرض فراوانی پیشین برابر برای مدل‌های تولیدکننده).

> **نکته:** بازیابی مدل **سوگیری‌های معیارها** را هم آشکار می‌کند: BIC در N کوچک به مدل‌های ساده‌تر و AIC به مدل‌های پیچیده‌تر تمایل دارد. «بهترین» معیار آن است که مدل‌های نامزد شما را با طرح آزمایش شما بهتر بازیابی کند، و این دقیقاً همان چیزی است که این مطالعه اندازه می‌گیرد.

خواندن ریاضی

- confusion matrix $P(\text{selected} = b \mid \text{generated} = a)$: سطرها مدل‌های واقعی (مولد) و ستون‌ها مدل‌های انتخاب‌شده‌اند. جمع هر سطر ۱ است. هر سطر را این‌طور بخوانید: «وقتی حقیقت a است، چند بار هر مدل را انتخاب می‌کنیم؟»
- inversion matrix $P(\text{generated} = a \mid \text{selected} = b)$: همان شمارش‌ها، ولی هر ستون به ۱ نرمال شده. هر ستون را این‌طور بخوانید: «وقتی b را انتخاب کردیم، چند بار واقعاً b حقیقت بود؟» این همان سؤالی است که برای داده‌ی واقعی اهمیت دارد، جایی که فقط برنده را می‌بینیم.
- **مثال کوچک.** از هر کدام از دو مدل ۱۰۰ مجموعه داده. از A: ۹۰ بار A و ۱۰ بار B انتخاب می‌شود. از B: ۴۰ بار A و ۶۰ بار B. سطر A در confusion matrix برابر (۰.۹۰، ۰.۱۰) است. ولی از ۱۳۰ مجموعه داده‌ای که A را انتخاب کردند، فقط ۹۰ تا از A آمده بودند: $P(\text{A true} \mid \text{A selected}) = 90/130 = 0.69$.

۵. identifiability

- non-identifiable **ساختاری:** مقادیر مختلف پارامتر برای هر داده‌ای دقیقاً پیش‌بینی‌های یکسان می‌دهند. مثال‌ها: جابه‌جایی برچسب در مدل دوردی (هفته‌ی ۳)، یا مکان و مقیاس در SDT (هفته‌ی ۲). راه‌حل یک قید یا reparameterization است.
- non-identifiable **عملی:** پارامترها در اصل identifiable هستند ولی با داده‌های موجود نه. بازیابی ضعیف است و برآوردها trade-off دارند. راه‌حل طرح آزمایش بهتر یا مدل ساده‌تر است.

بازیابی پارامتر آزمون عملی identifiability است.

برای یک مهندس

- AIC و BIC همان معیارهای انتخاب مرتبه‌ی مدل‌اند که شاید از مدل‌سازی AR/ARMA بشناسید؛ BIC اساساً همان معیار MDL ریسانن است. LRT برای مدل‌های nested دوباره همان GLRT است.
- **بازیابی پارامتر** یعنی آزمودن یک تخمین‌گر روی سیگنال‌های مصنوعی با حقیقت معلوم، با همان SNR و طول داده‌ی واقعی، پیش از اعتماد به آن روی داده‌ی اندازه‌گیری‌شده. مهندس‌ها این کار را مرتب انجام می‌دهند؛ در روان‌شناسی اغلب حذف می‌شود، و به همین دلیل این درس روی آن اصرار دارد.
- confusion matrix همان ماتریس احتمال انتقال یک کانال گسسته است: ورودی = مدل مولد، خروجی = مدل انتخاب‌شده. inversion matrix ماتریس احتمال‌های پسین $P(\text{input} \mid \text{output})$ است، یعنی چیزی که یک دیکدر MAP لازم دارد، با فرض احتمال‌های پیشین برابر برای ورودی‌ها.
- non-identifiability **ساختاری** مثل یک حالت مشاهده‌ناپذیر یا ماتریس سیستم با رتبه‌ی ناقص است: هیچ مقداری از داده کمک نمی‌کند. non-identifiability **عملی** یک مسئله‌ی بدحالت است: در اصل قابل شناسایی است ولی برای داده‌ی موجود نویز خیلی زیاد است.

برای مدرس

- **بازیابی را «آزمودن ابزار» معرفی کنید.** هیچ‌کس به دماسنجی که هیچ‌وقت در آبی با دمای معلوم امتحان نشده اعتماد نمی‌کند. بازیابی همان آزمون برای یک مدل است.
- **پیش از هر نظریه‌ای یک نمودار پراکندگی مقدار واقعی در برابر بازیابی‌شده نشان دهید** (بخش C lab): بازیابی خوب (نقطه‌ها روی قطر) کنار بازیابی بد (یک ابر صاف). تصویر خودش توضیح می‌دهد.
- confusion و inversion **را با مثال کوچک ۲×۲ بالا درس دهید؛** دانشجوها در امتحان بیش از هر چیز دیگری در این هفته این دو را با هم قاطی می‌کنند. تشبیه تست پزشکی کمک می‌کند: sensitivity یک تست با احتمال بیمار بودن کسی که تستش مثبت شده یکی نیست.
- **سؤال‌های رایج.**
  - «*AIC* یا *BIC*؟» به هدف بستگی دارد (پیش‌بینی در برابر پیدا کردن مدل درست) و در عمل به اینکه کدام در طرح آزمایش شما مدل‌ها را بهتر بازیابی می‌کند.
  - «چند مجموعه داده‌ی شبیه‌سازی‌شده؟» برای دیدن الگو ۵۰ تا ۱۰۰ برای هر حالت کافی است؛ برای انتشار بیشتر.
  - «بازیابی شکست خورد، حالا چه؟» آن پارامتر را تفسیر نکنید. طرح آزمایش را تغییر دهید یا مدل را ساده‌تر کنید.

۵.۲.۳ مثال حل‌شده

چهار مدل فراموشی که با MLE روی داده‌های هفته‌ی ۲ برازش شده‌اند NLL)های آموزش از هفته‌ی ۶)، با $N = 400$ پاسخ آیتم:

مدل	k	NLL	AIC $= 2\,\mathrm{NLL} + 2k$	BIC $= 2\,\mathrm{NLL} + k \ln 400$
exp	۲	۸۱۲.۲۹	۶۲.۶۳	۶۱.۷۱
pow	۲	۸۳۰.۱۹	**۶۶.۴۳**	**۶۴.۵۱**
expasym	۳	۹۱۹.۱۸	۸۴.۴۳	۸۱.۵۵
two	۴	۹۱۹.۱۸	۸۴.۴۵	۸۰.۶۱

قدم ۱: AIC برای مدل توانی. $2 \times 19.830 + 2 \times 2 = 43.66$.

قدم ۲: BIC برای مدل توانی. $\ln 400 = 5.991$، پس $2 \times 19.830 + 2 \times 5.991 = 51.64$.

قدم ۳: وزن‌های آکائیکه. تفاوت‌ها با بهترین AIC: $\Delta = (19.96, 0, 0.18, 2.18)$. پس $e^{-\Delta/2} = (0.00005, 1, 0.914, 0.336)$ که جمعشان ۲.۲۵۰ است، بنابراین

$$w^{\mathrm{AIC}} = (0.000,\ 0.444,\ 0.406,\ 0.149).$$

وزن‌های BIC به همین روش: $(0.000,\ 0.884,\ 0.110,\ 0.005)$.

قدم ۴: آزمون نسبت درست‌نمایی، exp nested در expasym: $\Lambda = 2(29.812 - 18.919) = 21.79$ با ۱ درجه‌ی آزادی، $p \approx 3 \times 10^{-6}$. افزودن مجانب مدل نمایی را به‌طور معناداری بهتر می‌کند.

تفسیر. هر دو معیار مدل نمایی خالص را قاطعانه رد می‌کنند. AIC نمی‌تواند مدل‌های توانی و مجانبی را از هم جدا کند (وزن‌های ۴۴.۰ در برابر ۴۱.۰): از نظر پیش‌بینی تقریباً به یک اندازه خوب‌اند، که با نتایج CV هفته‌ی ۶ سازگار است. جریمه‌ی بزرگ‌تر BIC مدل توانی دوپارامتری را ترجیح می‌دهد (۸۸.۰). پارامتر اضافه‌ی مدل دوردی هیچ چیزی نمی‌خرد: NLL آن با expasym یکسان است، پس جریمه را بی‌دلیل می‌پردازد. اینکه آیا باید به این ترجیح‌ها با این طرح آزمایش اعتماد کنیم سؤالی برای بازیابی مدل است (بخش D lab).

۶.۲.۳ lab (۲ ساعت)

اهداف

۱. اجرای آزمون نسبت درست‌نمایی و محاسبه‌ی AIC، AICc، BIC و وزن‌ها برای مدل‌های فراموشی.
۲. اجرای یک مطالعه‌ی بازیابی پارامتر برای مدل‌های توانی و نمایی با مجانب و بررسی trade-offها.
۳. اجرای یک مطالعه‌ی بازیابی مدل برای سه مدل با AIC و BIC؛ ساختن ماتریس‌های درهم‌ریختگی و معکوس.
۴. **تفسیر:** با این طرح آزمایش، از داده‌های هفته‌ی ۲ چه چیزی را می‌شود و چه چیزی را نمی‌شود نتیجه گرفت؟

زمان‌بندی: بخش A ۱۵ دقیقه · بخش B ۱۵ دقیقه · بخش C ۳۵ دقیقه · بخش D ۴۰ دقیقه · بخش E ۱۵ دقیقه.

آماده‌سازی

Code · کد: code/week07.py، cell ۱ · سلول ۱

بخش A: آزمون نسبت درست‌نمایی (۱۵ دقیقه)

Code · کد: code/week07.py، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
NLL exp = 29.812, NLL expasym = 18.919
LR statistic = 21.79, df = 1, naive p = 3.05e-06, boundary-corrected p =
↪  1.52e-06
```

سؤال: چرا نمی‌توانید از همین آزمون برای مقایسه‌ی مدل‌های توانی و نمایی استفاده کنید؟

بخش B: معیارهای اطلاعاتی و وزن‌ها (۱۵ دقیقه)

Code · کد: code/week07.py، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
         k     NLL     AIC    AICc     BIC  w_AIC  w_AICc  w_BIC
model
exp      2  29.812  63.625  63.655  71.608  0.000   0.000  0.000
pow      2  19.830  43.661  43.691  51.644  0.444   0.449  0.884
expasym  3  18.919  43.837  43.898  55.812  0.406   0.405  0.110
two      4  18.919  45.837  45.939  61.803  0.150   0.146  0.006
```

بررسی حساسیت: BIC را با $N = 8$ (تعداد خانه‌ها) به‌جای ۴۰۰ دوباره حساب کنید. آیا رتبه‌بندی عوض می‌شود؟ کدام انتخاب N اینجا قابل دفاع است و چرا؟

بخش C: بازیابی پارامتر (۳۵ دقیقه)

Code · کد: code/week07.py، cell ۴ · سلول ۴

خروجی مورد انتظار (حدود ۱ دقیقه):

```
pow:
   r(true, rec)   bias   RMSE
A         0.888  0.005  0.055
d         0.965  0.003  0.070

expasym:
     r(true, rec)   bias   RMSE
A           0.802  0.008  0.077
lam         0.799  0.034  0.230
s           0.918 -0.008  0.060

expasym: corr(true lam, true s) = -0.08;  corr(recovered lam, recovered
 ↪  s) = 0.03
```

تفسیر: ۱. با این طرح آزمایش، کدام پارامترها خوب بازیابی می‌شوند؟ تفسیر کدام را با تردید انجام می‌دهید؟ ۲. نرخ زوال λ در expasym با فاصله‌ی زیاد بیشترین RMSE را دارد (۰۲۳.۰ روی دامنه‌ی ۰۵.۰ تا ۱). به نمودارش نگاه کنید: بازیابی برای کدام مقادیر واقعی شکست می‌خورد و چرا؟ (راهنمایی: اگر زوال خیلی سریع باشد، بیشترِ افت پیش از دومین فاصله‌ی آزمون اتفاق می‌افتد؛ پس داده‌ها چه شکلی پیدا می‌کنند؟) اینجا λ و s بازیابی‌شده همبستگی ندارند (r = ۰۳.۰)، پس این عدم دقت است نه trade-off. این را با trade-off آشکار A–d مدل توانی که در هفته‌ی ۵ دیدیم مقایسه کنید. ۳. چه تغییری در طرح آزمایش بازیابی λ و s را بهتر می‌کند؟ یک ایده را در تمرین ۳ آزمون کنید.

بخش D: بازیابی مدل (۴۰ دقیقه)

Code · کد: `code/week07.py`، cell ۵ · سلول ۵

خروجی مورد انتظار (حدود ۱ تا ۲ دقیقه):

```
AIC confusion matrix (rows = generating model, columns = selected model):
          exp   pow  expasym
exp      0.91  0.00     0.09
pow      0.03  0.82     0.15
expasym  0.06  0.25     0.69
AIC inversion matrix (rows = generating model, columns = selected model):
          exp   pow  expasym
exp      0.91  0.00     0.10
pow      0.03  0.77     0.16
expasym  0.06  0.23     0.74

BIC confusion matrix (rows = generating model, columns = selected model):
          exp   pow  expasym
exp      0.99  0.01     0.00
pow      0.05  0.94     0.01
expasym  0.09  0.58     0.33
BIC inversion matrix (rows = generating model, columns = selected model):
          exp   pow  expasym
exp      0.88  0.01     0.00
pow      0.04  0.61     0.03
expasym  0.08  0.38     0.97
```

تفسیر: ۱. کدام مدل بیشتر با کدام اشتباه گرفته می‌شود؟ (با AIC، ٪۲۵ مجموعه‌داده‌های expasym برچسب توانی می‌گیرند؛ با BIC، ٪۵۸.) این تقلید را بر حسب شکل منحنی‌ها توضیح دهید. ۲. AIC و BIC را مقایسه کنید. کدام مدل‌های ساده‌تر را بهتر بازیابی می‌کند و کدام مدل پیچیده‌تر را؟ ۳. در بخش B، BIC برای داده‌ی واقعی مدل توانی را انتخاب کرد. با استفاده از BIC inversion matrix، چقدر باید مطمئن باشیم که داده‌ها را یک مدل توانی تولید کرده است؟ (فقط ٪۶۱ از حکم‌های «توانی» BIC از داده‌های تولیدشده با مدل توانی آمده‌اند؛ ٪۳۸ از (.expasym

بخش E: نتیجه‌گیری درباره‌ی داده‌های هفته‌ی ۲ (۱۵ دقیقه)

یک پاراگراف (۶ تا ۱۰ جمله) بنویسید که یک داور بپذیرد و خلاصه کند داده‌های هفته‌ی ۲ درباره‌ی شکل فراموشی چه می‌گویند. از بخش‌های A تا D و نتایج CV هفته‌ی ۶ استفاده کنید و بگویید با این طرح آزمایش چه چیزی را نمی‌شود نتیجه گرفت.

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. وزن‌های AIC و BIC مثال حل‌شده را با دست (ماشین‌حساب) حساب کنید و با بخش B مقایسه کنید.

تمرین ۲ ⋆. بخش B را با AICc تکرار کنید. برای چه Nای AICc و AIC برای مدل دوردی به‌طور قابل توجهی فرق می‌کنند؟

تمرین ۳ ⋆⋆ **(طراحی برای بازیابی).** بازیابی expasym بخش C را با فاصله‌های گسترش‌یافته به $\{0.25, 1, 2, 4, 7, 14, 30, 60, 90\}$ روز، و جداگانه با $n = 200$ آیتم، دوباره اجرا کنید. کدام تغییر بیشتر به بازیابی λ و s کمک می‌کند؟

تمرین ۴ ⋆⋆ (CV **در بازیابی مدل).** در بخش D، AIC/BIC را با CV پنج‌بخشی (از هفته‌ی ۶) برای ۳۰ شبیه‌سازی از هر مدل جایگزین کنید. آیا CV در بازیابی مدل‌ها از AIC بهتر است یا بدتر؟ آیا به زمان محاسبه‌اش می‌ارزد؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: بازیابی در** SDT**).** برای آزمایش پاداش هفته‌ی ۴ (سه شرط، ۸۰ + ۸۰ trial در هر شرط)، یک بازیابی مدل برای «d' مشترک» در برابر «d' جداگانه» با آزمون نسبت درست‌نمایی در $\alpha = .05$ و با BIC اجرا کنید. هر روش چند بار به‌اشتباه ادعا می‌کند که پاداش حساسیت را تغییر می‌دهد؟ برای اینکه یک تفاوت واقعی حساسیت به اندازه‌ی ۰.۳ را در ٪۸۰ شبیه‌سازی‌ها تشخیص دهید، در هر شرط چند trial لازم است؟

lab check-off

نشان دهید: (۱) جدول معیارهای اطلاعاتی با وزن‌ها (بخش B)، (۲) نمودارهای پراکنش بازیابی با یک جمله درباره‌ی اینکه کدام پارامتر بدتر بازیابی می‌شود و چرا، (۳) ماتریس‌های درهم‌ریختگی AIC و BIC، و (۴) پاراگراف بخش E.

۷.۲.۳ ارتباط با هوش مصنوعی و LLMها

مقایسه‌ی منحنی‌های یادگیری یک مدل هوش مصنوعی. LLMها می‌توانند یک تکلیف تازه را از چند مثال در prompt یاد بگیرند («یادگیری درون‌بافتی» یا in-context learning). اینکه خطا با تعداد مثال‌ها k چطور کم می‌شود یک منحنی یادگیری است، و سؤال «نمایی یا توانی؟» همان سؤال lab این هفته (و منحنی‌های فراموشی هفته‌ی ۲) است. معیارهای اطلاعاتی، بازیابی مدل و identifiability بدون تغییر به کار می‌آیند. طرح هم به همان اندازه مهم است: با مقادیر کم k و آیتم‌های آزمون کم، ممکن است دو منحنی اصلاً قابل تمیز نباشند.

Code · کد: `code/week07.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
{'exponential': 41.6, 'power': 40.4} Akaike weights: [0.362 0.638]
```

داده از یک قانون توانی تولید شده، ولی شواهد ضعیف است (وزن‌های ۶۴.۰ در برابر ۳۶.۰).

امتحانش کنید (بدون نیاز به API). ⋆ - در همین طرح یک بازیابی مدل (هفته‌ی ۷، بخش D) اجرا کنید: ۵۰ مجموعه داده از هر منحنی. confusion matrix را بسازید. - ⋆⋆ طرح را عوض کنید: مقادیر بیشتری برای k (تا ۱۲۸) یا ۲۰۰ آیتم آزمون برای هر k. کدام تغییر بازیابی مدل را بیشتر بهتر می‌کند؟ - ⋆⋆ بحث: مقاله‌ای از یک منحنی برازش‌شده نتیجه می‌گیرد که «یادگیری درون‌بافتی، مثل تمرین در انسان، از قانون توانی پیروی می‌کند». پیش از پذیرفتن این مقایسه با انسان، چه چیزی باید ببینید؟

۸.۲.۳ اشتباهات رایج و برداشت‌های نادرست

۱. **تفسیر یک مقدار AIC به‌تنهایی.** فقط تفاوت بین مدل‌هایی که روی داده‌ی یکسان برازش شده‌اند معنا دارد.
۲. **استفاده از LRT برای مدل‌های non-nested**، یا خواندن یک LRT غیرمعنادار به‌عنوان شاهدی به نفع مدل ساده‌تر.
۳. **فکر کردن اینکه BIC همان AIC» بیزی» با همان هدف است.** BIC به دنبال شناسایی مدل تولیدکننده‌ی داده است؛ AIC به دنبال پیش‌بینی. می‌توانند به دلایل موجه با هم مخالف باشند.
۴. **نامشخص** N. همیشه گزارش کنید چه چیزی به‌عنوان یک مشاهده شمرده شده؛ BIC و AICc به آن بستگی دارند.
۵. **نادیده گرفتن بازیابی.** پارامتری که با طرح آزمایش شما قابل بازیابی نیست نباید تفسیر شود، هر قدر هم برازش خوب باشد.
۶. **اجرای بازیابی با طرح یا رویه‌ی برازشی متفاوت** از تحلیل واقعی. نتایج بازیابی وابسته به طرح آزمایش‌اند.
۷. **خواندن confusion matrix به جای inversion matrix.** «داده‌های مدل A در ۹۰٪ موارد به‌عنوان A بازیابی می‌شوند» با «وقتی A برنده می‌شود در ۹۰٪ موارد مدل واقعی است» یکی نیست.
۸. **انتخاب دامنه‌های پارامتر برای بازیابی که از مقادیر معقول پهن‌تر یا باریک‌ترند.** دامنه‌ی خیلی پهن همبستگی‌ها را باد می‌کند؛ دامنه‌ی خیلی باریک مشکلات را پنهان می‌کند.

۹.۲.۳ خودآزمایی

۱. فرمول‌های AIC و BIC را بنویسید. برای چه Nای BIC هر پارامتر را بیشتر از AIC جریمه می‌کند؟ **پاسخ** $\mathrm{AIC} = -2\hat{\ell} + 2k$؛ $\mathrm{BIC} = -2\hat{\ell} + k \ln N$. جریمه‌ی BIC وقتی از AIC بیشتر است که $\ln N > 2$، یعنی $N > e^2 \approx 7.4$، پس برای $N \geq 8$.

۲. مدل A دارای AIC = ۴.۲۱۰ و مدل B دارای AIC = ۹.۲۱۲ است. وزن‌های آکائیکه را حساب و تفسیر کنید. **پاسخ** $\Delta = (0, 2.5)$، پس $e^{-\Delta/2} = (1, 0.287)$ و $w = (0.777, 0.223)$. A حدود ۵.۳ به ۱ به‌عنوان پیش‌بینی‌کننده‌ی بهتر ترجیح دارد، ولی B هنوز پشتیبانی قابل توجهی دارد.

۳. چرا آزمون نسبت درست‌نمایی می‌تواند نمایی و نمایی با مجانب را مقایسه کند ولی نمایی و توانی را نه؟ **پاسخ** نمایی حالت خاصی از مدل مجانبی است ($s = 0$)، پس مدل‌ها nested هستند و $2\Delta\ell$ تحت فرض صفر توزیع χ^2 معلومی دارد. نمایی و توانی nested نیستند: هیچ‌کدام حالت خاص دیگری نیست.

۴. مراحل یک مطالعه‌ی بازیابی پارامتر را شرح دهید. **پاسخ** مقادیر واقعی معقول برای پارامترها انتخاب کنید؛ با طرح واقعی داده شبیه‌سازی کنید؛ با رویه‌ی برازش واقعی برازش کنید؛ مقادیر بازیابی‌شده را با واقعی مقایسه کنید (نمودار پراکنش، همبستگی، سوگیری، RMSE)؛ همبستگی بین پارامترهای بازیابی‌شده را برای یافتن trade-off بررسی کنید.

۵. در یک مطالعه‌ی بازیابی، λ و s بازیابی‌شده با $r = -0.8$ همبسته‌اند، با اینکه مقادیر واقعی مستقل کشیده شده بودند. این یعنی چه؟ **پاسخ** یک trade-off: با این طرح آزمایش، ترکیب‌های مختلف نرخ زوال و مجانب پیش‌بینی‌های تقریباً یکسانی می‌دهند، پس خطا در یکی با دیگری جبران می‌شود. مقادیر تکی λ و s نباید جداگانه تفسیر شوند. طرح آزمایش بهتر یا reparameterization لازم است.

۶. تفاوت confusion matrix و inversion matrix را در بازیابی مدل توضیح دهید. **پاسخ** درهم‌ریختگی: $P(\text{selected} \mid \text{generated})$ که سطرهایش جمع ۱ دارند و رفتار روش را برای هر مدل واقعی توصیف می‌کند. معکوس: $P(\text{generated} \mid \text{selected})$ که ستون‌هایش جمع ۱ دارند (با فرض پیشین برابر برای مدل‌های تولیدکننده) و به ما می‌گوید هنگام تحلیل داده‌ی واقعی چقدر به یک برنده‌ی مشخص اعتماد کنیم.

۷. یک بازیابی مدل نشان می‌دهد وقتی مدل دوپارامتری داده را تولید کرده، AIC در ۴۰٪ موارد مدل سه‌پارامتری را انتخاب می‌کند. چه می‌کنید؟ **پاسخ** با این طرح آزمایش، به برد AIC برای مدل پیچیده با احتیاط نگاه کنید: بازیابی BIC یا CV را بررسی کنید که ممکن است محافظه‌کارتر باشند، طرح آزمایش را بهتر کنید (trial بیشتر، شرایط آگاهی‌بخش‌تر)، و نتایج بازیابی را کنار مقایسه‌ی داده‌ی واقعی گزارش کنید.

۱۰.۲.۳ تکلیف

ادامه‌ی A3 (موعد ابتدای درس هفته‌ی ۹)

کارهای ۴ (معیارهای اطلاعاتی) و ۵ (بازیابی پارامتر و مدل) A3 از مطالب این هفته استفاده می‌کنند. شرح کامل در هفته‌ی ۶ است. کد `parameter_recovery` امروز و حلقه‌ی بازیابی مدل را دوباره به کار ببرید: طوری طراحی شده‌اند که مستقیماً قابل تطبیق باشند.

پروژه‌ی پایانی: تشکیل گروه‌ها و انتشار راهنمای پیشنهاد

- **گروه‌ها:** ۱ یا ۲ نفر. تا پایان این هفته گروهتان را نزد دستیار آموزشی ثبت کنید.
- **کار:** یک مدل شناختی انتخاب کنید و کل مسیر مدل‌سازی را روی یک مجموعه‌داده (شبیه‌سازی‌شده، باز، یا داده‌ی خودتان) اجرا کنید: برازش، ارزیابی (دست‌کم یک مقایسه با یک مدل جایگزین)، بازیابی (دست‌کم یک تحلیل بازیابی پارامتر)، تفسیر. **گروه‌های دونفره** یک تحلیل بیزی/MCMC یا سلسله‌مراتبی و یک بیانیه‌ی سهم فردی هم اضافه می‌کنند.
- **پیشنهاد پروژه (موعد ابتدای درس هفته‌ی ۹، حداکثر ۲ صفحه):** سؤال پژوهش، مدل(ها) با معادلات، منبع داده و طرح آزمایش، تحلیل‌های مقایسه و بازیابی برنامه‌ریزی‌شده، و زمان‌بندی. شرح کامل پروژه و روبریک جداگانه توزیع می‌شود (`project_brief.md`).
- **مطمئن نیستید چه چیزی را مدل کنید؟** موضوعات هفته‌های ۱۴–۱۵ (دسته‌بندی exemplar، drift-diffusion، یادگیری تقویتی) همه پروژه‌های خوبی هستند، همین‌طور گسترش مدل‌های فراموشی و SDT این درس.

۱۱.۲.۳ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۱۰.** مقایسه‌ی مدل‌ها: آزمون نسبت درست‌نمایی، AIC، BIC و وزن‌هایشان؛ فرض‌ها و محدودیت‌هایشان. (منبع اصلی.)
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۷** (مقدمه). اینکه رویکرد بیزی به مقایسه‌ی مدل‌ها چه ارتباطی با روش‌های این هفته دارد؛ آمادگی برای هفته‌ی ۱۰.
- اختیاری، خارج از فهرست درس: Collins, A. G. E. & Wilson, R. C., (۲۰۱۹). Ten simple rules for the computational modeling of behavioral data. *eLife*, ۸, e49547. راهنمایی عملی که بازیابی پارامتر و مدل را رویه‌ی استاندارد می‌داند.

پیش‌نمایش هفته‌ی ۸: میان‌ترم. درس یک مرور یکپارچه است که در آن کل مسیر (شبیه‌سازی، برازش، ارزیابی، بازیابی، تفسیر) را روی یک مجموعه‌داده‌ی جدید اجرا می‌کنیم؛ زمان lab به آزمون میان‌ترم اختصاص دارد.

۳.۳ هفته‌ی ۸: مرور میان‌ترم: کل مسیر مدل‌سازی در یک مطالعه‌ی موردی

مرور فصل‌های ۱ تا ۳ · درس ۱ ساعت (مطالعه‌ی موردی یکپارچه) · زمان lab: **آزمون میان‌ترم** (۹۰ دقیقه) + مشاوره‌ی پروژه (۳۰ دقیقه)

۱.۳.۳ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
formalize / formal model	مدل فرمال / فرمال کردن	نوشتن نظریه به شکل معادله یا الگوریتم
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
criterion (c)	ملاک	آستانه‌ی تصمیم؛ نشان‌دهنده‌ی سوگیری پاسخ
least squares	کمترین مربعات	روش برازش با کمینه کردن مجموع مربع خطاها
cross-validation (CV)	اعتبارسنجی متقابل (cross-validation)	برازش روی بخشی از داده و آزمون روی بخش کنارگذاشته
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
RMSD / SSE	مجموع مربعات خطا / ریشه‌ی میانگین مربع انحراف	معیارهای فاصله‌ی داده و پیش‌بینی
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
noise	نویز	تغییرات تصادفی در شواهد یا در داده
deviance (G^2)	انحراف (deviance)	معیار عدم برازش نسبت به مدل اشباع‌شده
BIC / AIC	معیار اطلاعاتی آکائیکه / بیزی	برازش به‌علاوه‌ی جریمه برای تعداد پارامتر
research design	طرح آزمایش	شرایط، تعداد کوشش‌ها و نمونه‌ها
confusion matrix	ماتریس درهم‌ریختگی (confusion matrix)	P(مدل انتخاب‌شده
hit	اصابت (hit)	پاسخ «بله» وقتی علامت وجود دارد
response time (RT)	زمان واکنش	فاصله‌ی ارائه‌ی محرک تا پاسخ
signal detection theory (SDT)	نظریه‌ی تشخیص علامت	مدلی که حساسیت را از سوگیری پاسخ جدا می‌کند
evidence	شواهد	اطلاعاتی که برای تصمیم جمع می‌شود
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
test data / training	داده‌ی آموزش / آزمون	داده‌ی برازش / داده‌ی کنارگذاشته برای سنجش

۲.۳.۳ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. کل مسیر مدل‌سازی (فرمال‌سازی ← شبیه‌سازی ← برازش ← ارزیابی ← بازیابی ← تفسیر) را روی یک مسئله‌ی جدید بدون راهنمایی قدم‌به‌قدم **اجرا کنند**.
۲. درست‌نمایی، روش برازش و روش ارزیابی مناسب برای یک مجموعه‌داده را **انتخاب کنند** و هر انتخاب را **توجیه کنند**.
۳. مجموعه‌ای از برازش‌های مدل‌های رقیب، معیارهای اطلاعاتی و نتایج بازیابی را **تفسیر کنند** و یک نتیجه‌گیری قابل دفاع که محدودیت‌هایش را می‌گوید **بنویسند**.
۴. فرمول‌های کلیدی هفته‌های ۱ تا ۷ (برگه‌ی فرمول میان‌ترم) را **به خاطر بیاورند** و **به کار ببرند**.

۳.۳.۳ مقدمه

در هفت هفته یک جعبه‌ابزار را تکه‌تکه ساختیم: مدل‌های فرمال (هفته‌های ۱–۲)، کمترین مربعات و بهینه‌سازی (هفته‌ی ۳)، بیشینه درست‌نمایی (هفته‌ی ۴)، عدم قطعیت و چند شرکت‌کننده (هفته‌ی ۵)، cross-validation (هفته‌ی ۶)، معیارهای اطلاعاتی و بازیابی (هفته‌ی ۷). هر lab یکی دو تکه را تمرین کرد. پژوهش واقعی همه‌ی آن‌ها را هم‌زمان، به ترتیب درست و با قضاوت درباره‌ی اینکه چه چیزی مهم است، لازم دارد.

درس امروز کل مسیر را روی یک مسئله‌ی **جدید** اجرا می‌کند: آیا مطالعه‌ی بیشتر یک کلمه آن را به‌یادماندنی‌تر می‌کند (حساسیت بیشتر)، و اگر بله، حساسیت با تکرارها چطور رشد می‌کند؟ این مطالعه‌ی موردی بهترین آمادگی برای میان‌ترم هم هست که از شما می‌خواهد همین نوع تصمیم‌ها را بگیرید و توجیه کنید.

۴.۳.۳ جزوه‌ی درس

به زبان ساده این هفته همه‌ی تکه‌های نیمه‌ی اول درس را روی یک سؤال جدید کنار هم می‌گذارد: آیا مطالعه‌ی بیشتر یک کلمه، بازشناسی بعدی آن را آسان‌تر می‌کند؟ نظریه را به شکل یک مدل SDT می‌نویسیم که در آن حساسیت d' به تعداد تکرارها بستگی دارد. سه نسخه برای این وابستگی پیشنهاد می‌کنیم (بدون اثر، افزایش هموار، هر الگویی)، هر سه را با بیشینه‌ی درست‌نمایی برازش می‌کنیم، بررسی می‌کنیم که آیا هرکدام عدم برازش دارد (G^2)، آن‌ها را مقایسه می‌کنیم (LRT، AIC، BIC)، بررسی می‌کنیم که روش در این طرح آزمایش کار می‌کند (بازیابی)، و در پایان مدل برنده را به زبان ساده‌ی روان‌شناختی تفسیر می‌کنیم، از جمله اینکه داده چه چیزهایی را نمی‌تواند به ما بگوید. اگر بتوانید این یک مثال را از اول تا آخر دنبال کنید، نیمه‌ی اول درس را فهمیده‌اید.

زمان‌بندی پیشنهادی (۶۰ دقیقه): نقشه‌ی مفهومی ۱۰ · مطالعه‌ی موردی ۴۰ · توضیح آزمون ۱۰.

۱. نقشه‌ی مفهومی هفته‌های ۱ تا ۷

مرحله	سؤال	ابزارها	هفته
فرمال‌سازی	نظریه دقیقاً چه ادعایی دارد؟	پنج جزء یک مدل؛ پارامترها به‌عنوان سازه‌های روان‌شناختی	۱–۲
شبیه‌سازی	مدل چه کاری می‌تواند (و نمی‌تواند) بکند؟	شبیه‌سازی مستقیم، بررسی‌های تحلیلی، نمودار پیش‌بینی‌ها	۱–۲
برازش	کدام مقادیر پارامتر داده‌ها را بهتر توضیح می‌دهند؟	SSE / کمترین مربعات؛ MLE / NLL؛ شبکه، Nelder–Mead، L-BFGS-B؛ multi-start؛ کران‌ها و reparameterization	۳–۴
سنجش عدم قطعیت	برآوردها چقدر دقیق‌اند؟	SE از Hessian (Wald)، profile likelihood، bootstrap	۵
ارزیابی (مطلق)	آیا عدم برازش مدل از نویز بیشتر است؟	باقی‌مانده‌ها، G^2	۲–۴
ارزیابی (نسبی)	کدام مدل بهتر تعمیم پیدا می‌کند؟	CV، LRT، AIC/AICc/BIC، وزن‌ها	۶–۷
بازیابی	آیا روش با این طرح آزمایش می‌تواند کار کند؟	بازیابی پارامتر، بازیابی مدل (ماتریس‌های درهم‌ریختگی و معکوس)	۷
تفسیر	از نظر روان‌شناختی چه معنایی دارد و چه چیزی را نمی‌توانیم نتیجه بگیریم؟	معنای پارامترها، محدودیت‌های طرح آزمایش، خطاهای میانگین‌گیری	همه

راهنمای انتخاب درست‌نمایی:

داده	مدل نویز طبیعی	هفته
شمارش از n (یادآوری، hit، false alarm)	دوجمله‌ای	۲، ۴
انتخاب‌های دودویی تکی	برنولی	۴
پیوسته، تقریباً متقارن، با واریانس برابر (مثلاً میانگین زمان واکنش بلوک‌ها)	گاوسی (= کمترین مربعات)	۴–۵

۲. مطالعه‌ی موردی: آیا تکرار حساسیت حافظه را بالا می‌برد؟

طرح آزمایش. در یک آزمایش حافظه‌ی بازشناسی، کلمه‌ها ۱، ۲ یا ۴ بار مطالعه می‌شوند. در آزمون، برای هر شرط تکرار ۱۰۰ کلمه‌ی قدیمی و ۱۰۰ کلمه‌ی جدید (فریبنده یا lure) ارائه می‌شود و شرکت‌کننده می‌گوید «قدیمی» یا «جدید». چون کلمه‌های

فریبنده هرگز مطالعه نشده‌اند، **یک** نرخ false alarm مشترک برای همه‌ی شرایط و **سه** نرخ hit داریم.

فرمال‌سازی SDT) **با ملاک مطلق).** کلمه‌های جدید شواهد $X \sim \mathcal{N}(0,1)$ و کلمه‌های قدیمی‌ای که r بار مطالعه شده‌اند $X \sim \mathcal{N}(d'_r, 1)$ تولید می‌کنند؛ شرکت‌کننده اگر $X > \kappa$ باشد می‌گوید «قدیمی»، با یک ملاک κ برای همه‌ی آیتم‌های آزمون (آیتم‌ها در هم آمیخته‌اند، پس شرکت‌کننده نمی‌داند هر آیتم از کدام شرط است). پس

$$H_r = \Phi(d'_r - \kappa), \qquad F = \Phi(-\kappa).$$

سه مدل رقیب برای وابستگی d' به تکرارها:

مدل	d'_r	k	ادعا
$\mathcal{M}_0$ (بی‌اثر)	δ_0	۲	تکرار حساسیت را تغییر نمی‌دهد
$\mathcal{M}_1$ (خطی–لگاریتمی)	$\delta_0 + \delta_1 \log_2 r$	۳	هر دو برابر شدن مطالعه همان مقدار حساسیت اضافه می‌کند
$\mathcal{M}_2$ (آزاد)	d'_1, d'_2, d'_4	۴	هر الگویی (اشباع‌شده: ۴ پارامتر برای ۴ نرخ)

$\mathcal{M}_0 \subset \mathcal{M}_1 \subset \mathcal{M}_2$، پس همه‌ی جفت‌ها nested هستند.

درست‌نمایی. دوجمله‌ای برای هر یک از چهار شمارش (سه شمارش hit، یک شمارش false alarm).

کد lab در ادامه همه‌ی مراحل را اجرا می‌کند. دانشجویان آن را برای آمادگی آزمون در خانه اجرا می‌کنند؛ در درس خروجی‌ها مرور می‌شوند.

خواندن ریاضی

- $H_r = \Phi(d'_r - \kappa)$ و $F = \Phi(-\kappa)$: همان SDT هفته‌ی ۲، ولی ملاک به‌صورت یک موقعیت **مطلق** κ روی محور شواهد نوشته شده (از مرکز منحنی «کلمه‌ی جدید» سنجیده می‌شود) به جای اینکه نسبت به نقطه‌ی وسط سنجیده شود. کلمه‌های جدید: منحنی در ۰، پس F مساحت سمت راست κ است، یعنی $\Phi(-\kappa)$. کلمه‌های قدیمی که r بار مطالعه شده‌اند: منحنی در d'_r، پس $H_r = \Phi(d'_r - \kappa)$.
- یک κ برای همه‌ی شرایط: همه‌ی کلمه‌های آزمون با هم مخلوط‌اند، پس شرکت‌کننده نمی‌تواند برای کلمه‌هایی که یک بار و کلمه‌هایی که چهار بار مطالعه شده‌اند آستانه‌ی متفاوتی به کار ببرد.
- $\log_2 r$: لگاریتم در پایه‌ی ۲، پس $\log_2 1 = 0$، $\log_2 2 = 1$ و $\log_2 4 = 2$. در مدل $\mathcal{M}_1$، $d'_r = \delta_0 + \delta_1 \log_2 r$ یعنی: δ_0 حساسیت بعد از یک بار مطالعه است، و هر دو برابر شدن مطالعه δ_1 اضافه می‌کند.
- **عددهای مثال حل‌شده:** $\hat{\kappa} = 1.04$ می‌دهد $F = \Phi(-1.04) = 0.15$ ✓. با $\hat{d}'_1 = 0.82$: $H_1 = \Phi(0.82 - 1.04) = \Phi(-0.22) = 0.41$، نزدیک مقدار مشاهده‌شده‌ی ۴۰.۰ ✓.

برای یک مهندس مسیر نقشه‌ی مفهومی همان روند **شناسایی سیستم** (system identification) است که می‌شناسید: ساختارهای مدل نامزد را انتخاب کن، پارامترها را تخمین بزن (ML)، اعتبارسنجی کن (آزمون باقی‌مانده‌ها G^2)، مرتبه‌ی مدل را انتخاب کن (LRT/AIC/BIC $\approx$ GLRT/AIC/MDL)، و روش را روی داده‌ی شبیه‌سازی‌شده با حقیقت معلوم وارسی کن (بازیابی). دو تفاوت ارزش تأکید در کلاس را دارند: «سیستم» یک آدم است که خود پارامترهایش نتیجه‌ی علمی‌اند، و مقدار داده با معیارهای مهندسی خیلی کم است (۴۰۰ پاسخ دودویی)، پس عدم قطعیت و بازیابی خیلی مهم‌ترند.

برای مدرس

- **جدول نقشه‌ی مفهومی را ستون اصلی جلسه کنید.** برای هر سطر، خروجی متناظر در مطالعه‌ی موردی را نشان دهید (مثلاً «ارزیابی مطلق» ← ستون G^2). دانشجوها می‌بینند هر ابزار جایی دارد.
- **پیش از خودتان از کلاس بخواهید تفسیر کند.** جدول نتایج را بدون پاراگراف تفسیر نشان دهید و بگذارید گروه‌های کوچک دو جمله بنویسند: «چه نتیجه‌ای می‌گیریم و چه نتیجه‌ای نمی‌توانیم بگیریم؟» بعد با متن مقایسه کنید. این دقیقاً مهارتی است که میان‌ترم می‌سنجد.
- **توضیح امتحان:** به دانشجوها بگویید امتحان به تصمیم‌های مستدل (کدام درست‌نمایی، کدام معیار، چرا بازیابی مهم است) بیشتر از محاسبه نمره می‌دهد. یک سؤال به سبک امتحان از بخش خودآزمایی نشان دهید.
- **مشاوره‌ی پروژه (وقت lab):** از هر تیم سه سؤال بپرسید: سؤال شناختی شما چیست؟ کدام پارامتر یا مقایسه‌ی مدل به آن جواب می‌دهد؟ آیا طرح آزمایش شما می‌تواند آن را بازیابی کند؟ بیشتر پیشنهادهای ضعیف در سؤال سوم شکست می‌خورند.

۵.۳.۳ مثال حل‌شده

نتایج مطالعه‌ی موردی برای یک شرکت‌کننده‌ی شبیه‌سازی‌شده (مدل واقعی $\mathcal{M}_1$ با $\delta_0 = 0.8$، $\delta_1 = 0.6$، $\kappa = 1.0$)، از کد بخش .lab اعداد گرد شده‌اند.

قدم ۱: داده.

شرط	کلمه‌های قدیمی	پاسخ «قدیمی»	نرخ
$r = 1$	۱۰۰	۴۰	۴۰.۰
$r = 2$	۱۰۰	۶۶	۶۶.۰
$r = 4$	۱۰۰	۸۰	۸۰.۰
جدید (فریبنده)	۱۰۰	۱۵	۱۵.۰

قدم ۲: برازش و ارزیابی (MLE، $N = 400$ پاسخ):

مدل	k	NLL	G^2 (df، p)	AIC	BIC	w_{AIC}	w_{BIC}	$\hat{d}'_{1,2,4}$	$\hat{\kappa}$
$\mathcal{M}_0$ بی‌اثر	۲	۲۷.۲۷	۵۵.۳۵ (۲، < ۰۰۱.)	۵۴.۵۸	۵۲.۶۶	۰۰.۰	۰۰.۰	۳۴.۱، ۳۴.۱، ۳۴.۱	۰۴.۱
$\mathcal{M}_1$ خطی–لگاریتمی	۳	۷۷.۹	۵۴.۰ (۱، ۴۶.)	**۵۳.۲۵**	**۵۱.۳۷**	**۶۷.۰**	**۹۴.۰**	۳۷.۱، ۸۲.۰، ۹۳.۱	۰۴.۱
$\mathcal{M}_2$ آزاد	۴	۵۰.۹	۰ (اشباع‌شده)	۹۹.۲۶	۹۶.۴۲	۳۳.۰	۰۶.۰	۴۵.۱، ۷۸.۰، ۸۸.۱	۰۴.۱

آزمون‌های نسبت درست‌نمایی: $\mathcal{M}_0$ در برابر $\mathcal{M}_1$: $\Lambda = 35.01$، $\mathrm{df} = ۱$، $p < .001$؛ $\mathcal{M}_1$ در برابر $\mathcal{M}_2$: $\Lambda = 0.54$، $\mathrm{df} = ۱$، $p = .46$.

بازیابی با این طرح آزمایش (کد lab، بلوک دوم): پارامترهای $\mathcal{M}_1$ خوب بازیابی می‌شوند ($r = 0.89$ تا 0.93) و BIC مدل تولیدکننده را در ۸۷ تا ۹۸ درصد شبیه‌سازی‌ها شناسایی می‌کند.

قدم ۳: تفسیر. تکرار به‌وضوح حساسیت را بالا می‌برد: مدل بی‌اثر به‌شدت بد برازش می‌شود ($G^2 = 35.5$، $p < .001$) و همه‌ی معیارها آن را رد می‌کنند. مدل خطی–لگاریتمی با یک پارامتر کمتر به خوبی مدل اشباع‌شده برازش می‌شود (LRT با $p = .46$) و هم AIC و هم BIC آن را ترجیح می‌دهند. برآورد $\hat{\delta}_1 \approx 0.55$ یعنی هر دو برابر شدن مطالعه تقریباً نیم واحد d' اضافه می‌کند. نتایج بازیابی نشان می‌دهد که با این طرح آزمایش، هم به پارامترها و هم به انتخاب مدل می‌شود اعتماد کرد. هشدارها: این یک شرکت‌کننده‌ی شبیه‌سازی‌شده است؛ با فقط سه سطح تکرار، یک روند خطی–لگاریتمی را نمی‌شود از خیلی منحنی‌های صعودی دیگر (مثلاً یک تابع توانی از r) جدا کرد؛ و یک ملاک واحد κ فرض می‌کند شرکت‌کننده پیش از پاسخ نمی‌داند یک آیتم چند بار مطالعه شده است.

۶.۳.۳ lab (۲ ساعت): آزمون میان‌ترم + مشاوره‌ی پروژه

آزمون میان‌ترم (۹۰ دقیقه، در زمان lab)

- **شکل:** کتبی، کتاب‌بسته. یک **برگه‌ی فرمول** (در ادامه) داده می‌شود. بدون لپ‌تاپ: سؤال‌ها شامل خواندن تکه‌کدهای کوتاه و تفسیر خروجی‌هاست، نه نوشتن کد از صفر.
- **محدوده:** هفته‌های ۱ تا ۷ (فصل‌های ۱ تا ۳)، با تأکید بر فهم و تفسیر (هدف ویژه‌ی ۲ درس).
- **انواع سؤال:** (۱) سؤال‌های مفهومی کوتاه؛ (۲) یک محاسبه‌ی دستی (مثلاً d' و c، یک درست‌نمایی یا NLL، AIC/BIC و وزن‌ها)؛ (۳) خواندن کد و پیش‌بینی یا توضیح خروجی آن؛ (۴) تفسیر یک جدول برازش، نمودار باقی‌مانده‌ها یا ماتریس بازیابی/درهم‌ریختگی؛ (۵) یک سؤال کوتاه طراحی («چه چیزی را تغییر می‌دادید و چرا؟»).
- **وزن:** ۳ نمره از ۲۰.
- خود آزمون میان‌ترم با پاسخ‌های نمونه در مواد ارزشیابی درس آمده است.

برگه‌ی فرمولی که در آزمون داده می‌شود:

$$d' = \Phi^{-1}(H) - \Phi^{-1}(F), \quad c = -\tfrac{1}{2}[\Phi^{-1}(H) + \Phi^{-1}(F)], \quad H = \Phi(d'/2 - c), \quad F = \Phi(-d'/2 - c)$$

$$f_{\exp}(t) = Ae^{-\lambda t}, \quad f_{\mathrm{pow}}(t) = A(1+t)^{-d}, \quad P_c^{\mathrm{RW}} = \frac{1 - r^z}{1 - r^a},\ r = \frac{1-v}{1+v}, \quad \mathbb{E}[T] = \frac{aP_c - z}{v}$$

$$\mathrm{SSE} = \textstyle\sum_i (y_i - \hat{y}_i)^2, \quad \mathrm{RMSD} = \sqrt{\mathrm{SSE}/N}$$

$$\ell(\boldsymbol{\theta}) = \textstyle\sum_i \left[\ln \binom{n_i}{y_i} + y_i \ln f_i + (n_i - y_i)\ln(1 - f_i) \right], \quad \mathrm{NLL} = -\ell$$

$$G^2 = 2(\ell_{\mathrm{sat}} - \hat{\ell}), \quad \Lambda = 2(\hat{\ell}_1 - \hat{\ell}_0) \sim \chi^2_{\Delta k}$$

$$\mathrm{SE} \approx \sqrt{\mathrm{diag}(\mathbf{H}^{-1})}, \quad \text{Wald CI: } \hat{\theta} \pm 1.96\,\mathrm{SE}, \quad \text{profile CI: } 2(\mathrm{NLL}_{\mathrm{prof}} - \mathrm{NLL}_{\min}) \le 3.84$$

$$\mathrm{AIC} = 2\,\mathrm{NLL} + 2k, \quad \mathrm{AICc} = \mathrm{AIC} + \tfrac{2k(k+1)}{N-k-1}, \quad \mathrm{BIC} = 2\,\mathrm{NLL} + k \ln N, \quad w_i = \tfrac{e^{-\Delta_i/2}}{\sum_j e^{-\Delta_j/2}}$$

مقادیر بحرانی: $\chi^2_{1,.95} = 3.84$، $\chi^2_{2,.95} = 5.99$، $\chi^2_{3,.95} = 7.81$. quantileها: $\Phi^{-1}(0.84) \approx 1.0$، $\Phi^{-1}(0.975) = 1.96$. لگاریتم‌ها: $\ln 2 = 0.693$، $\ln 10 = 2.303$، $\ln 100 = 4.605$، $\ln 400 = 5.991$.

مشاوره‌ی پروژه (۳۰ دقیقه، بعد از آزمون)

هر گروه ۵ تا ۱۰ دقیقه با مدرس یا دستیار آموزشی درباره‌ی ایده‌ی پروژه‌اش پیش از موعد پیشنهاد (ابتدای هفته‌ی ۹) صحبت می‌کند. یک پاراگراف توصیف از سؤال، مدل و داده‌تان بیاورید.

مطالعه‌ی شخصی: مطالعه‌ی موردی در کد (پیش از آزمون اجرا کنید)

Code · کد: code/week08.py، cell ۱ · سلول ۱

Code · کد: code/week08.py، cell ۲ · سلول ۲

خروجی مورد انتظار (بلوک اول):

```
hits per condition: [40 66 80]  false alarms: 15
           k     NLL      G2  df  p(G2)     AIC     BIC
           ↪  d'_1,2,4  kappa  w_AIC  w_BIC
model
M0_none    2  27.269  35.549   2  0.000  58.538  66.521  [1.34, 1.34,
 ↪  1.34]   1.04  0.000  0.000
M1_loglin  3   9.766   0.543   1  0.461  25.533  37.507  [0.82, 1.37,
 ↪  1.93]   1.04  0.674  0.938
M2_free    4   9.495   0.000   0    NaN  26.990  42.956  [0.78, 1.45,
 ↪  1.88]   1.04  0.326  0.062

LRT M0 vs M1: 35.01 (df 1, p = 0.0000);  M1 vs M2: 0.54 (df 1, p = 0.461)
```

خروجی مورد انتظار (بلوک دوم، حدود ۱ دقیقه):

```
M1 recovery delta0 : r = 0.895, RMSE = 0.181
M1 recovery delta1 : r = 0.930, RMSE = 0.113
M1 recovery kappa  : r = 0.887, RMSE = 0.142

BIC model recovery, P(selected | generated):
           M0_none  M1_loglin  M2_free
M0_none       0.98       0.02     0.00
M1_loglin     0.05       0.93     0.02
M2_free       0.10       0.03     0.87
```

یادداشت درباره‌ی مولد $\mathcal{M}_2$ در بازیابی مدل: سه مقدار d' آن طوری کشیده می‌شوند که d'_4 بین d'_1 و d'_2 قرار بگیرد؛ یک الگوی غیریکنوا که $\mathcal{M}_1$ نمی‌تواند تولید کند. در غیر این صورت داده‌های $\mathcal{M}_2$ اغلب کاملاً با $\mathcal{M}_1$ سازگار می‌بودند و «اشتباه گرفتن‌ها» بی‌معنی می‌شد.

سؤال‌های خودسنجی درباره‌ی مطالعه‌ی موردی (در درس بحث می‌شوند): ۱. چرا فقط یک نرخ false alarm داریم، و این مدل SDT را در مقایسه با هفته‌ی ۲ چطور تغییر می‌دهد؟ ۲. هر معیار کدام مدل را ترجیح می‌دهد، و آیا LRTها با آن موافق‌اند؟ ۳.

آیا δ_1 با این طرح آزمایش قابل بازیابی است؟ آیا $\mathcal{M}_1$ از $\mathcal{M}_0$ و $\mathcal{M}_2$ قابل تشخیص است؟ ۴. نتیجه‌ی روان‌شناختی را در یک جمله، همراه با مهم‌ترین هشدارش، بنویسید.

۷.۳.۳ ارتباط با هوش مصنوعی و LLMها

chatbot به‌عنوان هم‌درس: اعتماد کن، ولی بررسی کن. بسیاری از دانشجوها از LLMها برای توضیح مفاهیم و بررسی جواب‌های امتحانی استفاده می‌کنند. این می‌تواند کمک کند، ولی LLMها می‌توانند محاسبه‌هایی روان، مطمئن و غلط تولید کنند. با جواب یک chatbot مثل پیش‌بینی یک مدل رفتار کنید: آن را با چیزی که خودتان می‌توانید حساب کنید بسنجید. کد پایین یک جواب ازپیش‌آماده‌ی chatbot به سؤال B3 میان‌ترم (AIC برای سه مدل) را بررسی می‌کند. chatbot به جای $2\,\mathrm{NLL} + 2k$ از $2\,\mathrm{NLL} + k$ استفاده کرده.

Code · **کد:** `code/week08.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
M1: chatbot 222.0, correct 224.0  WRONG
M2: chatbot 218.0, correct 221.0  WRONG
M3: chatbot 218.8, correct 223.8  WRONG
Akaike weights, chatbot: [0.07 0.55 0.37]  correct: [0.15 0.68 0.17]
```

chatbot اتفاقاً برنده‌ی درست ($\mathcal{M}_2$) را انتخاب می‌کند، ولی همه‌ی عددها غلط‌اند و پشتیبانی از پیچیده‌ترین مدل را دو برابر می‌کند. مصحح نمره‌ی کمی می‌داد، و در یک تحلیل واقعی این خطا به نفع overfitting تمام می‌شد.

امتحانش کنید (بدون نیاز به API). ⋆ کدام خطا در فرمول دقیقاً عددهای chatbot را تولید می‌کند؟ BIC با همین خطا چه شکلی می‌شد؟ ⋆⋆ سه «مورد آزمون» (ورودی با جواب معلوم) کوچک برای فرمول‌های SDT هفته‌ی ۲ بنویسید که بتوانید با آن هر جوابی را، چه از chatbot چه از هم‌کلاسی، بررسی کنید. یادآوری: در خود امتحان هیچ ابزار هوش مصنوعی مجاز نیست، و قانون درس درباره‌ی استفاده از هوش مصنوعی در تکلیف‌ها در `assessments/README.md` آمده است.

۸.۳.۳ اشتباهات رایج و برداشت‌های نادرست (۱۰ مورد اول از هفته‌های ۱ تا ۷)

۱. برازش خوب را شاهد درستی مدل دانستن (هفته‌های ۳، ۶).
۲. فراموش کردن علامت منفی: بهینه‌سازها **منفی** لگاریتم درست‌نمایی را کمینه می‌کنند (هفته‌ی ۴).
۳. محدود نکردن احتمال‌ها، که باعث می‌شود $\ln 0$ برازش را از کار بیندازد (هفته‌ی ۴).
۴. اعتماد به `success=True`، یک شروع تنها، یا Nelder–Mead کران‌داری که روی یک کران فرو ریخته است (هفته‌های ۳–۴).
۵. کمترین مربعات برای شمارش‌ها یا انتخاب‌ها بدون فکر کردن به مدل نویز (هفته‌های ۳–۴).
۶. گزارش برآوردها بدون عدم قطعیت، یا استفاده از بازه‌های Wald نزدیک کران‌ها (هفته‌ی ۵).
۷. نتیجه‌گیری درباره‌ی افراد از منحنی‌های میانگین‌گیری‌شده (هفته‌ی ۵).

۸. نشت داده‌ی آزمون به آموزش در cross-validation (هفته‌ی ۶).
۹. مقایسه‌ی مدل‌های non-nested با LRT، یا خواندن مقادیر AIC به‌تنهایی به‌جای تفاوت‌هایشان (هفته‌ی ۷).
۱۰. تفسیر پارامترها یا مقایسه‌ی مدل‌ها بدون مطالعه‌ی بازیابی با طرح آزمایش واقعی (هفته‌ی ۷).

۹.۳.۳ خودآزمایی (سؤال‌های تمرینی به سبک آزمون)

۱. (مفهومی) در سه جمله توضیح دهید چرا مدل نمایی با مجانب داده‌های هفته‌ی ۲ را بهتر از مدل توانی برازش کرد، با اینکه مدل توانی داده را تولید کرده بود. **پاسخ** مدل مجانبی یک پارامتر اضافه دارد، پس می‌تواند خودش را با نویز خاص نمونه، اینجا نقاط صاف‌نمای فاصله‌های طولانی، تطبیق دهد. برازش آموزش بهتر برای مدل‌های منعطف‌تر تضمین‌شده است و شاهد درستی نیست. برای قضاوت به معیارهای تعمیم (CV)، (AIC/BIC و مطالعات بازیابی نیاز داریم.

۲. (محاسبه) یک مشاهده‌گر $H = 0.84$ و $F = 0.16$ دارد. d' و c را حساب کنید (از $\Phi^{-1}(0.84) \approx 1.0$ استفاده کنید). **پاسخ** $d' = 1.0 - (-1.0) = 2.0$؛ $c = -\frac{1}{2}(1.0 + (-1.0)) = 0$، پس مشاهده‌گر بی‌سوگیری است.

۳. (محاسبه) دو مدل روی $N = 100$ پاسخ دودویی برازش شده‌اند. مدل A: $k = 2$، NLL = ۰.۶۰. مدل B: $k = 4$، NLL = ۵.۵۷. AIC و BIC هر دو را حساب کنید. هر معیار کدام را ترجیح می‌دهد؟ ($\ln 100 = 4.605$) **پاسخ** AIC: A = ۰.۱۲۴، B = ۰.۱۲۳، پس AIC (کمی) B را ترجیح می‌دهد. BIC: A = ۱۲۰ + ۲۱.۹ = ۲۱.۱۲۹؛ B = ۱۱۵ + ۴۲.۱۸ = ۴۲.۱۳۳، پس BIC A را ترجیح می‌دهد. معیارها با هم مخالف‌اند چون BIC هر پارامتر را ۶.۴ به‌جای ۲ جریمه می‌کند.

۴. (خواندن کد) این تابع NLL چه اشکالی دارد و بهینه‌ساز چه خواهد کرد؟

> **کد:** Code · سلول ۴ · cell ۴، `code/week08.py`

پاسخ (۱) لگاریتم درست‌نمایی را برمی‌گرداند نه منفی آن را، پس `minimize` پارامترها را به سمت بدترین برازش (لگاریتم درست‌نمایی به سمت $-\infty$) می‌برد. (۲) p محدود نشده، پس مقادیر پیش‌بینی‌شده‌ی ۰ یا بیشتر از ۱ مقدار $-\inf$ یا nan می‌دهند. اصلاح: `return -np.sum(binom.logpmf(y, n, np.clip(p, EPS, 1-EPS)))`.

۵. (تفسیر) یک مطالعه‌ی بازیابی برای پارامتر A مقدار $r(\text{true}, \text{recovered}) = 0.95$ و برای پارامتر B مقدار 0.35 می‌دهد. درباره‌ی مقاله‌ای که با این طرح آزمایش تفاوت گروه‌ها در B را گزارش می‌کند چه نتیجه‌ای می‌گیرید؟ **پاسخ** B با این طرح آزمایش ضعیف بازیابی می‌شود: برآوردها تحت تأثیر نویز یا trade-off هستند، پس تفاوت گروه‌ها در B برآوردشده قابل تفسیر نیست. مقاله باید طرح آزمایش را بهتر کند یا B را تفسیر نکند.

۶. (تفسیر) یک BIC confusion matrix دارای P(selected | generated) = power = ۵۸.۰ (asymptote) است. برنده‌ی BIC در داده‌ی واقعی شما مدل توانی است. چه باید بنویسید؟ **پاسخ** اینکه BIC مدل توانی را ترجیح می‌دهد، ولی با این طرح آزمایش BIC اغلب برای داده‌هایی که مدل مجانبی تولید کرده هم مدل توانی را انتخاب می‌کند، پس شواهد بین این دو به‌خوبی تمایز نمی‌گذارد. احتمال‌های معکوس و نتایج AIC/CV را گزارش کنید و طرحی با فاصله‌های طولانی‌تر پیشنهاد دهید.

۷. (طراحی) می‌خواهید بدانید آیا یک دارو در مدل random walk احتیاط (مرز a) را تغییر می‌دهد یا کیفیت شواهد (drift v) را. چه داده‌ای باید جمع کنید و چرا دقت به‌تنهایی کافی نیست؟ **پاسخ** انتخاب‌ها **و** زمان‌های واکنش (ترجیحاً کل توزیع زمان واکنش) تحت دارو و دارونما. هم a بزرگ‌تر و هم v بزرگ‌تر دقت را بالا می‌برند، ولی a پاسخ‌ها را کند و v سریع می‌کند، پس فقط الگوی مشترک آن‌ها را از هم جدا می‌کند (هفته‌ی ۱).

۸. (مفهومی) اگر بخواهیم پیش‌بینی trialهای جدید را آزمون کنیم، چرا باید بخش‌های cross-validation برای داده‌های فراموشی داخل فاصله‌ها ساخته شوند؟ **پاسخ** تا هر مجموعه‌ی آموزش همه‌ی فاصله‌های نگهداری (شرایط) را داشته باشد و آزمون درباره‌ی آیتم‌های جدید در شرایط معلوم باشد. کنار گذاشتن کل فاصله‌ها برون‌یابی به شرایط جدید را آزمون می‌کند که ادعای تعمیم دیگری است.

۱۰.۳.۳ تکلیف

- A3 **(مقایسه و بازیابی مدل)** در ابتدای درس هفته‌ی ۹ تحویل داده می‌شود.
- **پیشنهاد پروژه** در ابتدای درس هفته‌ی ۹ تحویل داده می‌شود (حداکثر ۲ صفحه؛ هفته‌ی ۷ را ببینید).
- این هفته تکلیف جدیدی نداریم. برای میان‌ترم با اجرای مطالعه‌ی موردی بالا و جواب دادن به سؤال‌های تمرینی بدون نگاه کردن به پاسخ‌ها آماده شوید.

۱۱.۳.۳ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل‌های ۲ تا ۵ و ۱۰.** خلاصه‌ی فصل‌ها را به‌عنوان مرور کل نیمه‌ی اول درس دوباره بخوانید.
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۱۱** .(SDT) توصیف مدل را برای آمادگی هفته‌ی ۹ بخوانید، که در آن شروع می‌کنیم پارامترها را متغیرهای تصادفی با پیشین در نظر بگیریم.

پیش‌نمایش هفته‌ی ۹: نیمه‌ی دوم درس بیزی می‌شود. به‌جای یک بهترین برآورد به‌علاوه‌ی یک بازه‌ی اطمینان، کل توزیع احتمال پارامترها به شرط داده را حساب می‌کنیم.

فصل ۴

مدل‌سازی بیزی

۱.۴ هفته‌ی ۹: مدل‌سازی بیزی ۱: پیشین، پسین و تقریب شبکه‌ای

فصل ۴: مدل‌سازی بیزی · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** یک نسبت یادآوری (۳۰ از ۵۰) و شرکت‌کننده‌ی SDT هفته‌ی ۲ (hit ۶۸/۱۰۰، false alarm ۱۱/۱۰۰).

۱.۱.۴ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
prior	توزیع پیشین (prior)	باور درباره‌ی پارامتر پیش از دیدن داده
posterior	توزیع پسین (posterior)	باور درباره‌ی پارامتر بعد از دیدن داده
grid approximation	تقریب شبکه‌ای (grid)	محاسبه‌ی پسین روی شبکه‌ای از مقادیر
signal detection theory (SDT)	نظریه‌ی تشخیص علامت	مدلی که حساسیت را از سوگیری پاسخ جدا می‌کند
hit	اصابت (hit)	پاسخ «بله» وقتی علامت وجود دارد
Bayes’ rule	قاعده‌ی بیز	پسین ∝ درست‌نمایی × پیشین
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
evidence	شواهد	اطلاعاتی که برای تصمیم جمع می‌شود
beta-binomial model	مدل beta-binomial	پیشین Beta با داده‌ی دوجمله‌ای
binomial distribution	توزیع دوجمله‌ای	توزیع تعداد موفقیت در n کوشش
MAP estimate	برآورد MAP	مُد توزیع پسین

English	فارسی	توضیح کوتاه
HDI / credible interval	بازه‌ی باورپذیر (credible interval)	بازه‌ای که با احتمال مشخص پارامتر را دارد
confidence interval (CI)	بازه‌ی اطمینان	بازه‌ای که با روش مشخص پارامتر واقعی را در بر می‌گیرد
prior predictive check	بررسی پیش‌بینی پیشین	شبیه‌سازی داده از پیشین برای سنجش معقول بودن آن
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
maximum likelihood estimate (MLE)	برآورد بیشینه‌ی درست‌نمایی	پارامترهایی که داده را محتمل‌ترین می‌کنند
cognitive model	مدل شناختی	توصیف دقیق و ریاضی یا محاسباتی از یک فرایند ذهنی
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
conjugate prior	پیشین مزدوج (conjugate)	پیشینی که پسین هم‌خانواده می‌دهد
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
accuracy	دقت	نسبت پاسخ‌های درست

۲.۱.۴ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. قاعده‌ی بیز را برای پارامترها **بیان کنند** و نقش پیشین (prior)، درست‌نمایی، شواهد (evidence) و پسین (posterior) را **مشخص کنند**.
۲. پسین را برای مدل beta-binomial به‌صورت تحلیلی و با تقریب شبکه‌ای به‌صورت عددی، برای یک و دو پارامتر، **حساب کنند**.
۳. یک پسین را **خلاصه کنند** (میانگین، میانه، MAP، انحراف معیار، بازه‌های دم‌برابر و بیشترین چگالی) و credible interval را از بازه‌ی اطمینان **متمایز کنند**.
۴. **توضیح دهند** که پیشین و مقدار داده با هم چطور پسین را تعیین می‌کنند، و با شبیه‌سازی پیش‌بینی پیشین **بررسی کنند** که پیشین معقول است یا نه.
۵. احتمال‌های پسین فرضیه‌های معنادار روان‌شناختی را **تفسیر کنند** (مثلاً «$P(d' > 1 \mid \text{data})$»).

۳.۱.۴ مقدمه

از هفته‌ی ۳ پرسیده‌ایم: «کدام مقدار واحد پارامتر داده‌ها را بهتر توضیح می‌دهد؟» و بعد، در هفته‌ی ۵، «این برآورد در تکرارهای خیالی چقدر تغییر می‌کرد؟» پژوهشگران اغلب می‌خواهند چیز مستقیم‌تری بگویند:

> «با توجه به این داده‌ها، با احتمال ٪۹۵ حساسیت این شرکت‌کننده بین ۲.۱ و ۱.۲ است.» «احتمال اینکه دست‌کاری پاداش شرکت‌کننده‌ها را *liberal*‌تر کرده باشد ۹۸.۰ است.»

بازه‌های اطمینان فراوانی‌گرا اجازه‌ی چنین جمله‌هایی را **نمی‌دهند** (هفته‌ی ۵). استنباط بیزی می‌دهد، به یک قیمت: باید بگوییم **پیش از** دیدن داده درباره‌ی پارامترها چه باوری داشتیم، به شکل یک **توزیع پیشین**. بعد قاعده‌ی بیز پیشین را با درست‌نمایی (که بلدیم بنویسیم) ترکیب می‌کند و یک **توزیع پسین** می‌سازد: همه‌ی آنچه مدل و داده با هم درباره‌ی پارامترها می‌گویند.

روش‌های بیزی چند دردسر قبلی ما را هم آسان‌تر می‌کنند: عدم قطعیت مجانی به دست می‌آید (بدون Hessian یا bootstrap)، مدل‌های سلسله‌مراتبی چند شرکت‌کننده طبیعی می‌شوند (هفته‌ی ۱۳)، و مقایسه‌ی مدل‌ها یک جواب اصولی پیدا می‌کند (هفته‌ی ۱۰). هزینه‌اش محاسبه است، و برای همین هفته‌های ۱۱ تا ۱۳ درباره‌ی نمونه‌گیری‌اند.

> **یادآوری (هفته‌ی ۱):** این هفته درباره‌ی **تحلیل داده‌ی بیزی** است؛ روشی که ما پژوهشگران برای برآورد پارامترهای هر مدلی به کار می‌بریم. هیچ ادعایی ندارد که ذهن بیزی است. مدل‌های بیزی شناخت در هفته‌ی ۱۵ می‌آیند.

این موضوع کجا به کار می‌رود؟

- **نمونه‌های کوچک و موردهای تکی.** در عصب‌روان‌شناسی بالینی اغلب یک بیمار و چند ده trial داریم. تحلیل بیزی با یک prior معقول، عدم قطعیت صادقانه و قابل استفاده‌ای می‌دهد، جایی که MLE ناپایدار است.
- **گزاره‌های احتمالی مستقیم** که پزشکان و سیاست‌گذاران می‌فهمند: «با احتمال ٪۹۷ آموزش جدید حافظه را بهتر کرده».
- **آزمون‌های تطبیقی** :(adaptive testing) آزمون‌های کامپیوتری (مثلاً آزمون‌های بینایی و شنوایی، امتحان‌های تطبیقی) بعد از هر پاسخ posterior را به‌روز می‌کنند و آیتم بعدی را جایی انتخاب می‌کنند که بیشترین اطلاعات را می‌دهد.
- **ترکیب شواهد:** posterior امروز prior فرداست، پس نتایج مطالعه‌های قبلی را می‌شود به‌طور رسمی وارد تحلیل کرد.
- **نرم‌افزارهای امروزی مدل‌سازی شناختی** (PyMC، Stan، JAGS) بیزی‌اند؛ بیشتر مدل‌های سلسله‌مراتبی در مقاله‌های اخیر به همین روش برازش می‌شوند (هفته‌ی ۱۳).

۴.۱.۴ جزوه‌ی درس

به زبان ساده تا اینجا یک بهترین مقدار پارامتر پیدا می‌کردیم و بعد می‌پرسیدیم چقدر ممکن است تغییر کند. روش بیزی در عوض دانش ما درباره‌ی پارامتر را به شکل یک **توزیع احتمال** کامل توصیف می‌کند. پیش از داده، prior **(پیشین)** می‌گوید کدام مقدارها را معقول می‌دانیم (مثلاً «احتمال یادآوری احتمالاً متوسط است، نه ۰ یا ۱»). بعد داده‌ها به هر مقدار ممکن به اندازه‌ی درست‌نمایی‌اش (هفته‌ی ۴) وزن تازه می‌دهند. نتیجه، posterior **(پسین)**، می‌گوید هر مقدار بعد از دیدن داده چقدر معقول است. به زبان ساده: $\textit{posterior} \propto \textit{likelihood} \times \textit{prior}$. از posterior می‌توانیم یک بهترین حدس (میانگین آن)، یک عدم قطعیت (پراکندگی آن) و گزاره‌های مستقیمی مثل «احتمال اینکه $d' > 1$ باشد ۹۳.۰ است» بخوانیم. با داده‌ی کم prior اثر زیادی دارد؛ با داده‌ی زیاد posterior زیر سلطه‌ی درست‌نمایی است و به MLE نزدیک می‌شود. محاسبه‌ی posterior برای یک یا دو پارامتر آسان است (روی grid) و برای بیشتر از آن به روش‌های نمونه‌گیری نیاز دارد (هفته‌های ۱۱ تا ۱۳).

زمان‌بندی پیشنهادی (۶۰ دقیقه): قاعده‌ی بیز ۱۰ · پیشین‌ها ۱۰ · beta-binomial ۱۲ · تقریب شبکه‌ای ۱۰ · خلاصه‌ها و credible intervalها ۱۲ · بررسی پیش‌بینی پیشین ۶.

۱. قاعده‌ی بیز برای پارامترها

$$\underbrace{p(\boldsymbol{\theta} \mid \mathbf{y})}_{\text{posterior}} = \frac{\overbrace{p(\mathbf{y} \mid \boldsymbol{\theta})}^{\text{likelihood}}\ \overbrace{p(\boldsymbol{\theta})}^{\text{prior}}}{\underbrace{p(\mathbf{y})}_{\text{evidence (marginal likelihood)}}}, \qquad p(\mathbf{y}) = \int p(\mathbf{y} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, d\boldsymbol{\theta}.$$

(این هفته «$\mathcal{M}$» را در نمادگذاری نمی‌نویسیم: همه‌چیز مشروط به مدل است.)

- **درست‌نمایی** دقیقاً همان تابع هفته‌ی ۴ است.
- **پیشین** آنچه را پیش از داده معلوم یا محتمل است بیان می‌کند.
- **شواهد** $p(\mathbf{y})$ به $\boldsymbol{\theta}$ بستگی ندارد. برای برآورد، فقط ثابت نرمال‌ساز است که انتگرال پسین را ۱ می‌کند:

$$p(\boldsymbol{\theta} \mid \mathbf{y}) \propto p(\mathbf{y} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta}).$$

پسین $\propto$ درست‌نمایی × پیشین. در هفته‌ی ۱۰ شواهد ستاره‌ی مقایسه‌ی بیزی مدل‌ها می‌شود.

شهود. پسین یک مصالحه است: جایی بالاست که مقادیر پارامتر هم از پیش محتمل‌اند و هم داده را محتمل می‌کنند. با داده‌ی کم پیشین مهم است؛ با داده‌ی زیاد درست‌نمایی غالب می‌شود و پسین حول MLE متمرکز می‌شود.

خواندن ریاضی

- $p(\boldsymbol{\theta} \mid \mathbf{y})$: «احتمال (چگالی) مقدار پارامتر $\boldsymbol{\theta}$ به شرط داده». این همان چیزی است که می‌خواهیم.
- $p(\mathbf{y} \mid \boldsymbol{\theta})$: درست‌نمایی، که به‌عنوان تابعی از $\boldsymbol{\theta}$ خوانده می‌شود (هفته‌ی ۴).
- $p(\boldsymbol{\theta})$: prior که پیش از داده انتخاب می‌شود.
- $p(\mathbf{y}) = \int p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})\, d\boldsymbol{\theta}$: انتگرال، «درست‌نمایی × prior» را روی همه‌ی مقدارهای ممکن پارامتر جمع می‌کند. یک عدد است و برای همه‌ی $\boldsymbol{\theta}$ها یکسان است، پس در برآورد فقط منحنی را طوری مقیاس می‌کند که مساحت کل ۱ شود.
- $\propto$ یعنی «متناسب با»: برابر، به‌جز یک ضریب ثابت. در عمل «درست‌نمایی × prior» را در مقدارهای زیادی حساب می‌کنیم و بعد بر جمعشان تقسیم می‌کنیم، دقیقاً مثل جدول چهارنقطه‌ای مثال حل‌شده (۰۰۰۴۴۷۹.۰ / ۰۰۰۹۵۷۴.۰ = ۴۶۸.۰).

۲. انتخاب پیشین‌ها

نوع	مثال برای احتمال یادآوری θ	چه وقت
تخت / یکنواخت	$\mathrm{Beta}(1,1)$	وقتی هر مقدار در دامنه واقعاً به یک اندازه محتمل است (به‌ندرت درست است)

نوع	مثال برای احتمال یادآوری θ	چه وقت
ضعیف‌آگاهی‌بخش (weakly informative)	$\mathrm{Beta}(2,2)$: ترجیح ملایم برای مقادیر میانی	**پیش‌فرض برای بیشتر مدل‌های شناختی**: مقادیر پوچ را کنار می‌گذارد و بقیه را به داده می‌سپارد
آگاهی‌بخش (informative)	$\mathrm{Beta}(20,5)$: «یادآوری بعد از یک روز حدود ۸۰ است»	وقتی مطالعات قبلی یا نظریه دانش واقعی می‌دهند

اصول: - پیشین‌ها باید **پیش از** دیدن داده تعیین شوند. - باید دامنه‌ی پارامتر را رعایت کنند (مثلاً هیچ جرم پیشینی روی نرخ زوال منفی نباشد). - باید با **شبیه‌سازی پیش‌بینی پیشین** بررسی شوند (بخش ۶): پیشین کدام داده‌ها را نتیجه می‌دهد؟ - یک پیشین «مبهم» روی یک مقیاس می‌تواند روی مقیاس دیگری خیلی آگاهی‌بخش باشد (بخش D lab. - پیشین‌هایتان را گزارش کنید و حساسیت نتیجه‌گیری‌ها را به جایگزین‌های معقول بررسی کنید (هفته‌ی ۱۰).

۳. یک حالت با جواب بسته: مدل beta-binomial

برای y موفقیت در n trial دوجمله‌ای با پیشین $\mathrm{Beta}(a_0, b_0)$ روی θ:

$$p(\theta \mid y) \propto \underbrace{\theta^{y}(1-\theta)^{n-y}}_{\text{likelihood}} \cdot \underbrace{\theta^{a_0-1}(1-\theta)^{b_0-1}}_{\text{prior}} = \theta^{a_0+y-1}(1-\theta)^{b_0+n-y-1},$$

پس پسین دوباره یک توزیع Beta است:

$$\theta \mid y \sim \mathrm{Beta}(a_0 + y,\ b_0 + n - y).$$

وقتی پیشین و پسین از یک خانواده باشند، پیشین را conjugate می‌نامند.

- a_0 و b_0 مثل **شمارش‌های کاذب** (pseudo-counts) موفقیت‌ها و شکست‌های پیشین عمل می‌کنند.
- میانگین پسین: $\dfrac{a_0 + y}{a_0 + b_0 + n}$؛ میانگین وزنی میانگین پیشین $\frac{a_0}{a_0+b_0}$ و نسبت مشاهده‌شده‌ی y/n، با وزن‌های a_0+b_0 و n.
- **ارتباط با هفته‌های ۲ و ۴:** تصحیح log-linear $(y+0.5)/(n+1)$ دقیقاً میانگین پسین تحت پیشین $\mathrm{Beta}(0.5,0.5)$، به نام پیشین *Jeffreys*، است. آن «تصحیح» یک برآورد بیزی در لباس مبدل بود.

خواندن ریاضی

- **توزیع** Beta $\mathrm{Beta}(a,b)$ یک منحنی زنگوله‌مانند انعطاف‌پذیر روی بازه‌ی ۰ تا ۱ است و برای توصیف باور درباره‌ی یک احتمال ایده‌آل است. میانگین آن $a/(a+b)$ است. $\mathrm{Beta}(1,1)$ صاف است؛ $\mathrm{Beta}(20,5)$ یک برآمدگی باریک حول ۸۰ است.
- قاعده‌ی به‌روزرسانی $\mathrm{Beta}(a_0,b_0) \to \mathrm{Beta}(a_0+y, b_0+n-y)$ فقط **شمردن** است: موفقیت‌های مشاهده‌شده را به a و شکست‌ها را به b اضافه کن. prior طوری رفتار می‌کند که انگار قبلاً a_0 موفقیت و b_0 شکست دیده‌ایم (شمارش‌های ساختگی یا pseudo-counts).
- **مثال:** prior برابر $\mathrm{Beta}(2,2)$ («انگار» ۲ یادآوری و ۲ شکست)، داده ۷ از ۱۰ $\leftarrow$ $\mathrm{Beta}(9,5)$ با میانگین $9/14 = 0.643$. prior مقدار مشاهده‌شده‌ی ۷۰.۰ را کمی به سمت ۵۰.۰ می‌کشد، چون ۴ مشاهده‌ی ساختگی به ۱۰ مشاهده‌ی واقعی اضافه می‌کند.

۴. تقریب شبکه‌ای (grid approximation)

بیشتر مدل‌های شناختی پیشین conjugate ندارند. اگر فقط یک یا دو پارامتر باشد، می‌توانیم پسین را روی یک شبکه تقریب بزنیم:

۱. شبکه‌ای از مقادیر پارامتر $\boldsymbol{\theta}_1, \ldots, \boldsymbol{\theta}_G$ تعریف کنید که همه‌ی مقادیر معقول را بپوشاند.
۲. در هر نقطه‌ی شبکه **لگاریتم** پیشین به‌علاوه‌ی **لگاریتم** درست‌نمایی را حساب کنید (لگاریتم‌ها، مثل هفته‌ی ۴، از سرریز جلوگیری می‌کنند).
۳. بیشینه را کم کنید، نمایی بگیرید و نرمال کنید تا جمع مقادیر ۱ شود (یا انتگرالشان ۱ شود).

نتیجه یک تقریب گسسته از پسین است که هر خلاصه‌ای را می‌شود از آن حساب کرد. تقریب شبکه‌ای تا حد دقت شبکه دقیق است و برای ساختن شهود ایده‌آل است. فراتر از ۲ تا ۳ پارامتر شکست می‌خورد (نفرین ابعاد، هفته‌ی ۳)، و همین انگیزه‌ی MCMC است (هفته‌های ۱۱–۱۳).

۵. خلاصه کردن یک پسین

خلاصه	تعریف	توضیح
میانگین پسین	$\mathbb{E}[\theta \mid \mathbf{y}]$	خطای مربع مورد انتظار را کمینه می‌کند
میانه‌ی پسین	صدک ۵۰	در برابر چولگی مقاوم است
MAP	$\arg\max_\theta p(\theta \mid \mathbf{y})$	تحت پیشین تخت با MLE برابر است
انحراف معیار پسین	$\sqrt{\mathrm{Var}[\theta \mid \mathbf{y}]}$	همتای بیزی SE
بازه‌ی دم‌برابر ٪۹۵	صدک ۵.۲ تا ۵.۹۷	محاسبه‌اش آسان است
HDI ٪۹۵ (بازه‌ی بیشترین چگالی)	باریک‌ترین بازه‌ای که ٪۹۵ پسین را در بر دارد؛ هر مقدار داخل آن از هر مقدار بیرونش محتمل‌تر است	برای پسین‌های چوله ترجیح دارد

credible interval در برابر بازه‌ی اطمینان. ٪۹۵ credible interval واقعاً یعنی «با توجه به مدل، پیشین و داده، پارامتر با احتمال ۹۵.۰ در این بازه است». بازه‌ی اطمینان گزاره‌ای درباره‌ی رفتار بلندمدت یک رویه است (هفته‌ی ۵). با پیشین‌های ضعیف و داده‌ی کافی، این دو اغلب از نظر عددی یکی می‌شوند، ولی تفسیرشان فرق دارد.

احتمال پسین فرضیه‌ها مجانی به دست می‌آید: $P(d' > 1 \mid \mathbf{y})$ فقط جرم پسین بالای ۱ است.

۶. بررسی‌های پیش‌بینی پیشین (prior predictive checks)

توزیع پیش‌بینی پیشین داده‌هایی را توصیف می‌کند که مدل پیش از دیدن هر داده‌ای انتظار دارد:

$$p(\mathbf{y}^{\text{rep}}) = \int p(\mathbf{y}^{\text{rep}} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, d\boldsymbol{\theta}.$$

برای شبیه‌سازی از آن: $\boldsymbol{\theta}$ را از پیشین بکشید و بعد از مدل داده شبیه‌سازی کنید. اگر داده‌های شبیه‌سازی‌شده پوچ به نظر برسند (مثلاً تقریباً همه‌ی نرخ‌های hit دقیقاً ۰ یا ۱، یا یادآوری‌ای که طی یک ماه بیشتر می‌شود)، پیشین نامعقول است. بررسی‌های پیش‌بینی پیشین نسخه‌ی بیزی عادت «پیش از برازش شبیه‌سازی کن» هفته‌ی ۲ هستند.

پیشرفته: پسین به‌عنوان پیشین به‌روزشده. چون برای داده‌های مستقل $p(\boldsymbol{\theta} \mid \mathbf{y}_1, \mathbf{y}_2) \propto p(\mathbf{y}_2 \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta} \mid \mathbf{y}_1)$، پسین امروز پیشین فرداست. پس به‌روزرسانی بیزی ذاتاً ترتیبی است، و به همین دلیل استنباط بیزی یک مدل هنجاری محبوب برای یادگیری است (هفته‌ی ۱۵).

برای یک مهندس

- این همان **تخمین بیزی** در نظریه‌ی آشکارسازی و تخمین است: posterior چیزی است که تخمین‌گر MAP یا MMSE با آن کار می‌کند. میانگین posterior همان **تخمین** MMSE است؛ مد posterior **تخمین** MAP است؛ با prior صاف، ML. = MAP
- **به‌روزرسانی** conjugate **بتا–دوجمله‌ای** همان ایده‌ی به‌روزرسانی conjugate گاوسی است، یعنی هسته‌ی اسکالر **فیلتر کالمن** (میانگین و واریانس prior + اندازه‌گیری ← میانگین و واریانس (posterior، فقط اینجا برای یک احتمال به جای یک حالت گاوسی.
- **به‌روزرسانی ترتیبی** posterior») امروز prior فرداست») دقیقاً همان فیلترینگ بیزی بازگشتی است.
- تفاوت در روان‌شناسی: prior معمولاً **ضعیف** است و باید برای خواننده توجیه شود، و خروجی اصلی یک تصمیم نیست، بلکه توصیف عدم قطعیت درباره‌ی یک پارامتر روان‌شناختی است. بررسی پیش‌بینی پیشین (prior predictive check) عادتی است که priorها را قابل دفاع می‌کند.

برای مدرس

- grid **چهارنقطه‌ای را روی تخته انجام دهید** (مثال حل‌شده، بخش ۱) با ستون‌هایی برای prior، درست‌نمایی، حاصل‌ضرب و posterior. کل استنباط بیزی در همین یک جدول است. بعد prior را به (۱.۰، ۱.۰، ۴.۰، ۴.۰) تغییر دهید و زنده دوباره حساب کنید: دانشجوها اثر prior را می‌بینند.
- **از داستان شمارش‌های ساختگی** Beta **استفاده کنید.** prior» برابر Beta(2, ۲) مثل این است که قبلاً ۲ یادآوری و ۲ شکست دیده باشیم.» دانشجوهایی که prior را دلبخواهی می‌دانند، وقتی آن را داده‌ی خیالی ببینند آرام می‌شوند.
- **مستقیماً به نگرانی «ذهنی بودن» جواب دهید.** هر تحلیلی فرض دارد (درست‌نمایی هم یک فرض است)؛ تحلیل بیزی یکی دیگر از فرض‌ها را صریح می‌کند، و تحلیل حساسیت (هفته‌ی ۱۰) بررسی می‌کند که چقدر مهم است.
- **سؤال‌های رایج.**
  - «کدام *prior* درست است؟» هیچ‌کدام تنها جواب درست نیست. از priorهای weakly informative استفاده کنید، آن‌ها را با شبیه‌سازی پیش‌بینی پیشین بررسی کنید و حساسیت را گزارش کنید.
  - «آیا *credible interval* همان بازه‌ی اطمینان است؟» با prior ضعیف و داده‌ی کافی اغلب از نظر عددی شبیه‌اند، ولی فقط credible interval یعنی «با احتمال ۹۵٪ پارامتر اینجاست».
  - «پس مغز بیزی است؟» این سؤال دیگری است (هفته‌ی ۱۵). این هفته بیز ابزاری برای پژوهشگر است.

۵.۱.۴ مثال حل‌شده

بخش ۱: یک شبکه‌ی چهارنقطه‌ای با دست

یک شرکت‌کننده $y = 7$ از $n = 10$ آیتم را به یاد می‌آورد. برای ساده نگه داشتن حساب، فرض کنید θ فقط می‌تواند مقادیر ۲.۰، ۴.۰، ۶.۰ یا ۸.۰ را بگیرد، هرکدام با احتمال پیشین ۱/۴.

θ	پیشین	درست‌نمایی $\theta^7(1-\theta)^3$ (بدون ثابت)	پیشین × درست‌نمایی	پسین
۲.۰	۲۵.۰	۰۰۰۰۰۶۶.۰	۰۰۰۰۰۱۶.۰	**۰۰۲.۰**
۴.۰	۲۵.۰	۰۰۰۳۵۳۹.۰	۰۰۰۰۸۸۵.۰	**۰۹۲.۰**
۶.۰	۲۵.۰	۰۰۱۷۹۱۶.۰	۰۰۰۴۴۷۹.۰	**۴۶۸.۰**
۸.۰	۲۵.۰	۰۰۱۶۷۷۷.۰	۰۰۰۴۱۹۴.۰	**۴۳۸.۰**
جمع	۱		۰۰۰۹۵۷۴.۰	۰۰۰.۱

هر مقدار پسین = (پیشین × درست‌نمایی) / جمع. ضریب دوجمله‌ای حذف شد چون در نرمال‌سازی ساده می‌شود. تفسیر: بعد از داده، ۶.۰ و ۸.۰ تقریباً به یک اندازه محتمل‌اند و ۲.۰ عملاً کنار گذاشته شده است.

بخش ۲: همان داده با یک پیشین Beta پیوسته

پیشین $\mathrm{Beta}(2,2)$ (میانگین ۵.۰، با ترجیح ملایم برای مقادیر میانی). پسین: $\mathrm{Beta}(2+7, 2+3) = \mathrm{Beta}(9,5)$.

- میانگین پسین $9/14 = 0.643$ ≔ بین میانگین پیشین (۵.۰) و نسبت مشاهده‌شده (۷.۰)، نزدیک‌تر به داده چون $n = 10 > a_0 + b_0 = 4$.
- MAP (مُد) $= (9-1)/(9+5-2) = 0.667$ ≕.
- ۹۵٪ credible interval دم‌برابر $= [0.386, 0.861]$ ≕.

تفسیر. با یک پیشین ملایم و ۱۰ آیتم، احتمال یادآوری احتمالاً حدود ۶۴.۰ است، ولی هر مقداری از حدود ۳۹.۰ تا ۸۶.۰ هنوز credible است. ده آیتم چیز زیادی به ما نمی‌گوید.

بخش ۳: با داده‌ی بیشتر پیشین کمتر مهم است

با $y = 30$ از $n = 50$:

پیشین	پسین	میانگین	۹۵٪ credible interval
$\mathrm{Beta}(1,1)$ (تخت)	$\mathrm{Beta}(31, 21)$	۵۹۶.۰	[۷۲۴.۰ ،۴۶۱.۰]
$\mathrm{Beta}(0.5, 0.5)$ (Jeffreys)	$\mathrm{Beta}(30.5, 20.5)$	۵۹۸.۰	[۷۲۷.۰ ،۴۶۲.۰]
$\mathrm{Beta}(20, 5)$ (آگاهی‌بخش، «≈ ۸.۰»)	$\mathrm{Beta}(50, 25)$	۶۶۷.۰	[۷۶۸.۰ ،۵۵۷.۰]

پیشین‌های تخت و Jeffreys عملاً یک جواب می‌دهند که با بازه‌ی profile likelihood هفته‌ی ۵، [۴۶۲.۰، ۷۲۸.۰]، هم برابر است. پیشین آگاهی‌بخش، که ارزشش ۲۵ مشاهده‌ی کاذب است، هنوز برآورد را به‌طور قابل توجهی به سمت ۸.۰ می‌کشد: ۵۰ مشاهده برای غلبه بر یک پیشین قوی کافی نیست. اینکه این خوب است یا نه به درست بودن دانش پیشین بستگی دارد.

۶.۱.۴ lab (۲ ساعت)

اهداف

۱. محاسبه‌ی پسین‌های beta-binomial به‌صورت تحلیلی و با تقریب شبکه‌ای، و دیدن مصالحه‌ی پیشین و داده.
۲. تماشای تیزتر شدن پسین با داده (به‌روزرسانی ترتیبی).
۳. محاسبه‌ی پسین شبکه‌ای دوبعدی برای SDT (d'، c)؛ خلاصه کردن آن با میانگین‌ها، HDIها و احتمال‌های پسین.
۴. استفاده از شبیه‌سازی پیش‌بینی پیشین برای افشای یک پیشین «مبهم» بد.

زمان‌بندی: بخش A ۲۵ دقیقه · بخش B ۱۵ دقیقه · بخش C ۴۰ دقیقه · بخش D ۲۵ دقیقه · بخش E ۱۵ دقیقه.

آماده‌سازی

Code · **کد:** `code/week09.py`، cell ۱ · سلول ۱

بخش A: beta-binomial، تحلیلی و روی شبکه (۲۵ دقیقه)

Code · **کد:** `code/week09.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
flat Beta(1,1)            grid mean = 0.5962, exact mean = 0.5962, 95% CI
↪  = [0.461 0.724]
Jeffreys Beta(.5,.5)      grid mean = 0.5980, exact mean = 0.5980, 95% CI
↪  = [0.462 0.727]
informative Beta(20,5)    grid mean = 0.6667, exact mean = 0.6667, 95% CI
↪  = [0.557 0.768]
```

پسین‌های شبکه‌ای و دقیق بر هم منطبق‌اند. ببینید هر پسین نسبت به پیشین و درست‌نمایی خودش کجا قرار می‌گیرد.

بخش B: به‌روزرسانی ترتیبی (۱۵ دقیقه)

Code · **کد:** `code/week09.py`، cell ۳ · سلول ۳

به این دقت کنید: پسین از خود پیشین شروع می‌شود، با جمع شدن آیتم‌ها باریک می‌شود و حول مقدار واقعی متمرکز می‌شود. پهنایش تقریباً مثل $1/\sqrt{n}$ کم می‌شود، همان‌طور که SE در هفته‌ی ۵ کم می‌شد.

بخش C: یک پسین شبکه‌ای دوپارامتری برای SDT (۴۰ دقیقه)

شرکت‌کننده‌ی هفته‌ی ۲: ۶۸ hit از ۱۰۰ trial علامت و ۱۱ false alarm از ۱۰۰ trial نویز. پیشین‌ها: $d' \sim \mathcal{N}(1, 1.5)$ (حساسیت معمولاً مثبت و به‌ندرت بالای ۴ است) و $c \sim \mathcal{N}(0, 1)$ (سوگیری معمولاً متوسط است).

Code · **کد:** `code/week09.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
    post. mean  post. SD    MAP  95% HDI low  95% HDI high
d'       1.688     0.209  1.675        1.250         2.062
c        0.376     0.106  0.375        0.163         0.575
MLE (uncorrected formulas): d' = 1.694, c = 0.379
P(d' > 1 | data) = 1.000;  P(c > 0 | data) = 1.000
Posterior correlation of d' and c: 0.245
```

(«۰.۰۰۰۱» یعنی هیچ‌کدام از ۲۰ ۰۰۰ نمونه‌ی پسین زیر آستانه نیفتادند، پس احتمال < 0.9999 است. آن را همین‌طور گزارش کنید، نه به‌عنوان قطعیت.)

تفسیر (در notebook بنویسید): ۱. میانگین پسین و MAP در مقایسه با MLE چطورند؟ چرا اینجا این‌قدر نزدیک‌اند؟ ۲. HDI مربوط به d' و $P(c > 0 \mid \text{data})$ را هرکدام به یک جمله‌ی ساده درباره‌ی این شرکت‌کننده ترجمه کنید. ۳. انحراف معیار پیشین d' را به ۱۰ افزایش دهید، بعد به ۳.۰ کم کنید (با مرکز ۱). کدام خلاصه‌ها تغییر می‌کنند و چقدر؟

بخش D: بررسی‌های پیش‌بینی پیشین (۲۵ دقیقه)

پیش از اعتماد به یک پیشین، به داده‌هایی که نتیجه می‌دهد نگاه کنید. پیشین ما را با یک پیشین «مبهم»، $d' \sim \mathcal{N}(0, 10)$ و $c \sim \mathcal{N}(0, 10)$، مقایسه کنید که گاهی به این دلیل استفاده می‌شود که «بی‌اطلاع» است.

Code · **کد:** `code/week09.py`، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
our prior: d'~N(1,1.5), c~N(0,1): 14% of simulated datasets have a rate
↪  of exactly 0 or 1; 24% have H < F
'vague' prior: d'~N(0,10), c~N(0,10): 96% of simulated datasets have a
↪  rate of exactly 0 or 1; 23% have H < F
```

به این دقت کنید: پیشین «مبهم» اصلاً خنثی نیست. روی مقیاس احتمال، ٪۹۶ مجموعه‌داده‌های شبیه‌سازی‌شده را در نرخ hit یا false alarm دقیقاً ۰ یا ۱ قرار می‌دهد؛ چیزی که در آزمایش‌های تشخیص واقعی عملاً هرگز اتفاق نمی‌افتد. این پیشین باوری قوی و پوچ درباره‌ی داده بیان می‌کند. ابهام روی مقیاس پارامتر، ابهام روی مقیاس داده نیست.

پیشین خود ما هم کامل نیست: حدود یک‌چهارم مجموعه‌داده‌های شبیه‌سازی‌شده‌اش $H < F$ دارند، چون $\mathcal{N}(1, 1.5)$ حدود ٪۲۵ جرمش را روی d' منفی می‌گذارد. برای تکلیفی که می‌دانیم شرکت‌کننده‌ها بالاتر از شانس عمل می‌کنند، پیشینی محدود به $d' > 0$ (مثلاً نیم‌نرمال یا Gamma) قابل دفاع‌تر است. امتحانش کنید و ببینید آیا پسین این شرکت‌کننده را تغییر می‌دهد. (راهنمایی: با ۲۰۰ trial آگاهی‌بخش، تقریباً نه.)

بخش E: تفسیر (۱۵ دقیقه)

یک «پاراگراف نتایج» کوتاه (۴ تا ۶ جمله) برای این شرکت‌کننده بنویسید، طوری که در یک مقاله می‌آید. پیشین‌ها، میانگین‌های پسین و HDIهای ٪۹۵ برای d' و c، $P(d' > 1 \mid \text{data})$، و یک جمله درباره‌ی حساسیت به پیشین (از سؤال ۳ بخش C) را گزارش کنید.

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. به‌صورت جبری نشان دهید که میانگین پسین مدل beta-binomial میانگین وزنی میانگین پیشین و y/n است. وزن‌ها چیستند؟

تمرین ۲ ⋆. با شبکه‌ی بخش A، HDI ٪۹۵ و بازه‌ی دم‌برابر را برای $\text{Beta}(1+2, 1+18)$ (۲ موفقیت از ۲۰) حساب کنید. چرا با هم فرق دارند؟

تمرین ۳ ⋆⋆ **(فراموشی با شبکه).** پسین شبکه‌ای (A, d) را برای مدل فراموشی توانی با داده‌های هفته‌ی ۲، با پیشین‌های $A \sim \text{Beta}(8, 2)$ و $d \sim \text{Gamma}(\text{shape } 2, \text{scale } 0.3)$ حساب کنید. میانگین‌های پسین و HDIهای ٪۹۵ را با MLE و بازه‌های profile و bootstrap هفته‌ی ۵ مقایسه کنید.

تمرین ۴ ⋆⋆ **(هم‌ارزی MAP و MLE).** در بخش C هر دو پیشین را با پیشین‌های تخت روی شبکه جایگزین کنید. نشان دهید MAP برابر MLE است. چرا میانگین پسین هنوز کمی فرق دارد؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: ترتیبی در برابر یکجا).** برای مدل SDT، پسین شبکه‌ای را trial به trial (پسین هر trial پیشین trial بعدی است) برای ۲۰۰ trial شبیه‌سازی‌شده به‌روز کنید و نشان دهید پسین نهایی (تا حد خطای عددی) با پسین یکجای همه‌ی trialها یکی است. انحراف معیار پسین d' را در برابر تعداد trialها رسم کنید.

lab check-off

نشان دهید: (۱) نمودار سه‌قسمتی پیشین/درست‌نمایی/پسین از بخش A، (۲) جدول خلاصه‌ی SDT و پسین مشترک از بخش C، و (۳) دو نمودار پیش‌بینی پیشین از بخش D با یک جمله درباره‌ی اینکه پیشین مبهم چه مشکلی دارد.

۷.۱.۴ ارتباط با هوش مصنوعی و LLMها

مدل واقعاً چقدر خوب است؟ یک جواب بیزی برای ارزیابی‌های کوچک. پژوهشگرها اغلب یک LLM را روی مجموعه‌ی کوچکی از آیتم‌ها، مثلاً ۲۵ مسئله‌ی دست‌نویس، می‌آزمایند. مدل beta-binomial این هفته همان چیزی را می‌دهد که چنین مطالعه‌هایی معمولاً ندارند: یک پسین کامل برای دقت، گزاره‌های احتمالی مستقیم («احتمال اینکه دقت از ٪۶۰ بیشتر باشد») و مقایسه‌ی مستقیم دو مدل.

Code ۰ **کد:** `code/week09.py`، cell ۶ ۰ سلول ۶

خروجی مورد انتظار:

```
Model A: posterior mean = 0.704, 95% interval = [0.522, 0.857],
 ↪  P(accuracy > 0.6) = 0.878
Model B: posterior mean = 0.593, 95% interval = [0.406, 0.766],
 ↪  P(accuracy > 0.6) = 0.479
P(A more accurate than B | data) = 0.807
```

با ۲۵ آیتم، پهنای بازه‌های پسین حدود ۰.۳۵ است، و احتمال پسین ٪۱۹ وجود دارد که در واقع B مدل بهتر باشد.

امتحانش کنید (بدون نیاز به API). ⋆ - یک پیشین آگاهی‌بخش از یک ارزیابی قبلی و بزرگ‌تر استفاده کنید (مثلاً Beta(14, 6)) برای مدل A. نتیجه‌گیری‌ها چقدر عوض می‌شوند؟ - ⋆⋆ مقایسه‌ی بالا دو مدل را مستقل در نظر می‌گیرد، با اینکه به همان آیتم‌ها جواب داده‌اند. چرا این مشکل است (کادر هفته‌ی ۵ را ببینید)؟ طرح کلی مدلی را بکشید که جفت بودن را رعایت کند. - ⋆⋆ بحث: برای دقت یک مدل کاملاً تازه روی یک آزمون چهارگزینه‌ای چه پیشینی استفاده می‌کنید، و چرا نباید جرم زیادی زیر ۰.۲۵ بگذارد؟

۸.۱.۴ اشتباهات رایج و برداشت‌های نادرست

۱. **«پیشین استنباط بیزی را ذهنی و نتایج را دلبخواهی می‌کند.»** پیشین‌ها فرض‌های صریح‌اند، درست مثل انتخاب درست‌نمایی. گزارششان کنید، توجیهشان کنید و حساسیت را بررسی کنید. با داده‌ی کافی، پیشین‌های معقول به نتیجه‌گیری‌های مشابه می‌رسند.

۲. **«پیشین‌های تخت یا خیلی پهن بی‌اطلاع‌اند.»** می‌توانند روی مقیاس داده به‌شدت آگاهی‌بخش باشند (بخش D). از پیشین‌های ضعیف‌آگاهی‌بخش استفاده کنید و با شبیه‌سازی پیش‌بینی پیشین بررسی‌شان کنید.

۳. **انتخاب پیشین بعد از نگاه کردن به داده.** این یعنی دو بار استفاده از داده.

۴. **ضرب احتمال‌ها روی شبکه بدون لگاریتم،** که سرریز می‌کند (هفته‌ی ۴). با لگاریتم پیشین + لگاریتم درست‌نمایی کار کنید و پیش از نمایی گرفتن بیشینه را کم کنید.

۵. **شبکه‌ی خیلی درشت یا خیلی باریک.** اگر پسین در لبه‌ی شبکه بریده شود، همه‌ی خلاصه‌ها غلط‌اند. بررسی کنید که پسین در لبه‌ها نزدیک صفر باشد.

۶. **خواندن credible interval به جای بازه‌ی اطمینان یا برعکس.** فقط جمله‌ی «با احتمال ٪۹۵ پارامتر اینجاست» (با توجه به مدل و پیشین) را پشتیبانی می‌کند.

۷. **فقط گزارش MAP.** نکته‌ی پسین کل توزیع است. یک مقدار مرکزی و یک بازه، و احتمال فرضیه‌هایی را که برایتان مهم‌اند گزارش کنید.

۹.۱.۴ خودآزمایی

۱. قاعده‌ی بیز را برای پارامتر θ بنویسید و هر جمله را نام ببرید. **پاسخ** $p(\theta \mid y) = p(y \mid \theta)p(\theta)/p(y)$: پسین = درست‌نمایی × پیشین / شواهد (marginal likelihood). برای برآورد، $p(\theta \mid y) \propto p(y \mid \theta)p(\theta)$.

۲. پیشین $\mathrm{Beta}(3,3)$، داده: ۱۲ یادآوری از ۲۰. پسین و میانگینش چیست؟ **پاسخ** $\mathrm{Beta}(3+12, 3+8) = \mathrm{Beta}(15, 11)$، با میانگین $15/26 = 0.577$.

۳. چرا با افزایش n پسین به MLE نزدیک‌تر می‌شود؟ **پاسخ** لگاریتم درست‌نمایی مجموعی روی مشاهدات است و با n بزرگ می‌شود، در حالی که لگاریتم پیشین ثابت می‌ماند. با داده‌ی زیاد درست‌نمایی بر حاصل‌ضرب غالب می‌شود و پسین حول بیشینه‌ی درست‌نمایی متمرکز می‌شود.

۴. تفاوت HDI ٪۹۵ و بازه‌ی دم‌برابر ٪۹۵ چیست؟ کی بر هم منطبق‌اند؟ **پاسخ** HDI باریک‌ترین بازه‌ای است که ٪۹۵ جرم پسین را در بر دارد و هر مقدار داخلش چگالی بیشتری از هر مقدار بیرونش دارد. بازه‌ی دم‌برابر از هر دم ٪۲.۵ را می‌بُرد. برای پسین‌های متقارن تک‌مُدی بر هم منطبق‌اند و برای پسین‌های چوله فرق دارند.

۵. چرا تقریب شبکه‌ای برای مدل‌هایی با پارامترهای زیاد غیرعملی می‌شود؟ **پاسخ** تعداد نقاط شبکه با تعداد پارامترها به‌طور نمایی رشد می‌کند (مثلاً ۱۰۰ نقطه برای هر پارامتر یعنی 100^k ارزیابی). این نفرین ابعاد است. نمونه‌گیری MCMC (هفته‌های ۱۱–۱۳) از آن دوری می‌کند.

۶. همکاری «برای احتیاط» از $d' \sim \mathcal{N}(0, 100)$ استفاده می‌کند. برای قانع کردنش که این ایده‌ی بدی است چه می‌کنید؟ **پاسخ** یک شبیه‌سازی پیش‌بینی پیشین: نشان دهید این پیشین نرخ‌های hit و false alarmی نتیجه می‌دهد که تقریباً همیشه دقیقاً ۰ یا ۱ هستند؛ باوری پوچ درباره‌ی داده‌ی تشخیص واقعی. به‌جایش یک پیشین ضعیف‌آگاهی‌بخش پیشنهاد کنید.

۷. این جمله را توضیح دهید: «تصحیح log-linear برای نرخ‌های حدی یک برآورد بیزی است». **پاسخ** نرخ تصحیح‌شده‌ی $(y + 0.5)/(n + 1)$ برابر میانگین پسین θ تحت پیشین $\text{Beta}(0.5, 0.5)$ است: $(0.5 + y)/(0.5 + 0.5 + n)$. این تصحیح به‌طور ضمنی از هر نوع نیم مشاهده‌ی کاذب اضافه می‌کند.

۱۰.۱.۴ تکلیف

- A3 **(مقایسه و بازیابی مدل)** و **پیشنهاد پروژه** در ابتدای درس این هفته تحویل داده می‌شوند.
- این هفته تکلیف نمره‌دار جدیدی نداریم. A4 **(تحلیل بیزی با شبکه)** در هفته‌ی ۱۰ منتشر می‌شود.
- **تمرین اختیاری (بدون نمره):** تمرین ۳ lab (فراموشی با شبکه) هسته‌ی A4 است. اگر الان شروعش کنید در وقتتان صرفه‌جویی می‌شود.

۱۱.۱.۴ مطالعه‌ی بیشتر

- Kruschke **(۲۰۱۴)، فصل‌های ۵–۶.** قاعده‌ی بیز، و استنباط یک احتمال دوجمله‌ای با تحلیل ریاضی دقیق (مدل beta-binomial). خیلی ساده و تصویری. (منبع اصلی.)
- Wagenmakers & Lee **(۲۰۱۴)، فصل‌های ۱ و ۳.** مبانی تحلیل بیزی، و استنباط با توزیع دوجمله‌ای.
- Lao & Martin, Kumar **(۲۰۲۱)، فصل ۱.** استنباط بیزی: اجزای یک مدل بیزی و توزیع‌های پیش‌بینی پیشین/پسین، همراه با کد Python.
- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۶.** برآورد بیزی پارامتر: مفاهیم پایه، مرتبط با چارچوب درست‌نمایی هفته‌ی ۴.
- **عظیمی‌فر و احمدی (۱۳۹۶)،** جلد ۱: بخش برآورد بیزی پارامتر و ارتباطش با برآورد ML [شماره‌ی فصل بررسی شود].

پیش‌نمایش هفته‌ی ۱۰: پسین درباره‌ی پارامترها درون یک مدل حرف می‌زند. هفته‌ی بعد می‌پرسیم داده‌ها باور ما را بین مدل‌ها چطور تغییر می‌دهند، با استفاده از شواهد $p(\mathbf{y} \mid \mathcal{M})$ که تا حالا به‌عنوان ثابت نرمال‌ساز نادیده‌اش گرفته‌ایم، و چطور بررسی کنیم که پیش‌بینی‌های پسین یک مدل شبیه داده‌ی واقعی هستند یا نه.

۲.۴ هفته‌ی ۱۰: مدل‌سازی بیزی ۲: بررسی پیش‌بینی پسین و Bayes factor

فصل ۴: مدل‌سازی بیزی (همراه با فصل ۳: ارزیابی) · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌های فراموشی هفته‌ی ۲ (نمایی در برابر توانی)، و یک شرکت‌کننده‌ی SDT با شواهد ضعیف (آیا $d' = 0$ است؟).

۱.۲.۴ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
posterior	توزیع پسین (posterior)	باور درباره‌ی پارامتر بعد از دیدن داده
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
evidence	شواهد	اطلاعاتی که برای تصمیم جمع می‌شود
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
posterior predictive check (PPC)	بررسی پیش‌بینی پسین	مقایسه‌ی داده‌ی شبیه‌سازی‌شده از پسین با داده‌ی واقعی
evidence / marginal likelihood	درست‌نمایی حاشیه‌ای	احتمال داده تحت مدل، میانگین روی پیشین
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
Bayes factor (BF)	عامل بیز (Bayes factor)	نسبت درست‌نمایی‌های حاشیه‌ای دو مدل
complexity / model flexibility	انعطاف‌پذیری / پیچیدگی مدل	دامنه‌ی الگوهایی که مدل می‌تواند تولید کند
grid approximation	تقریب شبکه‌ای (grid)	محاسبه‌ی پسین روی شبکه‌ای از مقادیر
Savage–Dickey ratio	نسبت Savage–Dickey	BF از نسبت چگالی پسین به پیشین در مقدار صفر
BIC / AIC	معیار اطلاعاتی آکائیکه / بیزی	برازش به‌علاوه‌ی جریمه برای تعداد پارامتر
prior	توزیع پیشین (prior)	باور درباره‌ی پارامتر پیش از دیدن داده
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
posterior odds	بخت پسین (odds)	نسبت احتمال پسین دو مدل
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود

English	فارسی	توضیح کوتاه
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
noise	نویز	تغییرات تصادفی در شواهد یا در داده
adequacy check	بررسی کفایت مدل	آیا مدل ویژگی‌های اصلی داده را بازتولید می‌کند
nested models	مدل‌های تودرتو (nested)	یک مدل حالت خاص مدل دیگر است
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
accuracy	دقت	نسبت پاسخ‌های درست

۲.۲.۴ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. توزیع‌های پیش‌بینی پسین را **تولید کنند** و بررسی‌های پیش‌بینی پسین (PPC) نموداری و عددی **انجام دهند**.
۲. marginal likelihood و Bayes factor را **تعریف کنند** و **توضیح دهند** چرا marginal likelihood انعطاف مدل را خودکار جریمه می‌کند.
۳. Bayes factor را با انتگرال‌گیری شبکه‌ای و با نسبت چگالی Savage–Dickey **حساب کنند** و با تقریب BIC **مقایسه کنند**.
۴. حساسیت Bayes factor به پیشین را **ارزیابی کنند** و آن را با پایداری برآوردهای پسین **مقایسه کنند**.
۵. Bayes factorها را روی یک مقیاس درجه‌بندی‌شده‌ی شواهد **تفسیر کنند** و با بخت‌های پیشین **ترکیب کنند** تا احتمال‌های پسین مدل‌ها به دست آید.

۳.۲.۴ مقدمه

هفته‌ی قبل پسین‌ها را درون یک مدل به دست آوردیم. دو سؤال باقی مانده است.

۱. آیا مدل اصلاً خوب است؟ یک پسین می‌تواند باریک و مطمئن باشد حتی وقتی مدل به‌شدت غلط است: مدل نمایی با کمال میل برای داده‌های هفته‌ی ۲ یک پسین دقیق برای λ می‌دهد. جواب بیزی این است که از مدل برازش‌شده بخواهیم **داده‌ی جدید تولید کند** و ببینیم شبیه داده‌ی واقعی است یا نه. این یک بررسی پیش‌بینی پسین (posterior predictive check) است؛ همتای بیزی نمودار باقی‌مانده‌ها و G^2.

۲. داده‌ها از کدام مدل بیشتر پشتیبانی می‌کنند؟ در هفته‌ی ۷ مدل‌ها را با AIC و BIC مقایسه کردیم که تعداد پارامترها را جریمه می‌کنند. استنباط بیزی جوابی داخلی دارد: حساب کنیم هر مدل پیش از برازش داده‌ها را چقدر خوب پیش‌بینی کرده بود، با میانگین‌گیری روی همه‌ی مقادیر پارامتری که پیشینش اجازه می‌دهد. این marginal likelihood است، و نسبت دو marginal likelihood Bayes factor است. یک مدل منعطف پیش‌بینی‌هایش را روی مجموعه‌داده‌های ممکن زیادی پخش می‌کند، پس به هرکدام احتمال کمتری می‌دهد. بنابراین Bayes factor تیغ اوکام را خودکار اجرا می‌کند، و به انعطاف شکل تابعی پاسخ می‌دهد، نه فقط به k.

Bayes factorها برای آزمون فرض صفر هم استفاده می‌شوند («آیا حساسیت صفر است؟»). برخلاف مقدار p، می‌توانند شواهد **به نفع** فرض صفر را هم کمّی کنند.

این موضوع کجا به کار می‌رود؟

- **شاهد برای «بدون اثر».** مطالعه‌های تکرار (replication) اغلب می‌پرسند آیا یک اثر وجود ندارد. p-value نمی‌تواند از فرض صفر پشتیبانی کند؛ Bayes factor می‌تواند («داده تحت فرض بدون اثر ۸ برابر محتمل‌تر است»).
- **مجله‌ها و نرم‌افزارهای روان‌شناسی:** Bayes factorها با ابزارهایی مثل JASP و بسته‌ی BayesFactor در R به‌طور معمول گزارش می‌شوند؛ هم برای t-test، ANOVA و همبستگی و هم برای مدل‌های شناختی.
- **بررسی مدل در هر تحلیل بیزی:** posterior predictive check گامی استاندارد پیش از اعتماد به هر نتیجه است (مثلاً در کارآزمایی‌های بالینی که به روش بیزی تحلیل می‌شوند و در مقاله‌های مدل‌سازی شناختی).
- **مقایسه‌ی نظریه‌هایی با انعطاف متفاوت:** وقتی دو مدل تعداد پارامتر یکسانی دارند ولی یکی می‌تواند الگوهای داده‌ی خیلی بیشتری بسازد، Bayes factor یکی از معدود ابزارهایی است که این را می‌بیند.

۴.۲.۴ جزوه‌ی درس

به زبان ساده این هفته دو سؤال جدا داریم. **(۱) آیا مدل من به اندازه‌ی کافی خوب است؟** بگذارید مدل برازش‌شده داده‌ی تازه تصور کند: مقدارهای معقول پارامتر را از posterior بردارید، یک آزمایش تازه شبیه‌سازی کنید و این کار را بارها تکرار کنید. اگر داده‌ی واقعی شبیه یک داده‌ی تصوری معمولی باشد، مدل کافی است؛ اگر داده‌ی واقعی بیرون از ابر داده‌های تصوری باشد، مدل چیزی را از قلم انداخته است. این یک posterior predictive check است. **(۲) داده از کدام‌یک از دو مدل بیشتر پشتیبانی می‌کند؟** از هر مدل بپرسید، پیش از برازش، داده‌ای را که واقعاً به دست آوردیم چقدر محتمل می‌دانست، با میانگین گرفتن روی همه‌ی مقدارهای پارامتری که prior آن اجازه می‌دهد. این عدد marginal likelihood است و نسبت آن برای دو مدل Bayes factor است. مدلی که روی همه‌چیز شرط می‌بندد (خیلی منعطف) باید شرط‌هایش را پخش کند، پس وقتی داده جایی می‌افتد که مدل ساده‌تر روی آن شرط بسته بود، کمتر برنده می‌شود. این همان تیغ اوکام است که در نظریه‌ی احتمال تعبیه شده. نکته‌ی مهم: Bayes factor به prior بستگی دارد، پس باید گزارش کنید که با priorهای معقول چطور تغییر می‌کند.

زمان‌بندی پیشنهادی (۶۰ دقیقه): بررسی پیش‌بینی پسین ۱۵ · marginal likelihood و Bayes factor ۲۰ · محاسبه‌ی Bayes factor (شبکه، BIC، Savage–Dickey) ۱۵ · حساسیت به پیشین و مقایسه‌ی روش‌ها ۱۰.

۱. بررسی‌های پیش‌بینی پسین

توزیع پیش‌بینی پسین داده‌ی جدید $\mathbf{y}^{\text{rep}}$ را که مدل برازش‌شده انتظار دارد توصیف می‌کند:

$$p(\mathbf{y}^{\text{rep}} \mid \mathbf{y}) = \int p(\mathbf{y}^{\text{rep}} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta} \mid \mathbf{y})\, d\boldsymbol{\theta}.$$

دستور شبیه‌سازی: برای $s = 1, \dots, S$، $\boldsymbol{\theta}^{(s)}$ را از پسین بکشید و یک مجموعه‌داده‌ی $\mathbf{y}^{\text{rep}(s)}$ از مدل با طرح آزمایش واقعی شبیه‌سازی کنید. این کار هم عدم قطعیت پارامترها و هم نویز نمونه‌گیری را منتقل می‌کند.

بررسی‌ها: - **نموداری:** داده‌ی مشاهده‌شده را روی بازه‌های پیش‌بینی (مثلاً ۹۵٪ مرکزی y^{rep} در هر شرط) رسم کنید. انحراف‌های نظام‌مند (نقاط مشاهده‌شده که مرتب بیرون نوارها یا در یک سمتشان‌اند) نشان می‌دهند مدل کجا شکست می‌خورد. - **عددی:** یک آماره‌ی آزمون $T(\mathbf{y})$ انتخاب کنید که ویژگی مورد نظرتان را نشان دهد (مثلاً یادآوری در طولانی‌ترین فاصله‌ها، تندی افت اولیه). **مقدار p پیش‌بینی پسین** برابر است با $p_B = P\big(T(\mathbf{y}^{\text{rep}}) \geq T(\mathbf{y}) \mid \mathbf{y}\big)$. مقادیر نزدیک ۰ یا ۱ نشان می‌دهند مدل نمی‌تواند این ویژگی را بازتولید کند.

PPCها کفایت **مطلق** را می‌سنجند، یعنی اینکه مدل به اندازه‌ی کافی خوب است یا نه، نه اینکه کدام از دو مدل بهتر است. گام همیشگی هر تحلیل بیزی‌اند (هفته‌ی ۱۳).

خواندن ریاضی

- $\mathbf{y}^{\text{rep}}$: داده‌ی «تکرارشده»، یک تکرار تصوری از آزمایش.
- $\int p(\mathbf{y}^{\text{rep}} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta} \mid \mathbf{y})\, d\boldsymbol{\theta}$: پیش‌بینی‌های مدل را روی همه‌ی مقدارهای پارامتر میانگین بگیر، هرکدام با وزن معقول بودنش در posterior. در عمل این انتگرال با دستور شبیه‌سازی دومرحله‌ای جایگزین می‌شود: $\boldsymbol{\theta}$ را از posterior بکش و بعد با آن داده شبیه‌سازی کن.
- $p_B = P(T(\mathbf{y}^{\text{rep}}) \geq T(\mathbf{y}) \mid \mathbf{y})$: کسری از داده‌های تصوری که آماره‌ی خلاصه‌ی T آن‌ها دست‌کم به اندازه‌ی داده‌ی واقعی بزرگ است. اگر فقط ۱٪ داده‌های تصوری یادآوری‌ای به بالایی مقدار مشاهده‌شده در ۳۰ روز نشان دهند ($p_B = 0.01$)، مدل نمی‌تواند این ویژگی را تولید کند.

۲. marginal likelihood و Bayes factor

marginal likelihood (شواهد) مدل $\mathcal{M}$ درست‌نمایی‌ای است که روی پیشین میانگین‌گیری شده است:

$$p(\mathbf{y} \mid \mathcal{M}) = \int p(\mathbf{y} \mid \boldsymbol{\theta}, \mathcal{M})\, p(\boldsymbol{\theta} \mid \mathcal{M})\, d\boldsymbol{\theta}.$$

این احتمالی است که مدل پیش از دیدن داده‌ی مشاهده‌شده به آن داده بود. قاعده‌ی بیز در سطح مدل‌ها می‌دهد:

$$\underbrace{\frac{p(\mathcal{M}_1 \mid \mathbf{y})}{p(\mathcal{M}_2 \mid \mathbf{y})}}_{\text{posterior odds}} = \underbrace{\frac{p(\mathbf{y} \mid \mathcal{M}_1)}{p(\mathbf{y} \mid \mathcal{M}_2)}}_{\text{BF}_{12}} \times \underbrace{\frac{p(\mathcal{M}_1)}{p(\mathcal{M}_2)}}_{\text{prior odds}}.$$

BF_{12} ضریبی است که داده‌ها با آن بخت $\mathcal{M}_1$ نسبت به $\mathcal{M}_2$ را تغییر می‌دهند، و $\text{BF}_{21} = 1/\text{BF}_{12}$.

تیغ خودکار اوکام. هر دو مدل باید احتمال کل ۱ را روی همه‌ی مجموعه‌داده‌های ممکن پخش کنند. یک مدل ساده پیش‌بینی‌هایش را روی چند مجموعه‌داده متمرکز می‌کند؛ یک مدل منعطف آن‌ها را نازک پخش می‌کند. اگر داده‌ها همان‌جایی بیفتند که مدل ساده پیش‌بینی کرده بود، مدل ساده marginal likelihood بالاتری می‌گیرد، حتی اگر مدل منعطف هم بعد از تنظیم پارامترهایش بتواند آن‌ها را خوب برازش کند. برخلاف AIC/BIC، این جریمه به اینکه مدل چقدر منعطف است (پراکندگی پیش‌بینی پیشین) بستگی دارد، نه فقط به k.

یک مقیاس رایج شواهد (برگرفته از دسته‌بندی کلاسیک Jeffreys، آن‌طور که Lee و Wagenmakers به کار می‌برند):

BF_{12}	شواهد به نفع $\mathcal{M}_1$
۱–۳	حکایتی (anecdotal)
۳–۱۰	متوسط
۱۰–۳۰	قوی
۳۰–۱۰۰	خیلی قوی
> ۱۰۰	فوق‌العاده قوی

(مقادیر کمتر از ۱ به همین شکل برای $\mathcal{M}_2$ خوانده می‌شوند.) این برچسب‌ها کمک‌کننده‌اند، نه آستانه. خود عدد را گزارش کنید.

خواندن ریاضی

- $p(\mathbf{y} \mid \mathcal{M}) = \int p(\mathbf{y} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, d\boldsymbol{\theta}$: درست‌نمایی که روی prior **میانگین** گرفته شده، نه بیشینه. مقایسه کنید: MLE بهترین مقدار پارامتر را برمی‌دارد؛ marginal likelihood میانگین وزن‌دار با *prior* روی همه‌ی مقدارها را. مدلی که prior آن مقدارهای بد زیادی دارد، میانگین پایینی می‌گیرد.
- **بخت پسین** = Bayes factor × **بخت پیشین**. بخت (odds) نسبت احتمال‌هاست: بخت ۳ یعنی ۳ به ۱، یعنی احتمال ۰.۷۵. اگر دو مدل پیش از داده به یک اندازه معقول بودند (بخت پیشین = ۱) و $\mathrm{BF}_{12} = 3$ باشد، بعد از داده $P(\mathcal{M}_1 \mid \mathbf{y}) = 3/(1+3) = 0.75$.
- **مثال حل‌شده در یک خط:** با ۷ درست از ۱۰، مدل شانس داده را با احتمال ۰.۱۱۷ و مدل «هر دقتی» با احتمال ۰.۹۱ پیش‌بینی کرده بودند، پس $\mathrm{BF}_{01} = 1.29$: داده بخت‌ها را تقریباً تغییر نمی‌دهد.

۳. محاسبه‌ی Bayes factor

(الف) انتگرال‌گیری شبکه‌ای (۱ تا ۲ پارامتر): $p(\mathbf{y} \mid \mathcal{M}) \approx \sum_g p(\mathbf{y} \mid \boldsymbol{\theta}_g)\, p(\boldsymbol{\theta}_g)\, \Delta_g$، که Δ_g مساحت هر خانه است. آن را در فضای لگاریتمی (log-sum-exp) انجام دهید و بررسی کنید که جرم پیشین داخل شبکه ≈ 1 باشد.

(ب) تقریب BIC. برای N بزرگ، $\ln p(\mathbf{y} \mid \mathcal{M}) \approx -\tfrac{1}{2}\mathrm{BIC}$، پس

$$\mathrm{BF}_{12} \approx \exp\big(-\tfrac{1}{2}(\mathrm{BIC}_1 - \mathrm{BIC}_2)\big).$$

سریع ولی خام است: پیشین واقعی را نادیده می‌گیرد (به‌طور ضمنی یک پیشین «unit-information» فرض می‌کند) و انعطاف شکل تابعی را هم.

(ج) نسبت چگالی Savage–Dickey (مدل‌های nested). اگر $\mathcal{M}_0$ در $\mathcal{M}_1$ مقدار $\phi = \phi_0$ را ثابت کند و پیشین‌های بقیه‌ی پارامترها یکی باشند، آن‌وقت

$$\mathrm{BF}_{01} = \frac{p(\phi = \phi_0 \mid \mathbf{y}, \mathcal{M}_1)}{p(\phi = \phi_0 \mid \mathcal{M}_1)}\,:$$

چگالی پسین در مقدار صفر تقسیم بر چگالی پیشین در مقدار صفر، هر دو تحت مدل بزرگ‌تر. اگر داده‌ها ϕ_0 را محتمل‌تر از قبل کنند، شواهد به نفع فرض صفر است. فقط یک پسین از $\mathcal{M}_1$ لازم داریم.

(روش‌های دیگر، مثل bridge sampling و thermodynamic integration، marginal likelihood مدل‌های پیچیده را از خروجی MCMC حساب می‌کنند. این‌ها خارج از محدوده‌ی این درس‌اند.)

خواندن ریاضی Savage–Dickey $\mathrm{BF}_{01} = p(\phi_0 \mid \mathbf{y}) / p(\phi_0)$: به ارتفاع posterior و prior در مقدار صفر ϕ_0 نگاه کنید (مثلاً $\theta = 0.5$). اگر posterior آنجا بلندتر از prior باشد، داده مقدار صفر را معقول‌تر کرده، پس شواهد به نفع فرض صفر است. در مثال حل‌شده prior (صاف) در ۰.۵ ارتفاع ۱ دارد و posterior یعنی $\mathrm{Beta}(8, 4)$ ارتفاع ۲۹.۱، پس $\mathrm{BF}_{01} = 1.29$. یک تصویر از دو منحنی و یک خط عمودی در ϕ_0 تمام چیزی است که برای توضیح این لازم دارید.

۴. حساسیت به پیشین: برآورد در برابر آزمون

برای **برآورد**، یک پیشین معقول با جمع شدن داده کم‌اهمیت‌تر می‌شود. برای Bayes factor، پیشین پارامتر آزمون‌شده هرگز بی‌اهمیت نمی‌شود. پهن‌تر کردن پیشین تحت $\mathcal{M}_1$ پیش‌بینی‌هایش را نازک‌تر پخش می‌کند و $p(\mathbf{y} \mid \mathcal{M}_1)$ را کم می‌کند، پس یک پیشین دلخواه مبهم Bayes factor را، هر داده‌ای که باشد، به نفع فرض صفر می‌کند (پارادوکس Jeffreys–Lindley). پیامدها: - پیشین‌ها برای مقایسه‌ی مدل باید با دقت انتخاب شوند، ترجیحاً منعکس‌کننده‌ی اندازه‌ی اثرهای واقع‌بینانه. - همیشه یک **تحلیل حساسیت** گزارش کنید: Bayes factor روی دامنه‌ای از پهنای معقول پیشین.

۵. مقایسه‌ی روش‌های ارزیابی مدل

روش	سؤال	چه چیزی را جریمه می‌کند	پیشین لازم است؟	هفته
G^2، باقی‌مانده‌ها، PPC	آیا مدل کافی است؟	—	بله PPC:	۴، ۱۰
LRT	آیا پارامتر اضافه برازش را بیش از شانس بهتر می‌کند؟ (فقط nested)	Δk از راه χ^2	نه	۷
CV / AIC	کدام مدل داده‌ی جدید را بهتر پیش‌بینی می‌کند؟	overfitting تخمینی	نه	۶–۷
BIC	به‌طور تقریبی: کدام مدل شواهد بیشتری دارد؟	$k \ln N$	ضمنی	۷
Bayes factor	داده‌ها بخت بین مدل‌ها را چقدر تغییر می‌دهند؟	پراکندگی پیش‌بینی پیشین (انعطاف واقعی)	**بله، و نتیجه به آن بستگی دارد**	۱۰

پیشرفته: Bayes factor در برابر معیارهای پیش‌بینی. marginal likelihood را می‌شود به شکل حاصل‌ضرب پیش‌بینی‌های ترتیبی نوشت، $p(\mathbf{y}) = p(y_1)\,p(y_2 \mid y_1)\cdots p(y_N \mid y_{1:N-1})$. پس امتیاز می‌دهد که مدل هر نقطه‌ی داده را از روی نقاط قبلی، با شروع از پیشین، چقدر خوب پیش‌بینی می‌کند. LOO-CV پیش‌بینی‌ها را از روی (تقریباً) همه‌ی داده‌های دیگر امتیاز می‌دهد. به همین دلیل Bayes factor به پیشین وابسته است و LOO تقریباً نه، و به همین دلیل ممکن است روی داده‌ی یکسان با هم مخالف باشند.

برای یک مهندس

- **بخت پسین** = BF × **بخت پیشین** همان **آشکارساز** MAP **(بیز)** بین دو فرضیه است که در آن Bayes factor نقش نسبت درست‌نمایی را دارد.
- تفاوت با GLRT (هفته‌های ۴ و ۷): با پارامترهای مجهول، GLRT درست‌نمایی را روی آن‌ها بیشینه می‌کند؛ Bayes factor با یک prior روی آن‌ها انتگرال (میانگین) می‌گیرد. بیشینه کردن به فرضیه‌های منعطف امتیاز می‌دهد؛ میانگین گرفتن آن‌ها را خودکار جریمه می‌کند.
- **پارادوکس** Jeffreys–Lindley رنگ‌وبوی مهندسی دارد: اگر بگذارید فرضیه‌ی جایگزین دامنه‌های سیگنال به‌طور نامعقول بزرگ را مجاز بداند prior) خیلی پهن)، تقریباً هر مشاهده‌ای با «فقط نویز» بهتر توضیح داده می‌شود.
- posterior predictive check شبیه اعتبارسنجی یک مدل کانال است: سیگنال‌های دریافتی را از مدل برازش‌شده شبیه‌سازی کنید و آماره‌هایشان (هیستوگرام، خودهمبستگی، eye diagram) را با اندازه‌گیری‌ها مقایسه کنید.

برای مدرس

- **تیغ اوکام را با داستان شرط‌بندی توضیح دهید.** دو پیش‌بینی‌کننده هرکدام ۱۰۰ ژتون دارند که باید روی نتیجه‌های ممکن بگذارند. یکی ژتون‌ها را روی همه‌چیز پخش می‌کند؛ دیگری بیشتر ژتون‌ها را روی یک محدوده‌ی باریک می‌گذارد. اگر نتیجه در آن محدوده‌ی باریک بیفتد، پیش‌بینی‌کننده‌ی متمرکز بیشتر می‌برد. marginal likelihood همان مبلغ برد است.
- **حساسیت به prior را زنده نشان دهید.** در کد lab پهنای prior تحت $\mathcal{M}_1$ را تغییر دهید و ببینید BF چطور جابه‌جا می‌شود. این از هر هشداری قانع‌کننده‌تر است.
- **دو سؤال را از هم جدا نگه دارید.** روی تخته بنویسید «آیا مدل کافی است؟ ← PPC» و «کدام مدل بهتر است؟ ← BF / CV / AIC». دانشجوها اغلب از BF برای ادعای خوب بودن یک مدل استفاده می‌کنند؛ BF فقط می‌گوید از دیگری بهتر است.
- **سؤال‌های رایج.**
  - «*BF* یا p-*value*؟» به سؤال‌های متفاوتی جواب می‌دهند. BF دو فرضیه‌ی مشخص را مقایسه می‌کند و می‌تواند از فرض صفر پشتیبانی کند؛ p-value فقط میزان غافلگیری تحت فرض صفر را می‌سنجد.
  - «*BF* = ۵.۲ معنادار است؟» آستانه‌ای وجود ندارد؛ شواهد حکایتی (anecdotal) است. عدد را گزارش کنید.
  - «چرا *BF* و *AIC* با هم توافق ندارند؟» هدف‌های متفاوتی دارند (شواهد در برابر پیش‌بینی) و BF به prior بستگی دارد.

۵.۲.۴ مثال حل‌شده

بخش ۱: آیا یادآوری در حد شانس است؟ یک Bayes factor با دست

یک شرکت‌کننده در $n = 10$ trial بین دو گزینه انتخاب می‌کند و در $y = 7$ trial درست جواب می‌دهد. آیا عملکرد در حد شانس است؟

- $\mathcal{M}_0$: $\theta = 0.5$ (بدون پارامتر آزاد).
- $\mathcal{M}_1$: $\theta \sim \text{Beta}(1, 1)$ (هر دقتی از پیش به یک اندازه محتمل است).

قدم ۱. $p(y \mid \mathcal{M}_0) = \binom{10}{7} 0.5^{10} = 120/1024 = 0.1172$.

قدم ۲. تحت پیشین یکنواخت، هر شمارش $0, \ldots, n$ از پیش به یک اندازه محتمل است، پس $p(y \mid \mathcal{M}_1) = \int_0^1 \binom{10}{7} \theta^7 (1-\theta)^3 \, d\theta = \frac{1}{n+1} = \frac{1}{11} = 0.0909$.

قدم ۳. $\text{BF}_{01} = 0.1172 / 0.0909 = 1.29$. داده‌ها کمی به نفع شانس‌اند؛ شواهدی حکایتی در هر دو جهت.

قدم ۴ (بررسی). پسین تحت $\mathcal{M}_1$ برابر $\text{Beta}(8, 4)$ است (Savage–Dickey). چگالی‌اش در ۵.۰ برابر ۲۸۹.۱ است. چگالی پیشین در ۵.۰ برابر ۱ است. نسبت ۲۹.۱ است، دقیقاً همان قدم ۳.

داده‌ی بیشتر:

داده	p (آزمون دوجمله‌ای دوطرفه)	BF_{01}	خوانش
۷/۱۰	۳۴.۰	۲۹.۱	حکایتی، در هر دو جهت
۶۰/۱۰۰	$\approx$ ۰۶.۰	۱۰.۱	هنوز حکایتی: داده‌ها به‌سختی شانس را از «کمی دقت» جدا می‌کنند

داده	p (آزمون دوجمله‌ای دوطرفه)	BF_{01}	خوانش
۷۰/۱۰۰	< ۰۰۱.۰	۰۰۲۳.۰ ($\mathrm{BF}_{10} \approx 430$)	شواهد فوق‌العاده قوی علیه شانس

تفسیر. با ۶۰/۱۰۰، مقدار p نزدیک ۰۵.۰ پژوهشگران را وسوسه می‌کند ادعای اثر کنند، ولی Bayes factor می‌گوید داده‌ها تحت هر دو فرضیه تقریباً به یک اندازه محتمل‌اند. دلیل: فرضیه‌ی جایگزین با پیشین یکنواخت «پیش‌بینی کرده بود» که دقت می‌تواند هر جایی بین ۰ و ۱ باشد. دقت مشاهده‌شده‌ی ۶.۰ فقط کمی بهتر با آن پیش‌بینی می‌شود تا با دقیقاً ۵.۰. یک پیشین باریک‌تر و واقع‌بینانه‌تر تحت $\mathcal{M}_1$ (مثلاً دقت‌های بین ۵.۰ و ۸.۰) Bayes factor متفاوتی می‌داد؛ به همین دلیل حساسیت به پیشین باید گزارش شود.

بخش ۲: احتمال‌های پسین مدل‌ها

برای ۷/۱۰ با بخت پیشین ۱: بخت پسین $1.29 =$، پس $P(\mathcal{M}_0 \mid y) = 1.29/2.29 = 0.56$. اگر یک داور از پیش باور داشته باشد که عملکرد در حد شانس ۴ برابر کمتر از عملکرد بالاتر از شانس محتمل است (بخت پیشین ۱:۴)، آن‌وقت بخت پسین $1.29 \times 0.25 = 0.32 =$، پس $P(\mathcal{M}_0 \mid y) = 0.24$. Bayes factor برای همه یکی است؛ احتمال‌های پسین مدل‌ها به بخت‌های پیشین بستگی دارند.

۶.۲.۴ lab (۲ ساعت)

اهداف

۱. اجرای بررسی‌های پیش‌بینی پسین نموداری و عددی برای مدل‌های فراموشی نمایی و توانی.
۲. محاسبه‌ی درست‌نمایی‌های حاشیه‌ای و Bayes factor توانی در برابر نمایی با انتگرال‌گیری شبکه‌ای؛ مقایسه با BIC.
۳. آزمون $d' = 0$ برای یک شرکت‌کننده‌ی SDT با شواهد ضعیف با نسبت Savage–Dickey، و وارسی آن با محاسبه‌ی مستقیم.
۴. ترسیم حساسیت Bayes factor به پیشین و مقایسه‌ی آن با برآورد پسین.

زمان‌بندی: بخش A ۳۵ دقیقه · بخش B ۲۵ دقیقه · بخش C ۳۰ دقیقه · بخش D ۲۰ دقیقه · بخش E ۱۰ دقیقه.

آماده‌سازی

Code · کد: `code/week10.py`، cell ۱ · سلول ۱

خروجی مورد انتظار:

```
exp: posterior mean A = 0.655, rate = 0.049
pow: posterior mean A = 0.867, rate = 0.417
```

بخش A: بررسی‌های پیش‌بینی پسین (۳۵ دقیقه)

کد: `code/week10.py` ، cell ۲ · سلول ۲ · Code

خروجی مورد انتظار:

```
exp: T(observed) = 0.267, mean T(rep) = 0.240, posterior predictive p =
↪  0.302
pow: T(observed) = 0.267, mean T(rep) = 0.243, posterior predictive p =
↪  0.320
```

تفسیر: اول به نمودارها نگاه کنید. برای مدل نمایی، یادآوری مشاهده‌شده در کوتاه‌ترین فاصله (۴۲/۵۰) بالای نوار ٪۹۵ و یادآوری در ۷ روز (۱۳/۵۰) پایین آن است. مدل نمایی نمی‌تواند اول تند افت کند و بعد ثابت شود. نوار مدل توانی همه‌ی نقاط مشاهده‌شده را در بر دارد.

با این حال بررسی عددی با T = میانگین یادآوری در سه فاصله‌ی طولانی‌تر برای **هر دو** مدل مقادیر p_B معمولی (حدود ۳.۰) می‌دهد. عدم برازش مدل نمایی در شکل است (فاصله‌های اولیه در برابر میانی)، که این آماره به آن نگاه نمی‌کند. **یک PPC فقط شکست‌هایی را تشخیص می‌دهد که آماره‌ی آزمونش به آن‌ها حساس است.** آماره‌هایی انتخاب کنید که ویژگی‌های متمایزکننده‌ی نظریه‌ها را هدف بگیرند؛ در تمرین ۲ یک آماره‌ی «افت اول» مدل نمایی را لو می‌دهد ($p_B \approx 0.02$).

بخش B: Bayes factor با انتگرال‌گیری شبکه‌ای (۲۵ دقیقه)

کد: `code/week10.py` ، cell ۳ · سلول ۳ · Code

خروجی مورد انتظار:

```
exp: log p(y|M) = -34.938   (prior mass inside grid = 0.9996)
pow: log p(y|M) = -22.872   (prior mass inside grid = 0.9991)

BF(pow vs exp) = exp(12.07) = 1.74e+05
BIC approximation: BF(pow vs exp) = exp(9.98) = 2.16e+04
```

تفسیر: $\mathrm{BF} \approx 1.7 \times 10^5$ شواهد فوق‌العاده قوی به نفع مدل توانی در برابر نمایی است. BIC همان حکم را می‌دهد ولی با عدد دیگری (2×10^4). چرا Bayes factor شبکه‌ای و تقریب BIC با هم فرق دارند؟ (راهنمایی: هرکدام از کدام پیشین استفاده می‌کند، و آیا دو مدل تحت پیشین‌های ما به یک اندازه منعطف‌اند؟)

بخش C: Savage–Dickey: آیا حساسیت این شرکت‌کننده صفر است؟ (۳۰ دقیقه)

یک شرکت‌کننده در یک تکلیف تشخیص سخت: ۱۲ hit از ۲۰ trial علامت، ۸ false alarm از ۲۰ trial نویز. $\mathcal{M}_1$: $d' \sim \mathcal{N}(0,1)$، $c \sim \mathcal{N}(0,1)$. $\mathcal{M}_0$: $d' = 0$، $c \sim \mathcal{N}(0,1)$.

کد · Code: `code/week10.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
BF01 Savage-Dickey = 1.328;  BF01 direct = 1.328;  posterior mean d' =
↪  0.444
MLE d' = 0.507
```

دو محاسبه با هم توافق دارند؛ بررسی مفیدی برای اینکه هر دو درست پیاده‌سازی شده‌اند.

بخش D: حساسیت به پیشین (۲۰ دقیقه)

کد · Code: `code/week10.py`، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
 prior SD of d'   BF01  BF10  posterior mean d'
           0.25  0.938 1.066               0.144
           0.50  0.972 1.028               0.313
           1.00  1.328 0.753               0.444
           2.00  2.314 0.432               0.496
           5.00  5.541 0.180               0.513
          10.00 11.011 0.091               0.515
```

به این دقت کنید: با پهن‌تر شدن پیشین d'، میانگین پسین d' سریع ثابت می‌شود، ولی BF_{01} مدام به نفع فرض صفر بزرگ‌تر می‌شود. یک پیشین خیلی پهن حساسیت‌های بزرگی را «پیش‌بینی می‌کند» که اتفاق نیفتاده‌اند، پس فرضیه‌ی جایگزین جریمه می‌شود. **برای برآورد، پیشین کم‌رنگ می‌شود؛ برای آزمون، نه.**

بخش E: تفسیر (۱۰ دقیقه)

۴ تا ۵ جمله بنویسید: آیا این شرکت‌کننده علامت را تشخیص می‌دهد؟ Bayes factor را با پیشین انتخابی‌تان گزارش کنید و پیشین را توجیه کنید، به تحلیل حساسیت اشاره کنید، و بگویید چه داده‌ی اضافه‌ای جواب را روشن‌تر می‌کرد.

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. با انتگرال‌گیری عددی (`scipy.integrate.quad`) بررسی کنید که $\int_0^1 \binom{10}{7}\theta^7(1-\theta)^3 d\theta = 1/11$.

تمرین ۲ ⋆. در بخش A از یک آماره‌ی آزمون دیگر استفاده کنید: افت یادآوری از اولین به دومین فاصله. کدام مدل (اگر هست) در این بررسی شکست می‌خورد؟ (انتظار: مدل نمایی، $p_B \approx 0.02$؛ مدل توانی قبول می‌شود.)

تمرین ۳ ⋆⋆ **(حساسیت Bayes factor فراموشی به پیشین).** بخش B را با پیشین‌های نرخ پهن‌تر (مقیاس × ۳) و باریک‌تر (مقیاس ÷ ۳) تکرار کنید. آیا نتیجه‌ی «توانی ≫ نمایی» باقی می‌ماند؟ چرا اینجا، برخلاف بخش D، این‌قدر پایدار است؟

تمرین ۴ ⋆⋆ **(یک جایگزین آگاهانه).** در بخش C پیشین d' را با یک نیم‌نرمال $d' \sim \mathcal{N}^{+}(0, 1)$ (فقط مقادیر مثبت؛ نرمال‌سازی دوباره را فراموش نکنید) جایگزین کنید. Bayes factor Savage–Dickey را حساب کنید. چرا یک پیشین جهت‌دار نتیجه را تغییر می‌دهد؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: Bayes factor برای مطالعه‌ی تکرار).** برای مطالعه‌ی موردی هفته‌ی ۸ ($\mathcal{M}_0$ در برابر $\mathcal{M}_1$)، پیشین‌هایی برای δ_0، δ_1 و κ انتخاب کنید، BF_{10} را با نسبت Savage–Dickey در $\delta_1 = 0$ با یک شبکه‌ی سه‌بعدی (درشت نگهش دارید) حساب کنید و با تقریب BIC مقایسه کنید.

lab check-off

نشان دهید: (۱) دو نمودار PPC با مقادیر p_B، (۲) Bayes factor شبکه‌ای توانی در برابر نمایی و تقریب BIC آن، و (۳) جدول حساسیت به پیشین از بخش D با یک جمله تفسیر.

۷.۲.۴ ارتباط با هوش مصنوعی و LLMها

آیا LLMها «نظریه‌ی ذهن» (theory of mind) دارند؟ بعضی مطالعه‌ها گزارش می‌دهند که LLMها تکلیف‌های باور نادرست (false belief) را با موفقیت انجام می‌دهند، یعنی آزمون‌های کلاسیکی که می‌سنجند آیا کسی می‌فهمد دیگران می‌توانند باورهای نادرست داشته باشند. بعضی دیگر نشان می‌دهند که تغییرهای کوچک در داستان‌ها عملکرد را فرو می‌ریزد [بررسی شود: Kosinski, ۲۰۲۳/۲۰۲۴؛ Ullman, ۲۰۲۳]. بسیاری از این آزمون‌ها دو گزینه‌ی جواب دارند، پس سطح شانس ۵۰٪ است، و تعداد آیتم‌ها کم است. Bayes factor به اولین سؤال درست جواب می‌دهد: آیا داده اصلاً از عملکرد بالاتر از شانس، در مقایسه با شانس، پشتیبانی می‌کند؟

Code ۰ **کد:** `code/week10.py`، cell ۶ ۰ سلول ۶

خروجی مورد انتظار:

```
26/40 correct (65%): BF10 = 1.16
130/200 correct (65%): BF10 = 785.26
```

همان ۶۵٪ با ۴۰ آیتم اصلاً شاهدی نیست، و با ۲۰۰ آیتم شاهدی قاطع است. عملکرد بالاتر از شانس هم فقط قدم اول است: بررسی پیش‌بینی پسین این هفته می‌پرسد مدل چطور موفق می‌شود و شکست می‌خورد. مثلاً آیا دقیقاً روی داستان‌های تغییریافته شکست می‌خورد، جایی که یک انسان شکست نمی‌خورد؟

امتحانش کنید (بدون نیاز به API). ⋆ با یک پیشین متمرکز روی مقادیر بالاتر از شانس تکرار کنید، مثلاً Beta(5, 2) محدودشده به $\theta > 0.5$ (چگالی را دوباره نرمال کنید). BF_{10} برای ۲۶/۴۰ چطور تغییر می‌کند؟ ⋆⋆ یک مدل «میان‌بُر» (shortcut) شبیه‌سازی کنید که ۹۰٪ داستان‌های استاندارد و ۳۰٪ داستان‌های تغییریافته را درست جواب می‌دهد (نیمی از هرکدام). دقت کلی‌اش ۶۰٪ است. یک بررسی پیش‌بینی پسین طراحی کنید که میان‌بُر را آشکار کند. ⋆⋆ بحث: «بالاتر از شانس در تکلیف‌های باور نادرست» ادعایی در سطح محاسباتی Marr است یا الگوریتمی؟

۸.۲.۴ اشتباهات رایج و برداشت‌های نادرست

۱. **«پسین باریک یعنی مدل درست است.»** دقت همان کفایت نیست. همیشه یک PPC اجرا کنید.
۲. **استفاده از بررسی پیش‌بینی پسین برای انتخاب بین مدل‌ها.** PPCها کفایت را بررسی می‌کنند. برای مقایسه از Bayes factor، CV یا معیارهای اطلاعاتی استفاده کنید.
۳. **احتمال پسین مدل است.»** Bayes factor تغییر بخت است. احتمال‌های پسین به بخت‌های پیشین هم نیاز دارند.
۴. **استفاده از پیشین‌های خیلی مبهم در آزمون‌های** .Bayes factor بی‌حد و مرز Bayes factor را به سمت فرض صفر سوگیر می‌کنند (بخش .(D از پیشین‌های واقع‌بینانه استفاده کنید و حساسیت را گزارش کنید.
۵. Savage–Dickey **با پیشین‌های ناهمخوان.** پیشین‌های پارامترهای مزاحم (nuisance) باید در هر دو مدل یکی باشند، و چگالی پیشین باید در مقدار صفر تحت مدل بزرگ‌تر ارزیابی شود.
۶. **محاسبه‌ی** marginal likelihood **روی شبکه‌ای که جرم پیشین را می‌بُرد.** بررسی کنید که جرم پیشین داخل شبکه نزدیک ۱ باشد.
۷. BF» = **۹.۲» و** BF» = **۱.۳» را کیفی متفاوت دانستن.** مقیاس شواهد پیوسته است؛ برچسب‌ها کمک‌کننده‌اند، نه آستانه‌ی تصمیم.

۹.۲.۴ خودآزمایی

۱. توزیع پیش‌بینی پسین چگونه شبیه‌سازی می‌شود و چه چیزهایی را ترکیب می‌کند؟ **پاسخ** پارامترها را از پسین بکشید و بعد با آن پارامترها (و طرح آزمایش واقعی) از مدل داده شبیه‌سازی کنید. عدم قطعیت درباره‌ی پارامترها را با نویز نمونه‌گیری داده‌ی جدید ترکیب می‌کند.

۲. marginal likelihood را با کلمات تعریف کنید. **پاسخ** احتمال (چگالی) داده‌ی مشاهده‌شده تحت مدل، میانگین‌گیری‌شده روی همه‌ی مقادیر پارامتر با وزن پیشین: اینکه مدل پیش از برازش این داده‌ها را چقدر خوب پیش‌بینی کرده بود.

۳. چرا marginal likelihood حتی بدون شمردن پارامترها مدل‌های منعطف را جریمه می‌کند؟ **پاسخ** احتمال روی مجموعه‌داده‌های ممکن باید جمعش ۱ شود. یک مدل منعطف پیش‌بینی‌های پیشینش را روی مجموعه‌داده‌های زیادی پخش می‌کند و بنابراین به هرکدام، از جمله داده‌ی مشاهده‌شده، احتمال کمتری می‌دهد؛ مگر اینکه داده جایی بیفتد که فقط مدل منعطف پیش‌بینی‌اش می‌کند.

۴. $\mathrm{BF}_{10} = 6$ و بخت پیشین ۱:۳ (علیه $\mathcal{M}_1$) است. بخت پسین و $P(\mathcal{M}_1 \mid \mathbf{y})$ چقدر است؟ **پاسخ** بخت پسین $= 6 \times 1/3 = 2$، پس $P(\mathcal{M}_1 \mid \mathbf{y}) = 2/3 \approx 0.67$.

۵. نسبت Savage–Dickey و شرایط استفاده از آن را بیان کنید. **پاسخ** $\mathrm{BF}_{01} = p(\phi_0 \mid \mathbf{y}, \mathcal{M}_1) / p(\phi_0 \mid \mathcal{M}_1)$: چگالی پسین تقسیم بر چگالی پیشین در مقدار صفر تحت مدل بزرگ‌تر. به مدل‌های nested (فرض صفر $\phi = \phi_0$ را ثابت می‌کند) و پیشین‌های یکسان برای بقیه‌ی پارامترها نیاز دارد.

۶. چرا پهن کردن پیشین پارامتر آزمون‌شده، حتی با داده‌ی ثابت، BF_{01} را افزایش می‌دهد؟ **پاسخ** یک پیشین پهن‌تر احتمال بیشتری به اثرهای بزرگ و احتمال کمتری به اندازه‌ی اثرهای کوچک سازگار با داده می‌دهد، پس marginal likelihood فرضیه‌ی جایگزین کم می‌شود در حالی که درست‌نمایی فرض صفر تغییری نمی‌کند.

۷. BIC مقدار $\mathrm{BF}_{12} \approx 20$ می‌دهد، در حالی که محاسبه‌ی شبکه‌ای با پیشین‌های شما ۳ می‌دهد. کدام را گزارش می‌کنید و چرا؟ **پاسخ** Bayes factor شبکه‌ای را، چون از پیشین‌های واقعی استفاده می‌کند و انعطاف شکل تابعی را در نظر می‌گیرد؛ BIC تقریبی برای نمونه‌ی بزرگ با یک پیشین ضمنی است. به اختلاف اشاره کنید و، در صورت امکان، یک تحلیل حساسیت به پیشین بیاورید.

۱۰.۲.۴ تکلیف

A4: یک تحلیل بیزی با شبکه (۱۰۰ نمره از ۲۰؛ انتشار هفته‌ی ۱۰، موعد ابتدای درس هفته‌ی ۱۲)

داده: مجموعه‌داده‌ی A2 (`rng=np.random.default_rng(2024)`، ۹ فاصله، $n = 20$ آیتم؛ هفته‌ی ۴ را ببینید).

کارها.

۱. **پیشین‌ها (۱۰۵ امتیاز).** پیشین‌هایی برای (A, λ) مدل نمایی و (A, d) مدل توانی انتخاب و توجیه کنید. شبیه‌سازی‌های پیش‌بینی پیشین منحنی‌های فراموشی را برای هر دو مدل نشان دهید و در صورت نیاز پیشین‌ها را اصلاح کنید.
۲. **پسین (۲ امتیاز).** پسین‌های شبکه‌ای را برای هر دو مدل حساب کنید. میانگین‌های پسین، انحراف معیارها و HDIهای ٪۹۵، و همبستگی پسین دو پارامتر را گزارش کنید. پسین‌های مشترک را رسم کنید.
۳. **بررسی‌های پیش‌بینی پسین (۲ امتیاز).** PPC نموداری برای هر دو مدل، به‌علاوه‌ی یک PPC عددی با آماره‌ی آزمونی که خودتان انتخاب و توجیه می‌کنید.
۴. **Bayes factor (۲ امتیاز).** $\mathrm{BF}_{\mathrm{pow,exp}}$ را با انتگرال‌گیری شبکه‌ای حساب کنید (جرم پیشین را بررسی کنید)، با تقریب BIC مقایسه کنید، و با دو تنظیم پیشین دیگر تکرار کنید (تحلیل حساسیت).
۵. **مقایسه با A2 (۱ امتیاز).** خلاصه‌های پسین را با MLEهای A2 و عدم قطعیتشان مقایسه کنید.
۶. **تفسیر (۵.۱ امتیاز، حداکثر ۳۰۰ کلمه).** درباره‌ی فراموشی در این داده‌ها چه نتیجه‌ای می‌گیرید و این نتیجه‌گیری چقدر در برابر پیشین پایدار است؟

روبریک: امتیازها مطابق بالا؛ داخل هر کار: درستی ٪۶۰، نمودارها و جدول‌ها ٪۲۰، تفسیر ٪۲۰. برای تحویل با تأخیر، روزی ٪۱۰ کسر می‌شود (حداکثر ۳ روز).

۱۱.۲.۴ مطالعه‌ی بیشتر

- Wagenmakers & Lee **(۲۰۱۴)، فصل ۷.** مقایسه‌ی بیزی مدل‌ها: درست‌نمایی‌های حاشیه‌ای، Bayes factor و روش Savage–Dickey، با مثال‌های حل‌شده. (منبع اصلی.)
- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۱۱.** مقایسه‌ی بیزی مدل‌ها با Bayes factor، در بافت مدل‌های شناختی.
- Kruschke **(۲۰۱۴)، فصل ۱۰.** مقایسه‌ی مدل‌ها و مدل‌سازی سلسله‌مراتبی؛ مقدمه‌ای ساده بر Bayes factor و حساسیتش به پیشین.
- Lao & Martin, Kumar **(۲۰۲۱)، فصل ۲.** تحلیل اکتشافی مدل‌های بیزی، از جمله بررسی‌های پیش‌بینی پسین.

پیش‌نمایش هفته‌ی ۱۱: شبکه‌های ما برای دو پارامتر کار کردند. برای پنج، ده یا صد پارامتر به راه هوشمندانه‌تری برای کاوش پسین نیاز داریم: Markov chain Monte Carlo. اولین نمونه‌گیر خود را از صفر می‌سازید.

فصل ۵

برآورد پارامتر با MCMC

۱.۵ هفته‌ی ۱۱: روش‌های Monte Carlo و الگوریتم Metropolis–Hastings

فصل ۵: برآورد پارامتر با روش‌های داده‌محور (MCMC) · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌های فراموشی هفته‌ی ۲ با پیشین‌های هفته‌ی ۱۰، تا بتوانیم نمونه‌گیر را با پسین شبکه‌ای‌ای که از قبل داریم مقایسه کنیم.

۱.۱.۵ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
Monte Carlo	Monte Carlo (مونت‌کارلو)	تقریب با میانگین نمونه‌های تصادفی
Metropolis algorithm	الگوریتم Metropolis	پیشنهاد یک حرکت و پذیرش یا رد آن
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
Markov chain Monte Carlo (MCMC)	زنجیره‌ی مارکوف Monte Carlo	نمونه‌گیری از پسین با یک زنجیره‌ی تصادفی
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
prior	توزیع پیشین (prior)	باور درباره‌ی پارامتر پیش از دیدن داده
sampler	نمونه‌گیر (sampler)	الگوریتمی که از توزیع نمونه می‌گیرد
grid approximation	تقریب شبکه‌ای (grid)	محاسبه‌ی پسین روی شبکه‌ای از مقادیر
posterior	توزیع پسین (posterior)	باور درباره‌ی پارامتر بعد از دیدن داده

English	فارسی	توضیح کوتاه
chain	زنجیره	دنباله‌ی نمونه‌های MCMC
proposal	پیشنهاد (proposal)	مقدار جدیدی که الگوریتم امتحان می‌کند
acceptance rate	نرخ پذیرش	نسبت پیشنهادهای پذیرفته‌شده
trace plot	نمودار trace	مقدار نمونه‌ها در برابر شماره‌ی تکرار
autocorrelation	خودهمبستگی	وابستگی نمونه‌های پشت سر هم
warm-up / burn-in	دوره‌ی گرم‌شدن (burn-in)	نمونه‌های اولیه که دور ریخته می‌شوند
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
starting point	نقطه‌ی شروع	سوگیری اولیه به سمت یکی از پاسخ‌ها
response bias	سوگیری پاسخ	تمایل به یک پاسخ، مستقل از محرک
large language model (LLM)	مدل بزرگ زبانی	شبکه‌ی عصبی‌ای که کلمه‌ی بعدی متن را پیش‌بینی می‌کند
self-consistency	self-consistency (رأی اکثریت)	چند بار نمونه‌گیری جواب و انتخاب رأی اکثریت
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
MCSE	خطای استاندارد Monte Carlo	خطای شبیه‌سازی در میانگین پسین

۲.۱.۵ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. **توضیح دهند** چرا کمیت‌های پسین انتگرال‌اند، و چطور نمونه‌گیری Monte Carlo انتگرال‌ها را به میانگین تبدیل می‌کند، با خطایی که مثل $1/\sqrt{S}$ کم می‌شود.
۲. منطق Markov chain Monte Carlo را **توصیف کنند**: زنجیره‌ای که توزیع بلندمدتش همان پسین است و فقط از پسین نرمال‌نشده استفاده می‌کند.
۳. الگوریتم Metropolis (و Metropolis–Hastings) را برای یک مدل شناختی یک‌پارامتری و دوپارامتری از صفر **پیاده‌سازی کنند**.
۴. توزیع پیشنهادی (proposal) را با استفاده از نرخ پذیرش، trace plot و خودهمبستگی **تنظیم کنند** و دوره‌ی burn-in را **مشخص کنند**.
۵. خلاصه‌های پسین و کمیت‌های مشتق‌شده (مثلاً نیمه‌عمر) را از نمونه‌ها **حساب کنند** و نمونه‌گیر را با یک جواب معلوم **اعتبارسنجی کنند**.

۳.۱.۵ مقدمه

هر چیزی که از یک پسین می‌خواهیم یک **انتگرال** است: میانگین پسین $\int \theta\, p(\theta \mid \mathbf{y})\, d\theta$، پسین حاشیه‌ای (با انتگرال‌گیری روی بقیه‌ی پارامترها)، $P(d' > 1 \mid \mathbf{y})$، توزیع پیش‌بینی پسین، و marginal likelihood. در هفته‌های ۹–۱۰ این انتگرال‌ها را روی شبکه حساب کردیم. این برای دو پارامتر کار کرد. یک مدل SDT سلسله‌مراتبی برای ۲۰ شرکت‌کننده (هفته‌ی ۱۳) بیش از ۴۰ پارامتر دارد؛ شبکه‌ای با فقط ۱۰ نقطه برای هر پارامتر به 10^{40} ارزیابی نیاز دارد.

روش‌های Monte Carlo انتگرال‌گیری را با **نمونه‌گیری** جایگزین می‌کنند: اگر بتوانیم مقادیر زیادی از پسین بکشیم، هر انتگرالی به میانگین روی نمونه‌ها تبدیل می‌شود و دقت به تعداد نمونه‌ها بستگی دارد، نه به تعداد پارامترها. مشکل این است که نمی‌توانیم مستقیماً از پسین نمونه بگیریم؛ معمولاً حتی ثابت نرمال‌سازش را هم نمی‌توانیم حساب کنیم.

Markov chain Monte Carlo (MCMC) این مشکل را با ترفندی به‌طرز زیبایی ساده حل می‌کند: یک گام‌زنی تصادفی در فضای پارامتر که به سمت مقادیر محتمل‌تر بیشتر از مقادیر کم‌احتمال‌تر حرکت می‌کند، دقیقاً با نسبت‌های درست. بعد از مدتی، جاهایی که این گام‌زن به آن‌ها سر می‌زند نمونه‌هایی از پسین‌اند. شناخته‌شده‌ترین نسخه، یعنی **الگوریتم** Metropolis، در ۱۵ خط Python جا می‌شود و امروز پیش از استفاده از هر کتابخانه‌ای خودتان آن را می‌نویسید.

این موضوع کجا به کار می‌رود؟

- **همه‌ی نرم‌افزارهای بیزی امروزی** (PyMC، Stan، JAGS، BUGS) روی MCMC ساخته شده‌اند. هر مدل سلسله‌مراتبی در مقاله‌های اخیر روان‌شناسی و علوم اعصاب با نسخه‌ای از آن برازش شده است.
- **فیزیک و شیمی** (جایی که الگوریتم Metropolis در سال ۱۹۵۳ برای شبیه‌سازی ذرات ابداع شد)، **همه‌گیرشناسی** (برآورد پارامترهای سرایت)، **تبارشناسی** (بازسازی درخت‌های تکاملی) و **مالی** همه به MCMC تکیه دارند.
- **علوم شناختی نمونه‌گیری را به‌عنوان نظریه‌ای درباره‌ی ذهن هم به کار می‌برد:** بعضی پژوهشگرها پیشنهاد می‌کنند آدم‌ها استنباط بیزی را با نمونه‌گیری ذهنی چند امکان تقریب می‌زنند، که بعضی سوگیری‌ها را توضیح می‌دهد.
- **هوش مصنوعی:** نمونه‌گیری جواب از یک مدل زبانی همان Monte Carlo است (بخش هوش مصنوعی و LLMها را ببینید).

۴.۱.۵ جزوه‌ی درس

به زبان ساده هر سؤالی که از posterior می‌پرسیم («مقدار میانگین چیست؟»، «احتمال اینکه $d' > 1$ باشد چقدر است؟») یک انتگرال است، و grid نمی‌تواند انتگرال روی پارامترهای زیاد را حساب کند. Monte Carlo انتگرال را با میانگین جایگزین می‌کند: اگر تعداد زیادی مقدار تصادفی کشیده‌شده از posterior داشتیم، میانگین آن‌ها میانگین posterior بود، کسری که بالای ۱ است $P(d' > 1)$ بود، و الی آخر. مشکل به دست آوردن این نمونه‌هاست. **الگوریتم** Metropolis آن‌ها را با یک قدم‌زدن تصادفی هوشمندانه به دست می‌آورد. روی یک مقدار پارامتر بایستید، یک قدم تصادفی کوچک پیشنهاد کنید و مقایسه کنید جای جدید چقدر معقول است (درست‌نمایی × prior). اگر معقول‌تر است، به آنجا بروید. اگر کمتر معقول است، فقط گاهی بروید، با احتمالی برابر نسبت معقول بودن‌ها؛ وگرنه همان‌جا بمانید و مقدار فعلی را دوباره ثبت کنید. اگر این کار را به اندازه‌ی کافی ادامه دهید، جاهایی که رفته‌اید نمونه‌ای از posterior هستند. نکته‌ی جالب این است که هرگز به ثابت نرمال‌سازی سخت نیاز ندارید، چون فقط از نسبت‌ها استفاده می‌شود.

زمان‌بندی پیشنهادی (۶۰ دقیقه): انتگرال‌گیری Monte Carlo ۱۲ · زنجیره‌های مارکوف ۸ · الگوریتم Metropolis ۱۸ · Metropolis–Hastings ۵ · تنظیم، burn-in و خودهمبستگی ۱۲ · پیش‌نمایش ۵.

۱. انتگرال‌گیری Monte Carlo

اگر $\theta^{(1)}, \dots, \theta^{(S)}$ نمونه‌های مستقلی از $p(\theta \mid \mathbf{y})$ باشند، برای هر تابع g:

$$\mathbb{E}[g(\theta) \mid \mathbf{y}] = \int g(\theta)\, p(\theta \mid \mathbf{y})\, d\theta \;\approx\; \frac{1}{S}\sum_{s=1}^{S} g\big(\theta^{(s)}\big).$$

آنچه می‌خواهیم	$g(\theta)$ را انتخاب کنید	برآورد Monte Carlo
میانگین پسین	θ	میانگین نمونه‌ها
$P(\theta > 1 \mid \mathbf{y})$	شاخص $\mathbb{1}[\theta > 1]$	نسبت نمونه‌های بالای ۱
پسین یک کمیت مشتق‌شده، مثلاً نیمه‌عمر $2^{1/d} - 1$	$g(d)$	g را روی هر نمونه اعمال و بعد خلاصه کنید
credible interval	—	صدک‌ها (یا HDI) نمونه‌ها
پسین حاشیه‌ای θ_1	—	فقط ستون‌های دیگر را نادیده بگیرید

خطای استاندارد Monte Carlo میانگین برای نمونه‌های مستقل $\mathrm{SD}(g)/\sqrt{S}$ است، مستقل از تعداد پارامترها. به همین دلیل نمونه‌گیری در ابعاد بالا بر شبکه برتری دارد.

خواندن ریاضی

- $\mathbb{E}[g(\theta) \mid \mathbf{y}] = \int g(\theta)\, p(\theta \mid \mathbf{y})\, d\theta$: میانگین posterior یک کمیت $g(\theta)$. انتخاب g یعنی انتخاب سؤال (جدول را ببینید).
- $\approx \frac{1}{S}\sum_s g(\theta^{(s)})$: انتگرال را با میانگین ساده روی S نمونه‌ی $\theta^{(1)}, \dots, \theta^{(S)}$ جایگزین کن. بالانویس (s) شماره‌ی نمونه است.
- **خطا:** $\mathrm{SD}(g)/\sqrt{S}$. برای نصف کردن خطا چهار برابر نمونه لازم است، هر تعداد پارامتری که داشته باشیم.
- **مثال:** ۱۰،۰۰۰ نمونه از $\mathrm{Beta}(8, 4)$؛ ۹،۰۰۰ تای آن‌ها بالای ۵.۰ هستند، پس $P(\theta > 0.5 \mid \mathbf{y}) \approx 0.90$ با خطای Monte Carlo برابر $\sqrt{0.9 \times 0.1/10000} = 0.003$.

۲. زنجیره‌های مارکوف در یک پاراگراف

یک **زنجیره‌ی مارکوف** دنباله‌ای $\theta^{(1)}, \theta^{(2)}, \dots$ است که در آن هر مقدار فقط از مقدار قبلی، با یک قاعده‌ی گذار ثابت، تولید می‌شود. تحت شرایط ملایم، زنجیره نقطه‌ی شروعش را «فراموش می‌کند» و به یک **توزیع ایستا** (stationary) می‌رسد: نسبت بلندمدت زمانی که در هر ناحیه می‌گذراند. MCMC قاعده‌ی گذاری می‌سازد که توزیع ایستایش همان پسین است. دو پیامد: - بخش اولیه‌ی زنجیره هنوز بازتاب نقطه‌ی شروع است. به‌عنوان burn-in (warm-up) دور ریخته می‌شود. - نمونه‌های پشت‌سرهم **همبسته‌اند**، پس S نمونه‌ی همبسته اطلاعات کمتری از S نمونه‌ی مستقل دارند (اندازه‌ی مؤثر نمونه، هفته‌ی ۱۲).

۳. الگوریتم Metropolis

فرض کنید $\tilde{p}(\theta) = p(\mathbf{y} \mid \theta)\, p(\theta)$ پسین **نرمال‌نشده** (درست‌نمایی × پیشین) باشد. یک **توزیع پیشنهادی** متقارن انتخاب کنید، معمولاً یک گام تصادفی نرمال $\theta' \sim \mathcal{N}(\theta, \sigma_{\text{prop}})$.

۱. از یک $\theta^{(0)}$ شروع کنید.

۲. برای $s = 1, 2, \ldots, S$:

- پیشنهاد دهید $\theta' \sim \mathcal{N}(\theta^{(s-1)}, \sigma_{\text{prop}})$.
- احتمال پذیرش را حساب کنید:

$$\alpha_{\text{acc}} = \min\left(1,\ \frac{\tilde{p}(\theta')}{\tilde{p}(\theta^{(s-1)})}\right).$$

- $u \sim \text{Uniform}(0,1)$ بکشید. اگر $u < \alpha_{\text{acc}}$، **بپذیرید**: $\theta^{(s)} = \theta'$. وگرنه **رد کنید**: $\theta^{(s)} = \theta^{(s-1)}$ (مقدار فعلی در زنجیره تکرار می‌شود).

چرا به‌طور شهودی کار می‌کند: حرکت‌های سربالا همیشه پذیرفته می‌شوند؛ حرکت‌های سرپایینی با احتمالی برابر نسبت چگالی‌ها پذیرفته می‌شوند. پس زنجیره در هر ناحیه به نسبت احتمال پسینش وقت می‌گذراند.

چرا فقط پسین نرمال‌نشده لازم است: شواهد $p(\mathbf{y})$ هم در صورت و هم در مخرج نسبت ظاهر می‌شود و ساده می‌شود. این کلید سودمندی MCMC است.

جزئیات عملی: - با **لگاریتم** کار کنید: اگر $\ln u < \ln \tilde{p}(\theta') - \ln \tilde{p}(\theta)$ بپذیرید. - **پارامترهای کران‌دار:** اگر یک پیشنهاد خارج از تکیه‌گاه بیفتد (مثلاً $A > 1$)، پیشینش ۰ است، پس $\ln \tilde{p} = -\infty$ و پیشنهاد خودکار رد می‌شود. (راه دیگر نمونه‌گیری روی یک مقیاس تبدیل‌شده و بی‌کران است، مثل هفته‌ی ۳؛ در این صورت باید Jacobian را به لگاریتم پسین اضافه کرد.) - **چند پارامتر:** همه‌ی پارامترها را هم‌زمان با برداری از انحراف معیارهای پیشنهادی پیشنهاد دهید، یا هر بار یک پارامتر را به‌روز کنید (که به نمونه‌گیری Gibbs می‌رسد، هفته‌ی ۱۲).

> **پیشرفته: تعادل جزئی** (detailed balance). یک قاعده‌ی گذار $T(\theta \to \theta')$ توزیع π را ایستا نگه می‌دارد اگر برای همه‌ی جفت‌ها $\pi(\theta)\,T(\theta \to \theta') = \pi(\theta')\,T(\theta' \to \theta)$. این را برای Metropolis با $\tilde{p}(\theta') < \tilde{p}(\theta)$ بررسی کنید: سمت چپ $\pi(\theta)\,q(\theta' \mid \theta)\,\tilde{p}(\theta')/\tilde{p}(\theta)$ و سمت راست $\pi(\theta')\,q(\theta \mid \theta') \cdot 1$ است. با q متقارن و $\pi \propto \tilde{p}$ این دو برابرند.

خواندن ریاضی

- $\tilde{p}(\theta) = p(\mathbf{y} \mid \theta)\,p(\theta)$: درست‌نمایی × prior، بدون تقسیم بر evidence. علامت تیلدا (~) یعنی «نرمال‌نشده».
- $\alpha_{\text{acc}} = \min(1, \tilde{p}(\theta')/\tilde{p}(\theta))$: اگر پیشنهاد معقول‌تر باشد، نسبت بزرگ‌تر از ۱ است و min آن را روی ۱ نگه می‌دارد (همیشه پذیرش). اگر نصف معقول باشد، با احتمال ۵۰٪ پذیرفته می‌شود.
- «$u \sim \text{Uniform}(0,1)$ بکش؛ اگر $u < \alpha$ بود بپذیر» فقط راهی است برای اینکه یک رویداد با احتمال α اتفاق بیفتد (یک سکه‌ی نامتعادل).
- **مثال حل‌شده، قدم ۳:** پیشنهاد ۹۵٪ فقط ۰۵۲٪ برابر ۸۰٪ معقول است؛ $u = 0.30 > 0.052$، پس رد می‌شود و ۸۰٪ بار دوم در زنجیره نوشته می‌شود.

۴. پیشنهادهای نامتقارن Metropolis–Hastings:

اگر توزیع پیشنهادی متقارن نباشد، $q(\theta' \mid \theta) \neq q(\theta \mid \theta')$ (مثلاً پیشنهاد log-normal برای یک نرخ مثبت)، احتمال پذیرش به یک تصحیح نیاز دارد:

$$\alpha_{\text{acc}} = \min\left(1,\ \frac{\tilde{p}(\theta')\,q(\theta \mid \theta')}{\tilde{p}(\theta)\,q(\theta' \mid \theta)}\right).$$

Metropolis حالت خاصی است که جمله‌های q ساده می‌شوند. نمونه‌گیری Gibbs (هفته‌ی ۱۲) حالت خاص دیگری است که در آن هر پیشنهادی پذیرفته می‌شود.

۵. تنظیم و تشخیص مشکلات یک نمونه‌گیر

انحراف معیار پیشنهادی σ_{prop} کارایی را کنترل می‌کند:

σ_{prop}	نرخ پذیرش	رفتار	trace plot چه شکلی است
خیلی کوچک	خیلی بالا (> ۰.۹۰)	گام‌های ریز؛ کاوش کند؛ خودهمبستگی قوی	خطی که آرام سرگردان است
خیلی بزرگ	خیلی پایین (< ۰.۱۰)	بیشتر پیشنهادها در نواحی کم‌احتمال می‌افتند و رد می‌شوند؛ زنجیره گیر می‌کند	پله‌های صاف با فلات‌های طولانی
تقریباً درست	≈ ۰.۲۰ تا ۰.۵	اختلاط (mixing) خوب	یک «کرم پشمالو» (fuzzy caterpillar)

نتایج نظری کلاسیک نرخ پذیرش بهینه‌ی حدود ۴۴.۰ را برای یک پارامتر پیشنهاد می‌کنند که برای پارامترهای زیاد به حدود ۲۳.۰ می‌رسد. این‌ها را هدف بدانید، نه قانون. σ_{prop} را در یک اجرای مقدماتی تنظیم کنید (نه در اجرایی که نگه می‌دارید). انحراف معیارهای پیشنهادی خوب هم‌مرتبه با انحراف معیارهای پسین‌اند، و پسین‌های همبسته به پیشنهادهای همبسته (یا reparameterization) نیاز دارند.

Burn-in. بخش اولیه‌ی زنجیره را پیش از رسیدن به ناحیه‌ی پراحتمال دور بریزید؛ trace plot نشان می‌دهد کجا. **Thinning** (نگه داشتن هر m-امین نمونه) حافظه را کم می‌کند ولی اطلاعات را دور می‌ریزد. برای استنباط درست لازم نیست.

خودهمبستگی. خودهمبستگی با تأخیر h همبستگی بین $\theta^{(s)}$ و $\theta^{(s+h)}$ است. خودهمبستگی بالا یعنی کاوش کند و نمونه‌های مؤثراً مستقل کمتر.

همیشه یک نمونه‌گیر جدید را روی مسئله‌ای با جواب معلوم اعتبارسنجی کنید (اینجا، beta-binomial conjugate و شبکه‌ی هفته‌ی ۱۰).

برای یک مهندس

- **انتگرال‌گیری Monte Carlo** همان کاری است که برای تخمین BER یا احتمال قطعی (outage) با شبیه‌سازی می‌کنید: میانگین یک تابع نشانگر روی تعداد زیادی تحقق تصادفی. قانون خطای $1/\sqrt{S}$ همان است، و به همین دلیل نرخ‌های خطای پایین شبیه‌سازی‌های خیلی طولانی لازم دارند.
- یک زنجیره‌ی MCMC یک **فرایند مارکوف** است که توزیع ایستای آن طوری طراحی شده که posterior باشد؛ burn-in همان حالت گذرا و بخش ایستا همان حالت ماندگار است.
- **خودهمبستگی** زنجیره دقیقاً همان خودهمبستگی یک فرایند تصادفی است. نمونه‌های همبسته اطلاعات کمتری دارند، همان‌طور که نمونه‌های نویز همبسته کندتر میانگین‌گیری می‌شوند؛ هفته‌ی ۱۲ این را به «اندازه‌ی مؤثر نمونه» تبدیل می‌کند.
- **تنظیم پیشنهاد** (proposal) یک مسئله‌ی اندازه‌ی گام است، مثل انتخاب اندازه‌ی گام یک فیلتر تطبیقی: خیلی کوچک کند همگرا می‌شود، خیلی بزرگ ناپایدار می‌شود (اینجا: بیشتر قدم‌ها رد می‌شوند).
- تفاوت با شبیه‌سازی معمولی: نمی‌توانیم مستقیم از توزیع هدف نمونه‌ی مستقل تولید کنیم، پس فرایندی می‌سازیم که به آن همگرا شود.

برای مدرس

- **زنجیره را روی تخته اجرا کنید.** منحنی $\theta^7(1-\theta)^3$ را بکشید و چهار قدم مثال حل‌شده را اجرا کنید، در حالی که یک دانشجو مقدارهای «u» را تولید می‌کند (یک اپلیکیشن عدد تصادفی کافی است). قدم ردشده که ۸۰.۰ را تکرار می‌کند

لحظه‌ی کلیدی است؛ بپرسید چرا باید ثبت شود.

- **تشبیهی که جواب می‌دهد:** گردشگری که شب در یک شهر می‌گردد و خیابان‌های روشن را ترجیح می‌دهد. خیابان روشن‌تر: همیشه برو. خیابان تاریک‌تر: فقط گاهی برو. بعد از یک پیاده‌روی طولانی، زمانی که در هر خیابان گذرانده متناسب با روشنایی آن است.
- **سه trace plot را** (خیلی کوچک، خوب، خیلی بزرگ) از بخش D lab کنار هم نشان دهید. دانشجوها این‌طوری در پنج دقیقه خواندن trace plot را یاد می‌گیرند.
- **سؤال‌های رایج.**
  - «چرا فقط از یک *grid* ریز استفاده نکنیم؟» با ۴۰ پارامتر grid ناممکن است؛ هزینه‌ی نمونه‌گیری این‌طور رشد نمی‌کند.
  - «از کجا بدانیم زنجیره همگرا شده؟» این موضوع هفته‌ی ۱۲ است (چند زنجیره، $\hat{R}$).
  - «چرا *burn-in* را دور بریزیم؟» نمونه‌های اولیه هنوز نقطه‌ی شروع دلبخواه را نشان می‌دهند، نه posterior را.

۵.۱.۵ مثال حل‌شده

مدل: یادآوری $y = 7$ از $n = 10$ با پیشین تخت، پس $\tilde{p}(\theta) = \theta^7(1-\theta)^3$ (بدون ثابت‌ها). پسین دقیق: $\mathrm{Beta}(8, 4)$ با میانگین ۶۶۷.۰. پیشنهاد: $\theta' = \theta + \mathcal{N}(0, 0.1)$.

گام	θ فعلی	پیشنهاد θ'	$\tilde{p}(\theta)$	$\tilde{p}(\theta')$	نسبت	u	تصمیم	θ جدید
۱	۵۰.۰	۵۸.۰	۰۰۰۹۷۷.۰	۰۰۱۶۳۶.۰	۶۷۵.۱	۴۲.۰	پذیرش (سربالا)	۵۸.۰
۲	۵۸.۰	۸۰.۰	۰۰۱۶۳۶.۰	۰۰۱۶۷۸.۰	۰۲۶.۱	۷۱.۰	پذیرش (سربالا)	۸۰.۰
۳	۸۰.۰	۹۵.۰	۰۰۱۶۷۸.۰	۰۰۰۰۸۷.۰	۰۵۲.۰	۳۰.۰	**رد**: $u > 0.052$	۸۰.۰
۴	۸۰.۰	۶۶.۰	۰۰۱۶۷۸.۰	۰۰۲۱۴۴.۰	۲۷۸.۱	۸۸.۰	پذیرش (سربالا)	۶۶.۰

زنجیره تا اینجا: ۰.۵۰، ۰.۵۸، ۰.۸۰، **۰.۸۰**، ۰.۶۶. گام ردشده مقدار ۰.۸۰ را در زنجیره تکرار می‌کند. این ضروری است: مقادیر تکراری راهی است که زنجیره ثبت می‌کند ۰.۸۰ از ۰.۹۵ محتمل‌تر است. حذف آن‌ها نمونه را سوگیر می‌کند.

تفسیر. در چهار گام، زنجیره از نقطه‌ی شروع به ناحیه‌ی چگالی پسین بالا (۰.۶ تا ۰.۸) رفت و از پرش به دنباله امتناع کرد. در طول هزاران گام، نسبت زمانی که نزدیک هر مقدار گذرانده می‌شود به $\text{Beta}(8, 4)$ همگرا می‌شود.

۶.۱.۵ lab (۲ ساعت)

اهداف

۱. انتگرال‌گیری Monte Carlo با نمونه‌های مستقل: دیدن خطای $1/\sqrt{S}$.
۲. نوشتن یک نمونه‌گیر Metropolis و اعتبارسنجی آن روی مدل beta-binomial.
۳. نمونه‌گیری از پسین مدل فراموشی توانی، مقایسه با شبکه‌ی هفته‌ی ۱۰، و محاسبه‌ی یک کمیت مشتق‌شده.
۴. تنظیم پیشنهاد: مقایسه‌ی انحراف معیارهای پیشنهادی خیلی کوچک، خوب و خیلی بزرگ با trace plot، نرخ پذیرش و خودهمبستگی.

زمان‌بندی: بخش A ۱۵ دقیقه · بخش B ۲۵ دقیقه · بخش C ۳۵ دقیقه · بخش D ۳۰ دقیقه · بخش E ۱۵ دقیقه.

آماده‌سازی

Code · **کد:** `code/week11.py`، cell ۱ · سلول ۱

بخش A: انتگرال‌گیری Monte Carlo (۱۵ دقیقه)

Code · **کد:** `code/week11.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
Exact: mean = 0.5926, P(theta > 0.65) = 0.1967
S =    100: mean = 0.5865 (MC s.e. 0.0065), P(theta > 0.65) = 0.1800
S =   1000: mean = 0.5935 (MC s.e. 0.0021), P(theta > 0.65) = 0.2160
S =  10000: mean = 0.5937 (MC s.e. 0.0007), P(theta > 0.65) = 0.2022
S = 100000: mean = 0.5927 (MC s.e. 0.0002), P(theta > 0.65) = 0.1971
```

ده برابر نمونه‌ی بیشتر حدود $\sqrt{10} \approx 3.2$ برابر خطای Monte Carlo کمتر می‌دهد.

بخش B: یک نمونه‌گیر Metropolis، اعتبارسنجی‌شده (۲۵ دقیقه)

Code · کد: code/week11.py، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
Acceptance rate: 0.59
Metropolis: mean = 0.5930, SD = 0.0660, 95% interval = [0.458 0.718]
Exact:      mean = 0.5926, SD = 0.0663, 95% interval = [0.46  0.719]
```

بخش C: Metropolis برای مدل فراموشی توانی (۳۵ دقیقه)

همان پیشین‌های هفته‌ی ۱۰: $A \sim \text{Beta}(8, 2)$، $d \sim \text{Gamma}(2, \text{scale } 0.3)$.

Code · کد: code/week11.py، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
Acceptance rate: 0.49
    mean     SD   2.5%  97.5%
A  0.868  0.052  0.762   0.96
d  0.418  0.048  0.325   0.51
Week 10 grid posterior means for comparison: A = 0.867, d = 0.417
```

کمیت‌های مشتق‌شده مجانی به دست می‌آیند. پسین نیمه‌عمر $t_{1/2} = 2^{1/d} - 1$ (هفته‌ی ۲) و یادآوری پیش‌بینی‌شده بعد از ۶۰ روز را حساب کنید:

Code · کد: code/week11.py، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
half-life (days)       mean = 4.493, 95% interval = [2.889 7.443]
P(recall) at 60 days   mean = 0.158, 95% interval = [0.113 0.211]
P(half-life < 3 days | data) = 0.039
```

بخش D: تنظیم توزیع پیشنهادی (۳۰ دقیقه)

کد: code/week11.py، cell ۰۶ · سلول ۶ · Code

خروجی مورد انتظار:

```
too small    proposal SD = [0.002, 0.002]: acceptance = 0.97, lag-10
↪  autocorrelation of d = 0.98, mean of d = 0.473
about right  proposal SD = [0.04, 0.05]: acceptance = 0.50, lag-10
↪  autocorrelation of d = 0.26, mean of d = 0.416
too large    proposal SD = [0.5, 1.5]: acceptance = 0.00, lag-10
↪  autocorrelation of d = 0.94, mean of d = 0.420
```

به این دقت کنید: زنجیره‌ی «خیلی کوچک» تقریباً همه‌چیز را می‌پذیرد ولی می‌خزد (trace) که آرام سرگردان است و خودهمبستگی‌اش حتی با تأخیر ۶۰ نزدیک ۱ است)؛ زنجیره‌ی «خیلی بزرگ» تقریباً همه‌چیز را رد می‌کند و مدت‌های طولانی ساکن می‌ماند (پله‌های صاف). هر دو با ۱۰ ۰۰۰ تکرار برآوردهای غیرقابل اعتماد می‌دهند: میانگین d زنجیره‌ی «خیلی کوچک» (۴۷۳.۰) از میانگین پسین واقعی (۴۱۷.۰) دور است، و میانگین زنجیره‌ی «خیلی بزرگ» فقط به این دلیل نزدیک است که تقریباً از مقدار شروعش (۴۲.۰) تکان نخورده است. زنجیره‌ی خوب تنظیم‌شده شبیه یک کرم پشمالوست و خودهمبستگی‌اش سریع کم می‌شود.

بخش E: تفسیر (۱۵ دقیقه)

در notebook جواب دهید: ۱. آیا خلاصه‌های پسین Metropolis برای (A, d) با شبکه‌ی هفته‌ی ۱۰ توافق دارند؟ این توافق چه چیزی را ثابت می‌کند؟ ۲. نیمه‌عمر حافظه‌ی این شرکت‌کننده را، همراه با عدم قطعیت، در یک جمله چطور گزارش می‌کنید؟ ۳. چرا پیشنهادهای ردشده باید به‌صورت مقادیر تکراری در زنجیره ثبت شوند؟

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. با نمونه‌گیر بخش B، $P(\theta > 0.65 \mid \mathbf{y})$ را برای ۳۰/۵۰ برآورد کنید و با مقدار دقیق بخش A مقایسه کنید. برای رسیدن به دقت $\pm$۰۱.۰ چند تکرار لازم است؟

تمرین ۲ ⋆. نمونه‌گیر بخش C را از چهار نقطه‌ی شروع خیلی متفاوت اجرا کنید، مثلاً $(0.3, 0.05)$، $(0.99, 2.5)$، $(0.5, 1.0)$ و $(0.9, 0.1)$. همه‌ی traceها را با هم رسم کنید. بعد از چند تکرار از هم قابل تشخیص نیستند؟ (این ایده‌ی پشت R-hat است، هفته‌ی ۱۲.)

تمرین ۳ ⋆⋆ **(مدل نمایی).** `log_post_exp` را با پیشین‌های هفته‌ی ۱۰ بنویسید، از آن نمونه بگیرید و پسین را با شبکه مقایسه کنید. بعد توزیع پیش‌بینی پسین را از نمونه‌هایتان حساب کنید و نمودار PPC هفته‌ی ۱۰ را بازتولید کنید.

تمرین ۴ ⋆⋆ **(Metropolis–Hastings با پیشنهاد نامتقارن).** از d با یک پیشنهاد گام تصادفی log-normal، $\ln d' \sim \mathcal{N}(\ln d, 0.1)$، که هرگز مقادیر منفی پیشنهاد نمی‌دهد، نمونه بگیرید. تصحیح Hastings یعنی $q(d \mid d')/q(d' \mid d) = d'/d$ را استخراج و اعمال کنید. نشان دهید حذف این تصحیح پسین را سوگیر می‌کند.

تمرین ۵ ⋆⋆⋆ **(پیشرفته: تنظیم تطبیقی).** یک مرحله‌ی warm-up بنویسید که هر ۵۰۰ تکرار انحراف معیارهای پیشنهادی را تنظیم کند تا نرخ پذیرش به سمت ۳۰.۰ برود (مثلاً اگر نرخ خیلی بالاست SD را در ۲.۱ و اگر خیلی پایین است در ۸.۰ ضرب کنید)، و بعد آن‌ها را برای اجرای اصلی ثابت کند. چرا تطبیق باید پیش از نمونه‌هایی که نگه می‌دارید متوقف شود؟

lab check-off

نشان دهید: (۱) اعتبارسنجی نمونه‌گیرتان در برابر پسین دقیق Beta (بخش B، (۲) trace plotها و خلاصه برای مدل توانی همراه با مقایسه با شبکه (بخش C، و (۳) نمودار تنظیم با نرخ‌های پذیرش (بخش .D)

۷.۱.۵ ارتباط با هوش مصنوعی و LLMها

نمونه‌گیری جواب از یک LLM همان Monte Carlo است. چون یک LLM خروجی‌اش را نمونه‌گیری می‌کند (کادر هفته‌ی ۱)، پرسیدن چندباره‌ی یک سؤال جواب‌های مختلفی می‌دهد. ترفند رایجی به نام self-consistency تعداد k جواب نمونه‌گیری می‌کند و رأی اکثریت را می‌گیرد [Wang et al., ۲۰۲۳، ICLR]. آیا کمک می‌کند، و چقدر؟ این یک سؤال Monte Carlo است: دقت رأی اکثریت را به‌راحتی نمی‌توانیم به‌صورت بسته حساب کنیم، ولی می‌توانیم شبیه‌سازی‌اش کنیم و خطای استاندارد Monte Carlo را گزارش کنیم، مثل lab این هفته.

Code ۰ کد: `code/week11.py`، cell ۷ ۰ سلول ۷

خروجی مورد انتظار:

```
k =  1 samples: majority-vote accuracy = 0.406 (MCSE 0.003)
k =  5 samples: majority-vote accuracy = 0.506 (MCSE 0.004)
k = 15 samples: majority-vote accuracy = 0.671 (MCSE 0.003)
k = 45 samples: majority-vote accuracy = 0.873 (MCSE 0.002)
```

امتحانش کنید (بدون نیاز به API). ⋆ - `p_answer` را طوری عوض کنید که یک جواب غلط محتمل‌ترین باشد (مثلاً `[0.30,0.35,0.20,0.15]`). حالا رأی اکثریت چه می‌کند؟ چرا؟ - ⋆⋆ برای MCSE برابر ۰۰۱.۰ به چند سؤال شبیه‌سازی‌شده (`n_sim`) نیاز دارید؟ جوابتان را با فرمول $\sqrt{p(1-p)/n}$ بررسی کنید. - ⋆⋆ ارتباط با شناخت: ایده‌ی «خرد جمعی درون فرد» (wisdom of the crowd within) می‌گوید میانگین گرفتن از حدس‌های تکراری یک نفر دقت را بالا می‌برد. کدام فرض این شبیه‌سازی (نمونه‌های مستقل) احتمالاً برای حدس‌های تکراری انسان، یا برای یک LLM با دمای پایین، برقرار نیست؟

۸.۱.۵ اشتباهات رایج و برداشت‌های نادرست

۱. **حذف گام‌های ردشده** به‌جای تکرار مقدار فعلی. این کار نمونه را به سمت دنباله‌ها سوگیر می‌کند.
۲. **استفاده از پسین نرمال‌شده.** لازم نیست و معمولاً ممکن هم نیست؛ شواهد در نسبت ساده می‌شود.
۳. **محاسبه‌ی نسبت بدون لگاریتم.** درست‌نمایی‌ها سرریز می‌کنند. لگاریتم چگالی‌ها را مقایسه کنید.
۴. **فراموش کردن تکیه‌گاه پیشین.** پیشنهادهای خارج از تکیه‌گاه باید $\ln \tilde{p} = -\infty$ بگیرند، وگرنه ممکن است درست‌نمایی در مقادیر ناممکن ارزیابی شود (مثلاً احتمال‌های منفی `nan` تولید می‌کنند).
۵. **قضاوت درباره‌ی نمونه‌گیر فقط با نرخ پذیرش.** نرخ ٪۳۰ همگرایی را تضمین نمی‌کند. به traceها و خودهمبستگی نگاه کنید و چند زنجیره اجرا کنید (هفته‌ی ۱۲).

۶. **نگه داشتن** burn-in یا تنظیم پیشنهاد در طول نمونه‌هایی که نگه می‌دارید. هر دو نتایج را سوگیر می‌کنند.
۷. **«تکرار بیشتر همیشه درستش می‌کند.»** اگر زنجیره در یک مُد گیر کرده یا مقیاس پیشنهاد بد است، تکرار بیشتر همان زنجیره ممکن است در زمان معقول کمکی نکند. اول تشخیص دهید.
۸. **فراموش کردن تصحیح** Hastings با پیشنهادهای نامتقارن.

۹.۱.۵ خودآزمایی

۱. چرا خطای Monte Carlo مستقل از تعداد پارامترهاست، ولی تقریب شبکه‌ای نه؟ **پاسخ** برآورد MC میانگین S نمونه است و خطای استانداردش $\mathrm{SD}/\sqrt{S}$ است، بدون توجه به بُعد θ. یک شبکه باید کل فضای پارامتر را بپوشاند، پس اندازه‌اش با تعداد پارامترها به‌طور نمایی رشد می‌کند.

۲. در الگوریتم Metropolis چرا به شواهد $p(\mathbf{y})$ نیاز نداریم؟ **پاسخ** پذیرش فقط به نسبت چگالی‌های پسین در مقدار پیشنهادی و فعلی بستگی دارد؛ $p(\mathbf{y})$ در هر دو ظاهر می‌شود و ساده می‌شود.

۳. $\tilde{p}(\theta) = 0.004$ فعلی، $\tilde{p}(\theta') = 0.001$ پیشنهادی و $u = 0.18$. پذیرش یا رد؟ اگر $u = 0.31$ باشد چه؟ **پاسخ** نسبت ۰.۲۵ است. با $u = 0.18 < 0.25$ بپذیرید؛ با $u = 0.31 > 0.25$ رد کنید و مقدار فعلی را تکرار کنید.

۴. نرخ پذیرش یک زنجیره ۰.۹۷ است. احتمالاً چه مشکلی هست و trace آن چه شکلی دارد؟ **پاسخ** انحراف معیار پیشنهادی خیلی کوچک است: تقریباً هر گام ریزی پذیرفته می‌شود، زنجیره خیلی آرام کاوش می‌کند و trace مثل خطی است که آرام سرگردان است و خودهمبستگی بالایی دارد. انحراف معیار پیشنهادی را بزرگ کنید.

۵. burn-in چیست و طولش را چطور تعیین می‌کنید؟ **پاسخ** تکرارهای اولیه، پیش از رسیدن زنجیره به ناحیه‌ی پراحتمال، که هنوز بازتاب مقدار شروع دلخواه‌اند. طولش را از روی trace plotها (و از چند زنجیره که از نقاط مختلف شروع شده‌اند) انتخاب کنید و آن تکرارها را دور بریزید.

۶. تصحیح Hastings کی لازم است؟ یک مثال بزنید. **پاسخ** وقتی پیشنهاد نامتقارن است، $q(\theta' \mid \theta) \neq q(\theta \mid \theta')$؛ مثلاً پیشنهاد log-normal برای یک نرخ مثبت، یا پیشنهادی که به موقعیت مقدار فعلی در یک بازه‌ی کران‌دار بستگی دارد.

۷. پسین نیمه‌عمر $t_{1/2} = 2^{1/d} - 1$ را از نمونه‌های d MCMC چطور به دست می‌آورید؟ **پاسخ** هر نمونه‌ی d را به یک نیمه‌عمر تبدیل کنید و نمونه‌های تبدیل‌شده را خلاصه کنید (میانگین، صدک‌ها، .(HDI هیچ استخراج اضافه‌ای لازم نیست؛ این یکی از مزیت‌های عملی بزرگ نمونه‌گیری است.

۱۰.۱.۵ تکلیف

این هفته تکلیف نمره‌دار جدیدی نداریم. A4 **(تحلیل بیزی با شبکه)** در ابتدای درس هفته‌ی ۱۲ تحویل داده می‌شود. A5 (MCMC **از صفر)** در هفته‌ی ۱۲ منتشر می‌شود و مستقیماً روی تابع `metropolis` امروز ساخته می‌شود، پس notebook lab را مرتب نگه دارید.

تمرین اختیاری (بدون نمره): تمرین ۲ (چند نقطه‌ی شروع) بهترین آمادگی برای هفته‌ی ۱۲ است.

۱۱.۱.۵ مطالعه‌ی بیشتر

- Kruschke **(۲۰۱۴)، فصل ۷.** Markov chain Monte Carlo: مقدمه‌ای شهودی بر الگوریتم Metropolis (مثال «سیاستمدار»)، منطق آن و نماینده بودن نمونه‌ها. (منبع اصلی.)
- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۷.** برآورد بیزی پارامتر با MCMC، به‌کاررفته روی مدل‌های شناختی.
- Lao & Martin, Kumar **(۲۰۲۱)**: بخش‌های موتورهای استنباط و MCMC [شماره‌ی فصل بررسی شود].

پیش‌نمایش هفته‌ی ۱۲: نمونه‌گیری Gibbs (بدون هیچ ردی)، و سؤالی که هر کاربر MCMC باید جواب دهد: آیا زنجیره‌ام همگرا شده است؟ R-hat و اندازه‌ی مؤثر نمونه را خودمان حساب می‌کنیم و بعد با ArviZ بررسی می‌کنیم.

۲.۵ هفته‌ی ۱۲: نمونه‌گیری Gibbs و تشخیص همگرایی

فصل ۵: برآورد پارامتر با روش‌های داده‌محور (MCMC) · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** لگاریتم زمان‌های واکنش یک شرکت‌کننده (مدل نرمال با میانگین و دقت نامعلوم)، و مدل فراموشی توانی که با نمونه‌گیر Metropolis هفته‌ی قبل نمونه‌گیری می‌شود.

۱.۲.۵ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
Gibbs sampling	نمونه‌گیری Gibbs	به‌روزرسانی هر پارامتر از توزیع شرطی کاملش
convergence	همگرایی	رسیدن زنجیره‌ها به توزیع هدف
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
Markov chain Monte Carlo (MCMC)	زنجیره‌ی مارکوف Monte Carlo	نمونه‌گیری از پسین با یک زنجیره‌ی تصادفی
response time (RT)	زمان واکنش	فاصله‌ی ارائه‌ی محرک تا پاسخ
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
Metropolis algorithm	الگوریتم Metropolis	پیشنهاد یک حرکت و پذیرش یا رد آن
sampler	نمونه‌گیر (sampler)	الگوریتمی که از توزیع نمونه می‌گیرد
full conditional	توزیع شرطی کامل (full conditional)	توزیع یک پارامتر به شرط بقیه و داده

English	فارسی	توضیح کوتاه
conjugate prior	پیشین مزدوج (conjugate)	پیشینی که پسین هم‌خانواده می‌دهد
R-hat	R-hat	مقایسه‌ی واریانس بین و درون زنجیره‌ها؛ باید ≈ 1 باشد
effective sample size (ESS)	اندازه‌ی مؤثر نمونه (ESS)	تعداد نمونه‌ی مستقل هم‌ارز
chain	زنجیره	دنباله‌ی نمونه‌های MCMC
trace plot	نمودار trace	مقدار نمونه‌ها در برابر شماره‌ی تکرار
Monte Carlo	Monte Carlo (مونت‌کارلو)	تقریب با میانگین نمونه‌های تصادفی
proposal	پیشنهاد (proposal)	مقدار جدیدی که الگوریتم امتحان می‌کند
posterior	توزیع پسین (posterior)	باور درباره‌ی پارامتر بعد از دیدن داده
MCSE	خطای استاندارد Monte Carlo	خطای شبیه‌سازی در میانگین پسین
prior	توزیع پیشین (prior)	باور درباره‌ی پارامتر پیش از دیدن داده
NUTS / HMC	Hamiltonian Monte Carlo / NUTS	MCMC مبتنی بر گرادیان
warm-up / burn-in	دوره‌ی گرم‌شدن (burn-in)	نمونه‌های اولیه که دور ریخته می‌شوند
autocorrelation	خودهمبستگی	وابستگی نمونه‌های پشت سر هم
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز

۲.۲.۵ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. full conditionalها یک مدل نرمال semi-conjugate را **استخراج کنند** و یک نمونه‌گیر Gibbs را از صفر **پیاده‌سازی کنند**.
۲. **توضیح دهند** که نمونه‌گیری Gibbs کی کاراست و کی کند مخلوط می‌شود (پارامترهای همبسته)، و Metropolis-within-Gibbs چطور full conditionalهای non-conjugate را مدیریت می‌کند.
۳. $\hat{R}$-split و اندازه‌ی مؤثر نمونه (ESS) را **پیاده‌سازی کنند** و با ArviZ **بررسی کنند**.
۴. عدم همگرایی را از روی چند زنجیره با trace plot، $\hat{R}$، ESS و خطای استاندارد Monte Carlo **تشخیص دهند**.
۵. یک چک‌لیست گزارش‌دهی برای نتایج MCMC را **به کار ببرند**.

۳.۲.۵ مقدمه

نمونه‌گیر Metropolis هفته‌ی قبل یک پیچ تنظیم داشت، یعنی انحراف معیار پیشنهادی، و یک سؤال آزاردهنده: از کجا بدانیم زنجیره همگرا شده است؟ این هفته به هر دو نگرانی جواب می‌دهد.

نمونه‌گیری Gibbs مسئله‌ی تنظیم را برای دسته‌ی بزرگ و مهمی از مدل‌ها حذف می‌کند. به‌جای پیشنهاد یک پرش برای همه‌ی پارامترها و گاهی رد آن، هر بار **یک پارامتر** را به‌روز می‌کند و آن را دقیقاً از توزیعش به شرط مقادیر فعلی همه‌ی پارامترهای دیگر می‌کشد. هر نمونه‌ای پذیرفته می‌شود. بسیاری از برنامه‌های کلاسیک بیزی (BUGS، JAGS، که در سراسر کتاب‌های Lee & Wagenmakers و Kruschke استفاده می‌شوند) بر همین ایده ساخته شده‌اند.

تشخیص همگرایی بخش صادقانه‌ی MCMC است. یک زنجیره فقط وقتی مفید است که (الف) نقطه‌ی شروعش را فراموش کرده باشد و (ب) کل پسین را کاوش کرده باشد، و هیچ چیزی در یک زنجیره‌ی تنها هیچ‌کدام را ثابت نمی‌کند. راه‌حل استاندارد اجرای **چند زنجیره از نقاط شروع مختلف** و بررسی توافق آن‌هاست. $\hat{R}$ این را کمّی می‌کند که «آیا زنجیره‌ها توافق دارند؟»، و ESS این را که «نمونه‌های همبسته چقدر اطلاعات مستقل دارند؟». هیچ نتیجه‌ی MCMC نباید بدون این‌ها گزارش شود.

این موضوع کجا به کار می‌رود؟

- **هر تحلیل** MCMC **منتشرشده** باید شاخص‌های همگرایی را گزارش کند؛ داوران در روان‌شناسی و علوم اعصاب امروز به‌طور معمول $\hat{R}$ و ESS را می‌خواهند.
- **نمونه‌گیری** Gibbs پایه‌ی برنامه‌های بیزی کلاسیک BUGS و JAGS است که در بسیاری از کتاب‌های درسی مدل‌سازی شناختی (Lee & Wagenmakers، Kruschke) و در پژوهش‌های بوم‌شناسی، همه‌گیرشناسی و آموزش استفاده می‌شوند.
- **پردازش تصویر و مخابرات:** نمونه‌گیرهای Gibbs برای بازسازی تصویر و برای آشکارسازی در گیرنده‌های چندآنتنی (MIMO) به کار رفته‌اند.
- **مدل‌های موضوعی** (topic models) برای پیدا کردن موضوع‌ها در مجموعه‌های بزرگ متن، به‌طور کلاسیک با نمونه‌گیری Gibbs برازش می‌شدند.

۴.۲.۵ جزوه‌ی درس

به زبان ساده Metropolis به یک اندازه‌ی گام خوب‌انتخاب‌شده نیاز دارد. **نمونه‌گیری** Gibbs برای بسیاری از مدل‌ها از این مشکل دوری می‌کند، چون **هر بار یک پارامتر** را به‌روز می‌کند: همه‌ی پارامترهای دیگر را روی مقدار فعلی‌شان ثابت نگه دار و پارامتر انتخاب‌شده را مستقیم از توزیع دقیقش در همان شرایط بکش (full conditional آن). بعد سراغ پارامتر بعدی برو و همین‌طور ادامه بده. هیچ‌وقت چیزی رد نمی‌شود. نیمه‌ی دوم هفته به این سؤال ناخوشایند جواب می‌دهد: «آیا نمونه‌گیر من واقعاً کار کرده؟» **چند زنجیره** را از نقطه‌های شروع خیلی متفاوت اجرا می‌کنیم. اگر همه به توصیف یک توزیع برسند، شاهد خوبی برای همگرایی است؛ $\hat{R}$ («R-hat») یک عدد است که می‌سنجد زنجیره‌ها با هم توافق دارند یا نه (باید کمتر از ۱.۰۱ باشد). چون نمونه‌های پشت سر هم همبسته‌اند، ۴۰۰۰ نمونه ممکن است فقط اطلاعات مثلاً ۱۰۰۰ نمونه‌ی مستقل را داشته باشند: این عدد **اندازه‌ی مؤثر نمونه** (ESS) است و می‌گوید میانگین‌های ما چقدر دقیق‌اند.

زمان‌بندی پیشنهادی (۶۰ دقیقه): نمونه‌گیری Gibbs ۲۰ · وقتی Gibbs به زحمت می‌افتد ۵ · همگرایی و چند زنجیره $\hat{R}$ ۸ · ESS ۱۰ · و MCSE ۱۰ · چک‌لیست گزارش‌دهی ۷.

۱. نمونه‌گیری Gibbs

برای پارامترهای $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_k)$، full conditional θ_m پسین آن به شرط داده و همه‌ی پارامترهای دیگر است، $p(\theta_m \mid \boldsymbol{\theta}_{-m}, \mathbf{y})$. نمونه‌گیری Gibbs بین آن‌ها می‌چرخد:

۱. از $\boldsymbol{\theta}^{(0)}$ شروع کنید.
۲. برای $s = 1, \ldots, S$:

- بکشید $\theta_1^{(s)} \sim p(\theta_1 \mid \theta_2^{(s-1)}, \ldots, \theta_k^{(s-1)}, \mathbf{y})$
- بکشید $\theta_2^{(s)} \sim p(\theta_2 \mid \theta_1^{(s)}, \theta_3^{(s-1)}, \ldots, \mathbf{y})$
- ... (همیشه با جدیدترین مقادیر)
- بکشید $\theta_k^{(s)} \sim p(\theta_k \mid \theta_1^{(s)}, \ldots, \theta_{k-1}^{(s)}, \mathbf{y})$

این حالت خاصی از Metropolis–Hastings است که در آن پیشنهاد خود full conditional است، پس احتمال پذیرش همیشه ۱ است.

پیدا کردن full conditionalها. چگالی مشترک $p(\mathbf{y} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})$ را بنویسید، فقط ضرایبی را که θ_m دارند نگه دارید، و یک توزیع شناخته‌شده را تشخیص دهید. این وقتی کار می‌کند که پیشین‌ها (به‌طور شرطی) conjugate باشند.

مثال: یک مدل نرمال برای لگاریتم زمان واکنش. فرض کنید y_i لگاریتم زمان‌های واکنش باشند، $y_i \sim \mathcal{N}(\mu, 1/\sqrt{\tau})$، که در آن **دقت** $\tau = 1/\sigma^2$ (precision) است. پیشین‌ها: $\mu \sim \mathcal{N}(m_0, s_0)$ و $\tau \sim \text{Gamma}(a_0, \text{rate } b_0)$، مستقل. آن‌وقت:

$$\mu \mid \tau, \mathbf{y} \sim \mathcal{N}\left(\frac{m_0/s_0^2 + \tau \sum_i y_i}{1/s_0^2 + N\tau},\ \frac{1}{\sqrt{1/s_0^2 + N\tau}} \right),$$

$$\tau \mid \mu, \mathbf{y} \sim \text{Gamma}\left(a_0 + \frac{N}{2},\ \text{rate} = b_0 + \frac{1}{2}\sum_i (y_i - \mu)^2 \right).$$

خواندن فرمول‌ها. میانگین شرطی μ میانگین وزنی (با وزن دقت) میانگین پیشین و میانگین داده است (مثل beta-binomial هفته‌ی ۹). توزیع شرطی τ برای هر نقطه‌ی داده نیم مشاهده به پارامتر شکل و نیم مربع باقی‌مانده به rate اضافه می‌کند.

> **نکته درباره‌ی پارامترسازی‌ها.** `rng.gamma(shape, scale)` در NumPy از 1/rate = scale استفاده می‌کند. قاطی کردن rate و scale رایج‌ترین باگ در نمونه‌گیرهای Gibbs است.

خواندن ریاضی

- $\boldsymbol{\theta}_{-m}$: «همه‌ی پارامترها به‌جز θ_m».
- **دقت** $\tau = 1/\sigma^2$ (precision): معکوس واریانس. دقت زیاد = نویز کم. کار کردن با دقت‌ها ترکیب اطلاعات را به یک جمع ساده تبدیل می‌کند.
- **به‌روزرسانی μ:** میانگین شرطی $\dfrac{m_0/s_0^2 + \tau \sum y_i}{1/s_0^2 + N\tau}$ میانگین وزنی میانگین prior یعنی m_0 (با وزن $1/s_0^2$، دقت prior) و میانگین داده (با وزن کل $N\tau$، دقت داده) است. دقت شرطی جمع این دو دقت است. مثال حل‌شده: $1+4\times 10 = 41$، پس داده غالب است.
- **به‌روزرسانی τ:** یک توزیع Gamma که shape آن برای هر مشاهده $1/2$ و rate آن به اندازه‌ی نصف هر مربع باقی‌مانده بزرگ می‌شود. میانگین آن، shape/rate، تقریباً «۱ / (میانگین مربع باقی‌مانده)» است، یعنی همان دقتی که داده نشان می‌دهد.

۲. وقتی Gibbs به زحمت می‌افتد، و Metropolis-within-Gibbs

- **همبستگی‌های قوی پسین.** Gibbs موازی با محورهای مختصات حرکت می‌کند. اگر پسین یک ridge باریک مورب باشد (مثل d–A trade-off مدل توانی)، هر گام فقط فاصله‌ی ریزی می‌تواند حرکت کند و زنجیره آرام در امتداد ridge زیگزاگ می‌زند. راه‌حل‌ها: reparameterization، به‌روزرسانی هم‌زمان پارامترهای همبسته («بلوک‌بندی»)، یا نمونه‌گیرهای گرادیانی (هفته‌ی ۱۳).

- **full conditionalهای** non-conjugate. بیشتر مدل‌های شناختی (منحنی‌های فراموشی، SDT، GCM) توزیع شرطی بسته ندارند. Metropolis-within-Gibbs هر پارامتر را با یک گام Metropolis یک‌بعدی که full conditionalش را هدف می‌گیرد به‌روز می‌کند، و هر جا ممکن باشد از نمونه‌های دقیق Gibbs استفاده می‌کند.

> **پیشرفته:** JAGS و BUGS برای هر پارامتر خودکار یک نمونه‌گیر انتخاب می‌کنند (Gibbs conjugate، slice sampling، Metropolis تطبیقی)، و به همین دلیل روی تقریباً هر مدلی اجرا می‌شوند. Hamiltonian Monte Carlo امروزی (Stan، NUTS در PyMC) در عوض از گرادیان لگاریتم پسین استفاده می‌کند تا همه‌ی پارامترها را هم‌زمان در امتداد هندسه‌ی پسین حرکت دهد، و پسین‌های همبسته را خیلی بهتر مدیریت می‌کند (هفته‌ی ۱۳).

۳. همگرایی: منطق چند زنجیره

یک زنجیره‌ی MCMC وقتی همگرا شده که نمونه‌هایش نماینده‌ی پسین باشند. دو حالت شکست: ۱. **هنوز ایستا نشده:** زنجیره هنوز بازتاب مقدار شروع است. ۲. **گیرکرده یا کند:** زنجیره فقط بخشی از پسین را کاوش می‌کند (مثلاً یکی از دو مُد، یا یک سر یک ridge طولانی).

هیچ‌کدام را نمی‌شود با اطمینان از یک زنجیره تشخیص داد، چون زنجیره‌ای که در یک ناحیه گیر کرده می‌تواند کاملاً پایدار به نظر برسد. $C \geq 4$ زنجیره از نقاط شروع **بیش‌پراکنده** (over-dispersed) اجرا کنید: اگر همه به توصیف همان توزیع برسند، این شاهد خوبی (هرچند هرگز قطعی نیست) برای همگرایی است.

trace plotهای همه‌ی زنجیره‌ها روی هم باید مثل یک «کرم پشمالوی» خوب مخلوط‌شده باشند، بدون زنجیره‌ای که آشکارا جدا افتاده یا روند دارد.

۴. ضریب کاهش مقیاس بالقوه $\hat{R}$

واریانس **بین** زنجیره‌ها را با واریانس **درون** زنجیره‌ها مقایسه کنید. با C زنجیره به طول S (بعد از burn-in)، میانگین زنجیره‌ها $\bar{\theta}_c$ و واریانس‌های درون‌زنجیره‌ای s_c^2:

$$W = \frac{1}{C}\sum_{c} s_c^2, \qquad B = \frac{S}{C-1}\sum_{c}(\bar{\theta}_c - \bar{\theta})^2, \qquad \widehat{\mathrm{var}}^{+} = \frac{S-1}{S}W + \frac{1}{S}B, \qquad \hat{R} = \sqrt{\frac{\widehat{\mathrm{var}}^{+}}{W}}.$$

اگر زنجیره‌ها مخلوط نشده باشند، B نسبت به W بزرگ است و $\hat{R} > 1$. با همگرا شدن زنجیره‌ها، $\hat{R} \to 1$.

- **Split-$\hat{R}$:** هر زنجیره را به نیمه‌ی اول و دوم تقسیم کنید و با آن‌ها مثل $2C$ زنجیره رفتار کنید. این کار زنجیره‌ی تنهایی را هم که هنوز در حال drift است تشخیص می‌دهد.
- **آستانه:** قاعده‌ی کلاسیک $\hat{R} < 1.1$ بود؛ توصیه‌های امروزی (Vehtari و همکاران، ۲۰۲۱) $\hat{R} < 1.01$ است که بعد از نرمال‌سازی رتبه‌ای (rank-normalization) حساب می‌شود (همان کاری که ArviZ می‌کند).

۵. اندازه‌ی مؤثر نمونه و خطای استاندارد Monte Carlo

نمونه‌های خودهمبسته اطلاعات کمتری از نمونه‌های مستقل دارند. **اندازه‌ی مؤثر نمونه** برابر است با

$$\mathrm{ESS} = \frac{C \cdot S}{1 + 2\sum_{h=1}^{\infty} \rho_h},$$

که در آن ρ_h خودهمبستگی با تأخیر h است که از همه‌ی زنجیره‌ها تخمین زده و وقتی تخمین‌ها نویز می‌شوند بریده می‌شود. ESS تعداد نمونه‌های مستقلی است که همان دقت را می‌دادند.

- **خطای استاندارد** Monte Carlo میانگین پسین برابر $\text{MCSE} = \text{posterior SD}/\sqrt{\text{ESS}}$ است. باید نسبت به دقتی که گزارش می‌کنید کوچک باشد (مثلاً اگر MCSE برابر ۰.۱ است ۳ رقم اعشار گزارش نکنید).
- **قاعده‌ی سرانگشتی:** bulk-ESS $\geq$ ۴۰۰ (با ۴ زنجیره) برای میانگین‌ها و بازه‌های پسین قابل اعتماد؛ tail-ESS $\geq$ ۴۰۰ برای quantileهای حدی قابل اعتماد.

خواندن ریاضی

- $\hat{R}$: W میانگین واریانس درون هر زنجیره است؛ B می‌سنجد میانگین‌های زنجیره‌ها چقدر از هم دورند. $\widehat{\text{var}}^+$ تخمینی از کل واریانس posterior است که اختلاف بین زنجیره‌ها را هم در بر دارد. اگر زنجیره‌ها توافق داشته باشند، B تقریباً چیزی اضافه نمی‌کند و $\hat{R} = \sqrt{\widehat{\text{var}}^+/W} \approx 1$. در مثال حل‌شده‌ی «همگرا نشده»، دو زنجیره حول ۰.۱ و ۰.۲ هستند، B خیلی بزرگ است و $\hat{R} = 4.4$.
- ESS: $C \cdot S$ کل تعداد نمونه‌هاست؛ مخرج $1 + 2\sum \rho_h$ برای نمونه‌های همبسته بزرگ می‌شود. با $\rho_h = 0.5^h$ جمع برابر $1 = 0.5 + 0.25 + \cdots$ است، پس نمونه‌ها فقط یک‌سوم حساب می‌شوند: ۴،۰۰۰ نمونه ارزش ۱،۳۳۳ نمونه‌ی مستقل را دارند.
- MCSE $= \text{posterior SD}/\sqrt{\text{ESS}}$ خطای شبیه‌سازی میانگین گزارش‌شده است؛ تعداد رقم‌های اعشار را از روی آن تصمیم بگیرید.

۶. چک‌لیست گزارش‌دهی MCMC

۱. نمونه‌گیر، تعداد زنجیره‌ها، تکرارها، burn-in (warm-up) و هر thinning.
۲. مقادیر شروع (پراکنده؟).
۳. $\hat{R}$ (کدام نسخه) و ESS برای **همه‌ی** پارامترهای گزارش‌شده، به‌علاوه‌ی بیشترین $\hat{R}$ و کمترین ESS.
۴. trace plotها (در پیوست) و جمله‌ای که نشان دهد بررسی شده‌اند.
۵. پیشین‌ها، و خلاصه‌های پسین با دقتی متناسب با MCSE.
۶. یک بررسی پیش‌بینی پسین (هفته‌ی ۱۰).

برای یک مهندس

- **میانگین‌گیری وزن‌دار با دقت** در به‌روزرسانی μ همان قاعده‌ی **ترکیب با نسبت بیشینه** (MRC) یا گام به‌روزرسانی اندازه‌گیری در فیلتر کالمن است: تخمین‌ها را به نسبت معکوس واریانس نویزشان ترکیب کن.
- **نمونه‌گیری** Gibbs هر بار یک متغیر را به شرط بقیه به‌روز می‌کند؛ مثل الگوریتم‌های تکراری مختصات‌به‌مختصات (بهینه‌سازی متناوب) و تبادل تکراری اطلاعات شرطی در گیرنده‌های از نوع turbo. نمونه‌گیرهای Gibbs برای آشکارسازی MIMO هم پیشنهاد شده‌اند.
- $\hat{R}$ یک ANOVA یک‌طرفه (واریانس بین گروه‌ها در برابر درون گروه‌ها) روی اجراهای مستقل شبیه‌سازی است: همان بررسی‌ای که با اجرای یک شبیه‌سازی Monte Carlo با چند seed مختلف و وارسی توافق اجراها انجام می‌دهید.
- ESS $= N/(1 + 2\sum \rho_h)$ فرمول استاندارد تعداد مؤثر نمونه‌های مستقل یک فرایند تصادفی همبسته است: میانگین گرفتن از N نمونه‌ی همبسته واریانس را فقط به اندازه‌ی میانگین گرفتن از ESS نمونه‌ی مستقل کم می‌کند (مرتبط با زمان همبستگی).

برای مدرس

- **Gibbs را روی یک نمودار تراز رسم کنید.** دو پارامتر، یک posterior بیضوی. Gibbs فقط با گام‌های افقی و عمودی حرکت می‌کند (یک پلکان). بعد یک بیضی مورب باریک بکشید: گام‌های پلکان خیلی ریز می‌شوند. همین یک تصویر هم نحوه‌ی کار Gibbs و هم زمان به زحمت افتادنش را توضیح می‌دهد.
- **$\hat{R}$ را اول تصویری کنید:** چهار trace plot را روی هم بکشید، یک بار با زنجیره‌هایی که توافق دارند و یک بار با یک زنجیره که جای دیگری گیر کرده. پیش از نشان دادن هر فرمولی بپرسید «آیا این زنجیره‌ها یک توزیع را توصیف می‌کنند؟»
- **چک‌لیست گزارش را به‌عنوان یک عادت درس دهید.** از دانشجوها بخواهید آن را روی پروژه‌شان و روی هر نتیجه‌ی MCMC در lab اعمال کنند.
- **سؤال‌های رایج.**
  - «$\hat{R}$ برابر ۱.۰۰ است، پس مدلم درست است؟» نه. $\hat{R}$ فقط بررسی می‌کند که زنجیره‌ها توافق دارند؛ مدل هنوز می‌تواند غلط باشد (با PPC بررسی کنید) یا کد هنوز می‌تواند باگ داشته باشد.
  - «زنجیره‌ها را *thin* کنم؟» برای درستی لازم نیست؛ فقط حافظه را صرفه‌جویی می‌کند.
  - «*rate* یا *scale*؟» توزیع Gamma در NumPy از scale = 1/rate استفاده می‌کند؛ رایج‌ترین باگ در نمونه‌گیرهای Gibbs دانشجوها.

۵.۲.۵ مثال حل‌شده

بخش ۱: یک تکرار Gibbs با دست

داده: $N = 4$ لگاریتم زمان واکنش، $\mathbf{y} = (6.0, 6.3, 6.1, 6.4)$، پس $\sum y_i = 24.8$. پیشین‌ها: $m_0 = 6$، $s_0 = 1$، $a_0 = 2$، $b_0 = 0.1$. مقادیر فعلی: $\mu = 6.0$، $\tau = 10$.

به‌روزرسانی μ. دقت $= 1/1^2 + 4 \times 10 = 41$؛ میانگین $= (6/1 + 10 \times 24.8)/41 = (6 + 248)/41 = 6.195$؛ انحراف معیار $= 1/\sqrt{41} = 0.156$. مثلاً $\mu = 6.22$ کشیده می‌شود.

به‌روزرسانی τ با $\mu = 6.22$. مربع باقی‌مانده‌ها: $0.0324 + 0.0144 + 0.0064 + 0.0484 = 0.1016$. شکل $= 2 + 4/2 = 4$؛ rate $= 0.1 + 0.1016/2 = 0.1508$. میانگین شرطی τ برابر $4/0.1508 = 26.5$ است (یعنی $\sigma \approx 0.19$). مثلاً $\tau = 24.1$ کشیده می‌شود.

حالت جدید: $(\mu, \tau) = (6.22, 24.1)$. هیچ گام پذیرش/ردی لازم نبود.

بخش ۲: $\hat{R}$ با دست

دو زنجیره، هرکدام $S = 4$ نمونه.

همگرا نشده. زنجیره‌ی ۱: (۶.۰، ۶.۲، ۶.۰، ۶.۱)؛ زنجیره‌ی ۲: (۶.۲، ۶.۲، ۶.۱، ۶.۲). - میانگین زنجیره‌ها: ۶.۱ و ۶.۲. واریانس‌های درون‌زنجیره‌ای (ddof = ۱): هر دو $0.08/3 = 0.0267$، پس $W = 0.0267$. - $B = S \times \mathrm{var}(\text{means}) = 4 \times 0.5 = 2.0$. - $\widehat{\mathrm{var}}^+ = \frac{3}{4} \times 0.0267 + \frac{1}{4} \times 2.0 = 0.520$. - $\hat{R} = \sqrt{0.520/0.0267} = 4.4$. زنجیره‌ها به‌وضوح با هم مخالف‌اند.

همگرا شده (با اعداد واقع‌بینانه). $S = 1000$ نمونه در هر زنجیره، $W = 0.05$، میانگین زنجیره‌ها ۶.۰۰ و ۶.۰۲: $B = 1000 \times \mathrm{var}(6.00, 6.02) = 1000 \times 0.0002 = 0.2$؛ $\widehat{\mathrm{var}}^+ = 0.999 \times 0.05 + 0.2/1000 = 0.05015$؛ $\hat{R} = \sqrt{0.05015/0.05} = 1.0015$. کمتر از ۱.۰۱: خوب است.

بخش ۳: ESS با دست

$C \cdot S = 4000$ نمونه با خودهمبستگی‌های $\rho_h = 0.5^h$. آن‌وقت $\sum_{h \geq 1} \rho_h = 1$، پس $\text{ESS} = 4000/(1+2) = 1333$.
با انحراف معیار پسین ۲.۰، $\text{MCSE} = 0.2/\sqrt{1333} = 0.0055$ ≔ میانگین پسین را با دو رقم اعشار گزارش کنید.

۶.۲.۵ lab (۲ ساعت)

اهداف

۱. پیاده‌سازی یک نمونه‌گیر Gibbs برای مدل نرمال لگاریتم زمان واکنش و اعتبارسنجی آن با یک پسین شبکه‌ای.
۲. اجرای چهار زنجیره‌ی پراکنده و وارسی آن‌ها.
۳. پیاده‌سازی $\hat{R}$-split و ESS؛ مقایسه با ArviZ.
۴. خراب کردن عمدی همگرایی (مدل توانی با یک نمونه‌گیر Metropolis بد) و دیدن اینکه تشخیص‌ها آن را می‌گیرند.

زمان‌بندی: بخش A ۳۰ دقیقه · بخش B ۱۵ دقیقه · بخش C ۳۰ دقیقه · بخش D ۳۰ دقیقه · بخش E ۱۵ دقیقه.

آماده‌سازی

کد: Code · `code/week12.py`، cell ۱ · سلول ۱

بخش A: یک نمونه‌گیر Gibbs (۳۰ دقیقه)

کد: Code · `code/week12.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
N = 40, sample mean = 6.200, sample SD = 0.225
Gibbs: mu = 6.1994 (SD 0.0358), sigma = 0.2283 (SD 0.0255)
Grid:  mu = 6.1996, sigma = 0.2287
```

بخش B: چهار زنجیره‌ی پراکنده (۱۵ دقیقه)

کد: Code · `code/week12.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
Chain means of mu: [6.2006 6.1988 6.1996 6.1992]
```

اینجا Gibbs حتی مقادیر شروع پوچ را در چند تکرار فراموش می‌کند، چون μ و τ در این پسین تقریباً ناهمبسته‌اند.

بخش C: $\hat{R}$ و ESS از صفر، بررسی‌شده با ArviZ (۳۰ دقیقه)

کد: Code · سلول ۴ · cell ۴، `code/week12.py`

خروجی مورد انتظار:

```
       R-hat (ours)  R-hat (ArviZ)  ESS (ours)  bulk-ESS (ArviZ)  MCSE
       ↪  of mean
param
mu           1.0002         1.0004   9980.4260        10032.6243
↪  0.0004
sigma        0.9997         0.9998   8772.9605         8861.7940
↪  0.0003
      ess_bulk ess_tail r_hat mcse_mean  mcse_sd
mu       10032     9427  1.00   0.00036  0.00027
sigma     8861     9714  1.00   0.00027  0.00021
```

(چیدمان دقیق ستون‌های `az.summary` بین نسخه‌های ArviZ کمی فرق دارد؛ خروجی بالا از ArviZ 1.x است.) برآوردگرهای ساده‌ی ما با ArviZ خیلی نزدیک‌اند. با ۴ × ۲۵۰۰ = ۱۰ ۰۰۰ نمونه، ESS ≈ ۹۰۰۰ تا ۱۰ ۰۰۰ یعنی نمونه‌های Gibbs تقریباً مستقل‌اند. ArviZ علاوه بر این نمونه‌ها را **نرمال‌سازی رتبه‌ای** می‌کند (Vehtari و همکاران، ۲۰۲۱)، که $\hat{R}$ و bulk-ESS آن را در برابر دنباله‌های سنگین مقاوم می‌کند، پس تفاوت‌های کوچک قابل انتظار است. در عمل از ArviZ استفاده کنید؛ نکته‌ی امروز این است که بدانید چه چیزی حساب می‌کند.

بخش D: گرفتن عدم همگرایی (۳۰ دقیقه)

نمونه‌گیر Metropolis هفته‌ی قبل را روی مدل فراموشی توانی دوباره به کار می‌بریم؛ یک بار بد تنظیم‌شده و کوتاه، یک بار خوب تنظیم‌شده.

کد: Code · سلول ۵ · cell ۵، `code/week12.py`

خروجی مورد انتظار:

```
bad (tiny steps, short)   split-R-hat(d) = 3.583, ArviZ R-hat(d) =
↪  3.424, ESS(d) = 4, chain means of d = [0.248 0.785 0.451 0.328]
good (tuned, longer)      split-R-hat(d) = 1.002, ArviZ R-hat(d) =
↪  1.002, ESS(d) = 1025, chain means of d = [0.414 0.414 0.415 0.413]
```

به این دقت کنید: با گام‌های ریز و زنجیره‌های کوتاه، هر زنجیره هنوز نزدیک جایی است که شروع کرده. traceها جدا از هم‌اند، $\hat{R}$ خیلی بالاتر از ۱.۰۱ است و ESS ناچیز است. هر زنجیره به‌تنهایی صاف و پایدار به نظر می‌رسد، و دقیقاً به همین دلیل یک زنجیره هرگز کافی نیست. نمونه‌گیر تنظیم‌شده traceهای روی هم افتاده، $\hat{R} = 1.002$ و ESS حدود ۱۰۰۰ از ۲۰ ۰۰۰ نمونه می‌دهد. نمونه‌گیر Gibbs بخش C، با نمونه‌های تقریباً ناهمبسته، از ۱۰ ۰۰۰ نمونه به ESS حدود ۹۰۰۰ تا ۱۰ ۰۰۰ رسید.

بخش E: تفسیر و گزارش (۱۵ دقیقه)

یک پاراگراف روش‌ها و نتایج MCMC برای مدل لگاریتم زمان واکنش، طبق چک‌لیست بخش ۶ جزوه، بنویسید: نمونه‌گیر، زنجیره‌ها، تکرارها، burn-in، مقادیر شروع، $\hat{R}$، ESS، میانگین‌های پسین و بازه‌های ۹۵٪ μ و σ (با e^{μ} مقدار μ را به میلی‌ثانیه برگردانید و بگویید نماینده‌ی چیست).

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. به‌صورت جبری نشان دهید که full conditional τ یک توزیع Gamma است: $p(\tau \mid \mu, \mathbf{y}) \propto \tau^{N/2}\exp(-\frac{\tau}{2}\sum(y_i-\mu)^2)\cdot\tau^{a_0-1}e^{-b_0\tau}$ را بنویسید و شکل و rate را بخوانید.

تمرین ۲ ⋆. باگ rate/scale را (`scale=B0+...` به‌جای `(1/(...)` وارد `gibbs_normal` کنید. آیا تشخیص‌ها آن را می‌گیرند؟ اعتبارسنجی با شبکه چطور؟ این درباره‌ی تفاوت همگرایی و درستی چه می‌گوید؟

تمرین ۳ ⋆⋆ (Gibbs) **همبسته).** یک نمونه‌گیر Gibbs برای یک «پسین» نرمال دومتغیره با همبستگی ρ بنویسید (full conditionalها: $\theta_1 \mid \theta_2 \sim \mathcal{N}(\rho\theta_2, \sqrt{1-\rho^2})$ و برعکس). ESS را برای $\rho = 0, 0.9, 0.99$ با ۵۰۰۰ تکرار مقایسه کنید و مسیر زیگزاگ را برای $\rho = 0.99$ رسم کنید.

تمرین ۴ ⋆⋆ (Metropolis-within-Gibbs). از مدل فراموشی توانی با به‌روزرسانی A و d **یکی‌یکی**، هرکدام با یک گام Metropolis یک‌بعدی، نمونه بگیرید. ESS در هر ثانیه را با نمونه‌گیر Metropolis مشترک مقایسه کنید. چرا ممکن است اینجا بدتر باشد؟ (راهنمایی: همبستگی A–d.)

تمرین ۵ ⋆⋆⋆ **(پیشرفته: دو شرط).** نمونه‌گیر Gibbs را برای لگاریتم زمان واکنش در دو شرط با میانگین‌های جداگانه‌ی μ_1, μ_2 و دقت مشترک τ گسترش دهید. داده‌ای با تفاوت واقعی ۱۰ شبیه‌سازی کنید، نمونه بگیرید، و پسین $\mu_2-\mu_1$ و $P(\mu_2 > \mu_1 \mid \mathbf{y})$ را با تشخیص‌ها گزارش کنید.

lab check-off

نشان دهید: (۱) اعتبارسنجی Gibbs در برابر شبکه (بخش A)، (۲) جدول $\hat{R}$/ESS خودتان کنار جدول ArviZ (بخش C)، و (۳) trace plotهای بد در برابر خوب با تشخیص‌هایشان (بخش D).

۷.۲.۵ ارتباط با هوش مصنوعی و LLMها

نمونه‌گیری Gibbs از یک مدل زبانی. مدل‌هایی مثل BERT آموزش می‌بینند که یک کلمه‌ی پوشانده‌شده (masked) را با توجه به همه‌ی کلمه‌های دیگر پر کنند: آن‌ها full conditionalها $P(w_i \mid \text{all other words})$ را یاد می‌گیرند. این دقیقاً چیزی است که یک نمونه‌گیر Gibbs لازم دارد. پوشاندن مکرر یک موقعیت و نمونه‌گیری دوباره‌ی آن، جمله‌های کامل تولید می‌کند (Wang & Cho, ۲۰۱۹). مدل اسباب‌بازی پایین فقط دو full conditional یک «زبان» دوکلمه‌ای را می‌داند، و نمونه‌گیری Gibbs توزیع توأم جمله‌ها را بازیابی می‌کند. چون این زبان «چسبناک» است (dog با barks می‌آید، cat با meows)، زنجیره کند مخلوط می‌شود، و $\hat{R}$ این را در اجراهای کوتاه تشخیص می‌دهد.

> Code · **کد:** `code/week12.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
  50 iterations: P(subject = dog) = 0.285 (exact 0.35), R-hat = 1.151
3000 iterations: P(subject = dog) = 0.354 (exact 0.35), R-hat = 1.000
```

امتحانش کنید (بدون نیاز به API). ⋆ - زبان را باز هم چسبناک‌تر کنید (مثلاً ۳۳.۰ روی قطر و ۰۰۱.۰ در بقیه، دوباره نرمال‌شده). حالا برای $\hat{R} < 1.01$ به چند تکرار نیاز دارید؟ ESS زنجیره‌های `is_dog` را حساب کنید (هفته‌ی ۱۲، بخش C). ⋆⋆ - مدل‌های masked واقعی برای هر موقعیت جداگانه آموزش می‌بینند، پس لازم نیست توزیع‌های شرطی‌شان از یک توزیع توأم واحد آمده باشند. `p_v_given_s` را کمی دست‌کاری کنید (بدون تغییر `p_s_given_v`) و بررسی کنید آیا نمونه‌گیر Gibbs هنوز `joint` را بازیابی می‌کند. این درباره‌ی اعتماد به نمونه‌گیری که توزیع‌های شرطی‌اش یادگرفته‌شده‌اند چه می‌گوید؟

مطالعه‌ی اختیاری: Cho, K. & Wang, A., ۲۰۱۹). BERT has a mouth, and it must speak: BERT as a Markov random field language model. *arXiv:1902.04094*.

۸.۲.۵ اشتباهات رایج و برداشت‌های نادرست

۱. **rate در برابر scale در توزیع Gamma.** NumPy و SciPy از scale = 1/rate استفاده می‌کنند. بنویسید فرمولتان از کدام استفاده می‌کند.

۲. **استفاده از مقادیر قدیمی داخل یک دور Gibbs.** هر توزیع شرطی باید از جدیدترین مقادیر پارامترهای دیگر استفاده کند.

۳. **«$\hat{R} \approx 1$، پس نتایج درست‌اند.»** تشخیص‌ها توافق بین زنجیره‌ها را آزمون می‌کنند، نه درستی مدل یا کد را (تمرین ۲). نمونه‌گیرهای جدید را روی حالت‌های معلوم اعتبارسنجی کنید.

۴. **یک زنجیره‌ی بلند به‌جای چند زنجیره.** زنجیره‌ی گیرکرده می‌تواند کاملاً پایدار به نظر برسد. از $\geq$ ۴ زنجیره‌ی پراکنده استفاده کنید.

۵. **گزارش نتایج با ESS پایین.** با ESS = ۵۰، MCSE میانگین پسین حدود ٪۱۴ انحراف معیار پسین است و quantileهای دنباله غیرقابل اعتمادند.

۶. **thinning برای «درست کردن» خودهمبستگی.** thinning حافظه را کم می‌کند ولی اطلاعات را زیاد نمی‌کند. ESS خودش خودهمبستگی را در نظر می‌گیرد.

۷. **استفاده‌ی بی‌چون‌وچرا از آستانه‌ی ۱.۱.** راهنمایی امروزی $\hat{R} < 1.01$ با $\hat{R}$-split نرمال‌شده‌ی رتبه‌ای است.

۸. **تشخیص فقط برای بعضی پارامترها.** همه‌ی پارامترهای گزارش‌شده، از جمله مشتق‌شده‌ها، را بررسی کنید.

۹.۲.۵ خودآزمایی

۱. چرا نمونه‌گیری Gibbs هیچ‌وقت یک نمونه را رد نمی‌کند؟ **پاسخ** هر نمونه دقیقاً از full conditional می‌آید. اگر آن را Metropolis–Hastings با full conditional به‌عنوان پیشنهاد ببینیم، نسبت پذیرش همیشه ۱ است.

۲. برای اجرای یک نمونه‌گیر Gibbs خالص به چه چیزی نیاز دارید؟ **پاسخ** full conditionalها برای هر پارامتر (یا بلوک) که بتوانید مستقیماً از آن‌ها نمونه بگیرید؛ معمولاً چون پیشین‌ها به‌طور شرطی conjugate هستند.

۳. یک نمونه‌گیر Gibbs برای دو پارامتر به‌شدت همبسته ESS خیلی پایینی دارد. چرا، و چه می‌توانید بکنید؟ **پاسخ** Gibbs هر بار یک مختصه را به‌روز می‌کند، پس روی یک ridge باریک مورب هر گام ریز است و زنجیره آرام زیگزاگ می‌زند. راه‌حل‌ها: reparameterization برای کم کردن همبستگی، به‌روزرسانی هم‌زمان پارامترهای همبسته (بلوک‌بندی)، یا استفاده از HMC/NUTS.

۴. $\hat{R}$ را در یک جمله توضیح دهید. کدام مقدار نشانه‌ی همگرایی است؟ **پاسخ** واریانس بین زنجیره‌ها را با واریانس درون زنجیره‌ها مقایسه می‌کند (تخمین می‌زند اگر زنجیره‌ها تا ابد اجرا می‌شدند پراکندگی پسین چقدر می‌توانست کم شود)؛ مقادیر نزدیک ۱ (طبق راهنمایی امروزی < ۱.۰۱) یعنی زنجیره‌ها توافق دارند.

۵. ۴۰۰۰ نمونه و ESS برابر ۲۰۰ برای پارامتری با انحراف معیار پسین ۵.۰ دارید. MCSE میانگین پسینش چقدر است؟ چند رقم اعشار باید گزارش کنید؟ **پاسخ** MCSE $= 0.5/\sqrt{200} = 0.035$. میانگین را با یک رقم اعشار (یا حداکثر دو) گزارش کنید، چون رقم سوم نویز Monte Carlo است.

۶. چرا یک زنجیره نمی‌تواند همگرایی را نشان دهد؟ **پاسخ** زنجیره‌ای که در یک ناحیه گیر کرده (یک مُد، یا بخشی از یک ridge) می‌تواند ایستا و خوب مخلوط‌شده به نظر برسد، و هیچ چیزی در خود زنجیره نواحی کاوش‌نشده را آشکار نمی‌کند. فقط زنجیره‌هایی که از جای دیگری شروع شده و به جای دیگری رسیده‌اند مشکل را لو می‌دهند.

۷. چهار چیزی را که بخش روش‌ها باید درباره‌ی یک تحلیل MCMC گزارش کند نام ببرید. **پاسخ** هر چهار مورد از این‌ها: نمونه‌گیر/نرم‌افزار؛ تعداد زنجیره‌ها؛ تکرارها و warm-up؛ مقادیر شروع؛ $\hat{R}$ و ESS برای همه‌ی پارامترها؛ اینکه trace plotها بررسی شده‌اند؛ پیشین‌ها؛ یک بررسی پیش‌بینی پسین.

۱۰.۲.۵ تکلیف

A5: MCMC از صفر، همراه با تشخیص همگرایی (۱۰۰ نمره از ۲۰؛ انتشار هفته‌ی ۱۲، موعد ابتدای درس هفته‌ی ۱۴)

داده: آزمایش SDT پاداش از بخش D هفته‌ی ۴ (با همان seed بازتولیدش کنید: `np.random.default_rng(11)`) و داده‌ی لگاریتم زمان واکنش lab امروز (`np.random.default_rng(12)`).

کارها.

۱. **Metropolis برای SDT (۳۰ امتیاز).** یک نمونه‌گیر Metropolis گام تصادفی برای مدل پاداش با d' مشترک (d'، c_1, c_2, c_3) با پیشین‌های $d' \sim \mathcal{N}(1, 1.5)$ و $c_m \sim \mathcal{N}(0, 1)$ پیاده‌سازی کنید. پیشنهاد را تنظیم کنید (نرخ پذیرش را گزارش کنید) و ۴ زنجیره‌ی پراکنده اجرا کنید.

۲. **تشخیص همگرایی (۲۰ امتیاز).** $\hat{R}$-split و ESS را برای همه‌ی پارامترها با توابع خودتان و با ArviZ گزارش کنید؛ trace plotها را نشان دهید. بگویید آیا به نتایج اعتماد می‌کنید و چرا.

۳. **استنباط (۵۰.۱ امتیاز).** میانگین‌های پسین و بازه‌های ۹۵٪ را گزارش کنید؛ پسین $c_{\text{conservative}} - c_{\text{liberal}}$ و احتمال مثبت بودنش را حساب کنید. d' را با MLE هفته‌ی ۴ مقایسه کنید.

۴. **Gibbs (۲۰ امتیاز).** نمونه‌گیر Gibbs دوشرطی تمرین ۵ را پیاده‌سازی کنید و پسین تفاوت میانگین‌ها را با تشخیص‌ها گزارش کنید.

۵. **تفسیر (۵.۱ امتیاز، حداکثر ۳۰۰ کلمه).** طبق پسین، پاداش‌ها با حساسیت و سوگیری چه می‌کنند؟ با نتیجه‌ی آزمون نسبت درست‌نمایی هفته‌ی ۴ مقایسه کنید.

روبریک: امتیازها مطابق بالا؛ داخل هر کار: درستی ٪۶۰، نمودارها/جدول‌ها ٪۲۰، تفسیر ٪۲۰. برای تحویل با تأخیر، روزی ٪۱۰ کسر می‌شود (حداکثر ۳ روز).

۱۱.۲.۵ مطالعه‌ی بیشتر

- Kruschke **(۲۰۱۴)، فصل ۷** (بخش‌های نمونه‌گیری Gibbs و نماینده بودن، دقت و کارایی MCMC): تشخیص همگرایی، ESS و MCSE به زبان تصویری. (منبع اصلی.)
- Lao & Martin, Kumar **(۲۰۲۱)، فصل ۲.** تحلیل اکتشافی مدل‌های بیزی: trace plotها، $\hat{R}$، ESS و MCSE با ArviZ.
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۴.** استنباط با توزیع‌های گاوسی: همان مدل نرمالی که امروز نمونه‌گیر Gibbs آن را ساختید، در بافت مدل‌سازی بیزی.
- اختیاری، خارج از فهرست درس: Bürkner, P.-C.& Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., (۲۰۲۱). Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC. *Bayesian Analysis*, ۱۶(۲)، ۶۶۷–۷۱۸.

پیش‌نمایش هفته‌ی ۱۳: نوشتن نمونه‌گیرها با دست یاد می‌دهد چطور کار می‌کنند، ولی کند و پراشتباه است. هفته‌ی بعد مدل‌ها را در PyMC توصیف می‌کنیم، می‌گذاریم نمونه‌گیر NUTS آن کار را بکند، و از وقتی که صرفه‌جویی می‌کنیم برای مفیدترین دسته‌ی مدل‌ها در علوم شناختی استفاده می‌کنیم: مدل‌های سلسله‌مراتبی چند شرکت‌کننده.

۳.۵ هفته‌ی ۱۳: برنامه‌نویسی احتمالاتی و مدل‌های سلسله‌مراتبی

فصل ۵: برآورد پارامتر با روش‌های داده‌محور (MCMC)، پلی به فصل ۶ · درس ۱ ساعت · lab ۲ ساعت
داده‌ی اصلی: یک آزمایش بازشناسی/تشخیص با ۱۲ شرکت‌کننده و فقط ۵۰ + ۵۰ trial برای هر نفر: SDT سلسله‌مراتبی در PyMC.

۱.۳.۵ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
hierarchical model	مدل سلسله‌مراتبی (چندسطحی)	پارامترهای فردی از یک توزیع گروهی می‌آیند

English	فارسی	توضیح کوتاه
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
probabilistic programming	برنامه‌نویسی احتمالاتی	تعریف مدل با کد و نمونه‌گیری خودکار (PyMC)
prior	توزیع پیشین (prior)	باور درباره‌ی پارامتر پیش از دیدن داده
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
prior predictive check	بررسی پیش‌بینی پیشین	شبیه‌سازی داده از پیشین برای سنجش معقول بودن آن
posterior	توزیع پسین (posterior)	باور درباره‌ی پارامتر بعد از دیدن داده
posterior predictive check (PPC)	بررسی پیش‌بینی پسین	مقایسه‌ی داده‌ی شبیه‌سازی‌شده از پسین با داده‌ی واقعی
NUTS / HMC	Hamiltonian Monte Carlo / NUTS	MCMC مبتنی بر گرادیان
divergent transition	divergence (گذار واگرا)	هشدار NUTS برای ناحیه‌ای که درست کاوش نشده
partial pooling / no / complete	ادغام کامل / بدون ادغام / ادغام جزئی (pooling)	یک پارامتر برای همه / جدا برای هر فرد / سلسله‌مراتبی
shrinkage	انقباض به سمت میانگین (shrinkage)	کشیده شدن برآوردهای پرنویز به سمت میانگین گروه
non-centered / centered parameterization	پارامتری‌سازی centered / non-centered	دو شکل نوشتن مدل سلسله‌مراتبی
group-level parameter	پارامتر سطح گروه	میانگین و پراکندگی پارامترها در جمعیت
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
hit	اصابت (hit)	پاسخ «بله» وقتی علامت وجود دارد
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
gradient	گرادیان	جهت و شیب تغییر تابع
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
reparameterization	بازپارامتری‌سازی	نوشتن پارامتر در مقیاس دیگر، مثلاً $\lambda = e^{\eta}$
standard error (SE)	خطای استاندارد	پراکندگی برآورد در تکرارهای فرضی آزمایش
benchmark	benchmark (مجموعه‌آزمون استاندارد)	مجموعه سؤال برای مقایسه‌ی مدل‌های هوش مصنوعی

۲.۳.۵ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. یک مدل شناختی را در PyMC **تعریف کنند** (پیشین‌ها، تبدیل‌های قطعی، درست‌نمایی) و یک گردش کار بیزی کامل را **اجرا کنند**: بررسی پیش‌بینی پیشین، نمونه‌گیری، تشخیص همگرایی، بررسی پیش‌بینی پسین.
۲. به‌طور مفهومی **توضیح دهند** که NUTS / Hamiltonian Monte Carlo چه فرقی با Metropolis گام تصادفی دارد و یک divergence نشانه‌ی چیست.
۳. یک مدل سلسله‌مراتبی (چندسطحی) را **صورت‌بندی کنند** و partial pooling و shrinkage را **توضیح دهند**، در مقایسه با رویکردهای complete pooling و no pooling هفته‌ی ۵.
۴. یک پارامترسازی non-centered را **پیاده‌سازی کنند** و استفاده‌اش را **توجیه کنند**.
۵. پسین‌های سطح گروه و سطح فرد را **تفسیر کنند** و طبق چک‌لیست هفته‌ی ۱۲ **گزارش کنند**.

۳.۳.۵ مقدمه

در هفته‌ی ۵ با یک دوراهی روبه‌رو شدیم. برازش **میانگین** همه‌ی شرکت‌کننده‌ها پایدار است ولی می‌تواند مدل را تحریف کند (خطای میانگین‌گیری) و تفاوت‌های فردی را نادیده می‌گیرد. برازش **هر شرکت‌کننده جداگانه** تفاوت‌ها را رعایت می‌کند، ولی با trialهای کم برای هر نفر برآوردها پرنویزند. بعضی‌شان حدی یا بی‌نهایت می‌شوند (شرکت‌کننده‌ای با ۵۰/۵۰ hit بدون تصحیح $d' = \infty$ دارد). آماره‌های مرحله‌ی دوم روی این برآوردها هم نادیده می‌گیرند که بعضی از بقیه خیلی نامطمئن‌ترند.

مدل‌های سلسله‌مراتبی این دوراهی را حل می‌کنند. فرض می‌کنند هر شرکت‌کننده پارامتر خودش را دارد، و این پارامترهای فردی از یک توزیع سطح گروه می‌آیند که میانگین و پراکندگی‌اش هم برآورد می‌شود. آن‌وقت هر برآورد فردی از بقیه نیرو قرض می‌گیرد: برآوردهای پرنویز و حدی دقیقاً به اندازه‌ای که عدم قطعیتشان ایجاب می‌کند به سمت میانگین گروه کشیده («shrink») می‌شوند. پارامترهای سطح گروه به سؤال جمعیت («حساسیت معمول چقدر است و آدم‌ها چقدر با هم فرق دارند؟») با در نظر گرفتن همه‌ی منابع عدم قطعیت جواب می‌دهند.

نوشتن نمونه‌گیر برای چنین مدل‌هایی با دست خودش یک پروژه‌ی پژوهشی است. **زبان‌های برنامه‌نویسی احتمالاتی** مثل PyMC به ما اجازه می‌دهند مدل را در چند خط توصیف کنیم و خودکار از یک نمونه‌گیر پیشرفته، NUTS، استفاده کنیم. نمونه‌گیرهای دست‌سازِ هفته‌های ۱۱–۱۲ همان چیزی‌اند که این جعبه‌ی سیاه را برایتان شفاف می‌کنند.

این موضوع کجا به کار می‌رود؟

- **بیشتر مطالعه‌های امروزی مدل‌سازی شناختی با شرکت‌کننده‌های زیاد** مدل‌های سلسله‌مراتبی برازش می‌کنند: مدل‌های drift-diffusion سلسله‌مراتبی (بسته‌ی HDDM، مدل‌های یادگیری تقویتی سلسله‌مراتبی در روان‌پزشکی محاسباتی، و SDT سلسله‌مراتبی در پژوهش حافظه.
- **مطالعه‌های بالینی و رشدی با جلسه‌های کوتاه:** کودکان و بیماران نمی‌توانند صدها trial انجام دهند، پس برآوردهای فردی پرنویزند؛ partial pooling آن‌ها را قابل استفاده می‌کند.
- **آموزش و علوم اجتماعی:** دانش‌آموزان درون کلاس‌ها درون مدرسه‌ها (مدل‌های چندسطحی) مثال کتاب‌درسی ساختار سلسله‌مراتبی است.
- **تحلیل ورزشی و پزشکی:** برآورد مهارت یک بازیکن یا نرخ موفقیت یک بیمارستان از چند مشاهده‌ی کم با کمک گرفتن از گروه، همین ایده است.

۴.۳.۵ جزوه‌ی درس

به زبان ساده وقتی هر نفر فقط کمی داده به ما می‌دهد، برآوردهای فردی پرنویزند و بعضی‌شان بی‌معنی از آب درمی‌آیند (نمره‌ی کامل یعنی $d' = \infty$). یک **مدل سلسله‌مراتبی** می‌گوید: هر نفر پارامتر خودش را دارد، ولی آدم‌ها به هم شبیه‌اند، پس پارامترهایشان از یک توزیع گروهی مشترک می‌آیند که میانگین و پراکندگی آن را هم برآورد می‌کنیم. نتیجه یک مصالحه‌ی معقول است: کسی که داده‌ی کم یا حدی دارد به سمت میانگین گروه کشیده می‌شود (shrinkage)، و کسی که داده‌ی زیادی دارد برآوردی نزدیک به برآورد خودش نگه می‌دارد. شدت این کشش به این بستگی دارد که آدم‌ها چقدر با هم فرق دارند، و این از روی داده یاد گرفته می‌شود. نوشتن نمونه‌گیر برای چنین مدلی با دست سخت است، پس از PyMC استفاده می‌کنیم: مدل را تقریباً مثل ریاضی آن می‌نویسیم و PyMC یک نمونه‌گیر پیشرفته (NUTS) را برایمان اجرا می‌کند. بخش آخر هفته یک **گردش کار** (workflow) قدم‌به‌قدم برای انجام امن این کار است.

زمان‌بندی پیشنهادی (۶۰ دقیقه): برنامه‌نویسی احتمالاتی ۱۰ · مفاهیم HMC/NUTS ۱۰ · مدل‌های سلسله‌مراتبی ۲۰ · پارامترسازی و divergenceها ۱۰ · گردش کار بیزی ۱۰.

۱. برنامه‌نویسی احتمالاتی با PyMC

یک مدل PyMC رونویسی مستقیم مدل ریاضی است:

ریاضی	PyMC
$\mu_d \sim \mathcal{N}(1, 1)$	`mu_d=pm.Normal("mu_d",1,1)`
$\sigma_d \sim \mathcal{N}^+(0, 1)$	`sigma_d=pm.HalfNormal("sigma_d", 1)`
$d'_j = \mu_d + \sigma_d z_j$	`d=pm.Deterministic("d",mu_d+sigma_d*z_d)`
$H_j = \Phi(d'_j/2 - c_j)$	`H=Phi(d/2-c)` (یک عبارت که با `pm.math` ساخته می‌شود)
$\text{hits}_j \sim \text{Binomial}(n_s, H_j)$	`pm.Binomial("hits",n=n_s,p=H,observed=hits)`

بعد `pm.sample()` مدل را کامپایل می‌کند، گرادیان‌ها را خودکار حساب می‌کند و NUTS را اجرا می‌کند. نتیجه یک شیء `DataTree/InferenceData` در ArviZ است با گروه‌هایی مثل `posterior`، `sample_stats`، `prior_predictive` و `posterior_predictive` که ArviZ آن‌ها را خلاصه و تشخیص می‌کند (هفته‌ی ۱۲).

نکته‌های عملی: وقتی یک اسکریپت ساده‌ی `.py` را در Windows اجرا می‌کنید از `cores=1` استفاده کنید (یا کد را داخل `if__name__=="__main__":` بگذارید)؛ به هر متغیر یک نام یکتا بدهید؛ برای برچسب زدن شرکت‌کننده‌ها از `coords/dims` استفاده کنید.

۲. Hamiltonian Monte Carlo و NUTS (به‌طور مفهومی)

Metropolis گام تصادفی گام‌های کورکورانه پیشنهاد می‌دهد و در ابعاد بالا یا در امتداد ridgeهای همبسته بیشترشان را هدر می‌دهد (هفته‌های ۱۱–۱۲). Hamiltonian Monte Carlo (HMC) منفی لگاریتم پسین را یک منظره و بردار فعلی پارامتر را یک توپ بدون اصطکاک در نظر می‌گیرد. به توپ یک ضربه‌ی تصادفی (تکانه) بدهید، بگذارید مدتی با دنبال کردن گرادیان منظره بغلتد، و جایی را که به آن می‌رسد پیشنهاد دهید. پیشنهادها می‌توانند دور باشند و هنوز در نواحی پراحتمال، پس پذیرش

بالا و خودهمبستگی پایین است. NUTS (No-U-Turn Sampler) زمان غلتیدن را خودکار تنظیم می‌کند. HMC به گرادیان نیاز دارد که PyMC برایتان حساب می‌کند.

Divergenceها. غلتیدن به‌صورت عددی در گام‌های کوچک شبیه‌سازی می‌شود. جایی که انحنای پسین ناگهان تغییر می‌کند (معمولاً در «قیف‌ها»، در ادامه)، شبیه‌سازی نادقیق می‌شود و NUTS یک divergence (divergent transition) را علامت می‌زند. حتی چند divergence یعنی پسین آنجا به‌طور قابل اعتماد کاوش نمی‌شود. نادیده‌شان نگیرید؛ reparameterize کنید.

> **پیشرفته:** HMC دینامیک هامیلتونی با انرژی $H(\boldsymbol{\theta},\mathbf{p}) = -\ln \tilde{p}(\boldsymbol{\theta}) + \tfrac{1}{2}\mathbf{p}^\top M^{-1}\mathbf{p}$ را با انتگرال‌گیر leapfrog شبیه‌سازی می‌کند. دینامیک دقیق H را پایسته نگه می‌دارد، پس پیشنهادها همیشه پذیرفته می‌شدند. خطای leapfrog یک تصحیح Metropolis را لازم می‌کند، و یک divergence مسیری است که خطای انرژی‌اش منفجر می‌شود.

۳. مدل‌های سلسله‌مراتبی

ساختار (برای SDT با J شرکت‌کننده):

$$
\begin{aligned}
&\text{Group level:} && \mu_d \sim \mathcal{N}(1,1),\ \ \sigma_d \sim \mathcal{N}^{+}(0,1),\ \ \mu_c \sim \mathcal{N}(0,1),\ \ \sigma_c \sim \mathcal{N}^{+}(0,1)\\
&\text{Individual level:} && d'_j \sim \mathcal{N}(\mu_d, \sigma_d),\ \ c_j \sim \mathcal{N}(\mu_c, \sigma_c),\quad j = 1,\dots,J\\
&\text{Data:} && \text{hits}_j \sim \text{Binomial}\big(n_s, \Phi(d'_j/2 - c_j)\big),\ \ \text{FAs}_j \sim \text{Binomial}\big(n_n, \Phi(-d'_j/2 - c_j)\big)
\end{aligned}
$$

سه راه ترکیب اطلاعات (مقایسه با هفته‌ی ۵):

رویکرد	مدل	فرضش چیست
complete pooling	یک d' و یک c برای همه	$\sigma_d = \sigma_c = 0$: بدون تفاوت فردی
no pooling	d'_j و c_j جداگانه با پیشین‌های ثابت و مستقل	$\sigma \to \infty$: شرکت‌کننده‌ها هیچ چیزی درباره‌ی هم به ما نمی‌گویند
partial pooling	سلسله‌مراتبی؛ σ_d و σ_c برآورد می‌شوند	داده‌ها تصمیم می‌گیرند شرکت‌کننده‌ها چقدر شبیه هم‌اند

shrinkage. با یک تقریب نرمال، برآورد سلسله‌مراتبی شرکت‌کننده‌ی j میانگین وزنی (با وزن دقت) برآورد خودش $\hat{d}_j$ (با خطای استاندارد SE_j) و میانگین گروه است:

$$
\mathbb{E}[d'_j \mid \text{data}] \approx \frac{\hat{d}_j/\text{SE}_j^2 + \mu_d/\sigma_d^2}{1/\text{SE}_j^2 + 1/\sigma_d^2}.
$$

شرکت‌کننده‌هایی با داده‌ی **پرنویزتر** (SE_j بزرگ‌تر) **بیشتر** shrink می‌شوند. اگر آدم‌ها واقعاً خیلی با هم فرق داشته باشند (σ_d بزرگ)، shrinkage ضعیف است؛ اگر شبیه هم باشند، قوی است. این از روی داده یاد گرفته می‌شود.

چرا shrinkage خوب است، نه تحریف: در کل شرکت‌کننده‌ها، برآوردهای shrinkشده به‌طور میانگین به مقادیر واقعی نزدیک‌ترند تا برآوردهای فردی خام. این یک نتیجه‌ی معروف در آمار است (پارادوکس Stein). برآوردهای خام حدی تا حدی از روی شانس حدی‌اند، و shrinkage این بازگشت به میانگین را جبران می‌کند.

سؤال‌های سطح گروه مستقیماً با پسین‌های μ_d (حساسیت معمول) و σ_d (تفاوت‌های فردی) جواب داده می‌شوند، و مقایسه‌ی گروه‌ها با افزودن اثرهای گروه یا شرط به سطح گروه انجام می‌شود.

خواندن ریاضی

- **دو سطح.** سطح گروه: μ_d (حساسیت معمول) و σ_d (آدم‌ها چقدر با هم فرق دارند). سطح فرد: $d'_j \sim \mathcal{N}(\mu_d, \sigma_d)$، یعنی حساسیت نفر j از توزیع گروه کشیده می‌شود. سطح داده: hitها و false alarmهای نفر j فقط به d'_j و c_j همان نفر بستگی دارند.
- $\mathcal{N}^+(0,1)$: توزیع «نیم‌نرمال» (half-normal)، یک منحنی نرمال که در ۰ تا شده و فقط مقدارهای مثبت در آن مانده‌اند (انحراف معیار نمی‌تواند منفی باشد).
- **فرمول** shrinkage یک میانگین وزنی با دقت است (مثل هفته‌ی ۱۲): برآورد خود فرد $\hat{d}_j$ دقت $1/\mathrm{SE}_j^2$ دارد و توزیع گروه دقت $1/\sigma_d^2$. مثال حل‌شده: $\mathrm{SE} = 0.40$ دقت ۲۵.۶ می‌دهد و گروه ۴، پس برآورد $= (6.25 \times 2.4 + 4 \times 1.3)/10.25$ 1.97 است: مقدار خام ۴.۲، ۴۰٪ راه را به سمت میانگین گروه یعنی ۳.۱ می‌رود.
- اگر آدم‌ها واقعاً خیلی با هم فرق داشته باشند (σ_d بزرگ)، دقت گروه کم و shrinkage ضعیف است. اگر شبیه هم باشند، shrinkage قوی است.

۴. پارامترسازی centered در برابر non-centered

نوشتن مستقیم $d'_j \sim \mathcal{N}(\mu_d, \sigma_d)$ (شکل centered) در پسین یک «قیف» می‌سازد: وقتی σ_d کوچک است همه‌ی d'_jها باید به هم فشرده شوند و وقتی بزرگ است می‌توانند پخش شوند. NUTS با این هندسه‌ی متغیر به زحمت می‌افتد و divergence تولید می‌کند، به‌خصوص با داده‌ی کم برای هر شرکت‌کننده. شکل non-centered انحراف‌های استانداردشده را نمونه‌گیری می‌کند و d'_j را به‌طور قطعی می‌سازد:

$$z_j \sim \mathcal{N}(0,1), \qquad d'_j = \mu_d + \sigma_d z_j.$$

همان مدل را توصیف می‌کند ولی هندسه‌ی خیلی دوستانه‌تری دارد. وقتی داده برای هر شرکت‌کننده کم است، به‌طور پیش‌فرض از آن استفاده کنید.

خواندن ریاضی $z_j \sim \mathcal{N}(0,1)$ و $d'_j = \mu_d + \sigma_d z_j$: به جای نمونه‌گیری مستقیم d'_j، یک نمره‌ی استانداردشده‌ی «این فرد چقدر غیرعادی است» یعنی z_j (بر حسب انحراف معیار گروه) را نمونه بگیر و d'_j را از روی آن بساز. هر دو نسخه دقیقاً یک مدل را توصیف می‌کنند. تفاوت فقط در چیزی است که نمونه‌گیر باید کاوش کند: در شکل centered، وقتی σ_d کوچک است، محدوده‌ی مجاز هر d'_j تقریباً به هیچ می‌رسد (یک قیف)؛ در شکل non-centered، z_jها همیشه روی یک مقیاس‌اند، پس اندازه‌ی گام نمونه‌گیر همه‌جا مناسب است.

۵. گردش کار بیزی

۱. مدل و پیشین‌ها را (با توجیه) **تعریف کنید**.
۲. **بررسی پیش‌بینی پیشین** (هفته‌ی ۹): آیا پیشین داده‌های معقولی نتیجه می‌دهد؟
۳. با چند زنجیره **برازش کنید**.
۴. **تشخیص دهید:** $\hat{R}$، ESS، divergenceها، trace plotها (هفته‌ی ۱۲).
۵. **بررسی پیش‌بینی پسین** (هفته‌ی ۱۰): آیا مدل برازش‌شده می‌تواند داده‌ها را بازتولید کند؟
۶. در صورت نیاز مدل‌ها را **مقایسه کنید** (LOO با ArviZ، Bayes factor؛ هفته‌های ۶، ۱۰).
۷. **تفسیر و گزارش کنید.**

برای یک مهندس

- **مدل سلسله‌مراتبی = تخمین با یک prior جمعیتی.** مثل این است که بهره‌ی کانال هر کاربر را از چند pilot تخمین بزنید و هم‌زمان توزیع بهره‌ها در سلول را یاد بگیرید و از آن به‌عنوان prior استفاده کنید: یک تخمین‌گر empirical Bayes / MMSE shrinkage به سمت میانگین گروه همان پدیده‌ی تخمین‌گر James–Stein است که وقتی سه واحد یا بیشتر داریم، در مجموع خطای مربعی از تخمین‌های ML جداگانه بهتر است.
- HMC/NUTS دینامیک همیلتونی (یک ذره‌ی بدون اصطکاک روی سطح منفی لگاریتم posterior) را با یک انتگرال‌گیر عددی (leapfrog) شبیه‌سازی می‌کند، مثل شبیه‌سازی‌های فیزیکی. یک divergence یعنی انتگرال‌گیر ناپایدار شده چون اندازه‌ی گام برای انحنای محلی خیلی بزرگ است؛ مثل یک معادله‌ی دیفرانسیل سخت (stiff) که با گام خیلی بزرگ انتگرال‌گیری شود.
- **پارامتری‌سازی** non-centered یک تغییر متغیر است که متغیرها را به مقیاس واحد نرمال می‌کند، یعنی حالت (conditioning) مسئله را بهتر می‌کند؛ شبیه سفید کردن یا نرمال کردن ورودی‌ها پیش از یک الگوریتم تطبیقی.
- PyMC گرادیان‌ها را خودکار حساب می‌کند (automatic differentiation)، همان فناوری‌ای که شبکه‌های عصبی را آموزش می‌دهد.

برای مدرس

- shrinkage **را با یک مثال ورزشی یا امتحانی معرفی کنید.** دانشجویی که ۳ از ۳ سؤال را درست جواب داده احتمالاً «دانشجوی ٪۱۰۰» نیست؛ دانشجویی با ۹۵ از ۱۰۰ احتمالاً نزدیک ٪۹۵ است. از کلاس بپرسید اطلاعات فردی و کلاسی را چطور ترکیب می‌کنند: خودشان partial pooling را اختراع می‌کنند.
- **نمودار** shrinkage **بخش** D lab **را نشان دهید:** برآوردهای خام، برآوردهای سلسله‌مراتبی و میانگین گروه روی یک شکل، با پیکان. ایده را ماندگار می‌کند.
- **ریاضی** HMC **را عمیق درس ندهید.** یک تصویر (یک توپ که روی منفی لگاریتم posterior با یک ضربه‌ی تصادفی می‌غلتد) کافی است؛ مهارت عملی مهم، خواندن شاخص‌های تشخیصی است (divergence، $\hat{R}$، ESS).
- **اجرای** PyMC **در کلاس:** روی Windows در اسکریپت‌ها از `cores=1` استفاده کنید و نمونه‌گیری را زود شروع کنید (بخش C، چون ممکن است چند دقیقه طول بکشد.
- **سؤال‌های رایج.**
  - «آیا *shrinkage* نتایج را سوگیر نمی‌کند؟» کمی، ولی خطای کل را کم می‌کند، پس برآوردها به‌طور میانگین به حقیقت نزدیک‌ترند.
  - «آیا مدل سلسله‌مراتبی همیشه بهتر است؟» وقتی افراد داده‌ی کافی دارند، نتایج شبیه برازش‌های جداگانه است؛ بیشترین سود وقتی است که برای هر نفر داده کم است.
  - *«divergence* برای نتایجم یعنی چه؟» یعنی بخشی از posterior به‌طور قابل اعتماد کاوش نشده. reparameterize کنید و دوباره اجرا کنید تا هیچ divergenceای نماند.

۵.۳.۵ مثال حل‌شده

shrinkage **با دست.** پسین گروه $\mu_d \approx 1.3$ و $\sigma_d \approx 0.5$ دارد (دقت گروه $1/0.5^2 = 4$). دو شرکت‌کننده هر دو برآورد خام $\hat{d}_j = 2.4$ دارند.

شرکت‌کننده	SE_j	دقت فردی $1/\mathrm{SE}_j^2$	برآورد سلسله‌مراتبی	انحراف معیار پسین
P1 (trial کم)	۴۰.۰	۲۵.۶	$(6.25 \times 2.4 + 4 \times 1.3)/(6.25+4) = 20.2/10.25 = \mathbf{1.97}$	$1/\sqrt{10.25} = 0.31$
P2 (trial زیاد)	۲۰.۰	۲۵	$(25 \times 2.4 + 4 \times 1.3)/(25+4) = 65.2/29 = \mathbf{2.25}$	$1/\sqrt{29} = 0.19$

تفسیر. هر دو شرکت‌کننده به نظر به یک اندازه حساس‌اند، ولی برآورد P1 بر داده‌ی کمتری تکیه دارد، پس مدل کمتر به آن اعتماد می‌کند و آن را ۴۳.۰ به سمت میانگین گروه جابه‌جا می‌کند. P2 فقط ۱۵.۰ جابه‌جا می‌شود. هر دو انحراف معیار پسین از SEهای خام کوچک‌ترند، چون توزیع گروه اطلاعات اضافه می‌کند. (در مدل کامل، μ_d و σ_d خودشان نامطمئن‌اند و هم‌زمان برآورد می‌شوند؛ این محاسبه برای توضیح آن‌ها را ثابت می‌گیرد.)

۶.۳.۵ lab (۲ ساعت)

اهداف

۱. شبیه‌سازی یک آزمایش با ۱۲ شرکت‌کننده و محاسبه‌ی برآوردهای فردی (no pooling).
۲. نوشتن مدل SDT سلسله‌مراتبی در PyMC با پارامترسازی non-centered؛ اجرای یک بررسی پیش‌بینی پیشین.
۳. نمونه‌گیری با NUTS؛ بررسی $\hat{R}$، ESS و divergenceها.
۴. نمایش shrinkage و مقایسه‌ی برآوردها با مقادیر واقعی.
۵. اجرای یک بررسی پیش‌بینی پسین و تفسیر پارامترهای سطح گروه.

زمان‌بندی: بخش A ۱۰ دقیقه · بخش B ۲۰ دقیقه · بخش C ۲۵ دقیقه · بخش D ۳۰ دقیقه · بخش E ۲۰ دقیقه · بخش F ۱۵ دقیقه.

> **زمان اجرا:** نمونه‌گیری از کمتر از یک دقیقه (نصب conda-forge با compiler تا حدود ۲ تا ۳ دقیقه (بدون compiler) طول می‌کشد. بخش C را زود شروع کنید.

بخش A: داده و برآوردهای no pooling (۱۰ دقیقه)

> Code · **کد:** `code/week13.py`، cell ۱ · سلول ۱

خروجی مورد انتظار:

```
    hits  fas  d_true  d_indiv  c_true  c_indiv
0     46    2    2.21     3.01    0.13     0.15
1     16   25   -0.24    -0.46    0.42     0.23
2     28    6    1.78     1.29    0.41     0.50
3     40   11    1.33     1.57    0.05    -0.03
4     43    9    1.96     1.94    0.09    -0.08
5     43   17    1.49     1.45   -0.34    -0.32
6     31    0    2.21     2.63    0.70     1.02
7     35   11    1.32     1.27    0.13     0.12
8     24    8    1.04     0.92    0.60     0.51
9     39    8    1.59     1.72    0.33     0.11
10    27    3    1.52     1.58    0.78     0.69
11    21    9    1.12     0.69    0.66     0.54
```

بخش B: مدل در PyMC، و یک بررسی پیش‌بینی پیشین (۲۰ دقیقه)

Code ۰۲ **کد:** `code/week13.py`، cell ۰۲ سلول ۲

خروجی مورد انتظار:

```
Share of prior-predictive rates exactly 0 or 1: 0.30
```

پیشین دامنه‌ی وسیعی از نرخ‌های hit و false alarm را نتیجه می‌دهد که بیشترشان بالای قطرند. حدود ۳۰٪ شرکت‌کننده‌های شبیه‌سازی‌شده شمارش hit یا false alarm دقیقاً ۰ یا ۵۰ دارند. این‌ها بیشتر شرکت‌کننده‌هایی‌اند که با حساسیت خیلی بالا و سوگیری قوی شبیه‌سازی شده‌اند و false alarm صفر تولید می‌کنند. این خیلی بهتر از ۹۶٪ پیشین «مبهم» هفته‌ی ۹ است، ولی هنوز کمی دست‌ودل‌باز است: تنگ‌تر کردن پیشین‌های `sigma_d` و `sigma_c` (مثلاً `HalfNormal(0.5)`) بیشترشان را حذف می‌کند. امتحانش کنید و ببینید آیا پسین تغییر می‌کند.

بخش C: نمونه‌گیری و تشخیص همگرایی (۲۵ دقیقه)

Code ۰۳ **کد:** `code/week13.py`، cell ۰۳ سلول ۳

خروجی مورد انتظار:

```
        ess_bulk ess_tail r_hat mcse_mean mcse_sd
mu_d        1303     1651  1.00    0.0075  0.0054
sigma_d     1639     2088  1.00    0.0055  0.0045
mu_c        1312     1474  1.00    0.0036   0.003
sigma_c     1203     1748  1.00    0.0034  0.0047
Number of divergent transitions: 0
Max R-hat over all individual d and c: 1.0023234826538692
```

بخش D: shrinkage و استنباط سطح گروه (۳۰ دقیقه)

Code · **کد:** code/week13.py، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
RMSE vs. true d':  no pooling = 0.339,  hierarchical = 0.279
mu_d     posterior mean = 1.45, 95% interval = [0.90, 1.95]
sigma_d  posterior mean = 0.90, 95% interval = [0.56, 1.42]
mu_c     posterior mean = 0.29, 95% interval = [0.04, 0.55]
sigma_c  posterior mean = 0.38, 95% interval = [0.22, 0.65]
P(mu_c > 0 | data) = 0.987
```

تفسیر (در notebook بنویسید): ۱. کدام شرکت‌کننده‌ها بیشتر shrink می‌شوند و چرا؟ یکی را که برآورد خامش حدی است پیدا کنید و توصیف کنید مدل سلسله‌مراتبی با آن چه می‌کند. ۲. آیا برآورد سلسله‌مراتبی به‌طور میانگین به حقیقت نزدیک‌تر است؟ آیا برای هر شرکت‌کننده نزدیک‌تر است؟ چرا این لازم نیست؟ ۳. μ_d و σ_d درباره‌ی این جمعیت چه می‌گویند؟ σ_d را با انحراف معیاری که برای شبیه‌سازی داده استفاده شد (۵.۰) مقایسه کنید و تفاوت را توضیح دهید (راهنمایی: ۱۲ شرکت‌کننده).

بخش E: بررسی پیش‌بینی پسین (۲۰ دقیقه)

Code · **کد:** code/week13.py، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
Share of observed counts inside their 95% predictive interval: 1.00
```

بخش F: گزارش (۱۵ دقیقه)

یک پاراگراف روش‌ها و نتایج طبق چک‌لیست هفته‌ی ۱۲ بنویسید: مدل و پیشین‌ها (با کلمات و نمادها)، نمونه‌گیر و تنظیمات، تشخیص‌ها (بیشترین $\hat{R}$، کمترین ESS، divergenceها)، نتیجه‌ی PPC، و نتیجه‌گیری‌های سطح گروه (μ_d، σ_d، μ_c با بازه‌های ۹۵٪؛ $P(\mu_c > 0 \mid \text{data})$).

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. مدل complete pooling (یک d' و یک c برای همه) را در PyMC برازش کنید. برآورد d' آن را با μ_d مدل سلسله‌مراتبی، و بررسی پیش‌بینی پسینش را با بخش E مقایسه کنید. کدام شرکت‌کننده‌ها را نمی‌تواند پیش‌بینی کند؟

تمرین ۲ ⋆. بخش C را با پارامترسازی **متمرکز** (`d=pm.Normal("d",mu_d,sigma_d,dims="participant")`) دوباره اجرا کنید. divergenceها، ESS و زمان اجرا را مقایسه کنید. بعد داده را به ۱۰ × ۱۰ trial برای هر شرکت‌کننده کم کنید و دوباره مقایسه کنید.

تمرین ۳ ⋆⋆ **(تعداد trial نابرابر).** به نیمی از شرکت‌کننده‌ها ۲۰ trial و به نیمی دیگر ۲۰۰ trial بدهید (داده‌ی جدید شبیه‌سازی کنید). نشان دهید shrinkage، مثل مثال حل‌شده، به تعداد trialها بستگی دارد.

تمرین ۴ ⋆⋆ **(مقایسه‌ی مدل با LOO).** لگاریتم درست‌نمایی را با `pm.compute_log_likelihood(idata)` حساب کنید. در ArviZ `loo` برای هر مشاهده به یک لگاریتم درست‌نمایی نقطه‌ای نیاز دارد: آرایه‌های لگاریتم درست‌نمایی `hits` و `fas` را در یک آرایه‌ی واحد برای هر شرکت‌کننده جمع کنید (مثلاً `idata.log_likelihood["obs"]=idata.log_likelihood["hits"]+idata.log_likelihood["fas"]`) و `az.loo(idata,var_name="obs")` را صدا بزنید. مدل‌های سلسله‌مراتبی و complete pooling را با `az.compare` مقایسه کنید. تشخیص‌های Pareto-k را بررسی کنید و بگویید برای پیش‌بینی leave-one-participant-out چه معنایی دارند.

تمرین ۵ ⋆⋆⋆ **(پیشرفته: اثر گروه).** دو گروه ۱۲ نفره شبیه‌سازی کنید که حساسیت میانگینشان ۰.۴ فرق دارد. مدل را با یک اثر گروه β روی μ_d گسترش دهید ($d'_j = \mu_d + \beta \cdot \text{group}_j + \sigma_d z_j$)، β را برآورد کنید و $P(\beta > 0 \mid \text{data})$ را گزارش کنید. با یک آزمون t روی برآوردهای فردی d' مقایسه کنید.

lab check-off

نشان دهید: (۱) خروجی تشخیص‌ها (بدون divergence، $\hat{R}$، ESS)، (۲) نمودار shrinkage با مقایسه‌ی RMSE، و (۳) نمودار PPC همراه با پاراگراف بخش F.

گزارش پیشرفت پروژه (این هفته): یک گزارش وضعیت یک‌صفحه‌ای تحویل دهید (چه کارهایی انجام شده، یک نمودار برازش یا شبیه‌سازی اولیه، مسائل باز). نمره ندارد؛ بازخورد کتبی ظرف یک هفته داده می‌شود.

۷.۳.۵ ارتباط با هوش مصنوعی و LLMها

benchmarkهای هوش مصنوعی برای partial pooling. benchmarkها به دسته‌های تکلیف تقسیم می‌شوند، و بعضی دسته‌ها فقط چند آیتم دارند. گزارش دقت خام برای هر دسته عددهای پرنویز و گاهی حدی می‌دهد، درست مثل برازش‌های فردی SDT با trialهای کم. یک مدل سلسله‌مراتبی دقت دسته‌ها را نمونه‌هایی از یک توزیع مشترک در نظر می‌گیرد و دسته‌های کوچک را به سمت میانگین کلی shrink می‌کند. کد پایین از یک نسخه‌ی سریع empirical-Bayes استفاده می‌کند: یک مدل beta-binomial که پارامترهای گروهش با بیشینه کردن marginal likelihood روی یک grid برآورد می‌شوند. در تمرین‌ها نسخه‌ی بیزی کامل را در PyMC برازش می‌کنید.

Code ۰۶ · کد: `code/week13.py`، cell ۰۶ · سلول ۶

خروجی مورد انتظار:

```
items   true    raw  shrunk
    5  0.72  0.80   0.71
    8  0.63  0.88   0.74
   10  0.64  0.50   0.63
   15  0.63  0.67   0.68
   25  0.76  0.88   0.80
   40  0.69  0.55   0.60
   60  0.80  0.78   0.76
   80  0.51  0.57   0.60
group mean = 0.69, concentration = 19.9;  RMSE raw = 0.125, shrunk =
↪  0.066
```

دسته‌ی ۸آیتمی (خام ۸۸.۰، واقعی ۶۳.۰) به‌شدت پایین کشیده می‌شود، و برآوردهای shrinkشده در مجموع حدود دو برابر دقیق‌ترند (RMSE برابر ۰۶۶.۰ در برابر ۱۲۵.۰).

امتحانش کنید (بدون نیاز به API). (⋆ کدام دسته‌ها بیشتر از همه جابه‌جا می‌شوند، و چرا؟ جوابتان را به فرمول shrinkage در جزوه‌ی درس این هفته ربط دهید. ⋆⋆ همین مدل را در PyMC برازش کنید: `mu~Beta(2,2)`، `kappa~Gamma(shape=2,0.1, rate=0.1)` و `y_j~Binomial(n_j, theta_j~Beta(mu*kappa, (1-mu)*kappa))`. میانگین‌های پسین را با برآوردهای empirical-Bayes مقایسه کنید و تشخیص‌ها را بررسی کنید. ⋆⋆⋆ بحث: یک جدول رتبه‌بندی «دسته‌ای که مدل X در آن ضعیف‌ترین است» را برجسته می‌کند، که یک دسته‌ی ۵آیتمی است. به نویسندگان چه می‌گویید؟

۸.۳.۵ اشتباهات رایج و برداشت‌های نادرست

۱. shrinkage» **نتایج را سوگیر می‌کند.»** کمی سوگیری را با کاهش زیاد واریانس معاوضه می‌کند و به‌طور میانگین برآوردهای دقیق‌تری می‌دهد. اصولی است، نه یک تصحیح موقت.

۲. **نادیده گرفتن** divergenceها**.** حتی چندتایشان نشانه‌ی کاوش غیرقابل اعتماد است. reparameterize کنید (non-centered)، پیشین‌های پارامترهای مقیاس را تنگ‌تر کنید، یا `target_accept` را بالا ببرید.

۳. **پارامترسازی** centered **با داده‌ی کم.** قیف و divergence می‌سازد. برای مدل‌های سلسله‌مراتبی با trialهای کم برای هر شرکت‌کننده، به‌طور پیش‌فرض از non-centered استفاده کنید.

۴. **پیشین‌های مبهم برای انحراف معیارهای گروه.** پیشین‌های خیلی پهن روی σ می‌توانند پیش‌بینی‌های پیشین نامعقول و مشکلات نمونه‌گیری بسازند. پیشین‌های نیم‌نرمال با مقیاس معقول معمولاً بهترند.

۵. **جادو دانستن جعبه‌ی سیاه.** PyMC از هر مدلی که بنویسید، از جمله مدل‌های غلط، نمونه می‌گیرد. گردش کار (بررسی پیش‌بینی پیشین، تشخیص‌ها، (PPC همچنان کامل لازم است.

۶. **اجرای نمونه‌گیری چندپردازشی از یک اسکریپت در** Windows **بدون** main guard، که خطاهای مبهم multiprocessing می‌دهد. از `cores=1` یا `if __name__=="__main__":` استفاده کنید.

۷. **گزارش فقط برآوردهای فردی.** پارامترهای سطح گروه اغلب به سؤال پژوهشی واقعی جواب می‌دهند.

۹.۳.۵ خودآزمایی

۱. سه راه ترکیب داده بین شرکت‌کننده‌ها کدام‌اند و هرکدام درباره‌ی تفاوت‌های فردی چه فرضی دارند؟ **پاسخ** complete pooling (همه یکسان‌اند، $\sigma = 0$)، no pooling (شرکت‌کننده‌ها بی‌ارتباط‌اند، پس هیچ اطلاعاتی به اشتراک گذاشته نمی‌شود)، و partial pooling/سلسله‌مراتبی (شرکت‌کننده‌ها از یک توزیع مشترک می‌آیند که پراکندگی‌اش از داده برآورد می‌شود).

۲. دو شرکت‌کننده برآورد خام d' یکسانی دارند. چرا ممکن است مدل سلسله‌مراتبی یکی را خیلی بیشتر shrink کند؟ **پاسخ** shrinkage به دقت هر برآورد فردی بستگی دارد. شرکت‌کننده‌ای که trial کمتری دارد (SE بزرگ‌تر) اطلاعات کمتری دارد و قوی‌تر به سمت میانگین گروه کشیده می‌شود.

۳. چرا پارامترسازی non-centered اغلب ترجیح دارد؟ **پاسخ** شکل centered پسینی قیفی‌شکل می‌سازد (پارامترهای فردی وقتی انحراف معیار گروه کوچک است باید به هم فشرده شوند) که NUTS بد کاوشش می‌کند و divergence می‌دهد. نمونه‌گیری z_j استانداردشده و محاسبه‌ی $d'_j = \mu + \sigma z_j$ هندسه‌ای می‌دهد که کاوشش خیلی آسان‌تر است.

۴. divergence چیست و باید با آن چه کرد؟ **پاسخ** مسیری در NUTS که شبیه‌سازی عددی‌اش شکسته است، معمولاً در ناحیه‌ای با انحنای زیاد؛ نشان می‌دهد بخشی از پسین به‌طور قابل اعتماد کاوش نمی‌شود. reparameterize کنید، برای پارامترهای مقیاس از پیشین‌های آگاهی‌بخش‌تر استفاده کنید، یا `target_accept` را بالا ببرید، و بعد بررسی کنید که divergenceها ناپدید شده باشند.

۵. چرا HMC معمولاً در ابعاد بالا خیلی بهتر از Metropolis گام تصادفی مخلوط می‌شود؟ **پاسخ** از اطلاعات گرادیان برای حرکت‌های بلند و جهت‌دار که شکل پسین را دنبال می‌کنند استفاده می‌کند، پس پیشنهادهای دور هم هنوز احتمال پذیرش بالایی دارند. پیشنهادهای گام تصادفی، مگر اینکه خیلی ریز باشند، تقریباً همیشه رد می‌شوند.

۶. در یک مدل SDT سلسله‌مراتبی، کدام پارامتر به «آدم‌ها چقدر در حساسیت با هم فرق دارند؟» و کدام به «حساسیت معمول چقدر است؟» جواب می‌دهد؟ **پاسخ** به ترتیب σ_d (انحراف معیار سطح گروه) و μ_d (میانگین سطح گروه).

۷. مراحل گردش کار بیزی را فهرست کنید. **پاسخ** تعریف مدل و پیشین‌ها ← بررسی پیش‌بینی پیشین ← برازش با چند زنجیره ← تشخیص ($\hat{R}$، ESS، divergenceها، traceها) ← بررسی پیش‌بینی پسین ← در صورت نیاز مقایسه‌ی مدل‌ها ← تفسیر و گزارش.

۱۰.۳.۵ تکلیف

- A5 (MCMC) **از صفر)** در ابتدای درس هفته‌ی ۱۴ تحویل داده می‌شود.
- **گزارش پیشرفت پروژه** این هفته (بالا را ببینید).
- تکلیف نمره‌دار جدیدی نداریم: هفته‌های باقی‌مانده برای پروژه‌ی پایانی است.

۱۱.۳.۵ مطالعه‌ی بیشتر

- Wagenmakers & Lee **(۲۰۱۴)، فصل ۱۱.** نظریه‌ی تشخیص علامت، از جمله همان مدل SDT سلسله‌مراتبی‌ای که امروز پیاده‌سازی کردید. (منبع اصلی.)
- Kruschke **(۲۰۱۴)، فصل ۹.** مدل‌های سلسله‌مراتبی: partial pooling و shrinkage، قدم‌به‌قدم.
- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۹.** مدل‌سازی چندسطحی یا سلسله‌مراتبی داده‌های شناختی.
- Lao & Martin, Kumar **(۲۰۲۱)، فصل‌های ۲ و ۱۰.** تشخیص با ArviZ، و زبان‌های برنامه‌نویسی احتمالاتی PyMC) در پشت صحنه چطور کار می‌کند).

پیش‌نمایش هفته‌ی ۱۴: با جعبه‌ابزار کامل، گشتی در مدل‌هایی از حوزه‌های مختلف علوم شناختی می‌زنیم؛ با دسته‌بندی (مدل exemplar یعنی GCM و سازوکار سرعت–دقت مدل drift-diffusion شروع می‌کنیم.

فصل ۶

کاربردها در علوم شناختی

۱.۶ هفته‌ی ۱۴: مدل‌سازی در علوم شناختی ۱: دسته‌بندی (GCM) و تصمیم‌گیری (Drift-Diffusion)

فصل ۶: نمونه‌هایی از مدل‌سازی در حوزه‌های مختلف علوم شناختی · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌ی دسته‌بندی شبیه‌سازی‌شده برای ساختار کلاسیک ۵-۴، و داده‌ی انتخاب–RT شبیه‌سازی‌شده از یک فرایند drift-diffusion در یک طرح سرعت/دقت × آسان/سخت.

۱.۱.۶ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
categorization	دسته‌بندی	قرار دادن محرک در یک دسته
Generalized Context Model (GCM)	مدل بافت تعمیم‌یافته	مدل exemplar دسته‌بندی بر پایه‌ی شباهت
drift rate	نرخ رانش	سرعت میانگین جمع شدن شواهد؛ نشانه‌ی کیفیت شواهد
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
response time (RT)	زمان واکنش	فاصله‌ی ارائه‌ی محرک تا پاسخ
drift-diffusion model (DDM)	مدل drift-diffusion (رانش–انتشار)	انباشت پیوسته‌ی شواهد بین دو مرز
speed–accuracy trade-off	بده‌بستان سرعت و دقت	سریع‌تر پاسخ دادن به قیمت خطای بیشتر
accuracy	دقت	نسبت پاسخ‌های درست

English	فارسی	توضیح کوتاه
exemplar	نمونه (exemplar)	یک مورد ذخیره‌شده در حافظه از یک دسته
prototype	پیش‌نمونه (prototype)	خلاصه یا میانگین یک دسته
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
attention weight	وزن توجه	سهم توجه به هر بُعد محرک
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
EZ-diffusion	EZ-diffusion	برآورد ساده‌ی پارامترهای DDM از سه آماره
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند
evidence	شواهد	اطلاعاتی که برای تصمیم جمع می‌شود
stimulus	محرک	چیزی که به شرکت‌کننده نشان داده می‌شود
boundary separation	فاصله‌ی مرزها	مقدار شواهد لازم برای پاسخ؛ نشانه‌ی احتیاط
non-decision time	زمان غیرتصمیمی	زمان دیدن محرک و اجرای حرکت پاسخ
similarity	شباهت	نزدیکی دو محرک در فضای روان‌شناختی
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
embedding	embedding (بردار معنایی)	برداری که مدل برای یک کلمه یا متن می‌سازد

۲.۱.۶ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. نظریه‌های نمونه‌محور (exemplar) و پیش‌نمونه‌ای (prototype) دسته‌بندی را **توصیف کنند** و آن‌ها را به‌صورت GCM و یک مدل prototype **صورت‌بندی کنند**.
۲. GCM و مدل prototype را با MLE روی داده‌ی دسته‌بندی **برازش کنند، مقایسه کنند**، و وزن‌های توجه و حساسیت را **تفسیر کنند**.
۳. مدل drift-diffusion (DDM) را به‌عنوان حد پیوسته‌ی random walk هفته‌ی ۱ **توصیف کنند** و پارامترهایش را به سازه‌های شناختی **نگاشت کنند**.

۴. پارامترهای DDM را با روش بسته‌ی EZ-diffusion (closed-form) **برآورد کنند** و آن را با بازیابی پارامتر **اعتبارسنجی کنند**.
۵. اثرهای آزمایشی را بر حسب پارامترهای مدل **تفسیر کنند** («این دست‌کاری احتیاط را تغییر داد، نه کیفیت شواهد را»).

۳.۱.۶ مقدمه

۱۳ هفته‌ی اول یک جعبه‌ابزار ساختند، بیشتر روی دو مثال کوچک (فراموشی و .(SDT فصل ۶ جعبه‌ابزار را روی مدل‌هایی به کار می‌گیرد که کل حوزه‌های پژوهشی را شکل داده‌اند. این هفته دو تا از تأثیرگذارترین‌ها را می‌بینیم.

دسته‌بندی. چطور تصمیم می‌گیریم که یک حیوان تازه سگ است؟ نظریه‌ی *prototype* می‌گوید آن را با یک خلاصه‌ی دسته، یعنی سگ میانگین، مقایسه می‌کنیم. نظریه‌ی *exemplar* می‌گوید آن را با خاطره‌های ذخیره‌شده‌ی همه‌ی سگ‌ها (و همه‌ی گربه‌ها)یی که دیده‌ایم مقایسه می‌کنیم. هر دو معقول به نظر می‌رسند و بحث‌های کلامی سال‌ها رفت و برگشت. مدل‌های فرمال بودند که فرق را ساختند: ساختار دسته‌ی ۵-۴ مدین و شیفر طوری طراحی شد که دو نظریه برای محرک‌های مشخصی **پیش‌بینی‌های متضاد** داشته باشند. **مدل بافت تعمیم‌یافته** (GCM) نوسوفسکی نظریه‌ی exemplar را به یک مدل دقیق و قابل برازش با وزن‌های توجه تفسیرپذیر تبدیل کرد.

تصمیم‌گیری. در هفته‌ی ۱ یک random walk ساختیم که شواهد را تا رسیدن به یک مرز جمع می‌کند. نسخه‌ی پیوسته‌اش، **مدل** drift-diffusion، احتمالاً موفق‌ترین مدل روان‌شناسی شناختی است: دقت و کل توزیع‌های RT پاسخ‌های درست و خطا را توضیح می‌دهد، با پارامترهایی برای کیفیت شواهد، احتیاط و .non-decision time برای مطالعه‌ی پیری، ADHD، افسردگی، یادگیری و اثر داروها از آن استفاده می‌شود. برازش DDM کامل از نظر محاسباتی سنگین است، ولی روش EZ-diffusion با معادله‌های بسته از سه آماره‌ی خلاصه برآوردهای خوبی می‌دهد.

این موضوع کجا به کار می‌رود؟

- **مدل‌های دسته‌بندی** توضیح می‌دهند آدم‌ها چطور مفهوم‌ها را یاد می‌گیرند (دانشجوی پزشکی که یاد می‌گیرد ضایعه‌های پوستی را تشخیص دهد، کودکی که کلمه یاد می‌گیرد)، و برای طراحی آموزش بهتر استفاده می‌شوند: کدام مثال‌ها را و با چه ترتیبی نشان دهیم.
- **ایده‌ی** exemplar **در یادگیری ماشین:** طبقه‌بندهای نزدیک‌ترین همسایه (nearest neighbor) و روش‌های kernel یک مورد جدید را بر اساس شباهتش به مثال‌های ذخیره‌شده طبقه‌بندی می‌کنند؛ همان اصل .GCM
- **مدل** drift-diffusion یکی از پرکاربردترین مدل‌ها در علوم اعصاب شناختی و پژوهش بالینی است: سالمندی، ADHD، افسردگی، اضطراب، اثر داروها و بی‌خوابی. در پژوهش مصرف‌کننده (اینکه آدم‌ها با چه سرعتی بین محصولات انتخاب می‌کنند) و در عصب‌اقتصاد هم استفاده می‌شود.
- EZ-diffusion محبوب است چون برای هر نفر فقط سه آماره‌ی خلاصه لازم دارد و به بهینه‌سازی نیاز ندارد، پس می‌شود آن را سریع روی داده‌های موجود اجرا کرد.

۴.۱.۶ جزوه‌ی درس

به زبان ساده این هفته دو مدل معروف داریم. **دسته‌بندی:** چطور تصمیم می‌گیریم یک حیوان تازه سگ است؟ یک نظریه می‌گوید آن را با یک «سگ ایده‌آل» میانگین مقایسه می‌کنیم (prototype). نظریه‌ی دیگر می‌گوید آن را با همه‌ی سگ‌ها و گربه‌هایی که به یاد داریم مقایسه می‌کنیم و می‌بینیم در مجموع به کدام گروه بیشتر شبیه است (exemplar**ها**). GCM ایده‌ی exemplar

را به ریاضی تبدیل می‌کند: فاصله‌ی آیتم جدید با هر مثال ذخیره‌شده را بسنج (با **توجه** بیشتر به بعضی ویژگی‌ها)، فاصله را به شباهت تبدیل کن (نزدیک‌تر = خیلی شبیه‌تر)، و دسته‌ی A را با احتمال «شباهت کل به A / شباهت کل به همه» انتخاب کن. یک مجموعه محرک هوشمندانه (ساختار ۵-۴) کاری می‌کند که دو نظریه برای بعضی آیتم‌ها پیش‌بینی‌های متضاد داشته باشند. **تصمیم‌گیری: مدل** drift-diffusion نسخه‌ی پیوسته‌ی random walk هفته‌ی ۱ است. شواهد با سرعت میانگین v (کیفیت شواهد) به سمت مرز درست می‌رود و هم‌زمان نویز آن را تکان می‌دهد؛ وقتی به مرز a (احتیاط) برسد پاسخ داده می‌شود؛ یک زمان ثابت T_{er} هم برای دیدن و زدن کلید اضافه می‌شود. EZ-diffusion یک میان‌بر است که v، a و T_{er} را فقط از سه عدد حساب می‌کند: دقت، و میانگین و واریانس زمان واکنش پاسخ‌های درست.

زمان‌بندی پیشنهادی (۶۰ دقیقه): نظریه‌های دسته‌بندی و ساختار ۵-۴ · ۱۰ GCM · ۱۵ مدل prototype و پیش‌بینی‌های کلیدی ۵ · مدل drift-diffusion · ۱۵ EZ-diffusion · ۱۰ تفسیر ۵.

۱. ساختار دسته‌ی ۵-۴

محرک‌ها روی چهار بعد دودویی فرق دارند (مثلاً شکل، رنگ، اندازه و موقعیت یک شکل هندسی در طرح مدین و شیفر؛ ویژگی‌های چهره در نسخه‌های بعدی). شرکت‌کننده‌ها یاد می‌گیرند ۹ محرک آموزشی را در دسته‌های A و B بگذارند، و بعد ۷ محرک **انتقال** (transfer) تازه را بدون بازخورد دسته‌بندی می‌کنند. مجموعه محرک رایج این است [با Schaffer, & Medin ۱۹۷۸ یا Smith & Minda, ۲۰۰۰ بررسی شود]:

دسته‌ی A	دسته‌ی B	انتقال
۱۱۱۰ A1	۱۱۰۰ B1	۱۰۰۱ T1
۱۰۱۰ A2	۰۱۱۰ B2	۱۰۰۰ T2
۱۰۱۱ A3	۰۰۰۱ B3	۱۱۱۱ T3
۱۱۰۱ A4	۰۰۰۰ B4	۰۰۱۰ T4
۰۱۱۱ A5		۰۱۰۱ T5
		۰۰۱۱ T6
		۰۱۰۰ T7

prototype دسته‌ی A برابر ۱۱۱۱ و prototype دسته‌ی B برابر ۰۰۰۰ است. مقایسه‌ی کلیدی: A1 **(۱۱۱۰)** سه ویژگی با prototype دسته‌ی A مشترک دارد، ولی A2 **(۱۰۱۰)** فقط دو تا. پس مدل prototype پیش‌بینی می‌کند A1 بهتر از A2 دسته‌بندی شود. اما A2 به دو exemplar دیگر A (یعنی A1 و A3) خیلی شبیه است و به هیچ exemplar از B شبیه نیست، در حالی که A1 به دو exemplar از B (یعنی B1 و B2) خیلی شبیه است. پس مدل exemplar می‌تواند پیش‌بینی کند که A2 دست‌کم به خوبیِ A1 دسته‌بندی شود، و در داده‌های تجربی A2 معمولاً بهتر دسته‌بندی می‌شود.

۲. مدل بافت تعمیم‌یافته (GCM)

فاصله بین محرک i و exemplar ذخیره‌شده‌ی e، با وزن‌های توجه $w_m \geq 0$ و $\sum_m w_m = 1$ (متریک city-block برای ابعاد جدایی‌پذیر):

$$\text{dist}_{ie} = \sum_{m=1}^{4} w_m \, |x_{im} - x_{em}|.$$

شباهت با فاصله به‌صورت نمایی کم می‌شود، با **حساسیت** c:

$$s_{ie} = \exp(-c \cdot \text{dist}_{ie}).$$

قاعده‌ی انتخاب (شباهت جمع‌شده، نسبت Luce):

$$P(A \mid i) = \frac{\sum_{e \in A} s_{ie}}{\sum_{e \in A} s_{ie} + \sum_{e \in B} s_{ie}}.$$

پارامترها: c (شباهت با فاصله چقدر تند کم می‌شود؛ c بزرگ یعنی فقط exemplarهای خیلی نزدیک مهم‌اند) و سه وزن توجه آزاد (چهارمی ۱ - $ بقیه است)، پس $k = 4$. (این همان c چندمعنایی جدول نمادگذاری هفته‌ی ۱ است؛ این هفته یعنی حساسیت، نه ملاک SDT.)

تفسیر وزن‌های توجه: w_m سهم توجهی است که به بعد m داده می‌شود. توجه بهینه روی ابعادی تأکید می‌کند که برای دسته تشخیصی (diagnostic) هستند. در ساختار ۵-۴، ابعاد ۱ و ۳ تشخیصی‌ترین‌اند.

مدل prototype: همان فاصله، شباهت و قاعده‌ی انتخاب، ولی هر دسته فقط با prototype خودش نمایش داده می‌شود: $P(A \mid i) = s_{i,P_A}/(s_{i,P_A} + s_{i,P_B})$. این هم $k = 4$ دارد، پس شمارش پارامترها روی مقایسه اثری ندارد.

درست‌نمایی: اگر محرک i به تعداد n_i بار دسته‌بندی شود و y_i بار «A» نامیده شود، $y_i \sim \text{Binomial}(n_i, P(A \mid i))$ است و با MLE و multi-start برازش می‌شود (هفته‌های ۳-۴). وزن‌ها بهتر است با یک reparameterization softmax (هفته‌ی ۳) برآورد شوند، $w = \text{softmax}(\eta_1, \eta_2, \eta_3, 0)$، و $c = e^{\gamma}$.

> **پیشرفته:** GCM کامل یک پارامتر سوگیری پاسخ b_A، یک توان شباهت (شباهت گاوسی در برابر نمایی)، یک پارامتر متریک r (city-block با $r = 1$ در برابر اقلیدسی با $r = 2$) و گاهی یک پارامتر قطعیت پاسخ (response determinism) γ (به توان رساندن شباهت‌های جمع‌شده) اضافه می‌کند. Lee & Wagenmakers (فصل ۱۷) یک GCM بیزی و سلسله‌مراتبی می‌سازند.

خواندن ریاضی

- **فاصله** $\sum_m w_m |x_{im} - x_{em}|$: ویژگی‌هایی را بشمار که آیتم جدید i و مثال ذخیره‌شده‌ی e در آن‌ها فرق دارند، ولی هر ویژگی را با توجه آن یعنی w_m وزن بده. با ۴ ویژگی دودویی و وزن‌های برابر ۲۵.۰، یک ویژگی ناهمخوان فاصله‌ی ۲۵.۰ می‌دهد.
- **شباهت** $e^{-c \cdot \text{dist}}$: فاصله‌ی ۰ شباهت ۱ می‌دهد؛ با $c = 2$، فاصله‌ی ۲۵.۰ شباهت $e^{-0.5} = 0.61$ و فاصله‌ی ۱ شباهت $e^{-2} = 0.14$ می‌دهد. c بزرگ‌تر باعث می‌شود شباهت سریع‌تر کم شود، پس فقط مثال‌های خیلی نزدیک مهم‌اند.
- **قاعده‌ی انتخاب:** شباهت‌ها به همه‌ی مثال‌های A و همه‌ی مثال‌های B را جمع بزن و تقسیم کن. در مثال حل‌شده، T3 شباهت کل ۷۹.۲ به A و ۰۹.۱ به B دارد، پس $P(A) = 2.79/3.89 = 0.72$.

۳. مدل drift-diffusion (DDM)

random walk هفته‌ی ۱ را بگیرید و بگذارید اندازه‌ی گام و مدت گام با هم کوچک شوند. آن‌وقت شواهد $X(t)$ به‌طور پیوسته تغییر می‌کند:

$$dX = v\,dt + s\,dW(t), \qquad X(0) = z,$$

که در آن dW نویز سفید گاوسی (فرایند Wiener) است. وقتی X به a (درست) یا 0 (خطا) برسد پاسخ داده می‌شود؛ $\text{RT} = T_{\text{decision}} + T_{er}$.

پارامتر	معنا	دست‌کاری معمولی که تغییرش می‌دهد
v (drift rate)	کیفیت / نرخ انباشت شواهد	دشواری محرک؛ حساسیت ادراکی؛ توجه
a (فاصله‌ی مرزها)	احتیاط پاسخ (تنظیم سرعت–دقت)	دستورالعمل سرعت در برابر دقت
z (نقطه‌ی شروع)	سوگیری پیشینی به سمت یک پاسخ	نرخ‌های پایه، پاداش‌ها
T_{er} (non-decision time)؛ هم t_0 نوشته می‌شود)	زمان رمزگذاری + حرکتی	نوع پاسخ، تخریب محرک
s (نویز درون trial)	ثابت مقیاس	ثابت (طبق قرارداد $s = 0.1$ در EZ و $s = 1$ در جاهای دیگر)

DDM کامل تغییرپذیری بین trialها در drift، نقطه‌ی شروع و non-decision time را هم دارد. تمرین ۵ هفته‌ی ۱ نشان داد که تغییرپذیری drift خطاهای کند تولید می‌کند.

پیش‌بینی‌های شاخص: توزیع‌های RT چوله به راست؛ trade-off سرعت–دقت وقتی a تغییر می‌کند؛ محرک‌های آسان‌تر که پاسخ‌هایی هم سریع‌تر و هم دقیق‌تر می‌دهند (v بالاتر)؛ تغییر T_{er} که کل توزیع RT را بدون تغییر شکلش جابه‌جا می‌کند.

خواندن ریاضی $dX = v\,dt + s\,dW(t)$ این‌طور خوانده می‌شود: «در یک گام زمانی خیلی کوچک dt، شواهد به اندازه‌ی یک هل قطعی $v\,dt$ به‌علاوه‌ی یک ضربه‌ی تصادفی $s\,dW$ تغییر می‌کند». dW نویز گاوسی است که واریانسش متناسب با dt است (پس در یک گام به طول dt ضربه انحراف معیار $s\sqrt{dt}$ دارد). در شبیه‌سازی lab این دقیقاً همان random walk هفته‌ی ۱ با گام‌های کوچک است: `x+=v*dt+s*sqrt(dt)*randn()`. جدول پارامترها بخشی است که باید به خاطر سپرد: v = کیفیت شواهد، a = احتیاط، z = سوگیری، T_{er} = non-decision time.

۴. EZ-diffusion

Wagenmakers، van der Maas و Grasman (۲۰۰۷) برآوردهای بسته‌ی v، a و T_{er} را (با فرض $z = a/2$، بدون تغییرپذیری بین trialها، $s = 0.1$) از سه آماره به دست آوردند: نسبت پاسخ‌های درست P_c، **واریانس** RTهای درست V_{RT} (بر حسب s^2) و **میانگین** RTهای درست M_{RT} (بر حسب s):

$$L = \operatorname{logit}(P_c) = \ln\frac{P_c}{1-P_c}, \qquad x = \frac{L\,(LP_c^2 - LP_c + P_c - 0.5)}{V_{RT}},$$

$$v = \operatorname{sign}(P_c - 0.5)\; s\; x^{1/4}, \qquad a = \frac{s^2 L}{v},$$

$$y = -\frac{va}{s^2}, \qquad \mathrm{MDT} = \frac{a}{2v}\cdot\frac{1-e^{y}}{1+e^{y}}, \qquad T_{er} = M_{RT} - \mathrm{MDT}.$$

حالت‌های مرزی: فرمول‌ها در $P_c = 0.5$ (که آن‌وقت $v = 0$) و $P_c = 1$ (که آن‌وقت $L = \infty$) کار نمی‌کنند. برای $P_c = 1$ یک راه‌حل استاندارد استفاده از $P_c = 1 - 1/(2N)$ است، شبیه تصحیح‌های نرخ حدی هفته‌ی ۲.

نقاط قوت و محدودیت‌ها. EZ سریع است، به بهینه‌سازی نیاز ندارد و وقتی فرض‌هایش برقرارند پارامترها را خوب بازیابی می‌کند (بخش C lab). RTهای خطا و شکل توزیع RT فراتر از میانگین و واریانس را نادیده می‌گیرد، و نمی‌تواند سوگیری یا تغییرپذیری‌های بین trialها را برآورد کند. برای این‌ها DDM کامل را با MLE یا روش‌های بیزی سلسله‌مراتبی برازش کنید (مثلاً بسته‌ی HDDM یا درست‌نمایی Wiener در PyMC/Stan).

خواندن ریاضی معادله‌های EZ ترسناک به نظر می‌رسند ولی یک دستور پخت‌اند؛ لازم نیست کسی آن‌ها را حفظ کند.

۱. $L = \ln(P_c/(1-P_c))$: logit دقت («لگاریتم بخت درست بودن»). $P_c = 0.8$ می‌دهد $L = \ln 4 = 1.39$.
۲. x دقت را با **واریانس** زمان واکنش پاسخ‌های درست ترکیب می‌کند: هرچه زمان‌های واکنش برای یک دقت مشخص پراکنده‌تر باشند، drift کمتر است.
۳. بعد v و a از L و x به دست می‌آیند؛ MDT میانگین زمان تصمیم پیش‌بینی‌شده است.
۴. $T_{er} = M_{RT} - \text{MDT}$: هر بخشی از میانگین زمان واکنش که زمان تصمیم نیست، non-decision time است.

از مثال حل‌شده (بخش ۲) برای نشان دادن هر قدم با عدد استفاده کنید؛ بعد بگذارید کامپیوتر انجامش دهد (تابع `ez_diffusion` در کد lab).

برای یک مهندس

- GCM یک طبقه‌بند مبتنی بر شباهت با کرنل نمایی و یک متریک L1 وزن‌دار (city-block) است، نزدیک به یک **طبقه‌بند کرنلی / پنجره‌ی Parzen**. وزن‌های توجه مثل وزن‌های یادگرفته‌شده‌ی ویژگی‌ها عمل می‌کنند؛ c معکوس پهنای کرنل است.
- DDM یک **فرایند Wiener با رانش** بین دو مرز جاذب است: مسئله‌ی کلاسیک زمان اولین عبور (first-passage time). SPRT پیوسته در زمان (کادر هفته‌ی ۱) دقیقاً همین فرایند است، با v متناسب با دامنه‌ی سیگنال و s سطح نویز.
- توزیع‌های زمان واکنش همان **توزیع‌های زمان اولین عبور** هستند و به همان دلیلی چوله به راست‌اند که تأخیرهای آشکارسازی یک آشکارساز ترتیبی.
- EZ-diffusion یک تخمین‌گر روش گشتاورها (method of moments) است: سه گشتاور نمونه (دقت، میانگین و واریانس زمان واکنش‌های درست) را با عبارت‌های بسته‌ی مدل برابر می‌گذارد، به جای اینکه درست‌نمایی را بیشینه کند.

برای مدرس

- **بگذارید دانشجوها خودشان شرکت‌کننده باشند.** پیش از GCM، ۹ محرک آموزشی ساختار ۵-۴ را به شکل نقاشی‌های ساده نشان دهید (مثلاً شکل‌هایی با ۴ ویژگی دودویی)، دسته‌ها را با بازخورد یاد بدهید و بعد A1 و A2 را آزمون کنید. داده‌ی خود کلاس اغلب الگوی exemplar را نشان می‌دهد.
- **DDM را با همان تصویر هفته‌ی ۱ و یک مسیر هموار و پرنویز بکشید.** بعد هر بار یک پارامتر را روی تخته تغییر دهید (مرزهای دورتر، drift تندتر، شروع دیرتر) و بپرسید دقت و زمان واکنش چه می‌شود.
- **EZ را اثبات نکنید.** آن را به‌عنوان یک «ماشین‌حساب» معرفی کنید و وقت را روی تفسیر بگذارید (بخش E lab: کدام دست‌کاری کدام پارامتر را تغییر داد.
- **سؤال‌های رایج.**
  - «*prototype* یا *exemplar*، کدام برنده شد؟» برای دسته‌های کوچک و کم‌ساختار معمولاً مدل‌های exemplar بهتر برازش می‌شوند؛ برای دسته‌های بزرگ و پرساختار prototype هم خوب کار می‌کند. هر دو ایده در مدل‌های امروزی زنده‌اند.
  - «چرا فقط میانگین زمان واکنش را مقایسه نکنیم؟» یک گروه کندتر ممکن است محتاط‌تر باشد، شواهد بدتری داشته باشد یا از نظر حرکتی کندتر باشد؛ فقط DDM این‌ها را جدا می‌کند.
  - «آیا پارامترهای *EZ* و *DDM* کامل یکی‌اند؟» همان کمیت‌ها را برآورد می‌کنند، ولی EZ فرض می‌کند سوگیری و تغییرپذیری بین trialها وجود ندارد.

۵.۱.۶ مثال حل‌شده

بخش ۱: یک پیش‌بینی GCM با دست

محرک T3 (۱۱۱۱)، توجه برابر $w_m = 0.25$، حساسیت $c = 2$.

Exemplar	ابعاد ناهمخوان	فاصله	شباهت $e^{-2\,\text{dist}}$
A1 ۱۱۱۰	۱	۲۵.۰	۶۰۷.۰
A2 ۱۰۱۰	۲	۵۰.۰	۳۶۸.۰
A3 ۱۰۱۱	۱	۲۵.۰	۶۰۷.۰
A4 ۱۱۰۱	۱	۲۵.۰	۶۰۷.۰
A5 ۰۱۱۱	۱	۲۵.۰	۶۰۷.۰
جمع A			**۷۹۴.۲**
B1 ۱۱۰۰	۲	۵۰.۰	۳۶۸.۰
B2 ۰۱۱۰	۲	۵۰.۰	۳۶۸.۰
B3 ۰۰۰۱	۳	۷۵.۰	۲۲۳.۰
B4 ۰۰۰۰	۴	۰۰.۱	۱۳۵.۰
جمع B			**۰۹۴.۱**

$$P(A \mid \text{T3}) = \frac{2.794}{2.794 + 1.094} = 0.719.$$

تفسیر. T3 خودِ prototype دسته‌ی A است، ولی مدل exemplar با این پارامترها فقط حدود ۷۲٪ پاسخ «A» پیش‌بینی می‌کند: دو exemplar از B (یعنی B1 و B2) فقط دو ویژگی فاصله دارند. یک c بزرگ‌تر (شباهت تیزتر) این احتمال را بالا می‌برد، چون نزدیک‌ترین همسایه‌ها (چهار exemplar از A در فاصله‌ی ۲۵.۰) غالب می‌شوند.

بخش ۲: EZ-diffusion با دست

یک شرکت‌کننده $P_c = 0.802$، $V_{RT} = 0.112$ s² و $M_{RT} = 0.723$ s دارد.

۱. $L = \ln(0.802/0.198) = 1.399$.
۲. $x = 1.399 \times (1.399 \times 0.643 - 1.399 \times 0.802 + 0.802 - 0.5)/0.112 = 0.998$.
۳. $v = 0.1 \times 0.998^{1/4} = 0.100$.
۴. $a = 0.01 \times 1.399/0.100 = 0.140$.
۵. $y = -0.100 \times 0.140/0.01 = -1.399$، پس $\text{MDT} = (0.140/0.200) \times (1 - e^{-1.399})/(1 + e^{-1.399}) = 0.423$ s.
۶. $T_{er} = 0.723 - 0.423 = 0.300$ s.

تفسیر. از میانگین RT درست ۷۲۳ میلی‌ثانیه، حدود ۴۲۳ میلی‌ثانیه صرف انباشت شواهد و ۳۰۰ میلی‌ثانیه صرف رمزگذاری و پاسخ می‌شود. drift ۱۰.۰ و مرز ۱۴.۰ (در واحدهای EZ با $s = 0.1$) مقادیر معمولی برای یک تکلیف با دشواری متوسط‌اند.

۶.۱.۶ lab (۲ ساعت)

اهداف

۱. پیاده‌سازی GCM و مدل prototype برای ساختار ۵-۴؛ شبیه‌سازی داده از GCM.
۲. برازش هر دو مدل با MLE، مقایسه‌شان، و بررسی پیش‌بینی کلیدی A1 در برابر A2.
۳. بررسی بازیابی پارامتر برای GCM.
۴. شبیه‌سازی یک فرایند drift-diffusion، بازیابی پارامترهایش با EZ-diffusion، و تفسیر یک آزمایش ۲ × ۲.

زمان‌بندی: بخش A ۲۰ دقیقه · بخش B ۲۵ دقیقه · بخش C ۱۵ دقیقه · بخش D ۴۰ دقیقه · بخش E ۲۰ دقیقه.

بخش A: ساختار ۵-۴ و دو مدل (۲۰ دقیقه)

Code · **کد:** `code/week14.py`، cell ۱ · سلول ۱

خروجی مورد انتظار:

```
stimulus features  P(A) true  A responses / 20
      A1     1110       0.84                15
      A2     1010       0.88                18
      A3     1011       0.91                18
      A4     1101       0.60                10
      A5     0111       0.60                11
      B1     1100       0.47                10
      B2     0110       0.47                11
      B3     0001       0.16                 4
      B4     0000       0.12                 2
      T1     1001       0.58                11
      T2     1000       0.48                11
      T3     1111       0.87                20
      T4     0010       0.48                10
      T5     0101       0.26                 6
      T6     0011       0.58                12
      T7     0100       0.19                 4
```

بخش B: برازش و مقایسه (۲۵ دقیقه)

Code · **کد:** `code/week14.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
GCM       NLL =  28.36  AIC =  64.72  BIC =  79.79  c = 3.82  w = [0.397
↪  0.111 0.426 0.066]
prototype NLL =  30.02  AIC =  68.04  BIC =  83.11  c = 1.90  w = [0.435
↪  0.009 0.461 0.095]
stimulus  observed   GCM  prototype
      A1      0.75 0.842      0.822
      A2      0.90 0.884      0.818
```

تفسیر کنید: ۱. کدام مدل ترجیح دارد و شواهد چقدر قوی است؟ ($\Delta\text{AIC} = 3.3$)، پس وزن‌های Akaike حدود ۸۴.۰ در برابر ۱۶.۰: ترجیحی متوسط، نه قاطع.) ۲. به A1 و A2 نگاه کنید. داده نشان می‌دهد A2 (۹۰.۰) بهتر از A1 (۷۵.۰) دسته‌بندی شده. GCM این ترتیب را پیش‌بینی می‌کند (۸۸.۰ در برابر ۸۴.۰)؛ مدل prototype نمی‌تواند (۸۲.۰ در برابر ۸۲.۰). چرا این مقایسه بین دو نظریه تیزتر از آماره‌ی برازش کلی تمایز می‌گذارد؟ ۳. وزن‌های توجه GCM را تفسیر کنید. شرکت‌کننده به کدام ابعاد توجه کرده، و آیا با ساختار دسته جور درمی‌آید؟

بخش C: آیا GCM در این طرح قابل بازیابی است؟ (۱۵ دقیقه)

کد: Code ۰ `code/week14.py`، cell ۳ ۰ سلول ۳

خروجی مورد انتظار (حدود ۱ دقیقه):

```
c: r(true, recovered) = 0.08
w1: r(true, recovered) = 0.91
w2: r(true, recovered) = 0.76
w3: r(true, recovered) = 0.89
w4: r(true, recovered) = 0.85
```

به چه دقت کنید: وزن‌های توجه خوب بازیابی می‌شوند (r = ۷۶.۰–۹۱.۰)، ولی حساسیت c در این طرح عملاً **قابل بازیابی نیست** (r = ۰۸.۰). با فقط ۱۶ محرک و ۲۰ trial برای هرکدام، یک c بزرگ و یک c متوسط می‌توانند نسبت‌های پاسخ خیلی شبیهی بدهند (وقتی c بزرگ شد، پیش‌بینی‌ها اشباع می‌شوند)، و c با میزان متمرکز بودن وزن‌ها trade-off دارد. پس باید وزن‌های توجه بخش B را تفسیر کنیم ولی مقدار $\hat{c} = 3.82$ را **نه**. trialهای بیشتر، دامنه‌ی محرک گسترده‌تر، یا یک پیشین بیزی روی c کمک می‌کند. این دقیقاً همان نوع نتیجه‌ای است که مطالعه‌ی بازیابی برایش ساخته شده (هفته‌ی ۷).

بخش D: drift-diffusion و EZ (۴۰ دقیقه)

کد: Code ۰ `code/week14.py`، cell ۴ ۰ سلول ۴

خروجی مورد انتظار (حدود ۳۰ ثانیه):

```
instruction difficulty    Pc   MRT  v_true  v_EZ  a_true  a_EZ  Ter_EZ
      speed       easy 0.870 0.423    0.25 0.243    0.08 0.078   0.304
      speed       hard 0.732 0.466    0.12 0.115    0.08 0.088   0.288
   accuracy       easy 0.975 0.572    0.25 0.261    0.14 0.140   0.317
   accuracy       hard 0.818 0.697    0.12 0.111    0.14 0.135   0.313
```

Code · **کد:** `code/week14.py`، cell ۵ · سلول ۵

بخش E: تفسیر آزمایش ۲ × ۲ (۲۰ دقیقه)

در notebook جواب دهید: ۱. کدام پارامتر EZ با دست‌کاری **دستورالعمل** تغییر می‌کند و کدام با **دشواری**؟ آیا هیچ‌کدام از دست‌کاری‌ها روی پارامتری که نباید اثر بگذارد اثر گذاشت؟ ۲. توصیف کنید توزیع RT از دستورالعمل سرعت به دقت چطور تغییر می‌کند (نمودار بخش D.). کدام بخش توزیع بیشتر تغییر می‌کند: لبه‌ی جلویی یا دنباله؟ ۳. یک مطالعه‌ی بالینی نشان می‌دهد بیماران از گروه کنترل کندترند ولی به همان اندازه دقیق. دو تبیین مختلف DDM برای این نتیجه طرح کنید و بگویید کدام داده‌ها بین آن‌ها تمایز می‌گذارند.

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. $P(A \mid \text{A1})$ و $P(A \mid \text{A2})$ را برای وزن‌های برابر و $c = 2$ تحت هر دو مدل با دست حساب کنید. آیا پیش‌بینی کلیدی را بازتولید می‌کنند؟

تمرین ۲ ⋆. EZ را روی آماره‌های مثال حل‌شده و روی $P_c = 1.0$ با $N = 100$ trial (با تصحیح مرزی) اعمال کنید. بدون تصحیح چه اتفاقی می‌افتد؟

تمرین ۳ ⋆⋆ **(داده‌ی prototype).** داده را از مدل prototype تولید کنید و هر دو مدل را برازش کنید. آیا مقایسه‌ی مدل، مدل مولد را تشخیص می‌دهد؟ یک بازیابی مدل کوچک اجرا کنید (۲۰ مجموعه داده برای هر مدل مولد) و confusion matrix ۲ × ۲ را بسازید.

تمرین ۴ ⋆⋆ **(بازیابی و سوگیری).** برای ۲۰۰ شرکت‌کننده‌ی شبیه‌سازی‌شده با (v, a, T_{er}) تصادفی و فقط ۱۰۰ trial برای هرکدام، برآوردهای EZ را با مقادیر واقعی مقایسه کنید. کدام پارامتر بدتر از همه بازیابی می‌شود؟ بعد تغییرپذیری بین trialها drift را به شبیه‌ساز اضافه کنید (تمرین ۵ هفته‌ی ۱) و ببینید کدام برآورد EZ سوگیر می‌شود.

تمرین ۵ ⋆⋆⋆ **(پیشرفته: GCM بیزی).** GCM را در PyMC با پیشین‌های $c \sim \text{Gamma}(2, \text{scale } 2)$ و $w \sim \text{Dirichlet}(1, 1, 1)$ برازش کنید. پسین وزن‌های توجه را با MLE مقایسه کنید و یک بررسی پیش‌بینی پسین روی تفاوت A1 و A2 اجرا کنید. (برای نسخه‌ی سلسله‌مراتبی، Wagenmakers & Lee فصل ۱۷ را ببینید.)

lab check-off

نشان دهید: (۱) جدول برازش و نمودار پیش‌بینی GCM در برابر مدل prototype همراه با جوابتان به سؤال ۲، (۲) جدول EZ برای طرح ۲ × ۲، و (۳) جوابتان به سؤال ۱ بخش E.

۷.۱.۶ ارتباط با هوش مصنوعی و LLMها

مدل‌های exemplar در یک «فضای معنایی» یادگرفته‌شده. GCM به یک فضای روان‌شناختی نیاز دارد تا فاصله‌ها را در آن اندازه بگیرد. به‌طور سنتی این فضا از رتبه‌بندی‌های شباهت و مقیاس‌بندی چندبعدی (MDS) می‌آید. مدل‌های زبانی یک جایگزین پیشنهاد می‌کنند: هر کلمه یا جمله به یک **بردار** embedding نگاشت می‌شود، و فاصله‌ی بین بردارها اغلب به جای شباهت روان‌شناختی استفاده می‌شود. ترکیب embeddingها با GCM مدلی می‌دهد که می‌تواند هر کلمه‌ی تازه‌ای را بدون رتبه‌بندی شباهت اضافه دسته‌بندی کند. اینکه فاصله‌های embedding با شباهت انسانی جور درمی‌آیند یا نه یک سؤال تجربی است، و می‌توانید آن را با ابزارهای این درس بیازمایید.

> Code · **کد:** `code/week14.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
P(fruit | tomato) = 0.902
P(fruit | knife) = 0.094
P(fruit | nutcracker) = 0.370
```

امتحانش کنید (بدون نیاز به API). c را به ۱ و به ۱۰ تغییر دهید. سه پیش‌بینی چطور عوض می‌شوند، و چرا «nutcracker» بیشتر از همه تغییر می‌کند؟ - ★★ فرض کنید ۲۰ شرکت‌کننده سه محرک آزمون را دسته‌بندی کرده‌اند، با ۱۹، ۱ و ۱۲ پاسخ «fruit». c را با MLE برازش کنید (درست‌نمایی دوجمله‌ای، هفته‌ی ۴) و یک آزمون G^2 اجرا کنید. آیا فضای embedding با یک پارامتر برازش خوبی دارد؟ - ★★ بحث: embeddingها از متن یاد گرفته شده‌اند، نه از ادراک. برای کدام دسته‌ها ممکن است شباهت مبتنی بر متن به‌طور نظام‌مند با شباهت انسانی فرق کند (به رنگ یا شکل فکر کنید)؟

۸.۱.۶ اشتباهات رایج و برداشت‌های نادرست

۱. **وزن‌های توجه بدون قید.** بدون قید جمع‌برابر-یک، c و w کاملاً با هم trade-off دارند (non-identifiable). از reparameterization softmax استفاده کنید.

۲. **قضاوت درباره‌ی مدل‌های exemplar و prototype فقط با برازش کلی.** پیش‌بینی‌هایی که از نظر نظری تشخیصی‌اند (A1) در برابر (A2) اغلب آگاهی‌بخش‌تر از تفاوت‌های کوچک AIC هستند.

۳. **میانگین‌گیری داده‌ی دسته‌بندی روی شرکت‌کننده‌هایی** که به ابعاد مختلف توجه می‌کنند. این می‌تواند یک فرد exemplarگونه را prototypeگونه نشان دهد (و برعکس)؛ خطاهای میانگین‌گیری هفته‌ی ۵ را به یاد بیاورید.

۴. **استفاده از EZ با واحدهای غلط.** RTها باید بر حسب **ثانیه** و واریانس بر حسب s^2 باشد، با $s = 0.1$. قاطی کردن ms و s نتیجه‌ی بی‌معنی می‌دهد.

۵. **استفاده از EZ وقتی فرض‌هایش نقض شده‌اند** (سوگیری قوی، خطاهای کند یا سریع). RTهای خطا را بررسی کنید؛ در صورت نیاز از DDM کامل استفاده کنید.

۶. **«گروه کندتر drift rate پایین‌تری دارد.»** کندی می‌تواند از مرز بالاتر، drift پایین‌تر یا non-decision time طولانی‌تر بیاید. فقط مدلی که روی دقت و توزیع‌های RT برازش شده می‌تواند بگوید کدام.

۷. **فراموش کردن حالت‌های مرزی $P_c = 1$ یا $P_c \le 0.5$ در EZ.**

۹.۱.۶ خودآزمایی

۱. تفاوت اصلی نظریه‌های exemplar و prototype را هرکدام در یک جمله بیان کنید. **پاسخ** :Exemplar یک دسته با همه‌ی نمونه‌های ذخیره‌شده نمایش داده می‌شود و دسته‌بندی به شباهت جمع‌شده با آن‌ها بستگی دارد. :Prototype یک دسته با یک خلاصه‌ی واحد (گرایش مرکزی) نمایش داده می‌شود و دسته‌بندی به شباهت با آن خلاصه بستگی دارد.

۲. در ساختار ۵-۴، چرا مقایسه‌ی A1 و A2 تشخیصی است؟ **پاسخ** A1 به prototype دسته‌ی A نزدیک‌تر است (۳ از ۴ ویژگی)، پس مدل prototype پیش‌بینی می‌کند بهتر از A2 دسته‌بندی شود. ولی A2 به exemplarهای دیگر A خیلی شبیه است و به هیچ exemplar از B شبیه نیست، در حالی که A1 به دو exemplar از B شبیه است، پس مدل exemplar می‌تواند A2 $\geq$ A1 را پیش‌بینی کند. دو نظریه پیش‌بینی‌های ترتیبی متضاد دارند.

۳. پارامترهای c و w_m در GCM چه چیزی را نشان می‌دهند؟ **پاسخ** c حساسیت است: شباهت با فاصله‌ی روان‌شناختی چقدر سریع کم می‌شود (c بزرگ یعنی فقط exemplarهای خیلی نزدیک مهم‌اند). w_m نسبت توجهی است که به بعد m داده می‌شود و فاصله‌ها را در امتداد ابعاد مورد توجه کش می‌دهد.

۴. انتظار دارید کدام پارامتر DDM تحت این موارد تغییر کند: (الف) دستورالعمل سرعت در برابر دقت، (ب) محرک‌های سخت‌تر، (ج) پاسخ حرکتی کندتر (مثلاً پا به جای انگشت)؟ **پاسخ** (الف) فاصله‌ی مرزها a. (ب) drift rate v. (ج) non-decision time T_{er}.

۵. EZ-diffusion به کدام سه آماره نیاز دارد و فرض‌های اصلی‌اش چیست؟ **پاسخ** نسبت پاسخ‌های درست، واریانس RTهای درست و میانگین RTهای درست. فرض می‌کند نقطه‌ی شروع بی‌سوگیر است ($z = a/2$)، پارامترها تغییرپذیری بین trialها ندارند، و مقیاس $s = 0.1$ است.

۶. DDM چه ارتباطی با مدل random walk هفته‌ی ۱ دارد؟ **پاسخ** حد زمان-پیوسته و شواهد-پیوسته‌ی random walk است: وقتی اندازه‌ی گام و مدت گام با هم به صفر میل کنند، random walk به یک فرایند انتشار Wiener با drift v و نویز s همگرا می‌شود.

۱۰.۱.۶ تکلیف

- A5 (MCMC) **از صفر)** در ابتدای درس این هفته تحویل داده می‌شود.
- تکلیف جدیدی نداریم: روی **پروژه‌ی پایانی** کار کنید. اگر پروژه‌تان از GCM یا DDM استفاده می‌کند، کد امروز نقطه‌ی شروع خوبی است؛ به مواد درس ارجاع دهید و بگویید چه چیزی را تغییر داده‌اید.

۱۱.۱.۶ مطالعه‌ی بیشتر

- Wagenmakers & Lee **(۲۰۱۴)، فصل ۱۷.** مدل بافت تعمیم‌یافته که به روش بیزی (و سلسله‌مراتبی) روی داده‌ی یادگیری دسته برازش می‌شود. (منبع اصلی برای دسته‌بندی.)
- Lewandowsky & Farrell **(۲۰۱۸)**: فصل مدل‌های زمان پاسخ انتخابی [شماره‌ی فصل بررسی شود] برای مدل drift-diffusion و خویشاوندانش.
- Verguts **(۲۰۲۲)**: فصل‌های دسته‌بندی و تصمیم‌گیری [فصل‌ها بررسی شود].
- اختیاری، خارج از فهرست درس: Grasman, R. P. P. & Wagenmakers, E.-J., van der Maas, H. L. J., (۲۰۰۷) P. An EZ-diffusion model for response time and accuracy. *Psychonomic Bulletin & Review,* ۱۴، ۳-۲۲. Schaffer, M. M. & Medin, D. L., (۱۹۷۸). Context theory of classification learning. *Psychological Review,* ۸۵، ۲۰۷-۲۳۸.

پیش‌نمایش هفته‌ی ۱۵: یادگیری از پاداش‌ها (یادگیری تقویتی)، ذهن به‌عنوان یک مشاهده‌گر بیزی، و اینکه مدل‌های شناختی و سیستم‌های هوش مصنوعی چطور به هم کمک می‌کنند.

۲.۶ هفته‌ی ۱۵: مدل‌سازی در علوم شناختی ۲: یادگیری تقویتی، شناخت بیزی و هوش مصنوعی

فصل ۶: نمونه‌هایی از مدل‌سازی در حوزه‌های مختلف علوم شناختی · درس ۱ ساعت · lab ۲ ساعت
داده‌ی اصلی: انتخاب‌های شبیه‌سازی‌شده در یک تکلیف bandit دوبازویی با یک وارونگی (reversal)؛ یک آزمایش شبیه‌سازی‌شده‌ی ترکیب نشانه‌های بینایی–لامسه‌ای (cue combination).

۱.۲.۶ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
bandit task	تکلیف bandit	انتخاب مکرر بین گزینه‌هایی با پاداش احتمالی
cue combination	ترکیب نشانه‌ها (cues)	ترکیب اطلاعات چند حس برای یک برآورد
Q-learning	Q-learning	قاعده‌ی یادگیری ارزش گزینه‌ها
inverse temperature / softmax (β)	softmax / دمای معکوس	تبدیل ارزش‌ها به احتمال انتخاب
learning rate (α)	نرخ یادگیری	اندازه‌ی به‌روزرسانی بعد از هر خطا
temperature	دما (temperature)	پارامتر نویز در انتخاب token؛ $1/T = \beta$
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
ideal observer	مشاهده‌گر ایده‌آل	مدل استنباط بهینه با اطلاعات موجود
cognitive model	مدل شناختی	توصیف دقیق و ریاضی یا محاسباتی از یک فرایند ذهنی

English	فارسی	توضیح کوتاه
exploitation / exploration	کاوش / بهره‌برداری	امتحان گزینه‌های دیگر / انتخاب بهترین گزینه‌ی فعلی
prediction error	خطای پیش‌بینی	تفاوت پاداش گرفته‌شده و پاداش مورد انتظار
reinforcement learning (RL)	یادگیری تقویتی	یادگیری از پاداش و پیامد
noise	نویز	تغییرات تصادفی در شواهد یا در داده
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
reliability	پایایی (قابلیت اطمینان)	دقت یک نشانه؛ عکس واریانس آن
large language model (LLM)	مدل بزرگ زبانی	شبکه‌ی عصبی‌ای که کلمه‌ی بعدی متن را پیش‌بینی می‌کند
parameter trade-off	بده‌بستان پارامترها	تغییر یک پارامتر که با پارامتر دیگر جبران می‌شود
reward model / RLHF	RLHF / مدل پاداش	آموزش chatbot از روی ترجیحات انسانی
Bradley–Terry model	مدل Bradley–Terry	مدل انتخاب برای مقایسه‌های جفتی

۲.۲.۶ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. یادگیری از پاداش را با قاعده‌ی Rescorla–Wagner / Q-learning و قاعده‌ی انتخاب softmax **صورت‌بندی کنند** و نرخ یادگیری و inverse temperature را **تفسیر کنند**.
۲. درست‌نمایی trial به trial یک مدل یادگیری را **بنویسند**، آن را با MLE **برازش کنند**، و بازیابی پارامتر و بازیابی مدل را در برابر راهبردهای ساده‌تر **ارزیابی کنند**.
۳. پیش‌بینی‌های یک مشاهده‌گر ایده‌آل بیزی (Bayesian ideal observer) را برای ترکیب نشانه‌ها **استخراج کنند** و **بیازمایند** که آیا رفتار شبیه‌سازی‌شده بهینه است.
۴. مدل‌های بیزی شناخت (ادعایی درباره‌ی ذهن) را از تحلیل داده‌ی بیزی (روشی برای دانشمندان) **تمیز دهند**.
۵. درباره‌ی اینکه مدل‌های شناختی و سیستم‌های هوش مصنوعی چطور به هم کمک می‌کنند، و اینکه ابزارهای ارزیابی این درس چطور روی سیستم‌های هوش مصنوعی‌ای که به‌عنوان مدل شناخت پیشنهاد می‌شوند به کار می‌روند، **بحث کنند**.

۳.۲.۶ مقدمه

یادگیری از پیامدها. یک شرکت‌کننده بارها بین دو ماشین بازی انتخاب می‌کند که یکی بیشتر از دیگری پاداش می‌دهد. وسط کار، ماشین‌ها مخفیانه جایشان عوض می‌شود. شرکت‌کننده چقدر سریع متوجه می‌شود و خودش را تطبیق می‌دهد؟ چقدر کاوش (explore) می‌کند و چقدر بهره‌برداری (exploit)؟ یکی از موفق‌ترین مدل‌های کل روان‌شناسی و علوم اعصاب با یک معادله جواب می‌دهد: انتظارتان را به اندازه‌ی کسری از **خطای پیش‌بینی** (prediction error)، یعنی تفاوت چیزی که گرفتید و چیزی که انتظار داشتید، به‌روز کنید. همین قاعده‌ی خطامحور در شرطی‌سازی کلاسیک (Rescorla–Wagner)، در یادگیری پیوندگرا (قاعده‌ی دلتا)، در شلیک نورون‌های دوپامینی، و در الگوریتم‌های یادگیری تقویتی پشت سیستم‌های هوش مصنوعی امروزی دیده می‌شود. برازش آن روی داده‌ی انتخاب یکی از رایج‌ترین کاربردهای مدل‌سازی شناختی امروز است، مثلاً در روان‌پزشکی محاسباتی.

ذهن به‌عنوان آماردان. وقتی یک شیء را هم‌زمان می‌بینید و لمس می‌کنید، بینایی و لامسه هر دو برآوردی پرنویز از اندازه‌اش می‌دهند. یک مشاهده‌گر ایده‌آل بیزی آن‌ها را با وزن دادن به هر نشانه به نسبت پایایی‌اش ترکیب می‌کند، که برآوردی دقیق‌تر از هرکدام به تنهایی می‌دهد. آیا آدم‌ها این کار را می‌کنند؟ این کاربردی متفاوت از کلمه‌ی «بیزی» نسبت به هفته‌های ۹–۱۳ است: اینجا قاعده‌ی بیز یک **فرضیه درباره‌ی ذهن** است، در سطح محاسباتی Marr (هفته‌ی ۱).

مدل‌های شناختی ↔ هوش مصنوعی. خیلی از ایده‌ها در هر دو جهت بین مدل‌سازی شناختی و هوش مصنوعی رفت‌وآمد می‌کنند: یادگیری خطامحور، شبکه‌های عصبی، یادگیری تقویتی، استنباط بیزی. امروز خود سیستم‌های هوش مصنوعی، از جمله مدل‌های بزرگ زبانی (LLM)ها، به‌عنوان مدل شناخت انسان پیشنهاد می‌شوند. ابزارهای این درس (درست‌نمایی، مقایسه‌ی مدل، آزمون‌های تعمیم، بازیابی) دقیقاً همان چیزی‌اند که برای ارزیابی چنین ادعاهایی لازم است.

این موضوع کجا به کار می‌رود؟

- **روان‌پزشکی محاسباتی:** مدل‌های یادگیری تقویتی روی انتخاب‌های بیماران افسرده، معتاد، مبتلا به اسکیزوفرنی یا وسواس برازش می‌شوند تا آزموده شود که آیا از پاداش و تنبیه متفاوت یاد می‌گیرند (مثلاً نرخ یادگیری پایین‌تر بعد از ضرر).
- **علوم اعصاب:** خطای پیش‌بینی در قاعده‌ی دلتا با فعالیت نورون‌های دوپامینی جور درمی‌آید؛ یکی از شناخته‌شده‌ترین پیوندهای یک مدل شناختی با مغز.
- **آموزش و بازی:** سیستم‌های یادگیری تطبیقی و طراحی بازی از ایده‌های RL برای مدل کردن اینکه بازیکن‌ها و یادگیرنده‌ها چطور خودشان را با بازخورد تطبیق می‌دهند استفاده می‌کنند.
- **ادراک و رباتیک:** ترکیب بهینه‌ی نشانه‌ها توضیح می‌دهد آدم‌ها چطور بینایی، لامسه و شنوایی را ترکیب می‌کنند، و همین قاعده‌ی وزن‌دهی در ادغام حسگرها (sensor fusion) به کار می‌رود.
- **هوش مصنوعی:** یادگیری تقویتی امروزی و آموزش chatbotها از روی ترجیحات انسانی (RLHF) از همین مدل‌های انتخاب استفاده می‌کنند (بخش هوش مصنوعی و LLMها را ببینید).

۴.۲.۶ جزوه‌ی درس

به زبان ساده یادگیری از پاداش. هر گزینه (مثلاً هر کدام از دو دستگاه بازی) در ذهن شرکت‌کننده یک «ارزش» دارد: چقدر پاداش از آن انتظار دارد. بعد از انتخاب یک گزینه و دیدن نتیجه، ارزش کمی به سمت چیزی که واقعاً اتفاق افتاد جابه‌جا می‌شود: ارزش جدید = ارزش قبلی + نرخ یادگیری × (پاداش − ارزش قبلی). عبارت داخل پرانتز **خطای پیش‌بینی** است، یعنی میزان غافلگیری. **نرخ یادگیری** α می‌گوید این جابه‌جایی چقدر بزرگ است. انتخاب‌ها کاملاً حریصانه نیستند: قاعده‌ی softmax گزینه‌ی باارزش‌تر را بیشتر انتخاب می‌کند و β inverse temperature تعیین می‌کند چقدر بیشتر (β پایین = کاوش تصادفی‌تر، β بالا = تقریباً همیشه بهترین). برازش این مدل یعنی پیدا کردن α و βای که دنباله‌ی واقعی انتخاب‌های شرکت‌کننده را محتمل‌ترین کند.
ذهن بیزی: وقتی دو حس تخمین‌های پرنویزی از یک چیز می‌دهند (دیدن و لمس کردن اندازه‌ی یک شیء)، بهترین حدس یک میانگین وزنی است که به حس قابل اعتمادتر بیشتر اعتماد می‌کند. آدم‌ها اغلب به این وزن‌دهی بهینه نزدیک‌اند؛ مدل این را بدون هیچ پارامتر آزادی پیش‌بینی می‌کند و همین آن را یک آزمون قوی می‌کند.

زمان‌بندی پیشنهادی (۶۰ دقیقه): یادگیری از پاداش ۲۰ · برازش مدل‌های یادگیری ۱۰ · مدل‌های بیزی شناخت ۱۵ · مدل‌های شناختی و هوش مصنوعی ۱۰ · جمع‌بندی درس ۵.

۱. یادگیری تقویتی: قاعده‌ی دلتا و Q-learning

قاعده‌ی دلتا / Rescorla–Wagner. بعد از انتخاب گزینه‌ی o در trial t و گرفتن پاداش $r_t \in \{0, 1\}$:

$$\delta_t = r_t - Q_t(o) \quad \text{(prediction error)}, \qquad Q_{t+1}(o) = Q_t(o) + \alpha\, \delta_t,$$

و ارزش گزینه‌های انتخاب‌نشده ثابت می‌ماند. **نرخ یادگیری** $\alpha \in [0, 1]$ تعیین می‌کند پیامدهای تازه چقدر قوی انتظارات قدیمی را بازنویسی کنند. α بالا سریع تطبیق می‌دهد ولی پرنویز است؛ α پایین پایدار است ولی وارونگی را دیر می‌فهمد.

قاعده‌ی انتخاب. softmax ارزش‌ها با inverse temperature $\beta \geq 0$ به احتمال انتخاب تبدیل می‌شوند:

$$P(\text{choose } o \text{ on trial } t) = \frac{\exp(\beta\, Q_t(o))}{\sum_{o'} \exp(\beta\, Q_t(o'))}.$$

$\beta = 0$ یعنی انتخاب تصادفی (کاوش محض)؛ β بزرگ یعنی همیشه گزینه‌ای که فعلاً بهترین است انتخاب شود (بهره‌برداری). برای دو گزینه این یک تابع لجستیک از تفاوت ارزش‌هاست: $P(o_1) = 1/(1 + e^{-\beta(Q_1 - Q_2)})$.

ارتباط‌ها: - این به‌روزرسانی همان **قاعده‌ی دلتا**ی شبکه‌های پیوندگراست (Verguts, ۲۰۲۲): یک شبکه‌ی تک‌لایه که با تصحیح خطا آموزش می‌بیند. - خطاهای پیش‌بینی δ_t شبیه پاسخ‌های فازیک نورون‌های دوپامینی مغز میانی‌اند، و همین مدل‌های RL را در علوم اعصاب محاسباتی محوری کرد. - Q-learning با خطاهای temporal-difference پایه‌ی یادگیری تقویتی مدرن در هوش مصنوعی است.

خواندن ریاضی

- $Q_t(o)$: ارزش گزینه‌ی o در trial شماره‌ی t (زیرنویس t شماره‌ی trial است).
- $\delta_t = r_t - Q_t(o)$: پاداش گرفته‌شده منهای پاداش مورد انتظار. مثبت = غافلگیری خوشایند، منفی = ناامیدی.
- $Q_{t+1}(o) = Q_t(o) + \alpha\, \delta_t$. **مثال:** $Q = 0.5$، $\alpha = 0.3$ و پاداش ۱: $\delta = 0.5$ و Q جدید $= 0.5 + 0.15 = 0.65$. بدون پاداش: $\delta = -0.5$ و Q جدید $= 0.35$.
- **برای دو گزینه:** $P(\text{option 1}) = 1/(1 + e^{-\beta(Q_1 - Q_2)})$. با $Q_1 - Q_2 = 0.25$: $\beta = 0$ می‌دهد ۵۰.۰ (تصادفی)، $\beta = 3$ می‌دهد ۶۸.۰، و $\beta = 20$ می‌دهد ۹۹.۰ (تقریباً همیشه گزینه‌ی ۱).

۲. برازش یک مدل یادگیری

درست‌نمایی ترتیبی است. ارزش‌ها به انتخاب‌ها و پاداش‌های گذشته‌ی خود شرکت‌کننده بستگی دارند، پس مدل را روی دنباله‌ی واقعی trialهای شرکت‌کننده اجرا می‌کنیم و احتمال‌هایی را که به انتخاب‌های واقعاً انجام‌شده نسبت داده در هم ضرب می‌کنیم:

$$\ell(\alpha, \beta) = \sum_{t=1}^{T} \ln P\big(\text{choice}_t \mid Q_t(\cdot;\ \alpha, \text{history}_{<t}),\ \beta\big).$$

نکته‌های عملی: - reparameterize کنید: $\alpha = 1/(1 + e^{-\eta_\alpha})$ و $\beta = e^{\eta_\beta}$ (هفته‌ی ۳)، و از multi-start استفاده کنید. - β–α trade-off: انتخاب پرنویز (β پایین) و یادگیری کند یا نامنظم (α حدی) می‌توانند رفتارهای شبیه به هم بسازند، پس برآوردها در برازش‌های مختلف اغلب همبسته‌اند، و علامت همبستگی به طرح و دامنه‌ی پارامترها بستگی دارد. مشکل دیگر این است که برآورد مقادیر خیلی بزرگ β اصلاً سخت است (بخش C lab). مطالعه‌ی بازیابی در همان طرح واقعی ضروری است

(هفته‌ی ۷). - **طرح مهم است:** برای برآورد α به وارونگی و trial کافی نیاز است؛ احتمال‌های پاداش ثابت اطلاعات کمی درباره‌اش می‌دهند. - **راهبردهای جایگزین** باید مقایسه شوند: مثلاً *win-stay/lose-shift* (WSLS: انتخاب پاداش‌گرفته را تکرار کن، بعد از بی‌پاداشی عوض کن، با نرخ لغزش ε)، یا یک مدل تصادفی سوگیر. برازش خوب RL معنای زیادی ندارد اگر WSLS هم به همان خوبی برازش شود.

خواندن ریاضی $\ell(\alpha,\beta) = \sum_t \ln P(\text{choice}_t \mid Q_t, \beta)$: مدل یادگیری را روی دنباله‌ی انتخاب‌ها و پاداش‌های خود شرکت‌کننده، trial به trial، اجرا کن. در هر trial احتمالی را که مدل به انتخابِ واقعی شرکت‌کننده داده حساب کن، لگاریتمش را بگیر و جمع بزن. مثال حل‌شده (بخش ۱) این کار را برای چهار trial انجام می‌دهد: $\ln 0.5 + \ln 0.679 + \ln 0.593 + \ln 0.755 = -1.884$. بهترین (α,β) این جمع را بیشینه می‌کنند. این همان درست‌نمایی هفته‌ی ۴ است، با این تفاوت که احتمال هر trial به تاریخچه‌ی پیش از آن بستگی دارد.

۳. مدل‌های بیزی شناخت

ترکیب نشانه‌ها. یک نشانه‌ی بینایی $x_V \sim \mathcal{N}(S, \sigma_V)$ و یک نشانه‌ی لامسه‌ای $x_H \sim \mathcal{N}(S, \sigma_H)$ هر دو اندازه‌ی واقعی S را می‌سنجند. با پیشین تخت، پسین S نرمال است با میانگین

$$\hat{S} = w_V x_V + w_H x_H, \qquad w_V = \frac{1/\sigma_V^2}{1/\sigma_V^2 + 1/\sigma_H^2}, \quad w_H = 1 - w_V,$$

و انحراف معیار

$$\sigma_{VH} = \sqrt{\frac{\sigma_V^2\,\sigma_H^2}{\sigma_V^2 + \sigma_H^2}} \;\le\; \min(\sigma_V, \sigma_H).$$

پیش‌بینی‌های آزمون‌پذیر (مثلاً آزموده‌شده توسط Banks, & Ernst ۲۰۰۲): (۱) وزن‌ها باید پایایی نشانه‌ها را دنبال کنند، که آزمایشگر می‌تواند با تخریب یک نشانه دست‌کاری‌اش کند؛ (۲) دقت دوحسی باید بهتر از بهترین نشانه‌ی تکی باشد، دقیقاً به اندازه‌ی بالا. انحراف معیارهای تک‌نشانه جداگانه اندازه‌گیری می‌شوند، پس پیش‌بینی‌های مشاهده‌گر ایده‌آل **هیچ پارامتر آزادی ندارند**. همین آن‌ها را آزمون‌هایی قوی و ابطال‌پذیر می‌کند.

یک مدل بیزی شناخت چه ادعایی دارد. اینکه رفتار، با توجه به نویز، پیشین و هدف‌های عامل، تقریبی از استنباط بهینه است: یک تبیین در **سطح محاسباتی** (Marr). درباره‌ی الگوریتم ساکت است: مغز ممکن است بیز را با نمونه‌گیری، heuristicها یا کدهای جمعیتی عصبی تقریب بزند.

نقدهایی که باید در ذهن داشت: با انتخاب آزادانه‌ی پیشین‌ها، درست‌نمایی‌ها و تابع‌های زیان، تقریباً هر رفتاری را می‌شود بعد از واقعه «بهینه» نامید (مسئله‌ی انعطاف‌پذیری هفته‌ی ۶). آزمون‌های قوی این اجزا را مستقل تثبیت می‌کنند، مثل ترکیب نشانه‌ها.

دو معنا، یک بار دیگر:

	مدل بیزی شناخت	تحلیل داده‌ی بیزی
چه کسی استنباط می‌کند؟	ذهن شرکت‌کننده (به‌طور فرضی)	دانشمند
پیشین نشان‌دهنده‌ی	باورهای شرکت‌کننده درباره‌ی جهان	دانش دانشمند درباره‌ی پارامترها
می‌تواند غلط باشد اگر…	آدم‌ها بهینه نباشند	مدل یا پیشین‌ها بد انتخاب شده باشند
نمونه‌ها در این درس	ترکیب نشانه‌ها (امروز)	هفته‌های ۹–۱۳

می‌توانید یک مدل بیزی شناخت را با بیشینه‌ی درست‌نمایی تحلیل کنید، و یک مدل غیربیزی (مثلاً Q-learning) را با تحلیل داده‌ی بیزی.

خواندن ریاضی

- $w_V = \frac{1/\sigma_V^2}{1/\sigma_V^2 + 1/\sigma_H^2}$: وزن بینایی برابر دقت آن (۱/واریانس) تقسیم بر دقت کل است. حسی که دو برابر دقیق‌تر باشد (نصف انحراف معیار، یک‌چهارم واریانس) چهار برابر وزن می‌گیرد.
- $\sigma_{VH} = \sqrt{\sigma_V^2\sigma_H^2/(\sigma_V^2 + \sigma_H^2)}$: انحراف معیار ترکیبی که همیشه از بهترین حس تنها کوچک‌تر است. **مثال:** $\sigma_V = 1$ و $\sigma_H = 2$: $w_V = 1/(1+1/4) = 0.8$ و $\sigma_{VH} = \sqrt{4/5} = 0.894$، حدود ۱۱٪ بهتر از بینایی به‌تنهایی.
- **آزمون:** σ_V و σ_H را جداگانه اندازه بگیر (هر بار یک حس)، w_V و σ_{VH} را بدون هیچ پارامتر آزادی پیش‌بینی کن، و بعد داده‌ی دوحسی را بررسی کن.

برای یک مهندس

- **قاعده‌ی دلتا همان به‌روزرسانی LMS است.** $Q \leftarrow Q + \alpha(r - Q)$ یک LMS تک‌ضریبی است (یا یک میانگین متحرک با وزن نمایی و ضریب فراموشی $1 - \alpha$): α بزرگ تغییرات را سریع دنبال می‌کند ولی پرنویز است، α کوچک هموار ولی کند است؛ همان trade-off آشنای ردیابی و خطای تنظیم (misadjustment).
- softmax همان توزیع Boltzmann/Gibbs است؛ β به معنای فیزیکی یک دمای معکوس است. نمونه‌گیری با دما همان روشی است که مدل‌های زبانی متن تولید می‌کنند (کادر هوش مصنوعی هفته‌ی ۱).
- **برازش α و β از روی انتخاب‌ها** یعنی شناسایی یک سیستم تطبیقی فقط از روی خروجی‌های دودویی آن: هرگز Q را نمی‌بینید، فقط تصمیم‌هایی را که تولید می‌کند. به همین دلیل α و β با هم trade-off دارند و بررسی بازیابی ضروری است.
- **ترکیب بهینه‌ی نشانه‌ها** دقیقاً از وزن‌های معکوس واریانس در **ترکیب با نسبت بیشینه** (MRC) و ادغام حسگرها در فیلتر کالمن استفاده می‌کند: واریانس تخمین ترکیبی $(1/\sigma_V^2 + 1/\sigma_H^2)^{-1}$ است. سؤال علمی این است که آیا مغز این ادغام را انجام می‌دهد.

۴. مدل‌های شناختی و هوش مصنوعی

جهت	نمونه‌ها
علوم شناختی ← هوش مصنوعی	شبکه‌های عصبی (الهام‌گرفته از نورون‌ها و قاعده‌های یادگیری)؛ یادگیری تقویتی (از نظریه‌ی یادگیری حیوانی)؛ ایده‌های exemplar/prototype در طبقه‌بندهای یادگیری ماشین (روش‌های نزدیک‌ترین همسایه در برابر مرکزوار)
هوش مصنوعی ← علوم شناختی	شبکه‌های عمیق به‌عنوان مدل قشر بینایی؛ عامل‌های RL به‌عنوان مدل تصمیم‌گیری؛ مدل‌های بزرگ زبانی که به‌عنوان مدل پردازش زبان و استدلال انسان‌گونه پیشنهاد می‌شوند
ریاضیات مشترک	درست‌نمایی‌ها و تابع‌های زیان؛ بهینه‌سازی مبتنی بر گرادیان (هفته‌ی ۳)؛ استنباط بیزی و MCMC؛ cross-validation و تعمیم (هفته‌ی ۶)

ارزیابی یک سیستم هوش مصنوعی به‌عنوان مدل شناختی دقیقاً از جعبه‌ابزار درس استفاده می‌کند: - آیا داده‌ی انسانی را فراتر از برازش پیش‌بینی می‌کند، مثلاً شرایط تازه و تفاوت‌های فردی را (تعمیم، هفته‌ی ۶)؟ - آیا در یک مقایسه‌ی منصفانه از مدل‌های شناختی ساده‌تر و تفسیرپذیر بهتر است (هفته‌های ۷، ۱۰)؟ - آیا می‌توانیم از روی داده بگوییم انسان و مدل از یک سازوکار استفاده می‌کنند، یا فقط خروجی‌های شبیه تولید می‌کنند (تقلید مدل و بازیابی، هفته‌ی ۷)؟ - آیا پارامترها یا حالت‌های درونی‌اش به‌عنوان

سازه‌های روان‌شناختی تفسیرپذیرند (هفته‌ی ۱)؟

مدلی با میلیاردها پارامتر که رفتار را خوب برازش می‌کند به‌طور خودکار یک تبیین نیست: انعطاف‌پذیری، identifiability و تفسیرپذیری به اندازه‌ی برازش مهم‌اند.

۵. جمع‌بندی درس

در حوزه‌های خیلی متفاوت (فراموشی، تشخیص، دسته‌بندی، تصمیم‌گیری، یادگیری، ادراک)، گردش کار یکسان بوده است: **صورت‌بندی** ← **شبیه‌سازی** ← **برازش** ← **ارزیابی** ← **بازیابی** ← **تفسیر**. حوزه مدل را عوض می‌کند؛ منطق مدل‌سازی ثابت می‌ماند.

برای مدرس

- **بازی bandit را با کلاس اجرا کنید.** دو «دستگاه» (دو دانشجو با سکه‌ی پنهان یا یک اپلیکیشن عدد تصادفی؛ یکی ٪۸۰ مواقع پاداش می‌دهد و دیگری ٪۲۰)، و در وسط کار مخفیانه جایشان را عوض کنید. کلاس پیش از دیدن هر معادله‌ای کاوش، بهره‌برداری و وارونگی را تجربه می‌کند.
- **چهار trial Q-learning مثال حل‌شده را روی تخته انجام دهید** با یک جدول: ارزش قبل، انتخاب، پاداش، خطای پیش‌بینی، ارزش بعد. ده دقیقه وقت می‌گیرد و کد را رازگشایی می‌کند.
- **برای ترکیب نشانه‌ها آزادانه از شهود مهندسی‌تان استفاده کنید:** «ترکیب دو حسگر پرنویز» راه طبیعی ارائه‌ی آن است و برای دانشجوهای روان‌شناسی روشنگر است.
- **بحث هوش مصنوعی را روی زمین نگه دارید.** بخش ۴ می‌تواند بحث‌های طولانی راه بیندازد؛ از چهار سؤال ارزیابی (تعمیم، مقایسه‌ی منصفانه، تقلید، تفسیرپذیری) برای متمرکز نگه داشتن آن استفاده کنید.
- **سؤال‌های رایج.**
  - «چرا برآورد β سخت است؟» وقتی انتخاب‌ها تقریباً قطعی شدند، بیشتر کردن β درست‌نمایی را تقریباً تغییر نمی‌دهد.
  - «آیا مغز واقعاً *Q-learning* انجام می‌دهد؟» توصیف خوبی از بسیاری از داده‌های انتخاب است و با سیگنال‌های دوپامین جور درمی‌آید، ولی مدل‌های پیچیده‌تر (یادگیری مبتنی بر مدل یا model-based) هم پشتیبانی دارند.
  - «آیا آدم‌ها همیشه نشانه‌ها را بهینه ترکیب می‌کنند؟» اغلب نزدیک، ولی نه همیشه؛ شرکت‌کننده‌ی lab به لامسه بیش از حد وزن می‌دهد.

۵.۲.۶ مثال حل‌شده

بخش ۱: چهار trial Q-learning با دست

دو گزینه؛ $\alpha = 0.5$، $\beta = 3$؛ ارزش‌های اولیه $Q(1) = Q(2) = 0.5$.

trial	$Q(1)$	$Q(2)$	$P(\text{choose } 1)$	انتخاب	پاداش	δ	به‌روزرسانی
۱	۵۰.۰		۵۰۰.۰	۱		$1 - 0.5 = +0.5$	$Q(1) = 0.5 + 0.5 \times 0.5 = 0.75$
۲	۵۰.۰		$1/(1+e^{-3\times 0.25}) = 0.679$	۱	۰	$0 - 0.75 = -0.75$	$Q(1) = 0.75 - 0.375 = 0.375$
۳	۳۷۵.۰	۵۰.۰	$1/(1 + e^{-3\times(-0.125)}) = 0.407$	۲	۱	$1 - 0.5 = +0.5$	$Q(2) = 0.75$
۴	۳۷۵.۰	۷۵.۰	$1/(1 + e^{-3\times(-0.375)}) = 0.245$	۲	۱	$+0.25$	$Q(2) = 0.875$

لگاریتم درست‌نمایی این چهار انتخاب: $\ln 0.5 + \ln 0.679 + \ln(1-0.407) + \ln(1-0.245) = -0.693 - 0.387 - 0.523 - 0.281 = -1.884$.

تفسیر. با $\alpha = 0.5$ یک بار بی‌پاداشی ارزش گزینه‌ی ۱ را نصف می‌کند و مدل یک تغییر انتخاب پیش‌بینی می‌کند، که شرکت‌کننده انجامش داد. درست‌نمایی به مقادیر پارامتری پاداش می‌دهد که دنباله‌ی انتخاب واقعی شرکت‌کننده را پیش‌بینی کنند.

بخش ۲: یک مشاهده‌گر ایده‌آل

انحراف معیار بینایی $\sigma_V = 1$ mm، انحراف معیار لامسه $\sigma_H = 2$ mm. وزن‌ها: $w_V = 1/(1+1/4) = 0.8$، $w_H = 0.2$. انحراف معیار ترکیبی پیش‌بینی‌شده: $\sqrt{(1\times 4)/(1+4)} = 0.894$ mm، حدود ۱۱٪ بهتر از بینایی به تنهایی. اگر $x_V = 50$ و $x_H = 54$ mm باشد، برآورد بهینه $0.8\times 50 + 0.2\times 54 = 50.8$ mm است.

تفسیر. مشاهده‌گری که نشانه‌ها را فقط میانگین بگیرد ($w = 0.5$) انحراف معیار $\sqrt{0.25\times 1 + 0.25\times 4} = 1.118$ mm دارد، یعنی بدتر از بینایی به تنهایی. وزن‌دهی بهینه است که ترکیب نشانه‌ها را ارزشمند می‌کند.

۶.۲.۶ lab (۲ ساعت)

اهداف

۱. شبیه‌سازی یک عامل Q-learning در یک تکلیف bandit با وارونگی.
۲. برازش (α, β) با MLE؛ اجرای بازیابی پارامتر و تشخیص trade-off α–β.
۳. مقایسه‌ی Q-learning با مدل‌های win-stay/lose-shift و تصادفی سوگیر.
۴. آزمودن اینکه آیا یک مشاهده‌گر شبیه‌سازی‌شده نشانه‌ها را بهینه ترکیب می‌کند.

زمان‌بندی: بخش A ۲۰ دقیقه · بخش B ۲۰ دقیقه · بخش C ۲۵ دقیقه · بخش D ۳۰ دقیقه · بخش E ۲۵ دقیقه.

بخش A: یک عامل Q-learning در تکلیف وارونگی (۲۰ دقیقه)

Code · کد: code/week15.py، cell ۱ · سلول ۱

خروجی مورد انتظار:

```
Total reward: 151 / 200;  chose the better option on 91% of trials
```

بخش B: درست‌نمایی و یک برازش MLE (۲۰ دقیقه)

Code · کد: code/week15.py، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
MLE: alpha = 0.491 (true 0.3), beta = 3.80 (true 5.0), NLL = 51.77
Chance-level NLL (always p = 0.5): 138.63
```

بخش C: بازیابی پارامتر و α–β trade-off (۲۵ دقیقه)

Code · کد: `code/week15.py`، cell ۳ · سلول ۳

خروجی مورد انتظار (حدود ۳۰–۶۰ ثانیه):

```
alpha: r(true, recovered) = 0.90
beta: r(true, recovered) = 0.17
corr(recovered alpha, recovered beta) = 0.31 (true values were drawn
↪  independently: 0.03)
```

تفسیر کنید: با ۲۰۰ trial و یک وارونگی، α خوب بازیابی می‌شود (r = ۰.۹۰) ولی β تقریباً اصلاً نه (r = ۰.۱۷). این برازش بخش B را هم توضیح می‌دهد ($\hat{\beta} = 3.8$ برای مقدار واقعی ۵.۰). به ناحیه‌ی β بزرگ در نمودار نگاه کنید. چرا دماهای معکوس بالا را به سختی می‌شود تعیین کرد؟ (راهنمایی: وقتی انتخاب‌ها تقریباً قطعی شدند، بالاتر بردن β درست‌نمایی را به‌زحمت تغییر می‌دهد.) α و β بازیابی‌شده هم همبسته‌اند (۳۱.۰) با اینکه مقادیر واقعی مستقل بودند: یک معاوضه. این برای مطالعه‌ای که β را با مثلاً یک پرسش‌نامه‌ی بالینی همبسته می‌کند چه معنایی دارد؟

بخش D: آیا واقعاً یادگیری تقویتی است؟ مقایسه‌ی مدل (۳۰ دقیقه)

Code · کد: `code/week15.py`، cell ۴ · سلول ۴

خروجی مورد انتظار (حدود ۱ دقیقه):

```
AIC for the Part A participant: {'Q-learning': 107.5, 'WSLS': 200.3,
↪  'bias': 278.9}

Model recovery (rows: generating, columns: selected by AIC):
            Q-learning  WSLS  bias
Q-learning          20     0     0
WSLS                 0    20     0
```

بخش E: یک مشاهده‌گر ایده‌آل برای ترکیب نشانه‌ها (۲۵ دقیقه)

یک شرکت‌کننده‌ی شبیه‌سازی‌شده اندازه‌ی اشیایی را که هم‌زمان دیده و لمس می‌شوند قضاوت می‌کند. سطح نویز تک‌نشانه را از بلوک‌های تک‌حسی می‌دانیم. آیا شرکت‌کننده نشانه‌ها را بهینه ترکیب می‌کند؟

Code · **کد:** `code/week15.py`، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
Ideal observer: w_V = 0.80, predicted bimodal SD = 0.894 mm
Participant: empirical w_V = 0.56, bimodal SD = 1.006 mm
Best single cue SD = 1.000 mm;  simple average would give 1.118 mm
```

تفسیر کنید: آیا این شرکت‌کننده بهینه است؟ وزن بینایی تجربی (۵۶.۰) خیلی پایین‌تر از مقدار بهینه‌ی ۸۰.۰ است: شرکت‌کننده به نشانه‌ی لامسه‌ای کم‌پایاتر بیش از حد وزن می‌دهد. در نتیجه انحراف معیار دوحسی‌اش (۰۰۶.۱ mm) بهتر از بینایی به تنهایی (۰۰۰.۱ mm) نیست، به جای ۸۹۴.۰ mm که یک مشاهده‌گر ایده‌آل به آن می‌رسید. توجه کنید که پیش‌بینی مشاهده‌گر ایده‌آل **هیچ پارامتر آزادی** نداشت: همین آن را یک آزمون قوی می‌کند.

(این شرکت‌کننده را با وزن واقعی ۶۵.۰ شبیه‌سازی کردیم. برآورد ۵۶.۰ حدود ۳ خطای استاندارد فاصله دارد، یک نمونه‌ی غیرمعمول بدشانس ولی یادآوری مفید که وزن‌های تجربی هم خطای نمونه‌گیری دارند. تمرین ۴ بازه‌های bootstrap دورشان می‌گذارد.)

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. چهار trial Q-learning مثال حل‌شده را با `nll_q` بازتولید کنید (راهنمایی: NLL را با `theta=(logit0, log3)` روی دنباله‌ی چهار trialی حساب کنید). آیا لگاریتم درست‌نمایی -۸۸۴.۱ به دست می‌آید؟

تمرین ۲ ⋆. بخش C را با ۵۰ trial (بدون وارونگی) و با ۴۰۰ trial (سه وارونگی) دوباره اجرا کنید. بازیابی α چطور تغییر می‌کند؟ این برای طراحی آزمایش چه معنایی دارد؟

تمرین ۳ ⋆⋆ **(دو نرخ یادگیری).** بسیاری از مطالعه‌ها نرخ‌های یادگیری متفاوتی برای خطاهای پیش‌بینی مثبت و منفی پیدا می‌کنند. مدلی با α^+ و α^- پیاده‌سازی کنید، یک عامل با $\alpha^+ = 0.4$ و $\alpha^- = 0.1$ شبیه‌سازی کنید، و با AIC/BIC و یک مطالعه‌ی بازیابی بیازمایید که آیا پارامتر اضافه در طرح بخش A identifiable است.

تمرین ۴ ⋆⋆ **(وزن‌های بهینه).** در بخش E، یک مشاهده‌گر با $w_V = 0.8$ (بهینه) و یکی با $w_V = 0.5$ (میانگین‌گیر)، هرکدام با ۱۰۰ trial دوحسی، شبیه‌سازی کنید. با bootstrap (هفته‌ی ۵) دور وزن‌ها و انحراف معیارهای تجربی بازه‌ی اطمینان بگذارید. با ۱۰۰ trial می‌توانید دو مشاهده‌گر را از هم تشخیص دهید؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: RL سلسله‌مراتبی).** ۲۰ عامل با (α_j, β_j) فردی و فقط ۸۰ trial برای هرکدام شبیه‌سازی کنید. آن‌ها را جداگانه با MLE و بعد با یک مدل بیزی سلسله‌مراتبی در PyMC برازش کنید. (راهنمایی: حلقه‌ی trialها را می‌شود با `pytensor.scan` نوشت؛ یا به جایش یک نمونه‌گیر Metropolis-within-Gibbs دست‌نویس پیاده کنید که از `nll_q` برای پارامترهای فردی و به‌روزرسانی‌های conjugate برای میانگین‌های گروه استفاده کند.) بازیابی α_j را بین دو رویکرد مقایسه کنید.

lab check-off

نشان دهید: (۱) برازش MLE و نمودارهای بازیابی همراه با تفسیرتان از نمودار β، (۲) جدول بازیابی مدل، و (۳) جوابتان درباره‌ی بهینه بودن مشاهده‌گر ترکیب نشانه‌ها.

۷.۲.۶ ارتباط با هوش مصنوعی و LLMها

قاعده‌ی انتخاب پشت آموزش chatbotها. chatbotهای امروزی با یادگیری تقویتی از بازخورد انسانی (RLHF) تنظیم دقیق (fine-tune) می‌شوند. آدم‌ها دو پاسخ را می‌بینند و می‌گویند کدام را ترجیح می‌دهند، یک **مدل پاداش** (reward model) روی این انتخاب‌ها برازش می‌شود، و بعد chatbot با یادگیری تقویتی آموزش می‌بیند تا پاداش یادگرفته‌شده را بیشینه کند (Christiano et al., ۲۰۱۷؛ Ouyang et al., ۲۰۲۲). مدل پاداش معمولاً مدل Bradley–Terry است، $P(i \succ j) = 1/(1+e^{-(r_i - r_j)})$. این همان قاعده‌ی انتخاب softmax این هفته با $\beta = 1$، و قاعده‌ی انتخاب Luce در GCM است. برازش آن یک مسئله‌ی MLE از هفته‌ی ۴ است. پس مدل‌های انتخاب انسانی در قلب شیوه‌ای قرار دارند که سیستم‌های هوش مصنوعی امروزی با ترجیحات انسانی همسو (align) می‌شوند، و مشکلاتشان هم همین‌جاست: انتخاب‌های پرنویز، identifiability (فقط تفاوت‌های r مهم‌اند، پس یک مقدار ثابت می‌شود)، و فاصله‌ی بین آنچه آدم‌ها انتخاب می‌کنند و آنچه واقعاً خوب است.

Code · **کد:** `code/week15.py`، cell ۰۶ · سلول ۶

خروجی مورد انتظار:

```
304 comparisons; estimated rewards = [0.   0.56 0.5  1.61] (true [0.
↪  0.5 1.  2. ])
```

با حدود ۳۰۰ مقایسه‌ی پرنویز، ترتیب برآوردشده‌ی پاسخ‌های ۱ و ۲ حتی برعکس شده. یک مدل پاداش یک مدل شناختی برازش‌شده است، و مثل هر مدل دیگری به برآورد عدم قطعیت و بررسی بازیابی نیاز دارد.

امتحانش کنید (بدون نیاز به API). ⋆ - خطاهای استاندارد مبتنی بر Hessian را برای سه برآورد حساب کنید (هفته‌ی ۵). آیا برعکس شدن پاسخ‌های ۱ و ۲ در محدوده‌ی عدم قطعیت است؟ - ⋆⋆ یک بازیابی پارامتر اجرا کنید: چند مقایسه لازم است تا ترتیب هر چهار پاسخ در ۹۰٪ مجموعه داده‌های شبیه‌سازی‌شده درست بازیابی شود؟ - ⋆⋆ ارزیاب‌هایی را شبیه‌سازی کنید که جواب‌های طولانی‌تر را صرف‌نظر از کیفیت ترجیح می‌دهند (یک پاداش طول به پاداش واقعی اضافه کنید). مدل پاداش برازش‌شده چه یاد می‌گیرد، و بعد chatbot برای انجام چه کاری آموزش می‌بیند؟

مطالعه‌ی اختیاری: Christiano, P. F., et al. (2017). Deep reinforcement learning from human preferences. *NeurIPS*. Ouyang, L., et al. (2022). Training language models to follow instructions with human feedback. *NeurIPS*.

۸.۲.۶ اشتباهات رایج و برداشت‌های نادرست

۱. **برازش یک مدل یادگیری روی نسبت‌های انتخاب تجمیع‌شده.** درست‌نمایی باید دنباله‌ی trialهای خود هر شرکت‌کننده را دنبال کند، چون ارزش‌ها به تاریخچه‌ی خودش بستگی دارند.

۲. **تفسیر α بدون بررسی بازیابی.** α و β با هم trade-off دارند، و α بدون وارونگی یا trial کافی بد شناسایی می‌شود.

۳. **مقایسه نکردن با راهبردهای ساده.** win-stay/lose-shift یا پافشاری (perseveration) می‌توانند یادگیری را تقلید کنند. نشان دهید مدل RL در یک مقایسه‌ی منصفانه برنده است.

۴. **فراموش کردن اینکه softmax از تفاوت ارزش‌ها استفاده می‌کند.** افزودن یک ثابت به همه‌ی ارزش‌های Q چیزی را عوض نمی‌کند، در حالی که مقیاس ارزش‌ها و β با هم trade-off دارند.

۵. **«آدم‌ها بیزی‌اند» از روی یک برازش پس‌از–واقعه.** اگر پیشین و درست‌نمایی برای برازش رفتار انتخاب شده باشند، بهینگی فرض شده، نه آزموده. آزمون‌های قوی آن‌ها را مستقل تثبیت می‌کنند (ترکیب نشانه‌ها).

۶. **قاطی کردن دو نوع بیزی‌گرایی** (مدل ذهن در برابر روش تحلیل).
۷. **«یک مدل بزرگ هوش مصنوعی که داده‌ی انسانی را برازش می‌کند، مدل شناختی خوبی است.»** برازش تبیین نیست. مثل هر مدل دیگری درباره‌ی تعمیم، تقلید، identifiability و تفسیرپذیری بپرسید.

۹.۲.۶ خودآزمایی

۱. به‌روزرسانی قاعده‌ی دلتا را بنویسید و نقش خطای پیش‌بینی را توضیح دهید. **پاسخ** $Q \leftarrow Q + \alpha(r - Q)$. خطای پیش‌بینی $r - Q$ تفاوت پیامد و انتظار است: خطاهای مثبت ارزش را بالا می‌برند، خطاهای منفی پایین می‌آورند، و نرخ یادگیری اندازه‌ی تغییر را تعیین می‌کند.

۲. inverse temperature β چه چیزی را کنترل می‌کند؟ $\beta = 0$ و $\beta \to \infty$ چه رفتاری تولید می‌کنند؟ **پاسخ** حساسیت انتخاب‌ها به تفاوت ارزش‌ها (کاوش در برابر بهره‌برداری). $\beta = 0$: انتخاب تصادفی بدون توجه به ارزش‌ها. $\beta \to \infty$: همیشه گزینه‌ای با بالاترین ارزش فعلی انتخاب می‌شود.

۳. چرا درست‌نمایی یک مدل یادگیری باید trial به trial روی دنباله‌ی واقعی هر شرکت‌کننده حساب شود؟ **پاسخ** پیش‌بینی‌های مدل در trial t به انتخاب‌ها و پاداش‌های قبلی خود آن شرکت‌کننده (از طریق ارزش‌های Q) بستگی دارد، پس احتمال هر انتخاب مشاهده‌شده را فقط با اجرای مدل روی تاریخچه‌ی مشاهده‌شده می‌شود حساب کرد.

۴. trade-off β–α را توضیح دهید. **پاسخ** ترکیب‌های مختلف نرخ یادگیری و نویز انتخاب می‌توانند دنباله‌های انتخاب مشابهی تولید کنند. مثلاً تطبیق کُند می‌تواند از یادگیری کند (α پایین) یا از انتخاب پرنویز و بی‌حساس به ارزش (β پایین) بیاید. پس برآوردها همبسته‌اند و هرکدام به تنهایی نامطمئن؛ جهت همبستگی به طرح بستگی دارد. علاوه بر این، مقادیر بالای β ضعیف شناسایی می‌شوند، چون انتخاب‌های تقریباً قطعی برای بسیاری از βهای بزرگ یکسان به نظر می‌رسند.

۵. بینایی انحراف معیار ۲ و لامسه انحراف معیار ۲ دارد. وزن‌های بهینه و انحراف معیار ترکیبی پیش‌بینی‌شده چقدر است؟ **پاسخ** پایایی‌های برابر $w_V = w_H = 0.5$ می‌دهند، و انحراف معیار ترکیبی $\sqrt{4 \times 4/8} = \sqrt{2} = 1.41$ است، بهتر از هر نشانه به تنهایی (۲).

۶. برای هرکدام یک نمونه بزنید: ایده‌ای که از علوم شناختی به هوش مصنوعی رفته، و ایده‌ای که از هوش مصنوعی به علوم شناختی آمده. **پاسخ** علوم شناختی ← هوش مصنوعی: یادگیری خطامحور (Rescorla–Wagner / قاعده‌ی دلتا) که به آموزش شبکه‌های عصبی و یادگیری تقویتی منجر شد. هوش مصنوعی ← علوم شناختی: شبکه‌های کانولوشنی عمیق که به‌عنوان مدل جریان بینایی شکمی (ventral visual stream) استفاده می‌شوند، یا عامل‌های RL و مدل‌های زبانی که به‌عنوان مدل رفتار انسان پیشنهاد می‌شوند.

۷. یک پژوهشگر نشان می‌دهد پاسخ‌های یک مدل بزرگ زبانی در یک تکلیف استدلال همبستگی بالایی با پاسخ‌های انسانی دارد. پیش از پذیرفتنش به‌عنوان یک مدل شناختی چه شواهد دیگری می‌خواهید؟ **پاسخ** پیش‌بینی شرایط تازه و تفاوت‌های فردی (تعمیم)؛ یک مقایسه‌ی منصفانه با مدل‌های شناختی ساده‌تر؛ آزمون‌هایی که سازوکار مدل را از جایگزین‌هایی که همان خروجی‌ها را تولید می‌کنند تمیز دهند (تقلید)؛ و نوعی تناظر بین حالت‌های درونی‌اش و سازه‌های روان‌شناختی.

۱۰.۲.۶ تکلیف

تکلیف جدیدی نداریم: **ارائه‌های پروژه‌ی پایانی هفته‌ی آینده است**، و گزارش کتبی و کد پیش از امتحان پایانی تحویل داده می‌شوند. وقت lab این هفته را برای کار روی پروژه و جمع‌بندی درس استفاده کنید.

۱۱.۲.۶ مطالعه‌ی بیشتر

- Verguts **(۲۰۲۲)**: فصل‌های قاعده‌ی دلتا و یادگیری تقویتی (یادگیری خطامحور و پایه‌ی عصبی‌اش) [فصل‌ها بررسی شود]. (منبع اصلی برای بخش ۱.)
- Lewandowsky & Farrell **(۲۰۱۸)**: فصل‌های مدل‌های شبکه‌ی عصبی و مدل‌ها در علوم اعصاب [شماره‌ی فصل‌ها بررسی شود].
- Anderson **(۲۰۱۴)**: فصل‌های شبکه‌های عصبی و یادگیری، که مدل‌های شناختی و علوم اعصاب محاسباتی را به هم وصل می‌کنند [فصل‌ها بررسی شود].
- اختیاری، خارج از فهرست درس: Banks, M. S. & Ernst, M. O., (۲۰۰۲). Humans integrate visual and haptic information in a statistically optimal fashion. *Nature,* ۴۱۵، ۴۲۹–۴۳۳. & Wilson, R. C., Collins, A. G. E. (۲۰۱۹). Ten simple rules for the computational modeling of behavioral data. *eLife,* ۸، e49547 (مثال اصلی‌اش یک تکلیف bandit مثل تکلیف امروز است).

پیش‌نمایش هفته‌ی ۱۶: ارائه‌های پروژه‌ی پایانی، و یک جلسه‌ی پایانی درباره‌ی شیوه‌ی خوب مدل‌سازی.

۳.۶ هفته‌ی ۱۶: ارائه‌های پروژه‌ی پایانی و شیوه‌ی خوب مدل‌سازی

جمع‌بندی درس · وقت درس: جمع‌بندی + اولین ارائه‌ها · وقت lab: ارائه‌ها و بازخورد همتایان

۱.۳.۶ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
peer feedback	بازخورد همتا	نقد سازنده‌ی کار هم‌کلاسی‌ها
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند
reproducibility	بازتولیدپذیری	امکان به دست آوردن دوباره‌ی همان نتایج
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها

English	فارسی	توضیح کوتاه
Bayes factor (BF)	عامل بیز (Bayes factor)	نسبت درست‌نمایی‌های حاشیه‌ای دو مدل
constraints / bounds	کران‌ها / قیدها	محدودیت‌های مجاز برای مقدار پارامترها
posterior	توزیع پسین (posterior)	باور درباره‌ی پارامتر بعد از دیدن داده
hierarchical model	مدل سلسله‌مراتبی (چندسطحی)	پارامترهای فردی از یک توزیع گروهی می‌آیند
adequacy check	بررسی کفایت مدل	آیا مدل ویژگی‌های اصلی داده را بازتولید می‌کند
posterior predictive check (PPC)	بررسی پیش‌بینی پسین	مقایسه‌ی داده‌ی شبیه‌سازی‌شده از پسین با داده‌ی واقعی
cross-validation (CV)	اعتبارسنجی متقابل (cross-validation)	برازش روی بخشی از داده و آزمون روی بخش کنارگذاشته
BIC / AIC	معیار اطلاعاتی آکائیکه / بیزی	برازش به‌علاوه‌ی جریمه برای تعداد پارامتر
research design	طرح آزمایش	شرایط، تعداد کوشش‌ها و نمونه‌ها
model recovery	بازیابی مدل	آیا مقایسه‌ی مدل، مدل مولد را درست انتخاب می‌کند
drift-diffusion model (DDM)	مدل drift-diffusion (رانش–انتشار)	انباشت پیوسته‌ی شواهد بین دو مرز
preregistration	پیش‌ثبت (preregistration)	ثبت برنامه‌ی تحلیل پیش از دیدن داده
prior	توزیع پیشین (prior)	باور درباره‌ی پارامتر پیش از دیدن داده
random seed	seed تصادفی	عدد شروع مولد اعداد تصادفی برای تکرارپذیری
large language model (LLM)	مدل بزرگ زبانی	شبکه‌ی عصبی‌ای که کلمه‌ی بعدی متن را پیش‌بینی می‌کند
accuracy	دقت	نسبت پاسخ‌های درست

۲.۳.۶ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. یک مطالعه‌ی مدل‌سازی کامل (سؤال، مدل، برازش، ارزیابی، بازیابی، تفسیر) را روشن و در محدوده‌ی زمانی **ارائه کنند**.
۲. مطالعه‌های مدل‌سازی دیگران را با معیارهای ارزیابی درس، به شکلی سازنده **نقد کنند**.
۳. یک چک‌لیست شیوه‌ی خوب مدل‌سازی (بازتولیدپذیری، شفافیت، استواری) را روی گزارش پروژه‌ی خودشان **اعمال کنند**.
۴. روش‌های درس را در یک گردش کار منسجم **یکپارچه کنند** و **توضیح دهند** کِی از کدام استفاده کنند.

۳.۳.۶ مقدمه

یک مدل فقط به اندازه‌ی توانایی دیگران در فهمیدن، بررسی کردن و ساختن روی آن مفید است. در ۱۵ هفته، همه‌ی labها یک مسیر را دنبال کرده‌اند: **صورت‌بندی** ← **شبیه‌سازی** ← **برازش** ← **ارزیابی** ← **بازیابی** ← **تفسیر**. این هفته این مسیر را در پروژه‌ی خودتان نشان می‌دهید، و نیمه‌ی دیگر مدل‌سازی علمی را تمرین می‌کنید: خواندن مدل دیگران به شکلی انتقادی ولی منصفانه. جلسه با شیوه‌هایی تمام می‌شود که کار مدل‌سازی را قابل اعتماد و قابل استفاده‌ی دوباره می‌کنند: کد بازتولیدپذیر، گزارش شفاف، بیان صادقانه‌ی محدودیت‌ها.

۴.۳.۶ جزوه‌ی درس

به زبان ساده هفته‌ی آخر روش جدیدی ندارد. دانشجوها پروژه‌هایشان را ارائه می‌دهند و کل درس به شکل یک گردش کار خلاصه می‌شود: نظریه را به شکل یک مدل **فرمال کن**، آن را **شبیه‌سازی کن** تا ببینی چه پیش‌بینی می‌کند، آن را روی داده **برازش کن**، **ارزیابی‌اش کن** (آیا برازش خوبی دارد و آیا از رقیب‌ها بهتر است؟)، بررسی کن که روش در این طرح آزمایش می‌تواند حقیقت را **بازیابی کند**، و نتیجه را به زبان روان‌شناختی **تفسیر کن**، از جمله اینکه چه نتیجه‌ای را نمی‌شود گرفت. چک‌لیست شیوه‌ی خوب این قدم‌ها را به چیزهای مشخصی تبدیل می‌کند که در هر گزارش باید بررسی شوند: کد بازتولیدپذیر، گزارش عدم قطعیت، بررسی کفایت مدل، بازیابی و بیان صادقانه‌ی محدودیت‌ها.

زمان‌بندی پیشنهادی (وقت درس، ۶۰ دقیقه): جمع‌بندی درس ۱۵ · چک‌لیست شیوه‌ی خوب ۱۵ · اولین ارائه‌ها ۳۰.

۱. کل درس در یک جدول

سؤالی که با آن روبه‌رو هستید	ابزارها	هفته
چطور یک نظریه را به مدل تبدیل کنم؟	پنج جزء؛ شبیه‌سازی؛ بررسی‌های تحلیلی	۱–۲
چطور پارامترها را برآورد کنم؟	کمترین مربعات؛ بیشینه‌ی درست‌نمایی؛ بهینه‌سازی grid)، Nelder–Mead، L-BFGS-B)، multi-start، کران‌ها	۳–۴
برآوردها چقدر مطمئن‌اند؟	SEهای Hessian، profile likelihood، bootstrap؛ بازه‌های پسین	۵، ۹
با شرکت‌کننده‌های زیاد چه کنم؟	برازش‌های فردی؛ خطاهای میانگین‌گیری؛ مدل‌های سلسله‌مراتبی	۵، ۱۳
آیا مدل کفایت دارد؟	باقی‌مانده‌ها، G^2، بررسی‌های پیش‌بینی پسین	۲–۴، ۱۰
کدام مدل بهتر است؟	CV، LRT، AIC/BIC، Bayes factor	۶–۷، ۱۰
آیا طرح من می‌تواند به سؤال جواب دهد؟	بازیابی پارامتر، بازیابی مدل	۷

سؤالی که با آن روبه‌رو هستید	ابزارها	هفته
چطور برای مدل‌های پیچیده پسین به دست بیاورم؟	Grid ← Metropolis–Hastings ← Gibbs ← NUTS (PyMC)؛ $\hat{R}$، ESS، divergenceها	۹–۱۳
مدل‌ها در حوزه‌های مختلف چه شکلی‌اند؟	SDT، فراموشی، تمرین، GCM، DDM/EZ، RL، مشاهده‌گرهای ایده‌آل	۲، ۵، ۱۴–۱۵

برای یک مهندس با نگاه به عقب، بیشتر درس روی ابزارهایی که قبلاً می‌شناسید منطبق است، و جدول زیر می‌تواند خلاصه‌ی خودتان برای جواب دادن به سؤال‌های دانشجوها باشد:

موضوع درس	معادل مهندسی
DDM / random walk (هفته‌های ۱، ۱۴)	آشکارسازی ترتیبی (SPRT)، زمان‌های اولین عبور
SDT، ROC (هفته‌ی ۲)	آشکارسازی دودویی، P_D / P_{FA}، ROC
کمترین مربعات، بهینه‌سازها (هفته‌ی ۳)	تخمین LS، روش‌های گرادیانی، Gauss–Newton
بیشینه‌ی درست‌نمایی، G^2، LRT (هفته‌های ۴، ۷)	تخمین ML، آزمون‌های نیکویی برازش، GLRT
SE از Hessian، bootstrap (هفته‌ی ۵)	اطلاعات فیشر / CRLB، ارزیابی کارایی با Monte Carlo
CV، AIC، BIC (هفته‌های ۶–۷)	انتخاب مرتبه‌ی مدل AIC)، (MDL، داده‌ی اعتبارسنجی
بازیابی پارامتر و مدل (هفته‌ی ۷)	آزمودن تخمین‌گرها روی داده‌ی مصنوعی با حقیقت معلوم
استنباط بیزی، BF (هفته‌های ۹–۱۰)	تخمین MAP/MMSE، آشکارسازی بیزی
MCMC، $\hat{R}$، ESS (هفته‌های ۱۱–۱۲)	شبیه‌سازی Monte Carlo، فرایندهای مارکوف، آمار نمونه‌های همبسته
مدل‌های سلسله‌مراتبی (هفته‌ی ۱۳)	empirical Bayes، shrinkage از نوع James–Stein
قاعده‌ی دلتا، ترکیب نشانه‌ها (هفته‌ی ۱۵)	تطبیق LMS، MRC / ادغام حسگر در کالمن

چیزی که در مدل‌سازی شناختی واقعاً متفاوت است: «سیستم» یک انسان است، داده کم و پرنویز است، و خود پارامترها یافته‌ی علمی‌اند؛ پس تفسیر، عدم قطعیت و بازیابی از کارایی خام مهم‌ترند.

۲. یک چک‌لیست شیوه‌ی خوب مدل‌سازی

پیش از برازش - [ ] سؤال پژوهشی بر حسب پارامترهای مدل یا مقایسه‌ی مدل‌ها بیان شده است. - [ ] مدل‌های نامزد (دست‌کم با یک جایگزین ساده‌تر) پیش از نگاه کردن به داده مشخص شده‌اند، ترجیحاً با پیش‌ثبت (preregistration). - [ ] پیشین‌ها (اگر بیزی است) توجیه شده‌اند و با شبیه‌سازی پیش‌بینی پیشین بررسی شده‌اند. - [ ] بازیابی پارامتر و مدل **در همان طرح واقعی** بررسی شده است.

برازش و ارزیابی - [ ] درست‌نمایی با نوع داده جور است (دوجمله‌ای برای شمارش‌ها، ترتیبی برای یادگیری، . . .). - [ ] بهینه‌سازی از multi-start و کران‌های معقول استفاده می‌کند و برازش‌ها به‌صورت تصویری بررسی شده‌اند؛ برای MCMC، $\hat{R}$، ESS و divergenceها گزارش شده‌اند. - [ ] برازش مطلق (باقی‌مانده‌ها، G^2 یا PPC) و برازش نسبی (CV/IC/BF) گزارش شده‌اند. - [ ] برای هر پارامتری که تفسیر می‌شود عدم قطعیت گزارش شده است.

گزارش و بازتولیدپذیری - [ ] همه‌ی کدها و (در صورت اجازه) داده‌ها به اشتراک گذاشته شده‌اند؛ seedهای تصادفی ثابت شده‌اند. - [ ] نسخه‌های نرم‌افزار ثبت شده‌اند (مثلاً `condaenvexport>environment.yml`). - [ ] یک دستور یا notebook

همه‌ی عددها و نمودارهای گزارش را دوباره تولید می‌کند. - [ ] محدودیت‌ها بیان شده‌اند: طرح چه چیزی را نمی‌تواند تمیز دهد، کدام پارامترها قابل بازیابی نیستند، کدام فرض‌ها آزموده نشده‌اند.

ثبت محیط محاسباتی (در هر notebook پروژه بگذارید):

> Code · **کد:** `code/week16.py`، cell ۱ · سلول ۱

۳. قالب ارائه

- **مدت:** ۸ دقیقه (انفرادی) یا ۱۰ دقیقه (دونفره)، به‌علاوه‌ی ۴ دقیقه پرسش. زمان دقیق رعایت می‌شود.
- **ساختار پیشنهادی** (تقریباً هر مورد یک اسلاید):

۱. سؤال و اینکه چرا مهم است.
۲. مدل(ها): معادله‌ها و معنای روان‌شناختی هر پارامتر.
۳. داده و طرح.
۴. روش برازش و یک نمودار برازش (داده + پیش‌بینی‌ها).
۵. ارزیابی: مقایسه‌ی مدل و یک بررسی کفایت.
۶. بازیابی: آیا طرح می‌تواند به سؤال جواب دهد؟
۷. تفسیر و محدودیت‌ها.

- **تیم‌های دونفره:** هر دو عضو ارائه می‌دهند، و بخش بیزی/MCMC یا سلسله‌مراتبی باید نشان داده شود.
- **برنامه:** یک هفته زودتر اعلام می‌شود؛ ترتیب با قرعه تعیین می‌شود. جلسه‌ها در وقت درس و lab برگزار می‌شوند (حدود ۱۵–۱۸ ارائه در ۳ ساعت، بسته به تعداد ثبت‌نام).

۴. دادن و گرفتن بازخورد

هر دانشجو برای سه ارائه‌ی تعیین‌شده یک **فرم بازخورد همتا** پر می‌کند (پایین). بازخورد برای ارائه‌دهنده ناشناس و برای مدرس قابل مشاهده است و در نمره‌ی مشارکت (lab check-off) حساب می‌شود. بازخورد خوب **مشخص** است («نمودار بازیابی نشان می‌دهد β identifiable نیست، پس تفاوت گروه‌ها در β نباید تفسیر شود») نه کلی («ارائه‌ی خوبی بود»)، و **سازنده** است (یک بهبود مشخص پیشنهاد می‌کند).

فرم بازخورد همتا

مورد	امتیاز (۱–۴)	توضیح
سؤال روشن بود و مدل با آن جور بود		
پارامترهای مدل با زبان روان‌شناختی توضیح داده شدند		
برازش نشان داده و ارزیابی شد (کفایت + مقایسه)		
به بازیابی یا identifiability پرداخته شد		
نتیجه‌گیری‌ها از نتایج بیرون آمدند و محدودیت‌ها بیان شدند		
یک چیزی که به‌خصوص خوب انجام شده بود		
یک پیشنهاد مشخص برای گزارش کتبی		

برای مدرس

- **با rubric نمره بدهید و با چک‌لیست نظر بدهید.** در طول ارائه‌ها چک‌لیست شیوه‌ی خوب را کنارتان نگه دارید و برای هر تیم یک نقطه‌ی قوت و یک پیشنهاد مشخص یادداشت کنید؛ این کار بازخورد کتبی را سریع و منصفانه می‌کند.
- **سؤال‌هایی برای ارائه‌دهندگان** (منطبق بر درس): کدام پارامتر به سؤال شما جواب می‌دهد؟ از کجا می‌دانید قابل بازیابی است؟ آیا مدل به‌طور مطلق برازش خوبی دارد، نه فقط بهتر از رقیب؟ طرح آزمایش شما چه چیزی را نمی‌تواند به ما بگوید؟
- **از نقد حل‌شده** (مطالعه‌ی خیالی Q-learning به‌عنوان الگوی بازخورد دادن دانشجوها استفاده کنید: مشخص، وصل به یکی از هفته‌های درس، و سازنده.
- **درس را با جدول خلاصه‌ی یک‌صفحه‌ای ببندید.** از دانشجوها بپرسید کدام سطر برایشان سخت‌تر بود و برای مرور امتحان آن‌ها را به هفته‌ی مربوط ارجاع دهید.

۵.۳.۶ مثال حل‌شده: نقد یک مطالعه‌ی مدل‌سازی

خلاصه‌ی یک مطالعه‌ی (خیالی). «یک مدل *Q-learning* را روی ۳۰ بیمار و ۳۰ فرد کنترل برازش کردیم که ۶۰ *trial* از یک تکلیف *bandit* دوبازویی با احتمال‌های پاداش ثابت انجام دادند. هر شرکت‌کننده با *MLE* برازش شد. بیماران نرخ یادگیری به‌طور معنادار پایین‌تری داشتند ($t(58) = 2.4$، $p = .02$). نتیجه می‌گیریم که این اختلال یادگیری از پاداش را مختل می‌کند.»

نقد با استفاده از چک‌لیست.

۱. **بازیابی در این طرح (هفته‌ی ۷، lab هفته‌ی ۱۵).** با ۶۰ trial و احتمال‌های پاداش ثابت، نرخ یادگیری ضعیف شناسایی می‌شود، و α و β با هم trade-off دارند. بدون مطالعه‌ی بازیابی، تفاوت در $\hat{\alpha}$ ممکن است بازتاب تفاوت در نویز انتخاب (β) یا فقط نویز برآورد باشد. پیشنهاد: بازیابی پارامتر را در همین طرح گزارش کنید و وارونگی اضافه کنید.

۲. **مقایسه‌ی مدل (هفته‌ی ۱۵، بخش D).** آیا Q-learning در هر دو گروه از راهبردهای ساده‌تر (WSLS، پافشاری) بهتر بود؟ اگر بیماران با راهبرد دیگری بهتر توصیف شوند، مقایسه‌ی α آن‌ها با گروه کنترل معنادار نیست. پیشنهاد: AIC/BIC یا CV را برای هر گروه همراه با بازیابی مدل گزارش کنید.

۳. **آزمون t مرحله‌ی دوم روی برآوردهای نقطه‌ای (هفته‌های ۵، ۱۳).** عدم قطعیت برآوردهای فردی را نادیده می‌گیرد، که با ۶۰ trial بزرگ است. پیشنهاد: یک مدل سلسله‌مراتبی با اثر گروه روی α، و گزارش پسین آن.

۴. **کفایت (هفته‌های ۴، ۱۰).** هیچ بررسی پیش‌بینی پسین یا نمودار منحنی یادگیری نشان داده نشده. آیا مدل منحنی یادگیری هر گروه را بازتولید می‌کند؟

۵. **تفسیر.** «یادگیری از پاداش را مختل می‌کند» یک ادعای فرایندی قوی است. $\hat{\alpha}$ پایین‌تر با کاوش بیشتر، انگیزه‌ی کمتر (β پایین‌تر) یا پیشین‌های متفاوت روی ارزش‌های اولیه هم سازگار است. پیشنهاد: نتیجه‌گیری را تعدیل کنید، یا طرحی اضافه کنید که این تبیین‌ها را از هم جدا کند.

در مجموع: یک مطالعه‌ی اول معقول که نتیجه‌گیری‌اش هنوز پشتوانه ندارد. سه افزوده (بازیابی، مقایسه‌ی مدل، برآورد سلسله‌مراتبی) آن را قانع‌کننده می‌کند. توجه کنید که هر نکته مستقیماً به یکی از هفته‌های این درس برمی‌گردد.

۶.۳.۶ lab (۲ ساعت): ارائه‌ها و بازخورد همتایان

اهداف: پروژه‌تان را ارائه دهید؛ برای سه ارائه بازخورد کتبی بدهید؛ بازخوردهایی را که می‌گیرید برای گزارش پایانی یادداشت کنید.

هماهنگی‌ها: - اسلایدها (PDF) را **پیش از** شروع جلسه در صفحه‌ی درس بارگذاری کنید. - لپ‌تاپتان را با notebook پروژه بیاورید، برای پرسش‌هایی درباره‌ی کد. - فرم‌های بازخورد همتا را در طول جلسه پر کنید (کاغذی یا فرم آنلاین) و تا پایان روز تحویل دهید.

بعد از ارائه‌ها: مدرس به هر تیم بازخورد شفاهی کوتاهی می‌دهد. بازخورد کتبی (مدرس + همتایان) ظرف ۳ روز برگردانده می‌شود تا در گزارش پایانی استفاده شود.

۷.۳.۶ ارتباط با هوش مصنوعی و LLMها

شیوه‌ی خوب وقتی هوش مصنوعی بخشی از کار مدل‌سازی شماست. ابزارهای هوش مصنوعی امروز با سه نقش وارد مدل‌سازی شناختی می‌شوند، و هر نقش به عادت‌های بررسی این درس نیاز دارد: ۱. **به‌عنوان دستیار کدنویسی.** کد تولیدشده می‌تواند درست به نظر برسد و غلط باشد. آن را به روش مدل‌سازی بیازمایید: داده را با پارامترهای معلوم شبیه‌سازی کنید و بررسی کنید که کد آن‌ها را بازیابی می‌کند (بازیابی پارامتر به‌عنوان unit test). ۲. **به‌عنوان «شرکت‌کننده‌ی شبیه‌سازی‌شده».** بعضی مطالعه‌ها آزمایش‌های روان‌شناسی را به LLMها می‌دهند و جواب‌ها را با داده‌ی انسانی مقایسه می‌کنند، یا حتی مدل‌هایی مبتنی بر LLM برای رفتار انسان پیشنهاد می‌کنند (مثلاً Schulz, & Binz ۲۰۲۳؛ Dillion et al., ۲۰۲۳ [بررسی شود]). چنین ادعاهایی را مثل هر مدل دیگری ارزیابی کنید: تعمیم به تکلیف‌های تازه، مقایسه با مدل‌های شناختی ساده‌تر، تقلید (mimicry) و تفسیرپذیری (هفته‌ی ۱۵). ۳. **به‌عنوان موضوع مطالعه.** اگر یک LLM را می‌آزمایید، نام و نسخه‌ی مدل، تاریخ، promptهای دقیق، دما و تعداد نمونه‌ها را ثبت کنید. بدون این‌ها مطالعه قابل بازتولید نیست.

کد پایین یک تابع SDT ازپیش‌آماده را که «یک دستیار نوشته» می‌آزماید. معقول به نظر می‌رسد و حتی حالت $c = 0$ را درست جواب می‌دهد، ولی یک آزمون بازیابی نشان می‌دهد که علامت c را غلط حساب می‌کند.

Code · **کد:** `code/week16.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
true (d', c) = (1.5, 0.3) -> recovered (1.50, -0.30)  FAIL
true (d', c) = (1.0, -0.4) -> recovered (1.00, 0.40)  FAIL
true (d', c) = (2.0, 0.0) -> recovered (2.00, 0.00)  OK
```

یک مشاهده‌گر liberal، محافظه‌کار گزارش می‌شد، که نتیجه‌گیری یک مطالعه‌ی سوگیری را برعکس می‌کرد. آزمونی که فقط $c = 0$ را بسنجد این را پیدا نمی‌کرد.

امتحانش کنید (بدون نیاز به API). - ⋆ تابع را اصلاح کنید و آزمون‌ها را دوباره اجرا کنید. - ⋆⋆ یک آزمون بازیابی مشابه برای تابع EZ-diffusion هفته‌ی ۱۴ بنویسید، با استفاده از شبیه‌ساز همان lab. - ⋆⋆ برای پروژه‌ی خودتان: یک پاراگراف به بیانیه‌ی بازتولیدپذیری اضافه کنید که توضیح دهد ابزارهای هوش مصنوعی چطور استفاده شدند و خروجی‌شان چطور بررسی شد (`assessments/project_brief.md`، بخش ۶ را ببینید).

مطالعه‌ی اختیاری: Schulz, E. & Binz, M., (۲۰۲۳). Using cognitive psychology to understand GPT-3. *PNAS*, ۱۲۰(۶)، e2218523120. Dillion, D., Tandon, N., Gu, Y., & Gray, K. (۲۰۲۳). Can AI language models replace human participants? *Trends in Cognitive Sciences*, ۲۷، ۵۹۷–۶۰۰ [بررسی شود].

۸.۳.۶ اشتباهات رایج و برداشت‌های نادرست (در ارائه‌ها و گزارش‌های پروژه)

۱. **پرداختن زیاد به روش و کم به معنا.** هر پارامتر و هر نتیجه به یک تفسیر روان‌شناختی نیاز دارد.
۲. **نشان دادن یک آماره‌ی برازش بدون نمودار برازش.** همیشه داده را در برابر پیش‌بینی‌ها رسم کنید.
۳. **مقایسه‌ی مدل بدون بررسی کفایت،** یا برعکس.
۴. **تفسیر پارامترهایی که قابل بازیابی بودنشان نشان داده نشده.**
۵. **ادعای بیش از حد:** «مدل درست است»، «ذهن بیزی است». بگویید شواهد از چه چیزی پشتیبانی می‌کند و از چه چیزی نه.
۶. **نتایج غیرقابل بازتولید:** seedهای جاافتاده، نسخه‌های ثبت‌نشده‌ی بسته‌ها، سلول‌های notebook که بی‌ترتیب اجرا شده‌اند.
۷. **رد کردن از زمان.** ارائه را تمرین کنید؛ در هر اسلاید یک ایده.

۹.۳.۶ خودآزمایی (پرسش‌های مرور یکپارچه برای امتحان پایانی)

۱. همکاری داده‌ی دقت و RT از یک دست‌کاری سرعت/دقت دارد و می‌خواهد بداند دست‌کاری روی احتیاط اثر می‌گذارد یا کیفیت شواهد. یک برنامه‌ی کامل مدل‌سازی طرح کنید و مدل، روش برازش، ارزیابی و بررسی بازیابی را نام ببرید. **پاسخ** مدل: drift-diffusion (EZ-diffusion برای دور اول، یا DDM کامل با MLE / بیزی سلسله‌مراتبی). برای هر شرکت‌کننده و شرط برازش کنید. مدل‌هایی را مقایسه کنید که در آن‌ها دست‌کاری فقط روی a، فقط روی v، یا روی هر دو اثر می‌گذارد (AIC/BIC یا یک مدل سلسله‌مراتبی با اثر شرط؛ PPC روی quantileهای .(RT بازیابی: با هر مدل در طرح واقعی داده شبیه‌سازی کنید و بررسی کنید که پارامترها و نتیجه‌ی «کدام پارامتر تغییر کرد» بازیابی می‌شوند. اثر شرط روی a و v را با عدم قطعیتش تفسیر کنید.

۲. کِی برای مقایسه‌ی دو مدل Bayes factor را به cross-validation ترجیح می‌دهید، و برعکس؟ **پاسخ** :Bayes factor وقتیِ سؤال این است که با توجه به داده کدام مدل محتمل‌تر است (شواهد، از جمله پشتیبانی از فرض صفر)، وقتی پیشین‌های معنادار در دسترس‌اند، و همراه با تحلیل حساسیت به پیشین. :CV وقتی هدف دقت پیش‌بینی برای داده‌ی تازه از یک نوع مشخص است، توجیه پیشین‌ها سخت است، یا BF بیش از حد به پیشین‌ها حساس است.

۳. توضیح دهید چطور یک پارامتر می‌تواند خیلی دقیق برآورد شود (CI یا پسین باریک) و با این حال بی‌معنی باشد. **پاسخ** دقت فقط انحنای درست‌نمایی را تحت مدل فرض‌شده نشان می‌دهد. اگر مدل بد مشخص شده باشد (در G^2/PPC رد شود)، اگر پارامتر با پارامتر دیگری معاوضه شود طوری که معنایش به یک قید دلبخواه بستگی داشته باشد، یا اگر بهینه‌ساز یا نمونه‌گیر شکست خورده باشد (کمینه‌ی محلی، کران، عدم همگرایی)، برآورد دقیق سازه‌ی مورد نظر را نمی‌سنجد.

۴. چرا مدل‌های سلسله‌مراتبی اغلب برآوردهای فردی بهتری از برازش‌های فردی جداگانه می‌دهند؟ **پاسخ** از طریق توزیع گروه بین شرکت‌کننده‌ها اطلاعات به اشتراک می‌گذارند و برآوردهای فردی پرنویز را به نسبت عدم قطعیتشان به سمت میانگین گروه shrink می‌کنند. این واریانس برآورد را بیشتر از سوگیری‌ای که اضافه می‌کند کم می‌کند، پس برآوردها به‌طور میانگین به حقیقت نزدیک‌ترند.

۵. سه راه مختلفی را که این درس از شبیه‌سازی استفاده کرد نام ببرید و بگویید چرا هرکدام مهم است. **پاسخ** (۱) کاوش پیش‌بینی‌های مدل پیش از برازش (چه چیزی را می‌تواند و نمی‌تواند تولید کند). (۲) بازیابی پارامتر و مدل (آیا طرح و روش می‌توانند به سؤال جواب دهند). (۳) bootstrap و بررسی‌های پیش‌بینی (عدم قطعیت و کفایت). همچنین: Monte Carlo و MCMC برای محاسبه‌ی پسین‌ها.

۶. یک مدل بین چهار نامزد بهترین AIC را دارد ولی بررسی پیش‌بینی پسین یک ناهمخوانی نظام‌مند در تأخیرهای طولانی نشان می‌دهد. چه گزارش می‌کنید و چه نتیجه می‌گیرید؟ **پاسخ** هر دو را گزارش کنید. مدل برای پیش‌بینی بهترینِ نامزدهاست، ولی

به‌طور مطلق کفایت ندارد: هیچ‌کدام از نامزدها رفتار تأخیرهای طولانی را نمی‌گیرد. نتیجه‌گیری‌ها باید به همین نسبت محدود شوند، و قدم بعدی بازنگری مدل با هدف همان ویژگی است.

۱۰.۳.۶ تکلیف

پروژه‌ی پایانی: گزارش کتبی و کد

- **مهلت:** یک هفته بعد از این جلسه، و در هر حال پیش از امتحان پایانی (تاریخ دقیق در صفحه‌ی درس).
- **تحویل:** گزارش PDF)، حداکثر ۱۰ صفحه برای انفرادی و ۱۴ برای دونفره، بدون منابع و پیوست) به‌علاوه‌ی یک آرشیو کد یا لینک repository که همه‌ی نتایج را بازتولید کند.
- **نمره‌دهی:** شرح پروژه و rubric را ببینید (`assessments/project_brief.md`). گزارش و کد ۳ نمره از ۶ نمره‌ی پروژه را دارند؛ پیشنهاد (۱) و ارائه (۲) قبلاً نمره گرفته‌اند.
- **از بازخورد امروز استفاده کنید:** rubric به پاسخ‌های قابل مشاهده به بازخورد ارائه نمره می‌دهد.

امتحان پایانی

کتبی، جامع (با تأکید بر فصل‌های ۴–۶)، با برگه‌ی فرمول، بدون لپ‌تاپ؛ ۳ نمره از ۲۰. برای قالب و یک نمونه سؤال `assessments/final_exam.md` را ببینید.

۱۱.۳.۶ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)**: فصل استفاده از مدل‌ها در روان‌شناسی (نقش مدل‌ها در توسعه‌ی نظریه و دام‌های رایج) [شماره‌ی فصل بررسی شود].
- Wagenmakers & Lee **(۲۰۱۴)**: مطالعه‌های موردی بخش IV را برای ایده‌هایی درباره‌ی گسترش پروژه‌تان مرور کنید.
- Lao & Martin, Kumar **(۲۰۲۱)، فصل ۹.** گردش‌های کار بیزی از ابتدا تا انتها، الگویی خوب برای ساختار دادن به یک گزارش.
- اختیاری، خارج از فهرست درس: Collins, A. G. E. & Wilson, R. C., (۲۰۱۹). Ten simple rules for the computational modeling of behavioral data. *eLife*, ۸، e49547.

از همراهی‌تان در این درس سپاسگزاریم؛ به مدل‌سازی ادامه دهید!

واژه‌نامه

اصطلاحات به ترتیب الفبای انگلیسی آمده‌اند تا با متن‌های انگلیسی و کتاب‌ها راحت تطبیق داده شوند. عدد داخل کروشه هفته‌ای است که اصطلاح در آن معرفی شده یا کامل‌تر توضیح داده شده است. نمادگذاری مطابق جدول نمادهای هفته‌ی ۱ است.

اصطلاح (English)	معادل فارسی	تعریف
Acceptance rate [۱۱]	نرخ پذیرش	نسبت پیشنهادهای (proposals) الگوریتم Metropolis که پذیرفته می‌شوند. خیلی بالا یعنی گام‌ها خیلی کوچک‌اند؛ خیلی پایین یعنی گام‌ها خیلی بزرگ‌اند. هدف تقریبی: ۲.۰ تا ۵.۰.
Aggregation artifact [۵]	خطای ناشی از میانگین‌گیری	الگویی در داده‌های میانگین‌گیری‌شده که در هیچ فردی دیده نمی‌شود؛ مثلاً منحنی توانی که از میانگین‌گیری یادگیرنده‌های نمایی به دست می‌آید.
AIC / AICc [۷]	معیار اطلاعاتی آکائیکه	$2\,\mathrm{NLL} + 2k$؛ دقت پیش‌بینی روی داده‌ی جدید را تخمین می‌زند. AICc یک تصحیح برای نمونه‌های کوچک اضافه می‌کند.
Akaike weight [۷]	وزن آکائیکه	$w_i \propto \exp(-\Delta_i/2)$: پشتیبانی نسبی از مدل i به‌عنوان بهترین پیش‌بینی‌کننده در میان مدل‌های رقیب.
Attention weight (w_m) [۱۴]	وزن توجه	پارامتر GCM: سهمی از توجه که به بُعد m محرک داده می‌شود (مجموع وزن‌ها ۱ است).
Bayes factor (BF_{12}) [۱۰]	Bayes factor	$p(\mathbf{y} \mid \mathcal{M}_1)/p(\mathbf{y} \mid \mathcal{M}_2)$: نسبت درست‌نمایی‌های حاشیه‌ای داده‌ها چقدر نسبت بخت (odds) دو مدل را تغییر می‌دهند.
Bayesian data analysis [۹]	تحلیل داده‌ی بیزی	استفاده از قاعده‌ی بیز برای استنباط پارامترها و مدل‌ها از داده؛ روشی که پژوهشگر به کار می‌برد و برای هر مدلی قابل استفاده است.

اصطلاح (English)	معادل فارسی	تعریف
Bayesian model of cognition [۱۵]	مدل بیزی شناخت	این فرضیه که ذهن (به‌طور تقریبی) استنباط بیزی انجام می‌دهد؛ نظریه‌ای در سطح محاسباتی.
Beta-binomial model [۹]	مدل beta-binomial	درست‌نمایی دوجمله‌ای با پیشین Beta؛ پسین هم دوباره Beta است (conjugacy).
BIC [۷]	معیار اطلاعاتی بیزی	$2\,\mathrm{NLL} + k \ln N$؛ تقریبی از $-2 \ln p(\mathbf{y} \mid \mathcal{M})$ است و مدل‌های ساده‌تری از AIC را ترجیح می‌دهد.
Bias–variance trade-off [۶]	trade-off سوگیری–واریانس	خطای مورد انتظار پیش‌بینی = نویز + مربع سوگیری + واریانس. مدل‌های منعطف سوگیری را کم و واریانس را زیاد می‌کنند.
Bootstrap (parametric) [۵]	bootstrap پارامتری	از مدل برازش‌شده تعداد زیادی مجموعه‌داده شبیه‌سازی کنید، هرکدام را دوباره برازش کنید و پراکندگی برآوردها را به‌عنوان عدم قطعیت آن‌ها به کار ببرید.
Boundary separation (a) [۱، ۱۴]	فاصله‌ی مرزها	پارامتر DDM: / random walk فاصله‌ی بین دو مرز پاسخ. نماینده‌ی احتیاط (caution).
Burn-in (warm-up) [۱۱]	دوره‌ی گرم‌شدن (burn-in)	تکرارهای اولیه‌ی MCMC که دور ریخته می‌شوند چون هنوز تحت تأثیر مقدار شروع‌اند.
Centered / non-centered parameterization [۱۳]	پارامترسازی centered / non-centered	دو روش هم‌ارز برای نوشتن یک مدل سلسله‌مراتبی؛ شکل non-centered ($d_j = \mu + \sigma z_j$) از هندسه‌ی قیفی و divergence جلوگیری می‌کند.
Complete / no / partial pooling [۵، ۱۳]	complete pooling / no pooling / partial pooling	یک مجموعه پارامتر برای همه / پارامترهای مستقل برای هر فرد / پارامترهای فردی که از یک توزیع گروهی برآوردشده می‌آیند.
Confusion matrix (model recovery) [۷]	confusion matrix (بازیابی مدل)	P(مدل تولیدکننده ∣ مدل انتخاب‌شده) که با شبیه‌سازی تخمین زده می‌شود.
Conjugate prior [۹، ۱۲]	پیشین conjugate	پیشینی که پسینی از همان خانواده می‌دهد (مثلاً Beta برای داده‌ی دوجمله‌ای)؛ نمونه‌گیری Gibbs را ممکن می‌کند.
HDI / Credible interval [۹]	credible interval / بازه‌ی بیشترین چگالی	بازه‌ای که احتمال پسین مشخصی (مثلاً ۹۵٪) را در بر دارد؛ HDI باریک‌ترین چنین بازه‌ای است.

اصطلاح (English)	معادل فارسی	تعریف
Criterion (c) [۲]	ملاک (criterion)	پارامتر سوگیری پاسخ در SDT: محل ملاک نسبت به نقطه‌ی میانی توزیع‌های نویز و علامت. مقدار مثبت یعنی محافظه‌کار.
Cross-validation (K-fold, LOO) [۶]	cross-validation	مدل را روی بخشی از داده برازش کنید و پیش‌بینی‌هایش را روی بخش کنارگذاشته بسنجید و این کار را بین K بخش (fold) بچرخانید؛ LOO هر بار یک مشاهده را کنار می‌گذارد.
d' (sensitivity) [۲]	حساسیت	پارامتر SDT: فاصله‌ی بین توزیع‌های علامت و نویز بر حسب واحد انحراف معیار.
Rescorla–Wagner / Delta rule [۱۵]	قاعده‌ی دلتا / قاعده‌ی Rescorla–Wagner	به‌روزرسانی مبتنی بر خطا: $Q \leftarrow Q + \alpha(r - Q)$.
Deterministic core [۲]	هسته‌ی قطعی	بخشی از مدل که پیش‌بینی میانگین را می‌دهد، $f(x;\boldsymbol{\theta})$.
Deviance (G^2) [۴]	انحراف (deviance)	$2(\ell_{\text{sat}} - \hat{\ell})$: میزان عدم برازش نسبت به مدل اشباع‌شده؛ تقریباً χ^2 با درجه‌ی آزادی = تعداد خانه‌ها $- k$.
Divergent transition [۱۳]	divergence	مسیری در NUTS که انتگرال‌گیری عددی‌اش شکسته است؛ نشان می‌دهد بخشی از پسین به‌خوبی کاوش نشده است.
Drift rate (v) [۱، ۱۴]	drift rate	پارامتر DDM: نرخ میانگین انباشت شواهد. نماینده‌ی کیفیت شواهد.
Drift-diffusion model (DDM) [۱۴]	مدل drift-diffusion	انباشت پیوسته و پرنویز شواهد بین دو مرز؛ انتخاب‌ها و توزیع زمان‌های واکنش را پیش‌بینی می‌کند.
Effective sample size (ESS) [۱۲]	اندازه‌ی مؤثر نمونه	تعداد نمونه‌های مستقلی که همان دقت نمونه‌های خودهمبسته‌ی MCMC را می‌دهند.
Error surface [۳]	سطح خطا	معیار ناهمخوانی (SSE یا NLL) به‌صورت تابعی از پارامترها؛ شکلش کمینه‌ها، دره‌ها و trade-off پارامترها) و فلات‌ها را نشان می‌دهد.
marginal likelihood / Evidence [۹، ۱۰]	شواهد / marginal likelihood	$p(\mathbf{y} \mid \mathcal{M}) = \int p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})\, d\boldsymbol{\theta}$: مدل پیش از برازش، داده‌ها را چقدر خوب پیش‌بینی کرده بود.

اصطلاح (English)	معادل فارسی	تعریف
EZ-diffusion [۱۴]	EZ-diffusion	برآورد بسته (closed-form) drift rate، فاصله‌ی مرزها و non-decision time از دقت و میانگین و واریانس زمان واکنش پاسخ‌های درست.
Flexibility (model complexity) [۶]	انعطاف‌پذیری (پیچیدگی مدل)	دامنه‌ی الگوهای داده‌ای که یک مدل می‌تواند تولید کند؛ به تعداد پارامترها و شکل تابعی بستگی دارد.
Forward / inverse problem [۱]	مسئله‌ی مستقیم / معکوس	شبیه‌سازی (پارامتر ← داده) در برابر برآورد (داده ← پارامتر).
Full conditional [۱۲]	full conditional	توزیع یک پارامتر به شرط همه‌ی پارامترهای دیگر و داده؛ Gibbs از آن نمونه می‌گیرد.
GCM (Generalized Context Model) [۱۴]	مدل بافت تعمیم‌یافته	مدل exemplar دسته‌بندی: دسته‌بندی بر اساس مجموع شباهت به نمونه‌های ذخیره‌شده.
Generalization criterion [۶]	معیار تعمیم	ارزیابی مدل‌ها با پیش‌بینی شرایط جدید (برون‌یابی) به‌جای trialهای جدید.
Gibbs sampling [۱۲]	نمونه‌گیری Gibbs	نوعی MCMC که هر پارامتر را با نمونه‌گیری از full conditionalش به‌روز می‌کند؛ همه‌ی نمونه‌ها پذیرفته می‌شوند.
Grid approximation [۹]	تقریب شبکه‌ای	محاسبه‌ی پسین روی شبکه‌ای از مقادیر پارامتر؛ برای ۱ تا ۲ پارامتر شدنی است.
Hamiltonian Monte Carlo (HMC) / NUTS [۱۳]	Hamiltonian Monte Carlo / NUTS	MCMC مبتنی بر گرادیان که با شبیه‌سازی دینامیک فیزیکی پیشنهادهای دور با احتمال پذیرش بالا می‌سازد؛ NUTS طول مسیر را خودکار تنظیم می‌کند.
observed Fisher / Hessian information [۵]	ماتریس Hessian / اطلاع فیشر مشاهده‌شده	ماتریس مشتق‌های دوم NLL در نقطه‌ی MLE؛ معکوسش تقریبی از کوواریانس برآوردهاست.
Hierarchical (multilevel) model [۱۳]	مدل سلسله‌مراتبی (چندسطحی)	مدلی که پارامترهای سطح فرد از توزیع‌های سطح گروه می‌آیند.
Identifiability (structural / practical) [۷]	identifiability (ساختاری / عملی)	آیا پارامترها به‌طور یکتا قابل تعیین‌اند؛ در اصل (ساختاری) یا با داده‌های موجود (عملی).
Ideal observer [۱۵]	مشاهده‌گر ایده‌آل	مدل استنباط بهینه با توجه به اطلاعات موجود؛ مثلاً ترکیب سرنخ‌ها با وزن‌دهی بر اساس قابلیت اطمینان.

اصطلاح (English)	معادل فارسی	تعریف
Inverse temperature (β) [۱۵]	inverse temperature	پارامتر softmax: حساسیت انتخاب‌ها به تفاوت ارزش‌ها (اکتشاف در برابر بهره‌برداری).
Inversion matrix (model recovery) [۷]	inversion matrix (بازیابی مدل)	P(مدل انتخاب‌شده ∣ مدل تولیدکننده): چقدر می‌توان به نتیجه‌ی انتخاب مدل اعتماد کرد.
Learning rate (α) [۱۵]	نرخ یادگیری	میزان تأثیر خطای پیش‌بینی بر به‌روزرسانی ارزش‌ها.
Likelihood (L)، log-likelihood (ℓ)، NLL [۴]	درست‌نمایی، لگاریتم درست‌نمایی، منفی لگاریتم درست‌نمایی	$p(\mathbf{y} \mid \boldsymbol{\theta})$ به‌عنوان تابعی از $\boldsymbol{\theta}$؛ لگاریتم آن؛ و منفی لگاریتم آن که بهینه‌سازها کمینه‌اش می‌کنند.
Likelihood-ratio test (LRT) [۷]	آزمون نسبت درست‌نمایی	برای مدل‌های nested، تحت مدل ساده‌تر $2\Delta\ell \sim \chi^2_{\Delta k}$.
Linking assumption [۲]	فرض پیوند	اینکه کمیت‌های مدل چگونه به رفتار قابل مشاهده نگاشت می‌شوند.
Local minimum [۳]	کمینه‌ی محلی	نقطه‌ای پایین‌تر از اطرافش ولی نه کمینه‌ی سراسری؛ بهینه‌سازی تک‌شروعی ممکن است در آن گیر کند. از multi-start استفاده کنید.
MAP [۹]	برآورد بیشینه‌ی پسین	مُد پسین؛ تحت پیشین تخت با MLE برابر است.
Markov chain Monte Carlo (MCMC) [۱۱]	مونت‌کارلوی زنجیره‌ی مارکوف	نمونه‌گیری از پسین با شبیه‌سازی یک زنجیره‌ی مارکوف که توزیع ایستایش همان پسین است.
Maximum likelihood estimate (MLE) [۴]	برآورد بیشینه درست‌نمایی	مقادیری از پارامترها که درست‌نمایی را بیشینه می‌کنند.
MCSE [۱۲]	خطای استاندارد مونت‌کارلو	$\sqrt{\mathrm{ESS}}$: انحراف معیار پسین تقسیم بر خطای شبیه‌سازی در میانگین پسین.
Metropolis / Metropolis–Hastings [۱۱]	Metropolis / Metropolis–Hastings	MCMC که یک حرکت پیشنهاد می‌دهد و آن را با احتمال (نسبت $\min(1, \cdot)$) می‌پذیرد؛ Hastings برای پیشنهادهای نامتقارن یک تصحیح اضافه می‌کند.
Model mimicry [۷]	تقلید مدل	وقتی یک مدل داده‌هایی تولید می‌کند که انگار مدل دیگری تولیدشان کرده است.
Model recovery [۷]	بازیابی مدل	شبیه‌سازی از هر مدل رقیب و بررسی اینکه آیا روش مقایسه، مدل تولیدکننده را انتخاب می‌کند.

اصطلاح (English)	معادل فارسی	تعریف
Monte Carlo integration [۱۱]	انتگرال‌گیری مونت‌کارلو	تقریب یک امید ریاضی با میانگین نمونه‌های تصادفی؛ خطا متناسب با $1/\sqrt{S}$.
Multi-start [۳]	چندشروعی	اجرای بهینه‌ساز از تعداد زیادی مقدار شروع و نگه‌داشتن بهترین نتیجه.
Nelder–Mead simplex [۳]	سیمپلکس Nelder–Mead	بهینه‌ساز بدون مشتق که یک سیمپلکس را با بازتاب، گسترش، انقباض و جمع‌شدن حرکت می‌دهد.
Nested models [۷]	مدل‌های nested	یکی حالت خاصی از دیگری است (با ثابت کردن برخی پارامترها).
Noise model [۲]	مدل نویز	توزیع مشاهدات حول پیش‌بینی قطعی (مثلاً دوجمله‌ای، گاوسی).
Non-decision time (T_{er} ،t_0) [۱، ۱۴]	non-decision time	بخشی از زمان واکنش که صرف انباشت شواهد نمی‌شود (رمزگذاری و اجرای حرکتی).
Overfitting [۶]	overfitting	برازش نویز یک نمونه، که برازش را بهتر و پیش‌بینی داده‌ی جدید را بدتر می‌کند.
Parameter recovery [۷]	بازیابی پارامتر	شبیه‌سازی داده از پارامترهای معلوم با همان طرح آزمایش واقعی و بررسی اینکه آیا برازش همان‌ها را برمی‌گرداند.
Parameter trade-off [۳، ۵]	trade-off پارامترها	تغییر یک پارامتر با پارامتر دیگری جبران می‌شود؛ به شکل دره‌ی مورب در سطح خطا و برآوردهای همبسته دیده می‌شود.
Posterior [۹]	پسین	$p(\boldsymbol{\theta} \mid \mathbf{y}) \propto p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})$.
Posterior predictive check (PPC) [۱۰]	بررسی پیش‌بینی پسین	مقایسه‌ی داده‌های شبیه‌سازی‌شده از مدل برازش‌شده با داده‌های مشاهده‌شده برای بررسی کفایت مدل.
exponential forgetting / Power [۲]	فراموشی توانی / نمایی	$A(1+t)^{-d}$ (نرخ نسبی فراموشی کاهشی) در برابر $Ae^{-\lambda t}$ (نرخ نسبی ثابت).
prior predictive check / Prior [۹]	پیشین / بررسی پیش‌بینی پیشین	توزیع پارامترها پیش از داده / شبیه‌سازی داده از پیشین برای اطمینان از منطقی بودن پیشین.
Profile likelihood [۵]	profile likelihood	NLL کمینه‌شده روی پارامترهای دیگر برای هر مقدار از پارامتر مورد نظر؛ بازه‌های نسبت درست‌نمایی را می‌دهد.
Prototype model [۱۴]	مدل پیش‌نمونه (prototype)	دسته‌بندی بر اساس شباهت به یک بازنمایی خلاصه برای هر دسته.

اصطلاح (English)	معادل فارسی	تعریف
R-hat ($\hat{R}$) [۱۲]	R-hat	نسبتی که واریانس بین زنجیره‌ها و درون زنجیره‌ها را مقایسه می‌کند؛ وقتی زنجیره‌ها هم‌خوان‌اند ≈ 1 (کمتر از ۱.۰۱).
Random walk model [۱]	مدل گام تصادفی	انباشت گسسته‌ی شواهد تا رسیدن به مرز؛ پیش‌درآمد DDM.
Relative loss rate (hazard) [۲]	نرخ نسبی فراموشی (hazard)	$-f'(t)/f(t)$: نرخ تناسبی فراموشی در زمان t.
Reparameterization [۳، ۱۳]	reparameterization	بهینه‌سازی یا نمونه‌گیری روی مقیاس تبدیل‌شده (مثلاً $\lambda = e^{\eta}$) برای اعمال قیدها یا بهبود هندسه.
RMSD [۳]	ریشه‌ی میانگین مربع انحراف	$\sqrt{\mathrm{SSE}/N}$، بر حسب واحد داده.
zROC / ROC [۲]	منحنی zROC / ROC	نرخ hit در برابر نرخ false alarm با تغییر ملاک / همین منحنی روی محورهای z (probit).
Saturated model [۴]	مدل اشباع‌شده	مدلی با یک پارامتر آزاد برای هر خانه‌ی داده که داده‌ها را دقیقاً بازتولید می‌کند.
Savage–Dickey density ratio [۱۰]	نسبت چگالی Savage–Dickey	برای مدل‌های nested، BF_{01} = چگالی پسین / چگالی پیشین در مقدار صفر (null).
Shrinkage [۱۳]	shrinkage	کشیده شدن برآوردهای فردی به سمت میانگین گروه در مدل‌های سلسله‌مراتبی؛ برای داده‌های پرنویزتر قوی‌تر است.
Signal detection theory (SDT) [۲]	نظریه‌ی تشخیص علامت	مدل تصمیم‌های تشخیص با شواهد پرنویز و یک ملاک؛ حساسیت را از سوگیری جدا می‌کند.
Softmax [۱۵]	softmax	$P(o) \propto \exp(\beta Q(o))$: ارزش‌ها را به احتمال انتخاب تبدیل می‌کند.
MSE / SSE [۳]	مجموع / میانگین مربعات خطا	مجموع یا میانگین مربع تفاوت‌های داده و پیش‌بینی.
Standard error [۵]	خطای استاندارد	انحراف معیار توزیع نمونه‌گیری یک برآوردگر.
Wald interval [۵]	بازه‌ی Wald	$\hat{\theta} \pm 1.96\,\mathrm{SE}$ با SE به‌دست‌آمده از Hessian؛ نرمال بودن تقریبی را فرض می‌کند.
Weighted least squares [۳]	کمترین مربعات وزنی	مربع خطاها با وزن معکوس واریانسشان.

۱۲.۳.۶ اصطلاحات هوش مصنوعی و LLM (از بخش‌های «ارتباط با هوش مصنوعی و LLMها»)

اصطلاح (English)	معادل فارسی	تعریف
Benchmark contamination [۶]	آلودگی benchmark	آیتم‌های آزمون (یا جواب‌هایشان) که در داده‌ی آموزشی مدل بوده‌اند؛ نوعی نشت داده که نمره را بیش از واقع نشان می‌دهد.
Bradley–Terry model [۱۵]	مدل Bradley–Terry	$P(i \succ j) = 1/(1+e^{-(r_i - r_j)})$: مدل انتخاب برای مقایسه‌های جفتی؛ برای مدل‌های پاداش RLHF استفاده می‌شود. هم‌ارز softmax دوگزینه‌ای با $\beta = 1$.
Cross-entropy loss [۴]	تابع زیان cross-entropy	تابع زیان آموزش مدل‌های زبانی: منفی لگاریتم درست‌نمایی token بعدی، میانگین‌گرفته روی tokenها.
Embedding [۱۴]	بردار embedding (بازنمایی برداری)	برداری که یک مدل به یک کلمه یا متن نسبت می‌دهد؛ فاصله‌ی embeddingها اغلب به جای شباهت استفاده می‌شود.
In-context learning [۷]	یادگیری درون‌بافتی	بهتر شدن یک LLM در یک تکلیف با مثال‌هایی که در prompt داده می‌شود، بدون تغییر پارامترهایش.
Large language model (LLM) [۱]	مدل بزرگ زبانی	یک شبکه‌ی عصبی (معمولاً transformer) که برای پیش‌بینی token بعدی در corpusهای متنی خیلی بزرگ آموزش دیده.
Perplexity [۴]	perplexity (سردرگمی)	$\exp(\text{NLL per token})$: تعداد مؤثر tokenهای بعدی هم‌احتمال؛ کمتر بهتر است.
RLHF [۱۵]	یادگیری تقویتی از بازخورد انسانی	یک مدل پاداش روی انتخاب‌های ترجیحی انسان برازش می‌شود، و بعد مدل زبانی برای بیشینه کردن آن پاداش آموزش می‌بیند.
Scaling law [۳]	قانون مقیاس	رابطه‌ای تجربی (معمولاً توانی) بین زیان مدل و اندازه‌ی مدل، اندازه‌ی داده یا محاسبات.
Self-consistency [۱۱]	self-consistency (خودسازگاری)	نمونه‌گیری چند جواب از یک مدل و گرفتن رأی اکثریت.

اصطلاح (English)	معادل فارسی	تعریف
Temperature [۱]	دما	logitها را پیش از softmax در یک LLM تقسیم می‌کند؛ دمای پایین خروجی تقریباً قطعی و دمای بالا خروجی تصادفی‌تر می‌دهد ($\beta = 1/T$).
Token [۱]	token	واحدی که مدل زبانی می‌خواند و پیش‌بینی می‌کند: یک کلمه یا بخشی از کلمه.

فهرست مطالعه

۱۳.۳.۶ منابع درس (طبق مشخصات درس)

منبع	نقش در درس	هفته‌ها
Lewandowsky, S. & Farrell, S., **(۲۰۱۸)**. *Computational modeling of cognition and behavior.* Cambridge University Press.	کتاب اصلی نیمه‌ی اول: از مدل کلامی به مدل فرمال، برآورد پارامتر، مقایسه‌ی مدل‌ها؛ همچنین برآورد بیزی، مدل‌های سلسله‌مراتبی و خانواده‌های مدل	۱–۱۰، ۱۲–۱۶
Wagenmakers, & Lee, M. D., **(۲۰۱۴)**. *Bayesian cognitive modeling: A practical course.* E.-J. Cambridge University Press.	کتاب اصلی نیمه‌ی دوم: استنباط بیزی، مقایسه‌ی مدل‌ها و مطالعات موردی (SDT)، نگهداری حافظه، (GCM	۲، ۴، ۷–۱۰، ۱۲–۱۴، ۱۶
Kruschke, J. K. **(۲۰۱۴)**. *Doing Bayesian data analysis: A tutorial with R, JAGS, and Stan* (2nd ed.). Academic Press.	مقدمه‌ای ساده و تصویری بر قاعده‌ی بیز، MCMC، تشخیص همگرایی، مدل‌های سلسله‌مراتبی و Bayes factor	۹–۱۳
Martin, O. A., Kumar, R., & Lao, J. **(۲۰۲۱)**. *Bayesian modeling and computation in Python.* CRC Press.	تمرین عملی با Python/PyMC/ArviZ: گردش کار بیزی، تشخیص همگرایی، PPC	۹–۱۳، ۱۶
Anderson, B. **(۲۰۱۴)**. *Computational neuroscience and cognitive modelling.* SAGE.	زمینه‌ای از علوم اعصاب محاسباتی؛ مدل‌های شبکه‌ی عصبی و یادگیری	۱، ۱۵
Verguts, T. **(۲۰۲۲)**. *Introduction to modeling cognitive processes.* MIT Press.	مقدمه‌ای قابل فهم بر مدل‌سازی؛ بهینه‌سازی و گرادیان نزولی؛ قاعده‌ی دلتا و یادگیری تقویتی؛ دسته‌بندی و تصمیم‌گیری	۱، ۳، ۱۴–۱۵
قدوسیان، ع. (۱۴۰۱). مبانی روش‌های مستقیم در بهینه‌سازی غیرخطی.	روش‌های جستجوی مستقیم در بهینه‌سازی غیرخطی (نظریه‌ی پشت Nelder–Mead)	۳

منبع	نقش در درس	هفته‌ها
عظیمی‌فر، ز. و احمدی، ا. (۱۳۹۶). شناسایی آماری الگو: یادگیری نظری مقدماتی، جلد ۱.	نگاه یادگیری آماری: برآورد ML و بیزی؛ تعمیم‌پذیری و trade-off سوگیری–واریانس	۴، ۶، ۹

۱۴.۳.۶ راهنمای فصل‌ها به تفکیک هفته

لطفاً بررسی کنید. شماره‌ی فصل‌های زیر از روی حافظه و بر اساس فهرست مطالب کتاب‌ها نوشته شده است. شماره‌های Lewandowsky & Farrell، Wagenmakers & Lee و Kruschke به احتمال زیاد درست‌اند ولی باید با نسخه‌های موجود در کتابخانه مقایسه شوند. برای Anderson، Verguts، قدوسیان و عظیمی‌فر و احمدی فقط موضوع آمده و شماره‌ی فصل‌ها با **[بررسی شود]** علامت خورده است.

هفته	منابع
۱	F&L فصل ۱–۲؛ Verguts، فصل مقدمه [بررسی شود]؛ Anderson، فصل مقدمه [بررسی شود]
۲	F&L فصل ۲؛ L&W فصل ۱۱ (پیش‌نمایش SDT) و فصل ۱۰ (نگهداری حافظه)
۳	F&L فصل ۳؛ قدوسیان (روش‌های جستجوی مستقیم) [بررسی شود]؛ Verguts (بهینه‌سازی/گرادیان نزولی) [بررسی شود]
۴	F&L فصل ۴؛ L&W فصل ۳؛ عظیمی‌فر و احمدی (برآورد ML) [بررسی شود]
۵	F&L فصل ۵ (و فصل ۴ درباره‌ی عدم قطعیت پارامترها)
۶	F&L فصل ۱۰؛ عظیمی‌فر و احمدی (تعمیم‌پذیری، سوگیری–واریانس) [بررسی شود]
۷	F&L فصل ۱۰؛ L&W فصل ۷ (مقدمه)
۸	مرور: F&L فصل ۲–۵ و ۱۰؛ L&W فصل ۱۱
۹	Kruschke فصل ۵–۶؛ L&W فصل ۱ و ۳؛ MKL فصل ۱؛ F&L فصل ۶؛ عظیمی‌فر و احمدی (برآورد بیزی) [بررسی شود]
۱۰	L&W فصل ۷؛ F&L فصل ۱۱؛ Kruschke فصل ۱۰؛ MKL فصل ۲
۱۱	Kruschke فصل ۷؛ F&L فصل ۷؛ MKL (MCMC و موتورهای استنباط) [بررسی شود]
۱۲	Kruschke فصل ۷؛ MKL فصل ۲؛ L&W فصل ۴
۱۳	L&W فصل ۱۱؛ Kruschke فصل ۹؛ F&L فصل ۹؛ MKL فصل ۲ و ۱۰

هفته	منابع
۱۴	L&W فصل ۱۷؛ F&L (زمان واکنش در انتخاب) [شماره‌ی فصل بررسی شود]؛ Verguts (دسته‌بندی، تصمیم‌گیری) [بررسی شود]
۱۵	Verguts (قاعده‌ی دلتا، یادگیری تقویتی) [بررسی شود]؛ F&L (شبکه‌های عصبی، علوم اعصاب) [بررسی شود]؛ Anderson (شبکه‌ها، یادگیری) [بررسی شود]
۱۶	F&L (استفاده از مدل‌ها در روان‌شناسی) [بررسی شود]؛ L&W بخش چهارم؛ MKL فصل ۹

اختصارها: F&L = Lewandowsky & Farrell؛ L&W = Wagenmakers & Lee؛ MKL = Lao. & Martin, Kumar

۱۵.۳.۶ منابع اختیاری خارج از فهرست درس

این منابع در هفته‌های مختلف برای دانشجویانی که مقاله‌های اصلی را می‌خواهند ذکر شده‌اند. همه آثار شناخته‌شده‌ای هستند؛ لطفاً پیش از توزیع، مشخصات را با سایت ناشر تطبیق دهید.

- Wang, Y.-M. & Busemeyer, J. R., (۲۰۰۰). Model comparisons and model selections based on generalization criterion methodology. *Journal of Mathematical Psychology,* ۴۴، ۱۷۱–۱۸۹. (هفته‌ی ۶)
- Banks, M. S. & Ernst, M. O., (۲۰۰۲). Humans integrate visual and haptic information in a statistically optimal fashion. *Nature,* ۴۱۵، ۴۲۹–۴۳۳. (هفته‌ی ۱۵)
- Mewhort, D. J. K. & Heathcote, A., Brown, S., (۲۰۰۰). The power law repealed: The case for an exponential law of practice. *Review, & Psychonomic Bulletin* ۷، ۱۸۵–۲۰۷. (هفته‌ی ۵)
- Marr, D. (۱۹۸۲). W. H. Freeman. *Vision.* (هفته‌ی ۱)
- Schaffer, M. M. & Medin, D. L., (۱۹۷۸). Context theory of classification learning. *Psychological Review,* ۸۵، ۲۰۷–۲۳۸. (هفته‌ی ۱۴)
- Pashler, H. & Roberts, S., (۲۰۰۰). How persuasive is a good fit? A comment on theory testing. *Psychological Review,* ۱۰۷، ۳۵۸–۳۶۷. (هفته‌ی ۶)
- Bürkner, P.-C. & Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., (۲۰۲۱). Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC. *Bayesian Analysis,* ۱۶، ۶۶۷–۷۱۸. (هفته‌ی ۱۲)
- Grasman, R. P. P. P. & Wagenmakers, E.-J., van der Maas, H. L. J., (۲۰۰۷). An EZ-diffusion model for response time and accuracy. *Review, & Psychonomic Bulletin* ۱۴، ۳–۲۲. (هفته‌ی ۱۴)
- Collins, A. G. E. & Wilson, R. C., (۲۰۱۹). Ten simple rules for the computational modeling of behavioral data. *eLife,* ۸، e49547. (هفته‌های ۷، ۱۵ و ۱۶)