مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۲: کالبدشکافی یک مدل: تشخیص علامت و منحنی‌های فراموشی

فهرست مطالب

۱ مبانی مدل‌سازی شناختی **۱**

۱.۱ هفته‌ی ۲: کالبدشکافی یک مدل: تشخیص علامت و منحنی‌های فراموشی ۱

۱.۱.۱ واژه‌های کلیدی ۱

۱.۱.۲ اهداف یادگیری ۲

۱.۱.۳ مقدمه ۳

۱.۱.۴ جزوه‌ی درس ۳

۱.۱.۵ مثال حل‌شده ۹

۱.۱.۶ lab (۲ ساعت) ۱۳

۱.۱.۷ ارتباط با هوش مصنوعی و LLMها ۱۸

۱.۱.۸ اشتباهات رایج و برداشت‌های نادرست ۱۹

۱.۱.۹ خودآزمایی ۱۹

۱.۱.۱۰ تکلیف ۲۰

۱.۱.۱۱ مطالعه‌ی بیشتر ۲۱

فصل ۱

مبانی مدل‌سازی شناختی

۱.۱ هفته‌ی ۲: کالبدشکافی یک مدل: تشخیص علامت و منحنی‌های فراموشی

فصل ۱: مبانی مدل‌سازی شناختی · درس ۱ ساعت · lab ۲ ساعت **مدل‌های اصلی این هفته:** نظریه‌ی تشخیص علامت گاوسی با واریانس برابر (SDT)؛ منحنی‌های فراموشی نمایی و توانی. هر دو در هفته‌های ۳ تا ۱۳ دوباره می‌آیند.

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
signal detection theory (SDT)	نظریه‌ی تشخیص علامت	مدلی که حساسیت را از سوگیری پاسخ جدا می‌کند
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
deterministic core	هسته‌ی قطعی	بخش بدون تصادف مدل که پیش‌بینی میانگین را می‌دهد
noise	نویز	تغییرات تصادفی در شواهد یا در داده
linking assumption	فرض پیوند	اینکه کمیت‌های مدل چطور به رفتار قابل مشاهده وصل می‌شوند
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز

English	فارسی	توضیح کوتاه
hit	اصابت (hit)	پاسخ «بله» وقتی علامت وجود دارد
response bias	سوگیری پاسخ	تمایل به یک پاسخ، مستقل از محرک
binomial distribution	توزیع دوجمله‌ای	توزیع تعداد موفقیت در n کوشش
noise model	مدل نویز	توزیع داده حول پیش‌بینی مدل
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
zROC curve / ROC	منحنی zROC / ROC	نرخ hit در برابر نرخ false alarm با تغییر ملاک
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
criterion (c)	ملاک	آستانه‌ی تصمیم؛ نشان‌دهنده‌ی سوگیری پاسخ
formalize / formal model	مدل فرمال / فرمال کردن	نوشتن نظریه به شکل معادله یا الگوریتم
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
false alarm	هشدار کاذب (false alarm)	پاسخ «بله» وقتی علامت وجود ندارد
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
correct rejection / miss	از دست دادن / رد درست	پاسخ «نه» با وجود علامت / پاسخ «نه» بدون علامت
conservative / liberal	آسان‌گیر / محافظه‌کار	تمایل به گفتن «بله» / «نه»
free parameter	پارامتر آزاد	پارامتری که از روی داده برآورد می‌شود
verbal theory	نظریه‌ی کلامی	نظریه‌ای که فقط با کلمات بیان شده و پیش‌بینی دقیق نمی‌دهد

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. یک مدل شناختی را به اجزایش **تجزیه کنند**: طرح آزمایش، پارامترهای آزاد و ثابت، هسته‌ی قطعی، مدل نویز (داده)، و فرض‌های پیوند (linking assumptions).
۲. d' و c را از یک جدول ۲×۲ شمارش‌ها **حساب کنند**، از جمله با تصحیح برای نرخ hit یا false alarm برابر ۰ یا ۱، و **توضیح دهند** چرا d' حساسیت را از سوگیری جدا می‌کند.
۳. مدل‌های فراموشی نمایی و توانی را با مدل نویز دوجمله‌ای **پیاده‌سازی کنند** و به‌طور کیفی **پیش‌بینی کنند** که هر پارامتر منحنی‌ها را چگونه تغییر می‌دهد.
۴. با شبیه‌سازی و نمودارهای تشخیصی (ROC/zROC)، نمودارهای نیمه‌لگاریتمی و لگاریتمی–لگاریتمی) **ارزیابی کنند** که آیا ردپای کیفی یک مدل در داده‌ها دیده می‌شود.
۵. پارامترهای برازش‌شده را به زبان روان‌شناختی **تفسیر کنند** و محدودیت‌های روش «برازش خط راست روی داده‌ی تبدیل‌شده» را **شناسایی کنند**.

۳.۱.۱ مقدمه

دو رادیولوژیست. رادیولوژیست R1 در ٪۹۳ از تصویرهایی که واقعاً تومور دارند تومور گزارش می‌کند، ولی در ٪۳۱ از تصویرهای سالم هم. رادیولوژیست R2 فقط ٪۶۹ از تومورها را گزارش می‌کند، ولی فقط در ٪۷ از تصویرهای سالم اشتباه می‌کند. درصد پاسخ درست هر دو یکسان است (٪۸۱). کدام تشخیص‌دهنده‌ی بهتری است؟

درصد پاسخ درست نمی‌تواند به این سؤال جواب دهد، چون دو چیز متفاوت را قاطی می‌کند: اینکه فرد **چقدر خوب** تومور را از بافت سالم تشخیص می‌دهد (حساسیت)، و اینکه **چقدر آمادگی** دارد بگوید «تومور هست» (سوگیری). نظریه‌ی تشخیص علامت یک مدل کوچک دوپارامتری است که این دو را از هم جدا می‌کند. همان‌طور که مثال حل‌شده نشان می‌دهد، R1 و R2 در واقع حساسیت **یکسانی** دارند؛ فقط ملاک‌شان را در جای متفاوتی گذاشته‌اند. این اولین ثمره‌ی مدل‌سازی است: پارامترهای مدل می‌توانند سازه‌های پنهانی را **اندازه بگیرند** که نمره‌های خام آن‌ها را قاطی می‌کنند.

منحنی ابینگهاوس. از زمان آزمایش‌هایی که ابینگهاوس در دهه‌ی ۱۸۸۰ روی خودش انجام داد می‌دانیم فراموشی اول سریع است و بعد کند می‌شود. «اول سریع، بعد کند» توصیفی کلامی است که هم تابع **نمایی** و هم تابع **توانی** با آن جور درمی‌آیند. ولی این دو معناهای متفاوتی دارند: نمایی یعنی یک خاطره در هر روز نسبت ثابتی از قدرتش را از دست می‌دهد، در هر سنی؛ توانی یعنی خاطره‌های قدیمی‌تر مقاوم‌تر می‌شوند. انتخاب بین این دو سؤالی درباره‌ی ماهیت حافظه است و به یک مدل فرمال نیاز دارد.

این موضوع کجا به کار می‌رود؟

- **تشخیص پزشکی.** رادیولوژیست‌ها، پاتولوژیست‌ها و برنامه‌های غربالگری با SDT و منحنی ROC ارزیابی می‌شوند تا پزشکی که «بهتر می‌بیند» از پزشکی که فقط بیشتر می‌گوید «غیرطبیعی است» جدا شود.
- **پژوهش حافظه.** در آزمون بازشناسی، کلمه‌های مطالعه‌شده «علامت» و کلمه‌های جدید «نویز» هستند. d' قدرت حافظه را جدا از تمایل به گفتن «قبلاً دیده‌ام» اندازه می‌گیرد.
- **شناسایی توسط شاهد عینی.** روش‌های مختلف صف شناسایی (line-up) در پلیس با تحلیل ROC مقایسه می‌شوند: بعضی روش‌ها دقت را بیشتر نمی‌کنند و فقط شاهد را محتاط‌تر می‌کنند.
- **آزمون‌های ادراک و شنوایی.** آستانه‌ی دیدن یا شنیدن محرک‌های ضعیف با SDT اندازه‌گیری می‌شود تا یک شنونده‌ی محتاط با کسی که کم‌شنواست اشتباه گرفته نشود.
- **یادگیری ماشین.** هر طبقه‌بند دودویی (فیلتر spam، آشکارساز تقلب، آشکارساز متن هوش مصنوعی) یک نرخ hit و یک نرخ false alarm دارد و با منحنی ROC و مساحت زیر آن (AUC) ارزیابی می‌شود. این همان نظریه است.
- **منحنی‌های فراموشی** برای زمان‌بندی یادگیری استفاده می‌شوند: اپلیکیشن‌های تکرار فاصله‌دار (مثلاً برای لغت) از روی مدلی از سرعت فراموشی تصمیم می‌گیرند کِی یک آیتم را دوباره نشان دهند.

۴.۱.۱ جزوه‌ی درس

به زبان ساده این هفته یک ایده‌ی اصلی دارد: هر مدل **اجزایی** دارد و هر جزء یک فرض جداست. دو مدل کوچک را می‌بینیم. **نظریه‌ی تشخیص علامت** (SDT) تصمیم‌های بله/نه در شرایط عدم قطعیت را توضیح می‌دهد. هر trial به مشاهده‌گر یک «حس وجود علامت» پرنویز می‌دهد. اگر این حس از یک آستانه‌ی شخصی قوی‌تر باشد، مشاهده‌گر می‌گوید «بله». دو عدد مشاهده‌گر را توصیف می‌کنند: حس «علامت هست» و «علامت نیست» به‌طور میانگین چقدر از هم فاصله دارند (**حساسیت**، d')، و آستانه کجاست (**ملاک**، c). دو نفر می‌توانند درصد پاسخ درست یکسانی داشته باشند به دلایل کاملاً متفاوت، و SDT نشان می‌دهد کدام دلیل. **منحنی فراموشی** نشان می‌دهد یادآوری با گذشت زمان چطور کم می‌شود. دو فرمول، نمایی و توانی، هر دو شکل «اول

سریع، بعد آهسته» دارند، ولی درباره‌ی حافظه حرف‌های متفاوتی می‌زنند. انتخاب بین آن‌ها از جنس سؤال‌هایی است که بقیه‌ی درس یاد می‌دهد با داده جواب دهیم.

واژه‌های آماری به زبان ساده

- **توزیع** (distribution): توصیف اینکه یک کمیت تصادفی چه مقدارهایی می‌گیرد و هرکدام چقدر رایج است. هیستوگرام تعداد زیادی اندازه‌گیری تقریبی از آن است.
- **توزیع نرمال (گاوسی)** $\mathcal{N}(\mu, \sigma)$: منحنی زنگوله‌ای با میانگین μ (مرکز) و انحراف معیار σ (پهنا). حدود ۶۸٪ مقدارها در $\mu \pm \sigma$ و ۹۵٪ در $\mu \pm 1.96\sigma$ قرار می‌گیرند.
- **نرمال استاندارد:** توزیع نرمال با $\mu = 0$ و $\sigma = 1$. مقداری که روی این مقیاس سنجیده شود z-score نام دارد: «چند انحراف معیار بالاتر از میانگین».
- $\Phi(x)$ **(تابع توزیع تجمعی یا** CDF**):** احتمال اینکه یک مقدار نرمال استاندارد کمتر از x باشد. $\Phi(0) = 0.5$، $\Phi(1) \approx 0.84$، $\Phi(1.96) \approx 0.975$. در Python: `norm.cdf(x)`.
- $\Phi^{-1}(p)$ **(معکوس** CDF**، «تبدیل** z**»):** سؤال برعکس: نسبت p از مقدارها زیر چه عددی هستند؟ $\Phi^{-1}(0.84) \approx 1$. در Python: `norm.ppf(p)`.
- **توزیع دوجمله‌ای** $\text{Binomial}(n, p)$**:** تعداد موفقیت‌ها در n تلاش مستقل که هرکدام با احتمال p موفق است (مثلاً تعداد کلمه‌های به‌یادآمده از ۵۰). میانگین آن np و واریانس آن $np(1-p)$ است.
- **نسبت در برابر احتمال:** نسبت چیزی است که مشاهده می‌کنیم (۳۰ از ۵۰ = ۰.۶۰)؛ احتمال مقدار زیربنایی مدل است که نسبت آن را برآورد می‌کند.

زمان‌بندی پیشنهادی (۶۰ دقیقه): کالبدشکافی مدل ۱۵ · SDT ۲۰ · منحنی‌های فراموشی ۱۵ · شبیه‌سازی به‌عنوان ابزار فکر کردن + پیش‌نمایش ۱۰.

۱. کالبدشکافی یک مدل

در هفته‌ی ۱ مدل را یک ماشین تولید داده نوشتیم، $\mathbf{y} \sim p(\mathbf{y} \mid \boldsymbol{\theta}, \mathcal{M})$. در عمل تقریباً هر مدلی که در این درس می‌بینید را می‌شود به پنج تکه تقسیم کرد:

جزء	سؤال	SDT	فراموشی (نمایی)
۱. طرح آزمایش x_i	چه چیزی دست‌کاری و اندازه‌گیری می‌شود؟	نوع trial (علامت/نویز)؛ پاسخ بله/نه	فاصله‌ی نگهداری t_i؛ تعداد آیتم‌های یادآوری‌شده از n آیتم
۲. پارامترها $\boldsymbol{\theta}$	چه چیزی آزاد است؟ چه چیزی ثابت؟	آزاد: d'، c. ثابت: هر دو انحراف معیار = ۱، میانگین نویز = ۰	آزاد: A، λ. ثابت: n
۳. هسته‌ی قطعی $f(x;\boldsymbol{\theta})$	مدل به‌طور میانگین چه پیش‌بینی می‌کند؟	$H = \Phi(d'/2 - c)$، $F = \Phi(-d'/2 - c)$	$f(t) = Ae^{-\lambda t}$
۴. مدل نویز	مشاهدات چگونه حول پیش‌بینی پراکنده می‌شوند؟	hitها $\sim \text{Binomial}(n_s, H)$؛ false alarmها $\sim \text{Binomial}(n_n, F)$	یادآوری‌شده‌ها $\sim \text{Binomial}(n, f(t))$
۵. فرض‌های پیوند	کمیت‌های مدل چگونه به رفتار نگاشت می‌شوند؟	اگر شواهد درونی از ملاک بیشتر باشد «بله»	احتمال یادآوری برابر قدرت حافظه $f(t)$ است

چند نکته درباره‌ی هر جزء:

- **پارامترهای آزاد در برابر ثابت.** پارامترهای ثابت «بی‌اهمیت» نیستند؛ آن‌ها فرض هستند. در هفته‌ی ۱، $t_0 = 300$ ms را ثابت گرفتیم. در SDT، ثابت گرفتن میانگین نویز روی ۰ و هر دو انحراف معیار روی ۱ است که اصلاً برآورد d' و c را ممکن می‌کند: جابه‌جا کردن یا کشیدن کل محور هیچ پیش‌بینی‌ای را عوض نمی‌کند. به چنین ثابت‌هایی **قیدهای مقیاس** (scaling constraints) می‌گویند.
- **دامنه‌ی پارامترها.** هر پارامتر دامنه‌ی معناداری دارد: $0 \le A \le 1$، $\lambda > 0$، و برای مشاهده‌گری که برعکس پاسخ نمی‌دهد $d' \ge 0$. رعایت این دامنه‌ها در برازش مهم است (هفته‌ی ۳).
- **مدل نویز جزئی از مدل است.** دو پژوهشگر با $f(t)$ یکسان ولی مدل نویز متفاوت (دوجمله‌ای در برابر گاوسی) مدل‌های متفاوتی دارند و برآوردهای پارامتر متفاوتی می‌گیرند (هفته‌ی ۴). توزیع دوجمله‌ای برای شمارش‌ها طبیعی است: واریانسش $f(1-f)/n$ در $f = 0.5$ بیشینه است و نزدیک ۰ و ۱ کم می‌شود.

۲. نظریه‌ی تشخیص علامت (SDT)

تکلیف آزمایشی. در هر trial محرک یا علامت است (مثلاً یک تومور، یک کلمه‌ی مطالعه‌شده، یک صدای ضعیف) یا نویز. مشاهده‌گر پاسخ «بله» (علامت) یا «نه» می‌دهد. نتیجه‌ها یک جدول ۲×۲ می‌سازند:

	پاسخ «بله»	پاسخ «نه»
trial **علامت**	hit	از دست دادن (miss)
trial **نویز**	false alarm (FA)	رد درست (correct rejection)، CR

با نرخ hit $H = \frac{\text{hits}}{\text{hits}+\text{misses}}$ و نرخ false alarm $F = \frac{\text{FAs}}{\text{FAs}+\text{CRs}}$.

مدل (شهودی). هر trial یک مقدار **شواهد** درونی تولید می‌کند. این مقدار پرنویز است: حتی trialهای نویز خالص هم گاهی شبیه علامت به نظر می‌رسند. trialهای علامت به‌طور میانگین شواهد بیشتری تولید می‌کنند. مشاهده‌گر هر وقت شواهد از یک **ملاک** (criterion) بیشتر باشد می‌گوید «بله».

مدل (فرمال)، SDT گاوسی با واریانس برابر:

$$\text{noise trials: } X \sim \mathcal{N}(0,1), \qquad \text{signal trials: } X \sim \mathcal{N}(d',1), \qquad \text{respond "yes" iff } X > k.$$

- d' **حساسیت** است: فاصله‌ی دو توزیع بر حسب واحد انحراف معیار.
- k محل مطلق ملاک است. راحت‌تر است ملاک را نسبت به نقطه‌ی میانی دو توزیع بسنجیم: $c = k - d'/2$. با $c = 0$ مشاهده‌گر بی‌سوگیری است، $c < 0$ یعنی liberal (راحت «بله» می‌گوید)، و $c > 0$ یعنی **محافظه‌کار** (conservative).

پیش‌بینی‌ها. با استفاده از CDF نرمال استاندارد Φ:

$$H = P(X > k \mid \text{signal}) = \Phi\left(\tfrac{d'}{2} - c\right), \qquad F = P(X > k \mid \text{noise}) = \Phi\left(-\tfrac{d'}{2} - c\right).$$

معکوس کردن مدل. با اعمال Φ^{-1} (که اغلب z نوشته می‌شود) روی هر دو معادله و حل آن‌ها، فرمول‌های آشنا به دست می‌آیند:

$$d' = \Phi^{-1}(H) - \Phi^{-1}(F), \qquad c = -\tfrac{1}{2}\left[\Phi^{-1}(H) + \Phi^{-1}(F)\right].$$

دقت کنید چه اتفاقی افتاد: این اولین **برآورد پارامتر** ماست. دو پارامتر آزاد و دو داده (H، F) داریم، پس مدل را می‌شود دقیقاً

حل کرد. وقتی تعداد داده‌ها از تعداد پارامترها بیشتر باشد، معمولاً جواب دقیق وجود ندارد و به روش‌های برازش هفته‌های ۳–۴ نیاز داریم.

مشکل نرخ‌های حدی. اگر $H = 1$ یا $F = 0$ باشد، Φ^{-1} برابر $\pm\infty$ و d' بی‌نهایت می‌شود. با تعداد trial کم این اتفاق زیاد می‌افتد. راه‌حل استاندارد **تصحیح** log-linear است: پیش از محاسبه‌ی نرخ‌ها به هر خانه‌ی جدول ۰.۵ اضافه کنید (یعنی ۰.۵ به hitها و false alarmها و ۱ به تعداد trialهای هر نوع). در lab به‌طور پیش‌فرض از آن استفاده می‌کنیم.

منحنی ROC: نشانه‌ی اصلی. SDT d' را ثابت نگه دارید و بگذارید c تغییر کند. جفت (F, H) یک منحنی رسم می‌کند به نام **منحنی مشخصه‌ی عملکرد گیرنده** (ROC). همه‌ی نقاط یک ROC حساسیت یکسان ولی سوگیری متفاوت دارند. رسم $\Phi^{-1}(H)$ در برابر $\Phi^{-1}(F)$ منحنی zROC را می‌دهد که در SDT با واریانس برابر یک خط راست است:

$$\Phi^{-1}(H) = d' + 1 \cdot \Phi^{-1}(F).$$

پس مدل یک پیش‌بینی قابل آزمون دارد: zROC **خطی با شیب ۱ است.** ROC را می‌شود با درجه‌بندی اطمینان (confidence ratings) اندازه گرفت (هر سطح اطمینان مثل یک ملاک جداگانه عمل می‌کند). در حافظه‌ی بازشناسی، شیب zROC معمولاً کمتر از ۱ است و همین انگیزه‌ی مدل با واریانس نابرابر در ادامه است.

> **پیشرفته: SDT با واریانس نابرابر.** اگر در trialهای علامت $X \sim \mathcal{N}(\mu_s, \sigma_s)$ باشد، zROC هنوز خطی است ولی شیبش $1/\sigma_s$ است. در این حالت d' که از یک جفت (H, F) حساب می‌شود با ملاک تغییر می‌کند، پس دیگر یک معیار خالص حساسیت نیست. یک شاخص جایگزین رایج $d_a = \mu_s \sqrt{2/(1+\sigma_s^2)}$ است. برآورد σ_s به بیش از یک ملاک، یعنی داده‌ی درجه‌بندی، نیاز دارد. این اثر را مستقیماً در بخش B lab می‌بینید.

خواندن ریاضی دو منحنی زنگوله‌ای. دو منحنی نرمال را روی یک محور بکشید: منحنی «نویز» با مرکز ۰ و منحنی «علامت» با مرکز d'. پهنای هر دو ۱ است. یک خط عمودی در محل ملاک k بکشید. هر چیزی سمت راست خط یعنی «بله».

- H = مساحت منحنی **علامت** در سمت راست خط. F = مساحت منحنی **نویز** در سمت راست خط.
- چرا $H = \Phi(d'/2 - c)$؟ ملاک در $k = d'/2 + c$ است (نقطه‌ی وسط به‌علاوه‌ی c). مرکز منحنی علامت d' است، پس خط به اندازه‌ی $k - d' = c - d'/2$ انحراف معیار از مرکز آن فاصله دارد. مساحت سمت راست این نقطه $1 - \Phi(c - d'/2) = \Phi(d'/2 - c)$ است، چون منحنی نرمال متقارن است.
- **مثال عددی.** $d' = 2$ و $c = 0$: $H = \Phi(1) = 0.84$ و $F = \Phi(-1) = 0.16$. حالا مشاهده‌گر را آسان‌گیر (liberal) کنید، $c = -0.5$: $H = \Phi(1.5) = 0.93$ و $F = \Phi(-0.5) = 0.31$. هر دو نرخ بالا رفتند و حساسیت تغییر نکرد. این همان رادیولوژیست R1 در مثال حل‌شده است.

معکوس کردن. $d' = \Phi^{-1}(H) - \Phi^{-1}(F)$: هر نرخ را به z-score تبدیل کنید و از هم کم کنید. برای R1: $1.476 - (-0.496) = 1.97$. c منفیِ میانگین دو z-score است: اگر هر دو نرخ بالا باشند (هر دو z-score مثبت)، c منفی است، یعنی آسان‌گیر.

خط zROC. $\Phi^{-1}(H) = d' + \Phi^{-1}(F)$ همان معادله‌ی قبلی است که مرتب شده. در واحد z، جابه‌جا کردن ملاک هر دو z-score را به یک اندازه تغییر می‌دهد، پس نقطه‌ها روی خطی با شیب ۱ و عرض از مبدأ d' قرار می‌گیرند.

برای یک مهندس SDT همان نظریه‌ی آشکارسازی رادار و مخابرات است که در دهه‌ی ۱۹۵۰ وارد روان‌شناسی شد.

	روان‌شناسی	مخابرات / رادار
علامت	trial نویز / trial	فرضیه‌ی H_0 (فقط نویز) / H_1 (سیگنال + نویز)
شواهد درونی	X	آماره‌ی آزمون، مثلاً خروجی فیلتر منطبق (matched filter)
ملاک	k (یا c)	آستانه‌ی آشکارسازی
نرخ hit یعنی	H	احتمال آشکارسازی P_D
نرخ false alarm یعنی	F	احتمال هشدار کاذب P_{FA}
حساسیت	d'	انحراف (deflection) $(\mu_1-\mu_0)/\sigma$؛ d'^2 نقش SNR را دارد
منحنی ROC		receiver operating characteristic (همان نام، همان نمودار)
مشاهده‌گر آسان‌گیر / محافظه‌کار		آستانه‌ی پایین / بالا (P_{FA} بالا / پایین)

تفاوت در تأکید: مهندس معمولاً آستانه را انتخاب می‌کند (مثلاً Neyman–Pearson: P_{FA} را ثابت کن و P_D را بیشینه کن). روان‌شناس P_D و P_{FA} یک آدم را مشاهده می‌کند و هم SNR (d') و هم آستانه‌ای (c) را که آن فرد به کار برده استنباط می‌کند. ملاک c از نقطه‌ی وسط دو میانگین سنجیده می‌شود، پس $c=0$ یعنی «بدون سوگیری». آستانه‌ی **بهینه** دقیقاً مثل آشکارسازی بیزی به احتمال‌های پیشین و هزینه‌ها بستگی دارد، و آدم‌ها وقتی پاداش‌ها تغییر می‌کنند معمولاً ملاکشان را در جهت درست جابه‌جا می‌کنند (هفته‌ی ۴).

۳. منحنی‌های فراموشی

داده. در هر فاصله‌ی نگهداری t_i (مثلاً به روز)، شرکت‌کننده با n آیتم آزمون می‌شود و y_i تا را به یاد می‌آورد.

دو هسته‌ی قطعی رقیب:

	نمایی	توانی
معادله	$f(t)=A\,e^{-\lambda t}$	$f(t)=A\,(1+t)^{-d}$
پارامترها	A: سطح اولیه؛ λ: نرخ زوال	A: سطح اولیه؛ d: نمای زوال
نمودار خطی‌کننده	$\ln f$ در برابر t خطی راست با شیب $-\lambda$ است	$\ln f$ در برابر $\ln(1+t)$ خطی راست با شیب $-d$ است
نرخ نسبی فراموشی $-f'(t)/f(t)$	λ (ثابت)	$d/(1+t)$ (با گذشت زمان کاهشی)
خوانش روان‌شناختی	خاطره در هر واحد زمان نسبت یکسانی از قدرتش را از دست می‌دهد، هر سنی که داشته باشد	خاطره‌های قدیمی‌تر کندتر قدرت از دست می‌دهند؛ مقاوم‌تر می‌شوند

نرخ نسبی فراموشی (که در تحلیل بقا به آن *hazard* می‌گویند) تفاوت کلیدی در تفسیر است. به همین دلیل انتخاب بین این دو تابع یک سؤال نظری است، نه یک جزئیات منحنی‌برازی.

مدل نویز. تعداد یادآوری‌ها دوجمله‌ای است:

$$y_i \sim \mathrm{Binomial}\big(n, f(t_i;\boldsymbol{\theta})\big).$$

با $n=50$ آیتم و $f=0.5$، انحراف معیار نسبت مشاهده‌شده $\sqrt{0.5\cdot 0.5/50}\approx 0.07$ است. این در مقایسه با تفاوت مدل‌ها

در فاصله‌های کوتاه بزرگ است؛ اولین نشانه‌ی اینکه **طرح آزمایش** (کدام فاصله‌ها، چند آیتم) تعیین می‌کند داده‌ها می‌توانند بین مدل‌ها تمایز بگذارند یا نه.

> **پیشرفته: «+۱» در مدل توانی بی‌خطر نیست.** $A\,t^{-d}$ در $t=0$ بی‌نهایت است، پس یک جابه‌جایی اضافه می‌شود. ولی $(1+t)$ به **واحد** t بستگی دارد: اندازه‌گیری به ساعت به‌جای روز، شکل منحنی را عوض می‌کند، نه فقط مقیاس محور را. به همین دلیل بعضی نویسندگان $A\,(1+bt)^{-d}$ را با پارامتر مقیاس آزاد b می‌نویسند؛ این یک پارامتر سوم اضافه می‌کند و سؤال‌های مقایسه‌ی مدل هفته‌های ۶–۷ را پیش می‌آورد. در طول این درس واحد را ثابت (روز) نگه دارید.

خواندن ریاضی

- $f(t)=Ae^{-\lambda t}$: A میزان یادآوری درست بعد از مطالعه ($t=0$) است و λ می‌گوید با چه سرعتی کم می‌شود. با $\lambda=0.1$ در روز، یادآوری هر روز در $e^{-0.1}\approx 0.905$ ضرب می‌شود: هر روز حدود ۹۵٪ از آنچه مانده از دست می‌رود، چه روز اول و چه روز صدم.
- $f(t)=A(1+t)^{-d}$: رفتن از روز ۰ به روز ۱ یادآوری را در 2^{-d} ضرب می‌کند؛ رفتن از روز ۹ به روز ۱۰ فقط در $(10/11)^d$ که نزدیک ۱ است. خاطره‌های قدیمی دیگر تقریباً تغییر نمی‌کنند.
- **نرخ نسبی فراموشی** $-f'(t)/f(t)$: «چه کسری از حافظه‌ی باقی‌مانده همین الان در هر روز از دست می‌رود». برای تابع نمایی ثابت است (λ) و برای تابع توانی کم می‌شود ($d/(1+t)$). همین یک عدد، تفاوت روان‌شناختی دو مدل است.
- $y_i \sim \text{Binomial}(n, f(t_i))$: در تأخیر t_i، شرکت‌کننده y_i آیتم از n آیتم را به یاد می‌آورد و هر آیتم با احتمال $f(t_i)$ به یاد آورده می‌شود. نسبت مشاهده‌شده‌ی y_i/n با انحراف معیار $\sqrt{f(1-f)/n}$ حول $f(t_i)$ پراکنده است؛ برای $n=50$ حدود ۰.۰۷.

برای یک مهندس

- منحنی **نمایی** همان پاسخ پله‌ی یک سیستم مرتبه‌ی اول است (دشارژ یک مدار RC): یک ثابت زمانی $\tau = 1/\lambda$. ثابت بودن نرخ نسبی فراموشی همان ویژگی «بی‌حافظگی» است که از طول عمر نمایی در نظریه‌ی قابلیت اطمینان می‌شناسید.
- منحنی **توانی** یک ثابت زمانی واحد ندارد. تصویر مفید: جمع تعداد زیادی منحنی نمایی با ثابت‌های زمانی متفاوت (مؤلفه‌های سریع و کند) شبیه یک قانون توانی می‌شود. هفته‌ی ۵ این را دقیقاً نشان می‌دهد و این یکی از توضیح‌های ممکن برای فراموشی توانی است.
- روی نمودار **لگاریتمی–لگاریتمی** قانون توانی یک خط راست است؛ روی نمودار **نیمه‌لگاریتمی** تابع نمایی خط راست است. مهندس‌ها از همین ترفند برای تشخیص مرتبه‌ی سیستم و نویز $1/f$ استفاده می‌کنند.
- مدل نویز دوجمله‌ای همان آمار شمارش یک آشکارساز است: مثل شمردن خطاهای بیتی از n بیت، عدم قطعیت یک نسبت با $1/\sqrt{n}$ کم می‌شود.

۴. شبیه‌سازی به‌عنوان ابزار فکر کردن

پیش از برازش هر چیزی، شبیه‌سازی کنید. شبیه‌سازی به سؤال‌هایی مثل این‌ها جواب می‌دهد:

- **مدل چه چیزی را می‌تواند تولید کند، و چه چیزی را نمی‌تواند؟** SDT با واریانس برابر و $d'>0$ هرگز نمی‌تواند $H<F$ تولید کند، و هرگز شیب zROC غیر از ۱ نمی‌دهد. منحنی‌های نمایی و توانی هر دو همیشه نزولی‌اند، پس نمی‌توانند بازیادآوری (reminiscence)، بهتر شدن یادآوری با گذشت زمان) را نشان دهند. مجموعه‌ی کارهایی که یک مدل **نمی‌تواند** انجام دهد همان چیزی است که آن را قابل آزمون می‌کند.
- **کدام پارامتر کجا اهمیت دارد؟** A کل منحنی فراموشی را جابه‌جا می‌کند؛ λ یا d شکل را کنترل می‌کند.

- **آیا طرح آزمایش می‌تواند بین مدل‌ها تمایز بگذارد؟** اگر دو مدل در فاصله‌هایی که می‌خواهیم آزمون کنیم پیش‌بینی‌های تقریباً یکسانی بدهند، هیچ روش برازشی نمی‌تواند آن‌ها را از هم جدا کند (تمرین lab ۴؛ تکلیف A1).

۵. پیش‌نمایش: برآورد با خطی‌سازی، و چرا کافی نیست

یک روش سنتی برای برازش منحنی فراموشی این است که از نسبت‌های مشاهده‌شده لگاریتم بگیریم و با رگرسیون معمولی یک خط راست برازش کنیم. سریع و شهودی است و در lab امتحانش می‌کنیم. سه مشکل دارد که انگیزه‌ی هفته‌های ۳–۴ است:

۱. $\ln(0)$ تعریف‌نشده است، پس فاصله‌ای با یادآوری صفر روش را از کار می‌اندازد.
۲. تبدیل لگاریتمی نویز را تحریف می‌کند: پراکندگی $\ln \hat{p}$ برای نسبت‌های کوچک خیلی بیشتر است، ولی رگرسیون با همه‌ی نقاط مثل هم رفتار می‌کند.
۳. خط روی مقیاس لگاریتمی برازش می‌شود، ولی ما به خطا روی مقیاس اصلی (نسبت) اهمیت می‌دهیم.

جایگزین اصولی این است که مدل را مستقیماً روی داده‌ی تبدیل‌نشده برازش کنیم: با کمینه کردن مربع خطا (هفته‌ی ۳) یا بیشینه کردن درست‌نمایی دوجمله‌ای (هفته‌ی ۴).

برای مدرس

- **با معمای رادیولوژیست‌ها شروع کنید** (بخش مقدمه) و پیش از نشان دادن هر فرمولی، بگذارید دانشجوها رأی بدهند کدام بهتر است. بیشترشان بر اساس درصد پاسخ درست انتخاب می‌کنند و بعد می‌فهمند که دو عدد یکسان است.
- **رسم کنید، اثبات نکنید.** دو منحنی زنگوله‌ای هم‌پوشان با یک خط عمودی متحرک، H، F، d' و c را بهتر از هر فرمولی توضیح می‌دهند. خط را روی تخته به چپ و راست ببرید و بپرسید H و F چه می‌شوند؛ بعد منحنی‌ها را از هم دور کنید و دوباره بپرسید.
- **از جدول Φ یا Python به‌طور زنده استفاده کنید.** d' رادیولوژیست R1 را جلوی کلاس با `norm.ppf` حساب کنید. دانشجوهایی که آمار برایشان تازه است باید ببینند Φ^{-1} «فقط یک جدول‌خوانی» است.
- **به چیزی که می‌شناسند وصل کنید:** یک تست کرونا یا بارداری نرخ hit (sensitivity) و نرخ false alarm (یک منهای specificity) دارد. «sensitivity» در پزشکی همان نرخ hit است، نه d': به این تشابه اسمی اشاره کنید.
- **سؤال‌های رایج.**
  - «چرا توزیع نرمال فرض می‌کنیم؟» فرضی راحت و اغلب کافی است؛ آزمون zROC (شیب ۱) آن را بررسی می‌کند و مدل واریانس نابرابر آن را آزادتر می‌کند.
  - «آیا ملاک آسان‌گیر بد است؟» نه؛ بهترین ملاک به هزینه‌ها و نرخ‌های پایه بستگی دارد.
  - «نمایی یا توانی، کدام درست است؟» در بسیاری از داده‌ها تابع توانی بهتر برازش می‌شود، ولی میانگین‌گیری روی افراد می‌تواند شکل توانی بسازد (هفته‌ی ۵). سؤال را باز نگه دارید.

۵.۱.۱ مثال حل‌شده

بخش ۱: دو رادیولوژیست (و یک سومی)

هر رادیولوژیست ۱۰۰ تصویر با تومور و ۱۰۰ تصویر سالم را می‌خواند.

مشاهده‌گر	H	F	$\Phi^{-1}(H)$	$\Phi^{-1}(F)$	d'	c	درصد درست
R0 (خنثی)	۸۴.۰	۱۶.۰	۹۹۴.۰	۹۹.۱	۰۰.۰	۸۴٪	
R1 (liberal)	۹۳.۰	۳۱.۰	۴۷۶.۱	۹۷.۱	۴۹.۰	۸۱٪	
R2 (محافظه‌کار)	۶۹.۰	۰۷.۰	۴۹۶.۰	۹۷.۱	۴۹.۰	۸۱٪	

قدم‌به‌قدم برای R1: ۱. $\Phi^{-1}(0.93) = 1.476$ و $\Phi^{-1}(0.31) = -0.496$ (`scipy.stats.norm.ppf`). ۲. $d' = 1.476 - (-0.496) = 1.972$. ۳. $c = -\frac{1}{2}(1.476 + (-0.496)) = -0.490$، که منفی است، پس R1 liberal است. ۴. بررسی با جای‌گذاری: $H = \Phi(1.972/2 + 0.490) = \Phi(1.476) = 0.93$ ✓

تفسیر. هر سه رادیولوژیست در عمل حساسیت یکسانی دارند ($d' \approx 2$). R1 و R2 درصد درست یکسان ولی سوگیری مخالف دارند. اینکه کدام سوگیری بهتر است سؤالی درباره‌ی ادراک نیست، بلکه درباره‌ی هزینه‌هاست: از دست دادن یک تومور معمولاً خیلی بدتر از یک false alarm است، پس شاید ملاک liberal همان ملاک مطلوب باشد. SDT به ما اجازه می‌دهد «آیا می‌بینند؟» و «چقدر آماده‌اند بگویند؟» را جداگانه بپرسیم.

تصحیح نرخ حدی. یک شرکت‌کننده ۵۰/۵۰ hit و ۳/۵۰ false alarm دارد. پس $H = 1$ و $d' = \infty$. با تصحیح log-linear: $H = 50.5/51 = 0.990$، $F = 3.5/51 = 0.069$، پس $d' = 2.33 - (-1.49) = 3.82$.

بخش ۲: فراموشی نمایی در برابر توانی

برای هر دو مدل $A = 0.95$ بگیرید، برای مدل نمایی $\lambda = 0.25$ در روز و برای مدل توانی $d = 0.6$.

t (روز)	۰	۱	۲	۷	۱۴	۳۰
نمایی $0.95\,e^{-0.25t}$	۹۵۰.۰	۷۴۰.۰	۵۷۶.۰	۱۶۵.۰	۰۲۹.۰	۰۰۱.۰
توانی $0.95\,(1+t)^{-0.6}$	۹۵۰.۰	۶۲۷.۰	۴۹۱.۰	۲۷۳.۰	۱۸۷.۰	۱۲۱.۰

نیمه‌عمر (زمانی که یادآوری به نصف سطح اولیه می‌رسد): - نمایی: $e^{-\lambda t} = 1/2 \Rightarrow t_{1/2} = \ln 2/\lambda = 0.693/0.25 =$ 2.77 روز. - توانی: $(1+t)^{-d} = 1/2 \Rightarrow t_{1/2} = 2^{1/d} - 1 = 2^{1.667} - 1 = 2.17$ روز.

تفسیر. در دو روز اول منحنی‌ها نسبتاً شبیه‌اند: حدود ۱.۰ با هم فرق دارند که با $n = 50$ آیتم فقط حدود ۵.۱ انحراف معیار دوجمله‌ای است. بعد از یک ماه کاملاً با هم اختلاف دارند: مدل نمایی می‌گوید تقریباً همه چیز فراموش شده (۰٪.۱)، در حالی که مدل توانی می‌گوید ۱۲٪ هنوز باقی است. **فاصله‌های نگهداری طولانی جایی است که این مدل‌ها از هم تشخیص داده می‌شوند؛** درسی درباره‌ی طراحی آزمایش که در تکلیف A1 از آن استفاده می‌کنید.

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. پیاده‌سازی SDT به‌عنوان یک مدل مولد (generative)، شبیه‌سازی آزمایش‌های بله/نه، و برآورد d' و c.
۲. استفاده از نمودارهای ROC و zROC برای **ارزیابی** فرض واریانس برابر.
۳. پیاده‌سازی فراموشی نمایی و توانی با نویز دوجمله‌ای و بررسی پارامترهایشان.
۴. **برازش** هر دو مدل فراموشی با خطی‌سازی، **ارزیابی** آن‌ها با باقی‌مانده‌ها (residuals)، و **تفسیر** نتیجه.

زمان‌بندی: بخش A ۳۰ دقیقه · بخش B ۲۵ دقیقه · بخش C ۳۰ دقیقه · بخش D ۲۵ دقیقه · زمان باقی‌مانده: تمرین‌ها.

آماده‌سازی

Code · **کد:** `code/week02.py`، cell ۱ · سلول ۱

بخش A: SDT به‌عنوان یک مدل مولد (۳۰ دقیقه)

Code · **کد:** `code/week02.py`، cell ۲ · سلول ۲

یک شرکت‌کننده را شبیه‌سازی کنید و پارامترها را بازیابی کنید:

Code · **کد:** `code/week02.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
Counts: {'hits': 68, 'misses': 32, 'fas': 11, 'crs': 89}
Predicted H = 0.674, F = 0.147
Estimated d' = 1.67 (true 1.5),  c = 0.37 (true 0.3)
```

یک شرکت‌کننده‌ی شبیه‌سازی‌شده چیز زیادی درباره‌ی کیفیت برآوردگر نمی‌گوید. آزمایش را چندین بار تکرار کنیم: این پیش‌نمایشی از منطق **بازیابی پارامتر** در هفته‌ی ۷ است.

کد: Code · سلول ۴ · cell ۴، `code/week02.py`

خروجی مورد انتظار:

```
            d_hat          c_hat
             mean    std   mean    std
n_per_type
20          1.500  0.449  0.296  0.224
50          1.489  0.290  0.295  0.143
200         1.502  0.142  0.299  0.071
```

به این دقت کنید: برآوردها حول مقادیر واقعی پراکنده‌اند و پراکندگی با افزایش تعداد trialها کم می‌شود. با ۲۰ trial از هر نوع، انحراف معیار $\hat{d}'$ حدود ۴۵.۰ است، پس برآوردهای تکی اغلب $\pm$۵.۰ یا بیشتر خطا دارند، و برای نصف کردن پراکندگی تقریباً ۴ برابر trial لازم است. اینجا به‌طور میانگین برآوردها درست سر هدف‌اند. ولی با d' بالاتر و trialهای کم، نرخ‌های حدی رایج می‌شوند و آن‌وقت تصحیح، برآوردها را به سمت ۰ می‌کشد (`true_d=3` را با ۲۰ trial امتحان کنید). هر وقت d' گروه‌هایی را مقایسه می‌کنید که با تعداد trial متفاوت آزمون شده‌اند، این را در نظر داشته باشید.

بخش B: منحنی‌های ROC و فرض واریانس برابر (۲۵ دقیقه)

اول، ROCهای پیش‌بینی‌شده‌ی مدل:

کد: Code · سلول ۵ · cell ۵، `code/week02.py`

حالا یک آزمایش **درجه‌بندی اطمینان** را شبیه‌سازی کنید. پاسخ‌ها روی یک مقیاس ۶ درجه‌ای داده می‌شوند (۱ = «مطمئنم نویز است» . . . ۶ = «مطمئنم علامت است») که معادل پنج ملاک هم‌زمان است. داده‌ها را از یک مشاهده‌گر با واریانس برابر و از یک مشاهده‌گر با **واریانس نابرابر** که توزیع علامتش انحراف معیار ۵.۱ دارد تولید می‌کنیم.

کد: Code · سلول ۶ · cell ۶، `code/week02.py`

خروجی مورد انتظار:

```
sigma_signal = 1.0: zROC slope = 0.96 (predicted 1.00); d' at each
↪  criterion = [1.52 1.48 1.48 1.43 1.43]
sigma_signal = 1.5: zROC slope = 0.67 (predicted 0.67); d' at each
↪  criterion = [1.46 1.34 1.16 0.96 0.84]
```

ارزیابی و تفسیر. برای مشاهده‌گر با واریانس برابر، شیب zROC نزدیک ۱ است و d' در همه‌ی ملاک‌ها تقریباً یکسان است: فرض مدل برقرار است. برای مشاهده‌گر با واریانس نابرابر، شیب نزدیک $1/1.5 = 0.67$ است و d' **به‌طور نظام‌مند با ملاک تغییر می‌کند.** اگر از چنین مشاهده‌گری فقط داده‌ی بله/نه جمع کرده بودیم، تفاوت گروه‌ها در «d'» می‌توانست صرفاً از تفاوت در سوگیری بیاید. بررسی پیش‌بینی امضایی یک مدل (اینجا: شیب zROC ≈ ۱) شکل پایه‌ای از **ارزیابی مدل** است.

بخش C: منحنی‌های فراموشی با نویز دوجمله‌ای (۳۰ دقیقه)

Code · **کد:** `code/week02.py`، cell ۷ · سلول ۷

پارامترها را بررسی کنید: A و پارامتر زوال هر منحنی را چگونه تغییر می‌دهند؟

Code · **کد:** `code/week02.py`، cell ۸ · سلول ۸

حالا یک **آزمایش شبیه‌سازی‌شده** بسازید. داده‌ها از مدل توانی می‌آیند، با ۵۰ آیتم که در هر یک از ۸ فاصله‌ی نگهداری آزمون می‌شوند:

Code · **کد:** `code/week02.py`، cell ۹ · سلول ۹

خروجی مورد انتظار:

```
       t  recalled   n  p_obs
0   0.25        42  50   0.84
1   1.00        30  50   0.60
2   2.00        26  50   0.52
3   4.00        25  50   0.50
4   7.00        13  50   0.26
5  14.00        13  50   0.26
6  21.00        13  50   0.26
7  30.00        14  50   0.28
```

بخش D: برازش با خطی‌سازی، ارزیابی، تفسیر (۲۵ دقیقه)

برازش. هر مدل را با رگرسیون خط راست روی مقیاس لگاریتمی برازش کنید (بخش ۵ جزوه).

Code · **کد:** `code/week02.py`، cell ۱۰ · سلول ۱۰

ارزیابی. به منحنی‌های برازش‌شده و باقی‌مانده‌ها نگاه کنید. یک مدل خوب باقی‌مانده‌هایی به جا می‌گذارد که به‌طور تصادفی حول صفر پراکنده‌اند؛ یک الگوی نظام‌مند یعنی شکل مدل غلط است.

Code · **کد:** `code/week02.py`، cell ۱۱ · سلول ۱۱

خروجی مورد انتظار:

```
exp: A = 0.550, rate = 0.032, RMSD = 0.1308
pow: A = 0.797, rate = 0.370, RMSD = 0.0628
true (power): A = 0.9, d = 0.5
```

تفسیر (برای هرکدام ۲ تا ۳ جمله در notebook بنویسید):

۱. کدام مدل داده‌ها را بهتر توصیف می‌کند، و الگوی باقی‌مانده‌های مدل دیگر چه شکلی دارد؟ (دنبال شکل U یا U وارونه بگردید: مدل نمایی در فاصله‌های میانی بیش‌برآورد و در فاصله‌های طولانی کم‌برآورد می‌کند، یا برعکس.)
۲. با پارامترهای برازش‌شده، نرخ نسبی فراموشی هر مدل بعد از ۱ روز و بعد از ۲۰ روز چقدر است؟ این برای حافظه چه معنایی دارد؟
۳. اینجا مدل توانی مدل واقعی است، ولی برآوردهایش ($\hat{A} \approx 0.80$، $\hat{d} \approx 0.37$) آشکارا با مقادیر واقعی ($A^* = 0.9$، $d^* = 0.5$) فاصله دارند. دو دلیل نام ببرید. (راهنمایی: به سه نقطه‌ی آخر نگاه کنید؛ فکر کنید تبدیل لگاریتمی با وزن نسبت‌های کوچک چه می‌کند.) در هفته‌ی ۳ همین داده‌ها را روی مقیاس اصلی دوباره برازش و مقایسه می‌کنیم.

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆ (نرخ‌های حدی). یک شرکت‌کننده ۴۰/۴۰ hit و ۰/۴۰ false alarm دارد. d' را بدون تصحیح و با تصحیح log-linear حساب کنید. d' تصحیح‌شده نماینده‌ی چیست، و چرا باید تصحیحی را که استفاده کرده‌اید گزارش کنید؟

تمرین ۲ ⋆ (نیمه‌عمرها). با پارامترهای برازش‌شده از بخش D، نیمه‌عمر هر مدل را حساب کنید. بعد حساب کنید چقدر طول می‌کشد تا یادآوری به ۱۰٪ سطح اولیه برسد. مدل‌ها کجا بیشترین اختلاف را دارند؟

تمرین ۳ ⋆⋆ (داده‌های ابینگهاوس). داده‌های کلاسیک savings از آزمایش‌های ابینگهاوس روی خودش در ۱۸۸۵ اغلب این‌طور گزارش می‌شوند [پیش از استفاده در کلاس با منبع اصلی تطبیق داده شود]:

	فاصله	۲۰ دقیقه	۱ ساعت	۸.۸ ساعت	۱ روز	۲ روز	۶ روز	۳۱ روز
Savings (٪)	۲.۵۸	۲.۴۴	۸.۳۵	۷.۳۳	۸.۲۷	۴.۲۵	۱.۲۱	

فاصله‌ها را به روز تبدیل کنید، هر دو مدل را با خطی‌سازی برازش کنید و باقی‌مانده‌هایشان را مقایسه کنید. کدام شکل بهتر برازش می‌شود؟ بعد تحلیل را با زمان بر حسب **ساعت** تکرار کنید. آیا برازش توانی تغییر می‌کند؟ با استفاده از کادر «پیشرفته» در بخش ۳ جزوه توضیح دهید.

تمرین ۴ ⋆⋆ (کدام طرح آزمایش مدل‌ها را از هم جدا می‌کند؟). (A, λ) و (A, d) را طوری انتخاب کنید که دو مدل در $t = 1$ و $t = 7$ روز یادآوری یکسانی پیش‌بینی کنند. (راهنمایی: برای هر مدل دو معادله و دو مجهول؛ لگاریتم بگیرید.) بعد هر دو منحنی را از $t = 0$ تا 60 روز رسم کنید و جاهایی را که اختلافشان با $n = 50$ از ۲ انحراف معیار دوجمله‌ای بیشتر است علامت بزنید. کدام فاصله‌های نگهداری را آزمون می‌کردید؟

تمرین ۵ ⋆⋆⋆ (پیشرفته: شمارش صفر). از مدل نمایی با $A = 0.9$، $\lambda = 0.3$ در فاصله‌های بخش C و با $n = 20$ آیتم داده تولید کنید. چند بار (از ۱۰۰۰ مجموعه‌داده‌ی شبیه‌سازی‌شده) دست‌کم یک فاصله یادآوری صفر دارد که `fit_linearized` را از کار می‌اندازد؟ یک راه‌حل سریع (مثلاً افزودن ۰.۵ به شمارش‌ها) پیشنهاد و پیاده‌سازی کنید و بررسی کنید آیا برآورد λ را سوگیر می‌کند. توضیح دهید چرا این نشان می‌دهد به روشی نیاز داریم که روی مقیاس اصلی کار کند (هفته‌های ۳–۴).

lab check-off

به مدرس یا دستیار آموزشی نشان دهید: (۱) جدول بازیابی SDT از بخش A، (۲) دو zROC تجربی با شیب‌هایشان از بخش B، و (۳) نمودار باقی‌مانده‌ها از بخش D با یک جمله تفسیر.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

آشکارسازهای متن هوش مصنوعی، مشاهده‌گرهایی در یک تکلیف SDT هستند. دانشگاه‌ها روزبه‌روز بیشتر از ابزارهایی استفاده می‌کنند که به یک متن امتیاز «چقدر محتمل است که هوش مصنوعی نوشته باشد» می‌دهند. هر متن یا با هوش مصنوعی نوشته شده («علامت») یا با انسان («نویز»)، و ابزار وقتی امتیاز از یک آستانه بیشتر شود می‌گوید «هوش مصنوعی». این دقیقاً موقعیت SDT این هفته است: ابزار یک **حساسیت** d' دارد (امتیاز چقدر خوب دو نوع متن را از هم جدا می‌کند) و یک **ملاک** c (آستانه‌ای که کاربر انتخاب می‌کند). یک false alarm یعنی دانشجویی به‌اشتباه متهم شود، پس انتخاب ملاک یک تصمیم اخلاقی است، نه فقط فنی.

Code · **کد:** `code/week02.py`، cell ۱۲ · سلول ۱۲

خروجی مورد انتظار:

```
threshold 0.0: H = 0.84, F = 0.49, d' = 1.03, c = -0.50
threshold 0.6: H = 0.70, F = 0.28, d' = 1.11, c = 0.03
threshold 1.2: H = 0.51, F = 0.09, d' = 1.35, c = 0.66
```

جابه‌جا کردن آستانه c را خیلی تغییر می‌دهد (از -0.50 تا 0.66)، در حالی که d' نزدیک مقدار واقعی‌اش یعنی ۲.۱ می‌ماند. تغییرات d' نویز نمونه‌گیری ناشی از ۲۰۰ متن در هر گروه است.

امتحانش کنید (بدون نیاز به API). - ⋆ فرض کنید ۱۰٪ مقاله‌های تحویلی با هوش مصنوعی نوشته شده‌اند. در آستانه‌ی ۲.۱، $P(\text{AI-written} \mid \text{flagged})$ چقدر است؟ (از قاعده‌ی بیز با H و F استفاده کنید.) آیا بر اساس یک هشدار اقدام می‌کنید؟ - ⋆⋆ ROC آشکارساز (همه‌ی آستانه‌ها از -2 تا ۳) و zROC آن را رسم کنید. آیا شیب نزدیک ۱ است؟ با امتیازهای متن انسانی با انحراف معیار ۵.۱ (آشکارسازی با واریانس نابرابر) تکرار کنید. - ⋆⋆ بحث: گزارش شده که آشکارسازها متن‌های نویسندگان

غیربومی انگلیسی را بیشتر علامت می‌زنند [بررسی شود: Liang et al., ۲۰۲۳، *Patterns*]. به زبان SDT این یعنی چه، و یک دانشگاه چه باید بکند؟

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **«درصد پاسخ درست کافی است.»** حساسیت و سوگیری را قاطی می‌کند (رادیولوژیست‌ها را ببینید). هر وقت پاسخ‌ها ممکن است سوگیری داشته باشند از d' و c استفاده کنید.

۲. **محاسبه‌ی d' به شکل $\Phi^{-1}(H-F)$ یا از روی درصدها.** فرمول $\Phi^{-1}(H) - \Phi^{-1}(F)$ است، با نرخ‌ها به‌صورت نسبت بین ۰ و ۱.

۳. **فراموش کردن مشکل نرخ‌های حدی.** $H = 1$ یا $F = 0$ یک d' بی‌نهایت می‌دهد و Python بدون هیچ خطایی `inf` برمی‌گرداند. همیشه از یک تصحیح استفاده کنید (و آن را گزارش کنید).

۴. **فرض اینکه d' در هر حالتی مستقل از سوگیری است.** فقط تحت مدل واریانس برابر مستقل از ملاک است. اگر شیب zROC با ۱ فرق کند، d' یک جفت (H, F) به سوگیری بستگی دارد.

۵. **«نمایی و توانی فقط دو شکل منحنی‌اند.»** آن‌ها ادعاهای متفاوتی درباره‌ی چگونگی فراموشی دارند (نرخ نسبی ثابت در برابر کاهشی).

۶. **قضاوت درباره‌ی مدل فقط با آماره‌ی برازش.** RMSD کوچک همراه با الگوی نظام‌مند در باقی‌مانده‌ها یعنی شکل مدل غلط است. همیشه باقی‌مانده‌ها را رسم کنید.

۷. **نادیده گرفتن مدل نویز.** مدل فقط $f(x;\boldsymbol{\theta})$ نیست. نویز دوجمله‌ای نسبت‌های یادآوری جزئی از مدل است و به شما می‌گوید کدام تفاوت‌ها معنادارند.

۸. **تغییر واحد t در مدل توانی جابه‌جاشده** و انتظار شکل یکسان.

۹.۱.۱ خودآزمایی

۱. پنج جزء یک مدل را نام ببرید و نسخه‌ی SDT هرکدام را بگویید. **پاسخ** طرح آزمایش (trial)های علامت در برابر نویز؛ پاسخ‌های بله/نه)؛ پارامترها (آزاد: d'، c؛ ثابت: میانگین نویز ۰، هر دو انحراف معیار ۱)؛ هسته‌ی قطعی ($H = \Phi(d'/2 - c)$، $F = \Phi(-d'/2 - c)$)؛ مدل نویز (شمارش hitها و false alarmها دوجمله‌ای است)؛ فرض پیوند (وقتی شواهد از ملاک بیشتر است پاسخ «بله»).

۲. چرا میانگین نویز و انحراف معیارها در SDT ثابت‌اند و آزاد نیستند؟ **پاسخ** چون identifiable نیستند: جابه‌جا کردن هر دو توزیع و ملاک به یک اندازه، یا کشیدن کل محور، هیچ پیش‌بینی‌ای را عوض نمی‌کند. ثابت کردن آن‌ها (قیدهای مقیاس) واحدهایی را تعریف می‌کند که d' و c با آن اندازه‌گیری می‌شوند.

۳. یک مشاهده‌گر $H = 0.80$ و $F = 0.20$ دارد. d' و c را حساب کنید. **پاسخ** ($\Phi^{-1}(0.80) = 0.842$) $d' = 0.842 - (-0.842) = 1.68$؛ $c = -\frac{1}{2}(0.842 - 0.842) = 0$، پس مشاهده‌گر بی‌سوگیری است.

۴. SDT با واریانس برابر درباره‌ی zROC چه پیش‌بینی می‌کند، و اگر شیب تجربی ۰.۷ باشد یعنی چه؟ **پاسخ** یک خط راست با شیب ۱. شیب ۰.۷ نشان می‌دهد توزیع علامت از توزیع نویز متغیرتر است ($\sigma_s \approx 1/0.7 \approx 1.4$). در این صورت d' تک‌نقطه‌ای به ملاک بستگی دارد و باید از مدل واریانس نابرابر (یا d_a) استفاده کرد.

۵. نرخ نسبی فراموشی هر مدل چیست، و چرا از نظر روان‌شناختی مهم است؟ **پاسخ** نمایی: λ، ثابت. توانی: $d/(1+t)$، با گذشت زمان کاهشی. مدل نمایی می‌گوید خاطره‌ها در هر سنی روزانه نسبت یکسانی از قدرتشان را از دست می‌دهند؛ تابع توانی می‌گوید خاطره‌های قدیمی‌تر در برابر فراموشی بیشتر مقاوم‌تر می‌شوند.

۶. برای اینکه سریع ببینید داده‌های فراموشی نمایی به نظر می‌رسند چه نموداری رسم می‌کنید؟ و برای توانی؟ **پاسخ** نمایی: $\ln(\text{recall})$ در برابر t (نیمه‌لگاریتمی) که باید خط راست باشد. توانی: $\ln(\text{recall})$ در برابر $\ln(1+t)$ (لگاریتمی–لگاریتمی) که باید خط راست باشد.

۷. دو دلیل بیاورید که چرا برازش خط راست روی نسبت‌های لگاریتمی‌شده روش برآورد ضعیفی است. **پاسخ** (۱) وقتی یک نسبت مشاهده‌شده ۰ باشد از کار می‌افتد. (۲) نویز را تحریف می‌کند: نسبت‌های کوچک روی مقیاس لگاریتمی خیلی متغیر می‌شوند ولی با وزن برابر در نظر گرفته می‌شوند، و خطاهایی که کمینه می‌شوند روی مقیاس غلط (لگاریتمی) هستند. برازش روی مقیاس اصلی با کمترین مربعات یا بیشینه درست‌نمایی از این مشکلات جلوگیری می‌کند.

۱۰.۱.۱ تکلیف

A1: از کلامی به فرمال (۰.۱ نمره از ۲۰؛ انتشار هفته‌ی ۲، موعد ابتدای درس هفته‌ی ۴)

سناریو. دو گروه پژوهشی فراموشی واژه‌هایی را که در یک کلاس زبان خارجی یاد گرفته شده‌اند مطالعه می‌کنند. - **گروه C** می‌گوید: «خاطره‌ها با نرخ ثابتی زوال پیدا می‌کنند.» - **گروه R** می‌گوید: «خاطره‌ها با بالا رفتن سن در برابر فراموشی مقاوم‌تر می‌شوند.»

هر دو گروه ادعا می‌کنند داده‌های منتشرشده (یادآوری سریع افت می‌کند و بعد ثابت می‌شود) از دیدگاهشان حمایت می‌کند.

کارها. یک Jupyter notebook به‌همراه خروجی PDF آن تحویل دهید.

۱. **فرمال‌سازی (گروه C و گروه R).** هر ادعای کلامی را به‌صورت یک مدل فرمال با هر پنج جزء بخش ۱ جزوه بنویسید: طرح آزمایش، پارامترهای آزاد/ثابت با دامنه‌شان، هسته‌ی قطعی، مدل نویز دوجمله‌ای، و فرض پیوند. در ۲ تا ۳ جمله توجیه کنید چرا هر معادله ادعای کلامی‌اش را نشان می‌دهد (از نرخ نسبی فراموشی استفاده کنید).

۲. **پیاده‌سازی.** توابع Python بنویسید که (الف) احتمال‌های یادآوری پیش‌بینی‌شده را برگردانند و (ب) برای فاصله‌ها و تعداد آیتم n داده‌شده، شمارش‌های یادآوری دوجمله‌ای را شبیه‌سازی کنند.

۳. **کالیبراسیون.** هر دو گروه قبول دارند که یادآوری **بعد از ۱ روز ۶۰.۰** و **بعد از ۷ روز ۳۵.۰** است. پارامترهای هر مدل را که دقیقاً این دو مقدار را بازتولید می‌کنند، دستی و به‌صورت بسته به دست آورید. محاسبه را نشان دهید (لگاریتم بگیرید) و آن را عددی بررسی کنید.

۴. **پیدا کردن جای اختلاف.** با پارامترهای کالیبره‌شده، هر دو منحنی پیش‌بینی‌شده را از ۰ تا ۹۰ روز رسم کنید. برای $n = 40$ آیتم، در هر فاصله یک شاخص تمایزپذیری $D(t) = \big(f_C(t) - f_R(t)\big)^2 / \mathrm{Var}(t)$ حساب کنید که در آن $\mathrm{Var}(t) = \bar{f}(1-\bar{f})/n$ و $\bar{f}$ میانگین دو پیش‌بینی است. $D(t)$ را رسم کنید.

۵. **طراحی آزمایش.** می‌توانید هر شرکت‌کننده را فقط در **۴** فاصله‌ی نگهداری آزمون کنید که از میان $\{۰.۵, ۱, ۲, ۴, ۷, ۱۴, ۳۰, ۶۰, ۹۰\}$ روز انتخاب می‌شوند. مجموعه‌ای را انتخاب کنید که مجموع $D(t)$ را بیشینه کند، توضیح دهید چرا منطقی است، و با طرح خود یک مجموعه‌داده از هر مدل شبیه‌سازی کنید. دو مجموعه‌داده را روی یک نمودار نشان دهید.

۶. **تفسیر (حداکثر ۳۰۰ کلمه).** کدام داده‌ها به نفع گروه C و کدام به نفع گروه R هستند؟ تحلیل شما درباره‌ی اینکه چرا هر دو گروه می‌توانند ادعا کنند «داده‌های منتشرشده» از آن‌ها حمایت می‌کند چه می‌گوید؟ یک فرض مدل‌هایتان را که ممکن است غلط باشد نام ببرید و بگویید چطور نتیجه‌گیری‌تان را تغییر می‌دهد.

روبریک نمره‌دهی (۱۰ امتیاز، معادل ۰.۱ از نمره‌ی نهایی):

معیار	امتیاز	شرط نمره‌ی کامل
فرمال‌سازی (کار ۱)	۲	هر پنج جزء برای هر دو مدل؛ دامنه‌ی درست پارامترها؛ ارتباط معادله و ادعای کلامی با نرخ نسبی فراموشی توضیح داده شده
کد (کار ۲)	۲	درست، با توضیح (comment)، قابل بازتولید (seed ثابت)؛ توابع برداری‌شده یا با حلقه‌ی روشن
کالیبراسیون (کار ۳)	۲	استخراج بسته‌ی درست و بررسی عددی برای هر دو مدل
اختلاف و طراحی (کارهای ۴–۵)	۵.۲	$D(t)$ درست؛ طرح انتخاب‌شده توجیه شده و واقعاً معیار را بیشینه می‌کند؛ نمودارهای روشن
تفسیر (کار ۶)	۵.۱	روشن، مشخص، با ارجاع به نتایج خودتان؛ یک محدودیت واقعی را نام می‌برد

برای تحویل با تأخیر، روزی ٪۱۰ کسر می‌شود (حداکثر ۳ روز).

۱۱.۱.۱ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۲.** ساختن مدل از یک نظریه‌ی کلامی؛ اجزای مدل و نقش پارامترها. (منبع اصلی.)
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۱۱.** نظریه‌ی تشخیص علامت به‌عنوان یک مدل شناختی (بیزی)؛ در هفته‌های ۹ و ۱۳ به آن برمی‌گردیم. بخش مقدمه را الان بخوانید و از کد بگذرید.
- Verguts **(۲۰۲۲)** و Anderson **(۲۰۱۴)**: فصل‌های مربوط به ساختن مدل و پارامترها [شماره‌ی فصل‌ها بررسی شود].
- پیش‌زمینه درباره‌ی منحنی‌های فراموشی: Wagenmakers & Lee (۲۰۱۴)، فصل ۱۰ (نگهداری حافظه) از یک مدل نگهداری نمایی نزدیک استفاده می‌کند که آن را در هفته‌های ۹–۱۱ به روش بیزی برازش می‌کنیم.

پیش‌نمایش هفته‌ی ۳: خطی‌سازی را کنار می‌گذاریم و مدل‌ها را مستقیماً با کمینه کردن مربع خطا برازش می‌کنیم؛ یعنی یاد می‌گیریم الگوریتم‌های بهینه‌سازی چطور فضای پارامتر را جستجو می‌کنند.