مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۴: برآورد بیشینه درست‌نمایی (Maximum Likelihood)

فهرست مطالب

۱ روش‌های برآورد پارامتر ۱

۱.۱ هفته‌ی ۴: برآورد بیشینه درست‌نمایی (Maximum Likelihood) ۱

۱.۱.۱ واژه‌های کلیدی ۱

۱.۱.۲ اهداف یادگیری ۲

۱.۱.۳ مقدمه ۳

۱.۱.۴ جزوه‌ی درس ۳

۱.۱.۵ مثال حل‌شده ۸

۱.۱.۶ lab (۲ ساعت) ۹

۱.۱.۷ ارتباط با هوش مصنوعی و LLMها ۱۲

۱.۱.۸ اشتباهات رایج و برداشت‌های نادرست ۱۳

۱.۱.۹ خودآزمایی ۱۳

۱.۱.۱۰ تکلیف ۱۴

۱.۱.۱۱ مطالعه‌ی بیشتر ۱۴

فصل ۱

روش‌های برآورد پارامتر

۱.۱ هفته‌ی ۴: برآورد بیشینه درست‌نمایی (Maximum Likelihood)

فصل ۲: روش‌های برآورد پارامتر · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** آزمایش فراموشی هفته‌های ۲–۳ (شمارش‌های یادآوری دوجمله‌ای)، به‌علاوه‌ی یک آزمایش SDT جدید با سه شرط پاداش (payoff).

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
binomial distribution	توزیع دوجمله‌ای	توزیع تعداد موفقیت در n کوشش
signal detection theory (SDT)	نظریه‌ی تشخیص علامت	مدلی که حساسیت را از سوگیری پاسخ جدا می‌کند
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
least squares	کمترین مربعات	روش برازش با کمینه کردن مجموع مربع خطاها

English	فارسی	توضیح کوتاه
maximum likelihood estimate (MLE)	برآورد بیشینه‌ی درست‌نمایی	پارامترهایی که داده را محتمل‌ترین می‌کنند
noise	نویز	تغییرات تصادفی در شواهد یا در داده
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
deviance (G^2)	انحراف (deviance)	معیار عدم برازش نسبت به مدل اشباع‌شده
constraints / bounds	کران‌ها / قیدها	محدودیت‌های مجاز برای مقدار پارامترها
response bias	سوگیری پاسخ	تمایل به یک پاسخ، مستقل از محرک
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
optimizer	بهینه‌ساز	الگوریتمی که کمینه‌ی تابع را پیدا می‌کند
RMSD / SSE	مجموع مربعات خطا / ریشه‌ی میانگین مربع انحراف	معیارهای فاصله‌ی داده و پیش‌بینی
saturated model	مدل اشباع‌شده	مدلی که داده را دقیقاً بازتولید می‌کند
likelihood-ratio test (LRT)	آزمون نسبت درست‌نمایی	مقایسه‌ی دو مدل تودرتو
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
conservative / liberal	آسان‌گیر / محافظه‌کار	تمایل به گفتن «بله» / «نه»
token	token (واحد متن)	کلمه یا بخشی از کلمه که مدل زبانی پیش‌بینی می‌کند
perplexity	perplexity (سردرگمی)	e به توان NLL هر token

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. احتمال (داده متغیر، پارامترها ثابت) را از درست‌نمایی (داده ثابت، پارامترها متغیر) **متمایز کنند**.
۲. درست‌نمایی و لگاریتم درست‌نمایی را برای مدل‌های داده‌ی دوجمله‌ای (برنولی) و گاوسی **استخراج کنند** و **نشان دهند** که کمترین مربعات همان بیشینه درست‌نمایی تحت نویز گاوسی با واریانس برابر است.
۳. برآورد بیشینه درست‌نمایی (MLE) را با کمینه کردن منفی لگاریتم درست‌نمایی (NLL) در Python، برای منحنی‌های فراموشی و یک مدل SDT چندشرطی، **پیاده‌سازی کنند**.
۴. برازش مطلق را با انحراف (deviance) G^2 **ارزیابی کنند** و MLE را با برآوردهای کمترین مربعات **مقایسه کنند**.
۵. مدل‌های مقیدشده (مثلاً «پاداش سوگیری را تغییر می‌دهد، نه حساسیت را») را به‌عنوان فرضیه‌های روان‌شناختی واقعی **تفسیر کنند**.

۳.۱.۱ مقدمه

در هفته‌ی ۳، کمترین مربعات با همه‌ی نقاط داده به یک اندازه قابل اعتماد رفتار کرد. ولی نسبت یادآوری ۵۰.۰ که روی ۵۰ آیتم اندازه‌گیری شده پرنویزتر از نسبت ۹۵.۰ است: واریانس دوجمله‌ای $f(1-f)/n$ به f بستگی دارد. کمترین مربعات همچنین درباره‌ی داده‌هایی که اعداد پیوسته نیستند، مثل یک پاسخ بله/نه، یک انتخاب بین چند گزینه یا یک درجه‌ی اطمینان، حرفی برای گفتن ندارد.

بیشینه درست‌نمایی «پیش‌بینی‌ها را به داده نزدیک کن» را با سؤالی دقیق‌تر جایگزین می‌کند:

> **کدام مقادیر پارامتر داده‌ای را که واقعاً مشاهده کردیم محتمل‌ترین می‌کنند؟**

برای جواب دادن، مدل باید بگوید هر مجموعه‌داده‌ی ممکن چقدر محتمل است، و این دقیقاً همان مدل نویز است (جزء ۴ در کالبدشکافی هفته‌ی ۲). وقتی آن را داشته باشیم، MLE با شمارش‌ها، انتخاب‌ها، زمان‌های واکنش و ترکیب‌هایشان به یک شکل کار می‌کند. همچنین بدون هزینه‌ی اضافه یک معیار مطلق عدم برازش (deviance)، پایه‌ی خطاهای استاندارد (هفته‌ی ۵)، معیارهای اطلاعاتی (هفته‌ی ۷) و جمله‌ی درست‌نمایی در قاعده‌ی بیز (هفته‌های ۹–۱۳) را به ما می‌دهد. **درست‌نمایی مهم‌ترین مفهوم این درس است.**

این موضوع کجا به کار می‌رود؟

- **تقریباً هر مدل شناختی منتشرشده** با بیشینه‌ی درست‌نمایی یا نسخه‌ی بیزی آن (هفته‌های ۹ تا ۱۳) برازش می‌شود. وقتی مقاله‌ای «برازش مدل»، «AIC» یا «log-likelihood» گزارش می‌کند، MLE پشت آن است.
- **داده‌ی انتخاب:** اینکه آدم کدام گزینه را انتخاب می‌کند (در آزمون حافظه، یک قمار، یک تکلیف یادگیری) یک عدد پیوسته نیست، پس کمترین مربعات کار نمی‌کند. درست‌نمایی به‌طور طبیعی با انتخاب‌ها کار می‌کند.
- **روان‌فیزیک** :(psychophysics) تابع روان‌سنجی (احتمال تشخیص یک محرک بر حسب شدت آن) در هر آزمایشگاه بینایی و شنوایی با MLE دوجمله‌ای برازش می‌شود.
- **آزمودن فرضیه‌ها داخل یک مدل:** «آیا پاداش حساسیت را عوض می‌کند یا فقط سوگیری را؟» به مقایسه‌ی دو درست‌نمایی تبدیل می‌شود (بخش ۶).
- **هوش مصنوعی:** مدل‌های بزرگ زبانی با بیشینه کردن درست‌نمایی متن آموزش می‌بینند (بخش هوش مصنوعی و LLMها را ببینید).

۴.۱.۱ جزوه‌ی درس

به زبان ساده تصور کنید مقدارهای مختلف پارامتر را یکی‌یکی امتحان می‌کنید. برای هر مقدار از مدل بپرسید: «اگر این مقدار واقعی بود، داده‌ای که واقعاً جمع کرده‌ام چقدر محتمل بود؟» این عدد **درست‌نمایی** (likelihood) آن مقدار پارامتر است. **برآورد بیشینه‌ی درست‌نمایی** (MLE) مقداری از پارامتر است که تحت آن، داده‌ی مشاهده‌شده محتمل‌ترین بود. مثال: کسی ۷ کلمه از ۱۰ کلمه را به یاد می‌آورد. اگر احتمال واقعی یادآوری او ۵.۰ بود، به دست آمدن دقیقاً ۷ نسبتاً بعید بود (۱۱۷.۰)؛ اگر ۷.۰ بود، محتمل‌تر بود (۲۶۷.۰). پس ۷.۰ توضیح بهتری است و در واقع MLE برابر ۷/۱۰ است. در عمل با **لگاریتم** درست‌نمایی کار می‌کنیم (تا ضرب‌ها به جمع تبدیل شوند) و از کامپیوتر می‌خواهیم منفی آن (NLL) را با بهینه‌سازهای هفته‌ی ۳ کمینه کند. دو جایزه هم می‌گیریم: معلوم می‌شود کمترین مربعات حالت خاصی از MLE است، و درست‌نمایی یک آزمون مطلق برای عدم برازش (G^2) می‌دهد.

زمان‌بندی پیشنهادی (۶۰ دقیقه): احتمال در برابر درست‌نمایی ۱۰ · MLE دوجمله‌ای ۱۵ · لگاریتم درست‌نمایی و NLL ۱۰ · حالت گاوسی LS) = (MLE ۱۰ · برازش مطلق G^2 ۱۰ · مدل‌های مقیدشده ۵.

۱. احتمال در برابر درست‌نمایی

تابع یکسان $p(\mathbf{y} \mid \boldsymbol{\theta})$ را می‌شود به دو شکل خواند:

	خوانش	ثابت	متغیر	نام	جمع/انتگرالش ۱ است؟
پیش از آزمایش	$\boldsymbol{\theta}$	$\mathbf{y}$		احتمال (جرم/چگالی) داده	بله، روی $\mathbf{y}$
پس از آزمایش	$\mathbf{y}$ (مشاهده‌شده)	$\boldsymbol{\theta}$		**درست‌نمایی** $L(\boldsymbol{\theta}) = p(\mathbf{y} \mid \boldsymbol{\theta}, \mathcal{M})$	**نه**، روی $\boldsymbol{\theta}$ نه

درست‌نمایی احتمال درست بودن پارامترها **نیست**. احتمال داده تحت هر مقدار ممکن پارامتر است. (تبدیل آن به یک توزیع احتمال روی $\boldsymbol{\theta}$ به یک پیشین نیاز دارد: بیز، هفته‌ی ۹.)

مثال. یک شرکت‌کننده $y = 7$ از $n = 10$ آیتم را به یاد می‌آورد. تحت یک مدل دوجمله‌ای با احتمال یادآوری θ:

$$L(\theta) = \binom{10}{7} \theta^7 (1-\theta)^3.$$

$L(0.5) = 0.117$، $L(0.7) = 0.267$: داده‌های مشاهده‌شده اگر $\theta = 0.7$ باشد حدود ۲.۲ برابر محتمل‌ترند تا اگر $\theta = 0.5$ باشد.

خواندن ریاضی $L(\theta) = \binom{10}{7}\theta^7(1-\theta)^3$:

- θ^7: احتمال اینکه ۷ آیتم مشخص به یاد آورده شوند (هرکدام با احتمال θ).
- $(1-\theta)^3$: احتمال اینکه ۳ آیتم دیگر فراموش شوند.
- $\binom{10}{7} = 120$ («ترکیب ۷ از ۱۰»): تعداد راه‌های مختلف برای انتخاب اینکه کدام ۷ آیتم از ۱۰ آیتم به یاد آمده‌اند. به θ بستگی ندارد، پس هیچ‌وقت محل بیشینه را عوض نمی‌کند.
- با $\theta = 0.7$: $120 \times 0.7^7 \times 0.3^3 = 120 \times 0.0824 \times 0.027 = 0.267$.

تغییر نگاه اصلی: در احتمال، θ ثابت است و درباره‌ی داده‌های مختلف می‌پرسیم؛ در درست‌نمایی، داده ثابت است (آن را داریم) و θهای مختلف را مقایسه می‌کنیم.

۲. برآورد بیشینه درست‌نمایی

$$\hat{\boldsymbol{\theta}}_{\text{ML}} = \arg\max_{\boldsymbol{\theta}} L(\boldsymbol{\theta}) = \arg\max_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}), \qquad \ell(\boldsymbol{\theta}) = \ln L(\boldsymbol{\theta}).$$

چرا لگاریتم؟ ۱. با مشاهدات مستقل، درست‌نمایی یک **حاصل‌ضرب** است، $L = \prod_i p(y_i \mid \boldsymbol{\theta})$، که در کامپیوتر حتی برای چند صد trial به ۰ سرریز (underflow) می‌کند. لگاریتم آن را به یک **مجموع** تبدیل می‌کند، $\ell = \sum_i \ln p(y_i \mid \boldsymbol{\theta})$. ۲. لگاریتم اکیداً صعودی است، پس بیشینه‌کننده‌ی یکسانی دارد. ۳. مشتق گرفتن از مجموع راحت‌تر است.

بهینه‌سازها کمینه می‌کنند، پس در کد **منفی لگاریتم درست‌نمایی**، $\text{NLL}(\boldsymbol{\theta}) = -\ell(\boldsymbol{\theta})$، را کمینه می‌کنیم.

مثال تحلیلی (دوجمله‌ای). $\ell(\theta) = \text{const} + y\ln\theta + (n-y)\ln(1-\theta)$. با صفر قرار دادن مشتق:

$$\frac{d\ell}{d\theta} = \frac{y}{\theta} - \frac{n-y}{1-\theta} = 0 \quad \Rightarrow \quad \hat{\theta} = \frac{y}{n}.$$

MLE یک احتمال همان نسبت مشاهده‌شده است، که خیال‌مان را راحت می‌کند. در مدل‌های شناختی، احتمال پیش‌بینی‌شده تابعی از پارامترهاست، $\theta_i = f(x_i;\boldsymbol{\theta})$، و معمولاً به یک بهینه‌ساز عددی نیاز داریم.

۳. درست‌نمایی دوجمله‌ای برای منحنی‌های فراموشی

با y_i آیتم یادآوری‌شده از n_i در فاصله‌ی t_i و فاصله‌های مستقل:

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^{N} \left[\ln \binom{n_i}{y_i} + y_i \ln f(t_i;\boldsymbol{\theta}) + (n_i - y_i)\ln\big(1 - f(t_i;\boldsymbol{\theta})\big) \right].$$

- ضریب دوجمله‌ای به $\boldsymbol{\theta}$ بستگی ندارد، پس روی MLE اثری ندارد (ولی اگر می‌خواهید لگاریتم درست‌نمایی را بین کدگذاری‌های مختلف داده مقایسه کنید نگهش دارید؛ `scipy.stats.binom.logpmf` آن را شامل می‌شود).
- مشاهداتی که پیش‌بینی می‌شود نزدیک ۰ یا ۱ باشند واریانس کمی دارند، پس پیش‌بینی‌ای که آن‌ها را از دست بدهد بیشتر جریمه می‌شود. MLE همان وزن‌دهی واریانسی کمترین مربعات وزنی هفته‌ی ۳ را خودکار انجام می‌دهد.
- **ایمنی عددی:** اگر مدل جایی که $y > 0$ است $f = 0$ پیش‌بینی کند، $\ln 0 = -\infty$ می‌شود. پیش‌بینی‌ها را به $[\epsilon, 1-\epsilon]$ محدود (clip) کنید، مثلاً با $\epsilon = 10^{-10}$.

برنولی در برابر دوجمله‌ای. اگر پاسخ‌های تکی ۰/۱ را نگه داریم، $\ell = \sum_{\text{trials}} [y \ln f + (1-y)\ln(1-f)]$. این فقط با ضرایب دوجمله‌ای ثابت با نسخه‌ی دوجمله‌ای فرق دارد، پس همان MLE را می‌دهد.

خواندن ریاضی لگاریتم درست‌نمایی فراموشی همان لگاریتم درست‌نمایی یک نسبت (بخش ۲) است که برای هر فاصله‌ی زمانی یک بار نوشته و جمع شده است:

- برای فاصله‌ی i: جمله‌ی $y_i \ln f(t_i)$ به پیش‌بینی احتمال یادآوری بالا در جایی که آیتم‌های زیادی به یاد آمده‌اند پاداش می‌دهد؛ $(n_i - y_i)\ln(1 - f(t_i))$ به پیش‌بینی احتمال پایین در جایی که آیتم‌های زیادی فراموش شده‌اند پاداش می‌دهد.
- جمع زدن روی فاصله‌ها مجاز است چون فرض می‌کنیم فاصله‌ها **مستقل**‌اند: لگاریتم حاصل‌ضرب احتمال‌ها برابر جمع لگاریتم‌هاست.
- چرا وزن‌دهی خودکار است: اگر مدل $f = 0.95$ پیش‌بینی کند ولی فقط ۴۰ از ۵۰ به یاد آمده باشد، جمله‌ی $10\ln(0.05) \approx -30$ خیلی پرهزینه است. نزدیک $f = 0.5$ همان مقدار خطا هزینه‌ی خیلی کمتری دارد. به نقطه‌هایی که باید دقیق باشند بیشتر اعتماد می‌شود.

۴. حالت گاوسی: کمترین مربعات همان بیشینه درست‌نمایی است

فرض کنید $y_i = f(x_i;\boldsymbol{\theta}) + \varepsilon_i$ با $\varepsilon_i \sim \mathcal{N}(0,\sigma)$، مستقل و با σ **یکسان**. آن‌وقت

$$\ell(\boldsymbol{\theta},\sigma) = \sum_{i=1}^{N} \ln\left[\frac{1}{\sqrt{2\pi}\sigma}\exp\left(-\frac{(y_i - f(x_i;\boldsymbol{\theta}))^2}{2\sigma^2}\right)\right] = -\frac{N}{2}\ln(2\pi\sigma^2) - \frac{\mathrm{SSE}(\boldsymbol{\theta})}{2\sigma^2}.$$

برای هر σ ثابت، بیشینه کردن ℓ روی $\boldsymbol{\theta}$ یعنی کمینه کردن SSE. پس **کمترین مربعات = MLE تحت نویز گاوسی مستقل و با واریانس برابر**. بیشینه کردن روی σ هم $\hat{\sigma}^2 = \mathrm{SSE}/N$ را می‌دهد.

این توضیح می‌دهد کمترین مربعات کی مناسب است (نویز پیوسته، تقریباً متقارن، با واریانس ثابت) و کی نیست (شمارش‌ها، نسبت‌ها، انتخاب‌ها، زمان‌های واکنش چوله).

پیشرفته: ویژگی‌های MLE. تحت شرایط منظم بودن (مدل identifiable، پارامترهای واقعی نه روی مرز، N بزرگ)، MLE سازگار (consistent: به مقدار واقعی همگرا می‌شود)، به‌طور مجانبی نرمال و به‌طور مجانبی کارا است (هیچ برآوردگر سازگاری در حد واریانس کمتری ندارد). واریانس نمونه‌گیری آن با معکوس **اطلاع فیشر** (Fisher information)، یعنی انحنای $-\ell$ در کمینه‌اش، تقریب زده می‌شود. هفته‌ی ۵ دقیقاً از همین برای محاسبه‌ی خطاهای استاندارد استفاده می‌کند. در نمونه‌های کوچک MLE ممکن است سوگیری داشته باشد (مثلاً $\hat{\sigma}^2 = \mathrm{SSE}/N$ واریانس σ^2 را کمتر برآورد می‌کند).

۵. برازش مطلق: انحراف G^2

مقدار لگاریتم درست‌نمایی به‌تنهایی معنای مطلقی ندارد. برای قضاوت درباره‌اش، مدل را با **مدل اشباع‌شده** (saturated) مقایسه کنید که برای هر خانه‌ی داده یک احتمال آزاد دارد و بنابراین هر نسبت مشاهده‌شده را دقیقاً بازتولید می‌کند ($\hat{f}_i = y_i/n_i$). **انحراف** (deviance) برابر است با

$$G^2 = 2\big[\ell_{\text{saturated}} - \ell(\hat{\boldsymbol{\theta}})\big] = 2\sum_{i}\left[y_i \ln\frac{y_i}{n_i \hat{f}_i} + (n_i - y_i)\ln\frac{n_i - y_i}{n_i(1-\hat{f}_i)}\right],$$

با $0 \ln 0 = 0$. اگر مدل درست باشد و شمارش‌ها خیلی کوچک نباشند، G^2 تقریباً توزیع χ^2 با $\mathrm{df} = (\text{تعداد خانه‌ها}) - k$ دارد. G^2 بزرگ (p کوچک) یعنی عدم برازش مدل بیش از آن است که نویز نمونه‌گیری بتواند توضیح دهد.

هشدارها: با N خیلی بزرگ، هر عدم برازش کوچکی «معنادار» می‌شود؛ با N کوچک، عدم برازش واقعی ممکن است دیده نشود. یک G^2 غیرمعنادار **ثابت نمی‌کند** که مدل درست است (هفته‌ی ۶).

خواندن ریاضی

- **مدل اشباع‌شده** (saturated) مدل «تقلب‌کننده»‌ای است که هر نسبت مشاهده‌شده را دقیقاً پیش‌بینی می‌کند. لگاریتم درست‌نمایی آن بهترین مقداری است که هر مدلی ممکن است روی این داده به دست آورد.
- $G^2 = 2(\ell_{\text{saturated}} - \ell(\hat{\boldsymbol{\theta}}))$ اندازه می‌گیرد مدل ما چقدر از این سقف فاصله دارد. $G^2 = 0$ یعنی برازش کامل.
- **درجه‌ی آزادی** (df) = تعداد خانه‌های داده − تعداد پارامترهای برازش‌شده. با ۸ فاصله و ۲ پارامتر، df = ۶.
- اگر مدل درست باشد، G^2 مثل یک متغیر χ^2 با همان df رفتار می‌کند که میانگینش df است. پس $G^2 \approx 6$ با df = ۶ مقدار عادی عدم برازش است (فقط نویز)؛ $G^2 = 26$ با df = ۶ ($p = .0002$) یعنی مدل به‌طور نظام‌مند داده را از دست می‌دهد.

۶. مدل‌های مقیدشده به‌عنوان فرضیه

برازش MLE **چند شرط هم‌زمان با بعضی پارامترهای مشترک** را آسان می‌کند. مثال: یک آزمایش SDT با سه شرط پاداش (پاداش برای پاسخ «بله»، خنثی، پاداش برای «نه»).

مدل	پارامترهای آزاد	k	فرضیه
حساسیت مشترک	d'؛ c_1, c_2, c_3	۴	پاداش فقط سوگیری را تغییر می‌دهد

	مدل	پارامترهای آزاد	k	فرضیه
جداگانه		c_1, c_2, c_3 ،d'_1, d'_2, d'_3	۶	پاداش ممکن است حساسیت را هم تغییر دهد (این مدل اشباع‌شده برای ۶ نرخ است)

لگاریتم درست‌نمایی مشترک، مجموع لگاریتم درست‌نمایی‌های دوجمله‌ای hitها و false alarmها در همه‌ی شرایط است. مقایسه‌ی لگاریتم درست‌نمایی بیشینه‌ی دو مدل یک سؤال واقعی را آزمون می‌کند. برای مدل‌های nested مثل این‌ها، $2(\ell_6 - \ell_4)$ تقریباً χ^2 با ۲ درجه‌ی آزادی است: **آزمون نسبت درست‌نمایی** که در هفته‌ی ۷ کامل می‌شود.

> **پیشرفته: MLE در SDT و فرمول‌ها.** برای یک شرط تنها، MLE (d', c) از شمارش‌ها دقیقاً همان چیزی است که فرمول‌های هفته‌ی ۲ بدون تصحیح می‌دهند، چون مدل اشباع‌شده است (۲ پارامتر، ۲ نرخ) و MLE نرخ‌های مشاهده‌شده را بازتولید می‌کند. تصحیح log-linear، MLE نیست؛ بیشتر به یک برآورد بیزی با پیشین ضعیف شبیه است (هفته‌ی ۹).

برای یک مهندس

- این دقیقاً همان **تخمین بیشینه‌ی درست‌نمایی** در نظریه‌ی تخمین است (تخمین ML کانال یا فرکانس، آشکارسازی دنباله با ML). تنها تفاوت مدل نویز است: شمارش دوجمله‌ای به جای AWGN.
- ML = LS **تحت** AWGN (بخش ۴) نتیجه‌ای است که قبلاً از آن استفاده کرده‌اید: با نویز سفید گاوسی با واریانس معلوم و برابر، تخمین‌گر ML خطای مربعی را کمینه می‌کند.
- **اطلاعات فیشر** (Fisher information) و واریانس مجانبی MLE (کادر پیشرفته) همان کمیت‌های **کران پایین** Cramér–Rao هستند. هفته‌ی ۵ از آن‌ها برای محاسبه‌ی خطای استاندارد استفاده می‌کند.
- مقایسه‌ی یک مدل مقید و یک مدل آزاد با $2(\ell_{\text{free}} - \ell_{\text{constrained}})$ همان **آزمون نسبت درست‌نمایی تعمیم‌یافته** (GLRT) است: هر دو فرضیه پارامترهای مجهول دارند که با تخمین ML جایگزین می‌شوند.
- **پاداش‌ها و جابه‌جایی ملاک:** در آشکارسازی بیزی، آستانه‌ی بهینه با هزینه‌ها و احتمال‌های پیشین جابه‌جا می‌شود. بخش ۶ می‌آزماید که آیا آدم‌ها وقتی پاداش‌ها عوض می‌شوند فقط آستانه‌شان (c) را جابه‌جا می‌کنند و «SNR»شان (d') ثابت می‌ماند.

برای مدرس

- **جمله‌ای که باید تکرار کنید:** «درست‌نمایی احتمال داده‌ای است که مشاهده کرده‌ایم، به‌عنوان تابعی از پارامترها». آن را روی تخته بنویسید و تا آخر جلسه نگه دارید.
- **رسمش کنید.** $L(\theta)$ را برای ۷ از ۱۰ (مثال حل‌شده، بخش ۱) به شکل منحنی روی θ از ۰ تا ۱ بکشید. بپرسید: قله کجاست؟ آیا مساحت زیر منحنی ۱ است؟ (نه.) بعد آن را برای ۷۰ از ۱۰۰ بکشید: همان قله، منحنی خیلی باریک‌تر. این باریکی همان دقت (precision) است، موضوع هفته‌ی ۵.
- **از پیش‌زمینه‌ی خودتان استفاده کنید.** خیلی از دانشجوها MLE را انتزاعی می‌دانند؛ شما می‌توانید آن را به‌عنوان «روش تخمینی که مهندس‌ها وقتی نویز گاوسی نیست به کار می‌برند» معرفی کنید.
- **سؤال‌های رایج.**
  - «آیا درست‌نمایی احتمال درست بودن θ است؟» نه. برای آن به prior نیاز داریم (هفته‌ی ۹).
  - «چرا NLL را کمینه می‌کنیم به جای اینکه L را بیشینه کنیم؟» جواب یکی است، ولی جمع لگاریتم‌ها از underflow عددی جلوگیری می‌کند و بهینه‌سازها برای کمینه کردن نوشته شده‌اند.

- «آیا G^2 غیرمعنادار ثابت می‌کند مدل درست است؟» نه؛ فقط یعنی عدم برازش بیشتر از نویز نیست، و با داده‌ی کم ممکن است عدم برازش واقعی پنهان بماند.

- **مدیریت زمان.** بخش ۴ (حالت گاوسی) را می‌شود سریع به‌عنوان LS» حالت خاصی است» نشان داد. وقت صرفه‌جویی‌شده را روی بخش ۵ (G^2) بگذارید.

۵.۱.۱ مثال حل‌شده

بخش ۱: درست‌نمایی یک نسبت تنها

$y = 7$ یادآوری از $n = 10$:

θ	۵.۰	۶.۰	**۷.۰**	۸.۰
$L(\theta) = \binom{10}{7}\theta^7(1-\theta)^3$	۱۱۷.۰	۲۱۵.۰	**۲۶۷.۰**	۲۰۱.۰
$\ell(\theta)$	۱۴۴.۲−	۵۳۷.۱−	**۳۲۱.۱**−	۶۰۳.۱−

بیشینه در $\hat\theta = 7/10 = 0.7$ است. دقت کنید که مقادیر درست‌نمایی روی θ جمعشان ۱ نمی‌شود: درست‌نمایی توزیع احتمال روی پارامترها نیست.

بخش ۲: یک آزمایش فراموشی دوفاصله‌ای

$y = (30, 13)$ آیتم یادآوری‌شده از $n = 50$ در $t = (1, 7)$ روز. مدل: $f(t) = Ae^{-\lambda t}$.

قدم ۱: NLL برای یک نامزد. برای $(A, \lambda) = (0.70, 0.15)$: $f(1) = 0.7e^{-0.15} = 0.6025$، $f(7) = 0.7e^{-1.05} = 0.2450$.

$$\ell = \ln \mathrm{Binom}(30; 50, 0.6025) + \ln \mathrm{Binom}(13; 50, 0.2450) = -2.167 + (-2.088) = -4.255,$$

پس $\mathrm{NLL} = 4.255$.

قدم ۲: مقایسه. برای $(0.70, 0.12)$: $f = (0.621, 0.302)$ و $\mathrm{NLL} = 4.488$ که بدتر است. نامزد اول داده‌ها را محتمل‌تر می‌کند.

قدم ۳: MLE. با ۲ پارامتر و ۲ داده، مدل می‌تواند هر دو نسبت مشاهده‌شده را دقیقاً بازتولید کند: $Ae^{-\lambda} = 0.60$ و $Ae^{-7\lambda} = 0.26$. تقسیم این دو می‌دهد $e^{6\lambda} = 0.60/0.26$، پس $\hat\lambda = \ln(2.308)/6 = 0.139$ و $\hat A = 0.60\, e^{0.139} = 0.690$، با $\mathrm{NLL} = 4.225$ (کمینه). یک بهینه‌ساز عددی همین مقادیر را می‌دهد.

تفسیر. MLE می‌گوید این شرکت‌کننده در شروع حدود ۶۹٪ را به یاد می‌آورد و هر روز حدود ۱۳٪ از باقی‌مانده را از دست می‌دهد ($1 - e^{-0.139}$). چون اینجا $k = N$ است، $G^2 = 0$: مدل نمی‌تواند بد برازش شود، پس این برازش کامل هیچ شاهدی برای شکل نمایی نیست. فقط داده‌هایی با تعداد خانه‌ی بیشتر از تعداد پارامترها می‌توانند یک مدل را آزمون کنند.

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. رسم یک تابع درست‌نمایی و دیدن اینکه چرا با لگاریتم درست‌نمایی کار می‌کنیم.
۲. برازش مدل‌های فراموشی نمایی و توانی با MLE؛ مقایسه با کمترین مربعات؛ ارزیابی با G^2.
۳. وارسی عددی اینکه MLE گاوسی با کمترین مربعات برابر است.
۴. برازش یک مدل SDT چندشرطی مقیدشده و **تفسیر** آنچه درباره‌ی پاداش‌ها می‌گوید.

زمان‌بندی: بخش A ۱۵ دقیقه · بخش B ۳۵ دقیقه · بخش C ۱۵ دقیقه · بخش D ۳۵ دقیقه · بخش E ۲۰ دقیقه (تمرین‌ها).

آماده‌سازی

Code · **کد:** `code/week04.py`، cell ۱ · سلول ۱

بخش A: تابع درست‌نمایی (۱۵ دقیقه)

Code · **کد:** `code/week04.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
Area under L(theta): 0.091 (not 1: L is not a distribution over theta)
Product of 2000 trial probabilities: 0.0
Sum of their logs: -1239.52
```

بخش B: MLE برای منحنی‌های فراموشی (۳۵ دقیقه)

Code · **کد:** `code/week04.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
model method      A   rate     NLL    SSE
  exp    MLE 0.6377 0.0458 29.8123 0.1100
  exp     LS 0.6568 0.0566 30.6983 0.1061
  pow    MLE 0.8773 0.4214 19.8303 0.0262
  pow     LS 0.8712 0.4251 19.8585 0.0259
True (power): A = 0.9, d = 0.5
```

به این‌ها دقت کنید: - هر روش در معیار خودش برنده است: MLE کمترین NLL و LS کمترین SSE را دارد. - برای مدل توانی (مدل واقعی) دو روش خیلی به هم نزدیک‌اند. - برای مدل نمایی دو روش بیشتر با هم فرق دارند (نرخ زوال ۰۴۶.۰ در برابر ۰۵۷.۰). درست‌نمایی دوجمله‌ای به نقاطی که نزدیک کف دقیق اندازه‌گیری شده‌اند (فاصله‌های طولانی) وزن بیشتری می‌دهد، پس منحنی ML کندتر زوال پیدا می‌کند تا به آن‌ها نزدیک‌تر بماند.

> **هشدار: یک دام واقعی بهینه‌ساز.** در برازش ML بالا `"L-BFGS-B"` را با `"Nelder-Mead"` عوض کنید (با نگه داشتن `bounds=bounds`) و دوباره اجرا کنید. برای مدل نمایی، Nelder–Mead کران‌دار scipy روی کران `A=1` فرو می‌ریزد و با NLL = ۵.۷۹ «`success`» گزارش می‌کند؛ خیلی بدتر از کمینه‌ی واقعی ۸.۲۹ (حتی بدتر از NLL برآورد .(LS روش‌های سیمپلکس کران‌دار وقتی رأس‌ها روی یک کران فشرده شوند ممکن است تباهیده (degenerate) شوند. دو بررسی سریع این را لو می‌دهند: برآوردی که دقیقاً روی یک کران نشسته، و یک «MLE» که NLL آن از مقادیر پارامتر دیگری که امتحان کرده‌اید بیشتر است. multi-start (هفته‌ی ۳) درمان کلی آن است.

حالا برازش مطلق را با انحراف ارزیابی کنید:

Code · **کد:** `code/week04.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
exp: G2 =  26.27, df = 6, p = 0.0002
pow: G2 =   6.31, df = 6, p = 0.3895
```

تفسیر: عدم برازش مدل نمایی خیلی بیشتر از آن است که نویز دوجمله‌ای اجازه می‌دهد ($p = .0002$): می‌توانیم آن را به‌عنوان توصیف این داده‌ها **رد کنیم**. عدم برازش مدل توانی با نویز نمونه‌گیری سازگار است. این ثابت نمی‌کند که مدل درستی است؛ یعنی این داده‌ها دلیلی برای رد آن نمی‌دهند.

Code · **کد:** `code/week04.py`، cell ۵ · سلول ۵

بخش C: MLE گاوسی همان کمترین مربعات است (۱۵ دقیقه)

نسبت‌ها را پیوسته در نظر بگیرید و نویز گاوسی با σ آزاد (پارامتر سوم) فرض کنید. برآوردهای A و d باید با کمترین مربعات یکی باشند و $\hat{\sigma}$ باید برابر $\sqrt{\mathrm{SSE}/N}$ باشد.

Code · **کد:** `code/week04.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
Gaussian MLE: A = 0.8712, d = 0.4251, sigma = 0.0569
Least squares: A = 0.8711, d = 0.4251, sqrt(SSE/N) = 0.0569
```

بخش D: یک مدل SDT چندشرطی مقیدشده (۳۵ دقیقه)

آزمایش. شرکت‌کننده‌ها یک صدای ضعیف را تحت سه طرح پاداش تشخیص می‌دهند: liberal (پاداش برای hit، **خنثی** و **محافظه‌کار** (جریمه برای false alarm) در هر شرط ۸۰ trial علامت و ۸۰ trial نویز. یک شرکت‌کننده را شبیه‌سازی می‌کنیم که حساسیتش در همه‌ی شرایط یکسان است و ملاکش با پاداش جابه‌جا می‌شود.

Code · **کد:** `code/week04.py`، cell ۷ · سلول ۷

خروجی مورد انتظار:

```
      condition  hits  n_signal  fas  n_noise
0       liberal    73        80   33       80
1       neutral    58        80   16       80
2  conservative    44        80    7       80

Shared d':   d' = 1.496, c = [-0.555  0.124  0.618], NLL = 13.134
Separate d': d' = [1.577 1.439 1.482], c = [-0.568  0.122  0.615], NLL =
 ↪  13.043

Likelihood-ratio statistic = 0.18, df = 2, p = 0.913
```

دقت کنید که `d'` برآوردشده (حدود ۵.۱) از مقدار تولیدکننده‌ی ۲.۱ بیشتر است. با ۸۰ trial در هر خانه این یک خطای نمونه‌گیری عادی است. هفته‌ی ۵ نشان می‌دهد چطور دور آن بازه‌ی اطمینان بسازیم.

تفسیر (در notebook بنویسید): ۱. آیا مقید کردن d' به برابری در همه‌ی شرایط پاداش درست‌نمایی زیادی را هزینه می‌کند؟ درباره‌ی اثر پاداش‌ها چه نتیجه‌ای می‌گیرید؟ ۲. برآوردهای d' جداگانه چند دهم با هم فرق دارند. چرا این شاهدی بر اینکه پاداش حساسیت را تغییر می‌دهد نیست؟ ۳. بررسی کنید که مدل d' جداگانه نرخ‌های hit و false alarm مشاهده‌شده را دقیقاً بازتولید می‌کند. چرا باید این‌طور باشد؟

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. MLE θ را برای یک دنباله‌ی برنولی با y موفقیت در n trial با دست استخراج کنید و آن را برای $y = 13$، $n = 40$ با `minimize_scalar` عددی بررسی کنید.

تمرین ۲ ⋆. در بخش B، هر دو مدل را با درست‌نمایی **برنولی** روی داده‌ی سطح آیتم دوباره برازش کنید (هر شمارش را به پاسخ‌های ۰/۱ باز کنید). نشان دهید برآوردها با برازش‌های دوجمله‌ای یکسان‌اند و NLLها به اندازه‌ی یک ثابت فرق دارند. آن ثابت چیست؟

تمرین ۳ ⋆⋆ (شمارش صفر). دو شمارش آخر را ۰ کنید (`recalled[-2:]=0`). کدام روش‌های برازش هفته‌های ۲–۴ هنوز کار می‌کنند؟ هر دو مدل را با MLE برازش کنید و درباره‌ی آنچه بر سر برآوردها و G^2 می‌آید توضیح دهید.

تمرین ۴ ⋆⋆ (یک مدل SDT سوم). مدلی را برازش کنید که در آن ملاک در همه‌ی شرایط یکسان است ولی d' فرق دارد ($k = 4$). NLL آن را با مدل d' مشترک مقایسه کنید. هر دو $k = 4$ دارند؛ چرا اینجا می‌توانید مستقیماً با NLL مقایسه کنید؟ کدام برای یک دست‌کاری پاداش از نظر روان‌شناختی معقول‌تر است؟

تمرین ۵ ⋆⋆⋆ (پیشرفته: LS در برابر MLE با شبیه‌سازی). ۵۰۰ مجموعه‌داده از مدل توانی ($A = 0.9$، $d = 0.5$، همان ۸ فاصله، $n = 50$) شبیه‌سازی کنید، هرکدام را با LS و با MLE برازش کنید و دو برآوردگر d را مقایسه کنید: میانگین (سوگیری)، انحراف معیار، و ریشه‌ی میانگین مربع خطا. کدام اینجا بهتر است؟ با $n = 10$ تکرار کنید. (آمادگی خوبی برای A2 است.)

lab check-off

نشان دهید: (۱) جدول LS در برابر MLE و نتایج G^2 از بخش B، (۲) مقایسه‌ی گاوسی در برابر LS از بخش C، و (۳) پاسخ‌هایتان به سؤال‌های تفسیری بخش D.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

LLMها با بیشینه‌ی درست‌نمایی آموزش می‌بینند. «cross-entropy loss» که برای آموزش همه‌ی مدل‌های زبانی استفاده می‌شود، همان منفی لگاریتم درست‌نمایی token بعدی است که روی یک corpus متنی عظیم میانگین گرفته شده. پس آموزش یک LLM یک مسئله‌ی MLE با میلیاردها پارامتر است که به جای Nelder–Mead با gradient descent حل می‌شود. دو کمیتی که در مقاله‌های هوش مصنوعی می‌بینید همان کمیت‌های این هفته در لباس دیگرند: loss = NLL برای هر token، و perplexity = $e^{\text{NLL per token}}$، یعنی تعداد مؤثر گزینه‌های هم‌احتمالی که مدل بینشان «سردرگم» است.

ساده‌ترین مدل زبانی، یعنی **مدل** bigram، یک MLE بسته دارد: $P(w_2 \mid w_1) = \text{count}(w_1 w_2)/\text{count}(w_1)$. این مدل یک مشکل آشنا را نشان می‌دهد. هر جفت کلمه‌ای که در آموزش دیده نشده احتمال ۰ می‌گیرد، پس فقط یک جفت تازه درست‌نمایی کل جمله را ۰ می‌کند (NLL = ∞). هموارسازی (smoothing) این را حل می‌کند، همان‌طور که تصحیح log-linear هفته‌ی ۲ مشکل نرخ hit ۱ را حل کرد.

Code · **کد:** `code/week04.py`، cell ۸ · سلول ۸

خروجی مورد انتظار:

```
P(cat | the) = 0.333
'the dog sat on the mat .'   MLE      NLL =  3.584  perplexity =   1.82
'the dog sat on the mat .'   add-one  NLL =  9.537  perplexity =   4.90
'the dog saw the cat .'      MLE      NLL =    inf  perplexity =    inf
'the dog saw the cat .'      add-one  NLL =  9.624  perplexity =   6.85
```

امتحانش کنید (بدون نیاز به API). ⋆ کدام جفت کلمه در «the dog saw the cat .» هرگز در corpus دیده نشده؟ با دست بررسی کنید که MLE برای $P(\text{cat} \mid \text{the})$ برابر ۱/۳ است. ⋆⋆ هموارسازی جمله‌ی آموزشی را کم‌احتمال‌تر می‌کند (NLL از ۶.۳ به ۵.۹) ولی جمله‌ی تازه را ممکن می‌کند. add-one را با $k$add- عوض کنید و k را با cross-validation leave-one-sentence-out انتخاب کنید (پیش‌نمایشی از هفته‌ی ۶). ⋆⋆ بحث: MLE یک مدل bigram corpus آموزشی را تا جای ممکن بازتولید می‌کند. چرا «بیشینه کردن درست‌نمایی روی متن اینترنت» با «یاد گرفتن راست‌گویی» یکی نیست؟

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **«درست‌نمایی احتمال درست بودن پارامترهاست.»** احتمال (چگالی) داده به شرط پارامترهاست. انتگرالش روی $\boldsymbol{\theta}$ برابر ۱ نیست.

۲. **ضرب کردن احتمال‌ها به‌جای جمع کردن لگاریتم‌ها.** حاصل‌ضرب برای تعداد trial واقعی به ۰ سرریز می‌کند (بخش A).

۳. **بیشینه کردن وقتی بهینه‌ساز کمینه می‌کند.** `minimize` به **منفی** لگاریتم درست‌نمایی نیاز دارد. فراموش کردن علامت منفی بهینه‌ساز را به بدترین پارامترها می‌فرستد.

۴. **محدود نکردن احتمال‌ها.** احتمال‌های پیش‌بینی‌شده‌ی دقیقاً ۰ یا ۱ لگاریتم درست‌نمایی $-\infty$ می‌دهند و بهینه‌ساز را از کار می‌اندازند.

۵. **مقایسه‌ی NLL بین مجموعه‌داده‌ها یا کدگذاری‌های مختلف.** NLL به تعداد مشاهدات و ثابت‌ها (مثلاً ضرایب دوجمله‌ای) بستگی دارد. فقط مدل‌هایی را مقایسه کنید که روی همان داده با همان کدگذاری برازش شده‌اند.

۶. **استفاده‌ی پیش‌فرض از کمترین مربعات برای انتخاب‌ها یا شمارش‌ها.** ساختار نویز داده را نادیده می‌گیرد. از درست‌نمایی‌ای استفاده کنید که با نحوه‌ی تولید داده جور باشد.

۷. **خواندن G^2 غیرمعنادار به‌عنوان اثبات درستی مدل.** فقط می‌گوید عدم برازش با این حجم نمونه به‌طور قابل تشخیصی از نویز نمونه‌گیری بیشتر نیست.

۸. **فراموش کردن اینکه مدل اشباع‌شده یا دقیقاً تعیین‌شده همیشه کامل برازش می‌شود** (مثال حل‌شده، مدل d' جداگانه در بخش D). در این حالت برازش کامل بی‌اطلاع است.

۹.۱.۱ خودآزمایی

۱. هرکدام در یک جمله: در یک توزیع احتمال در برابر یک تابع درست‌نمایی چه چیزی متغیر و چه چیزی ثابت است؟ **پاسخ** احتمال: پارامترها ثابت، داده متغیر، و جمع/انتگرالش روی داده ۱ است. درست‌نمایی: داده روی مقادیر مشاهده‌شده ثابت، پارامترها متغیر، و لازم نیست انتگرالش روی پارامترها ۱ باشد.

۲. دو دلیل برای کار با لگاریتم درست‌نمایی بیاورید. **پاسخ** (۱) عددی: حاصل‌ضرب احتمال‌های زیاد سرریز می‌کند ولی مجموع لگاریتم‌ها نه. (۲) لگاریتم monotone است، پس بیشینه‌کننده عوض نمی‌شود، و مشتق‌گیری و بهینه‌سازی مجموع‌ها راحت‌تر است.

۳. تحت چه فرض‌هایی کمترین مربعات با بیشینه درست‌نمایی معادل است؟ گام کلیدی را نشان دهید. **پاسخ** خطاهای گاوسی مستقل با واریانس برابر σ^2. آن‌وقت $\ell = -\frac{N}{2}\ln(2\pi\sigma^2) - \mathrm{SSE}/(2\sigma^2)$، پس برای هر σ، بیشینه کردن ℓ روی $\boldsymbol{\theta}$ همان کمینه کردن SSE است.

۴. یک مدل ۲ پارامتری روی ۸ خانه‌ی دوجمله‌ای برازش شده و $G^2 = 4.1$ می‌دهد. درجه‌ی آزادی چند است و چه نتیجه‌ای می‌گیرید؟ **پاسخ** $\mathrm{df} = 8 - 2 = 6$. میانگین χ^2_6 برابر ۶ است، پس ۴.۱ کاملاً در دامنه‌ی مورد انتظار از نویز نمونه‌گیری است ($p \approx 0.66$). شاهدی بر عدم برازش نیست، ولی این درستی مدل را ثابت نمی‌کند.

۵. چرا MLE با درست‌نمایی دوجمله‌ای نقاط داده را متفاوت از کمترین مربعات ساده وزن می‌دهد؟ **پاسخ** لگاریتم درست‌نمایی دوجمله‌ای واریانس $f(1-f)/n$ را منعکس می‌کند: نقاطی که پیش‌بینی می‌شود نزدیک ۰ یا ۱ باشند (واریانس کم) دقیق‌تر برازش می‌شوند، و نقاط با n بزرگ‌تر بیشتر حساب می‌شوند. کمترین مربعات ساده همه‌ی مربع خطاها را یکسان وزن می‌دهد.

۶. در آزمایش پاداش، مدل d' مشترک چه فرضیه‌ی روان‌شناختی را بیان می‌کند و چطور آزمونش می‌کنید؟ **پاسخ** اینکه پاداش‌ها فقط سوگیری پاسخ (ملاک) را تغییر می‌دهند، نه حساسیت ادراکی را. با مقایسه‌ی لگاریتم درست‌نمایی بیشینه با مدل d' جداگانه آزمونش کنید: $2(\ell_6 - \ell_4) \sim \chi^2_2$ تقریبی (آزمون نسبت درست‌نمایی)، یا با AIC/BIC (هفته‌ی ۷).

۷. مدلی را برازش می‌کنید و بهینه‌ساز NLL = −۲.۳۵ (منفی) برمی‌گرداند. آیا اشکالی هست؟ **پاسخ** نه لزوماً. برای داده‌ی پیوسته، چگالی‌ها می‌توانند از ۱ بیشتر باشند (مثلاً یک گاوسی باریک)، پس لگاریتم چگالی می‌تواند مثبت و NLL منفی باشد. برای داده‌ی گسسته (دوجمله‌ای) احتمال‌ها ≤ 1 هستند، پس NLL باید ≥ 0 باشد و مقدار منفی نشانه‌ی باگ است.

۱۰.۱.۱ تکلیف

A2: کمترین مربعات در برابر بیشینه درست‌نمایی (۱۰ نمره از ۲۰؛ انتشار هفته‌ی ۴، موعد ابتدای درس هفته‌ی ۶)

داده. مجموعه‌داده را دقیقاً با این کد بسازید (همه داده‌ی یکسانی می‌گیرند):

> Code ۰ **کد:** `code/week04.py`، cell ۹ ۰ سلول ۹

کارها.

۱. **برازش (۲ امتیاز).** مدل‌های نمایی و توانی را روی این داده‌ها با (الف) کمترین مربعات روی نسبت‌ها و (ب) MLE دوجمله‌ای برازش کنید. همه‌ی برآوردها را با SSE و NLL در یک جدول گزارش کنید.

۲. **ارزیابی (۲ امتیاز).** G^2، درجه‌ی آزادی و p را برای برازش MLE هر مدل حساب کنید. داده‌ها را با بازه‌های ۹۵٪ دوجمله‌ای، هر دو منحنی برازش‌شده، و باقی‌مانده‌ها رسم کنید. کدام مدل (اگر هست) قابل رد است؟

۳. **مطالعه‌ی شبیه‌سازی (۳ امتیاز).** مدل توانی با $A = 0.95$، $d = 0.7$ را مدل واقعی در نظر بگیرید. ۵۰۰ مجموعه‌داده با همین طرح شبیه‌سازی کنید، هرکدام را با LS و MLE برازش کنید و سوگیری، انحراف معیار و RMSE برآورد $\hat{d}$ را برای هر روش گزارش کنید. هیستوگرام‌ها را نشان دهید. با $n = 100$ آیتم تکرار کنید و بگویید چه تغییر می‌کند.

۴. **تفسیر (۲ امتیاز، حداکثر ۳۰۰ کلمه).** برای داده‌های یادآوری کدام برآوردگر را توصیه می‌کنید و چرا؟ جوابتان را به ساختار نویز داده‌های دوجمله‌ای و به شمارش‌های نزدیک به کف (۱ تا ۲ از ۲۰) در طولانی‌ترین فاصله‌ها ربط دهید. اگر یکی از آن شمارش‌ها ۰ بود، چه بر سر روش خطی‌سازی هفته‌ی ۲ می‌آمد؟

۵. **کیفیت کد (۱ امتیاز).** notebook قابل بازتولید و با توضیح؛ seedها ثابت؛ توابع دوباره استفاده شوند نه کپی.

برای تحویل با تأخیر، روزی ۱۰٪ کسر می‌شود (حداکثر ۳ روز).

۱۱.۱.۱ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۴.** برآورد پارامتر با بیشینه درست‌نمایی: توابع درست‌نمایی برای انواع رایج داده، لگاریتم درست‌نمایی و برازش در عمل. (منبع اصلی.)
- **عظیمی‌فر و احمدی (۱۳۹۶)**، شناسایی آماری الگو، جلد ۱: بخش برآورد پارامتر با بیشینه درست‌نمایی، با نگاه یادگیری آماری [شماره‌ی فصل بررسی شود].
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۳.** استنباط با توزیع دوجمله‌ای. الان برای چیدمان دوجمله‌ای بخوانید؛ در هفته‌ی ۹ از سمت بیزی دوباره به آن برمی‌گردیم.

پیش‌نمایش هفته‌ی ۵: برآورد بدون عدم قطعیت نصف یک نتیجه است. خطاهای استاندارد و بازه‌های اطمینان را از انحنای درست‌نمایی و با bootstrap حساب می‌کنیم، و کشف می‌کنیم که چطور میانگین‌گیری از شرکت‌کننده‌ها می‌تواند «قانونی» بسازد که هیچ فردی از آن پیروی نمی‌کند.