مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۵: عدم قطعیت برآوردها و برازش برای چند شرکت‌کننده

فهرست مطالب

۱ روش‌های برآورد پارامتر **۱**

۱.۱ هفته‌ی ۵: عدم قطعیت برآوردها و برازش برای چند شرکت‌کننده ۱

۱.۱.۱ واژه‌های کلیدی ۱

۲.۱.۱ اهداف یادگیری ۲

۳.۱.۱ مقدمه ۳

۴.۱.۱ جزوه‌ی درس ۳

۵.۱.۱ مثال حل‌شده ۸

۶.۱.۱ lab (۲ ساعت) ۸

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها ۱۰

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست ۱۰

۹.۱.۱ خودآزمایی ۱۱

۱۰.۱.۱ تکلیف ۱۱

۱۱.۱.۱ مطالعه‌ی بیشتر ۱۱

فصل ۱

روش‌های برآورد پارامتر

۱.۱ هفته‌ی ۵: عدم قطعیت برآوردها و برازش برای چند شرکت‌کننده

فصل ۲: روش‌های برآورد پارامتر · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌های فراموشی هفته‌های ۲–۴ (برآوردهای ما چقدر قطعی‌اند؟) و یک آزمایش **تمرین** (practice) شبیه‌سازی‌شده‌ی جدید با ۲۰ شرکت‌کننده (قانون توانی تمرین).

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

جدول ۱.۱: واژه‌های کلیدی

English	فارسی	توضیح کوتاه
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
power law of practice	قانون توانی تمرین	کاهش توانی زمان واکنش با تمرین
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
sampling distribution	توزیع نمونه‌گیری	توزیع برآورد در تکرارهای فرضی آزمایش

English	فارسی	توضیح کوتاه
standard error (SE)	خطای استاندارد	پراکندگی برآورد در تکرارهای فرضی آزمایش
confidence interval (CI)	بازه‌ی اطمینان	بازه‌ای که با روش مشخص پارامتر واقعی را در بر می‌گیرد
Hessian	ماتریس Hessian	ماتریس مشتق‌های دوم؛ انحنای درست‌نمایی
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
Wald interval	بازه‌ی Wald	برآورد $\pm$ ۹۶.۱ SE
profile likelihood	درست‌نمایی نیم‌رخ (profile)	درست‌نمایی یک پارامتر با بهینه کردن بقیه
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
bootstrap	bootstrap (بازنمونه‌گیری)	تخمین عدم قطعیت با شبیه‌سازی یا بازنمونه‌گیری
parameter trade-off	بده‌بستان پارامترها	تغییر یک پارامتر که با پارامتر دیگر جبران می‌شود
aggregation artifact	خطای ناشی از میانگین‌گیری	الگویی در میانگین که در هیچ فردی نیست
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
constraints / bounds	کران‌ها / قیدها	محدودیت‌های مجاز برای مقدار پارامترها
accuracy	دقت	نسبت پاسخ‌های درست
partial pooling / no / complete	ادغام کامل / بدون ادغام / ادغام جزئی (pooling)	یک پارامتر برای همه / جدا برای هر فرد / سلسله‌مراتبی
individual differences	تفاوت‌های فردی	فرق پارامترها بین افراد
noise	نویز	تغییرات تصادفی در شواهد یا در داده
benchmark	benchmark (مجموعه‌آزمون استاندارد)	مجموعه سؤال برای مقایسه‌ی مدل‌های هوش مصنوعی

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. توزیع نمونه‌گیری (sampling distribution) یک برآوردگر را **توضیح دهند** و خطای استاندارد (SE) را از انحراف معیار داده‌ها **متمایز کنند**.
۲. خطاهای استاندارد و بازه‌های اطمینان پارامترهای مدل را به سه روش **حساب کنند**: از Hessian تابع NLL (روش Wald)، از profile likelihood و با bootstrap پارامتری؛ و این سه روش را **مقایسه کنند**.
۳. trade-off پارامترها را از همبستگی برآوردشده بین پارامترها **تشخیص دهند**.

۴. با شبیه‌سازی **نشان دهند** که میانگین‌گیری از منحنی‌های فردی می‌تواند شکل تابعی‌ای (یک «قانون توانی») بسازد که هیچ فردی از آن پیروی نمی‌کند.
۵. بین برازش تجمیعی، فردی و (پیش‌نمایش) سلسله‌مراتبی **انتخاب کنند** و انتخابشان را **توجیه کنند**.

۳.۱.۱ مقدمه

«$\hat{d} = 0.42$» نصف یک نتیجه است. هفته‌ی قبل MLE مدل توانی برای داده‌های هفته‌ی ۲ برابر $\hat{d} = 0.42$ بود (مقدار واقعی ۰.۵). آیا ۴۲.۰ با ۵.۰ سازگار است؟ با ۳.۰؟ با ۶.۰؟ بدون یک معیار عدم قطعیت نمی‌توانیم بگوییم دو شرکت‌کننده، دو گروه یا دو شرط واقعاً با هم فرق دارند یا نه. از این به بعد هر برآورد پارامتری که گزارش می‌کنیم با یک بازه‌ی اطمینان همراه است.

قانونی که هیچ‌کس از آن پیروی نمی‌کند. قانون توانی تمرین (power law of practice) یکی از پرارجاع‌ترین یافته‌ها در روان‌شناسی شناختی است: زمان واکنش با تمرین تقریباً به شکل تابع توانی از تعداد trialها کم می‌شود. اگر این‌طور باشد، «قانون» میانگین را توصیف می‌کند ولی هیچ یادگیرنده‌ی تکی را نه، و نظریه‌ای که برای توضیح یک تابع توانی در ذهن هر فرد ساخته شود در واقع یک خطای ناشی از میانگین‌گیری را توضیح می‌دهد. این هفته این اثر را با داده‌ی شبیه‌سازی‌شده نشان می‌دهیم و یاد می‌گیریم کی باید افراد را برازش کرد نه میانگین گروه را.

این موضوع کجا به کار می‌رود؟

- **هر ادعای تفاوت** («بیماران سریع‌تر از گروه کنترل فراموش می‌کنند»، «آموزش حساسیت را بالا برد») به برآورد عدم قطعیت نیاز دارد. بدون آن، تفاوت ۰.۵۰ در یک پارامتر ممکن است فقط نویز باشد.
- **ارزیابی بالینی یک فرد:** برای اینکه بگوییم سرعت فراموشی یک بیمار غیرعادی است، به خطای استاندارد برآورد همان بیمار نیاز داریم، نه فقط میانگین گروه.
- **پژوهش یادگیری و مهارت:** «قانون توانی تمرین» مدت‌ها یک قانون همگانی حساب می‌شد. خطای ناشی از میانگین‌گیری این هفته نشان می‌دهد چرا امروز پژوهشگرها یادگیرنده‌ها را جداگانه برازش می‌کنند (و چرا همین احتیاط درباره‌ی منحنی‌های میانگین گروه در آموزش، علوم ورزشی و ارگونومی هم لازم است).

۴.۱.۱ جزوه‌ی درس

به زبان ساده اگر همان آزمایش را دوباره روی همان آدم اجرا کنید، داده‌ی کمی متفاوت و در نتیجه برآورد پارامتر کمی متفاوتی می‌گیرید. **خطای استاندارد** (SE) می‌گوید برآورد بین چنین تکرارهایی چقدر بالا و پایین می‌پرد؛ **بازه‌ی اطمینان** محدوده‌ای است که از روی آن ساخته می‌شود (تقریباً برآورد $\pm$ ۲ SE). نمی‌توانیم آزمایش را بارها تکرار کنیم، پس این پرش را به سه روش تخمین می‌زنیم: (۱) از اینکه قله‌ی درست‌نمایی چقدر تیز است (قله‌ی تیز یعنی داده پارامتر را دقیق تعیین می‌کند؛ نیمه‌ی دوم هفته درباره‌ی یک دام هشدار می‌دهد: میانگین گرفتن داده‌ها روی افراد می‌تواند شکلی از منحنی بسازد که **هیچ فردی** آن را ندارد. اگر هر یادگیرنده به‌طور نمایی ولی با سرعتی متفاوت بهتر شود، میانگین گروه شبیه قانون توانی می‌شود.

زمان‌بندی پیشنهادی (۶۰ دقیقه): توزیع‌های نمونه‌گیری ۱۰ · خطای استاندارد از Hessian ۱۵ · profile likelihood ۸ · bootstrap ۱۰ · چند شرکت‌کننده و میانگین‌گیری ۱۷.

۱. برآوردها توزیع نمونه‌گیری دارند

اگر همان آزمایش را روی همان شرکت‌کننده (با همان θ^* واقعی) تکرار می‌کردیم، داده‌ی متفاوت و در نتیجه $\hat{\boldsymbol{\theta}}$ متفاوتی می‌گرفتیم. توزیع $\hat{\boldsymbol{\theta}}$ روی تکرارهای فرضی، **توزیع نمونه‌گیری** آن است.

- **خطای استاندارد** (SE) یک پارامتر، انحراف معیار توزیع نمونه‌گیری‌اش است: اینکه برآورد بین تکرارها چقدر تغییر می‌کند.
- یک **بازه‌ی اطمینان ٪۹۵** با رویه‌ای ساخته می‌شود که در تکرارها، در ٪۹۵ موارد θ^* را در بر می‌گیرد. (این نه به معنای «احتمال ٪۹۵ که θ^* در همین بازه‌ی مشخص باشد» است؛ آن یک credible interval بیزی است، هفته‌ی ۹.)

نمی‌توانیم آزمایش را بارها تکرار کنیم، پس توزیع نمونه‌گیری را به سه روش تقریب می‌زنیم.

۲. خطای استاندارد از انحنای درست‌نمایی (Wald)

شهود. اگر NLL یک کمینه‌ی تیز و باریک داشته باشد، تغییرات کوچک در $\boldsymbol{\theta}$ داده‌ها را خیلی کم‌احتمال‌تر می‌کنند، پس داده‌ها $\boldsymbol{\theta}$ را دقیق تعیین می‌کنند. یک کمینه‌ی پهن و تخت یعنی مقادیر زیادی تقریباً به یک اندازه خوب برازش می‌شوند، پس عدم قطعیت زیاد است. انحنا با مشتق‌های دوم اندازه‌گیری می‌شود.

صورت‌بندی. Hessian تابع NLL در نقطه‌ی MLE ماتریس مشتق‌های دوم است،

$$\mathbf{H}_{mn} = \left.\frac{\partial^2 \operatorname{NLL}(\boldsymbol{\theta})}{\partial\theta_m\,\partial\theta_n}\right|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}},$$

که به آن **اطلاع فیشر مشاهده‌شده** (observed Fisher information) هم می‌گویند. برای نمونه‌های بزرگ:

$$\widehat{\operatorname{Cov}}(\hat{\boldsymbol{\theta}}) \approx \mathbf{H}^{-1}, \qquad \operatorname{SE}(\hat{\theta}_m) = \sqrt{[\mathbf{H}^{-1}]_{mm}}, \qquad 95\%\text{ Wald CI: } \hat{\theta}_m \pm 1.96\,\operatorname{SE}(\hat{\theta}_m).$$

عناصر غیرقطری $\mathbf{H}^{-1}$، وقتی به همبستگی تبدیل شوند، trade-off **پارامترها** را نشان می‌دهند: همبستگی -۹.۰ بین دو برآورد یعنی خطاهایشان تا حد زیادی همدیگر را جبران می‌کنند (همان دره‌ی مورب هفته‌ی ۳).

بررسی درستی (دوجمله‌ای). برای یک نسبت، $\operatorname{NLL}''(\theta) = y/\theta^2 + (n-y)/(1-\theta)^2$. در $\hat{\theta} = y/n$ این برابر $n/[\hat{\theta}(1-\hat{\theta})]$ است، پس $\operatorname{SE} = \sqrt{\hat{\theta}(1-\hat{\theta})/n}$؛ همان فرمول آشنای کتاب‌های درسی.

در عمل: $\mathbf{H}$ را عددی با تفاضل‌های متناهی حساب کنید (بخش A lab).

وقتی Wald جواب نمی‌دهد: نمونه‌های کوچک، برآوردهای نزدیک یک کران (مثلاً سطح یادآوری $\hat{A}$ نزدیک ۱)، درست‌نمایی‌هایی که شدیداً غیرمربعی‌اند، یا پارامترهایی با توزیع نمونه‌گیری چوله (نرخ‌ها، واریانس‌ها). در این حالت‌ها بازه‌ی متقارن $\operatorname{SE} \pm 1.96$ ممکن است تا مقادیر ناممکن کشیده شود.

> **پیشرفته: چرا این کار می‌کند.** نزدیک کمینه، هر NLL همواری تقریباً مربعی است (بسط تیلور مرتبه‌ی دوم). یک NLL مربعی دقیقاً NLL یک توزیع نرمال چندمتغیره است که معکوس کوواریانسش همان Hessian است. همراه با نرمال بودن مجانبی MLE (هفته‌ی ۴)، این نتیجه را می‌دهد. همین تقریب مربعی، به نام تقریب *Laplace*، در مقایسه‌ی بیزی مدل‌ها (هفته‌ی ۱۰) دوباره ظاهر می‌شود.

خواندن ریاضی

- $\mathbf{H}_{mn} = \partial^2\operatorname{NLL}/\partial\theta_m\partial\theta_n$ در نقطه‌ی $\hat{\boldsymbol{\theta}}$: ماتریس مشتق‌های دوم، یعنی **انحنای** کاسه‌ی NLL در کف آن. درایه‌های قطری: کاسه در امتداد هر پارامتر چقدر شیب‌دار است. درایه‌های غیرقطری: آیا کاسه کج است (پارامترها trade-off دارند).

- $\widehat{\mathrm{Cov}}(\hat{\boldsymbol{\theta}}) \approx \mathbf{H}^{-1}$: کاسه‌ی خیلی خمیده ($\mathbf{H}$ بزرگ) کوواریانس کوچک می‌دهد، یعنی برآورد دقیق. معکوس گرفتن همان چیزی است که «شیب‌داری» را به «عدم قطعیت» تبدیل می‌کند.
- $\mathrm{SE}(\hat{\theta}_m) = \sqrt{[\mathbf{H}^{-1}]_{mm}}$: درایه‌ی قطری mام ماتریس معکوس را بردارید و از آن جذر بگیرید.
- **بررسی با یک پارامتر:** برای یک نسبت، $\mathrm{NLL}'' = n/[\hat{\theta}(1-\hat{\theta})]$، پس $\mathrm{SE} = \sqrt{\hat{\theta}(1-\hat{\theta})/n}$. با ۳۰ از ۵۰: $\sqrt{0.6 \times 0.4/50} = 0.069$ و بازه‌ی ۹۵٪ برابر $0.60 \pm 1.96 \times 0.069 = [0.46, 0.74]$ است.
- **همبستگی از کوواریانس:** $\mathrm{corr} = \mathrm{Cov}_{12}/(\mathrm{SE}_1\mathrm{SE}_2)$. مقداری مثل -۰.۹ یعنی دو برآورد به‌شدت trade-off دارند.

۳. بازه‌های profile likelihood

برای پارامتر مورد نظر ψ (مثلاً d)، NLL profile با ثابت گرفتن ψ روی یک شبکه و کمینه کردن NLL روی همه‌ی پارامترهای دیگر در هر نقطه‌ی شبکه به دست می‌آید:

$$\mathrm{NLL}_{\mathrm{prof}}(\psi) = \min_{\text{other params}} \mathrm{NLL}(\psi, \text{others}).$$

بازه‌ی نسبت درست‌نمایی (profile) ۹۵٪، مجموعه‌ی مقادیری از ψ است که خیلی بدتر از بهترین نیستند:

$$\left\{\psi : 2\left[\mathrm{NLL}_{\mathrm{prof}}(\psi) - \mathrm{NLL}_{\min}\right] \le 3.84\right\}, \qquad 3.84 = \chi^2_{1,\,0.95}.$$

بازه‌های profile شکل واقعی درست‌نمایی را دنبال می‌کنند، پس می‌توانند **نامتقارن** باشند و کران‌های طبیعی را رعایت کنند. در نمونه‌های کوچک معمولاً از بازه‌های Wald دقیق‌ترند.

خواندن ریاضی

- $\mathrm{NLL}_{\mathrm{prof}}(\psi)$: پارامتر مورد نظر ψ را روی یک مقدار ثابت کنید، بگذارید بهینه‌ساز بهترین مقدار همه‌ی پارامترهای دیگر را انتخاب کند، و NLL حاصل را ثبت کنید. برای مقدارهای زیادی از ψ تکرار کنید. نتیجه یک منحنی یک‌بعدی است.
- بازه هر ψای را نگه می‌دارد که NLL نیم‌رخ آن حداکثر $3.84/2 = 1.92$ واحد بالاتر از کمینه باشد. عدد ۸۴.۳ نقطه‌ی ۹۵٪ توزیع χ^2 با ۱ درجه‌ی آزادی است و از آزمون نسبت درست‌نمایی می‌آید (هفته‌ی ۷).
- برخلاف Wald، این منحنی مجبور نیست سهمی متقارن باشد، پس بازه می‌تواند نامتقارن باشد و هیچ‌وقت تا مقدارهای ناممکن کشیده نمی‌شود.

۴. bootstrap پارامتری

جوابی شبیه‌سازی‌محور به «اگر آزمایش را تکرار می‌کردیم چه؟»:

۱. مدل را روی داده برازش کنید: $\hat{\boldsymbol{\theta}}$.
۲. B مجموعه‌داده‌ی جدید از مدل با $\hat{\boldsymbol{\theta}}$ و با همان طرح آزمایش واقعی شبیه‌سازی کنید.
۳. هر مجموعه‌داده را دوباره برازش کنید: $\hat{\boldsymbol{\theta}}^{*(1)}, \ldots, \hat{\boldsymbol{\theta}}^{*(B)}$.
۴. انحراف معیار برآوردهای bootstrap تقریب SE است. صدک‌های ۵.۲ و ۵.۹۷ یک **بازه‌ی اطمینان صدکی** (percentile CI) می‌دهند.

bootstrap به مشتق نیاز ندارد، برای هر آماره‌ای کار می‌کند (مثلاً نیمه‌عمر یا تفاوت دو شرط)، و شکل کامل و همبستگی‌های توزیع نمونه‌گیری را نشان می‌دهد. هزینه‌اش B بار برازش است ($B \approx 500$ تا 2000). bootstrap **ناپارامتری** به‌جای شبیه‌سازی از مدل، trialهای مشاهده‌شده را با جایگذاری بازنمونه‌گیری می‌کند.

مقایسه:

جدول ۲.۱: 4. bootstrapپارامتری

روش	هزینه	متقارن؟	کران را رعایت می‌کند؟	نیاز دارد به
Wald (Hessian)	یک Hessian	همیشه	نه	NLL هموار، N بزرگ
profile likelihood	یک برازش برای هر نقطه‌ی شبکه	می‌تواند نامتقارن باشد	بله	یک درست‌نمایی
bootstrap پارامتری	B برازش	می‌تواند نامتقارن باشد	بله	مدلی که بتوانید شبیه‌سازی کنید

۵. برازش برای چند شرکت‌کننده

آزمایش‌های واقعی J شرکت‌کننده دارند (اندیس j). سه راهبرد کلی وجود دارد:

جدول ۳.۱: ۵. برازش برای چند شرکت‌کننده

راهبرد	چه چیزی برازش می‌شود	مزایا	معایب
تجمیعی (complete pooling)	یک مدل روی داده‌های میانگین‌گیری‌شده	پایدار؛ با trialهای کم برای هر نفر هم کار می‌کند	فرض می‌کند همه یکسان‌اند؛ **می‌تواند شکل تابعی را تحریف کند**
فردی (no pooling)	یک مدل برای هر شرکت‌کننده؛ بعد تحلیل J مجموعه برآورد	تفاوت‌های فردی را رعایت می‌کند؛ روش استاندارد	با trial کم برآوردها پرنویزند؛ تحلیل مرحله‌ی دوم عدم قطعیت برآورد را نادیده می‌گیرد
سلسله‌مراتبی (partial pooling)	پارامترهای فردی از یک توزیع گروهی، که با هم برآورد می‌شوند	بهترینِ هر دو؛ shrinkage اصولی	پیچیده‌تر؛ معمولاً بیزی (هفته‌ی ۱۳)

خطاهای ناشی از میانگین‌گیری. میانگین منحنی‌های غیرخطی معمولاً منحنی‌ای از همان خانواده **نیست**. مثلاً میانگین منحنی‌های نمایی با نرخ‌های متفاوت نمایی نمی‌شود: یادگیرنده‌های سریع زود به پایان می‌رسند، پس نرخ نسبی تغییر میانگین با گذشت زمان کند می‌شود؛ و این دقیقاً ویژگی تعریف‌کننده‌ی تابع توانی است (هفته‌ی ۲، نرخ نسبی فراموشی).

پیشرفته: یک نتیجه‌ی دقیق. فرض کنید هر شرکت‌کننده از $e^{-\lambda_j t}$ پیروی کند و نرخ‌ها بین افراد توزیع Gamma داشته باشند، $\lambda_j \sim \mathrm{Gamma}(\text{shape } s, \text{rate } b)$. آن‌وقت منحنی میانگین گروه برابر است با

$$\mathbb{E}\left[e^{-\lambda t}\right] = \left(1 + \frac{t}{b}\right)^{-s},$$

که دقیقاً یک تابع توانی جابه‌جاشده است (این تابع مولد گشتاور توزیع Gamma در نقطه‌ی $t-$ است). همه به‌طور نمایی فراموش می‌کنند، ولی میانگین با یک قانون توانی با نمای برابر با پارامتر شکل Gamma یعنی s فراموش می‌کند. این را در تمرین ۴ عددی بررسی می‌کنید.

راهنمای عملی. هر وقت هر شرکت‌کننده داده‌ی کافی برای مقید کردن مدل دارد، افراد را برازش کنید؛ داده‌ی تجمیعی را فقط به‌عنوان خلاصه به کار ببرید، هرگز به‌عنوان شاهدی درباره‌ی شکل یک فرایند در سطح فرد. وقتی داده‌های فردی کم است، از مدل‌های سلسله‌مراتبی استفاده کنید (هفته‌ی ۱۳).

برای یک مهندس

- SE **روش** Wald **از** Hessian = معکوس اطلاعات فیشر، یعنی همان CRLB که در نقطه‌ی برآورد محاسبه شده. MLE به‌طور مجانبی به این کران می‌رسد، پس برای N بزرگ بازه‌ی Wald همان بازه‌ی مبتنی بر CRLB است.
- bootstrap **پارامتری** همان ارزیابی کارایی با Monte Carlo است که برای یک تخمین‌گر یا گیرنده انجام می‌دهید (مثلاً شبیه‌سازی تعداد زیادی تحقق نویز برای به دست آوردن واریانس تخمین‌گر یا منحنی BER)، فقط در مقدارهای برازش‌شده‌ی پارامتر.
- profile likelihood همان کاری است که با پارامترهای مزاحم *(nuisance parameters)* می‌کنید: آن‌ها را بهینه کنید و کنار بگذارید و به درست‌نمایی پارامتری که برایتان مهم است نگاه کنید.
- **خطای ناشی از میانگین‌گیری** = تفاوت **میانگین آنسامبل** و **یک تحقق تنها**. میانگین گرفتن از افت‌های نمایی با ثابت‌های زمانی مختلف یک افت کندتر با دنباله‌ی سنگین می‌دهد؛ همان‌طور که میانگین تعداد زیادی تحقق کانال شبیه هیچ تحقق تکی نیست. فرایند «بین افراد ارگودیک» نیست: میانگین گروه، فرد را توصیف نمی‌کند.

برای مدرس

- **با سؤال «آیا ۴۲.۰ با ۵.۰ فرق دارد؟» شروع کنید** (بخش مقدمه). دانشجوها جواب بله/نه می‌خواهند؛ نشان دهید جواب کاملاً به SE بستگی دارد.
- **سه روش را کنار هم نشان دهید** روی همان داده (جدول بخش C lab.).
- **نمایش میانگین‌گیری نقطه‌ی اوج جلسه است.** ۵ منحنی نمایی فردی و میانگین آن‌ها را روی نمودار لگاریتمی–لگاریتمی رسم کنید: میانگین تقریباً یک خط راست است (قانون توانی) در حالی که هر منحنی فردی خمیده است. از کلاس بپرسید پژوهشگری که فقط میانگین را دیده چه نتیجه‌ای می‌گیرد.
- **سؤال‌های رایج.**
  - «فرق *SD* و *SE* چیست؟» SD پراکندگی داده‌ها را توصیف می‌کند؛ SE پراکندگی یک برآورد در تکرارهای آزمایش را. SE با داده‌ی بیشتر کم می‌شود؛ SD نه.
  - «آیا یک بازه‌ی اطمینان ٪۹۵ با احتمال ۹۵.۰ مقدار واقعی را دارد؟» این بازه‌ی مشخص نه؛ ٪۹۵ بازه‌هایی که به این روش ساخته می‌شوند آن را دارند. credible interval) بیزی هفته‌ی ۹ همین تفسیر مستقیم را دارد.)
  - «آیا همیشه باید افراد را جداگانه برازش کنم؟» بله، اگر هر نفر داده‌ی کافی دارد؛ وگرنه از مدل‌های سلسله‌مراتبی استفاده کنید (هفته‌ی ۱۳).

۵.۱.۱ مثال حل‌شده

بخش ۱: سه بازه برای یک احتمال یادآوری

یک شرکت‌کننده $y = 30$ از $n = 50$ آیتم را به یاد می‌آورد؛ $\hat{\theta} = 0.60$.

Wald. $\mathrm{SE} = \sqrt{0.6 \times 0.4/50} = 0.0693$، پس بازه‌ی اطمینان ۹۵٪ برابر $0.60 \pm 1.96 \times 0.0693 = [0.464, 0.736]$ است.

profile **(نسبت درست‌نمایی).** معادله‌ی $2[\ell(0.6) - \ell(\theta)] = 3.84$ را در دو طرف ۶.۰ عددی حل کنید. بازه‌ی ۹۵٪ برابر $[0.462, 0.728]$ است که کمی **نامتقارن** است: ۱۳۸.۰ پایین‌تر از برآورد و ۱۲۸.۰ بالاتر از آن می‌رود، چون درست‌نمایی به سمت ۵.۰، جایی که واریانس دوجمله‌ای بیشینه است، چوله است.

تفسیر. با ۵۰ آیتم، یک احتمال یادآوری فقط تا حدود $\pm$۱۳.۰ معلوم است. تفاوت ۱۰.۰ بین دو شرط با این اندازه به‌تنهایی قانع‌کننده نیست.

بخش ۲: میانگین‌گیری از دو یادگیرنده‌ی نمایی

شرکت‌کننده‌ی ۱ با $\lambda = 0.1$ و شرکت‌کننده‌ی ۲ با $\lambda = 1.0$ فراموش می‌کند. منحنی میانگین $\bar{f}(t) = (e^{-0.1t} + e^{-t})/2$:

جدول ۴.۱: بخش ۲: میانگین‌گیری از دو یادگیرنده‌ی نمایی

t	۰	۱	۲	۵	۱۰
$\bar{f}(t)$	۰۰۰.۱	۶۳۶.۰	۴۷۷.۰	۳۰۷.۰	۱۸۴.۰
نرخ نسبی فراموشی $-\bar{f}'(t)/\bar{f}(t)$	۵۵.۰	۳۶.۰	۲۳.۰	۱۱.۰	۱۰.۰

هر شرکت‌کننده یک نرخ نسبی ثابت دارد (۱.۰ و ۰.۱)، ولی نرخ میانگین از ۵۵.۰ به ۱۰.۰ **کاهش** می‌یابد؛ نشانه‌ی یک منحنی شبه‌توانی. دلیل: در زمان‌های بعدی، فراموش‌کننده‌ی کند که نرخش پایین است بر میانگین غالب است. **تفسیر:** پژوهشگری که فقط میانگین را برازش کند نتیجه می‌گیرد که «خاطره‌ها با بالا رفتن سن مقاوم‌تر می‌شوند»؛

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. محاسبه‌ی بازه‌های Wald، profile و bootstrap برای مدل توانی برازش‌شده روی داده‌های هفته‌ی ۲ و مقایسه‌ی آن‌ها.
۲. نمایش trade-off پارامترها از طریق همبستگی برآوردشده و ابر نقاط bootstrap.
۳. شبیه‌سازی ۲۰ یادگیرنده‌ی نمایی، برازش مدل‌های نمایی و توانی روی **میانگین** و روی **هر فرد**، و تفسیر تناقض.

زمان‌بندی: بخش A ۲۰ دقیقه · بخش B ۱۵ دقیقه · بخش C ۲۵ دقیقه · بخش D ۴۰ دقیقه · بخش E ۲۰ دقیقه.

بخش A: خطای استاندارد Wald از یک Hessian عددی (۲۰ دقیقه)

تفسیر: هر دو بازه‌ی ۹۵٪ مقادیر واقعی ($A^* = 0.9$، $d^* = 0.5$) را در بر دارند، پس «خطایی» که در هفته‌های ۳–۴ نگرانش بودیم کاملاً در حد خطای نمونه‌گیری است. دقت کنید که بازه‌ی Wald برای A اتفاقاً درست روی ۰.۰۰۰۱، یعنی مرز مقادیر ممکن، تمام می‌شود. با داده‌ای کمی پرنویزتر، بازه‌ی متقارن Wald مقادیر ناممکن (احتمال بیشتر از ۱) را هم شامل می‌شد، در حالی که بازه‌ی bootstrap نمی‌تواند. همبستگی مثبت همان دره‌ی trade-off هفته‌ی ۳ است: وقتی برآورد A زیادی بالاست، برآورد d هم معمولاً زیادی بالاست.

بخش C: bootstrap پارامتری (۲۵ دقیقه)

مقایسه کنید: بازه‌های Wald، profile و bootstrap برای d را کنار هم بگذارید. شبیه هم‌اند؟ با این داده‌ها (۸ خانه × ۵۰ آیتم) هر سه روش باید نسبتاً با هم توافق داشته باشند. با آیتم‌های کمتر یا برآوردهای نزدیک کران بیشتر از هم فاصله می‌گیرند (تمرین ۵).

بخش D: قانون توانی تمرین به‌عنوان خطای میانگین‌گیری (۴۰ دقیقه)

هر شرکت‌کننده به‌طور **نمایی** بهتر می‌شود: $J = 20$

$$\mathrm{RT}_j(m) = E + B\, e^{-r_j (m-1)} + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, 40\ \text{ms}),$$

با مجانب $E = 400$ ms، بهبود اولیه‌ی $B = 600$ ms و نرخ‌های یادگیری فردی $r_j \sim \mathrm{Gamma}(\text{shape} = 0.7, \text{scale} = 0.5)$ (میانگین ۳۵۰ در هر بلوک؛ توزیعی چوله با چند یادگیرنده‌ی خیلی سریع و چند یادگیرنده‌ی خیلی کند). اینجا m شماره‌ی بلوک تمرین و ε نویز میانگین زمان واکنش هر بلوک است.

بخش E: تفسیر (۲۰ دقیقه)

۲. چرا نرخ نمایی برازش‌شده روی منحنی میانگین از میانگین نرخ‌های فردی کوچک‌تر است؟ اینجا با ۶۰ بلوک برای هر نفر، برازش‌های فردی نرخ‌های واقعی را خوب بازیابی می‌کنند. با فقط ۱۰ بلوک برای هر نفر چه تغییر می‌کرد و آن‌وقت چه می‌کردید؟ (پیش‌نمایش هفته‌ی ۱۳.)

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. بازه‌های اطمینان ۹۵٪ Wald را برای MLE مدل نمایی روی داده‌های هفته‌ی ۲ حساب کنید. آیا مقادیر معقولی در بر دارند؟ در نقطه‌ای که کمینه نیست چه بر سر Hessian می‌آید؟

تمرین ۲ ⋆. bootstrap را با $B = 50, 200, 1000$ و seedهای مختلف دوباره اجرا کنید. حدود صدکی چقدر پایدارند؟ برای یک بازه‌ی ۹۵٪، B چقدر باید بزرگ باشد؟

تمرین ۳ ⋆⋆ **(یک کمیت مشتق‌شده).** با نمونه‌های bootstrap بخش C یک بازه‌ی ۹۵٪ برای **نیمه‌عمر** مدل توانی، $t_{1/2} = 2^{1/d} - 1$، حساب کنید. چرا این کار با bootstrap آسان و با Hessian دست‌وپاگیر است؟

تمرین ۴ ⋆⋆ **(نتیجه‌ی Gamma–توانی).** ۱۰۰ ۰۰۰ نرخ $\lambda \sim \mathrm{Gamma}(\text{shape } s = 0.8, \text{rate } b = 2)$ بکشید، $e^{-\lambda t}$ را روی آن‌ها برای $t \in [0, 30]$ میانگین بگیرید و منحنی تحلیلی $(1 + t/b)^{-s}$ را روی آن رسم کنید (کادر «پیشرفته» بخش ۵ جزوه). بعد توابع نمایی و توانی را روی منحنی میانگین برازش کنید.

تمرین ۵ ⋆⋆⋆ **(پیشرفته: پوشش).** بازه‌های ۹۵٪ واقعاً چند وقت یک بار مقدار واقعی را در بر می‌گیرند؟ $A = 0.9 \cdot d = 0.5 \cdot n = 10$ پوشش (نسبت بازه‌هایی که ۵۰ را در بر دارند) هر روش را گزارش کنید. با $n = 50$ تکرار کنید.

lab check-off

نشان دهید: (۱) جدولی که بازه‌های ٪۹۵ Wald، profile و bootstrap برای d را مقایسه می‌کند؛ (۲) نمودار پراکنش bootstrap با یک جمله درباره‌ی trade-off؛ (۳) مقایسه‌ی فردی در برابر میانگین و پاسخ شما به سؤال تفسیری ۱.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

نمره‌های benchmark هم خطای استاندارد دارند. مدل‌های هوش مصنوعی روی benchmarkها مقایسه می‌شوند، و جدول‌های رتبه‌بندی (leaderboard) اغلب مدل‌هایی را رتبه‌بندی می‌کنند که یکی دو درصد با هم فرق دارند. یک benchmark یک نمونه از آیتم‌هاست، پس دقتش، درست مثل برآورد یک پارامتر، خطای نمونه‌گیری دارد. دو درس این هفته مستقیماً به کار می‌آیند: ۱. **عدم قطعیت را گزارش کنید.** bootstrap روی آیتم‌ها یک بازه‌ی اطمینان برای دقت و برای تفاوت دو مدل می‌دهد. ۲. **به طرح احترام بگذارید.** هر دو مدل به همان آیتم‌ها جواب داده‌اند، پس مقایسه جفتی است، مثل یک طرح درون‌آزمودنی. نمونه‌گیری مجدد مستقل از دو مدل، دشواری مشترک آیتم‌ها را نادیده می‌گیرد و بازه‌هایی بیش از حد پهن می‌دهد.

دشواری آیتم‌ها هم خیلی متفاوت است، که نسخه‌ی سطح آیتمِ ناهمگنی شرکت‌کننده‌ها در بخش D است: یک دقت میانگین واحد آن را پنهان می‌کند.

۷ درصد برتری روی ۱۰۰ آیتم به‌وضوح با صفر فرق ندارد. جدول رتبه‌بندی‌ای که A را بدون بازه بالای B می‌گذارد، بیش از حد مطمئن است.

با شبیه‌سازی پیدا کنید. - ★★ SE والد (Wald) هر دقت، $\sqrt{p(1-p)/n}$، را حساب کنید و با SE حاصل از bootstrap مقایسه کنید. - ★★ بحث: مقاله‌ای «مدل A: ٪۷۴، مدل B: ٪۶۷» را بدون بازه گزارش می‌کند و نتیجه می‌گیرد که A «بهتر استدلال می‌کند». فهرست کنید از نویسندگان چه می‌پرسید.

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **قاطی کردن SE با SD.** SD پراکندگی داده‌ها را توصیف می‌کند؛ SE عدم قطعیت یک برآورد را توصیف می‌کند و با بزرگ شدن داده‌ها کوچک می‌شود.
۲. **«با احتمال ٪۹۵ مقدار واقعی در بازه‌ی اطمینان من است.»** در بازه‌ی اطمینان فراوانی‌گرا، ٪۹۵ به رفتار بلندمدت رویه برمی‌گردد. این گزاره‌ی احتمالاتی مال credible intervalهای بیزی است (هفته‌ی ۹).
۳. Hessian را درست حساب کنید.
۴. **اعتماد به بازه‌های Wald نزدیک کران‌ها.** اگر $\hat{\theta}$ روی کران یا نزدیک آن است، یا بازه از مقادیر ناممکن عبور می‌کند، از بازه‌های profile یا bootstrap استفاده کنید.
۵. **گزارش پارامترها بدون عدم قطعیت.** مقایسه‌ی دو برآورد نقطه‌ای («شرکت‌کننده‌ی ۱ دارای $d = 0.42$ و شرکت‌کننده‌ی ۲ دارای $d = 0.51$ است») بدون بازه بی‌معنی است.
۶. **استنباط فرایندهای سطح فرد از داده‌های میانگین‌گیری‌شده.** میانگین منحنی‌های غیرخطی شکل تابعی را عوض می‌کند (بخش D). این برای آیتم‌ها، trialها و شرکت‌کننده‌ها یکسان صادق است.
۷. **با برآوردهای فردی مثل داده رفتار کردن.** آزمون t مرحله‌ی دوم روی پارامترهای برازش‌شده نادیده می‌گیرد که بعضی برآوردها خیلی پرنویزتر از بقیه‌اند. مدل‌های سلسله‌مراتبی این را درست می‌کنند (هفته‌ی ۱۳).

۹.۱.۱ خودآزمایی

۱. توزیع نمونه‌گیری یک برآوردگر چیست و چرا نمی‌توانیم مستقیماً آن را ببینیم؟ **پاسخ** توزیع برآوردهایی که در تکرارهای فرضی بسیار زیاد آزمایش با همان پارامترهای واقعی می‌گرفتیم. فقط یک مجموعه‌داده داریم، پس آن را با Hessian (نظریه‌ی مجانبی)، profile likelihood یا شبیه‌سازی (bootstrap) تقریب می‌زنیم.

۲. NLL در یک جهت از فضای پارامتر کمینه‌ی خیلی تختی دارد. این درباره‌ی خطاهای استاندارد و همبستگی برآوردها چه می‌گوید؟ **پاسخ** انحنای کم یعنی درایه‌ی کوچک Hessian در آن جهت، پس واریانس بزرگ در $\mathbf{H}^{-1}$: SEهای بزرگ. اگر جهت تخت مورب باشد، برآوردها به‌شدت همبسته‌اند .(trade-off)

۳. SE روش Wald را برای یک نسبت دوجمله‌ای از مشتق دوم NLL به دست آورید. **پاسخ** $\mathrm{NLL}''(\theta) = y/\theta^2 + (n-y)/(1-\theta)^2$. در $\hat{\theta} = y/n$ این برابر $n/\hat{\theta} + n/(1-\hat{\theta}) = n/[\hat{\theta}(1-\hat{\theta})]$ است. معکوس کردن و جذر گرفتن می‌دهد $\mathrm{SE} = \sqrt{\hat{\theta}(1-\hat{\theta})/n}$.

۴. مراحل یک bootstrap پارامتری برای بازه‌ی اطمینان یک پارامتر مدل را بنویسید. **پاسخ** مدل را برازش کنید تا $\hat{\boldsymbol{\theta}}$ به دست آید. B مجموعه‌داده از مدل با $\hat{\boldsymbol{\theta}}$ و طرح آزمایش اصلی شبیه‌سازی کنید. انحراف معیار برآوردهای جدید را SE و صدک‌های ۵.۲ و ۵.۹۷ آن‌ها را بازه‌ی ۹۵٪ در نظر بگیرید.

۵. چرا بازه‌ی profile likelihood می‌تواند نامتقارن باشد ولی بازه‌ی Wald نمی‌تواند؟ **پاسخ** بازه‌ی Wald یک NLL مربعی (توزیع نمونه‌گیری نرمال) فرض می‌کند که ذاتاً متقارن است. بازه‌ی profile از درست‌نمایی واقعی استفاده می‌کند که ممکن است چوله باشد، مثلاً نزدیک یک کران یا برای پارامترهای نرخ.

منحنی میانگین با تابع توانی بهتر برازش می‌شود. آیا باید نتیجه بگیریم که یادگیری از قانون توانی پیروی می‌کند؟ **پاسخ** نه. شکل توانی خطای ناشی از میانگین‌گیری است: میانگین توابع نمایی با نرخ‌های ناهمگن منحنی‌ای می‌سازد که نرخ نسبی تغییرش با زمان کم می‌شود. نتیجه‌گیری درباره‌ی شکل یادگیری فردی باید از برازش‌های فردی (یا سلسله‌مراتبی) بیاید.

۷. یک مزیت و یک عیب برازش جداگانه‌ی هر شرکت‌کننده بگویید. **پاسخ** مزیت: تفاوت‌های فردی را رعایت می‌کند و از خطای میانگین‌گیری دوری می‌کند. عیب: با trialهای کم برای هر نفر، برآوردها پرنویزند (و گاهی حدی یا روی کران)، و تحلیل آن‌ها در مرحله‌ی دوم عدم قطعیت‌های متفاوتشان را نادیده می‌گیرد.

۱۰.۱.۱ تکلیف

این هفته تکلیف نمره‌دار جدیدی نداریم. A2 (LS) **در برابر** (MLE) **در ابتدای درس هفته‌ی ۶ تحویل داده می‌شود.** بخش A lab امروز نشان می‌دهد چطور به برآوردهای A2 خود خطای استاندارد اضافه کنید. این کار الزامی نیست ولی تفسیرتان را قوی‌تر می‌کند.

تمرین اختیاری (بدون نمره): تمرین ۵ (پوشش) بهترین آمادگی برای مطالعات بازیابی هفته‌ی ۷ است.

۱۱.۱.۱ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۵.** ترکیب اطلاعات چند شرکت‌کننده: برازش تجمیعی در برابر فردی و خطرات میانگین‌گیری. (منبع اصلی.)
- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۴** (بخش‌های مربوط به عدم قطعیت پارامتر و Hessian، مرور از هفته‌ی قبل.

- اختیاری، خارج از فهرست درس: Mewhort, D. J. K. & Heathcote, A., Brown, S., (۲۰۰۰). The power law repealed: The case for an exponential law of practice. *Psychonomic Bulletin & Review*، ۷، ۱۸۵–۲۰۷. تحلیل کلاسیک خطاهای میانگین‌گیری در داده‌های تمرین.

پیش‌نمایش هفته‌ی ۶: تمرین ۴ هفته‌ی ۳ نشان داد که یک مدل سه‌پارامتری در SSE از مدل واقعی جلو می‌زند. هفته‌ی بعد مستقیماً با این روبه‌رو می‌شویم: چرا برازش خوب کافی نیست، و چطور cross-validation چیزی را که واقعاً می‌خواهیم، یعنی پیش‌بینی داده‌ی جدید، اندازه می‌گیرد.