مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۶: ارزیابی مدل‌ها ۱: نیکویی برازش، overfitting و cross-validation

فهرست مطالب

۱ ارزیابی مدل‌های شناختی ۱

۱.۱ هفته‌ی ۶: ارزیابی مدل‌ها ۱: نیکویی برازش، overfitting و cross-validation ۱

۱.۱.۱ واژه‌های کلیدی ۱

۱.۱.۲ اهداف یادگیری ۲

۱.۱.۳ مقدمه ۳

۱.۱.۴ جزوه‌ی درس ۳

۱.۱.۵ مثال حل‌شده ۷

۱.۱.۶ lab (۲ ساعت) ۸

۱.۱.۷ ارتباط با هوش مصنوعی و LLMها ۱۳

۱.۱.۸ اشتباهات رایج و برداشت‌های نادرست ۱۴

۱.۱.۹ خودآزمایی ۱۴

۱.۱.۱۰ تکلیف ۱۵

۱.۱.۱۱ مطالعه‌ی بیشتر ۱۶

فصل ۱

ارزیابی مدل‌های شناختی

۱.۱ هفته‌ی ۶: ارزیابی مدل‌ها ۱: نیکویی برازش، overfitting و cross-validation

فصل ۳: ارزیابی مدل‌های شناختی · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌های فراموشی هفته‌های ۲–۵، این بار با چهار مدل رقیب: نمایی ($k = 2$)، توانی ($k = 2$)، نمایی با مجانب ($k = 3$) و دوردی ($k = 4$).

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
goodness of fit	نیکویی برازش	اینکه مدل داده‌ی موجود را چقدر خوب توصیف می‌کند
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
overfitting	بیش‌برازش (overfitting)	برازش نویز نمونه به‌جای الگوی واقعی
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
trace plot	نمودار trace	مقدار نمونه‌ها در برابر شماره‌ی تکرار
complexity / model flexibility	انعطاف‌پذیری / پیچیدگی مدل	دامنه‌ی الگوهایی که مدل می‌تواند تولید کند
test data / training	داده‌ی آموزش / آزمون	داده‌ی برازش / داده‌ی کنارگذاشته برای سنجش

English	فارسی	توضیح کوتاه
cross-validation (CV)	اعتبارسنجی متقابل (cross-validation)	برازش روی بخشی از داده و آزمون روی بخش کنارگذاشته
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
generalization	تعمیم	پیش‌بینی خوب داده‌ی جدید
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
RMSD / SSE	مجموع مربعات خطا / ریشه‌ی میانگین مربع انحراف	معیارهای فاصله‌ی داده و پیش‌بینی
noise	نویز	تغییرات تصادفی در شواهد یا در داده
response bias	سوگیری پاسخ	تمایل به یک پاسخ، مستقل از محرک
criterion (c)	ملاک	آستانه‌ی تصمیم؛ نشان‌دهنده‌ی سوگیری پاسخ
bias–variance trade-off	بده‌بستان سوگیری و واریانس	مدل ساده سوگیر، مدل منعطف پرواریانس
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
data leakage	نشت داده	رسیدن اطلاعات داده‌ی آزمون به برازش
BIC / AIC	معیار اطلاعاتی آکائیکه / بیزی	برازش به‌علاوه‌ی جریمه برای تعداد پارامتر
benchmark	benchmark (مجموعه‌آزمون استاندارد)	مجموعه سؤال برای مقایسه‌ی مدل‌های هوش مصنوعی
benchmark contamination	آلودگی benchmark	بودن سؤال‌های آزمون در داده‌ی آموزش مدل
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. با استفاده از مفاهیم انعطاف‌پذیری و overfitting **توضیح دهند** که چرا برازش خوب شاهد لازم ولی ناکافی برای یک مدل است.
۲. با شبیه‌سازی overfitting را **نشان دهند**: خطای آموزش با پیچیدگی مدل یکنواخت کم می‌شود ولی خطای پیش‌بینی نه.

۳. اعتبارسنجی hold-out، K-fold- و leave-one-out را با امتیاز لگاریتم درست‌نمایی خارج از نمونه **پیاده‌سازی کنند** و داده‌های آموزش و آزمون را درست جدا نگه دارند.
۴. بر اساس ادعای تعمیمی که مطرح است، **انتخاب کنند** چه چیزی را کنار بگذارند trial)ها، شرایط، شرکت‌کننده‌ها).
۵. نتایج cross-validation، از جمله عدم قطعیتشان، را برای مقایسه‌ی مدل‌های شناختی **تفسیر کنند**.

۳.۱.۱ مقدمه

در تمرین ۴ هفته‌ی ۳، مدل سه‌پارامتری نمایی با مجانب داده‌های هفته‌ی ۲ را بهتر از مدل توانی برازش کرد ($\text{SSE} \approx 0.020$ در برابر 0.026)، با اینکه داده‌ها از مدل توانی تولید شده بودند. در بخش D3 هفته‌ی ۳، یک مدل دوردی چهارپارامتری هم همین‌قدر خوب بود. اگر مدل‌ها را بر اساس برازش انتخاب کنیم، مدل غلط را انتخاب می‌کنیم و تا ابد پارامتر اضافه می‌کنیم.

این مشکل مخصوص منحنی‌های فراموشی نیست. یک مدل به اندازه‌ی کافی منعطف می‌تواند هر داده‌ای، از جمله نویز، را برازش کند. Roberts و Pashler به‌طور معروفی پرسیدند که یک برازش خوب واقعاً چقدر قانع‌کننده است (مطالعه‌ی بیشتر را ببینید). جوابشان: نه خیلی، مگر اینکه بدانیم مدل چه چیزی را نمی‌توانست برازش کند.

راه خروج این است که یادمان بیاید **چرا** مدل برازش می‌کنیم. می‌خواهیم فرایندی را که داده را تولید کرده بگیریم، و مدلی که فرایند را گرفته باشد باید **داده‌ی جدید** از همان فرایند را **پیش‌بینی کند**. نویز طبق تعریف تکرار نمی‌شود. پس سؤال از «مدل این داده‌ها را چقدر خوب برازش می‌کند؟» به «مدل داده‌هایی را که ندیده چقدر خوب پیش‌بینی می‌کند؟» تغییر می‌کند. cross-validation مستقیماً با همین داده‌هایی که داریم به این سؤال جواب می‌دهد.

این موضوع کجا به کار می‌رود؟

- **انتخاب بین نظریه‌ها.** هر وقت دو مدل حافظه، تصمیم یا یادگیری مقایسه می‌شوند، برازش خوب به‌تنهایی قانع‌کننده نیست؛ داوران مقاله‌ها cross-validation یا معیاری می‌خواهند که انعطاف را جریمه کند.
- **پیش‌بینی در روان‌شناسی بالینی و روان‌پزشکی:** مدل‌هایی که عود بیماری، پاسخ به درمان یا تشخیص را پیش‌بینی می‌کنند باید روی بیماران جدید اعتبارسنجی شوند، نه روی بیمارانی که با آن‌ها برازش شده‌اند. بسیاری از پیش‌بینی‌کننده‌های منتشرشده دقیقاً در همین آزمون شکست می‌خورند.
- **یادگیری ماشین:** تقسیم train/validation/test و cross-validation با k بخش، روش استاندارد انتخاب مدل و hyperparameterهاست؛ overfitting خطر اصلی است.
- **ارزیابی سیستم‌های هوش مصنوعی:** نمره‌ی benchmark فقط وقتی معنا دارد که آیتم‌های آزمون در داده‌ی آموزش نبوده باشند (بخش هوش مصنوعی و LLMها را ببینید).

۴.۱.۱ جزوه‌ی درس

به زبان ساده مدلی که پیچ‌های کافی داشته باشد می‌تواند از همه‌ی نقطه‌های داده بگذرد، حتی از نویز تصادفی. این آن را مدل خوبی نمی‌کند: نویز دفعه‌ی بعد فرق می‌کند، پس مدلی که نویز را کپی کرده داده‌ی جدید را بد پیش‌بینی می‌کند. این overfitting **(بیش‌برازش)** است. راه‌حل این است که مدل‌ها را با این بسنجیم که داده‌ای را که **ندیده‌اند** چقدر خوب پیش‌بینی می‌کنند. cross-validation این کار را با همان داده‌ای که داریم انجام می‌دهد: بخشی از داده را پنهان کن، مدل را روی بقیه برازش کن، بخش پنهان را پیش‌بینی کن، و تکرار کن تا هر بخش یک بار پنهان شده باشد. مدلی که بهترین پیش‌بینی را روی داده‌ی پنهان دارد برنده است. پیام اصلی هفته: برازش بهتر به همان داده دلیلی بر مدل بهتر نیست؛ پیش‌بینی بهتر داده‌ی جدید دلیل است.

زمان‌بندی پیشنهادی (۶۰ دقیقه): معیارهای برازش و محدودیت‌هایشان ۱۰ · overfitting و انعطاف‌پذیری ۱۵ · منطق تعمیم ۵ · cross-validation ۲۰ · چه چیزی را کنار بگذاریم ۱۰.

۱. معیارهای نیکویی برازش

معیار	تعریف	مقیاس	توضیح
RMSD	$\sqrt{\mathrm{SSE}/N}$	واحد داده	راحت خوانده می‌شود؛ وزن برابر فرض می‌کند
R^2	$1-\mathrm{SSE}/\sum_i (y_i-\bar{y})^2$	۰ تا ۱ (برای مدل‌های خطی)	محبوب ولی برای مدل‌های غیرخطی گمراه‌کننده: می‌تواند منفی شود، انعطاف را پاداش می‌دهد، و تحت سلطه‌ی واریانس بزرگ بین شرایط است (برازش یک افت یکنوا تقریباً خودکار R^2 بالا می‌دهد)
لگاریتم درست‌نمایی $\ell(\hat{\boldsymbol{\theta}})$، NLL	هفته‌ی ۴	nat	معیار طبیعی برای مدل‌های مبتنی بر درست‌نمایی
انحراف G^2	$2(\ell_{\text{sat}}-\ell)$	χ^2 تقریبی	آزمون مطلق عدم برازش (هفته‌ی ۴)

همه‌ی این‌ها **کفایت توصیفی** را می‌سنجند: اینکه مدل داده‌هایی را که رویشان برازش شده چقدر خوب بازتولید می‌کند. هیچ‌کدام در نظر نمی‌گیرند که مدل چقدر راحت می‌توانست آن داده‌ها را تولید کند.

۲. overfitting و انعطاف‌پذیری

هر مشاهده را به شکل **علامت + نویز** بنویسید: $y_i = g(x_i) + \varepsilon_i$ که در آن g فرایند واقعی است. مدل برازش‌شده سعی می‌کند y_i را بازتولید کند، ولی فقط بخش g است که در داده‌ی جدید دوباره ظاهر می‌شود.

- مدلی که **خیلی ساده** باشد بخشی از g را از دست می‌دهد: عدم برازش نظام‌مند، یا **کم‌برازش** (underfitting)، سوگیری بالا).
- مدلی که **خیلی منعطف** باشد خم می‌شود تا ε_i خاص این نمونه را دنبال کند: overfitting (واریانس بالا). برازشش روی نمونه بهتر و پیش‌بینی‌اش برای داده‌ی جدید بدتر می‌شود.

با افزایش پیچیدگی، خطای آموزش همیشه کم می‌شود، در حالی که خطای مورد انتظار پیش‌بینی اول کم و بعد زیاد می‌شود: یک شکل U (بخش .A lab).

انعطاف‌پذیری چیزی بیش از تعداد پارامترهاست. دو مدل با k یکسان می‌توانند از نظر انعطاف، یعنی دامنه‌ی الگوهای داده‌ای که می‌توانند تولید کنند، خیلی فرق داشته باشند. پارامتری که به‌صورت نما یا جابه‌جایی وارد می‌شود معمولاً انعطاف بیشتری می‌خرد تا پارامتری که فقط منحنی را مقیاس می‌دهد. مدل دوردی می‌تواند منحنی‌های نمایی، شبه‌توانی و مجانبی را تقلید کند، و دقیقاً به همین دلیل برازش خوبش چشمگیر نیست. معیارهای اطلاعاتی (هفته‌ی ۷) پارامترها را می‌شمارند؛ cross-validation و Bayes factor (هفته‌ی ۱۰) به انعطاف واقعی پاسخ می‌دهند.

پیشرفته: تجزیه‌ی سوگیری–واریانس. برای مربع خطا، خطای مورد انتظار پیش‌بینی در نقطه‌ی x (روی مجموعه‌داده‌های جدید و نویز جدید) این‌طور تجزیه می‌شود:

$$\mathbb{E}\big[(y_{\text{new}} - \hat{f}(x))^2\big] = \underbrace{\sigma^2}_{\text{irreducible noise}} + \underbrace{\big(g(x) - \mathbb{E}[\hat{f}(x)]\big)^2}_{\text{bias}^2} + \underbrace{\mathrm{Var}[\hat{f}(x)]}_{\text{variance}}.$$

افزودن پارامتر سوگیری را کم و واریانس را زیاد می‌کند. بهترین مدل برای پیش‌بینی این دو را متعادل می‌کند، و وقتی داده کم است لزوماً مدل واقعی نیست. این تجزیه در کتاب عظیمی‌فر و احمدی به‌تفصیل آمده است (مطالعه‌ی بیشتر را ببینید).

خواندن ریاضی تجزیه‌ی bias–variance (کادر پیشرفته) میانگین خطای مربعی پیش‌بینی را به سه بخش تقسیم می‌کند:

- σ^2، **نویز کاهش‌ناپذیر**: حتی فرایند واقعی هم نمی‌تواند بخش تصادفی داده‌ی جدید را پیش‌بینی کند. هیچ مدلی از این پایین‌تر نمی‌رود.
- $\text{bias}^2 := (g(x) - \mathbb{E}[\hat{f}(x)])^2$ پیش‌بینی میانگین مدل (میانگین روی مجموعه داده‌های ممکن) چقدر از حقیقت دور است. مدل‌های خیلی ساده bias بزرگی دارند.
- $\text{variance} := \mathrm{Var}[\hat{f}(x)]$ منحنی برازش‌شده از یک مجموعه داده به مجموعه داده‌ی دیگر چقدر بالا و پایین می‌پرد. مدل‌های خیلی منعطف variance بزرگی دارند، چون دنبال نویز هر مجموعه داده می‌دوند.

اضافه کردن پارامتر، خطا را از جمله‌ی bias به جمله‌ی variance منتقل می‌کند. بهترین پیش‌بینی‌کننده جایی است که جمع این دو کمترین باشد؛ به همین دلیل وقتی داده کم است، یک مدل ساده و کمی غلط می‌تواند بهتر از مدل درست ولی پیچیده پیش‌بینی کند.

۳. تعمیم به‌عنوان معیار

مدلی را ترجیح می‌دهیم که **داده‌ی جدید از همان فرایند** را بهتر پیش‌بینی کند. سه نوع «جدید» با سه ادعای علمی متناظرند:

داده‌ی جدید یعنی...	ادعایی که آزمون می‌شود	کنار بگذارید...
trialهای جدید از همان شرکت‌کننده در همان شرایط	مدل فرایند این فرد را گرفته است	trialها یا آیتم‌های تصادفی
شرایط جدید (مثلاً فاصله‌های طولانی‌تر، محرک‌های جدید)	مدل سازوکار را گرفته، پس می‌تواند برون‌یابی کند	کل شرایط (رویکرد معیار تعمیم)
شرکت‌کننده‌های جدید	مدل آنچه را بین آدم‌ها مشترک است گرفته است	کل شرکت‌کننده‌ها

همیشه بگویید ارزیابی‌تان کدام نوع تعمیم را هدف گرفته است.

۴. cross-validation (CV)

اعتبارسنجی hold-out. داده را به یک مجموعه‌ی آموزش (برای برازش) و یک مجموعه‌ی آزمون (برای ارزیابی) تقسیم کنید. ساده ولی پرهدر و پرنویز است: نتیجه به یک تقسیم خاص بستگی دارد.

اعتبارسنجی K-fold. داده را به K بخش (fold) تقریباً برابر تقسیم کنید. برای هر بخش $k = 1, \ldots, K$: ۱. مدل را روی

همه‌ی داده‌ها **جز** بخش k برازش کنید و $\hat{\boldsymbol{\theta}}_{(-k)}$ را بگیرید. ۲. پیش‌بینی‌هایش برای بخش k را امتیاز دهید.

امتیازها را روی بخش‌ها جمع کنید. هر مشاهده یک بار برای آزمون استفاده می‌شود و مدل هرگز روی داده‌ای که با آن آموزش دیده آزمون نمی‌شود. مقادیر معمول $K = 5$ یا 10 است. Leave-one-out (LOO) حالت خاصی است که هر مشاهده خودش یک بخش است.

امتیاز. برای مدل‌های مبتنی بر درست‌نمایی از **لگاریتم درست‌نمایی خارج از نمونه** (امتیاز پیش‌بینی لگاریتمی) استفاده کنید:

$$\text{CV-NLL} = -\sum_{k=1}^{K} \sum_{i \in \text{fold } k} \ln p\big(y_i \mid \hat{\boldsymbol{\theta}}_{(-k)}, \mathcal{M}\big).$$

کمتر بهتر است. برای مدل‌های گاوسی، مربع خطای خارج از نمونه گزینه‌ی معادلی است.

قواعد CV صادقانه: ۱. **هر چیزی** که از داده یاد گرفته می‌شود، از جمله برآورد پارامترها، انتخاب مقدار شروع از شبکه‌ها و تبدیل‌های داده‌محور، باید داخل هر بخش آموزش انجام شود. وگرنه اطلاعات از مجموعه‌ی آزمون «نشت» می‌کند (data leakage). ۲. در امتداد واحد درست تقسیم کنید (بخش ۳). برای CV در سطح trial با شمارش‌های دوجمله‌ای، **آیتم‌ها** را داخل هر شرط تقسیم کنید تا هر بخش آموزش هنوز همه‌ی شرایط را داشته باشد. ۳. برآوردهای CV پرنویزند. با چند تقسیم تصادفی تکرار کنید و میانگین و پراکندگی، یا SE تفاوت مدل‌ها بین بخش‌ها، را گزارش کنید. ۴. با تقسیم در سطح آیتم، CV مدل‌هایی را مقایسه می‌کند که روی $(K-1)/K$ داده برازش شده‌اند، پس مدل‌هایی را که داده‌ی زیادی لازم دارند کمی جریمه می‌کند.

> **پیشرفته: LOO، AIC و بیز.** برای مدل‌های منظم و N بزرگ، LOO با امتیاز لگاریتمی و AIC (هفته‌ی ۷) به‌طور مجانبی یک مدل را انتخاب می‌کنند. در مدل‌سازی بیزی، تقریبی کارا از LOO (PSIS-LOO) از نمونه‌های پسین محاسبه می‌شود. در هفته‌ی ۱۳ با ArviZ با آن آشنا می‌شوید.

خواندن ریاضی $\text{CV-NLL} = -\sum_k \sum_{i \in \text{fold } k} \ln p(y_i \mid \hat{\boldsymbol{\theta}}_{(-k)}, \mathcal{M})$:

- $\hat{\boldsymbol{\theta}}_{(-k)}$: پارامترهایی که **بدون** بخش k برآورد شده‌اند (علامت منفی در زیرنویس یعنی «کنار گذاشتن»).
- $\ln p(y_i \mid \hat{\boldsymbol{\theta}}_{(-k)})$: مدلی که بدون این مشاهده‌ها آموزش دیده، آن‌ها را چقدر محتمل می‌داند. مدلی که آن‌ها را خوب پیش‌بینی کرده، احتمال بالایی به آن‌ها می‌دهد.
- جمع دوگانه این مقدار را روی همه‌ی بخش‌ها و همه‌ی نقطه‌های کنارگذاشته جمع می‌کند؛ علامت منفی آن را به کمیتی برای کمینه کردن تبدیل می‌کند، مثل NLL هفته‌ی ۴. همان NLL است، ولی هر مشاهده با مدلی سنجیده می‌شود که هرگز آن را ندیده.

۵. تفسیر یک مقایسه‌ی مدل

- تفاوت‌های CV-NLL بر حسب nat هستند. به‌عنوان راهنمای تقریبی، تفاوت‌های کمتر از حدود ۱ تا ۲ nat، یا کمتر از دو برابر SE آن‌ها بین بخش‌ها یا تکرارها، نباید بیش از حد تفسیر شوند.
- مدلی که در CV برنده می‌شود بهترین **پیش‌بینی‌کننده** در میان مدل‌های مقایسه‌شده، برای این نوع تعمیم و این مقدار داده، است. «مدل واقعی» نیست. با داده‌ی بیشتر، مدل‌های پیچیده‌تر اغلب شروع به بردن می‌کنند، چون واریانسشان کم می‌شود.
- CV را با بررسی‌های کیفی‌ای که می‌شناسید ترکیب کنید: الگوی باقی‌مانده‌ها، معقول بودن پارامترها، و قابل تفسیر بودن مدل.

برای یک مهندس

- overfitting همان مشکل آشنای برازش یک چندجمله‌ای با درجه‌ی بالا یا یک فیلتر با تعداد tap زیاد روی یک سیگنال کوتاه و پرنویز است: خطای آموزش به صفر می‌رسد و خطای پیش‌بینی منفجر می‌شود.
- **trade-off بین bias و variance** همان چیزی است که هنگام انتخاب مرتبه‌ی مدل (مرتبه‌ی AR، تعداد tapهای فیلتر) یا پنجره‌ی هموارسازی می‌بینید: درجه‌ی آزادی کم bias می‌دهد و درجه‌ی آزادی زیاد variance.
- cross-validation نسخه‌ی داده‌محور انتخاب مرتبه‌ی مدل است. معیارهایی از نوع AIC/MDL (هفته‌ی ۷) میان‌برهای تحلیلی‌اند که شاید از انتخاب مرتبه‌ی مدل AR بشناسید.
- **آموزش روی داده‌ی آزمون** مثل این است که یک گیرنده را روی همان تحقق نویزی تنظیم کنید که بعداً BER آن را رویش اندازه می‌گیرید: کارایی گزارش‌شده خوش‌بینانه است.
- nat نسخه‌ی لگاریتم طبیعی bit است: تفاوت ۱ nat یعنی نسبت درست‌نمایی $e \approx 2.7$.

برای مدرس

- **با مثال حل‌شده‌ی چندجمله‌ای روی تخته شروع کنید.** چهار نقطه، چهار مدل. بگذارید دانشجوها بهترین مدل را با SSE آموزش انتخاب کنند (مکعبی را انتخاب می‌کنند)، بعد بپرسید پیش‌بینی آن در ۱۶ روز چیست (-8.5). خنده‌ی کلاس همان درس است.
- **leave-one-out را برای یک نقطه با دست انجام دهید** (نقطه‌ی ۸ روز را با دست بپوشانید، خط را با چشم دوباره برازش کنید و پیش‌بینی کنید). بعد دانشجوها می‌فهمند کد lab چه می‌کند.
- **روی «چه چیزی کنار گذاشته می‌شود» تأکید کنید.** سه نوع داده‌ی «جدید» (بخش ۳) را روی تخته بنویسید؛ بیشتر اشتباه‌های پروژه‌های دانشجویی از کنار گذاشتن چیز اشتباه می‌آید.
- **سؤال‌های رایج.**
  - «اگر مدل درست کمتر *overfit* می‌کند، چرا یک مدل غلط می‌تواند در *CV* برنده شود؟» با داده‌ی کم، یک مدل ساده‌ی غلط ممکن است variance کمتری داشته باشد. CV بهترین پیش‌بینی‌کننده را انتخاب می‌کند، نه مدل درست را.
  - «چند بخش *(fold)*؟» ۵ یا ۱۰ استاندارد است؛ برای داده‌های خیلی کوچک LOO.
  - «آیا $R^2 = 0.98$ خوب است؟» برای یک منحنی نزولی، تقریباً هر مدل یکنوایی R^2 بالا می‌گیرد؛ چیز زیادی نمی‌گوید.

۵.۱.۱ مثال حل‌شده

داده. چهار نسبت یادآوری $y = (0.62, 0.50, 0.47, 0.27)$ در $t = (1, 2, 4, 8)$ روز. چندجمله‌ای‌هایی با درجه‌ی رو به افزایش را به‌عنوان «مدل» مقایسه می‌کنیم.

قدم ۱: برازش روی همه‌ی داده‌ها

مدل	k	برازش‌شده معادله‌ی	آموزش SSE
ثابت	۱	$\hat{y} = 0.465$	۰۶۳۳.۰
خطی	۲	$\hat{y} = 0.637 - 0.046\,t$	۰۰۳۲.۰
دو درجه‌ی	۳	$\hat{y} = 0.647 - 0.053\,t + 0.0008\,t^2$	۰۰۳۱.۰
سه درجه‌ی	۴	می‌گذرد نقطه ۴ هر از دقیقاً	۰۰۰۰.۰

مدل	k	معادله‌ی برازش‌شده	SSE آموزش

بر اساس SSE آموزش، چندجمله‌ای درجه‌ی سه «کامل» است. ولی از آن بخواهید یادآوری را در $t = 16$ روز پیش‌بینی کند: -8.5 پیش‌بینی می‌کند، یعنی منفی ٪۸۵۰ یادآوری. مدل خطی -0.10 پیش‌بینی می‌کند (آن هم ناممکن ولی کمتر پوچ) و مدل ثابت ۴۷.۰.

قدم ۲: اعتبارسنجی leave-one-out

هر بار یک نقطه را کنار بگذارید، روی سه نقطه‌ی باقی‌مانده دوباره برازش کنید و نقطه‌ی کنارگذاشته را پیش‌بینی کنید.

t کنارگذاشته	مشاهده‌شده	پیش‌بینی ثابت	پیش‌بینی خطی	پیش‌بینی درجه‌ی دو
۱	۶۲.۰	۴۱۳.۰	۵۶۰.۰	۴۹۸.۰
۲	۵۰.۰	۴۵۳.۰	۵۷۰.۰	۵۷۰.۰
۴	۴۷.۰	۴۶۳.۰	۴۴۸.۰	۳۳۰.۰
۸	۲۷.۰	۵۳۰.۰	۲۷۵.۰	**۲۵۰.۱**
SSE در LOO		**۱۱۲۵.۰**	۰۰۹۰.۰	۰۰۰۰.۱

(چندجمله‌ای درجه‌ی سه اینجا قابل اعتبارسنجی نیست: سه نقطه چهار پارامتر را تعیین نمی‌کنند.)

تفسیر. SSE آموزش مدل درجه‌ی دو عملاً با مدل خطی برابر است، ولی خطای LOO آن بیش از ۱۰۰ برابر بزرگ‌تر است. وقتی نقطه‌ی ۸ روزه را نمی‌بینند، انحنایش را طوری خم می‌کند که سه فاصله‌ی کوتاه را برازش کند و در ۸ روز یادآوری بیشتر از ۱ پیش‌بینی می‌کند. پارامتر اضافه نویز را برازش کرد، نه فراموشی را. مدل خطی از میان این سه بهترین تعمیم را دارد. (هیچ‌کدام از این چندجمله‌ای‌ها مدل شناختی معقولی برای فراموشی نیستند، چون هیچ‌کدام دامنه‌ی ۰ تا ۱ را رعایت نمی‌کنند؛ دقیقاً به همین دلیل به‌جایشان از مدل‌های نمایی و توانی استفاده می‌کنیم.)

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. دیدن overfitting در عمل: خطای آموزش در برابر خطای آزمون با افزایش درجه‌ی چندجمله‌ای.
۲. پیاده‌سازی K-fold CV در سطح آیتم با لگاریتم درست‌نمایی دوجمله‌ای خارج از نمونه، و مقایسه‌ی چهار مدل فراموشی.
۳. اجرای یک آزمون **معیار تعمیم**: آموزش روی فاصله‌های کوتاه، پیش‌بینی فاصله‌های طولانی.
۴. **تفسیر** اینکه کدام مدل تعمیم پیدا می‌کند و چرا مدلی که بهترین برازش را دارد بهترین پیش‌بینی‌کننده نیست.

زمان‌بندی: بخش A ۲۵ دقیقه · بخش B ۴۵ دقیقه · بخش C ۲۵ دقیقه · بخش D ۲۵ دقیقه.

آماده‌سازی: داده و چهار مدل

کد: Code · سلول ۱ · cell ۱، `code/week06.py`

خروجی مورد انتظار:

```
exp      k = 2  training NLL = 29.812  params = [0.638 0.046]
pow      k = 2  training NLL = 19.830  params = [0.877 0.421]
expasym  k = 3  training NLL = 18.919  params = [0.861 0.38  0.308]
two      k = 4  training NLL = 18.919  params = [0.265 0.    0.596 0.38 ]
```

بر اساس NLL آموزش، مدل‌های پیچیده‌تر برنده‌اند. دقت کنید که بهترین برازش مدل دوردی یک جزء کند با نرخ ۰ دارد: مثل هفته‌ی ۳ به مدل نمایی با مجانب تبدیل شده است (با NLL یکسان). حالا ببینیم آیا پیش‌بینی بهتری هم دارند.

بخش A: overfitting با چندجمله‌ای‌ها (۲۵ دقیقه)

چندجمله‌ای‌هایی بر حسب $x = \ln(1 + t)$ را به‌عنوان مدل‌های منعطفِ عمداً «بی‌فکر» به کار می‌بریم. داده‌های **آزمون** ۵۰۰ مجموعه‌داده‌ی تازه‌اند که با همان طرح از مدل توانی واقعی شبیه‌سازی شده‌اند.

کد: Code · سلول ۲ · cell ۲، `code/week06.py`

خروجی مورد انتظار:

```
 degree  k  train_MSE  test_MSE
      0  1    0.03980   0.05072
      1  2    0.00663   0.00787
      2  3    0.00204   0.00634
      3  4    0.00202   0.00640
      4  5    0.00173   0.00661
      5  6    0.00087   0.00750
      6  7    0.00087   0.00750
      7  8    0.00000   0.00833
```

به این دقت کنید: خطای آموزش با هر پارامتر اضافه کم می‌شود و در $k = 8$ به ۰ می‌رسد (درون‌یابی). خطای آزمون در یک پیچیدگی میانی کمترین است و بعد بالا می‌رود: پارامترهای اضافه دنبال نویز می‌دوند. حتی بهترین چندجمله‌ای هم بدتر از مدل توانی واقعی پیش‌بینی می‌کند؛ MSE آزمون آن را می‌توانید به‌عنوان تمرین حساب کنید.

بخش B: cross-validation K-fold روی آیتم‌ها (۴۵ دقیقه)

در هر فاصله ۵۰ آیتم آزمون شده است. هر آیتم را داخل هر فاصله به یکی از $K = 5$ بخش اختصاص می‌دهیم تا هر مجموعه‌ی آموزش همه‌ی ۸ فاصله را داشته باشد.

Code · **کد:** `code/week06.py`، cell ۳ · سلول ۳

خروجی مورد انتظار (حدود ۱ تا ۲ دقیقه):

```
         k  train_NLL  CV_NLL_mean  CV_NLL_sd
exp      2     29.812      256.458      1.058
pow      2     19.830      245.791      0.734
expasym  3     18.919      247.370      1.574
two      4     18.919      247.531      1.172

CV-NLL difference to the power model (mean, SD over repeats):
         exp  pow  expasym    two
mean  10.667  0.0    1.579  1.740
std    1.137  0.0    1.807  1.349
```

دقت کنید که NLL آموزش (دوجمله‌ای، با ضرایب دوجمله‌ای) و CV-NLL (برنولی، در سطح آیتم) مقیاس‌های متفاوتی دارند. مدل‌ها را **داخل** هر ستون مقایسه کنید، نه بین ستون‌ها.

تفسیر: ۱. کدام مدل آیتم‌های کنارگذاشته را بهتر پیش‌بینی می‌کند؟ آیا برتری‌اش بر نفر دوم از تغییرپذیری بین تکرارهای CV بیشتر است؟ ۲. مدل دوردی بهترین برازش آموزش را دارد. در CV چه بر سرش می‌آید و چرا؟ ۳. آیا CV با این داده‌ها می‌تواند مدل توانی و مدل نمایی با مجانب را از هم جدا کند؟ چه چیزی کمک می‌کرد؟

بخش C: معیار تعمیم: پیش‌بینی فاصله‌های طولانی‌تر (۲۵ دقیقه)

مدلی که فهمیده فراموشی چگونه کار می‌کند باید بتواند برون‌یابی کند. روی پنج فاصله‌ی کوتاه‌تر ($t \leq 7$ روز) آموزش دهید و سه فاصله‌ی طولانی‌تر (۱۴، ۲۱، ۳۰ روز) را که مدل‌ها هرگز ندیده‌اند پیش‌بینی کنید.

Code · **کد:** `code/week06.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
         test_NLL_long_delays  pred_t14  pred_t21  pred_t30
model
exp                    72.550     0.086     0.028     0.007
pow                     9.627     0.228     0.186     0.156
expasym                 6.268     0.260     0.257     0.257
two                    46.072     0.131     0.057     0.020
observed: {14: 0.26, 21: 0.26, 30: 0.28}
```

به این دقت کنید: اینجا مدل **نمایی با مجانب** بهترین برون‌یابی را دارد، نه مدل توانی واقعی. سه نقطه‌ی کنارگذاشته اتفاقاً صاف‌اند (۲۶.۰، ۲۶.۰، ۲۸.۰) و منحنی‌ای که ثابت می‌شود آن‌ها را خوب پیش‌بینی می‌کند. مدل توانی، مثل فرایند واقعی، به افت ادامه می‌دهد، ولی در این نمونه نویز فاصله‌های طولانی یادآوری را صاف نشان داده است. مدل نمایی خالص و مدل دوردی (که برازش فاصله‌های کوتاهش هیچ قیدی روی جزء کند نمی‌گذارد) بد برون‌یابی می‌کنند. درس‌ها: (۱) معیارهای تعمیم مختلف می‌توانند مدل‌ها را متفاوت رتبه‌بندی کنند؛ (۲) یک آزمون روی سه نقطه‌ی داده خودش پرنویز است، پس برد یک مدل در یک مجموعه‌ی آزمون اثبات نیست؛ (۳) توافق چند معیار (بخش B، بخش C، و AIC/BIC هفته‌ی ۷) قانع‌کننده‌تر از هر یک از آن‌هاست.

بخش D: کنار هم گذاشتن (۲۵ دقیقه)

این جدول را در notebook از روی بخش‌های B و C پر کنید و یک پاراگراف کوتاه (۵ تا ۸ جمله) در جواب این سؤال بنویسید:
کدام مدل را به‌عنوان بهترین توضیح این داده‌های فراموشی توصیه می‌کنید و چقدر مطمئنید؟

مدل	k	NLL آموزش	CV-NLL پنج‌بخشی (میانگین $\pm$ SD)	NLL آزمون فاصله‌های طولانی	الگوی باقی‌مانده‌ها (هفته‌ی ۴)	پارامترها معقول‌اند؟
exp						
pow						
expasym						
two						

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. در بخش A، مدل توانی واقعی با پارامترهای واقعی را به‌عنوان یک «مدل» اضافه کنید (هیچ پارامتر برازش‌شده‌ای ندارد). MSE آزمون آن را حساب کنید و با بهترین چندجمله‌ای مقایسه کنید. خطای کاهش‌ناپذیر چقدر است؟

تمرین ۲ ⋆. بخش B را با $K = 2$، $K = 10$ و leave-one-item-out ($K = 50$) دوباره اجرا کنید. آیا رتبه‌بندی تغییر می‌کند؟ کدام K پایدارترین نتایج را بین تکرارها می‌دهد؟

تمرین ۳ ⋆⋆ **(نشت داده).** یک CV «غلط» بنویسید که در آن مقادیر شروع هر بخش از برازش روی کل مجموعه‌داده گرفته شود، و یکی دیگر که در آن آیتم‌های آزمون هر بخش اشتباهاً در آموزش هم باشند. نتایج را با CV درست مقایسه کنید. کدام اشتباه مهم‌تر است و چرا؟

تمرین ۴ ⋆⋆ **(داده‌ی بیشتر).** یک مجموعه‌داده‌ی جدید از مدل توانی واقعی با $n = 500$ آیتم در هر فاصله شبیه‌سازی کنید و بخش‌های B و C را دوباره اجرا کنید. آیا رتبه‌بندی روشن‌تر می‌شود؟ آیا مدل دوردی هیچ‌وقت برنده می‌شود؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته:** leave-one-participant-out). از مولد داده‌ی تمرین بخش D هفته‌ی ۵ با ۲۰ شرکت‌کننده استفاده کنید. CV ای پیاده‌سازی کنید که هر بخش آن یک شرکت‌کننده را کنار بگذارد: یک مدل تجمیعی (میانگین گروه) را روی ۱۹ شرکت‌کننده برازش کنید و پیش‌بینی منحنی شرکت‌کننده‌ی کنارگذاشته را با لگاریتم درست‌نمایی گاوسی امتیاز دهید. مدل‌های نمایی و توانی را مقایسه کنید. بعد همین کار را با برازش‌های سطح فرد انجام دهید. توضیح دهید چرا این دو طرح CV به دو سؤال علمی متفاوت جواب می‌دهند.

lab check-off

نشان دهید: (۱) نمودار آموزش در برابر آزمون از بخش A، (۲) جدول خلاصه‌ی CV از بخش B، و (۳) پاراگراف بخش D.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

آلودگی benchmark (contamination) **همان نشت داده است.** LLMها روی حجم عظیمی از متن اینترنت آموزش می‌بینند. اگر سؤال‌های یک benchmark (یا جواب‌هایشان) آنلاین منتشر شده باشند، ممکن است در داده‌ی آموزشی باشند، پس مدل روی آیتم‌هایی آزموده می‌شود که قبلاً دیده. این دقیقاً مسئله‌ی نشت در cross-validation است: مجموعه‌ی آزمون دیگر از مجموعه‌ی آموزش مستقل نیست، پس نمره علاوه بر تعمیم، حفظ کردن را هم می‌سنجد. این یکی از جدی‌ترین مشکلات ارزیابی سیستم‌های هوش مصنوعی است، از جمله ادعاهایی که می‌گویند LLMها روی تکلیف‌های کلاسیک روان‌شناسی، که مواد آن‌ها همه‌جا منتشر شده، توانایی‌های شناختی انسان‌گونه نشان می‌دهند.

Code · کد: `code/week06.py`، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
Reported accuracy (all items): 0.73
Accuracy on leaked items:      0.96  (n = 120)
Accuracy on clean items:       0.63  (n = 280)
```

نمره‌ی گزارش‌شده (۷۳.۰) توانایی حل مسئله‌های تازه (۶۳.۰) را بیش از واقع نشان می‌دهد. راه‌حل همان است که در lab این هفته دیدید: ارزیابی روی آیتم‌هایی که مطمئنیم در برازش استفاده نشده‌اند، مثلاً آیتم‌های تازه‌نوشته، یا گونه‌های نظام‌مند تکلیف‌های کلاسیک.

امتحانش کنید (بدون نیاز به API). ⋆ - سهم آیتم‌های نشت‌کرده را از ۰ تا ۹.۰ تغییر دهید و دقت گزارش‌شده را رسم کنید. آیا فقط از روی دقت گزارش‌شده می‌توانید بگویید چقدر نشت کرده؟ - ⋆⋆ در عمل نمی‌دانیم کدام آیتم‌ها نشت کرده‌اند. فرض کنید برای هر آیتم یک گونه‌ی «تازه» (همان منطق، عبارت‌بندی تازه) داریم. گونه‌های تازه را با $P(\text{correct}) = 0.60$ شبیه‌سازی کنید و اثر نشت را به‌صورت تفاوت دقت آیتم‌های اصلی و تازه، با یک بازه‌ی bootstrap جفتی (هفته‌ی ۵) برآورد کنید. - ⋆⋆ بحث: یک LLM معمای استدلالی معروفی از یک مقاله‌ی روان‌شناسی دهه‌ی ۱۹۷۰ را حل می‌کند. چرا این شاهد ضعیفی است بر اینکه «مثل انسان استدلال می‌کند»؟ چه آزمونی قوی‌تر است؟

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **«مدلی که بهترین برازش را دارد بهترین مدل است.»** برازش انعطاف را پاداش می‌دهد. همیشه بپرسید مدل داده‌ی جدید را چقدر خوب پیش‌بینی می‌کند.
۲. **«انعطاف = تعداد پارامترها.»** شکل تابعی هم مهم است. مدل‌هایی با k برابر می‌توانند در آنچه می‌توانند برازش کنند خیلی فرق داشته باشند.
۳. **نشت اطلاعات آزمون به آموزش،** مثلاً انتخاب مقدار شروع، کران یا تبدیل از روی کل داده، یا نرمال‌سازی با آماره‌های کل داده.
۴. **تقسیم در امتداد واحد غلط.** اگر ادعا درباره‌ی شرکت‌کننده‌های جدید است، کنار گذاشتن trialهای تصادفی تعمیم را بیش از حد برآورد می‌کند.
۵. **بیش‌تفسیر تفاوت‌های کوچک .CV** برآوردهای CV پرنویزند. تقسیم‌ها را تکرار کنید و به تغییرپذیری تفاوت‌ها نگاه کنید.
۶. CV» **مدل واقعی را انتخاب کرد.»** CV بهترین پیش‌بینی‌کننده را برای این مقدار داده انتخاب می‌کند. با داده‌ی کم، یک مدل ساده‌تر (حتی غلط) می‌تواند بهتر از مدل واقعی پیش‌بینی کند.
۷. **استفاده از R^2 برای مقایسه‌ی مدل‌های شناختی غیرخطی.** بین مدل‌ها قابل مقایسه نیست و انعطاف را پاداش می‌دهد.

۹.۱.۱ خودآزمایی

۱. چرا وقتی به یک مدل nested پارامتر اضافه می‌کنیم، خطای آموزش همیشه کم می‌شود (یا ثابت می‌ماند)؟ **پاسخ** مدل بزرگ‌تر مدل کوچک‌تر را به‌عنوان حالت خاص در بر دارد (مثلاً با صفر گذاشتن پارامتر اضافه)، پس بهترین برازشش هرگز بدتر نیست. بهینه‌ساز همیشه می‌تواند برازش مدل کوچک‌تر را بازتولید کند و معمولاً با برازش نویز آن را بهتر می‌کند.

۲. overfitting را بر حسب علامت و نویز تعریف کنید. **پاسخ** داده = علامت (فرایند نظام‌مند) + نویز (تغییرات تصادفی). مدلی که overfitting می‌کند خودش را با نویز نمونه‌ی خاص تطبیق می‌دهد. این برازشش روی این داده‌ها را بهتر و پیش‌بینی داده‌ی جدید را، که نویزش متفاوت است، بدتر می‌کند.

۳. K-fold cross-validation را در چهار قدم توضیح دهید. **پاسخ** (۱) داده را به K بخش تقسیم کنید. (۲) برای هر بخش، مدل را روی $K-1$ بخش دیگر برازش کنید. (۳) پیش‌بینی‌های مدل برازش‌شده را برای بخش کنارگذاشته امتیاز دهید (مثلاً با لگاریتم درست‌نمایی). (۴) امتیازها را روی بخش‌ها جمع یا میانگین کنید؛ در صورت امکان با تقسیم‌های تصادفی جدید تکرار کنید.

۴. در آزمایش فراموشی، چرا آیتم‌ها را داخل هر فاصله‌ی نگهداری به بخش‌ها اختصاص می‌دهیم به‌جای اینکه کل فاصله‌ها را کنار بگذاریم؟ **پاسخ** تقسیم داخل فاصله پیش‌بینی trialهای جدید در همان شرایط را آزمون می‌کند، و هر بخش آموزش هنوز همه‌ی شرایط را دارد. کنار گذاشتن کل فاصله‌ها ادعای دیگری را آزمون می‌کند: برون‌یابی به شرایط جدید (معیار تعمیم، بخش C).

۵. CV-NLL مدل A به‌طور میانگین ۱.۲ nat کمتر از مدل B است، ولی این تفاوت بین تکرارهای CV با SD برابر ۰.۳ تغییر می‌کند. چه نتیجه‌ای می‌گیرید؟ **پاسخ** شاهد ضعیف است. به‌طور دقیق، SD بین تکرارها تغییرپذیری بین تقسیم‌ها را نشان می‌دهد نه عدم قطعیت نمونه‌گیری داده را، ولی در هر حال یک تفاوت ۲ nat با این همه ناپایداری نباید بیش‌تفسیر شود. داده‌ی بیشتری جمع کنید یا مدل‌ها را تقریباً هم‌ارز در پیش‌بینی گزارش کنید.

۶. چرا یک مدل ساده‌تر و «غلط» گاهی در CV از مدل واقعی و پیچیده‌تر بهتر عمل می‌کند؟ **پاسخ** با داده‌ی محدود، پارامترهای مدل پیچیده با واریانس بالا برآورد می‌شوند و این واریانس بیشتر از سوگیری مدل ساده‌تر به پیش‌بینی آسیب می‌زند (trade-off سوگیری–واریانس). با داده‌ی بیشتر واریانس مدل واقعی کم می‌شود و بالاخره برنده می‌شود.

۷. دانشجویی $R^2 = 0.97$ را برای یک مدل غیرخطی فراموشی گزارش می‌کند و نتیجه می‌گیرد مدل درست است. دو اعتراض بیاورید. **پاسخ** (۱) R^2 برای تقریباً هر منحنی نزولی یکنوایی بالاست، چون بیشترِ واریانس داده‌های فراموشی همان افت کلی است. (۲) برازش خوب چیزی درباره‌ی تعمیم یا انعطاف نمی‌گوید؛ الگوی باقی‌مانده‌ها، CV و مقایسه با مدل‌های جایگزین لازم است.

۱۰.۱.۱ تکلیف

A3: مقایسه و بازیابی مدل (۱۰.۱ نمره از ۲۰؛ انتشار هفته‌ی ۶، موعد ابتدای درس هفته‌ی ۹)

A3 این هفته و هفته‌ی بعد را در بر می‌گیرد: کارهای ۱ تا ۳ از مطالب این هفته و کارهای ۴ تا ۶ از مطالب هفته‌ی ۷ (AIC/BIC، بازیابی پارامتر و مدل) استفاده می‌کنند.

داده. یک آزمایش فراموشی با ۱۲ شرکت‌کننده که با این کد تولید می‌شود:

> Code · **کد:** `code/week06.py`، cell ۶ · سلول ۶

کارها.

۱. **برازش‌های فردی (۵.۱ امتیاز).** مدل‌های نمایی، توانی و نمایی با مجانب را برای هر شرکت‌کننده با MLE چندشروعی برازش کنید. جدولی از پارامترها و NLLها گزارش کنید؛ برآوردهای روی کران را مشخص کنید.

۲. **برازش مطلق (۱ امتیاز).** G^2 را برای هر شرکت‌کننده و مدل حساب کنید. هر مدل برای چند شرکت‌کننده برازش ناموفق دارد ($p < .05$)؟

۳. **cross-validation (۲ امتیاز).** برای هر شرکت‌کننده، CV پنج‌بخشی در سطح آیتم (۵ بار تکرار) را برای سه مدل اجرا کنید. گزارش کنید هر مدل برای چند شرکت‌کننده برنده است، و مجموع CV-NLL روی شرکت‌کننده‌ها را با تغییرپذیری‌اش.

۴. **معیارهای اطلاعاتی (۵.۱ امتیاز، هفته‌ی ۷).** AIC، AICc و BIC را برای هر شرکت‌کننده و مدل و وزن‌های آکائیکه را حساب کنید. آیا معیارها با CV توافق دارند؟

۵. **بازیابی (۵.۲ امتیاز، هفته‌ی ۷).** (الف) بازیابی پارامتر برای مدل توانی در این طرح: ۲۰۰ شبیه‌سازی با پارامترهایی از دامنه‌های معقول؛ مقادیر واقعی در برابر بازیابی‌شده را رسم کنید، همبستگی‌ها را گزارش کنید و درباره‌ی هر trade-offی توضیح دهید. (ب) بازیابی مدل برای سه مدل با AIC و BIC: یک confusion matrix ۳ × ۳ از ۱۰۰ شبیه‌سازی برای هر مدل تولیدکننده.

۶. **تفسیر (۵.۱ امتیاز، حداکثر ۴۰۰ کلمه).** کدام مدل فراموشی را در این مطالعه بهتر توصیف می‌کند، شواهد چقدر قوی است، و تحلیل بازیابی چطور نتیجه‌گیری شما را مقید می‌کند؟

روبریک (۱۰ امتیاز، معادل ۰.۱): امتیاز هر کار در بالا آمده است. داخل هر کار: درستی ٪۶۰، وضوح جدول‌ها و نمودارها ٪۲۰، تفسیر ٪۲۰. برای تحویل با تأخیر، روزی ٪۱۰ کسر می‌شود (حداکثر ۳ روز).

۱۱.۱.۱ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۱۰.** مقایسه‌ی مدل‌ها: چرا برازش کافی نیست، انعطاف‌پذیری، و cross-validation در کنار دیگر روش‌های مقایسه. (منبع اصلی.)
- **عظیمی‌فر و احمدی (۱۳۹۶)،** جلد ۱: مطالب مربوط به تعمیم‌پذیری، overfitting و trade-off سوگیری–واریانس از دیدگاه شناسایی الگو [شماره‌ی فصل بررسی شود].
- کلاسیک‌های اختیاری، خارج از فهرست درس: Pashler, H. & Roberts, S., (۲۰۰۰). How persuasive is a good fit? A comment on theory testing. *Psychological Review,* ۱۰۷، ۳۵۸–۳۶۷. Busemeyer, J. Wang, Y.-M. & R., (۲۰۰۰). Model comparisons and model selections based on generalization criterion methodology. *Journal of Mathematical Psychology,* ۴۴، ۱۷۱–۱۸۹.

پیش‌نمایش هفته‌ی ۷: cross-validation کلی است ولی از نظر محاسباتی پرهزینه. معیارهای اطلاعاتی (AIC، BIC) تعمیم را از یک برازش واحد تخمین می‌زنند. و پیش از اعتماد به هر مقایسه‌ای، باید بررسی کنیم آیا روش ما می‌تواند پارامترها و مدل‌هایی را که واقعاً داده را تولید کرده‌اند بازیابی کند.