مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۷: ارزیابی مدل‌ها ۲: معیارهای اطلاعاتی، بازیابی پارامتر و بازیابی مدل

فهرست مطالب

۱ ارزیابی مدل‌های شناختی ۱

۱.۱ هفته‌ی ۷: ارزیابی مدل‌ها ۲: معیارهای اطلاعاتی، بازیابی پارامتر و بازیابی مدل ۱

۱.۱.۱ واژه‌های کلیدی ۱

۲.۱.۱ اهداف یادگیری ۲

۳.۱.۱ مقدمه ۳

۴.۱.۱ جزوه‌ی درس ۳

۵.۱.۱ مثال حل‌شده ۷

۶.۱.۱ lab (۲ ساعت) ۸

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها ۱۱

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست ۱۱

۹.۱.۱ خودآزمایی ۱۲

۱۰.۱.۱ تکلیف ۱۳

۱۱.۱.۱ مطالعه‌ی بیشتر ۱۳

فصل ۱

ارزیابی مدل‌های شناختی

۱.۱ هفته‌ی ۷: ارزیابی مدل‌ها ۲: معیارهای اطلاعاتی، بازیابی پارامتر و بازیابی مدل

فصل ۳: ارزیابی مدل‌های شناختی · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌ها و مدل‌های فراموشی هفته‌های ۲–۶، به‌علاوه‌ی مطالعات شبیه‌سازی بزرگ با همان طرح آزمایش.

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
criterion (c)	ملاک	آستانه‌ی تصمیم؛ نشان‌دهنده‌ی سوگیری پاسخ
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
model recovery	بازیابی مدل	آیا مقایسه‌ی مدل، مدل مولد را درست انتخاب می‌کند
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
research design	طرح آزمایش	شرایط، تعداد کوشش‌ها و نمونه‌ها
likelihood-ratio test (LRT)	آزمون نسبت درست‌نمایی	مقایسه‌ی دو مدل تودرتو
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
nested models	مدل‌های تودرتو (nested)	یک مدل حالت خاص مدل دیگر است

English	فارسی	توضیح کوتاه
BIC / AIC	معیار اطلاعاتی آکائیکه / بیزی	برازش به‌علاوه‌ی جریمه برای تعداد پارامتر
response bias	سوگیری پاسخ	تمایل به یک پاسخ، مستقل از محرک
confusion matrix	ماتریس درهم‌ریختگی (confusion matrix)	P(مدل انتخاب‌شده
inversion matrix	ماتریس معکوس (inversion matrix)	P(مدل مولد
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
identifiability	شناسایی‌پذیری	آیا داده پارامترها را به‌طور یکتا تعیین می‌کند
parameter trade-off	بده‌بستان پارامترها	تغییر یک پارامتر که با پارامتر دیگر جبران می‌شود
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
Akaike weights	وزن‌های آکائیکه	پشتیبانی نسبی از هر مدل
cross-validation (CV)	اعتبارسنجی متقابل (cross-validation)	برازش روی بخشی از داده و آزمون روی بخش کنارگذاشته
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
model mimicry	تقلید مدل	تولید داده‌ای که شبیه داده‌ی مدل دیگر است
in-context learning	یادگیری درون‌متنی	یادگیری از مثال‌های داخل prompt

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. آزمون نسبت درست‌نمایی را برای مدل‌های nested **انجام دهند** و **توضیح دهند** چرا نمی‌تواند مدل‌های non-nested را مقایسه کند.
۲. AIC، AICc، BIC و وزن‌های آکائیکه/BIC را **حساب و تفسیر کنند** و اهداف متفاوت AIC و BIC را **توضیح دهند**.
۳. یک مطالعه‌ی بازیابی پارامتر را **طراحی و اجرا کنند** و پارامترهای سوگیر، پرنویز یا دارای trade-off را **تشخیص دهند**.
۴. یک مطالعه‌ی بازیابی مدل را **طراحی و اجرا کنند** و ماتریس‌های درهم‌ریختگی و معکوس را **تفسیر کنند**.
۵. **ارزیابی کنند** که آیا یک طرح آزمایش و روش مقایسه‌ی مشخص می‌تواند از نتیجه‌گیری‌هایی که پژوهشگر می‌خواهد بگیرد پشتیبانی کند.

۳.۱.۱ مقدمه

cross-validation (هفته‌ی ۶) کلی ولی پرهزینه است: هر بخش یعنی یک برازش دوباره، و برازش دوباره‌ی مدل‌های پیچیده با multi-start ممکن است ساعت‌ها طول بکشد. **معیارهای اطلاعاتی** عملکرد خارج از نمونه را از یک برازش واحد تخمین می‌زنند؛ با افزودن یک جریمه‌ی پیچیدگی به برازش آموزش.

ولی سؤال بنیادی‌تری هست که هیچ معیاری به‌تنهایی به آن جواب نمی‌دهد: **آیا روش ما اصلاً با این طرح آزمایش می‌تواند کار کند؟** فرض کنید نتیجه بگیریم «شرکت‌کننده‌ها با یک قانون توانی با نمای زوال ۴۲.۰ فراموش می‌کنند». برای اینکه این حرف معنایی داشته باشد دو چیز باید درست باشد:

۱. اگر داده‌ها از یک مدل توانی با $d = 0.42$ آمده بودند، رویه‌ی برازش ما چیزی نزدیک به ۴۲.۰ برمی‌گرداند (**بازیابی پارامتر**).
۲. اگر داده‌ها از یک مدل نمایی آمده بودند، روش مقایسه‌ی ما می‌گفت «نمایی»، نه «توانی» (**بازیابی مدل**).

هر دو را می‌شود با شبیه‌سازی بررسی کرد، چون برای داده‌ی شبیه‌سازی‌شده حقیقت را می‌دانیم. راهنماهای امروزی مدل‌سازی محاسباتی این بررسی‌ها را ضروری می‌دانند؛ نادیده گرفتنشان مثل اجرای آزمایش بدون وارسی سالم بودن تجهیزات است. این هفته بخش «شبیه‌سازی ← برازش ← ارزیابی ← **بازیابی**» مسیر مدل‌سازی ما را کامل می‌کند.

این موضوع کجا به کار می‌رود؟

- **جدول‌های مقایسه‌ی مدل با** AIC/BIC تقریباً در هر مقاله‌ی مدل‌سازی در روان‌شناسی، علوم اعصاب، بوم‌شناسی و اقتصاد دیده می‌شوند.
- **روان‌پزشکی محاسباتی:** پیش از ادعای اینکه بیماران نرخ یادگیری پایین‌تری دارند، پژوهشگرها باید با بازیابی پارامتر نشان دهند که نرخ یادگیری در طرح آزمایش آن‌ها قابل برآورد است. داوران مقاله‌ها روزبه‌روز بیشتر این را می‌خواهند.
- **طراحی آزمایش:** شبیه‌سازی‌های بازیابی پیش از جمع‌آوری داده اجرا می‌شوند تا تعداد trialها و شرایط انتخاب شود (نسخه‌ی مدل‌سازی تحلیل توان آماری یا power analysis).
- **هر مطالعه‌ای که می‌گوید «مدل X داده را بهتر از همه توضیح می‌دهد»** باید بازیابی مدل را گزارش کند؛ وگرنه ممکن است برنده فقط سوگیری معیار مقایسه را نشان دهد.

۴.۱.۱ جزوه‌ی درس

به زبان ساده **معیارهای اطلاعاتی** (AIC و BIC) فرمول‌های سریعی‌اند که برازش cross-validation صادق ولی کند است. هر مدل را می‌گیرند و برای هر پارامتر یک جریمه کم می‌کنند؛ پس مدلی برنده می‌شود که پارامترهای اضافه‌اش برازش را بیش از «هزینه‌شان» بهتر کنند. هدف AIC بهترین پیش‌بینی‌کننده و هدف BIC مدل درست است، و جریمه‌ی BIC بزرگ‌تر است. نیمه‌ی دوم هفته که مهم‌تر است می‌پرسد آیا روش‌های ما اصلاً کار می‌کنند. آن‌ها را روی داده‌ی ساختگی امتحان می‌کنیم که در آن حقیقت را می‌دانیم. **بازیابی پارامتر:** داده را با پارامترهای معلوم شبیه‌سازی کن، برازش کن، و بررسی کن که مقدارهای برازش‌شده نزدیک مقدارهای واقعی برگردند. **بازیابی مدل:** داده را از هر مدل نامزد شبیه‌سازی کن و بررسی کن که روش مقایسه همان مدلی را انتخاب کند که داده را تولید کرده. اگر روشی نتواند حقیقت را در داده‌ی شبیه‌سازی‌شده پیدا کند، جوابش روی داده‌ی واقعی بی‌معناست.

زمان‌بندی پیشنهادی (۶۰ دقیقه): آزمون نسبت درست‌نمایی ۸ ۰ AIC و BIC ۲۰ ۰ بازیابی پارامتر ۱۴ ۰ بازیابی مدل ۱۴ ۰ identifiability ۴.

۱. آزمون نسبت درست‌نمایی (مدل‌های nested)

مدل $\mathcal{M}_0$ در $\mathcal{M}_1$ nested است اگر $\mathcal{M}_0$ حالت خاصی از $\mathcal{M}_1$ باشد که با ثابت کردن بعضی پارامترها به دست می‌آید. مثال: مدل نمایی همان مدل نمایی با مجانب با $s = 0$ (مجانب در ۰) است. تحت فرض صفر که $\mathcal{M}_0$ درست است،

$$\Lambda = 2\big[\ell_1(\hat{\boldsymbol{\theta}}_1) - \ell_0(\hat{\boldsymbol{\theta}}_0)\big] \;\dot{\sim}\; \chi^2_{\Delta k},$$

که در آن Δk تفاوت تعداد پارامترهای آزاد است. Λ بزرگ یعنی پارامترهای اضافه برازش را بیشتر از آنچه شانس توضیح می‌دهد بهتر کرده‌اند.

محدودیت‌ها: فقط برای مدل‌های nested کار می‌کند (توانی در برابر نمایی را نمی‌شود این‌طور آزمون کرد)؛ آزمون فرض صفر است (می‌تواند مدل ساده‌تر را رد کند ولی هرگز از آن حمایت نمی‌کند)؛ و وقتی مقدار ثابت‌شده‌ی پارامتر روی مرز فضای پارامتر است (مثل $s = 0$) تقریبی است.

> **پیشرفته: فرض صفر روی مرز.** وقتی مقدار صفر روی مرز است (واریانس ۰، مجانب ۰، وزن آمیخته‌ی ۰)، توزیع Λ تحت فرض صفر آمیزه‌ای ۵۰:۵۰ از χ^2_0 (یک جرم نقطه‌ای در ۰) و χ^2_1 است. در این حالت استفاده از χ^2_1 محافظه‌کارانه است: مقدار p درست نصف مقدار ساده است.

۲. معیارهای اطلاعاتی

معیارهای اطلاعاتی بین برازش و پیچیدگی trade-off برقرار می‌کنند. با لگاریتم درست‌نمایی بیشینه $\hat{\ell}$، k پارامتر آزاد و N مشاهده:

$$\mathrm{AIC} = -2\hat{\ell} + 2k, \qquad \mathrm{AICc} = \mathrm{AIC} + \frac{2k(k+1)}{N-k-1}, \qquad \mathrm{BIC} = -2\hat{\ell} + k\ln N.$$

کمتر بهتر است. فقط **تفاوت‌ها** بین مدل‌هایی که روی داده‌ی یکسان برازش شده‌اند معنادارند.

	AIC (و AICc)	BIC
هدف	بهترین **پیش‌بینی** داده‌ی جدید (کمینه کردن واگرایی Kullback–Leibler مورد انتظار نسبت به حقیقت)	انتخاب مدل **واقعی** اگر میان نامزدها باشد (سازگاری)؛ تقریبی از Bayes factor
جریمه‌ی هر پارامتر	۲	$\ln N$ (از $N \geq 8$ بیشتر از ۲)
وقتی $N \to \infty$	ممکن است همچنان مدل‌های بیش از حد پیچیده را انتخاب کند	مدل واقعی را با احتمال $\to 1$ انتخاب می‌کند
تصحیح نمونه‌ی کوچک	AICc (وقتی $N/k < 40$)	—

N چیست؟ تعداد مشاهدات مستقلی که وارد درست‌نمایی می‌شوند. برای داده‌ی یادآوری دوجمله‌ای این تعداد پاسخ‌های آیتم است (اینجا $8 \times 50 = 400$)، نه تعداد خانه‌ها (۸). این انتخاب روی BIC (از راه $\ln N$) و AICc اثر دارد. آن را گزارش کنید.

وزن‌ها. با $\Delta_i = \mathrm{IC}_i - \min_j \mathrm{IC}_j$،

$$w_i = \frac{\exp(-\Delta_i/2)}{\sum_j \exp(-\Delta_j/2)}.$$

وزن‌های آکائیکه احتمال اینکه مدل i بهترین پیش‌بینی‌کننده در میان نامزدها باشد را تخمین می‌زنند. **وزن‌های** BIC احتمال‌های پسین مدل‌ها را تحت بخت‌های پیشین برابر تقریب می‌زنند (هفته‌ی ۱۰).

قواعد سرانگشتی برای Δ: ۰ تا ۲، پشتیبانی عملاً برابر؛ ۴ تا ۷، پشتیبانی به‌طور قابل توجهی کمتر؛ بیشتر از ۱۰، عملاً بدون پشتیبانی. این‌ها قرارداد هستند، نه قانون.

محدودیت مشترک AIC **و** BIC: هر دو پارامترها (k) را می‌شمارند، پس به تفاوت **انعطاف شکل تابعی** بین مدل‌هایی با k یکسان کورند (هفته‌ی ۶). cross-validation و Bayes factor (هفته‌ی ۱۰) این‌طور نیستند.

> **پیشرفته: جریمه‌ی AIC از کجا می‌آید.** لگاریتم درست‌نمایی بیشینه برآوردی خوش‌بینانه و سوگیر از لگاریتم درست‌نمایی مورد انتظار داده‌ی جدید است، چون همان داده برای انتخاب $\hat{\boldsymbol{\theta}}$ به کار رفته است. آکائیکه نشان داد که برای مدل‌های منظم و N بزرگ، این سوگیری تقریباً k است. تصحیحش $-2(\hat{\ell} - k) = \mathrm{AIC}$ را می‌دهد. به همین دلیل است که AIC و LOO-CV به‌طور مجانبی با هم توافق دارند.

خواندن ریاضی

- $-2\hat{\ell}$ بخش **عدم برازش** است (دو برابر NLL کمینه‌شده)؛ $2k$ یا $k \ln N$ بخش **جریمه** است. AIC/BIC کمتر بهتر است.
- هر پارامتر اضافه باید $-2\hat{\ell}$ را بیش از ۲ (برای AIC) یا بیش از $\ln N$ (برای BIC) کم کند تا ارزشش را داشته باشد. با $N = 400$، $\ln N \approx 6$: یک پارامتر باید NLL را حدود ۳ واحد بهتر کند تا از BIC بگذرد، ولی برای AIC فقط ۱ واحد.
- **وزن‌ها:** $\exp(-\Delta_i/2)$ تفاوت AIC را به درست‌نمایی نسبی تبدیل می‌کند. $\Delta = 2$ می‌دهد $e^{-1} = 0.37$، پس مدلی که ۲ واحد AIC بدتر است حدود یک‌سوم پشتیبانی دارد. تقسیم بر جمع، وزن‌ها را طوری می‌کند که جمعشان ۱ شود.
- **عددهای مثال حل‌شده:** AIC مدل توانی $2(19.830) + 2(2) = 43.66$؛ مدل نمایی با مجانب $= 2(18.919) + 2(3) = 43.84$. مدل مجانب بهتر برازش می‌شود (NLL کمتر) ولی هزینه‌ی یک پارامتر بیشتر را می‌دهد، پس دو مدل تقریباً مساوی می‌شوند.

۳. بازیابی پارامتر

سؤال: با این طرح آزمایش، آیا رویه‌ی برازش پارامترهایی را که داده را تولید کرده‌اند برمی‌گرداند؟

رویه: ۱. مجموعه‌ای از مقادیر واقعی پارامتر $\boldsymbol{\theta}^*$ انتخاب کنید که دامنه‌ی معقول را پوشش دهد (یک شبکه، یا نمونه‌های تصادفی از دامنه‌های معقول، مثلاً حول برآوردهای داده‌ی واقعی). ۲. برای هر $\boldsymbol{\theta}^*$ یک مجموعه‌داده با **دقیقاً همان طرح واقعی** (همان شرایط، همان تعداد trial) شبیه‌سازی کنید. ۳. مدل را با **دقیقاً همان رویه‌ی برازش واقعی** (همان بهینه‌ساز، شروع‌ها، کران‌ها) برازش کنید. ۴. $\hat{\boldsymbol{\theta}}$ را با $\boldsymbol{\theta}^*$ مقایسه کنید: نمودار پراکنش واقعی در برابر بازیابی‌شده؛ همبستگی؛ سوگیری (میانگین $\hat{\theta} - \theta^*$)؛ RMSE. ۵. پارامترهای بازیابی‌شده را **در برابر هم** هم رسم کنید. همبستگی قوی بین مثلاً $\hat{\lambda}$ و $\hat{s}$ که در مقادیر واقعی نیست، یک trade-off را آشکار می‌کند.

خواندن نتایج: نقاط روی خط همانی یعنی بازیابی خوب؛ ابری موازی با محور افقی یعنی پارامتر با این طرح قابل بازیابی نیست؛ منحنی‌ای که در دو انتها کج می‌شود یعنی سوگیری نزدیک کران‌ها. اگر بازیابی شکست بخورد، آن پارامتر را تفسیر نکنید. طرح آزمایش را عوض کنید (trial) بیشتر، شرایط دیگر) یا مدل را ساده کنید.

۴. بازیابی مدل

سؤال: اگر مدل $\mathcal{M}_a$ داده را تولید کرده باشد، آیا روش مقایسه‌ی ما $\mathcal{M}_a$ را انتخاب می‌کند؟

رویه: ۱. برای هر مدل نامزد $\mathcal{M}_a$: مجموعه‌داده‌های زیادی با طرح واقعی و با پارامترهایی از دامنه‌های معقول شبیه‌سازی کنید. ۲. **همه‌ی** مدل‌های نامزد را روی هر مجموعه‌داده برازش کنید. ۳. با معیار انتخاب‌شده (AIC، BIC، CV، . . .) یک برنده انتخاب کنید. ۴. confusion matrix $P(\text{selected} = b \mid \text{generated} = a)$ را جدول کنید.

یک روش خوب ماتریسی با درایه‌های قطری بزرگ می‌دهد. جرم خارج از قطر **تقلید مدل** (model mimicry) را نشان می‌دهد: یک مدل می‌تواند داده‌هایی بسازد که شبیه داده‌های مدل دیگر است.

چیزی که در تفسیر داده‌ی واقعی واقعاً لازم داریم برعکس است: با فرض اینکه مدل b برنده شد، چقدر محتمل است که b داده را تولید کرده باشد؟ این inversion matrix $P(\text{generated} = a \mid \text{selected} = b)$ است که با نرمال کردن هر ستون شمارش‌های درهم‌ریختگی به دست می‌آید (با فرض فراوانی پیشین برابر برای مدل‌های تولیدکننده).

> **نکته:** بازیابی مدل **سوگیری‌های معیارها** را هم آشکار می‌کند: BIC در N کوچک به مدل‌های ساده‌تر و AIC به مدل‌های پیچیده‌تر تمایل دارد. «بهترین» معیار آن است که مدل‌های نامزد شما را با طرح آزمایش شما بهتر بازیابی کند، و این دقیقاً همان چیزی است که این مطالعه اندازه می‌گیرد.

خواندن ریاضی

- confusion matrix $P(\text{selected} = b \mid \text{generated} = a)$: سطرها مدل‌های واقعی (مولد) و ستون‌ها مدل‌های انتخاب‌شده‌اند. جمع هر سطر ۱ است. هر سطر را این‌طور بخوانید: «وقتی حقیقت a است، چند بار هر مدل را انتخاب می‌کنیم؟»
- inversion matrix $P(\text{generated} = a \mid \text{selected} = b)$: همان شمارش‌ها، ولی هر ستون به ۱ نرمال شده. هر ستون را این‌طور بخوانید: «وقتی b را انتخاب کردیم، چند بار واقعاً b حقیقت بود؟» این همان سؤالی است که برای داده‌ی واقعی اهمیت دارد، جایی که فقط برنده را می‌بینیم.
- **مثال کوچک.** از هر کدام از دو مدل ۱۰۰ مجموعه داده. از A: ۹۰ بار A و ۱۰ بار B انتخاب می‌شود. از B: ۴۰ بار A و ۶۰ بار B. سطر A در confusion matrix برابر (۹۰.۰، ۱۰.۰) است. ولی از ۱۳۰ مجموعه داده‌ای که A را انتخاب کردند، فقط ۹۰ تا از A آمده بودند: $P(\text{A true} \mid \text{A selected}) = 90/130 = 0.69$.

۵. identifiability

- **ساختاری:** non-identifiable مقادیر مختلف پارامتر برای هر داده‌ای دقیقاً پیش‌بینی‌های یکسان می‌دهند. مثال‌ها: جابه‌جایی برچسب در مدل دوردی (هفته‌ی ۳)، یا مکان و مقیاس در SDT (هفته‌ی ۲). راه‌حل یک قید یا reparameterization است.
- **عملی:** non-identifiable پارامترها در اصل identifiable هستند ولی با داده‌های موجود نه. بازیابی ضعیف است و برآوردها trade-off دارند. راه‌حل طرح آزمایش بهتر یا مدل ساده‌تر است.

بازیابی پارامتر آزمون عملی identifiability است.

برای یک مهندس

- AIC و BIC همان معیارهای انتخاب مرتبه‌ی مدل‌اند که شاید از مدل‌سازی AR/ARMA بشناسید؛ BIC اساساً همان معیار MDL ریسانن است. LRT برای مدل‌های nested دوباره همان GLRT است.
- **بازیابی پارامتر** یعنی آزمودن یک تخمین‌گر روی سیگنال‌های مصنوعی با حقیقت معلوم، با همان SNR و طول داده‌ی واقعی، پیش از اعتماد به آن روی داده‌ی اندازه‌گیری‌شده. مهندس‌ها این کار را مرتب انجام می‌دهند؛ در روان‌شناسی اغلب حذف می‌شود، و به همین دلیل این درس روی آن اصرار دارد.
- confusion matrix همان ماتریس احتمال انتقال یک کانال گسسته است: ورودی = مدل مولد، خروجی = مدل انتخاب‌شده. inversion matrix ماتریس احتمال‌های پسین $P(\text{input} \mid \text{output})$ است، یعنی چیزی که یک دیکدر MAP لازم دارد، با فرض احتمال‌های پیشین برابر برای ورودی‌ها.

- non-identifiability **ساختاری** مثل یک حالت مشاهده‌ناپذیر یا ماتریس سیستم با رتبه‌ی ناقص است: هیچ مقداری از داده کمک نمی‌کند. non-identifiability **عملی** یک مسئله‌ی بدحالت است: در اصل قابل شناسایی است ولی برای داده‌ی موجود نویز خیلی زیاد است.

برای مدرس

- **بازیابی را «آزمودن ابزار» معرفی کنید.** هیچ‌کس به دماسنجی که هیچ‌وقت در آبی با دمای معلوم امتحان نشده اعتماد نمی‌کند. بازیابی همان آزمون برای یک مدل است.
- **پیش از هر نظریه‌ای یک نمودار پراکندگی مقدار واقعی در برابر بازیابی‌شده نشان دهید** (بخش C lab:) بازیابی خوب (نقطه‌ها روی قطر) کنار بازیابی بد (یک ابر صاف). تصویر خودش توضیح می‌دهد.
- confusion و inversion **را با مثال کوچک ۲×۲ بالا درس دهید؛** دانشجوها در امتحان بیش از هر چیز دیگری در این هفته این دو را با هم قاطی می‌کنند. تشبیه تست پزشکی کمک می‌کند: sensitivity یک تست با احتمال بیمار بودن کسی که تستش مثبت شده یکی نیست.
- **سؤال‌های رایج.**
  - *AIC*» یا *BIC*؟» به هدف بستگی دارد (پیش‌بینی در برابر پیدا کردن مدل درست) و در عمل به اینکه کدام در طرح آزمایش شما مدل‌ها را بهتر بازیابی می‌کند.
  - «چند مجموعه داده‌ی شبیه‌سازی‌شده؟» برای دیدن الگو ۵۰ تا ۱۰۰ برای هر حالت کافی است؛ برای انتشار بیشتر.
  - «بازیابی شکست خورد، حالا چه؟» آن پارامتر را تفسیر نکنید. طرح آزمایش را تغییر دهید یا مدل را ساده‌تر کنید.

۵.۱.۱ مثال حل‌شده

چهار مدل فراموشی که با MLE روی داده‌های هفته‌ی ۲ برازش شده‌اند NLL)های آموزش از هفته‌ی ۶)، با $N = 400$ پاسخ آیتم:

مدل	k	NLL	$\text{AIC} = 2\,\text{NLL} + 2k$	$\text{BIC} = 2\,\text{NLL} + k \ln 400$
exp	۲	۸۱۲.۲۹	۶۲.۶۳	۶۱.۷۱
pow	۲	۸۳۰.۱۹	**۶۶.۴۳**	**۶۴.۵۱**
expasym	۳	۹۱۹.۱۸	۸۴.۴۳	۸۱.۵۵
two	۴	۹۱۹.۱۸	۸۴.۴۵	۸۰.۶۱

قدم ۱: AIC برای مدل توانی. $2 \times 19.830 + 2 \times 2 = 43.66$.

قدم ۲: BIC برای مدل توانی. $\ln 400 = 5.991$، پس $2 \times 19.830 + 2 \times 5.991 = 51.64$.

قدم ۳: وزن‌های آکائیکه. تفاوت‌ها با بهترین AIC: $\Delta = (19.96, 0, 0.18, 2.18)$. پس $e^{-\Delta/2} = (0.00005, 1, 0.914, 0.336)$ که جمعشان ۲۵۰.۲ است، بنابراین

$$w^{\text{AIC}} = (0.000,\ 0.444,\ 0.406,\ 0.149).$$

وزن‌های BIC به همین روش: $(0.000,\ 0.884,\ 0.110,\ 0.005)$.

قدم ۴: آزمون نسبت درست‌نمایی، exp nested در expasym: $\Lambda = 2(29.812 - 18.919) = 21.79$ با ۱ درجه‌ی آزادی، $p \approx 3 \times 10^{-6}$. افزودن مجانب مدل نمایی را به‌طور معناداری بهتر می‌کند.

تفسیر. هر دو معیار مدل نمایی خالص را قاطعانه رد می‌کنند. AIC نمی‌تواند مدل‌های توانی و مجانبی را از هم جدا کند (وزن‌های ۴۴.۰ در برابر ۴۱.۰): از نظر پیش‌بینی تقریباً به یک اندازه خوب‌اند، که با نتایج CV هفته‌ی ۶ سازگار است. جریمه‌ی بزرگ‌تر BIC مدل توانی دوپارامتری را ترجیح می‌دهد (۸۸.۰). پارامتر اضافه‌ی مدل دوردی هیچ چیزی نمی‌خرد: NLL آن با expasym یکسان است، پس جریمه را بی‌دلیل می‌پردازد. اینکه آیا باید به این ترجیح‌ها با این طرح آزمایش اعتماد کنیم سؤالی برای بازیابی مدل است (بخش D lab).

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. اجرای آزمون نسبت درست‌نمایی و محاسبه‌ی AIC، AICc، BIC و وزن‌ها برای مدل‌های فراموشی.
۲. اجرای یک مطالعه‌ی بازیابی پارامتر برای مدل‌های توانی و نمایی با مجانب و بررسی trade-offها.
۳. اجرای یک مطالعه‌ی بازیابی مدل برای سه مدل با AIC و BIC؛ ساختن ماتریس‌های درهم‌ریختگی و معکوس.
۴. **تفسیر**: با این طرح آزمایش، از داده‌های هفته‌ی ۲ چه چیزی را می‌شود و چه چیزی را نمی‌شود نتیجه گرفت؟

زمان‌بندی: بخش A ۱۵ دقیقه · بخش B ۱۵ دقیقه · بخش C ۳۵ دقیقه · بخش D ۴۰ دقیقه · بخش E ۱۵ دقیقه.

آماده‌سازی

> Code · **کد:** `code/week07.py`، cell ۱ · سلول ۱

بخش A: آزمون نسبت درست‌نمایی (۱۵ دقیقه)

> Code · **کد:** `code/week07.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
NLL exp = 29.812, NLL expasym = 18.919
LR statistic = 21.79, df = 1, naive p = 3.05e-06, boundary-corrected p =
↪  1.52e-06
```

سؤال: چرا نمی‌توانید از همین آزمون برای مقایسه‌ی مدل‌های توانی و نمایی استفاده کنید؟

بخش B: معیارهای اطلاعاتی و وزن‌ها (۱۵ دقیقه)

Code · کد: code/week07.py، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
         k     NLL     AIC    AICc     BIC  w_AIC  w_AICc  w_BIC
model
exp      2  29.812  63.625  63.655  71.608  0.000   0.000  0.000
pow      2  19.830  43.661  43.691  51.644  0.444   0.449  0.884
expasym  3  18.919  43.837  43.898  55.812  0.406   0.405  0.110
two      4  18.919  45.837  45.939  61.803  0.150   0.146  0.006
```

بررسی حساسیت: BIC را با $N = 8$ (تعداد خانه‌ها) به‌جای ۴۰۰ دوباره حساب کنید. آیا رتبه‌بندی عوض می‌شود؟ کدام انتخاب N اینجا قابل دفاع است و چرا؟

بخش C: بازیابی پارامتر (۳۵ دقیقه)

Code · کد: code/week07.py، cell ۴ · سلول ۴

خروجی مورد انتظار (حدود ۱ دقیقه):

```
pow:
   r(true, rec)   bias   RMSE
A         0.888  0.005  0.055
d         0.965  0.003  0.070

expasym:
     r(true, rec)   bias   RMSE
A           0.802  0.008  0.077
lam         0.799  0.034  0.230
s           0.918 -0.008  0.060

expasym: corr(true lam, true s) = -0.08;  corr(recovered lam, recovered
↪  s) = 0.03
```

تفسیر: ۱. با این طرح آزمایش، کدام پارامترها خوب بازیابی می‌شوند؟ تفسیر کدام را با تردید انجام می‌دهید؟ ۲. نرخ زوال λ در expasym با فاصله‌ی زیاد بیشترین RMSE را دارد (۰.۲۳ روی دامنه‌ی ۰.۵ تا ۱). به نمودارش نگاه کنید: بازیابی برای کدام مقادیر واقعی شکست می‌خورد و چرا؟ (راهنمایی: اگر زوال خیلی سریع باشد، بیشترِ افت پیش از دومین فاصله‌ی آزمون اتفاق می‌افتد؛ پس داده‌ها چه شکلی پیدا می‌کنند؟) اینجا λ و s بازیابی‌شده همبستگی ندارند (r = ۰.۰۳)، پس این عدم دقت است نه trade-off. این را با trade-off آشکار d–A مدل توانی که در هفته‌ی ۵ دیدیم مقایسه کنید. ۳. چه تغییری در طرح آزمایش بازیابی λ و s را بهتر می‌کند؟ یک ایده را در تمرین ۳ آزمون کنید.

بخش D: بازیابی مدل (۴۰ دقیقه)

> **کد** · Code · سلول ۵ · cell ۵، `code/week07.py`

خروجی مورد انتظار (حدود ۱ تا ۲ دقیقه):

```
AIC confusion matrix (rows = generating model, columns = selected model):
          exp   pow  expasym
exp      0.91  0.00     0.09
pow      0.03  0.82     0.15
expasym  0.06  0.25     0.69
AIC inversion matrix (rows = generating model, columns = selected model):
          exp   pow  expasym
exp      0.91  0.00     0.10
pow      0.03  0.77     0.16
expasym  0.06  0.23     0.74

BIC confusion matrix (rows = generating model, columns = selected model):
          exp   pow  expasym
exp      0.99  0.01     0.00
pow      0.05  0.94     0.01
expasym  0.09  0.58     0.33
BIC inversion matrix (rows = generating model, columns = selected model):
          exp   pow  expasym
exp      0.88  0.01     0.00
pow      0.04  0.61     0.03
expasym  0.08  0.38     0.97
```

تفسیر: ۱. کدام مدل بیشتر با کدام اشتباه گرفته می‌شود؟ (با AIC، ٪۲۵ مجموعه‌داده‌های expasym برچسب توانی می‌گیرند؛ با BIC، ٪۵۸.) این تقلید را بر حسب شکل منحنی‌ها توضیح دهید. ۲. AIC و BIC را مقایسه کنید. کدام مدل‌های ساده‌تر را بهتر بازیابی می‌کند و کدام مدل پیچیده‌تر را؟ ۳. در بخش B، BIC برای داده‌ی واقعی مدل توانی را انتخاب کرد. با استفاده از BIC inversion matrix، چقدر باید مطمئن باشیم که داده‌ها را یک مدل توانی تولید کرده است؟ (فقط ٪۶۱ از حکم‌های «توانی» BIC از داده‌های تولیدشده با مدل توانی آمده‌اند؛ ٪۳۸ از expasym.)

بخش E: نتیجه‌گیری درباره‌ی داده‌های هفته‌ی ۲ (۱۵ دقیقه)

یک پاراگراف (۶ تا ۱۰ جمله) بنویسید که یک داور بپذیرد و خلاصه کند داده‌های هفته‌ی ۲ درباره‌ی شکل فراموشی چه می‌گویند. از بخش‌های A تا D و نتایج CV هفته‌ی ۶ استفاده کنید و بگویید با این طرح آزمایش چه چیزی را نمی‌شود نتیجه گرفت.

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. وزن‌های AIC و BIC مثال حل‌شده را با دست (ماشین‌حساب) حساب کنید و با بخش B مقایسه کنید.

تمرین ۲ ⋆. بخش B را با AICc تکرار کنید. برای چه Nای AICc و AIC برای مدل دوردی به‌طور قابل توجهی فرق می‌کنند؟

تمرین ۳ ⋆⋆ **(طراحی برای بازیابی).** بازیابی expasym بخش C را با فاصله‌های گسترش‌یافته به $\{0.25, 1, 2, 4, 7, 14, 30, 60, 90\}$ روز، و جداگانه با $n = 200$ آیتم، دوباره اجرا کنید. کدام تغییر بیشتر به بازیابی λ و s کمک می‌کند؟

تمرین ۴ ⋆⋆ (CV) **در بازیابی مدل).** در بخش D، AIC/BIC را با CV پنج‌بخشی (از هفته‌ی ۶) برای ۳۰ شبیه‌سازی از هر مدل جایگزین کنید. آیا CV در بازیابی مدل‌ها از AIC بهتر است یا بدتر؟ آیا به زمان محاسبه‌اش می‌ارزد؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: بازیابی در** SDT**).** برای آزمایش پاداش هفته‌ی ۴ (سه شرط، ۸۰ + ۸۰ trial در هر شرط)، یک بازیابی مدل برای «d' مشترک» در برابر «d' جداگانه» با آزمون نسبت درست‌نمایی در $\alpha = .05$ و با BIC اجرا کنید. هر روش چند بار به‌اشتباه ادعا می‌کند که پاداش حساسیت را تغییر می‌دهد؟ برای اینکه یک تفاوت واقعی حساسیت به اندازه‌ی ۰.۳ را در ۸۰٪ شبیه‌سازی‌ها تشخیص دهید، در هر شرط چند trial لازم است؟

lab check-off

نشان دهید: (۱) جدول معیارهای اطلاعاتی با وزن‌ها (بخش B)، (۲) نمودارهای پراکنش بازیابی با یک جمله درباره‌ی اینکه کدام پارامتر بدتر بازیابی می‌شود و چرا، (۳) ماتریس‌های درهم‌ریختگی AIC و BIC، و (۴) پاراگراف بخش E.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

مقایسه‌ی منحنی‌های یادگیری یک مدل هوش مصنوعی. LLMها می‌توانند یک تکلیف تازه را از چند مثال در prompt یاد بگیرند («یادگیری درون‌بافتی» یا in-context learning). اینکه خطا با تعداد مثال‌ها k چطور کم می‌شود یک منحنی یادگیری است، و سؤال «نمایی یا توانی؟» همان سؤال lab این هفته (و منحنی‌های فراموشی هفته‌ی ۲) است. معیارهای اطلاعاتی، بازیابی مدل و identifiability بدون تغییر به کار می‌آیند. طرح هم به همان اندازه مهم است: با مقادیر کم k و آیتم‌های آزمون کم، ممکن است دو منحنی اصلاً قابل تمیز نباشند.

Code ۰۶ · **کد:** `code/week07.py`، cell ۰۶ · سلول ۶

خروجی مورد انتظار:

```
{'exponential': 41.6, 'power': 40.4} Akaike weights: [0.362 0.638]
```

داده از یک قانون توانی تولید شده، ولی شواهد ضعیف است (وزن‌های ۶۴.۰ در برابر ۳۶.۰).

امتحانش کنید (بدون نیاز به API**).** ⋆ - در همین طرح یک بازیابی مدل (هفته‌ی ۷، بخش D) اجرا کنید: ۵۰ مجموعه داده از هر منحنی. confusion matrix را بسازید. - ⋆⋆ طرح را عوض کنید: مقادیر بیشتری برای k (تا ۱۲۸) یا ۲۰۰ آیتم آزمون برای هر k. کدام تغییر بازیابی مدل را بیشتر بهتر می‌کند؟ - ⋆⋆ بحث: مقاله‌ای از یک منحنی برازش‌شده نتیجه می‌گیرد که «یادگیری درون‌بافتی، مثل تمرین در انسان، از قانون توانی پیروی می‌کند». پیش از پذیرفتن این مقایسه با انسان، چه چیزی باید ببینید؟

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **تفسیر یک مقدار** AIC **به‌تنهایی.** فقط تفاوت بین مدل‌هایی که روی داده‌ی یکسان برازش شده‌اند معنا دارد.
۲. **استفاده از** LRT **برای مدل‌های** non-nested**،** یا خواندن یک LRT غیرمعنادار به‌عنوان شاهدی به نفع مدل ساده‌تر.

۳. **فکر کردن اینکه BIC همان AIC» بیزی» با همان هدف است.** BIC به دنبال شناسایی مدل تولیدکننده‌ی داده است؛ AIC به دنبال پیش‌بینی. می‌توانند به دلایل موجه با هم مخالف باشند.
۴. N **نامشخص.** همیشه گزارش کنید چه چیزی به‌عنوان یک مشاهده شمرده شده؛ BIC و AICc به آن بستگی دارند.
۵. **نادیده گرفتن بازیابی.** پارامتری که با طرح آزمایش شما قابل بازیابی نیست نباید تفسیر شود، هر قدر هم برازش خوب باشد.
۶. **اجرای بازیابی با طرح یا رویه‌ی برازشی متفاوت** از تحلیل واقعی. نتایج بازیابی وابسته به طرح آزمایش‌اند.
۷. **خواندن** confusion matrix **به جای** .inversion matrix «داده‌های مدل A در ٪۹۰ موارد به‌عنوان A بازیابی می‌شوند» با «وقتی A برنده می‌شود در ٪۹۰ موارد مدل واقعی است» یکی نیست.
۸. **انتخاب دامنه‌های پارامتر برای بازیابی که از مقادیر معقول پهن‌تر یا باریک‌ترند.** دامنه‌ی خیلی پهن همبستگی‌ها را باد می‌کند؛ دامنه‌ی خیلی باریک مشکلات را پنهان می‌کند.

۹.۱.۱ خودآزمایی

۱. فرمول‌های AIC و BIC را بنویسید. برای چه Nای BIC هر پارامتر را بیشتر از AIC جریمه می‌کند؟ **پاسخ** $\mathrm{AIC} = -2\hat{\ell} + 2k$؛ $\mathrm{BIC} = -2\hat{\ell} + k \ln N$. جریمه‌ی BIC وقتی از AIC بیشتر است که $\ln N > 2$، یعنی $N > e^2 \approx 7.4$، پس برای $N \geq 8$.

۲. مدل A دارای AIC = ۴.۲۱۰ و مدل B دارای AIC = ۹.۲۱۲ است. وزن‌های آکائیکه را حساب و تفسیر کنید. **پاسخ** $\Delta = (0, 2.5)$، پس $e^{-\Delta/2} = (1, 0.287)$ و $w = (0.777, 0.223)$. A حدود ۵.۳ به ۱ به‌عنوان پیش‌بینی‌کننده‌ی بهتر ترجیح دارد، ولی B هنوز پشتیبانی قابل توجهی دارد.

۳. چرا آزمون نسبت درست‌نمایی می‌تواند نمایی و نمایی با مجانب را مقایسه کند ولی نمایی و توانی را نه؟ **پاسخ** نمایی حالت خاصی از مدل مجانبی است ($s = 0$)، پس مدل‌ها nested هستند و $2\Delta\ell$ تحت فرض صفر توزیع χ^2 معلومی دارد. نمایی و توانی nested نیستند: هیچ‌کدام حالت خاص دیگری نیست.

۴. مراحل یک مطالعه‌ی بازیابی پارامتر را شرح دهید. **پاسخ** مقادیر واقعی معقول برای پارامترها انتخاب کنید؛ با طرح واقعی داده شبیه‌سازی کنید؛ با رویه‌ی برازش واقعی برازش کنید؛ مقادیر بازیابی‌شده را با واقعی مقایسه کنید (نمودار پراکنش، همبستگی، سوگیری، RMSE)؛ همبستگی بین پارامترهای بازیابی‌شده را برای یافتن trade-off بررسی کنید.

۵. در یک مطالعه‌ی بازیابی، λ و s بازیابی‌شده با $r = -0.8$ همبسته‌اند، با اینکه مقادیر واقعی مستقل کشیده شده بودند. این یعنی چه؟ **پاسخ** یک trade-off: با این طرح آزمایش، ترکیب‌های مختلف نرخ زوال و مجانب پیش‌بینی‌های تقریباً یکسانی می‌دهند، پس خطا در یکی با دیگری جبران می‌شود. مقادیر تکی λ و s نباید جداگانه تفسیر شوند. طرح آزمایش بهتر یا reparameterization لازم است.

۶. تفاوت confusion matrix و inversion matrix را در بازیابی مدل توضیح دهید. **پاسخ** درهم‌ریختگی: $P(\text{selected} \mid \text{generated})$ که سطرهایش جمع ۱ دارند و رفتار روش را برای هر مدل واقعی توصیف می‌کند. معکوس: $P(\text{generated} \mid \text{selected})$ که ستون‌هایش جمع ۱ دارند (با فرض پیشین برابر برای مدل‌های تولیدکننده) و به ما می‌گوید هنگام تحلیل داده‌ی واقعی چقدر به یک برنده‌ی مشخص اعتماد کنیم.

۷. یک بازیابی مدل نشان می‌دهد وقتی مدل دوپارامتری داده را تولید کرده، AIC در ٪۴۰ موارد مدل سه‌پارامتری را انتخاب می‌کند. چه می‌کنید؟ **پاسخ** با این طرح آزمایش، به برد AIC برای مدل پیچیده با احتیاط نگاه کنید: بازیابی BIC یا CV را بررسی کنید که ممکن است محافظه‌کارتر باشند، طرح آزمایش را بهتر کنید (trial بیشتر، شرایط آگاهی‌بخش‌تر)، و نتایج بازیابی را کنار مقایسه‌ی داده‌ی واقعی گزارش کنید.

۱۰.۱.۱ تکلیف

ادامه‌ی A3 (موعد ابتدای درس هفته‌ی ۹)

کارهای ۴ (معیارهای اطلاعاتی) و ۵ (بازیابی پارامتر و مدل) A3 از مطالب این هفته استفاده می‌کنند. شرح کامل در هفته‌ی ۶ است. کد `parameter_recovery` امروز و حلقه‌ی بازیابی مدل را دوباره به کار ببرید: طوری طراحی شده‌اند که مستقیماً قابل تطبیق باشند.

پروژه‌ی پایانی: تشکیل گروه‌ها و انتشار راهنمای پیشنهاد

- **گروه‌ها:** ۱ یا ۲ نفر. تا پایان این هفته گروهتان را نزد دستیار آموزشی ثبت کنید.
- **کار:** یک مدل شناختی انتخاب کنید و کل مسیر مدل‌سازی را روی یک مجموعه‌داده (شبیه‌سازی‌شده، باز، یا داده‌ی خودتان) اجرا کنید: برازش، ارزیابی (دست‌کم یک مقایسه با یک مدل جایگزین)، بازیابی (دست‌کم یک تحلیل بازیابی پارامتر)، تفسیر. **گروه‌های دونفره** یک تحلیل بیزی/MCMC یا سلسله‌مراتبی و یک بیانیه‌ی سهم فردی هم اضافه می‌کنند.
- **پیشنهاد پروژه (موعد ابتدای درس هفته‌ی ۹، حداکثر ۲ صفحه):** سؤال پژوهش، مدل(ها) با معادلات، منبع داده و طرح آزمایش، تحلیل‌های مقایسه و بازیابی برنامه‌ریزی‌شده، و زمان‌بندی. شرح کامل پروژه و روبریک جداگانه توزیع می‌شود (`project_brief.md`).
- **مطمئن نیستید چه چیزی را مدل کنید؟** موضوعات هفته‌های ۱۴–۱۵ (دسته‌بندی exemplar، drift-diffusion، یادگیری تقویتی) همه پروژه‌های خوبی هستند، همین‌طور گسترش مدل‌های فراموشی و SDT این درس.

۱۱.۱.۱ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۱۰.** مقایسه‌ی مدل‌ها: آزمون نسبت درست‌نمایی، AIC، BIC و وزن‌هایشان؛ فرض‌ها و محدودیت‌هایشان. (منبع اصلی.)
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۷** (مقدمه). اینکه رویکرد بیزی به مقایسه‌ی مدل‌ها چه ارتباطی با روش‌های این هفته دارد؛ آمادگی برای هفته‌ی ۱۰.
- اختیاری، خارج از فهرست درس: Collins, A. G. E. & Wilson, R. C., (۲۰۱۹). Ten simple rules for the computational modeling of behavioral data. *eLife,* ۸، e49547. راهنمایی عملی که بازیابی پارامتر و مدل را رویه‌ی استاندارد می‌داند.

پیش‌نمایش هفته‌ی ۸: میان‌ترم. درس یک مرور یکپارچه است که در آن کل مسیر (شبیه‌سازی، برازش، ارزیابی، بازیابی، تفسیر) را روی یک مجموعه‌داده‌ی جدید اجرا می‌کنیم؛ زمان lab به آزمون میان‌ترم اختصاص دارد.