مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۸: مرور میان‌ترم: کل مسیر مدل‌سازی در یک مطالعه‌ی موردی

فهرست مطالب

۱ **ارزیابی مدل‌های شناختی** ۱

۱.۱ هفته‌ی ۸: مرور میان‌ترم: کل مسیر مدل‌سازی در یک مطالعه‌ی موردی ۱

۱.۱.۱ واژه‌های کلیدی ۱

۱.۱.۲ اهداف یادگیری ۲

۱.۱.۳ مقدمه ۳

۱.۱.۴ جزوه‌ی درس ۳

۱.۱.۵ مثال حل‌شده ۶

۱.۱.۶ lab (۲ ساعت): آزمون میان‌ترم + مشاوره‌ی پروژه ۸

۱.۱.۷ ارتباط با هوش مصنوعی و LLMها ۱۰

۱.۱.۸ اشتباهات رایج و برداشت‌های نادرست (۱۰ مورد اول از هفته‌های ۱ تا ۷) ۱۰

۱.۱.۹ خودآزمایی (سؤال‌های تمرینی به سبک آزمون) ۱۱

۱.۱.۱۰ تکلیف ۱۲

۱.۱.۱۱ مطالعه‌ی بیشتر ۱۲

فصل ۱

ارزیابی مدل‌های شناختی

۱.۱ هفته‌ی ۸: مرور میان‌ترم: کل مسیر مدل‌سازی در یک مطالعه‌ی موردی

مرور فصل‌های ۱ تا ۳ · درس ۱ ساعت (مطالعه‌ی موردی یکپارچه) · زمان lab: **آزمون میان‌ترم** (۹۰ دقیقه) + مشاوره‌ی پروژه (۳۰ دقیقه)

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
formalize / formal model	مدل فرمال / فرمال کردن	نوشتن نظریه به شکل معادله یا الگوریتم
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
criterion (c)	ملاک	آستانه‌ی تصمیم؛ نشان‌دهنده‌ی سوگیری پاسخ
least squares	کمترین مربعات	روش برازش با کمینه کردن مجموع مربع خطاها
cross-validation (CV)	اعتبارسنجی متقابل (cross-validation)	برازش روی بخشی از داده و آزمون روی بخش کنارگذاشته
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز

English	فارسی	توضیح کوتاه
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
RMSD / SSE	مجموع مربعات خطا / ریشه‌ی میانگین مربع انحراف	معیارهای فاصله‌ی داده و پیش‌بینی
NLL / log-likelihood	لگاریتم درست‌نمایی / منفی آن	مقداری که بهینه‌سازها کمینه یا بیشینه می‌کنند
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
noise	نویز	تغییرات تصادفی در شواهد یا در داده
deviance (G^2)	انحراف (deviance)	معیار عدم برازش نسبت به مدل اشباع‌شده
BIC / AIC	معیار اطلاعاتی آکائیکه / بیزی	برازش به‌علاوه‌ی جریمه برای تعداد پارامتر
research design	طرح آزمایش	شرایط، تعداد کوشش‌ها و نمونه‌ها
confusion matrix	ماتریس درهم‌ریختگی (confusion matrix)	P(مدل انتخاب‌شده
hit	اصابت (hit)	پاسخ «بله» وقتی علامت وجود دارد
response time (RT)	زمان واکنش	فاصله‌ی ارائه‌ی محرک تا پاسخ
signal detection theory (SDT)	نظریه‌ی تشخیص علامت	مدلی که حساسیت را از سوگیری پاسخ جدا می‌کند
evidence	شواهد	اطلاعاتی که برای تصمیم جمع می‌شود
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
test data / training	داده‌ی آموزش / آزمون	داده‌ی برازش / داده‌ی کنارگذاشته برای سنجش

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. کل مسیر مدل‌سازی (فرمال‌سازی ← شبیه‌سازی ← برازش ← ارزیابی ← بازیابی ← تفسیر) را روی یک مسئله‌ی جدید بدون راهنمایی قدم‌به‌قدم **اجرا کنند**.
۲. درست‌نمایی، روش برازش و روش ارزیابی مناسب برای یک مجموعه‌داده را **انتخاب کنند** و هر انتخاب را **توجیه کنند**.
۳. مجموعه‌ای از برازش‌های مدل‌های رقیب، معیارهای اطلاعاتی و نتایج بازیابی را **تفسیر کنند** و یک نتیجه‌گیری قابل دفاع که محدودیت‌هایش را می‌گوید **بنویسند**.
۴. فرمول‌های کلیدی هفته‌های ۱ تا ۷ (برگه‌ی فرمول میان‌ترم) را **به خاطر بیاورند** و **به کار ببرند**.

۳.۱.۱ مقدمه

در هفت هفته یک جعبه‌ابزار را تکه‌تکه ساختیم: مدل‌های فرمال (هفته‌های ۱–۲)، کمترین مربعات و بهینه‌سازی (هفته‌ی ۳)، بیشینه درست‌نمایی (هفته‌ی ۴)، عدم قطعیت و چند شرکت‌کننده (هفته‌ی ۵)، cross-validation (هفته‌ی ۶)، معیارهای اطلاعاتی و بازیابی (هفته‌ی ۷). هر lab یکی دو تکه را تمرین کرد. پژوهش واقعی همه‌ی آن‌ها را هم‌زمان، به ترتیب درست و با قضاوت درباره‌ی اینکه چه چیزی مهم است، لازم دارد.

درس امروز کل مسیر را روی یک مسئله‌ی **جدید** اجرا می‌کند: آیا مطالعه‌ی بیشتر یک کلمه آن را به‌یادماندنی‌تر می‌کند (حساسیت بیشتر)، و اگر بله، حساسیت با تکرارها چطور رشد می‌کند؟ این مطالعه‌ی موردی بهترین آمادگی برای میان‌ترم هم هست که از شما می‌خواهد همین نوع تصمیم‌ها را بگیرید و توجیه کنید.

۴.۱.۱ جزوه‌ی درس

به زبان ساده این هفته همه‌ی تکه‌های نیمه‌ی اول درس را روی یک سؤال جدید کنار هم می‌گذارد: آیا مطالعه‌ی بیشتر یک کلمه، بازشناسی بعدی آن را آسان‌تر می‌کند؟ نظریه را به شکل یک مدل SDT می‌نویسیم که در آن حساسیت d' به تعداد تکرارها بستگی دارد. سه نسخه برای این وابستگی پیشنهاد می‌کنیم (بدون اثر، افزایش هموار، هر الگویی)، هر سه را با بیشینه‌ی درست‌نمایی برازش می‌کنیم، بررسی می‌کنیم که آیا هرکدام عدم برازش دارد (G^2)، آن‌ها را مقایسه می‌کنیم (LRT، AIC، BIC)، بررسی می‌کنیم که روش در این طرح آزمایش کار می‌کند (بازیابی)، و در پایان مدل برنده را به زبان ساده‌ی روان‌شناختی تفسیر می‌کنیم، از جمله اینکه داده چه چیزهایی را نمی‌تواند به ما بگوید. اگر بتوانید این یک مثال را از اول تا آخر دنبال کنید، نیمه‌ی اول درس را فهمیده‌اید.

زمان‌بندی پیشنهادی (۶۰ دقیقه): نقشه‌ی مفهومی ۱۰ · مطالعه‌ی موردی ۴۰ · توضیح آزمون ۱۰.

۱. نقشه‌ی مفهومی هفته‌های ۱ تا ۷

مرحله	سؤال	ابزارها	هفته
فرمال‌سازی	نظریه دقیقاً چه ادعایی دارد؟	پنج جزء یک مدل؛ پارامترها به‌عنوان سازه‌های روان‌شناختی	۱–۲
شبیه‌سازی	مدل چه کاری می‌تواند (و نمی‌تواند) بکند؟	شبیه‌سازی مستقیم، بررسی‌های تحلیلی، نمودار پیش‌بینی‌ها	۱–۲
برازش	کدام مقادیر پارامتر داده‌ها را بهتر توضیح می‌دهند؟	SSE / کمترین مربعات؛ MLE / NLL؛ شبکه، Nelder–Mead، L-BFGS-B؛ multi-start؛ کران‌ها و reparameterization	۳–۴
سنجش عدم قطعیت	برآوردها چقدر دقیق‌اند؟	SE از Hessian (Wald)، profile likelihood، bootstrap	۵

مرحله	سؤال	ابزارها	هفته
ارزیابی (مطلق)	آیا عدم برازش مدل از نویز بیشتر است؟	باقی‌مانده‌ها، G^2	۲–۴
ارزیابی (نسبی)	کدام مدل بهتر تعمیم پیدا می‌کند؟	CV، LRT، AIC/AICc/BIC، وزن‌ها	۶–۷
بازیابی	آیا روش با این طرح آزمایش می‌تواند کار کند؟	بازیابی پارامتر، بازیابی مدل (ماتریس‌های درهم‌ریختگی و معکوس)	۷
تفسیر	از نظر روان‌شناختی چه معنایی دارد و چه چیزی را نمی‌توانیم نتیجه بگیریم؟	معنای پارامترها، محدودیت‌های طرح آزمایش، خطاهای میانگین‌گیری	همه

راهنمای انتخاب درست‌نمایی:

داده	مدل نویز طبیعی	هفته
شمارش از n (یادآوری، hit، false alarm)	دوجمله‌ای	۲، ۴
انتخاب‌های دودویی تکی	برنولی	۴
پیوسته، تقریباً متقارن، با واریانس برابر (مثلاً میانگین زمان واکنش بلوک‌ها)	گاوسی (= کمترین مربعات)	۴–۵

۲. مطالعه‌ی موردی: آیا تکرار حساسیت حافظه را بالا می‌برد؟

طرح آزمایش. در یک آزمایش حافظه‌ی بازشناسی، کلمه‌ها ۱، ۲ یا ۴ بار مطالعه می‌شوند. در آزمون، برای هر شرط تکرار ۱۰۰ کلمه‌ی قدیمی و ۱۰۰ کلمه‌ی جدید (فریبنده یا lure) ارائه می‌شود و شرکت‌کننده می‌گوید «قدیمی» یا «جدید». چون کلمه‌های فریبنده هرگز مطالعه نشده‌اند، **یک** نرخ false alarm مشترک برای همه‌ی شرایط و **سه** نرخ hit داریم.

فرمال‌سازی SDT) با ملاک مطلق). کلمه‌های جدید شواهد $X \sim \mathcal{N}(0,1)$ و کلمه‌های قدیمی‌ای که r بار مطالعه شده‌اند $X \sim \mathcal{N}(d'_r, 1)$ تولید می‌کنند؛ شرکت‌کننده اگر $X > \kappa$ باشد می‌گوید «قدیمی»، با یک ملاک κ برای همه‌ی آیتم‌های آزمون (آیتم‌ها در هم آمیخته‌اند، پس شرکت‌کننده نمی‌داند هر آیتم از کدام شرط است). پس

$$H_r = \Phi(d'_r - \kappa), \qquad F = \Phi(-\kappa).$$

سه مدل رقیب برای وابستگی d' به تکرارها:

مدل	d'_r	k	ادعا
$\mathcal{M}_0$ (بی‌اثر)	δ_0	۲	تکرار حساسیت را تغییر نمی‌دهد
$\mathcal{M}_1$ (خطی–لگاریتمی)	$\delta_0 + \delta_1 \log_2 r$	۳	هر دو برابر شدن مطالعه همان مقدار حساسیت اضافه می‌کند

مدل	d'_r	k	ادعا
$\mathcal{M}_2$ (آزاد)	d'_1, d'_2, d'_4	۴	هر الگویی (اشباع‌شده: ۴ پارامتر برای ۴ نرخ)

$\mathcal{M}_0 \subset \mathcal{M}_1 \subset \mathcal{M}_2$، پس همه‌ی جفت‌ها nested هستند.

درست‌نمایی. دوجمله‌ای برای هر یک از چهار شمارش (سه شمارش hit، یک شمارش false alarm).

کد lab در ادامه همه‌ی مراحل را اجرا می‌کند. دانشجویان آن را برای آمادگی آزمون در خانه اجرا می‌کنند؛ در درس خروجی‌ها مرور می‌شوند.

خواندن ریاضی

- $H_r = \Phi(d'_r - \kappa)$ و $F = \Phi(-\kappa)$: همان SDT هفته‌ی ۲، ولی ملاک به‌صورت یک موقعیت **مطلق** κ روی محور شواهد نوشته شده (از مرکز منحنی «کلمه‌ی جدید» سنجیده می‌شود) به جای اینکه نسبت به نقطه‌ی وسط سنجیده شود. کلمه‌های جدید: منحنی در ۰، پس F مساحت سمت راست κ است، یعنی $\Phi(-\kappa)$. کلمه‌های قدیمی که r بار مطالعه شده‌اند: منحنی در d'_r، پس $H_r = \Phi(d'_r - \kappa)$.
- یک κ برای همه‌ی شرایط: همه‌ی کلمه‌های آزمون با هم مخلوط‌اند، پس شرکت‌کننده نمی‌تواند برای کلمه‌هایی که یک بار و کلمه‌هایی که چهار بار مطالعه شده‌اند آستانه‌ی متفاوتی به کار ببرد.
- $\log_2 r$: لگاریتم در پایه‌ی ۲، پس $\log_2 1 = 0$، $\log_2 2 = 1$ و $\log_2 4 = 2$. در مدل $\mathcal{M}_1$، $d'_r = \delta_0 + \delta_1 \log_2 r$ یعنی: δ_0 حساسیت بعد از یک بار مطالعه است، و هر دو برابر شدن مطالعه δ_1 اضافه می‌کند.
- **عددهای مثال حل‌شده:** $\hat{\kappa} = 1.04$ می‌دهد $F = \Phi(-1.04) = 0.15$ ✓. با $\hat{d}'_1 = 0.82$: $H_1 = \Phi(0.82 - 1.04) = \Phi(-0.22) = 0.41$، نزدیک مقدار مشاهده‌شده‌ی ۰.۴۰ ✓.

برای یک مهندس مسیر نقشه‌ی مفهومی همان روند **شناسایی سیستم** (system identification) است که می‌شناسید: ساختارهای مدل نامزد را انتخاب کن، پارامترها را تخمین بزن (ML)، اعتبارسنجی کن (آزمون باقی‌مانده‌ها $G^2 \approx$)، مرتبه‌ی مدل را انتخاب کن (LRT/AIC/BIC $\approx$ GLRT/AIC/MDL)، و روش را روی داده‌ی شبیه‌سازی‌شده با حقیقت معلوم وارسی کن (بازیابی). دو تفاوت ارزش تأکید در کلاس را دارند: «سیستم» یک آدم است که خود پارامترهایش نتیجه‌ی علمی‌اند، و مقدار داده با معیارهای مهندسی خیلی کم است (۴۰۰ پاسخ دودویی)، پس عدم قطعیت و بازیابی خیلی مهم‌ترند.

برای مدرس

- **جدول نقشه‌ی مفهومی را ستون اصلی جلسه کنید.** برای هر سطر، خروجی متناظر در مطالعه‌ی موردی را نشان دهید (مثلاً «ارزیابی مطلق» ← ستون G^2). دانشجوها می‌بینند هر ابزار جایی دارد.
- **پیش از خودتان از کلاس بخواهید تفسیر کند.** جدول نتایج را بدون پاراگراف تفسیر نشان دهید و بگذارید گروه‌های کوچک دو جمله بنویسند: «چه نتیجه‌ای می‌گیریم و چه نتیجه‌ای نمی‌توانیم بگیریم؟» بعد با متن مقایسه کنید. این دقیقاً مهارتی است که میان‌ترم می‌سنجد.
- **توضیح امتحان:** به دانشجوها بگویید امتحان به تصمیم‌های مستدل (کدام درست‌نمایی، کدام معیار، چرا بازیابی مهم است) بیشتر از محاسبه نمره می‌دهد. یک سؤال به سبک امتحان از بخش خودآزمایی نشان دهید.
- **مشاوره‌ی پروژه (وقت lab):** از هر تیم سه سؤال بپرسید: سؤال شناختی شما چیست؟ کدام پارامتر یا مقایسه‌ی مدل به آن جواب می‌دهد؟ آیا طرح آزمایش شما می‌تواند آن را بازیابی کند؟ بیشتر پیشنهادهای ضعیف در سؤال سوم شکست می‌خورند.

۵.۱.۱ مثال حل‌شده

نتایج مطالعه‌ی موردی برای یک شرکت‌کننده‌ی شبیه‌سازی‌شده (مدل واقعی $\mathcal{M}_1$ با $\delta_0 = 0.8$، $\delta_1 = 0.6$، $\kappa = 1.0$)، از کد بخش .lab اعداد گرد شده‌اند.

قدم ۱: داده.

شرط	کلمه‌های قدیمی	پاسخ «قدیمی»	نرخ
$r = 1$	۱۰۰	۴۰	۴۰.۰
$r = 2$	۱۰۰	۶۶	۶۶.۰
$r = 4$	۱۰۰	۸۰	۸۰.۰
جدید (فریبنده)	۱۰۰	۱۵	۱۵.۰

قدم ۲: برازش و ارزیابی MLE)، $N = 400$ پاسخ):

مدل	k	NLL	G^2 (df، p)	AIC	BIC	w_{AIC}	w_{BIC}	$\hat{d}'_{1,2,4}$	$\hat{\kappa}$
$\mathcal{M}_0$ بی‌اثر	۲	۲۷.۲۷	۵۵.۳۵ (۲، $<$ ۰۰۱.)	۵۴.۵۸	۵۲.۶۶	۰۰.۰	۰۰.۰	۳۴.۱، ۳۴.۱، ۳۴.۱	۰۴.۱
$\mathcal{M}_1$ خطی–لگاریتمی	۳	۷۷.۹	۵۴.۰ (۱، ۴۶.)	**۵۳.۲۵**	**۵۱.۳۷**	**۶۷.۰**	**۹۴.۰**	۳۷.۱، ۸۲.۰، ۹۳.۱	۰۴.۱
$\mathcal{M}_2$ آزاد	۴	۵۰.۹	۰ (اشباع‌شده)	۹۹.۲۶	۹۶.۴۲	۳۳.۰	۰۶.۰	۴۵.۱، ۷۸.۰، ۸۸.۱	۰۴.۱

آزمون‌های نسبت درست‌نمایی: $\mathcal{M}_0$ در برابر $\mathcal{M}_1$: $\Lambda = 35.01$، $\mathrm{df} = ۱$، $p < .001$؛ $\mathcal{M}_1$ در برابر $\mathcal{M}_2$: $\Lambda = 0.54$، $\mathrm{df} = ۱$، $p = .46$.

بازیابی با این طرح آزمایش (کد lab، بلوک دوم): پارامترهای $\mathcal{M}_1$ خوب بازیابی می‌شوند ($r = 0.89$ تا 0.93) و BIC مدل تولیدکننده را در ۸۷ تا ۹۸ درصد شبیه‌سازی‌ها شناسایی می‌کند.

قدم ۳: تفسیر. تکرار به‌وضوح حساسیت را بالا می‌برد: مدل بی‌اثر به‌شدت بد برازش می‌شود ($G^2 = 35.5$، $p < .001$) و همه‌ی معیارها آن را رد می‌کنند. مدل خطی–لگاریتمی با یک پارامتر کمتر به خوبی مدل اشباع‌شده برازش می‌شود (LRT با $p = .46$) و هم AIC و هم BIC آن را ترجیح می‌دهند. برآورد $\hat{\delta}_1 \approx 0.55$ یعنی هر دو برابر شدن مطالعه تقریباً نیم واحد d' اضافه می‌کند. نتایج بازیابی نشان می‌دهد که با این طرح آزمایش، هم به پارامترها و هم به انتخاب مدل می‌شود اعتماد کرد. هشدارها: این یک شرکت‌کننده‌ی شبیه‌سازی‌شده است؛ با فقط سه سطح تکرار، یک روند خطی–لگاریتمی را نمی‌شود از خیلی منحنی‌های صعودی دیگر (مثلاً یک تابع توانی از r) جدا کرد؛ و یک ملاک واحد κ فرض می‌کند شرکت‌کننده پیش از پاسخ نمی‌داند یک آیتم چند بار مطالعه شده است.

۶.۱.۱ lab (۲ ساعت): آزمون میان‌ترم + مشاوره‌ی پروژه

آزمون میان‌ترم (۹۰ دقیقه، در زمان lab)

- **شکل:** کتبی، کتاب‌بسته. یک **برگه‌ی فرمول** (در ادامه) داده می‌شود. بدون لپ‌تاپ: سؤال‌ها شامل خواندن تکه‌کدهای کوتاه و تفسیر خروجی‌هاست، نه نوشتن کد از صفر.
- **محدوده:** هفته‌های ۱ تا ۷ (فصل‌های ۱ تا ۳)، با تأکید بر فهم و تفسیر (هدف ویژه‌ی ۲ درس).
- **انواع سؤال:** (۱) سؤال‌های مفهومی کوتاه؛ (۲) یک محاسبه‌ی دستی (مثلاً d' و c، یک درست‌نمایی یا NLL، AIC/BIC و وزن‌ها)؛ (۳) خواندن کد و پیش‌بینی یا توضیح خروجی آن؛ (۴) تفسیر یک جدول برازش، نمودار باقی‌مانده‌ها یا ماتریس بازیابی/درهم‌ریختگی؛ (۵) یک سؤال کوتاه طراحی («چه چیزی را تغییر می‌دادید و چرا؟»).
- **وزن:** ۳ نمره از ۲۰.
- خود آزمون میان‌ترم با پاسخ‌های نمونه در مواد ارزشیابی درس آمده است.

برگه‌ی فرمولی که در آزمون داده می‌شود:

$$d' = \Phi^{-1}(H) - \Phi^{-1}(F), \quad c = -\tfrac{1}{2}[\Phi^{-1}(H) + \Phi^{-1}(F)], \quad H = \Phi(d'/2 - c), \quad F = \Phi(-d'/2 - c)$$

$$f_{\exp}(t) = Ae^{-\lambda t}, \quad f_{\mathrm{pow}}(t) = A(1+t)^{-d}, \quad P_c^{\mathrm{RW}} = \frac{1 - r^z}{1 - r^a},\ r = \frac{1-v}{1+v}, \quad \mathbb{E}[T] = \frac{aP_c - z}{v}$$

$$\mathrm{SSE} = \textstyle\sum_i (y_i - \hat{y}_i)^2, \quad \mathrm{RMSD} = \sqrt{\mathrm{SSE}/N}$$

$$\ell(\boldsymbol{\theta}) = \textstyle\sum_i \left[\ln \binom{n_i}{y_i} + y_i \ln f_i + (n_i - y_i)\ln(1 - f_i) \right], \quad \mathrm{NLL} = -\ell$$

$$G^2 = 2(\ell_{\mathrm{sat}} - \hat{\ell}), \quad \Lambda = 2(\hat{\ell}_1 - \hat{\ell}_0) \sim \chi^2_{\Delta k}$$

$$\mathrm{SE} \approx \sqrt{\mathrm{diag}(\mathbf{H}^{-1})}, \quad \text{Wald CI: } \hat{\theta} \pm 1.96\,\mathrm{SE}, \quad \text{profile CI: } 2(\mathrm{NLL}_{\mathrm{prof}} - \mathrm{NLL}_{\min}) \le 3.84$$

$$\mathrm{AIC} = 2\,\mathrm{NLL} + 2k, \quad \mathrm{AICc} = \mathrm{AIC} + \tfrac{2k(k+1)}{N-k-1}, \quad \mathrm{BIC} = 2\,\mathrm{NLL} + k \ln N, \quad w_i = \tfrac{e^{-\Delta_i/2}}{\sum_j e^{-\Delta_j/2}}$$

مقادیر بحرانی: $\chi^2_{1,.95} = 3.84$، $\chi^2_{2,.95} = 5.99$، $\chi^2_{3,.95} = 7.81$. quantileها: $\Phi^{-1}(0.84) \approx 1.0$، $\Phi^{-1}(0.975) = 1.96$. لگاریتم‌ها: $\ln 2 = 0.693$، $\ln 10 = 2.303$، $\ln 100 = 4.605$، $\ln 400 = 5.991$.

مشاوره‌ی پروژه (۳۰ دقیقه، بعد از آزمون)

هر گروه ۵ تا ۱۰ دقیقه با مدرس یا دستیار آموزشی درباره‌ی ایده‌ی پروژه‌اش پیش از موعد پیشنهاد (ابتدای هفته‌ی ۹) صحبت می‌کند. یک پاراگراف توصیف از سؤال، مدل و داده‌تان بیاورید.

مطالعه‌ی شخصی: مطالعه‌ی موردی در کد (پیش از آزمون اجرا کنید)

Code · کد: code/week08.py، cell ۱ · سلول ۱

Code · کد: code/week08.py، cell ۲ · سلول ۲

خروجی مورد انتظار (بلوک اول):

```
hits per condition: [40 66 80]  false alarms: 15
           k     NLL      G2  df  p(G2)     AIC     BIC
           ↪  d'_1,2,4  kappa  w_AIC  w_BIC
model
M0_none    2  27.269  35.549   2  0.000  58.538  66.521  [1.34, 1.34,
 ↪  1.34]   1.04  0.000  0.000
M1_loglin  3   9.766   0.543   1  0.461  25.533  37.507  [0.82, 1.37,
 ↪  1.93]   1.04  0.674  0.938
M2_free    4   9.495   0.000   0    NaN  26.990  42.956  [0.78, 1.45,
 ↪  1.88]   1.04  0.326  0.062

LRT M0 vs M1: 35.01 (df 1, p = 0.0000);  M1 vs M2: 0.54 (df 1, p = 0.461)
```

خروجی مورد انتظار (بلوک دوم، حدود ۱ دقیقه):

```
M1 recovery delta0 : r = 0.895, RMSE = 0.181
M1 recovery delta1 : r = 0.930, RMSE = 0.113
M1 recovery kappa  : r = 0.887, RMSE = 0.142

BIC model recovery, P(selected | generated):
           M0_none  M1_loglin  M2_free
M0_none       0.98       0.02     0.00
M1_loglin     0.05       0.93     0.02
M2_free       0.10       0.03     0.87
```

یادداشت درباره‌ی مولد $\mathcal{M}_2$ در بازیابی مدل: سه مقدار d' آن طوری کشیده می‌شوند که d'_4 بین d'_1 و d'_2 قرار بگیرد؛ یک الگوی غیریکنوا که $\mathcal{M}_1$ نمی‌تواند تولید کند. در غیر این صورت داده‌های $\mathcal{M}_2$ اغلب کاملاً با $\mathcal{M}_1$ سازگار می‌بودند و «اشتباه گرفتن‌ها» بی‌معنی می‌شد.

سؤال‌های خودسنجی درباره‌ی مطالعه‌ی موردی (در درس بحث می‌شوند): ۱. چرا فقط یک نرخ false alarm داریم، و این مدل SDT را در مقایسه با هفته‌ی ۲ چطور تغییر می‌دهد؟ ۲. هر معیار کدام مدل را ترجیح می‌دهد، و آیا LRTها با آن موافق‌اند؟ ۳.

آیا δ_1 با این طرح آزمایش قابل بازیابی است؟ آیا $\mathcal{M}_1$ از $\mathcal{M}_0$ و $\mathcal{M}_2$ قابل تشخیص است؟ ۴. نتیجه‌ی روان‌شناختی را در یک جمله، همراه با مهم‌ترین هشدارش، بنویسید.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

chatbot به‌عنوان هم‌درس: اعتماد کن، ولی بررسی کن. بسیاری از دانشجوها از LLMها برای توضیح مفاهیم و بررسی جواب‌های امتحانی استفاده می‌کنند. این می‌تواند کمک کند، ولی LLMها می‌توانند محاسبه‌هایی روان، مطمئن و غلط تولید کنند. با جواب یک chatbot مثل پیش‌بینی یک مدل رفتار کنید: آن را با چیزی که خودتان می‌توانید حساب کنید بسنجید. کد پایین یک جواب ازپیش‌آماده‌ی chatbot به سؤال B3 میان‌ترم (AIC برای سه مدل) را بررسی می‌کند. chatbot به جای $2\,\mathrm{NLL} + 2k$ از $2\,\mathrm{NLL} + k$ استفاده کرده.

Code · **کد:** `code/week08.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
M1: chatbot 222.0, correct 224.0  WRONG
M2: chatbot 218.0, correct 221.0  WRONG
M3: chatbot 218.8, correct 223.8  WRONG
Akaike weights, chatbot: [0.07 0.55 0.37]  correct: [0.15 0.68 0.17]
```

chatbot اتفاقاً برنده‌ی درست ($\mathcal{M}_2$) را انتخاب می‌کند، ولی همه‌ی عددها غلط‌اند و پشتیبانی از پیچیده‌ترین مدل را دو برابر می‌کند. مصحح نمره‌ی کمی می‌داد، و در یک تحلیل واقعی این خطا به نفع overfitting تمام می‌شد.

امتحانش کنید (بدون نیاز به API). ⋆ کدام خطا در فرمول دقیقاً عددهای chatbot را تولید می‌کند؟ BIC با همین خطا چه شکلی می‌شد؟ ⋆⋆ سه «مورد آزمون» (ورودی با جواب معلوم) کوچک برای فرمول‌های SDT هفته‌ی ۲ بنویسید که بتوانید با آن هر جوابی را، چه از chatbot چه از هم‌کلاسی، بررسی کنید. یادآوری: در خود امتحان هیچ ابزار هوش مصنوعی مجاز نیست، و قانون درس درباره‌ی استفاده از هوش مصنوعی در تکلیف‌ها در `assessments/README.md` آمده است.

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست (۱۰ مورد اول از هفته‌های ۱ تا ۷)

۱. برازش خوب را شاهد درستی مدل دانستن (هفته‌های ۳، ۶).
۲. فراموش کردن علامت منفی: بهینه‌سازها **منفی** لگاریتم درست‌نمایی را کمینه می‌کنند (هفته‌ی ۴).
۳. محدود نکردن احتمال‌ها، که باعث می‌شود $\ln 0$ برازش را از کار بیندازد (هفته‌ی ۴).
۴. اعتماد به `success=True`، یک شروع تنها، یا Nelder–Mead کران‌داری که روی یک کران فرو ریخته است (هفته‌های ۳–۴).
۵. کمترین مربعات برای شمارش‌ها یا انتخاب‌ها بدون فکر کردن به مدل نویز (هفته‌های ۳–۴).
۶. گزارش برآوردها بدون عدم قطعیت، یا استفاده از بازه‌های Wald نزدیک کران‌ها (هفته‌ی ۵).
۷. نتیجه‌گیری درباره‌ی افراد از منحنی‌های میانگین‌گیری‌شده (هفته‌ی ۵).

۸. نشت داده‌ی آزمون به آموزش در cross-validation (هفته‌ی ۶).
۹. مقایسه‌ی مدل‌های non-nested با LRT، یا خواندن مقادیر AIC به‌تنهایی به‌جای تفاوت‌هایشان (هفته‌ی ۷).
۱۰. تفسیر پارامترها یا مقایسه‌ی مدل‌ها بدون مطالعه‌ی بازیابی با طرح آزمایش واقعی (هفته‌ی ۷).

۹.۱.۱ خودآزمایی (سؤال‌های تمرینی به سبک آزمون)

۱. (مفهومی) در سه جمله توضیح دهید چرا مدل نمایی با مجانب داده‌های هفته‌ی ۲ را بهتر از مدل توانی برازش کرد، با اینکه مدل توانی داده را تولید کرده بود. **پاسخ** مدل مجانبی یک پارامتر اضافه دارد، پس می‌تواند خودش را با نویز خاص نمونه، اینجا نقاط صاف‌نمای فاصله‌های طولانی، تطبیق دهد. برازش آموزش بهتر برای مدل‌های منعطف‌تر تضمین‌شده است و شاهد درستی نیست. برای قضاوت به معیارهای تعمیم (CV)، (AIC/BIC و مطالعات بازیابی نیاز داریم.

۲. (محاسبه) یک مشاهده‌گر $H = 0.84$ و $F = 0.16$ دارد. d' و c را حساب کنید (از $\Phi^{-1}(0.84) \approx 1.0$ استفاده کنید). **پاسخ** $d' = 1.0 - (-1.0) = 2.0$؛ $c = -\frac{1}{2}(1.0 + (-1.0)) = 0$، پس مشاهده‌گر بی‌سوگیری است.

۳. (محاسبه) دو مدل روی $N = 100$ پاسخ دودویی برازش شده‌اند. مدل A: $k = 2$، NLL = ۰.۶۰. مدل B: $k = 4$، NLL = ۵.۵۷. AIC و BIC هر دو را حساب کنید. هر معیار کدام را ترجیح می‌دهد؟ ($\ln 100 = 4.605$) **پاسخ** AIC: A = ۰.۱۲۴، B = ۰.۱۲۳، پس AIC (کمی) B را ترجیح می‌دهد. BIC: A = ۱۲۰ + ۲۱.۹ = ۲۱.۱۲۹؛ B = ۱۱۵ + ۴۲.۱۸ = ۴۲.۱۳۳، پس BIC A را ترجیح می‌دهد. معیارها با هم مخالف‌اند چون BIC هر پارامتر را ۶.۴ به‌جای ۲ جریمه می‌کند.

۴. (خواندن کد) این تابع NLL چه اشکالی دارد و بهینه‌ساز چه خواهد کرد؟

> **کد:** Code · سلول ۴ · cell ۴، `code/week08.py`

پاسخ (۱) لگاریتم درست‌نمایی را برمی‌گرداند نه منفی آن را، پس `minimize` پارامترها را به سمت بدترین برازش (لگاریتم درست‌نمایی به سمت $-\infty$) می‌برد. (۲) p محدود نشده، پس مقادیر پیش‌بینی‌شده‌ی ۰ یا بیشتر از ۱ مقدار $-\inf$ یا nan می‌دهند. اصلاح: `return -np.sum(binom.logpmf(y,n,np.clip(p,EPS,1-EPS)))`.

۵. (تفسیر) یک مطالعه‌ی بازیابی برای پارامتر A مقدار $r(\text{true}, \text{recovered}) = 0.95$ و برای پارامتر B مقدار 0.35 می‌دهد. درباره‌ی مقاله‌ای که با این طرح آزمایش تفاوت گروه‌ها در B را گزارش می‌کند چه نتیجه‌ای می‌گیرید؟ **پاسخ** B با این طرح آزمایش ضعیف بازیابی می‌شود: برآوردها تحت تأثیر نویز یا trade-off هستند، پس تفاوت گروه‌ها در B برآوردشده قابل تفسیر نیست. مقاله باید طرح آزمایش را بهتر کند یا B را تفسیر نکند.

۶. (تفسیر) یک BIC confusion matrix دارای P(selected | generated) = power = ۵۸.۰ = asymptote است. برنده‌ی BIC در داده‌ی واقعی شما مدل توانی است. چه باید بنویسید؟ **پاسخ** اینکه BIC مدل توانی را ترجیح می‌دهد، ولی با این طرح آزمایش BIC اغلب برای داده‌هایی که مدل مجانبی تولید کرده هم مدل توانی را انتخاب می‌کند، پس شواهد بین این دو به‌خوبی تمایز نمی‌گذارد. احتمال‌های معکوس و نتایج AIC/CV را گزارش کنید و طرحی با فاصله‌های طولانی‌تر پیشنهاد دهید.

۷. (طراحی) می‌خواهید بدانید آیا یک دارو در مدل random walk احتیاط (مرز a) را تغییر می‌دهد یا کیفیت شواهد (drift v) را. چه داده‌ای باید جمع کنید و چرا دقت به‌تنهایی کافی نیست؟ **پاسخ** انتخاب‌ها **و** زمان‌های واکنش (ترجیحاً کل توزیع زمان واکنش) تحت دارو و دارونما. هم a بزرگ‌تر و هم v بزرگ‌تر دقت را بالا می‌برند، ولی a پاسخ‌ها را کند و v سریع می‌کند، پس فقط الگوی مشترک آن‌ها را از هم جدا می‌کند (هفته‌ی ۱).

۸. (مفهومی) اگر بخواهیم پیش‌بینی trialهای جدید را آزمون کنیم، چرا باید بخش‌های cross-validation برای داده‌های فراموشی داخل فاصله‌ها ساخته شوند؟ **پاسخ** تا هر مجموعه‌ی آموزش همه‌ی فاصله‌های نگهداری (شرایط) را داشته باشد و آزمون درباره‌ی آیتم‌های جدید در شرایط معلوم باشد. کنار گذاشتن کل فاصله‌ها برون‌یابی به شرایط جدید را آزمون می‌کند که ادعای تعمیم دیگری است.

۱۰.۱.۱ تکلیف

- A3 **(مقایسه و بازیابی مدل)** در ابتدای درس هفته‌ی ۹ تحویل داده می‌شود.
- **پیشنهاد پروژه** در ابتدای درس هفته‌ی ۹ تحویل داده می‌شود (حداکثر ۲ صفحه؛ هفته‌ی ۷ را ببینید).
- این هفته تکلیف جدیدی نداریم. برای میان‌ترم با اجرای مطالعه‌ی موردی بالا و جواب دادن به سؤال‌های تمرینی بدون نگاه کردن به پاسخ‌ها آماده شوید.

۱۱.۱.۱ مطالعه‌ی بیشتر

- Lewandowsky & Farrell **(۲۰۱۸)، فصل‌های ۲ تا ۵ و ۱۰.** خلاصه‌ی فصل‌ها را به‌عنوان مرور کل نیمه‌ی اول درس دوباره بخوانید.
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۱۱** .(SDT) توصیف مدل را برای آمادگی هفته‌ی ۹ بخوانید، که در آن شروع می‌کنیم پارامترها را متغیرهای تصادفی با پیشین در نظر بگیریم.

پیش‌نمایش هفته‌ی ۹: نیمه‌ی دوم درس بیزی می‌شود. به‌جای یک بهترین برآورد به‌علاوه‌ی یک بازه‌ی اطمینان، کل توزیع احتمال پارامترها به شرط داده را حساب می‌کنیم.