مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۹: مدل‌سازی بیزی ۱: پیشین، پسین و تقریب شبکه‌ای

فهرست مطالب

۱ مدل‌سازی بیزی ۱

۱.۱ هفته‌ی ۹: مدل‌سازی بیزی ۱: پیشین، پسین و تقریب شبکه‌ای ۱

۱.۱.۱ واژه‌های کلیدی ۱

۱.۱.۲ اهداف یادگیری ۲

۱.۱.۳ مقدمه ۳

۱.۱.۴ جزوه‌ی درس ۳

۱.۱.۵ مثال حل‌شده ۷

۱.۱.۶ lab (۲ ساعت) ۹

۱.۱.۷ ارتباط با هوش مصنوعی و LLMها ۱۱

۱.۱.۸ اشتباهات رایج و برداشت‌های نادرست ۱۲

۱.۱.۹ خودآزمایی ۱۲

۱.۱.۱۰ تکلیف ۱۳

۱.۱.۱۱ مطالعه‌ی بیشتر ۱۳

فصل ۱

مدل‌سازی بیزی

۱.۱ هفته‌ی ۹: مدل‌سازی بیزی ۱: پیشین، پسین و تقریب شبکه‌ای

فصل ۴: مدل‌سازی بیزی · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** یک نسبت یادآوری (۳۰ از ۵۰) و شرکت‌کننده‌ی SDT هفته‌ی ۲ (hit ۶۸/۱۰۰، false alarm ۱۱/۱۰۰).

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
prior	توزیع پیشین (prior)	باور درباره‌ی پارامتر پیش از دیدن داده
posterior	توزیع پسین (posterior)	باور درباره‌ی پارامتر بعد از دیدن داده
grid approximation	تقریب شبکه‌ای (grid)	محاسبه‌ی پسین روی شبکه‌ای از مقادیر
signal detection theory (SDT)	نظریه‌ی تشخیص علامت	مدلی که حساسیت را از سوگیری پاسخ جدا می‌کند
hit	اصابت (hit)	پاسخ «بله» وقتی علامت وجود دارد
Bayes’ rule	قاعده‌ی بیز	پسین $\propto$ درست‌نمایی × پیشین
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
evidence	شواهد	اطلاعاتی که برای تصمیم جمع می‌شود
beta-binomial model	مدل beta-binomial	پیشین Beta با داده‌ی دوجمله‌ای
binomial distribution	توزیع دوجمله‌ای	توزیع تعداد موفقیت در n کوشش
MAP estimate	برآورد MAP	مُد توزیع پسین

English	فارسی	توضیح کوتاه
HDI / credible interval	بازه‌ی باورپذیر (credible interval)	بازه‌ای که با احتمال مشخص پارامتر را دارد
confidence interval (CI)	بازه‌ی اطمینان	بازه‌ای که با روش مشخص پارامتر واقعی را در بر می‌گیرد
prior predictive check	بررسی پیش‌بینی پیشین	شبیه‌سازی داده از پیشین برای سنجش معقول بودن آن
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
maximum likelihood estimate (MLE)	برآورد بیشینه‌ی درست‌نمایی	پارامترهایی که داده را محتمل‌ترین می‌کنند
cognitive model	مدل شناختی	توصیف دقیق و ریاضی یا محاسباتی از یک فرایند ذهنی
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
conjugate prior	پیشین مزدوج (conjugate)	پیشینی که پسین هم‌خانواده می‌دهد
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
accuracy	دقت	نسبت پاسخ‌های درست

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. قاعده‌ی بیز را برای پارامترها **بیان کنند** و نقش پیشین (prior)، درست‌نمایی، شواهد (evidence) و پسین (posterior) را **مشخص کنند**.
۲. پسین را برای مدل beta-binomial به‌صورت تحلیلی و با تقریب شبکه‌ای به‌صورت عددی، برای یک و دو پارامتر، **حساب کنند**.
۳. یک پسین را **خلاصه کنند** (میانگین، میانه، MAP، انحراف معیار، بازه‌های دم‌برابر و بیشترین چگالی) و credible interval را از بازه‌ی اطمینان **متمایز کنند**.
۴. **توضیح دهند** که پیشین و مقدار داده با هم چطور پسین را تعیین می‌کنند، و با شبیه‌سازی پیش‌بینی پیشین **بررسی کنند** که پیشین معقول است یا نه.
۵. احتمال‌های پسین فرضیه‌های معنادار روان‌شناختی را **تفسیر کنند** (مثلاً «$P(d' > 1 \mid \text{data})$»).

۳.۱.۱ مقدمه

از هفته‌ی ۳ پرسیده‌ایم: «کدام مقدار واحد پارامتر داده‌ها را بهتر توضیح می‌دهد؟» و بعد، در هفته‌ی ۵، «این برآورد در تکرارهای خیالی چقدر تغییر می‌کرد؟» پژوهشگران اغلب می‌خواهند چیز مستقیم‌تری بگویند:

> «با توجه به این داده‌ها، با احتمال ٪۹۵ حساسیت این شرکت‌کننده بین ۲.۱ و ۱.۲ است.» «احتمال اینکه دست‌کاری پاداش شرکت‌کننده‌ها را *liberal*‌تر کرده باشد ۹۸.۰ است.»

بازه‌های اطمینان فراوانی‌گرا اجازه‌ی چنین جمله‌هایی را **نمی‌دهند** (هفته‌ی ۵). استنباط بیزی می‌دهد، به یک قیمت: باید بگوییم **پیش از** دیدن داده درباره‌ی پارامترها چه باوری داشتیم، به شکل یک **توزیع پیشین**. بعد قاعده‌ی بیز پیشین را با درست‌نمایی (که بلدیم بنویسیم) ترکیب می‌کند و یک **توزیع پسین** می‌سازد: همه‌ی آنچه مدل و داده با هم درباره‌ی پارامترها می‌گویند.

روش‌های بیزی چند دردسر قبلی ما را هم آسان‌تر می‌کنند: عدم قطعیت مجانی به دست می‌آید (بدون Hessian یا bootstrap)، مدل‌های سلسله‌مراتبی چند شرکت‌کننده طبیعی می‌شوند (هفته‌ی ۱۳)، و مقایسه‌ی مدل‌ها یک جواب اصولی پیدا می‌کند (هفته‌ی ۱۰). هزینه‌اش محاسبه است، و برای همین هفته‌های ۱۱ تا ۱۳ درباره‌ی نمونه‌گیری‌اند.

> **یادآوری (هفته‌ی ۱):** این هفته درباره‌ی **تحلیل داده‌ی بیزی** است؛ روشی که ما پژوهشگران برای برآورد پارامترهای هر مدلی به کار می‌بریم. هیچ ادعایی ندارد که ذهن بیزی است. مدل‌های بیزی شناخت در هفته‌ی ۱۵ می‌آیند.

این موضوع کجا به کار می‌رود؟

- **نمونه‌های کوچک و موردهای تکی.** در عصب‌روان‌شناسی بالینی اغلب یک بیمار و چند ده trial داریم. تحلیل بیزی با یک prior معقول، عدم قطعیت صادقانه و قابل استفاده‌ای می‌دهد، جایی که MLE ناپایدار است.
- **گزاره‌های احتمالی مستقیم** که پزشکان و سیاست‌گذاران می‌فهمند: «با احتمال ٪۹۷ آموزش جدید حافظه را بهتر کرده».
- **آزمون‌های تطبیقی** :(adaptive testing) آزمون‌های کامپیوتری (مثلاً آزمون‌های بینایی و شنوایی، امتحان‌های تطبیقی) بعد از هر پاسخ posterior را به‌روز می‌کنند و آیتم بعدی را جایی انتخاب می‌کنند که بیشترین اطلاعات را می‌دهد.
- **ترکیب شواهد:** posterior امروز prior فرداست، پس نتایج مطالعه‌های قبلی را می‌شود به‌طور رسمی وارد تحلیل کرد.
- **نرم‌افزارهای امروزی مدل‌سازی شناختی** (PyMC، Stan، JAGS) بیزی‌اند؛ بیشتر مدل‌های سلسله‌مراتبی در مقاله‌های اخیر به همین روش برازش می‌شوند (هفته‌ی ۱۳).

۴.۱.۱ جزوه‌ی درس

به زبان ساده تا اینجا یک بهترین مقدار پارامتر پیدا می‌کردیم و بعد می‌پرسیدیم چقدر ممکن است تغییر کند. روش بیزی در عوض دانش ما درباره‌ی پارامتر را به شکل یک **توزیع احتمال** کامل توصیف می‌کند. پیش از داده، prior **(پیشین)** می‌گوید کدام مقدارها را معقول می‌دانیم (مثلاً «احتمال یادآوری احتمالاً متوسط است، نه ۰ یا ۱»). بعد داده‌ها به هر مقدار ممکن به اندازه‌ی درست‌نمایی‌اش (هفته‌ی ۴) وزن تازه می‌دهند. نتیجه، posterior **(پسین)**، می‌گوید هر مقدار بعد از دیدن داده چقدر معقول است. به زبان ساده: $\textit{posterior} \propto \textit{likelihood} \times \textit{prior}$. از posterior می‌توانیم یک بهترین حدس (میانگین آن)، یک عدم قطعیت (پراکندگی آن) و گزاره‌های مستقیمی مثل «احتمال اینکه $d' > 1$ باشد ۹۳.۰ است» بخوانیم. با داده‌ی کم prior اثر زیادی دارد؛ با داده‌ی زیاد posterior زیر سلطه‌ی درست‌نمایی است و به MLE نزدیک می‌شود. محاسبه‌ی posterior برای یک یا دو پارامتر آسان است (روی grid) و برای بیشتر از آن به روش‌های نمونه‌گیری نیاز دارد (هفته‌های ۱۱ تا ۱۳).

زمان‌بندی پیشنهادی (۶۰ دقیقه): قاعده‌ی بیز ۱۰ · پیشین‌ها ۱۰ · beta-binomial ۱۲ · تقریب شبکه‌ای ۱۰ · خلاصه‌ها و credible intervalها ۱۲ · بررسی پیش‌بینی پیشین ۶.

۱. قاعده‌ی بیز برای پارامترها

$$\underbrace{p(\boldsymbol{\theta} \mid \mathbf{y})}_{\text{posterior}} = \frac{\overbrace{p(\mathbf{y} \mid \boldsymbol{\theta})}^{\text{likelihood}}\ \overbrace{p(\boldsymbol{\theta})}^{\text{prior}}}{\underbrace{p(\mathbf{y})}_{\text{evidence (marginal likelihood)}}}, \qquad p(\mathbf{y}) = \int p(\mathbf{y} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, d\boldsymbol{\theta}.$$

(این هفته «$\mathcal{M}$» را در نمادگذاری نمی‌نویسیم: همه‌چیز مشروط به مدل است.)

- **درست‌نمایی** دقیقاً همان تابع هفته‌ی ۴ است.
- **پیشین** آنچه را پیش از داده معلوم یا محتمل است بیان می‌کند.
- **شواهد** $p(\mathbf{y})$ به $\boldsymbol{\theta}$ بستگی ندارد. برای برآورد، فقط ثابت نرمال‌ساز است که انتگرال پسین را ۱ می‌کند:

$$p(\boldsymbol{\theta} \mid \mathbf{y}) \propto p(\mathbf{y} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta}).$$

پسین $\propto$ درست‌نمایی × پیشین. در هفته‌ی ۱۰ شواهد ستاره‌ی مقایسه‌ی بیزی مدل‌ها می‌شود.

شهود. پسین یک مصالحه است: جایی بالاست که مقادیر پارامتر هم از پیش محتمل‌اند و هم داده را محتمل می‌کنند. با داده‌ی کم پیشین مهم است؛ با داده‌ی زیاد درست‌نمایی غالب می‌شود و پسین حول MLE متمرکز می‌شود.

خواندن ریاضی

- $p(\boldsymbol{\theta} \mid \mathbf{y})$: «احتمال (چگالی) مقدار پارامتر $\boldsymbol{\theta}$ به شرط داده». این همان چیزی است که می‌خواهیم.
- $p(\mathbf{y} \mid \boldsymbol{\theta})$: درست‌نمایی، که به‌عنوان تابعی از $\boldsymbol{\theta}$ خوانده می‌شود (هفته‌ی ۴).
- $p(\boldsymbol{\theta})$: prior که پیش از داده انتخاب می‌شود.
- $p(\mathbf{y}) = \int p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})\, d\boldsymbol{\theta}$: انتگرال، «درست‌نمایی × prior» را روی همه‌ی مقدارهای ممکن پارامتر جمع می‌کند. یک عدد است و برای همه‌ی $\boldsymbol{\theta}$ها یکسان است، پس در برآورد فقط منحنی را طوری مقیاس می‌کند که مساحت کل ۱ شود.
- $\propto$ یعنی «متناسب با»: برابر، به‌جز یک ضریب ثابت. در عمل «درست‌نمایی × prior» را در مقدارهای زیادی حساب می‌کنیم و بعد بر جمعشان تقسیم می‌کنیم، دقیقاً مثل جدول چهارنقطه‌ای مثال حل‌شده (۰۰۰۴۴۷۹.۰ / ۰۰۰۹۵۷۴.۰ = ۴۶۸.۰).

۲. انتخاب پیشین‌ها

نوع	مثال برای احتمال یادآوری θ	چه وقت
تخت / یکنواخت	$\mathrm{Beta}(1,1)$	وقتی هر مقدار در دامنه واقعاً به یک اندازه محتمل است (به‌ندرت درست است)

نوع	مثال برای احتمال یادآوری θ	چه وقت
ضعیف‌آگاهی‌بخش (weakly informative)	$\mathrm{Beta}(2,2)$: ترجیح ملایم برای مقادیر میانی	**پیش‌فرض برای بیشتر مدل‌های شناختی**: مقادیر پوچ را کنار می‌گذارد و بقیه را به داده می‌سپارد
آگاهی‌بخش (informative)	$\mathrm{Beta}(20,5)$: «یادآوری بعد از یک روز حدود ۸۰ است»	وقتی مطالعات قبلی یا نظریه دانش واقعی می‌دهند

اصول: - پیشین‌ها باید **پیش از** دیدن داده تعیین شوند. - باید دامنه‌ی پارامتر را رعایت کنند (مثلاً هیچ جرم پیشینی روی نرخ زوال منفی نباشد). - باید با **شبیه‌سازی پیش‌بینی پیشین** بررسی شوند (بخش ۶): پیشین کدام داده‌ها را نتیجه می‌دهد؟ - یک پیشین «مبهم» روی یک مقیاس می‌تواند روی مقیاس دیگری خیلی آگاهی‌بخش باشد (بخش D lab. - پیشین‌هایتان را گزارش کنید و حساسیت نتیجه‌گیری‌ها را به جایگزین‌های معقول بررسی کنید (هفته‌ی ۱۰).

۳. یک حالت با جواب بسته: مدل beta-binomial

برای y موفقیت در n trial دوجمله‌ای با پیشین $\mathrm{Beta}(a_0, b_0)$ روی θ:

$$p(\theta \mid y) \propto \underbrace{\theta^{y}(1-\theta)^{n-y}}_{\text{likelihood}} \cdot \underbrace{\theta^{a_0-1}(1-\theta)^{b_0-1}}_{\text{prior}} = \theta^{a_0+y-1}(1-\theta)^{b_0+n-y-1},$$

پس پسین دوباره یک توزیع Beta است:

$$\theta \mid y \sim \mathrm{Beta}(a_0 + y,\ b_0 + n - y).$$

وقتی پیشین و پسین از یک خانواده باشند، پیشین را conjugate می‌نامند.

- a_0 و b_0 مثل **شمارش‌های کاذب** (pseudo-counts) موفقیت‌ها و شکست‌های پیشین عمل می‌کنند.
- میانگین پسین: $\dfrac{a_0 + y}{a_0 + b_0 + n}$؛ میانگین وزنی میانگین پیشین $\frac{a_0}{a_0+b_0}$ و نسبت مشاهده‌شده‌ی y/n، با وزن‌های a_0+b_0 و n.
- **ارتباط با هفته‌های ۲ و ۴:** تصحیح log-linear $(y+0.5)/(n+1)$ دقیقاً میانگین پسین تحت پیشین $\mathrm{Beta}(0.5,0.5)$، به نام پیشین *Jeffreys*، است. آن «تصحیح» یک برآورد بیزی در لباس مبدل بود.

خواندن ریاضی

- **توزیع** Beta $\mathrm{Beta}(a,b)$ یک منحنی زنگوله‌مانند انعطاف‌پذیر روی بازه‌ی ۰ تا ۱ است و برای توصیف باور درباره‌ی یک احتمال ایده‌آل است. میانگین آن $a/(a+b)$ است. $\mathrm{Beta}(1,1)$ صاف است؛ $\mathrm{Beta}(20,5)$ یک برآمدگی باریک حول ۸۰ است.
- قاعده‌ی به‌روزرسانی $\mathrm{Beta}(a_0,b_0) \to \mathrm{Beta}(a_0+y, b_0+n-y)$ فقط **شمردن** است: موفقیت‌های مشاهده‌شده را به a و شکست‌ها را به b اضافه کن. prior طوری رفتار می‌کند که انگار قبلاً a_0 موفقیت و b_0 شکست دیده‌ایم (شمارش‌های ساختگی یا pseudo-counts).
- **مثال:** prior برابر $\mathrm{Beta}(2,2)$ («انگار» ۲ یادآوری و ۲ شکست)، داده ۷ از ۱۰ $\leftarrow$ $\mathrm{Beta}(9,5)$ با میانگین $9/14 = 0.643$. prior مقدار مشاهده‌شده‌ی ۷۰.۰ را کمی به سمت ۵۰.۰ می‌کشد، چون ۴ مشاهده‌ی ساختگی به ۱۰ مشاهده‌ی واقعی اضافه می‌کند.

۴. تقریب شبکه‌ای (grid approximation)

بیشتر مدل‌های شناختی پیشین conjugate ندارند. اگر فقط یک یا دو پارامتر باشد، می‌توانیم پسین را روی یک شبکه تقریب بزنیم:

۱. شبکه‌ای از مقادیر پارامتر $\boldsymbol{\theta}_1, \ldots, \boldsymbol{\theta}_G$ تعریف کنید که همه‌ی مقادیر معقول را بپوشاند.
۲. در هر نقطه‌ی شبکه **لگاریتم** پیشین به‌علاوه‌ی **لگاریتم** درست‌نمایی را حساب کنید (لگاریتم‌ها، مثل هفته‌ی ۴، از سرریز جلوگیری می‌کنند).
۳. بیشینه را کم کنید، نمایی بگیرید و نرمال کنید تا جمع مقادیر ۱ شود (یا انتگرالشان ۱ شود).

نتیجه یک تقریب گسسته از پسین است که هر خلاصه‌ای را می‌شود از آن حساب کرد. تقریب شبکه‌ای تا حد دقت شبکه دقیق است و برای ساختن شهود ایده‌آل است. فراتر از ۲ تا ۳ پارامتر شکست می‌خورد (نفرین ابعاد، هفته‌ی ۳)، و همین انگیزه‌ی MCMC است (هفته‌های ۱۱–۱۳).

۵. خلاصه کردن یک پسین

خلاصه	تعریف	توضیح
میانگین پسین	$\mathbb{E}[\theta \mid \mathbf{y}]$	خطای مربع مورد انتظار را کمینه می‌کند
میانه‌ی پسین	صدک ۵۰	در برابر چولگی مقاوم است
MAP	$\arg\max_\theta p(\theta \mid \mathbf{y})$	تحت پیشین تخت با MLE برابر است
انحراف معیار پسین	$\sqrt{\mathrm{Var}[\theta \mid \mathbf{y}]}$	همتای بیزی SE
بازه‌ی دم‌برابر ٪۹۵	صدک ۵.۲ تا ۵.۹۷	محاسبه‌اش آسان است
HDI ٪۹۵ (بازه‌ی بیشترین چگالی)	باریک‌ترین بازه‌ای که ٪۹۵ پسین را در بر دارد؛ هر مقدار داخل آن از هر مقدار بیرونش محتمل‌تر است	برای پسین‌های چوله ترجیح دارد

credible interval در برابر بازه‌ی اطمینان. ٪۹۵ credible interval واقعاً یعنی «با توجه به مدل، پیشین و داده، پارامتر با احتمال ۹۵.۰ در این بازه است». بازه‌ی اطمینان گزاره‌ای درباره‌ی رفتار بلندمدت یک رویه است (هفته‌ی ۵). با پیشین‌های ضعیف و داده‌ی کافی، این دو اغلب از نظر عددی یکی می‌شوند، ولی تفسیرشان فرق دارد.

احتمال پسین فرضیه‌ها مجانی به دست می‌آید: $P(d' > 1 \mid \mathbf{y})$ فقط جرم پسین بالای ۱ است.

۶. بررسی‌های پیش‌بینی پیشین (prior predictive checks)

توزیع پیش‌بینی پیشین داده‌هایی را توصیف می‌کند که مدل پیش از دیدن هر داده‌ای انتظار دارد:

$$p(\mathbf{y}^{\text{rep}}) = \int p(\mathbf{y}^{\text{rep}} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, d\boldsymbol{\theta}.$$

برای شبیه‌سازی از آن: $\boldsymbol{\theta}$ را از پیشین بکشید و بعد از مدل داده شبیه‌سازی کنید. اگر داده‌های شبیه‌سازی‌شده پوچ به نظر برسند (مثلاً تقریباً همه‌ی نرخ‌های hit دقیقاً ۰ یا ۱، یا یادآوری‌ای که طی یک ماه بیشتر می‌شود)، پیشین نامعقول است. بررسی‌های پیش‌بینی پیشین نسخه‌ی بیزی عادت «پیش از برازش شبیه‌سازی کن» هفته‌ی ۲ هستند.

پیشرفته: پسین به‌عنوان پیشین به‌روزشده. چون برای داده‌های مستقل $p(\boldsymbol{\theta} \mid \mathbf{y}_1, \mathbf{y}_2) \propto p(\mathbf{y}_2 \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta} \mid \mathbf{y}_1)$، پسین امروز پیشین فرداست. پس به‌روزرسانی بیزی ذاتاً ترتیبی است، و به همین دلیل استنباط بیزی یک مدل هنجاری محبوب برای یادگیری است (هفته‌ی ۱۵).

برای یک مهندس

- این همان **تخمین بیزی** در نظریه‌ی آشکارسازی و تخمین است: posterior چیزی است که تخمین‌گر MAP یا MMSE با آن کار می‌کند. میانگین posterior همان **تخمین** MMSE است؛ مد posterior **تخمین** MAP است؛ با prior صاف، ML. = MAP
- **به‌روزرسانی** conjugate **بتا–دوجمله‌ای** همان ایده‌ی به‌روزرسانی conjugate گاوسی است، یعنی هسته‌ی اسکالر **فیلتر کالمن** (میانگین و واریانس prior + اندازه‌گیری ← میانگین و واریانس (posterior، فقط اینجا برای یک احتمال به جای یک حالت گاوسی.
- **به‌روزرسانی ترتیبی** posterior») امروز prior فرداست») دقیقاً همان فیلترینگ بیزی بازگشتی است.
- تفاوت در روان‌شناسی: prior معمولاً **ضعیف** است و باید برای خواننده توجیه شود، و خروجی اصلی یک تصمیم نیست، بلکه توصیف عدم قطعیت درباره‌ی یک پارامتر روان‌شناختی است. بررسی پیش‌بینی پیشین (prior predictive check) عادتی است که priorها را قابل دفاع می‌کند.

برای مدرس

- grid **چهارنقطه‌ای را روی تخته انجام دهید** (مثال حل‌شده، بخش ۱) با ستون‌هایی برای prior، درست‌نمایی، حاصل‌ضرب و posterior. کل استنباط بیزی در همین یک جدول است. بعد prior را به (۱.۰، ۱.۰، ۴.۰، ۴.۰) تغییر دهید و زنده دوباره حساب کنید: دانشجوها اثر prior را می‌بینند.
- **از داستان شمارش‌های ساختگی** Beta **استفاده کنید.** prior» برابر Beta(2, ۲) مثل این است که قبلاً ۲ یادآوری و ۲ شکست دیده باشیم.» دانشجوهایی که prior را دلبخواهی می‌دانند، وقتی آن را داده‌ی خیالی ببینند آرام می‌شوند.
- **مستقیماً به نگرانی «ذهنی بودن» جواب دهید.** هر تحلیلی فرض دارد (درست‌نمایی هم یک فرض است)؛ تحلیل بیزی یکی دیگر از فرض‌ها را صریح می‌کند، و تحلیل حساسیت (هفته‌ی ۱۰) بررسی می‌کند که چقدر مهم است.
- **سؤال‌های رایج.**
  - «کدام *prior* درست است؟» هیچ‌کدام تنها جواب درست نیست. از priorهای weakly informative استفاده کنید، آن‌ها را با شبیه‌سازی پیش‌بینی پیشین بررسی کنید و حساسیت را گزارش کنید.
  - «آیا *credible interval* همان بازه‌ی اطمینان است؟» با prior ضعیف و داده‌ی کافی اغلب از نظر عددی شبیه‌اند، ولی فقط credible interval یعنی «با احتمال ٪۹۵ پارامتر اینجاست».
  - «پس مغز بیزی است؟» این سؤال دیگری است (هفته‌ی ۱۵). این هفته بیز ابزاری برای پژوهشگر است.

۵.۱.۱ مثال حل‌شده

بخش ۱: یک شبکه‌ی چهارنقطه‌ای با دست

یک شرکت‌کننده $y = 7$ از $n = 10$ آیتم را به یاد می‌آورد. برای ساده نگه داشتن حساب، فرض کنید θ فقط می‌تواند مقادیر ۲.۰، ۴.۰، ۶.۰ یا ۸.۰ را بگیرد، هرکدام با احتمال پیشین ۱/۴.

θ	پیشین	درست‌نمایی $\theta^7(1-\theta)^3$ (بدون ثابت)	پیشین × درست‌نمایی	پسین
۲.۰	۲۵.۰	۰۰۰۰۰۶۶.۰	۰۰۰۰۰۱۶.۰	**۰۰۲.۰**
۴.۰	۲۵.۰	۰۰۰۳۵۳۹.۰	۰۰۰۰۸۸۵.۰	**۰۹۲.۰**
۶.۰	۲۵.۰	۰۰۱۷۹۱۶.۰	۰۰۰۴۴۷۹.۰	**۴۶۸.۰**
۸.۰	۲۵.۰	۰۰۱۶۷۷۷.۰	۰۰۰۴۱۹۴.۰	**۴۳۸.۰**
جمع	۱		۰۰۰۹۵۷۴.۰	۰۰۰.۱

هر مقدار پسین = (پیشین × درست‌نمایی) / جمع. ضریب دوجمله‌ای حذف شد چون در نرمال‌سازی ساده می‌شود. تفسیر: بعد از داده، ۶.۰ و ۸.۰ تقریباً به یک اندازه محتمل‌اند و ۲.۰ عملاً کنار گذاشته شده است.

بخش ۲: همان داده با یک پیشین Beta پیوسته

پیشین $\mathrm{Beta}(2,2)$ (میانگین ۵.۰، با ترجیح ملایم برای مقادیر میانی). پسین: $\mathrm{Beta}(2+7, 2+3) = \mathrm{Beta}(9,5)$.

- میانگین پسین $9/14 = 0.643$ ≔ بین میانگین پیشین (۵.۰) و نسبت مشاهده‌شده (۷.۰)، نزدیک‌تر به داده چون $n = 10 > a_0 + b_0 = 4$.
- MAP (مُد) $= (9-1)/(9+5-2) = 0.667$ ≕.
- credible interval دم‌برابر ۹۵٪ $= [0.386, 0.861]$ ≕.

تفسیر. با یک پیشین ملایم و ۱۰ آیتم، احتمال یادآوری احتمالاً حدود ۶۴.۰ است، ولی هر مقداری از حدود ۳۹.۰ تا ۸۶.۰ هنوز credible است. ده آیتم چیز زیادی به ما نمی‌گوید.

بخش ۳: با داده‌ی بیشتر پیشین کمتر مهم است

با $y = 30$ از $n = 50$:

پیشین	پسین	میانگین	۹۵٪ credible interval
$\mathrm{Beta}(1,1)$ (تخت)	$\mathrm{Beta}(31,21)$	۵۹۶.۰	[۷۲۴.۰ ،۴۶۱.۰]
$\mathrm{Beta}(0.5,0.5)$ (Jeffreys)	$\mathrm{Beta}(30.5,20.5)$	۵۹۸.۰	[۷۲۷.۰ ،۴۶۲.۰]
$\mathrm{Beta}(20,5)$ (آگاهی‌بخش، «≈ ۸.۰»)	$\mathrm{Beta}(50,25)$	۶۶۷.۰	[۷۶۸.۰ ،۵۵۷.۰]

پیشین‌های تخت و Jeffreys عملاً یک جواب می‌دهند که با بازه‌ی profile likelihood هفته‌ی ۵، [۴۶۲.۰، ۷۲۸.۰]، هم برابر است. پیشین آگاهی‌بخش، که ارزشش ۲۵ مشاهده‌ی کاذب است، هنوز برآورد را به‌طور قابل توجهی به سمت ۸.۰ می‌کشد: ۵۰ مشاهده برای غلبه بر یک پیشین قوی کافی نیست. اینکه این خوب است یا نه به درست بودن دانش پیشین بستگی دارد.

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. محاسبه‌ی پسین‌های beta-binomial به‌صورت تحلیلی و با تقریب شبکه‌ای، و دیدن مصالحه‌ی پیشین و داده.
۲. تماشای تیزتر شدن پسین با داده (به‌روزرسانی ترتیبی).
۳. محاسبه‌ی پسین شبکه‌ای دوبعدی برای SDT (d'، c)؛ خلاصه کردن آن با میانگین‌ها، HDIها و احتمال‌های پسین.
۴. استفاده از شبیه‌سازی پیش‌بینی پیشین برای افشای یک پیشین «مبهم» بد.

زمان‌بندی: بخش A ۲۵ دقیقه · بخش B ۱۵ دقیقه · بخش C ۴۰ دقیقه · بخش D ۲۵ دقیقه · بخش E ۱۵ دقیقه.

آماده‌سازی

Code · **کد:** `code/week09.py`، cell ۱ · سلول ۱

بخش A: beta-binomial، تحلیلی و روی شبکه (۲۵ دقیقه)

Code · **کد:** `code/week09.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
flat Beta(1,1)            grid mean = 0.5962, exact mean = 0.5962, 95% CI
↪  = [0.461 0.724]
Jeffreys Beta(.5,.5)      grid mean = 0.5980, exact mean = 0.5980, 95% CI
↪  = [0.462 0.727]
informative Beta(20,5)    grid mean = 0.6667, exact mean = 0.6667, 95% CI
↪  = [0.557 0.768]
```

پسین‌های شبکه‌ای و دقیق بر هم منطبق‌اند. ببینید هر پسین نسبت به پیشین و درست‌نمایی خودش کجا قرار می‌گیرد.

بخش B: به‌روزرسانی ترتیبی (۱۵ دقیقه)

Code · **کد:** `code/week09.py`، cell ۳ · سلول ۳

به این دقت کنید: پسین از خود پیشین شروع می‌شود، با جمع شدن آیتم‌ها باریک می‌شود و حول مقدار واقعی متمرکز می‌شود. پهنایش تقریباً مثل $1/\sqrt{n}$ کم می‌شود، همان‌طور که SE در هفته‌ی ۵ کم می‌شد.

بخش C: یک پسین شبکه‌ای دوپارامتری برای SDT (۴۰ دقیقه)

شرکت‌کننده‌ی هفته‌ی ۲: ۶۸ hit از ۱۰۰ trial علامت و ۱۱ false alarm از ۱۰۰ trial نویز. پیشین‌ها: $d' \sim \mathcal{N}(1, 1.5)$ (حساسیت معمولاً مثبت و به‌ندرت بالای ۴ است) و $c \sim \mathcal{N}(0, 1)$ (سوگیری معمولاً متوسط است).

Code · **کد:** `code/week09.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
    post. mean  post. SD    MAP  95% HDI low  95% HDI high
d'       1.688     0.209  1.675        1.250         2.062
c        0.376     0.106  0.375        0.163         0.575
MLE (uncorrected formulas): d' = 1.694, c = 0.379
P(d' > 1 | data) = 1.000;  P(c > 0 | data) = 1.000
Posterior correlation of d' and c: 0.245
```

(«۰.۰۰۰۱» یعنی هیچ‌کدام از ۲۰ ۰۰۰ نمونه‌ی پسین زیر آستانه نیفتادند، پس احتمال < 0.9999 است. آن را همین‌طور گزارش کنید، نه به‌عنوان قطعیت.)

تفسیر (در notebook بنویسید): ۱. میانگین پسین و MAP در مقایسه با MLE چطورند؟ چرا اینجا این‌قدر نزدیک‌اند؟ ۲. HDI مربوط به d' و $P(c > 0 \mid \text{data})$ را هرکدام به یک جمله‌ی ساده درباره‌ی این شرکت‌کننده ترجمه کنید. ۳. انحراف معیار پیشین d' را به ۱۰ افزایش دهید، بعد به ۳.۰ کم کنید (با مرکز ۱). کدام خلاصه‌ها تغییر می‌کنند و چقدر؟

بخش D: بررسی‌های پیش‌بینی پیشین (۲۵ دقیقه)

پیش از اعتماد به یک پیشین، به داده‌هایی که نتیجه می‌دهد نگاه کنید. پیشین ما را با یک پیشین «مبهم»، $d' \sim \mathcal{N}(0, 10)$ و $c \sim \mathcal{N}(0, 10)$، مقایسه کنید که گاهی به این دلیل استفاده می‌شود که «بی‌اطلاع» است.

Code · **کد:** `code/week09.py`، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
our prior: d'~N(1,1.5), c~N(0,1): 14% of simulated datasets have a rate
↪  of exactly 0 or 1; 24% have H < F
'vague' prior: d'~N(0,10), c~N(0,10): 96% of simulated datasets have a
↪  rate of exactly 0 or 1; 23% have H < F
```

به این دقت کنید: پیشین «مبهم» اصلاً خنثی نیست. روی مقیاس احتمال، ٪۹۶ مجموعه‌داده‌های شبیه‌سازی‌شده را در نرخ hit یا false alarm دقیقاً ۰ یا ۱ قرار می‌دهد؛ چیزی که در آزمایش‌های تشخیص واقعی عملاً هرگز اتفاق نمی‌افتد. این پیشین باوری قوی و پوچ درباره‌ی داده بیان می‌کند. ابهام روی مقیاس پارامتر، ابهام روی مقیاس داده نیست.

پیشین خود ما هم کامل نیست: حدود یک‌چهارم مجموعه‌داده‌های شبیه‌سازی‌شده‌اش $H < F$ دارند، چون $\mathcal{N}(1, 1.5)$ حدود ٪۲۵ جرمش را روی d' منفی می‌گذارد. برای تکلیفی که می‌دانیم شرکت‌کننده‌ها بالاتر از شانس عمل می‌کنند، پیشینی محدود به $d' > 0$ (مثلاً نیم‌نرمال یا Gamma) قابل دفاع‌تر است. امتحانش کنید و ببینید آیا پسین این شرکت‌کننده را تغییر می‌دهد. (راهنمایی: با ۲۰۰ trial آگاهی‌بخش، تقریباً نه.)

بخش E: تفسیر (۱۵ دقیقه)

یک «پاراگراف نتایج» کوتاه (۴ تا ۶ جمله) برای این شرکت‌کننده بنویسید، طوری که در یک مقاله می‌آید. پیشین‌ها، میانگین‌های پسین و HDIهای ٪۹۵ برای d' و c، $P(d' > 1 \mid \text{data})$، و یک جمله درباره‌ی حساسیت به پیشین (از سؤال ۳ بخش C) را گزارش کنید.

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. به‌صورت جبری نشان دهید که میانگین پسین مدل beta-binomial میانگین وزنی میانگین پیشین و y/n است. وزن‌ها چیستند؟

تمرین ۲ ⋆. با شبکه‌ی بخش A، ٪۹۵ HDI و بازه‌ی دم‌برابر را برای $\text{Beta}(1+2, 1+18)$ (۲ موفقیت از ۲۰) حساب کنید. چرا با هم فرق دارند؟

تمرین ۳ ⋆⋆ **(فراموشی با شبکه).** پسین شبکه‌ای (A, d) را برای مدل فراموشی توانی با داده‌های هفته‌ی ۲، با پیشین‌های $A \sim \text{Beta}(8, 2)$ و $d \sim \text{Gamma}(\text{shape } 2, \text{scale } 0.3)$ حساب کنید. میانگین‌های پسین و HDIهای ٪۹۵ را با MLE و بازه‌های profile و bootstrap هفته‌ی ۵ مقایسه کنید.

تمرین ۴ ⋆⋆ **(هم‌ارزی MAP و MLE).** در بخش C هر دو پیشین را با پیشین‌های تخت روی شبکه جایگزین کنید. نشان دهید MAP برابر MLE است. چرا میانگین پسین هنوز کمی فرق دارد؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: ترتیبی در برابر یکجا).** برای مدل SDT، پسین شبکه‌ای را trial به trial (پسین هر trial پیشین trial بعدی است) برای ۲۰۰ trial شبیه‌سازی‌شده به‌روز کنید و نشان دهید پسین نهایی (تا حد خطای عددی) با پسین یکجای همه‌ی trialها یکی است. انحراف معیار پسین d' را در برابر تعداد trialها رسم کنید.

lab check-off

نشان دهید: (۱) نمودار سه‌قسمتی پیشین/درست‌نمایی/پسین از بخش A، (۲) جدول خلاصه‌ی SDT و پسین مشترک از بخش C، و (۳) دو نمودار پیش‌بینی پیشین از بخش D با یک جمله درباره‌ی اینکه پیشین مبهم چه مشکلی دارد.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

مدل واقعاً چقدر خوب است؟ یک جواب بیزی برای ارزیابی‌های کوچک. پژوهشگرها اغلب یک LLM را روی مجموعه‌ی کوچکی از آیتم‌ها، مثلاً ۲۵ مسئله‌ی دست‌نویس، می‌آزمایند. مدل beta-binomial این هفته همان چیزی را می‌دهد که چنین مطالعه‌هایی معمولاً ندارند: یک پسین کامل برای دقت، گزاره‌های احتمالی مستقیم («احتمال اینکه دقت از ٪۶۰ بیشتر باشد») و مقایسه‌ی مستقیم دو مدل.

Code ۰۶ · کد: `code/week09.py`، cell ۰۶ · سلول ۶

خروجی مورد انتظار:

```
Model A: posterior mean = 0.704, 95% interval = [0.522, 0.857],
 ↪  P(accuracy > 0.6) = 0.878
Model B: posterior mean = 0.593, 95% interval = [0.406, 0.766],
 ↪  P(accuracy > 0.6) = 0.479
P(A more accurate than B | data) = 0.807
```

با ۲۵ آیتم، پهنای بازه‌های پسین حدود ۰.۳۵ است، و احتمال پسین ٪۱۹ وجود دارد که در واقع B مدل بهتر باشد.

امتحانش کنید (بدون نیاز به API). ⋆ - یک پیشین آگاهی‌بخش از یک ارزیابی قبلی و بزرگ‌تر استفاده کنید (مثلاً Beta(14, 6)) برای مدل A. نتیجه‌گیری‌ها چقدر عوض می‌شوند؟ - ⋆⋆ مقایسه‌ی بالا دو مدل را مستقل در نظر می‌گیرد، با اینکه به همان آیتم‌ها جواب داده‌اند. چرا این مشکل است (کادر هفته‌ی ۵ را ببینید)؟ طرح کلی مدلی را بکشید که جفت بودن را رعایت کند. - ⋆⋆ بحث: برای دقت یک مدل کاملاً تازه روی یک آزمون چهارگزینه‌ای چه پیشینی استفاده می‌کنید، و چرا نباید جرم زیادی زیر ۰.۲۵ بگذارد؟

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **«پیشین استنباط بیزی را ذهنی و نتایج را دلبخواهی می‌کند.»** پیشین‌ها فرض‌های صریح‌اند، درست مثل انتخاب درست‌نمایی. گزارششان کنید، توجیهشان کنید و حساسیت را بررسی کنید. با داده‌ی کافی، پیشین‌های معقول به نتیجه‌گیری‌های مشابه می‌رسند.

۲. **«پیشین‌های تخت یا خیلی پهن بی‌اطلاع‌اند.»** می‌توانند روی مقیاس داده به‌شدت آگاهی‌بخش باشند (بخش D). از پیشین‌های ضعیف‌آگاهی‌بخش استفاده کنید و با شبیه‌سازی پیش‌بینی پیشین بررسی‌شان کنید.

۳. **انتخاب پیشین بعد از نگاه کردن به داده.** این یعنی دو بار استفاده از داده.

۴. **ضرب احتمال‌ها روی شبکه بدون لگاریتم،** که سرریز می‌کند (هفته‌ی ۴). با لگاریتم پیشین + لگاریتم درست‌نمایی کار کنید و پیش از نمایی گرفتن بیشینه را کم کنید.

۵. **شبکه‌ی خیلی درشت یا خیلی باریک.** اگر پسین در لبه‌ی شبکه بریده شود، همه‌ی خلاصه‌ها غلط‌اند. بررسی کنید که پسین در لبه‌ها نزدیک صفر باشد.

۶. **خواندن credible interval به جای بازه‌ی اطمینان یا برعکس.** فقط credible interval جمله‌ی «با احتمال ٪۹۵ پارامتر اینجاست» (با توجه به مدل و پیشین) را پشتیبانی می‌کند.

۷. **فقط گزارش MAP.** نکته‌ی پسین کل توزیع است. یک مقدار مرکزی و یک بازه، و احتمال فرضیه‌هایی را که برایتان مهم‌اند گزارش کنید.

۹.۱.۱ خودآزمایی

۱. قاعده‌ی بیز را برای پارامتر θ بنویسید و هر جمله را نام ببرید. **پاسخ** $p(\theta \mid y) = p(y \mid \theta)p(\theta)/p(y)$: پسین = درست‌نمایی × پیشین / شواهد (marginal likelihood). برای برآورد، $p(\theta \mid y) \propto p(y \mid \theta)p(\theta)$.

۲. پیشین $\mathrm{Beta}(3,3)$، داده: ۱۲ یادآوری از ۲۰. پسین و میانگینش چیست؟ **پاسخ** $\mathrm{Beta}(3+12, 3+8) = \mathrm{Beta}(15, 11)$، با میانگین $15/26 = 0.577$.

۳. چرا با افزایش n پسین به MLE نزدیک‌تر می‌شود؟ **پاسخ** لگاریتم درست‌نمایی مجموعی روی مشاهدات است و با n بزرگ می‌شود، در حالی که لگاریتم پیشین ثابت می‌ماند. با داده‌ی زیاد درست‌نمایی بر حاصل‌ضرب غالب می‌شود و پسین حول بیشینه‌ی درست‌نمایی متمرکز می‌شود.

۴. تفاوت HDI ٪۹۵ و بازه‌ی دم‌برابر ٪۹۵ چیست؟ کی بر هم منطبق‌اند؟ **پاسخ** HDI باریک‌ترین بازه‌ای است که ٪۹۵ جرم پسین را در بر دارد و هر مقدار داخلش چگالی بیشتری از هر مقدار بیرونش دارد. بازه‌ی دم‌برابر از هر دم ٪۲.۵ را می‌بُرد. برای پسین‌های متقارن تک‌مُدی بر هم منطبق‌اند و برای پسین‌های چوله فرق دارند.

۵. چرا تقریب شبکه‌ای برای مدل‌هایی با پارامترهای زیاد غیرعملی می‌شود؟ **پاسخ** تعداد نقاط شبکه با تعداد پارامترها به‌طور نمایی رشد می‌کند (مثلاً ۱۰۰ نقطه برای هر پارامتر یعنی 100^k ارزیابی). این نفرین ابعاد است. نمونه‌گیری MCMC (هفته‌های ۱۱–۱۳) از آن دوری می‌کند.

۶. همکاری «برای احتیاط» از $d' \sim \mathcal{N}(0, 100)$ استفاده می‌کند. برای قانع کردنش که این ایده‌ی بدی است چه می‌کنید؟ **پاسخ** یک شبیه‌سازی پیش‌بینی پیشین: نشان دهید این پیشین نرخ‌های hit و false alarmی نتیجه می‌دهد که تقریباً همیشه دقیقاً ۰ یا ۱ هستند؛ باوری پوچ درباره‌ی داده‌ی تشخیص واقعی. به‌جایش یک پیشین ضعیف‌آگاهی‌بخش پیشنهاد کنید.

۷. این جمله را توضیح دهید: «تصحیح log-linear برای نرخ‌های حدی یک برآورد بیزی است». **پاسخ** نرخ تصحیح‌شده‌ی $(y + 0.5)/(n + 1)$ برابر میانگین پسین θ تحت پیشین $\text{Beta}(0.5, 0.5)$ است: $(0.5 + y)/(0.5 + 0.5 + n)$. این تصحیح به‌طور ضمنی از هر نوع نیم مشاهده‌ی کاذب اضافه می‌کند.

۱۰.۱.۱ تکلیف

- A3 **(مقایسه و بازیابی مدل)** و **پیشنهاد پروژه** در ابتدای درس این هفته تحویل داده می‌شوند.
- این هفته تکلیف نمره‌دار جدیدی نداریم. A4 **(تحلیل بیزی با شبکه)** در هفته‌ی ۱۰ منتشر می‌شود.
- **تمرین اختیاری (بدون نمره):** تمرین ۳ lab (فراموشی با شبکه) هسته‌ی A4 است. اگر الان شروعش کنید در وقتتان صرفه‌جویی می‌شود.

۱۱.۱.۱ مطالعه‌ی بیشتر

- Kruschke **(۲۰۱۴)، فصل‌های ۵–۶.** قاعده‌ی بیز، و استنباط یک احتمال دوجمله‌ای با تحلیل ریاضی دقیق (مدل beta-binomial). خیلی ساده و تصویری. (منبع اصلی.)
- Wagenmakers & Lee **(۲۰۱۴)، فصل‌های ۱ و ۳.** مبانی تحلیل بیزی، و استنباط با توزیع دوجمله‌ای.
- Lao & Martin, Kumar **(۲۰۲۱)، فصل ۱.** استنباط بیزی: اجزای یک مدل بیزی و توزیع‌های پیش‌بینی پیشین/پسین، همراه با کد Python.
- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۶.** برآورد بیزی پارامتر: مفاهیم پایه، مرتبط با چارچوب درست‌نمایی هفته‌ی ۴.
- **عظیمی‌فر و احمدی (۱۳۹۶)،** جلد ۱: بخش برآورد بیزی پارامتر و ارتباطش با برآورد ML [شماره‌ی فصل بررسی شود].

پیش‌نمایش هفته‌ی ۱۰: پسین درباره‌ی پارامترها درون یک مدل حرف می‌زند. هفته‌ی بعد می‌پرسیم داده‌ها باور ما را بین مدل‌ها چطور تغییر می‌دهند، با استفاده از شواهد $p(\mathbf{y} \mid \mathcal{M})$ که تا حالا به‌عنوان ثابت نرمال‌ساز نادیده‌اش گرفته‌ایم، و چطور بررسی کنیم که پیش‌بینی‌های پسین یک مدل شبیه داده‌ی واقعی هستند یا نه.