مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۱۰: مدل‌سازی بیزی ۲: بررسی پیش‌بینی پسین و dir ltr Bayes factor

فهرست مطالب

۱ **مدل‌سازی بیزی** ۱

۱.۱ هفته‌ی ۱۰: مدل‌سازی بیزی ۲: بررسی پیش‌بینی پسین و Bayes factor ۱

۱.۱.۱ واژه‌های کلیدی ۱

۲.۱.۱ اهداف یادگیری ۲

۳.۱.۱ مقدمه ۳

۴.۱.۱ جزوه‌ی درس ۳

۵.۱.۱ مثال حل‌شده ۷

۶.۱.۱ lab (۲ ساعت) ۸

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها ۱۰

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست ۱۰

۹.۱.۱ خودآزمایی ۱۱

۱۰.۱.۱ تکلیف ۱۱

۱۱.۱.۱ مطالعه‌ی بیشتر ۱۲

فصل ۱

مدل‌سازی بیزی

۱.۱ هفته‌ی ۱۰: مدل‌سازی بیزی ۲: بررسی پیش‌بینی پسین و Bayes factor

فصل ۴: مدل‌سازی بیزی (همراه با فصل ۳: ارزیابی) · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌های فراموشی هفته‌ی ۲ (نمایی در برابر توانی)، و یک شرکت‌کننده‌ی SDT با شواهد ضعیف (آیا $d' = 0$ است؟).

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

جدول ۱.۱: واژه‌های کلیدی

English	فارسی	توضیح کوتاه
posterior	توزیع پسین (posterior)	باور درباره‌ی پارامتر بعد از دیدن داده
forgetting curve	منحنی فراموشی	کاهش یادآوری با گذشت زمان
power function / exponential	تابع نمایی / توانی	دو شکل رایج برای منحنی فراموشی و یادگیری
evidence	شواهد	اطلاعاتی که برای تصمیم جمع می‌شود
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
posterior predictive check (PPC)	بررسی پیش‌بینی پسین	مقایسه‌ی داده‌ی شبیه‌سازی‌شده از پسین با داده‌ی واقعی
evidence / marginal likelihood	درست‌نمایی حاشیه‌ای	احتمال داده تحت مدل، میانگین روی پیشین
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها

English	فارسی	توضیح کوتاه
Bayes factor (BF)	عامل بیز (Bayes factor)	نسبت درست‌نمایی‌های حاشیه‌ای دو مدل
complexity / model flexibility	انعطاف‌پذیری / پیچیدگی مدل	دامنه‌ی الگوهایی که مدل می‌تواند تولید کند
grid approximation	تقریب شبکه‌ای (grid)	محاسبه‌ی پسین روی شبکه‌ای از مقادیر
Savage–Dickey ratio	نسبت Savage–Dickey	BF از نسبت چگالی پسین به پیشین در مقدار صفر
BIC / AIC	معیار اطلاعاتی آکائیکه / بیزی	برازش به‌علاوه‌ی جریمه برای تعداد پارامتر
prior	توزیع پیشین (prior)	باور درباره‌ی پارامتر پیش از دیدن داده
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
posterior odds	بخت پسین (odds)	نسبت احتمال پسین دو مدل
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
noise	نویز	تغییرات تصادفی در شواهد یا در داده
adequacy check	بررسی کفایت مدل	آیا مدل ویژگی‌های اصلی داده را بازتولید می‌کند
nested models	مدل‌های تودرتو (nested)	یک مدل حالت خاص مدل دیگر است
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
accuracy	دقت	نسبت پاسخ‌های درست

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. توزیع‌های پیش‌بینی پسین را **تولید کنند** و بررسی‌های پیش‌بینی پسین (PPC) نموداری و عددی **انجام دهند**.
۲. marginal likelihood و Bayes factor را **تعریف کنند** و **توضیح دهند** چرا marginal likelihood انعطاف مدل را خودکار جریمه می‌کند.
۳. Bayes factor را با انتگرال‌گیری شبکه‌ای و با نسبت چگالی Savage–Dickey **حساب کنند** و با تقریب BIC **مقایسه کنند**.
۴. حساسیت Bayes factor به پیشین را **ارزیابی کنند** و آن را با پایداری برآوردهای پسین **مقایسه کنند**.
۵. Bayes factorها را روی یک مقیاس درجه‌بندی‌شده‌ی شواهد **تفسیر کنند** و با بخت‌های پیشین **ترکیب کنند** تا احتمال‌های پسین مدل‌ها به دست آید.

۳.۱.۱ مقدمه

هفته‌ی قبل پسین‌ها را درون یک مدل به دست آوردیم. دو سؤال باقی مانده است.

۱. آیا مدل اصلاً خوب است؟ یک پسین می‌تواند باریک و مطمئن باشد حتی وقتی مدل به‌شدت غلط است: مدل نمایی با کمال میل برای داده‌های هفته‌ی ۲ یک پسین دقیق برای λ می‌دهد. جواب بیزی این است که از مدل برازش‌شده بخواهیم **داده‌ی جدید تولید کند** و ببینیم شبیه داده‌ی واقعی است یا نه. این یک بررسی پیش‌بینی پسین (posterior predictive check) است؛ همتای بیزی نمودار باقی‌مانده‌ها و G^2.

استنباط بیزی جوابی داخلی دارد: حساب کنیم هر مدل پیش از برازش داده‌ها را چقدر خوب پیش‌بینی کرده بود، با میانگین‌گیری روی همه‌ی مقادیر پارامتری که پیشینش اجازه می‌دهد. این marginal likelihood است، و نسبت دو marginal likelihood Bayes factor است. بنابراین Bayes factor تیغ اوکام را خودکار اجرا می‌کند، و به انعطاف شکل تابعی پاسخ می‌دهد، نه فقط به k.

Bayes factorها برای آزمون فرض صفر هم استفاده می‌شوند («آیا حساسیت صفر است؟»). برخلاف مقدار p، می‌توانند شواهد **به نفع** فرض صفر را هم کمّی کنند.

این موضوع کجا به کار می‌رود؟

- **شاهد برای «بدون اثر».** مطالعه‌های تکرار (replication) اغلب می‌پرسند آیا یک اثر وجود ندارد. p-value نمی‌تواند از فرض صفر پشتیبانی کند؛ Bayes factor می‌تواند («داده تحت فرض بدون اثر ۸ برابر محتمل‌تر است»).
- **بررسی مدل در هر تحلیل بیزی:** posterior predictive check گامی استاندارد پیش از اعتماد به هر نتیجه است (مثلاً در کارآزمایی‌های بالینی که به روش بیزی تحلیل می‌شوند و در مقاله‌های مدل‌سازی شناختی).
- **مقایسه‌ی نظریه‌هایی با انعطاف متفاوت:** وقتی دو مدل تعداد پارامتر یکسانی دارند ولی یکی می‌تواند الگوهای داده‌ی خیلی بیشتری بسازد، Bayes factor یکی از معدود ابزارهایی است که این را می‌بیند.

۴.۱.۱ جزوه‌ی درس

به زبان ساده این هفته دو سؤال جدا داریم. **(۱) آیا مدل من به اندازه‌ی کافی خوب است؟** بگذارید مدل برازش‌شده داده‌ی تازه تصور کند: مقدارهای معقول پارامتر را از posterior بردارید، یک آزمایش تازه شبیه‌سازی کنید و این کار را بارها تکرار کنید. اگر داده‌ی واقعی شبیه یک داده‌ی تصوری معمولی باشد، مدل کافی است؛ اگر داده‌ی واقعی بیرون از ابر داده‌های تصوری باشد، مدل چیزی را از قلم انداخته است. این یک posterior predictive check است. این عدد marginal likelihood است و نسبت آن برای دو مدل Bayes factor است. مدلی که روی همه‌چیز شرط می‌بندد (خیلی منعطف) باید شرط‌هایش را پخش کند، پس وقتی داده جایی می‌افتد که مدل ساده‌تر روی آن شرط بسته بود، کمتر برنده می‌شود. این همان تیغ اوکام است که در نظریه‌ی احتمال تعبیه شده. نکته‌ی مهم: Bayes factor به prior بستگی دارد، پس باید گزارش کنید که با priorهای معقول چطور تغییر می‌کند.

زمان‌بندی پیشنهادی (۶۰ دقیقه): بررسی پیش‌بینی پسین ۱۵ · marginal likelihood و Bayes factor ۲۰ · محاسبه‌ی Bayes factor (شبکه، BIC، Savage–Dickey) ۱۵ · حساسیت به پیشین و مقایسه‌ی روش‌ها ۱۰.

۱. بررسی‌های پیش‌بینی پسین

توزیع پیش‌بینی پسین داده‌ی جدید $\mathbf{y}^{\text{rep}}$ را که مدل برازش‌شده انتظار دارد توصیف می‌کند:

$$p(\mathbf{y}^{\text{rep}} \mid \mathbf{y}) = \int p(\mathbf{y}^{\text{rep}} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta} \mid \mathbf{y})\, d\boldsymbol{\theta}.$$

دستور شبیه‌سازی: برای $s = 1, \dots, S$، $\boldsymbol{\theta}^{(s)}$ را از پسین بکشید و یک مجموعه‌داده‌ی $\mathbf{y}^{\text{rep}(s)}$ از مدل با طرح آزمایش واقعی شبیه‌سازی کنید. این کار هم عدم قطعیت پارامترها و هم نویز نمونه‌گیری را منتقل می‌کند.

بررسی‌ها: - **نموداری:** داده‌ی مشاهده‌شده را روی بازه‌های پیش‌بینی (مثلاً ٪۹۵ مرکزی y^{rep} در هر شرط) رسم کنید. انحراف‌های نظام‌مند (نقاط مشاهده‌شده که مرتب بیرون نوارها یا در یک سمتشان‌اند) نشان می‌دهند مدل کجا شکست می‌خورد. - **عددی:** یک آماره‌ی آزمون $T(\mathbf{y})$ انتخاب کنید که ویژگی مورد نظرتان را نشان دهد (مثلاً یادآوری در طولانی‌ترین فاصله‌ها، تندی افت اولیه). **مقدار p پیش‌بینی پسین** برابر است با $p_B = P\big(T(\mathbf{y}^{\text{rep}}) \geq T(\mathbf{y}) \mid \mathbf{y}\big)$. مقادیر نزدیک ۰ یا ۱ نشان می‌دهند مدل نمی‌تواند این ویژگی را بازتولید کند.

گام همیشگی هر تحلیل بیزی‌اند (هفته‌ی ۱۳).

خواندن ریاضی

- $\mathbf{y}^{\text{rep}}$: داده‌ی «تکرارشده»، یک تکرار تصوری از آزمایش.
- $\int p(\mathbf{y}^{\text{rep}} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta} \mid \mathbf{y})\, d\boldsymbol{\theta}$ در عمل این انتگرال با دستور شبیه‌سازی دومرحله‌ای جایگزین می‌شود: $\boldsymbol{\theta}$ را از posterior بکش و بعد با آن داده شبیه‌سازی کن.
- $p_B = P(T(\mathbf{y}^{\text{rep}}) \geq T(\mathbf{y}) \mid \mathbf{y})$: کسری از داده‌های تصوری که آماره‌ی خلاصه‌ی T آن‌ها دست‌کم به اندازه‌ی داده‌ی واقعی بزرگ است. اگر فقط ٪۱ داده‌های تصوری یادآوری‌ای به بالایی مقدار مشاهده‌شده در ۳۰ روز نشان دهند ($p_B = 0.01$)، مدل نمی‌تواند این ویژگی را تولید کند.

۲. marginal likelihood و Bayes factor

marginal likelihood (شواهد) مدل $\mathcal{M}$ درست‌نمایی‌ای است که روی پیشین میانگین‌گیری شده است:

$$p(\mathbf{y} \mid \mathcal{M}) = \int p(\mathbf{y} \mid \boldsymbol{\theta}, \mathcal{M})\, p(\boldsymbol{\theta} \mid \mathcal{M})\, d\boldsymbol{\theta}.$$

این احتمالی است که مدل پیش از دیدن داده‌ی مشاهده‌شده به آن داده بود. قاعده‌ی بیز در سطح مدل‌ها می‌دهد:

$$\underbrace{\frac{p(\mathcal{M}_1 \mid \mathbf{y})}{p(\mathcal{M}_2 \mid \mathbf{y})}}_{\text{posterior odds}} = \underbrace{\frac{p(\mathbf{y} \mid \mathcal{M}_1)}{p(\mathbf{y} \mid \mathcal{M}_2)}}_{\text{BF}_{12}} \times \underbrace{\frac{p(\mathcal{M}_1)}{p(\mathcal{M}_2)}}_{\text{prior odds}}.$$

BF_{12} ضریبی است که داده‌ها با آن بخت $\mathcal{M}_1$ نسبت به $\mathcal{M}_2$ را تغییر می‌دهند، و $\text{BF}_{21} = 1/\text{BF}_{12}$.

تیغ خودکار اوکام. هر دو مدل باید احتمال کل ۱ را روی همه‌ی مجموعه‌داده‌های ممکن پخش کنند. یک مدل ساده پیش‌بینی‌هایش را روی چند مجموعه‌داده متمرکز می‌کند؛ یک مدل منعطف آن‌ها را نازک پخش می‌کند. اگر داده‌ها همان‌جایی بیفتند که مدل ساده پیش‌بینی کرده بود، مدل ساده marginal likelihood بالاتری می‌گیرد، حتی اگر مدل منعطف هم بعد از تنظیم پارامترهایش بتواند آن‌ها را خوب برازش کند. برخلاف AIC/BIC، این جریمه به اینکه مدل چقدر منعطف است (پراکندگی پیش‌بینی پیشین) بستگی دارد، نه فقط به k.

یک مقیاس رایج شواهد (برگرفته از دسته‌بندی کلاسیک Jeffreys، آن‌طور که Lee و Wagenmakers به کار می‌برند):

جدول ۲.۱: 2. marginal likelihood و Bayes factor

BF_{12}	$\mathcal{M}_1$ شواهد به نفع
۳–۱	حکایتی (anecdotal)
۱۰–۳	متوسط
۳۰–۱۰	قوی
۱۰۰–۳۰	خیلی قوی
۱۰۰ <	فوق‌العاده قوی

(مقادیر کمتر از ۱ به همین شکل برای $\mathcal{M}_2$ خوانده می‌شوند.) این برچسب‌ها کمک‌کننده‌اند، نه آستانه. خود عدد را گزارش کنید.

خواندن ریاضی

- $p(\mathbf{y} \mid \mathcal{M}) = \int p(\mathbf{y} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})\, d\boldsymbol{\theta}$: درست‌نمایی که روی prior **میانگین** گرفته شده، نه بیشینه. مقایسه کنید: MLE بهترین مقدار پارامتر را برمی‌دارد؛ marginal likelihood میانگین وزن‌دار با *prior* روی همه‌ی مقدارها را. مدلی که prior آن مقدارهای بد زیادی دارد، میانگین پایینی می‌گیرد.
- **بخت پسین** = Bayes factor × **بخت پیشین**. بخت (odds) نسبت احتمال‌هاست: بخت ۳ یعنی ۳ به ۱، یعنی احتمال ۰.۷۵. اگر دو مدل پیش از داده به یک اندازه معقول بودند (بخت پیشین = ۱) و $\mathrm{BF}_{12} = 3$ باشد، بعد از داده $P(\mathcal{M}_1 \mid \mathbf{y}) = 3/(1+3) = 0.75$.
- **مثال حل‌شده در یک خط:** با ۷ درست از ۱۰، مدل شانس داده را با احتمال ۰.۱۱۷ و مدل «هر دقتی» با احتمال ۰.۰۹۱ پیش‌بینی کرده بودند، پس $\mathrm{BF}_{01} = 1.29$: داده بخت‌ها را تقریباً تغییر نمی‌دهد.

۳. محاسبه‌ی Bayes factor

(الف) انتگرال‌گیری شبکه‌ای (۱ تا ۲ پارامتر): $p(\mathbf{y} \mid \mathcal{M}) \approx \sum_g p(\mathbf{y} \mid \boldsymbol{\theta}_g)\, p(\boldsymbol{\theta}_g)\, \Delta_g$، که Δ_g مساحت هر خانه است. آن را در فضای لگاریتمی (log-sum-exp) انجام دهید و بررسی کنید که جرم پیشین داخل شبکه ≈ 1 باشد.

(ب) تقریب BIC. برای N بزرگ، $\ln p(\mathbf{y} \mid \mathcal{M}) \approx -\frac{1}{2}\mathrm{BIC}$، پس

$$\mathrm{BF}_{12} \approx \exp\big(-\tfrac{1}{2}(\mathrm{BIC}_1 - \mathrm{BIC}_2)\big).$$

سریع ولی خام است: پیشین واقعی را نادیده می‌گیرد (به‌طور ضمنی یک پیشین «unit-information» فرض می‌کند) و انعطاف شکل تابعی را هم.

(ج) نسبت چگالی Savage–Dickey (مدل‌های nested). اگر $\mathcal{M}_0$ در $\mathcal{M}_1$ مقدار $\phi = \phi_0$ را ثابت کند و پیشین‌های بقیه‌ی پارامترها یکی باشند، آن‌وقت

$$\mathrm{BF}_{01} = \frac{p(\phi = \phi_0 \mid \mathbf{y}, \mathcal{M}_1)}{p(\phi = \phi_0 \mid \mathcal{M}_1)}\,:$$

چگالی پسین در مقدار صفر تقسیم بر چگالی پیشین در مقدار صفر، هر دو تحت مدل بزرگ‌تر. اگر داده‌ها ϕ_0 را محتمل‌تر از قبل کنند، شواهد به نفع فرض صفر است. فقط یک پسین از $\mathcal{M}_1$ لازم داریم.

(روش‌های دیگر، مثل bridge sampling و thermodynamic integration، marginal likelihood مدل‌های پیچیده را از خروجی MCMC حساب می‌کنند. این‌ها خارج از محدوده‌ی این درس‌اند.)

خواندن ریاضی Savage–Dickey $\mathrm{BF}_{01} = p(\phi_0 \mid \mathbf{y}) / p(\phi_0)$: به ارتفاع posterior و prior در مقدار صفر ϕ_0 نگاه کنید (مثلاً $\theta = 0.5$). اگر posterior آنجا بلندتر از prior باشد، داده مقدار صفر را معقول‌تر کرده، پس شواهد به نفع فرض صفر است. در مثال حل‌شده prior (صاف) در ۵.۰ ارتفاع ۱ دارد و posterior یعنی $\mathrm{Beta}(8, 4)$ ارتفاع ۲۹.۱، پس $\mathrm{BF}_{01} = 1.29$. یک تصویر از دو منحنی و یک خط عمودی در ϕ_0 تمام چیزی است که برای توضیح این لازم دارید.

۴. حساسیت به پیشین: برآورد در برابر آزمون

برای **برآورد**، یک پیشین معقول با جمع شدن داده کم‌اهمیت‌تر می‌شود. برای Bayes factor، پیشین پارامتر آزمون‌شده هرگز بی‌اهمیت نمی‌شود. پهن‌تر کردن پیشین تحت $\mathcal{M}_1$ پیش‌بینی‌هایش را نازک‌تر پخش می‌کند و $p(\mathbf{y} \mid \mathcal{M}_1)$ را کم می‌کند، پس یک پیشین دلخواه مبهم Bayes factor را، هر داده‌ای که باشد، به نفع فرض صفر می‌کند (پارادوکس Jeffreys–Lindley). پیامدها: - پیشین‌ها برای مقایسه‌ی مدل باید با دقت انتخاب شوند، ترجیحاً منعکس‌کننده‌ی اندازه‌ی اثرهای واقع‌بینانه. - همیشه یک **تحلیل حساسیت** گزارش کنید: Bayes factor روی دامنه‌ای از پهنای معقول پیشین.

۵. مقایسه‌ی روش‌های ارزیابی مدل

جدول ۳.۱: ۵. مقایسه‌ی روش‌های ارزیابی مدل

روش	سؤال	چه چیزی را جریمه می‌کند	پیشین لازم است؟	هفته
G^2، باقی‌مانده‌ها، PPC	آیا مدل کافی است؟	—	بله PPC:	۴، ۱۰
LRT	آیا پارامتر اضافه برازش را بیش از شانس بهتر می‌کند؟ (فقط nested)	Δk از راه χ^2	نه	۷
CV / AIC	ام مدل داده‌ی جدید را بهتر پیش‌بینی می‌کند؟	overfitting تخمینی	نه	۶–۷
BIC	به‌طور تقریبی: ام مدل شواهد بیشتری دارد؟	$k \ln N$	ضمنی	۷
Bayes factor	داده‌ها بخت بین مدل‌ها را چقدر تغییر می‌دهند؟	پراکندگی پیش‌بینی پیشین (انعطاف واقعی)	**بله، و نتیجه به آن بستگی دارد**	۱۰

پیشرفته: Bayes factor در برابر معیارهای پیش‌بینی. marginal likelihood را می‌شود به شکل حاصل‌ضرب پیش‌بینی‌های ترتیبی نوشت، $p(\mathbf{y}) = p(y_1)\, p(y_2 \mid y_1) \cdots p(y_N \mid y_{1:N-1})$. پس امتیاز می‌دهد که مدل هر نقطه‌ی داده را از روی نقاط قبلی، با شروع از پیشین، چقدر خوب پیش‌بینی می‌کند. LOO-CV پیش‌بینی‌ها را از روی (تقریباً) همه‌ی داده‌های دیگر امتیاز می‌دهد. به همین دلیل Bayes factor به پیشین وابسته است و LOO تقریباً نه، و به همین دلیل ممکن است روی داده‌ی یکسان با هم مخالف باشند.

برای یک مهندس

- **بخت پسین** = BF × **بخت پیشین** همان **آشکارساز** MAP **(بیز)** بین دو فرضیه است که در آن Bayes factor نقش نسبت درست‌نمایی را دارد.
- تفاوت با GLRT (هفته‌های ۴ و ۷): با پارامترهای مجهول، GLRT درست‌نمایی را روی آن‌ها بیشینه می‌کند؛ Bayes factor با یک prior روی آن‌ها انتگرال (میانگین) می‌گیرد. بیشینه کردن به فرضیه‌های منعطف امتیاز می‌دهد؛ میانگین گرفتن آن‌ها را خودکار جریمه می‌کند.
- **پارادوکس** Jeffreys–Lindley رنگ‌وبوی مهندسی دارد: اگر بگذارید فرضیه‌ی جایگزین دامنه‌های سیگنال به‌طور نامعقول بزرگ را مجاز بداند prior) خیلی پهن)، تقریباً هر مشاهده‌ای با «فقط نویز» بهتر توضیح داده می‌شود.
- posterior predictive check شبیه اعتبارسنجی یک مدل کانال است: سیگنال‌های دریافتی را از مدل برازش‌شده شبیه‌سازی کنید و آماره‌هایشان (هیستوگرام، خودهمبستگی، eye diagram) را با اندازه‌گیری‌ها مقایسه کنید.

برای مدرس

- یکی ژتون‌ها را روی همه‌چیز پخش می‌کند؛ دیگری بیشتر ژتون‌ها را روی یک محدوده‌ی باریک می‌گذارد. اگر نتیجه در آن محدوده‌ی باریک بیفتد، پیش‌بینی‌کننده‌ی متمرکز بیشتر می‌برد. marginal likelihood همان مبلغ برد است.
- **دو سؤال را از هم جدا نگه دارید.** روی تخته بنویسید «آیا مدل کافی است؟ ← BF / CV / AIC». دانشجوها اغلب از BF برای ادعای خوب بودن یک مدل استفاده می‌کنند؛ BF فقط می‌گوید از دیگری بهتر است.
- **سؤال‌های رایج.**
  - «*BF* یا *value*p-؟» به سؤال‌های متفاوتی جواب می‌دهند. BF دو فرضیه‌ی مشخص را مقایسه می‌کند و می‌تواند از فرض صفر پشتیبانی کند؛ p-value فقط میزان غافلگیری تحت فرض صفر را می‌سنجد.
  - «*BF* = ۵.۲ معنادار است؟» آستانه‌ای وجود ندارد؛ شواهد حکایتی (anecdotal) است. عدد را گزارش کنید.
  - «چرا *BF* و *AIC* با هم توافق ندارند؟» هدف‌های متفاوتی دارند (شواهد در برابر پیش‌بینی) و BF به prior بستگی دارد.

۵.۱.۱ مثال حل‌شده

بخش ۱: آیا یادآوری در حد شانس است؟ یک Bayes factor با دست

یک شرکت‌کننده در $n = 10$ trial بین دو گزینه انتخاب می‌کند و در $y = 7$ trial درست جواب می‌دهد. آیا عملکرد در حد شانس است؟

- $\mathcal{M}_0$: $\theta = 0.5$ (بدون پارامتر آزاد).
- $\mathcal{M}_1$: $\theta \sim \mathrm{Beta}(1,1)$ (هر دقتی از پیش به یک اندازه محتمل است).

قدم ۱. $p(y \mid \mathcal{M}_0) = \binom{10}{7} 0.5^{10} = 120/1024 = 0.1172$.

قدم ۲. تحت پیشین یکنواخت، هر شمارش $0, \dots, n$ از پیش به یک اندازه محتمل است، پس $p(y \mid \mathcal{M}_1) = \int_0^1 \binom{10}{7} \theta^7 (1-\theta)^3 \, d\theta = \frac{1}{n+1} = \frac{1}{11} = 0.0909$.

قدم ۳. $\mathrm{BF}_{01} = 0.1172 / 0.0909 = 1.29$. داده‌ها کمی به نفع شانس‌اند؛ شواهدی حکایتی در هر دو جهت.

قدم ۴ (بررسی). Savage–Dickey). پسین تحت $\mathcal{M}_1$ برابر $\mathrm{Beta}(8,4)$ است که چگالی‌اش در ۵.۰ برابر ۲۸۹.۱ است. چگالی پیشین در ۵.۰ برابر ۱ است. نسبت ۲۹.۱ است، دقیقاً همان قدم ۳.

داده‌ی بیشتر:

جدول ۴.۱: بخش ۱: آیا یادآوری در حد شانس است؟ یک Bayes factorبا دست

داده	p (آزمون دوجمله‌ای دوطرفه)	BF_{01}	خوانش
۷/۱۰	۳۴.۰	۲۹.۱	حکایتی، در هر دو جهت
۶۰/۱۰۰	$\approx$ ۰۶.۰	۱۰.۱	هنوز حکایتی: داده‌ها به‌سختی شانس را از «کمی دقت» جدا می‌کنند
۷۰/۱۰۰	$<$ ۰۰۱.۰	۰۰۲۳.۰ ($\mathrm{BF}_{10} \approx 430$)	شواهد فوق‌العاده قوی علیه شانس

تفسیر. با ۶۰/۱۰۰، مقدار p نزدیک ۰۵. پژوهشگران را وسوسه می‌کند ادعای اثر کنند، ولی Bayes factor می‌گوید داده‌ها تحت هر دو فرضیه تقریباً به یک اندازه محتمل‌اند. دلیل: فرضیه‌ی جایگزین با پیشین یکنواخت «پیش‌بینی کرده بود» که دقت می‌تواند هر جایی بین ۰ و ۱ باشد. دقت مشاهده‌شده‌ی ۶۰ فقط کمی بهتر با آن پیش‌بینی می‌شود تا با دقیقاً ۵۰. یک پیشین باریک‌تر و واقع‌بینانه‌تر تحت $\mathcal{M}_1$ (مثلاً دقت‌های بین ۵۰ و ۸۰) Bayes factor متفاوتی می‌داد؛ به همین دلیل حساسیت به پیشین باید گزارش شود.

بخش ۲: احتمال‌های پسین مدل‌ها

برای ۷/۱۰ با بخت پیشین ۱: بخت پسین $1.29 =$، پس $P(\mathcal{M}_0 \mid y) = 1.29/2.29 = 0.56$. اگر یک داور از پیش باور داشته باشد که عملکرد در حد شانس ۴ برابر کمتر از عملکرد بالاتر از شانس محتمل است (بخت پیشین ۱:۴)، آن‌وقت بخت پسین $1.29 \times 0.25 = 0.32 =$، پس $P(\mathcal{M}_0 \mid y) = 0.24$. Bayes factor برای همه یکی است؛ احتمال‌های پسین مدل‌ها به بخت‌های پیشین بستگی دارند.

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. اجرای بررسی‌های پیش‌بینی پسین نموداری و عددی برای مدل‌های فراموشی نمایی و توانی.
۲. محاسبه‌ی درست‌نمایی‌های حاشیه‌ای و Bayes factor توانی در برابر نمایی با انتگرال‌گیری شبکه‌ای؛ مقایسه با BIC.
۳. آزمون $d' = 0$ برای یک شرکت‌کننده‌ی SDT با شواهد ضعیف با نسبت Savage–Dickey، و وارسی آن با محاسبه‌ی مستقیم.
۴. ترسیم حساسیت Bayes factor به پیشین و مقایسه‌ی آن با برآورد پسین.

زمان‌بندی: بخش A ۳۵ دقیقه · بخش B ۲۵ دقیقه · بخش C ۳۰ دقیقه · بخش D ۲۰ دقیقه · بخش E ۱۰ دقیقه.

بخش A: بررسی‌های پیش‌بینی پسین (۳۵ دقیقه)

تفسیر: اول به نمودارها نگاه کنید. برای مدل نمایی، یادآوری مشاهده‌شده در کوتاه‌ترین فاصله (۴۲/۵۰) بالای نوار ٪۹۵ و یادآوری در ۷ روز (۱۳/۵۰) پایین آن است. مدل نمایی نمی‌تواند اول تند افت کند و بعد ثابت شود. نوار مدل توانی همه‌ی نقاط مشاهده‌شده را در بر دارد.

عدم برازش مدل نمایی در شکل است (فاصله‌های اولیه در برابر میانی)، که این آماره به آن نگاه نمی‌کند. **یک PPC فقط شکست‌هایی را تشخیص می‌دهد که آماره‌ی آزمونش به آن‌ها حساس است.** آماره‌هایی انتخاب کنید که ویژگی‌های متمایزکننده‌ی نظریه‌ها را هدف بگیرند؛ در تمرین ۲ یک آماره‌ی «افت اول» مدل نمایی را لو می‌دهد ($p_B \approx 0.02$).

بخش B: Bayes factor با انتگرال‌گیری شبکه‌ای (۲۵ دقیقه)

تفسیر: $\mathrm{BF} \approx 1.7 \times 10^5$ شواهد فوق‌العاده قوی به نفع مدل توانی در برابر نمایی است. BIC همان حکم را می‌دهد ولی با عدد دیگری (2×10^4). چرا Bayes factor شبکه‌ای و تقریب BIC با هم فرق دارند؟

بخش C: Savage–Dickey: آیا حساسیت این شرکت‌کننده صفر است؟ (۳۰ دقیقه)

یک شرکت‌کننده در یک تکلیف تشخیص سخت: ۱۲ hit از ۲۰ trial علامت، ۸ false alarm از ۲۰ trial نویز. $\mathcal{M}_1$: $d' \sim \mathcal{N}(0,1)$، $c \sim \mathcal{N}(0,1)$. $\mathcal{M}_0$: $d' = 0$، $c \sim \mathcal{N}(0,1)$.

دو محاسبه با هم توافق دارند؛ بررسی مفیدی برای اینکه هر دو درست صورت‌بندی شده‌اند.

بخش D: حساسیت به پیشین (۲۰ دقیقه)

به این دقت کنید: با پهن‌تر شدن پیشین d'، میانگین پسین d' سریع ثابت می‌شود، ولی BF_{01} مدام به نفع فرض صفر بزرگ‌تر می‌شود. یک پیشین خیلی پهن حساسیت‌های بزرگی را «پیش‌بینی می‌کند» که اتفاق نیفتاده‌اند، پس فرضیه‌ی جایگزین جریمه می‌شود. **برای برآورد، پیشین کم‌رنگ می‌شود؛ برای آزمون، نه.**

بخش E: تفسیر (۱۰ دقیقه)

۴ تا ۵ جمله بنویسید: آیا این شرکت‌کننده علامت را تشخیص می‌دهد؟ Bayes factor را با پیشین انتخابی‌تان گزارش کنید و پیشین را توجیه کنید، به تحلیل حساسیت اشاره کنید، و بگویید چه داده‌ی اضافه‌ای جواب را روشن‌تر می‌کرد.

تمرین‌ها (به ترتیب سختی)

$$\int_0^1 \binom{10}{7} \theta^7 (1-\theta)^3 d\theta = 1/11$$

تمرین ۲ ⋆. در بخش A از یک آماره‌ی آزمون دیگر استفاده کنید: افت یادآوری از اولین به دومین فاصله. (انتظار: مدل نمایی، $p_B \approx 0.02$؛ مدل توانی قبول می‌شود.)

تمرین ۳ ⋆⋆ **(حساسیت Bayes factor فراموشی به پیشین).** بخش B را با پیشین‌های نرخ پهن‌تر (مقیاس × ۳) و باریک‌تر (مقیاس ÷ ۳) تکرار کنید. آیا نتیجه‌ی «توانی ≫ نمایی» باقی می‌ماند؟ چرا اینجا، برخلاف بخش D، این‌قدر پایدار است؟

تمرین ۴ ⋆⋆ **(یک جایگزین آگاهانه).** در بخش C پیشین d' را با یک نیم‌نرمال $d' \sim \mathcal{N}^+(0,1)$ (فقط مقادیر مثبت؛ نرمال‌سازی دوباره را فراموش نکنید) جایگزین کنید. Bayes factor Savage–Dickey را حساب کنید. چرا یک پیشین جهت‌دار نتیجه را تغییر می‌دهد؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: Bayes factor برای مطالعه‌ی تکرار).** برای مطالعه‌ی موردی هفته‌ی ۸ ($\mathcal{M}_0$ در برابر $\mathcal{M}_1$)، پیشین‌هایی برای δ_0، δ_1 و κ انتخاب کنید، BF_{10} را با نسبت Savage–Dickey در $\delta_1 = 0$ با یک شبکه‌ی سه‌بعدی (درشت نگهش دارید) حساب کنید و با تقریب BIC مقایسه کنید.

lab check-off

نشان دهید: (۱) دو نمودار PPC با مقادیر p_B، (۲) Bayes factor شبکه‌ای توانی در برابر نمایی و تقریب BIC آن، و (۳) جدول حساسیت به پیشین از بخش D با یک جمله تفسیر.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

آیا LLMها «نظریه‌ی ذهن» (theory of mind) دارند؟ بعضی مطالعه‌ها گزارش می‌دهند که LLMها تکلیف‌های باور نادرست (false belief) را با موفقیت انجام می‌دهند، یعنی آزمون‌های کلاسیکی که می‌سنجند آیا کسی می‌فهمد دیگران می‌توانند باورهای نادرست داشته باشند. بعضی دیگر نشان می‌دهند که تغییرهای کوچک در داستان‌ها عملکرد را فرو می‌ریزد [بررسی شود: Kosinski, ۲۰۲۳/۲۰۲۴؛ Ullman, ۲۰۲۳]. بسیاری از این آزمون‌ها دو گزینه‌ی جواب دارند، پس سطح شانس ۵۰٪ است، و تعداد آیتم‌ها کم است. Bayes factor به اولین سؤال درست جواب می‌دهد: آیا داده اصلاً از عملکرد بالاتر از شانس، در مقایسه با شانس، پشتیبانی می‌کند؟

همان ۶۵٪ با ۴۰ آیتم اصلاً شاهدی نیست، و با ۲۰۰ آیتم شاهدی قاطع است. عملکرد بالاتر از شانس هم فقط قدم اول است: بررسی پیش‌بینی پسین این هفته می‌پرسد مدل چطور موفق می‌شود و شکست می‌خورد. مثلاً آیا دقیقاً روی داستان‌های تغییریافته شکست می‌خورد، جایی که یک انسان شکست نمی‌خورد؟

$\mathrm{BF}_{10}\ \theta > 0.5$ برای ۲۶/۴۰ چطور تغییر می‌کند؟ دقت کلی‌اش ۶۰٪ است. یک بررسی پیش‌بینی پسین طراحی کنید که میان‌بُر را آشکار کند. - ★★ بحث: «بالاتر از شانس در تکلیف‌های باور نادرست» ادعایی در سطح محاسباتی Marr است یا الگوریتمی؟

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **«پسین باریک یعنی مدل درست است.»** دقت همان کفایت نیست. همیشه یک PPC اجرا کنید.
۲. **استفاده از بررسی پیش‌بینی پسین برای انتخاب بین مدل‌ها.** PPCها کفایت را بررسی می‌کنند. برای مقایسه از Bayes factor، CV یا معیارهای اطلاعاتی استفاده کنید.
۳. Bayes factor» **احتمال پسین مدل است.»** Bayes factor تغییر بخت است. احتمال‌های پسین به بخت‌های پیشین هم نیاز دارند.
۴. **استفاده از پیشین‌های خیلی مبهم در آزمون‌های** .Bayes factor بی‌حد و مرز Bayes factor را به سمت فرض صفر سوگیر می‌کنند (بخش .(D از پیشین‌های واقع‌بینانه استفاده کنید و حساسیت را گزارش کنید.
۵. Savage–Dickey **با پیشین‌های ناهمخوان.** پیشین‌های پارامترهای مزاحم (nuisance) باید در هر دو مدل یکی باشند، و چگالی پیشین باید در مقدار صفر تحت مدل بزرگ‌تر ارزیابی شود.
۶. **محاسبه‌ی** marginal likelihood **روی شبکه‌ای که جرم پیشین را می‌بُرد.** بررسی کنید که جرم پیشین داخل شبکه نزدیک ۱ باشد.
۷. BF» = **۹.۲» و** BF» = **۱.۳» را کیفی متفاوت دانستن.** مقیاس شواهد پیوسته است؛ برچسب‌ها کمک‌کننده‌اند، نه آستانه‌ی تصمیم.

۹.۱.۱ خودآزمایی

۱. توزیع پیش‌بینی پسین چگونه شبیه‌سازی می‌شود و چه چیزهایی را ترکیب می‌کند؟ **پاسخ** پارامترها را از پسین بکشید و بعد با آن پارامترها (و طرح آزمایش واقعی) از مدل داده شبیه‌سازی کنید. عدم قطعیت درباره‌ی پارامترها را با نویز نمونه‌گیری داده‌ی جدید ترکیب می‌کند.

۲. marginal likelihood را با کلمات تعریف کنید. **پاسخ** احتمال (چگالی) داده‌ی مشاهده‌شده تحت مدل، میانگین‌گیری‌شده روی همه‌ی مقادیر پارامتر با وزن پیشین: اینکه مدل پیش از برازش این داده‌ها را چقدر خوب پیش‌بینی کرده بود.

۳. چرا marginal likelihood حتی بدون شمردن پارامترها مدل‌های منعطف را جریمه می‌کند؟ **پاسخ** احتمال روی مجموعه‌داده‌های ممکن باید جمعش ۱ شود. مگر اینکه داده جایی بیفتد که فقط مدل منعطف پیش‌بینی‌اش می‌کند.

۴. $\mathrm{BF}_{10} = 6$ و بخت پیشین ۱:۳ (علیه $\mathcal{M}_1$) است. بخت پسین و $P(\mathcal{M}_1 \mid \mathbf{y})$ چقدر است؟ **پاسخ** بخت پسین $= 6 \times 1/3 = 2$، پس $P(\mathcal{M}_1 \mid \mathbf{y}) = 2/3 \approx 0.67$.

۵. نسبت Savage–Dickey و شرایط استفاده از آن را بیان کنید. **پاسخ** $\mathrm{BF}_{01} = p(\phi_0 \mid \mathbf{y}, \mathcal{M}_1) / p(\phi_0 \mid \mathcal{M}_1)$: چگالی پسین تقسیم بر چگالی پیشین در مقدار صفر تحت مدل بزرگ‌تر. به مدل‌های nested (فرض صفر $\phi = \phi_0$ را ثابت می‌کند) و پیشین‌های یکسان برای بقیه‌ی پارامترها نیاز دارد.

۶. چرا پهن کردن پیشین پارامتر آزمون‌شده، حتی با داده‌ی ثابت، BF_{01} را افزایش می‌دهد؟ **پاسخ** یک پیشین پهن‌تر احتمال بیشتری به اثرهای بزرگ و احتمال کمتری به اندازه‌ی اثرهای کوچک سازگار با داده می‌دهد، پس marginal likelihood فرضیه‌ی جایگزین کم می‌شود در حالی که درست‌نمایی فرض صفر تغییری نمی‌کند.

۷. BIC مقدار $\mathrm{BF}_{12} \approx 20$ می‌دهد، در حالی که محاسبه‌ی شبکه‌ای با پیشین‌های شما ۳ می‌دهد. **پاسخ** Bayes factor شبکه‌ای را، چون از پیشین‌های واقعی استفاده می‌کند و انعطاف شکل تابعی را در نظر می‌گیرد؛ BIC تقریبی برای نمونه‌ی بزرگ با یک پیشین ضمنی است. به اختلاف اشاره کنید و، در صورت امکان، یک تحلیل حساسیت به پیشین بیاورید.

۱۰.۱.۱ تکلیف

A4: یک تحلیل بیزی با شبکه (۱۰.۰ نمره از ۲۰؛ انتشار هفته‌ی ۱۰، موعد ابتدای درس هفته‌ی ۱۲)

$n = 20$ هفته‌ی ۴ را ببینید).

کارها.

۱. **پیشین‌ها (۵.۱ امتیاز).** پیشین‌هایی برای (A, λ) مدل نمایی و (A, d) مدل توانی انتخاب و توجیه کنید. شبیه‌سازی‌های پیش‌بینی پیشین منحنی‌های فراموشی را برای هر دو مدل نشان دهید و در صورت نیاز پیشین‌ها را اصلاح کنید.

۲. **پسین (۲ امتیاز).** پسین‌های شبکه‌ای را برای هر دو مدل حساب کنید. میانگین‌های پسین، انحراف معیارها و HDIهای ۹۵٪، و همبستگی پسین دو پارامتر را گزارش کنید. پسین‌های مشترک را رسم کنید.

۳. **بررسی‌های پیش‌بینی پسین (۲ امتیاز).** PPC نموداری برای هر دو مدل، به‌علاوه‌ی یک PPC عددی با آماره‌ی آزمونی که خودتان انتخاب و توجیه می‌کنید.

۴. Bayes factor **(۲ امتیاز).** $\mathrm{BF}_{\text{pow,exp}}$ را با انتگرال‌گیری شبکه‌ای حساب کنید (جرم پیشین را بررسی کنید)، با تقریب BIC مقایسه کنید، و با دو تنظیم پیشین دیگر تکرار کنید (تحلیل حساسیت).

۵. **مقایسه با A2 (۱ امتیاز).** خلاصه‌های پسین را با MLEهای A2 و عدم قطعیتشان مقایسه کنید.

۶. **تفسیر (۵.۱ امتیاز، حداکثر ۳۰۰ کلمه).** درباره‌ی فراموشی در این داده‌ها چه نتیجه‌ای می‌گیرید و این نتیجه‌گیری چقدر در برابر پیشین پایدار است؟

روبریک: امتیازها مطابق بالا؛ داخل هر کار: درستی ٪۶۰، نمودارها و جدول‌ها ٪۲۰، تفسیر ٪۲۰. برای تحویل با تأخیر، روزی ٪۱۰ کسر می‌شود (حداکثر ۳ روز).

۱۱.۱.۱ مطالعه‌ی بیشتر

- Wagenmakers & Lee **(۲۰۱۴)، فصل ۷.** مقایسه‌ی بیزی مدل‌ها: درست‌نمایی‌های حاشیه‌ای، Bayes factor و روش Savage–Dickey، با مثال‌های حل‌شده. (منبع اصلی.)
- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۱۱.** مقایسه‌ی بیزی مدل‌ها با Bayes factor، در بافت مدل‌های شناختی.
- Kruschke **(۲۰۱۴)، فصل ۱۰.** مقایسه‌ی مدل‌ها و مدل‌سازی سلسله‌مراتبی؛ مقدمه‌ای ساده بر Bayes factor و حساسیتش به پیشین.
- Lao & Martin, Kumar **(۲۰۲۱)، فصل ۲.** تحلیل اکتشافی مدل‌های بیزی، از جمله بررسی‌های پیش‌بینی پسین.

پیش‌نمایش هفته‌ی ۱۱: شبکه‌های ما برای دو پارامتر کار کردند. برای پنج، ده یا صد پارامتر به راه هوشمندانه‌تری برای کاوش پسین نیاز داریم: Markov chain Monte Carlo. اولین نمونه‌گیر خود را از صفر می‌سازید.