# مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۱۲: نمونه‌گیری Gibbs و تشخیص همگرایی

# فهرست مطالب


**۱ برآورد پارامتر با MCMC** **۱**

۱.۱ هفته‌ی ۱۲: نمونه‌گیری Gibbs و تشخیص همگرایی . . . . . ۱

۱.۱.۱ واژه‌های کلیدی . . . . . ۱

۲.۱.۱ اهداف یادگیری . . . . . ۲

۳.۱.۱ مقدمه . . . . . ۳

۴.۱.۱ جزوه‌ی درس . . . . . ۳

۵.۱.۱ مثال حل‌شده . . . . . ۷

۶.۱.۱ lab (۲ ساعت) . . . . . ۸

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها . . . . . ۱۱

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست . . . . . ۱۱

۹.۱.۱ خودآزمایی . . . . . ۱۲

۱۰.۱.۱ تکلیف . . . . . ۱۲

۱۱.۱.۱ مطالعه‌ی بیشتر . . . . . ۱۳

# فصل ۱

# برآورد پارامتر با MCMC

## ۱.۱ هفته‌ی ۱۲: نمونه‌گیری Gibbs و تشخیص همگرایی

**فصل ۵: برآورد پارامتر با روش‌های داده‌محور** (MCMC) · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** لگاریتم زمان‌های واکنش یک شرکت‌کننده (مدل نرمال با میانگین و دقت نامعلوم)، و مدل فراموشی توانی که با نمونه‌گیر Metropolis هفته‌ی قبل نمونه‌گیری می‌شود.

---

### ۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

| English | فارسی | توضیح کوتاه |
|---|---|---|
| Gibbs sampling | نمونه‌گیری Gibbs | به‌روزرسانی هر پارامتر از توزیع شرطی کاملش |
| convergence | همگرایی | رسیدن زنجیره‌ها به توزیع هدف |
| parameter | پارامتر | کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند |
| estimator / estimate | برآورد / برآوردگر | مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن |
| Markov chain Monte Carlo (MCMC) | زنجیره‌ی مارکوف Monte Carlo | نمونه‌گیری از پسین با یک زنجیره‌ی تصادفی |
| response time (RT) | زمان واکنش | فاصله‌ی ارائه‌ی محرک تا پاسخ |
| forgetting curve | منحنی فراموشی | کاهش یادآوری با گذشت زمان |
| Metropolis algorithm | الگوریتم Metropolis | پیشنهاد یک حرکت و پذیرش یا رد آن |
| sampler | نمونه‌گیر (sampler) | الگوریتمی که از توزیع نمونه می‌گیرد |

| English | فارسی | توضیح کوتاه |
|---|---|---|
| full conditional | توزیع شرطی کامل (full conditional) | توزیع یک پارامتر به شرط بقیه و داده |
| conjugate prior | پیشین مزدوج (conjugate) | پیشینی که پسین هم‌خانواده می‌دهد |
| R-hat | R-hat | مقایسه‌ی واریانس بین و درون زنجیره‌ها؛ باید $\approx 1$ باشد |
| effective sample size (ESS) | اندازه‌ی مؤثر نمونه (ESS) | تعداد نمونه‌ی مستقل هم‌ارز |
| chain | زنجیره | دنباله‌ی نمونه‌های MCMC |
| trace plot | نمودار trace | مقدار نمونه‌ها در برابر شماره‌ی تکرار |
| Monte Carlo | Monte Carlo (مونت‌کارلو) | تقریب با میانگین نمونه‌های تصادفی |
| proposal | پیشنهاد (proposal) | مقدار جدیدی که الگوریتم امتحان می‌کند |
| posterior | توزیع پسین (posterior) | باور درباره‌ی پارامتر بعد از دیدن داده |
| MCSE | خطای استاندارد Monte Carlo | خطای شبیه‌سازی در میانگین پسین |
| prior | توزیع پیشین (prior) | باور درباره‌ی پارامتر پیش از دیدن داده |
| NUTS / HMC | Hamiltonian Monte Carlo / NUTS | MCMC مبتنی بر گرادیان |
| warm-up / burn-in | دوره‌ی گرم‌شدن (burn-in) | نمونه‌های اولیه که دور ریخته می‌شوند |
| autocorrelation | خودهمبستگی | وابستگی نمونه‌های پشت سر هم |
| sensitivity (d′) | حساسیت | فاصله‌ی توزیع علامت و نویز |

---

### ۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. full conditionalها یک مدل نرمال semi-conjugate را **استخراج کنند** و یک نمونه‌گیر Gibbs را از صفر **پیاده‌سازی کنند**.
۲. **توضیح دهند** که نمونه‌گیری Gibbs کی کاراست و کی کند مخلوط می‌شود (پارامترهای همبسته)، و Metropolis-within-Gibbs چطور full conditionalهای non-conjugate را مدیریت می‌کند.
۳. $\hat{R}$-split و اندازه‌ی مؤثر نمونه (ESS) را **پیاده‌سازی کنند** و با ArviZ **بررسی کنند**.
۴. عدم همگرایی را از روی چند زنجیره با trace plot، $\hat{R}$، ESS و خطای استاندارد Monte Carlo **تشخیص دهند**.
۵. یک چک‌لیست گزارش‌دهی برای نتایج MCMC را **به کار ببرند**.

---

### ۳.۱.۱ مقدمه

نمونه‌گیر Metropolis هفته‌ی قبل یک پیچ تنظیم داشت، یعنی انحراف معیار پیشنهادی، و یک سؤال آزاردهنده: از کجا بدانیم زنجیره همگرا شده است؟ این هفته به هر دو نگرانی جواب می‌دهد.

**نمونه‌گیری** Gibbs مسئله‌ی تنظیم را برای دسته‌ی بزرگ و مهمی از مدل‌ها حذف می‌کند. به‌جای پیشنهاد یک پرش برای همه‌ی پارامترها و گاهی رد آن، هر بار **یک پارامتر** را به‌روز می‌کند و آن را دقیقاً از توزیعش به شرط مقادیر فعلی همه‌ی پارامترهای دیگر می‌کشد. هر نمونه‌ای پذیرفته می‌شود. بسیاری از برنامه‌های کلاسیک بیزی (BUGS، JAGS، که در سراسر کتاب‌های Lee & Wagenmakers و Kruschke استفاده می‌شوند) بر همین ایده ساخته شده‌اند.

**تشخیص همگرایی** بخش صادقانه‌ی MCMC است. یک زنجیره فقط وقتی مفید است که (الف) نقطه‌ی شروعش را فراموش کرده باشد و (ب) کل پسین را کاوش کرده باشد، و هیچ چیزی در یک زنجیره‌ی تنها هیچ‌کدام را ثابت نمی‌کند. راه‌حل استاندارد اجرای **چند زنجیره از نقاط شروع مختلف** و بررسی توافق آن‌هاست. $\hat{R}$ این را کمّی می‌کند که «آیا زنجیره‌ها توافق دارند؟»، و ESS این را که «نمونه‌های همبسته چقدر اطلاعات مستقل دارند؟». هیچ نتیجه‌ی MCMC نباید بدون این‌ها گزارش شود.

#### این موضوع کجا به کار می‌رود؟

- **هر تحلیل MCMC منتشرشده** باید شاخص‌های همگرایی را گزارش کند؛ داوران در روان‌شناسی و علوم اعصاب امروز به‌طور معمول $\hat{R}$ و ESS را می‌خواهند.
- **نمونه‌گیری** Gibbs پایه‌ی برنامه‌های بیزی کلاسیک BUGS و JAGS است که در بسیاری از کتاب‌های درسی مدل‌سازی شناختی (Lee & Wagenmakers، Kruschke) و در پژوهش‌های بوم‌شناسی، همه‌گیرشناسی و آموزش استفاده می‌شوند.
- **پردازش تصویر و مخابرات:** نمونه‌گیرهای Gibbs برای بازسازی تصویر و برای آشکارسازی در گیرنده‌های چندآنتنی (MIMO) به کار رفته‌اند.
- **مدل‌های موضوعی** (topic models) برای پیدا کردن موضوع‌ها در مجموعه‌های بزرگ متن، به‌طور کلاسیک با نمونه‌گیری Gibbs برازش می‌شدند.

---

### ۴.۱.۱ جزوه‌ی درس

**به زبان ساده** Metropolis به یک اندازه‌ی گام خوب‌انتخاب‌شده نیاز دارد. **نمونه‌گیری** Gibbs برای بسیاری از مدل‌ها از این مشکل دوری می‌کند، چون **هر بار یک پارامتر** را به‌روز می‌کند: همه‌ی پارامترهای دیگر را روی مقدار فعلی‌شان ثابت نگه دار و پارامتر انتخاب‌شده را مستقیم از توزیع دقیقش در همان شرایط بکش (full conditional آن). بعد سراغ پارامتر بعدی برو و همین‌طور ادامه بده. هیچ‌وقت چیزی رد نمی‌شود. نیمه‌ی دوم هفته به این سؤال ناخوشایند جواب می‌دهد: «آیا نمونه‌گیر من واقعاً کار کرده؟» **چند زنجیره** را از نقطه‌های شروع خیلی متفاوت اجرا می‌کنیم. اگر همه به توصیف یک توزیع برسند، شاهد خوبی برای همگرایی است؛ $\hat{R}$ («R-hat») یک عدد است که می‌سنجد زنجیره‌ها با هم توافق دارند یا نه (باید کمتر از ۱.۰۱ باشد). چون نمونه‌های پشت سر هم همبسته‌اند، ۴،۰۰۰ نمونه ممکن است فقط اطلاعات مثلاً ۱،۰۰۰ نمونه‌ی مستقل را داشته باشند: این عدد **اندازه‌ی مؤثر نمونه** (ESS) است و می‌گوید میانگین‌های ما چقدر دقیق‌اند.

**زمان‌بندی پیشنهادی (۶۰ دقیقه):** نمونه‌گیری Gibbs ۲۰ · وقتی Gibbs به زحمت می‌افتد ۵ · همگرایی و چند زنجیره $\hat{R}$ ۸ · ESS ۱۰ · و MCSE ۱۰ · چک‌لیست گزارش‌دهی ۷.

### ۱. نمونه‌گیری Gibbs

برای پارامترهای $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_k)$، full conditional $\theta_m$ پسین آن به شرط داده و همه‌ی پارامترهای دیگر است، $p(\theta_m \mid \boldsymbol{\theta}_{-m}, \mathbf{y})$. نمونه‌گیری Gibbs بین آن‌ها می‌چرخد:

۱. از $\boldsymbol{\theta}^{(0)}$ شروع کنید.
۲. برای $s = 1, \ldots, S$:

- بکشید $\theta_1^{(s)} \sim p(\theta_1 \mid \theta_2^{(s-1)}, \ldots, \theta_k^{(s-1)}, \mathbf{y})$
- بکشید $\theta_2^{(s)} \sim p(\theta_2 \mid \theta_1^{(s)}, \theta_3^{(s-1)}, \ldots, \mathbf{y})$
- … (همیشه با جدیدترین مقادیر)
- بکشید $\theta_k^{(s)} \sim p(\theta_k \mid \theta_1^{(s)}, \ldots, \theta_{k-1}^{(s)}, \mathbf{y})$

این حالت خاصی از Metropolis–Hastings است که در آن پیشنهاد خود full conditional است، پس احتمال پذیرش همیشه ۱ است.

**پیدا کردن fullهای conditional.** چگالی مشترک $p(\mathbf{y} \mid \boldsymbol{\theta})\, p(\boldsymbol{\theta})$ را بنویسید، فقط ضرایبی را که $\theta_m$ دارند نگه دارید، و یک توزیع شناخته‌شده را تشخیص دهید. این وقتی کار می‌کند که پیشین‌ها (به‌طور شرطی) conjugate باشند.

**مثال: یک مدل نرمال برای لگاریتم زمان واکنش.** فرض کنید $y_i$ لگاریتم زمان‌های واکنش باشند، $y_i \sim \mathcal{N}(\mu, 1/\sqrt{\tau})$، که در آن $\tau = 1/\sigma^2$ **دقت** (precision) است. پیشین‌ها: $\mu \sim \mathcal{N}(m_0, s_0)$ و $\tau \sim \text{Gamma}(a_0, \text{rate } b_0)$، مستقل. آن‌وقت:

$$\mu \mid \tau, \mathbf{y} \sim \mathcal{N}\left( \frac{m_0/s_0^2 + \tau \sum_i y_i}{1/s_0^2 + N\tau},\ \frac{1}{\sqrt{1/s_0^2 + N\tau}} \right),$$

$$\tau \mid \mu, \mathbf{y} \sim \text{Gamma}\left( a_0 + \frac{N}{2},\ \text{rate} = b_0 + \frac{1}{2}\sum_i (y_i - \mu)^2 \right).$$

**خواندن فرمول‌ها.** میانگین شرطی $\mu$ میانگین وزنی (با وزن دقت) میانگین پیشین و میانگین داده است (مثل beta-binomial هفته‌ی ۹). توزیع شرطی $\tau$ برای هر نقطه‌ی داده نیم مشاهده به پارامتر شکل و نیم مربع باقی‌مانده به rate اضافه می‌کند.

> **نکته درباره‌ی پارامترسازی‌ها.** `rng.gamma(shape, scale)` در NumPy از 1/rate = scale استفاده می‌کند. قاطی کردن rate و scale رایج‌ترین باگ در نمونه‌گیرهای Gibbs است.

#### خواندن ریاضی

- $\boldsymbol{\theta}_{-m}$: «همه‌ی پارامترها به‌جز $\theta_m$».
- **دقت** (precision) $\tau = 1/\sigma^2$: معکوس واریانس. دقت زیاد = نویز کم. کار کردن با دقت‌ها ترکیب اطلاعات را به یک جمع ساده تبدیل می‌کند.
- **به‌روزرسانی $\mu$:** میانگین شرطی $\dfrac{m_0/s_0^2 + \tau \sum y_i}{1/s_0^2 + N\tau}$ میانگین وزنی میانگین prior یعنی $m_0$ (با وزن $1/s_0^2$، دقت prior) و میانگین داده (با وزن کل $N\tau$، دقت داده) است. دقت شرطی جمع این دو دقت است. مثال حل‌شده: $1 + 4 \times 10 = 41$، پس داده غالب است.
- **به‌روزرسانی $\tau$:** یک توزیع Gamma که shape آن برای هر مشاهده $1/2$ و rate آن به اندازه‌ی نصف هر مربع باقی‌مانده بزرگ می‌شود. میانگین آن، shape/rate، تقریباً «۱ / (میانگین مربع باقی‌مانده)» است، یعنی همان دقتی که داده نشان می‌دهد.

### ۲. وقتی Gibbs به زحمت می‌افتد، و Metropolis-within-Gibbs

- **همبستگی‌های قوی پسین.** Gibbs موازی با محورهای مختصات حرکت می‌کند. اگر پسین یک ridge باریک مورب باشد (مثل $A$–$d$ trade-off مدل توانی)، هر گام فقط فاصله‌ی ریزی می‌تواند حرکت کند و زنجیره آرام در امتداد ridge زیگزاگ می‌زند. راه‌حل‌ها: reparameterization، به‌روزرسانی هم‌زمان پارامترهای همبسته («بلوک‌بندی»)، یا نمونه‌گیرهای گرادیانی (هفته‌ی ۱۳).
- **full conditionalهای non-conjugate.** بیشتر مدل‌های شناختی (منحنی‌های فراموشی، SDT، GCM) توزیع شرطی بسته ندارند. Metropolis-within-Gibbs هر پارامتر را با یک گام Metropolis یک‌بعدی که full conditionalش را هدف می‌گیرد به‌روز می‌کند، و هر جا ممکن باشد از نمونه‌های دقیق Gibbs استفاده می‌کند.

> **پیشرفته:** JAGS و BUGS برای هر پارامتر خودکار یک نمونه‌گیر انتخاب می‌کنند (Gibbs conjugate، slice sampling، Metropolis تطبیقی)، و به همین دلیل روی تقریباً هر مدلی اجرا می‌شوند. Hamiltonian Monte Carlo امروزی (Stan)، NUTS در (PyMC در عوض از گرادیان لگاریتم پسین استفاده می‌کند تا همه‌ی پارامترها را هم‌زمان در امتداد هندسه‌ی پسین حرکت دهد، و پسین‌های همبسته را خیلی بهتر مدیریت می‌کند (هفته‌ی ۱۳).

### ۳. همگرایی: منطق چند زنجیره

یک زنجیره‌ی MCMC وقتی همگرا شده که نمونه‌هایش نماینده‌ی پسین باشند. دو حالت شکست: ۱. **هنوز ایستا نشده:** زنجیره هنوز بازتاب مقدار شروع است. ۲. **گیرکرده یا کند:** زنجیره فقط بخشی از پسین را کاوش می‌کند (مثلاً یکی از دو مُد، یا یک سر یک ridge طولانی).

هیچ‌کدام را نمی‌شود با اطمینان از یک زنجیره تشخیص داد، چون زنجیره‌ای که در یک ناحیه گیر کرده می‌تواند کاملاً پایدار به نظر برسد. $C \geq 4$ زنجیره از نقاط شروع **بیش‌پراکنده** (over-dispersed) اجرا کنید: اگر همه به توصیف همان توزیع برسند، این شاهد خوبی (هرچند هرگز قطعی نیست) برای همگرایی است.

trace plotهای همه‌ی زنجیره‌ها روی هم باید مثل یک «کرم پشمالوی» خوب مخلوط‌شده باشند، بدون زنجیره‌ای که آشکارا جدا افتاده یا روند دارد.

### ۴. ضریب کاهش مقیاس بالقوه $\hat{R}$

واریانس **بین** زنجیره‌ها را با واریانس **درون** زنجیره‌ها مقایسه کنید. با $C$ زنجیره به طول $S$ (بعد از burn-in)، میانگین زنجیره‌ها $\bar{\theta}_c$ و واریانس‌های درون‌زنجیره‌ای $s_c^2$:

$$W = \frac{1}{C}\sum_{c} s_c^2, \qquad B = \frac{S}{C-1}\sum_{c}(\bar{\theta}_c - \bar{\theta})^2, \qquad \widehat{\mathrm{var}}^{+} = \frac{S-1}{S}\,W + \frac{1}{S}\,B, \qquad \hat{R} = \sqrt{\frac{\widehat{\mathrm{var}}^{+}}{W}}.$$

اگر زنجیره‌ها مخلوط نشده باشند، $B$ نسبت به $W$ بزرگ است و $\hat{R} > 1$. با همگرا شدن زنجیره‌ها، $\hat{R} \to 1$.

- **Split-$\hat{R}$:** هر زنجیره را به نیمه‌ی اول و دوم تقسیم کنید و با آن‌ها مثل $2C$ زنجیره رفتار کنید. این کار زنجیره‌ی تنهایی را هم که هنوز در حال drift است تشخیص می‌دهد.
- **آستانه:** قاعده‌ی کلاسیک $\hat{R} < 1.1$ بود؛ توصیه‌های امروزی (Vehtari و همکاران، ۲۰۲۱) $\hat{R} < 1.01$ است که بعد از نرمال‌سازی رتبه‌ای (rank-normalization) حساب می‌شود (همان کاری که ArviZ می‌کند).

### ۵. اندازه‌ی مؤثر نمونه و خطای استاندارد Monte Carlo

نمونه‌های خودهمبسته اطلاعات کمتری از نمونه‌های مستقل دارند. **اندازه‌ی مؤثر نمونه** برابر است با

$$\mathrm{ESS} = \frac{C \cdot S}{1 + 2\sum_{h=1}^{\infty} \rho_h},$$

که در آن $\rho_h$ خودهمبستگی با تأخیر $h$ است که از همه‌ی زنجیره‌ها تخمین زده و وقتی تخمین‌ها نویز می‌شوند بریده می‌شود. ESS تعداد نمونه‌های مستقلی است که همان دقت را می‌دادند.

- **خطای استاندارد** Monte Carlo میانگین پسین برابر $\mathrm{MCSE} = \text{posterior SD}/\sqrt{\mathrm{ESS}}$ است. باید نسبت به دقتی که گزارش می‌کنید کوچک باشد (مثلاً اگر MCSE برابر ۰.۱۰ است ۳ رقم اعشار گزارش نکنید).
- **قاعده‌ی سرانگشتی:** bulk-ESS $\geq$ ۴۰۰ (با ۴ زنجیره) برای میانگین‌ها و بازه‌های پسین قابل اعتماد؛ tail-ESS $\geq$ ۴۰۰ برای quantileهای حدی قابل اعتماد.

#### خواندن ریاضی

- $\hat{R}$: $W$ میانگین واریانس درون هر زنجیره است؛ $B$ می‌سنجد میانگین‌های زنجیره‌ها چقدر از هم دورند. $\widehat{\mathrm{var}}^{+}$ تخمینی از کل واریانس posterior است که اختلاف بین زنجیره‌ها را هم در بر دارد. اگر زنجیره‌ها توافق داشته باشند، $B$ تقریباً چیزی اضافه نمی‌کند و $\hat{R} = \sqrt{\widehat{\mathrm{var}}^{+}/W} \approx 1$. در مثال حل‌شده‌ی «همگرا نشده»، دو زنجیره حول ۰.۱ و ۰.۲ هستند، $B$ خیلی بزرگ است و $\hat{R} = 4.4$.
- ESS: $C \cdot S$ کل تعداد نمونه‌هاست؛ مخرج $1 + 2\sum \rho_h$ برای نمونه‌های همبسته بزرگ می‌شود. با $\rho_h = 0.5^h$ جمع برابر $0.5 + 0.25 + \cdots = 1$ است، پس نمونه‌ها فقط یک‌سوم حساب می‌شوند: ۴،۰۰۰ نمونه ارزش ۱،۳۳۳ نمونه‌ی مستقل را دارند.
- MCSE $= \text{posterior SD}/\sqrt{\mathrm{ESS}}$ خطای شبیه‌سازی میانگین گزارش‌شده است؛ تعداد رقم‌های اعشار را از روی آن تصمیم بگیرید.

### ۶. چک‌لیست گزارش‌دهی MCMC

۱. نمونه‌گیر، تعداد زنجیره‌ها، تکرارها، burn-in (warm-up) و هر thinning.
۲. مقادیر شروع (پراکنده؟).
۳. $\hat{R}$ (کدام نسخه) و ESS برای **همه‌ی** پارامترهای گزارش‌شده، به‌علاوه‌ی بیشترین $\hat{R}$ و کمترین ESS.
۴. trace plotها (در پیوست) و جمله‌ای که نشان دهد بررسی شده‌اند.
۵. پیشین‌ها، و خلاصه‌های پسین با دقتی متناسب با MCSE.
۶. یک بررسی پیش‌بینی پسین (هفته‌ی ۱۰).

#### برای یک مهندس

- **میانگین‌گیری وزن‌دار با دقت** در به‌روزرسانی $\mu$ همان قاعده‌ی **ترکیب با نسبت بیشینه** (MRC) یا گام به‌روزرسانی اندازه‌گیری در فیلتر کالمن است: تخمین‌ها را به نسبت معکوس واریانس نویزشان ترکیب کن.
- **نمونه‌گیری** Gibbs هر بار یک متغیر را به شرط بقیه به‌روز می‌کند؛ مثل الگوریتم‌های تکراری مختصات‌به‌مختصات (بهینه‌سازی متناوب) و تبادل تکراری اطلاعات شرطی در گیرنده‌های از نوع turbo. نمونه‌گیرهای Gibbs برای آشکارسازی MIMO هم پیشنهاد شده‌اند.

- $\hat{R}$ یک ANOVA یک‌طرفه (واریانس بین گروه‌ها در برابر درون گروه‌ها) روی اجراهای مستقل شبیه‌سازی است: همان بررسی‌ای که با اجرای یک شبیه‌سازی Monte Carlo با چند seed مختلف و وارسی توافق اجراها انجام می‌دهید.
- ESS $= N/(1+2\sum \rho_h)$ فرمول استاندارد تعداد مؤثر نمونه‌های مستقل یک فرایند تصادفی همبسته است: میانگین گرفتن از $N$ نمونه‌ی همبسته واریانس را فقط به اندازه‌ی میانگین گرفتن از ESS نمونه‌ی مستقل کم می‌کند (مرتبط با زمان همبستگی).

**برای مدرس**

- **Gibbs را روی یک نمودار تراز رسم کنید.** دو پارامتر، یک posterior بیضوی. Gibbs فقط با گام‌های افقی و عمودی حرکت می‌کند (یک پلکان). بعد یک بیضی مورب باریک بکشید: گام‌های پلکان خیلی ریز می‌شوند. همین یک تصویر هم نحوه‌ی کار Gibbs و هم زمان به زحمت افتادنش را توضیح می‌دهد.
- **$\hat{R}$ را اول تصویری کنید:** چهار trace plot را روی هم بکشید، یک بار با زنجیره‌هایی که توافق دارند و یک بار با یک زنجیره که جای دیگری گیر کرده. پیش از نشان دادن هر فرمولی بپرسید «آیا این زنجیره‌ها یک توزیع را توصیف می‌کنند؟»
- **چک‌لیست گزارش را به‌عنوان یک عادت درس دهید.** از دانشجوها بخواهید آن را روی پروژه‌شان و روی هر نتیجه‌ی MCMC در lab اعمال کنند.
- **سؤال‌های رایج.**
  - «$\hat{R}$ برابر ۱.۰۰ است، پس مدلم درست است؟» نه. $\hat{R}$ فقط بررسی می‌کند که زنجیره‌ها توافق دارند؛ مدل هنوز می‌تواند غلط باشد (با PPC بررسی کنید) یا کد هنوز می‌تواند باگ داشته باشد.
  - «زنجیره‌ها را *thin* کنم؟» برای درستی لازم نیست؛ فقط حافظه را صرفه‌جویی می‌کند.
  - «*rate* یا *scale*؟» توزیع Gamma در NumPy از scale = 1/rate استفاده می‌کند؛ رایج‌ترین باگ در نمونه‌گیرهای Gibbs دانشجوها.

---

### ۵.۱.۱ مثال حل‌شده

**بخش ۱: یک تکرار Gibbs با دست**

داده: $N=4$ لگاریتم زمان واکنش، $\mathbf{y}=(6.0,6.3,6.1,6.4)$، پس $\sum y_i = 24.8$. پیشین‌ها: $m_0=6$، $s_0=1$، $a_0=2$، $b_0=0.1$. مقادیر فعلی: $\mu=6.0$، $\tau=10$.

**به‌روزرسانی $\mu$.** دقت $=1/1^2+4\times10=41$؛ میانگین $=(6/1+10\times24.8)/41=(6+248)/41=6.195$؛ انحراف معیار $=1/\sqrt{41}=0.156$. مثلاً $\mu=6.22$ کشیده می‌شود.

**به‌روزرسانی $\tau$** با $\mu=6.22$. مربع باقی‌مانده‌ها: $0.0484+0.0064+0.0144+0.0324=0.1016$. شکل $=2+4/2=4$؛ rate $=0.1+0.1016/2=0.1508$. میانگین شرطی $\tau$ برابر $4/0.1508=26.5$ است (یعنی $\sigma\approx0.19$). مثلاً $\tau=24.1$ کشیده می‌شود.

حالت جدید: $(\mu,\tau)=(6.22,24.1)$. هیچ گام پذیرش/ردی لازم نبود.

**بخش ۲: $\hat{R}$ با دست**

دو زنجیره، هرکدام $S=4$ نمونه.

**همگرا نشده.** زنجیره‌ی ۱: (۶.۱، ۶.۳، ۶.۰، ۶.۱)؛ زنجیره‌ی ۲: (۶.۲، ۶.۲، ۶.۱، ۶.۲). - میانگین زنجیره‌ها: ۶.۱ و ۶.۲. واریانس‌های درون‌زنجیره‌ای (ddof = ۱): هر دو $0.08/3=0.0267$، پس $W=0.0267$. - $B=S\times\mathrm{var}(\text{means})=4\times0.5=2.0$. - $\widehat{\mathrm{var}}^{+}=\frac{3}{4}\times0.0267+\frac{1}{4}\times2.0=0.520$ - $\hat{R}=\sqrt{0.520/0.0267}=4.4$. زنجیره‌ها به‌وضوح با هم مخالف‌اند.

**همگرا شده (با اعداد واقع‌بینانه).** $S = 1000$ نمونه در هر زنجیره، $W = 0.05$، میانگین زنجیره‌ها ۱.۰۰ و ۱.۰۲: $B = 1000 \times \text{var}(1.00, 1.02) = 1000 \times 0.0002 = 0.2$؛ $\widehat{\text{var}}^{+} = 0.999 \times 0.05 + 0.2/1000 = 0.05015$؛ $\hat{R} = \sqrt{0.05015/0.05} = 1.0015$. کمتر از ۱.۱: خوب است.

### بخش ۳: ESS با دست

$C \cdot S = 4000$ نمونه با خودهمبستگی‌های $\rho_h = 0.5^h$. آن‌وقت $\sum_{h \geq 1} \rho_h = 1$، پس $\text{ESS} = 4000/(1+2) = 1333$.

با انحراف معیار پسین ۲.۰، $\text{MCSE} = 0.2/\sqrt{1333} = 0.0055$ ≈ میانگین پسین را با دو رقم اعشار گزارش کنید.

---

## ۶.۱.۱ lab (۲ ساعت)

### اهداف

۱. پیاده‌سازی یک نمونه‌گیر Gibbs برای مدل نرمال لگاریتم زمان واکنش و اعتبارسنجی آن با یک پسین شبکه‌ای.
۲. اجرای چهار زنجیره‌ی پراکنده و وارسی آن‌ها.
۳. پیاده‌سازی $\hat{R}$-split و ESS؛ مقایسه با ArviZ.
۴. خراب کردن عمدی همگرایی (مدل توانی با یک نمونه‌گیر Metropolis بد) و دیدن اینکه تشخیص‌ها آن را می‌گیرند.

**زمان‌بندی:** بخش A ۳۰ دقیقه · بخش B ۱۵ دقیقه · بخش C ۳۰ دقیقه · بخش D ۳۰ دقیقه · بخش E ۱۵ دقیقه.

### آماده‌سازی

> Code · **کد:** `code/week12.py`، cell ۱ · سلول ۱

### بخش A: یک نمونه‌گیر Gibbs (۳۰ دقیقه)

> Code · **کد:** `code/week12.py`، cell ۲ · سلول ۲

**خروجی مورد انتظار:**

```
N = 40, sample mean = 6.200, sample SD = 0.225
Gibbs: mu = 6.1994 (SD 0.0358), sigma = 0.2283 (SD 0.0255)
Grid:  mu = 6.1996, sigma = 0.2287
```

### بخش B: چهار زنجیره‌ی پراکنده (۱۵ دقیقه)

**کد** · Code · سلول ۳ · cell ۳، `code/week12.py`

**خروجی مورد انتظار:**

```
Chain means of mu: [6.2006 6.1988 6.1996 6.1992]
```

اینجا Gibbs حتی مقادیر شروع پوچ را در چند تکرار فراموش می‌کند، چون $\mu$ و $\tau$ در این پسین تقریباً ناهمبسته‌اند.

### بخش C: $\hat{R}$ و ESS از صفر، بررسی‌شده با ArviZ (۳۰ دقیقه)

**کد** · Code · سلول ۴ · cell ۴، `code/week12.py`

**خروجی مورد انتظار:**

```
       R-hat (ours)  R-hat (ArviZ)  ESS (ours)  bulk-ESS (ArviZ)  MCSE
        ↪  of mean
param
mu           1.0002         1.0004   9980.4260        10032.6243
 ↪  0.0004
sigma        0.9997         0.9998   8772.9605         8861.7940
 ↪  0.0003
      ess_bulk ess_tail  r_hat  mcse_mean  mcse_sd
mu       10032     9427   1.00    0.00036  0.00027
sigma     8861     9714   1.00    0.00027  0.00021
```

(چیدمان دقیق ستون‌های `az.summary` بین نسخه‌های ArviZ کمی فرق دارد؛ خروجی بالا از ArviZ 1.x است.) برآوردگرهای ساده‌ی ما با ArviZ خیلی نزدیک‌اند. با ۴ × ۲۵۰۰ = ۱۰ ۰۰۰ نمونه، ESS ≈ ۹۰۰۰ تا ۱۰ ۰۰۰ یعنی نمونه‌های Gibbs تقریباً مستقل‌اند. ArviZ علاوه بر این نمونه‌ها را **نرمال‌سازی رتبه‌ای** می‌کند Vehtari) و همکاران، ۲۰۲۱)، که $\hat{R}$ و bulk-ESS آن را در برابر دنباله‌های سنگین مقاوم می‌کند، پس تفاوت‌های کوچک قابل انتظار است. در عمل از ArviZ استفاده کنید؛ نکته‌ی امروز این است که بدانید چه چیزی حساب می‌کند.

### بخش D: گرفتن عدم همگرایی (۳۰ دقیقه)

نمونه‌گیر Metropolis هفته‌ی قبل را روی مدل فراموشی توانی دوباره به کار می‌بریم؛ یک بار بد تنظیم‌شده و کوتاه، یک بار خوب تنظیم‌شده.

**کد** · Code · سلول ۵ · cell ۵، `code/week12.py`

**خروجی مورد انتظار:**

```
bad (tiny steps, short)   split-R-hat(d) = 3.583, ArviZ R-hat(d) =
↪  3.424, ESS(d) = 4, chain means of d = [0.248 0.785 0.451 0.328]
good (tuned, longer)      split-R-hat(d) = 1.002, ArviZ R-hat(d) =
↪  1.002, ESS(d) = 1025, chain means of d = [0.414 0.414 0.415 0.413]
```

**به این دقت کنید:** با گام‌های ریز و زنجیره‌های کوتاه، هر زنجیره هنوز نزدیک جایی است که شروع کرده. traceها جدا از هم‌اند، $\hat{R}$ خیلی بالاتر از ۱.۰۱ است و ESS ناچیز است. هر زنجیره به‌تنهایی صاف و پایدار به نظر می‌رسد، و دقیقاً به همین دلیل یک زنجیره هرگز کافی نیست. نمونه‌گیر تنظیم‌شده traceهای روی هم افتاده، $\hat{R} = 1.002$ و ESS حدود ۱۰۰۰ از ۲۰ ۰۰۰ نمونه می‌دهد. نمونه‌گیر Gibbs بخش C، با نمونه‌های تقریباً ناهمبسته، از ۱۰ ۰۰۰ نمونه به ESS حدود ۹۰۰۰ تا ۱۰ ۰۰۰ رسید.

### بخش E: تفسیر و گزارش (۱۵ دقیقه)

یک پاراگراف روش‌ها و نتایج MCMC برای مدل لگاریتم زمان واکنش، طبق چک‌لیست بخش ۶ جزوه، بنویسید: نمونه‌گیر، زنجیره‌ها، تکرارها، burn-in، مقادیر شروع، $\hat{R}$، ESS، میانگین‌های پسین و بازه‌های ۹۵٪ $\mu$ و $\sigma$ (با $e^{\mu}$ مقدار $\mu$ را به میلی‌ثانیه برگردانید و بگویید نماینده‌ی چیست).

### تمرین‌ها (به ترتیب سختی)

**تمرین ۱** ⋆. به‌صورت جبری نشان دهید که full conditional $\tau$ یک توزیع Gamma است: $p(\tau \mid \mu, \mathbf{y}) \propto \tau^{N/2} \exp(-\frac{\tau}{2}\sum(y_i-\mu)^2) \cdot \tau^{a_0-1}e^{-b_0\tau}$ را بنویسید و شکل و rate را بخوانید.

**تمرین ۲** ⋆. باگ rate/scale را (`scale=B0+...` به‌جای `1/(...)`) وارد `gibbs_normal` کنید. آیا تشخیص‌ها آن را می‌گیرند؟ اعتبارسنجی با شبکه چطور؟ این درباره‌ی تفاوت همگرایی و درستی چه می‌گوید؟

**تمرین ۳** ⋆⋆ (Gibbs **همبسته**). یک نمونه‌گیر Gibbs برای یک «پسین» نرمال دومتغیره با همبستگی $\rho$ بنویسید (full conditionalها: $\theta_1 \mid \theta_2 \sim \mathcal{N}(\rho\theta_2, \sqrt{1-\rho^2})$ و برعکس). ESS را برای $\rho = 0, 0.9, 0.99$ با ۵۰۰۰ تکرار مقایسه کنید و مسیر زیگزاگ را برای $\rho = 0.99$ رسم کنید.

**تمرین ۴** ⋆⋆ (Metropolis-within-Gibbs). از مدل فراموشی توانی با به‌روزرسانی $A$ و $d$ **یکی‌یکی**، هرکدام با یک گام Metropolis یک‌بعدی، نمونه بگیرید. ESS در هر ثانیه را با نمونه‌گیر Metropolis مشترک مقایسه کنید. چرا ممکن است اینجا بدتر باشد؟ (راهنمایی: همبستگی $A$–$d$.)

**تمرین ۵** ⋆⋆⋆ **(پیشرفته: دو شرط).** نمونه‌گیر Gibbs را برای لگاریتم زمان واکنش در دو شرط با میانگین‌های جداگانه‌ی $\mu_1, \mu_2$ و دقت مشترک $\tau$ گسترش دهید. داده‌ای با تفاوت واقعی ۱۰ شبیه‌سازی کنید، نمونه بگیرید، و پسین $\mu_2 - \mu_1$ و $P(\mu_2 > \mu_1 \mid \mathbf{y})$ را با تشخیص‌ها گزارش کنید.

### lab check-off

نشان دهید: (۱) اعتبارسنجی Gibbs در برابر شبکه (بخش A)، (۲) جدول $\hat{R}$/ESS خودتان کنار جدول ArviZ (بخش C)، و (۳) trace plotهای بد در برابر خوب با تشخیص‌هایشان (بخش D).

---

### ۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

**نمونه‌گیری Gibbs از یک مدل زبانی.** masked مدل‌هایی مثل BERT آموزش می‌بینند که یک کلمه‌ی پوشانده‌شده (masked) را با توجه به همه‌ی کلمه‌های دیگر پر کنند: آن‌ها full conditionalها ($P(w_i \mid \text{all other words})$) را یاد می‌گیرند. این دقیقاً چیزی است که یک نمونه‌گیر Gibbs لازم دارد. پوشاندن مکرر یک موقعیت و نمونه‌گیری دوباره‌ی آن، جمله‌های کامل تولید می‌کند (Wang & Cho, ۲۰۱۹). مدل اسباب‌بازی پایین فقط دو full conditional یک «زبان» دوکلمه‌ای را می‌داند، و نمونه‌گیری Gibbs توزیع توأم جمله‌ها را بازیابی می‌کند. چون این زبان «چسبناک» است (dog با barks می‌آید، cat با meows)، زنجیره کند مخلوط می‌شود، و $\hat{R}$ این را در اجراهای کوتاه تشخیص می‌دهد.

> **Code · کد:** `code/week12.py`، cell ۶ · سلول ۶

**خروجی مورد انتظار:**

```
  50 iterations: P(subject = dog) = 0.285 (exact 0.35), R-hat = 1.151
3000 iterations: P(subject = dog) = 0.354 (exact 0.35), R-hat = 1.000
```

**امتحانش کنید (بدون نیاز به API).** ⋆ – زبان را باز هم چسبناک‌تر کنید (مثلاً ۳۳.۰ روی قطر و ۰۰۱.۰ در بقیه، دوباره نرمال‌شده). حالا برای $\hat{R} < 1.01$ به چند تکرار نیاز دارید؟ ESS زنجیره‌های `is_dog` را حساب کنید (هفته‌ی ۱۲، بخش C). ⋆⋆ – مدل‌های masked واقعی برای هر موقعیت جداگانه آموزش می‌بینند، پس لازم نیست توزیع‌های شرطی‌شان از یک توزیع توأم واحد آمده باشند. `p_v_given_s` را کمی دست‌کاری کنید (بدون تغییر `p_s_given_v`) و بررسی کنید آیا نمونه‌گیر Gibbs هنوز `joint` را بازیابی می‌کند. این درباره‌ی اعتماد به نمونه‌گیری که توزیع‌های شرطی‌اش یادگرفته‌شده‌اند چه می‌گوید؟

مطالعه‌ی اختیاری: Cho, K. & Wang, A., (۲۰۱۹). BERT has a mouth, and it must speak: BERT as a Markov random field language model. *arXiv:1902.04094*.

---

### ۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **rate در برابر scale در توزیع Gamma.** NumPy و SciPy از scale = 1/rate استفاده می‌کنند. بنویسید فرمولتان از کدام استفاده می‌کند.

۲. **استفاده از مقادیر قدیمی داخل یک دور Gibbs.** هر توزیع شرطی باید از جدیدترین مقادیر پارامترهای دیگر استفاده کند.

۳. **«$\hat{R} \approx 1$، پس نتایج درست‌اند.»** تشخیص‌ها توافق بین زنجیره‌ها را آزمون می‌کنند، نه درستی مدل یا کد را (تمرین ۲). نمونه‌گیرهای جدید را روی حالت‌های معلوم اعتبارسنجی کنید.

۴. **یک زنجیره‌ی بلند به‌جای چند زنجیره.** زنجیره‌ی گیرکرده می‌تواند کاملاً پایدار به نظر برسد. از $\geq 4$ زنجیره‌ی پراکنده استفاده کنید.

۵. **گزارش نتایج با ESS پایین.** با ESS = ۵۰، MCSE میانگین پسین حدود ٪۱۴ انحراف معیار پسین است و quantileهای دنباله غیرقابل اعتمادند.

۶. **thinning برای «درست کردن» خودهمبستگی.** thinning حافظه را کم می‌کند ولی اطلاعات را زیاد نمی‌کند. ESS خودش خودهمبستگی را در نظر می‌گیرد.

۷. **استفاده‌ی بی‌چون‌وچرا از آستانه‌ی ۱.۱.** راهنمایی امروزی $\hat{R} < 1.01$ با $\hat{R}$-split نرمال‌شده‌ی رتبه‌ای است.

۸. **تشخیص فقط برای بعضی پارامترها.** همه‌ی پارامترهای گزارش‌شده، از جمله مشتق‌شده‌ها، را بررسی کنید.

---

### ۹.۱.۱ خودآزمایی

**۱.** چرا نمونه‌گیری Gibbs هیچ‌وقت یک نمونه را رد نمی‌کند؟ **پاسخ** هر نمونه دقیقاً از full conditional می‌آید. اگر آن را Metropolis–Hastings با full conditional به‌عنوان پیشنهاد ببینیم، نسبت پذیرش همیشه ۱ است.

**۲.** برای اجرای یک نمونه‌گیر Gibbs خالص به چه چیزی نیاز دارید؟ **پاسخ** full conditionalها برای هر پارامتر (یا بلوک) که بتوانید مستقیماً از آن‌ها نمونه بگیرید؛ معمولاً چون پیشین‌ها به‌طور شرطی conjugate هستند.

**۳.** یک نمونه‌گیر Gibbs برای دو پارامتر به‌شدت همبسته ESS خیلی پایینی دارد. چرا، و چه می‌توانید بکنید؟ **پاسخ** Gibbs هر بار یک مختصه را به‌روز می‌کند، پس روی یک ridge باریک مورب هر گام ریز است و زنجیره آرام زیگزاگ می‌زند. راه‌حل‌ها: reparameterization برای کم کردن همبستگی، به‌روزرسانی هم‌زمان پارامترهای همبسته (بلوک‌بندی)، یا استفاده از HMC/NUTS.

**۴.** $\hat{R}$ را در یک جمله توضیح دهید. کدام مقدار نشانه‌ی همگرایی است؟ **پاسخ** واریانس بین زنجیره‌ها را با واریانس درون زنجیره‌ها مقایسه می‌کند (تخمین می‌زند اگر زنجیره‌ها تا ابد اجرا می‌شدند پراکندگی پسین چقدر می‌توانست کم شود)؛ مقادیر نزدیک ۱ (طبق راهنمایی امروزی $< ۱.۰۱$) یعنی زنجیره‌ها توافق دارند.

**۵.** ۴۰۰۰ نمونه و ESS برابر ۲۰۰ برای پارامتری با انحراف معیار پسین ۰.۵ دارید. MCSE میانگین پسینش چقدر است؟ چند رقم اعشار باید گزارش کنید؟ **پاسخ** $\text{MCSE} = 0.5/\sqrt{200} = 0.035$. میانگین را با یک رقم اعشار (یا حداکثر دو) گزارش کنید، چون رقم سوم نویز Monte Carlo است.

**۶.** چرا یک زنجیره نمی‌تواند همگرایی را نشان دهد؟ **پاسخ** زنجیره‌ای که در یک ناحیه گیر کرده (یک مُد، یا بخشی از یک ridge) می‌تواند ایستا و خوب مخلوط‌شده به نظر برسد، و هیچ چیزی در خود زنجیره نواحی کاوش‌نشده را آشکار نمی‌کند. فقط زنجیره‌هایی که از جای دیگری شروع شده و به جای دیگری رسیده‌اند مشکل را لو می‌دهند.

**۷.** چهار چیزی را که بخش روش‌ها باید درباره‌ی یک تحلیل MCMC گزارش کند نام ببرید. **پاسخ** هر چهار مورد از این‌ها: نمونه‌گیر/نرم‌افزار؛ تعداد زنجیره‌ها؛ تکرارها و warm-up؛ مقادیر شروع؛ $\hat{R}$ و ESS برای همه‌ی پارامترها؛ اینکه trace plotها بررسی شده‌اند؛ پیشین‌ها؛ یک بررسی پیش‌بینی پسین.

---

### ۱۰.۱.۱ تکلیف

**A5: MCMC از صفر، همراه با تشخیص همگرایی (۱۰.۰ نمره از ۲۰؛ انتشار هفته‌ی ۱۲، موعد ابتدای درس هفته‌ی ۱۴)**

**داده:** آزمایش SDT پاداش از بخش D هفته‌ی ۴ (با همان seed بازتولیدش کنید: `np.random.default_rng(11)`) و داده‌ی لگاریتم زمان واکنش lab امروز (`np.random.default_rng(12)`).

**کارها.**

۱. Metropolis **برای SDT (۳ امتیاز).** یک نمونه‌گیر Metropolis گام تصادفی برای مدل پاداش با $d'$ مشترک ($d'$، $c_1, c_2, c_3$) با پیشین‌های $d' \sim \mathcal{N}(1, 1.5)$ و $c_m \sim \mathcal{N}(0, 1)$ پیاده‌سازی کنید. پیشنهاد را تنظیم کنید (نرخ پذیرش را گزارش کنید) و ۴ زنجیره‌ی پراکنده اجرا کنید.

۲. **تشخیص همگرایی (۲ امتیاز).** $\hat{R}$split- و ESS را برای همه‌ی پارامترها با توابع خودتان و با ArviZ گزارش کنید؛ trace plotها را نشان دهید. بگویید آیا به نتایج اعتماد می‌کنید و چرا.

۳. **استنباط (۵.۱ امتیاز).** میانگین‌های پسین و بازه‌های ٪۹۵ را گزارش کنید؛ پسین $c_{\text{conservative}} - c_{\text{liberal}}$ و احتمال مثبت بودنش را حساب کنید. $d'$ را با MLE هفته‌ی ۴ مقایسه کنید.

۴. Gibbs **(۲ امتیاز).** نمونه‌گیر Gibbs دوشرطی تمرین ۵ را پیاده‌سازی کنید و پسین تفاوت میانگین‌ها را با تشخیص‌ها گزارش کنید.

۵. **تفسیر (۵.۱ امتیاز، حداکثر ۳۰۰ کلمه).** طبق پسین، پاداش‌ها با حساسیت و سوگیری چه می‌کنند؟ با نتیجه‌ی آزمون نسبت درست‌نمایی هفته‌ی ۴ مقایسه کنید.

**روبریک:** امتیازها مطابق بالا؛ داخل هر کار: درستی ٪۶۰، نمودارها/جدول‌ها ٪۲۰، تفسیر ٪۲۰. برای تحویل با تأخیر، روزی ٪۱۰ کسر می‌شود (حداکثر ۳ روز).

---

### ۱۱.۱.۱ مطالعه‌ی بیشتر

- Kruschke **(۲۰۱۴)، فصل ۷** (بخش‌های نمونه‌گیری Gibbs و نماینده بودن، دقت و کارایی MCMC): تشخیص همگرایی، ESS و MCSE به زبان تصویری. (منبع اصلی.)
- Lao & Martin, Kumar **(۲۰۲۱)، فصل ۲.** تحلیل اکتشافی مدل‌های بیزی: trace plotها، $\hat{R}$، ESS و MCSE با ArviZ.
- Wagenmakers & Lee **(۲۰۱۴)، فصل ۴.** استنباط با توزیع‌های گاوسی: همان مدل نرمالی که امروز نمونه‌گیر Gibbs آن را ساختید، در بافت مدل‌سازی بیزی.
- اختیاری، خارج از فهرست درس: Bürkner, P.-C.& Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., (۲۰۲۱). Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC. *Bayesian Analysis*, ۱۶(۲)، ۶۶۷–۷۱۸.

پیش‌نمایش هفته‌ی ۱۳: نوشتن نمونه‌گیرها با دست یاد می‌دهد چطور کار می‌کنند، ولی کند و پراشتباه است. هفته‌ی بعد مدل‌ها را در PyMC توصیف می‌کنیم، می‌گذاریم نمونه‌گیر NUTS آن کار را بکند، و از وقتی که صرفه‌جویی می‌کنیم برای مفیدترین دسته‌ی مدل‌ها در علوم شناختی استفاده می‌کنیم: مدل‌های سلسله‌مراتبی چند شرکت‌کننده.