مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۱۳: برنامه‌نویسی احتمالاتی و مدل‌های سلسله‌مراتبی

فهرست مطالب

۱ برآورد پارامتر با MCMC **۱**

۱.۱ هفته‌ی ۱۳: برنامه‌نویسی احتمالاتی و مدل‌های سلسله‌مراتبی ۱

۱.۱.۱ واژه‌های کلیدی ۱

۲.۱.۱ اهداف یادگیری ۲

۳.۱.۱ مقدمه ۳

۴.۱.۱ جزوه‌ی درس ۳

۵.۱.۱ مثال حل‌شده ۷

۶.۱.۱ lab (۲ ساعت) ۸

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها ۱۱

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست ۱۲

۹.۱.۱ خودآزمایی ۱۳

۱۰.۱.۱ تکلیف ۱۳

۱۱.۱.۱ مطالعه‌ی بیشتر ۱۳

فصل ۱

برآورد پارامتر با MCMC

۱.۱ هفته‌ی ۱۳: برنامه‌نویسی احتمالاتی و مدل‌های سلسله‌مراتبی

فصل ۵: برآورد پارامتر با روش‌های داده‌محور (MCMC)، پلی به فصل ۶ · درس ۱ ساعت · lab ۲ ساعت
داده‌ی اصلی: یک آزمایش بازشناسی/تشخیص با ۱۲ شرکت‌کننده و فقط ۵۰ + ۵۰ trial برای هر نفر: SDT سلسله‌مراتبی در PyMC.

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
hierarchical model	مدل سلسله‌مراتبی (چندسطحی)	پارامترهای فردی از یک توزیع گروهی می‌آیند
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
probabilistic programming	برنامه‌نویسی احتمالاتی	تعریف مدل با کد و نمونه‌گیری خودکار (PyMC)
prior	توزیع پیشین (prior)	باور درباره‌ی پارامتر پیش از دیدن داده
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها
prior predictive check	بررسی پیش‌بینی پیشین	شبیه‌سازی داده از پیشین برای سنجش معقول بودن آن

English	فارسی	توضیح کوتاه
posterior	توزیع پسین (posterior)	باور درباره‌ی پارامتر بعد از دیدن داده
posterior predictive check (PPC)	بررسی پیش‌بینی پسین	مقایسه‌ی داده‌ی شبیه‌سازی‌شده از پسین با داده‌ی واقعی
NUTS / HMC	Hamiltonian Monte Carlo / NUTS	MCMC مبتنی بر گرادیان
divergent transition	divergence (گذار واگرا)	هشدار NUTS برای ناحیه‌ای که درست کاوش نشده
partial pooling / no / complete	ادغام کامل / بدون ادغام / ادغام جزئی (pooling)	یک پارامتر برای همه / جدا برای هر فرد / سلسله‌مراتبی
shrinkage	انقباض به سمت میانگین (shrinkage)	کشیده شدن برآوردهای پرنویز به سمت میانگین گروه
non-centered / centered parameterization	پارامتری‌سازی centered / non-centered	دو شکل نوشتن مدل سلسله‌مراتبی
group-level parameter	پارامتر سطح گروه	میانگین و پراکندگی پارامترها در جمعیت
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
hit	اصابت (hit)	پاسخ «بله» وقتی علامت وجود دارد
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
gradient	گرادیان	جهت و شیب تغییر تابع
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
reparameterization	بازپارامتری‌سازی	نوشتن پارامتر در مقیاس دیگر، مثلاً $\lambda = e^{\eta}$
standard error (SE)	خطای استاندارد	پراکندگی برآورد در تکرارهای فرضی آزمایش
benchmark	benchmark (مجموعه‌آزمون استاندارد)	مجموعه سؤال برای مقایسه‌ی مدل‌های هوش مصنوعی

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. یک مدل شناختی را در PyMC **تعریف کنند** (پیشین‌ها، تبدیل‌های قطعی، درست‌نمایی) و یک گردش کار بیزی کامل را **اجرا کنند**: بررسی پیش‌بینی پیشین، نمونه‌گیری، تشخیص همگرایی، بررسی پیش‌بینی پسین.
۲. به‌طور مفهومی **توضیح دهند** که NUTS / Hamiltonian Monte Carlo چه فرقی با Metropolis گام تصادفی دارد و یک divergence نشانه‌ی چیست.
۳. یک مدل سلسله‌مراتبی (چندسطحی) را **صورت‌بندی کنند** و partial pooling و shrinkage را **توضیح دهند**، در مقایسه با رویکردهای complete pooling و no pooling هفته‌ی ۵.

۴. یک پارامترسازی non-centered را **پیاده‌سازی کنند** و استفاده‌اش را **توجیه کنند**.
۵. پسین‌های سطح گروه و سطح فرد را **تفسیر کنند** و طبق چک‌لیست هفته‌ی ۱۲ **گزارش کنند**.

۳.۱.۱ مقدمه

در هفته‌ی ۵ با یک دوراهی روبه‌رو شدیم. برازش **میانگین** همه‌ی شرکت‌کننده‌ها پایدار است ولی می‌تواند مدل را تحریف کند (خطای میانگین‌گیری) و تفاوت‌های فردی را نادیده می‌گیرد. برازش **هر شرکت‌کننده جداگانه** تفاوت‌ها را رعایت می‌کند، ولی با trialهای کم برای هر نفر برآوردها پرنویزند. بعضی‌شان حدی یا بی‌نهایت می‌شوند (شرکت‌کننده‌ای با ۵۰/۵۰ hit بدون تصحیح $d' = \infty$ دارد). آماره‌های مرحله‌ی دوم روی این برآوردها هم نادیده می‌گیرند که بعضی از بقیه خیلی نامطمئن‌ترند.

مدل‌های سلسله‌مراتبی این دوراهی را حل می‌کنند. فرض می‌کنند هر شرکت‌کننده پارامتر خودش را دارد، و این پارامترهای فردی از یک توزیع سطح گروه می‌آیند که میانگین و پراکندگی‌اش هم برآورد می‌شود. آن‌وقت هر برآورد فردی از بقیه نیرو قرض می‌گیرد: برآوردهای پرنویز و حدی دقیقاً به اندازه‌ای که عدم قطعیتشان ایجاب می‌کند به سمت میانگین گروه کشیده («shrink») می‌شوند. پارامترهای سطح گروه به سؤال جمعیت («حساسیت معمول چقدر است و آدم‌ها چقدر با هم فرق دارند؟») با در نظر گرفتن همه‌ی منابع عدم قطعیت جواب می‌دهند.

نوشتن نمونه‌گیر برای چنین مدل‌هایی با دست خودش یک پروژه‌ی پژوهشی است. **زبان‌های برنامه‌نویسی احتمالاتی** مثل PyMC به ما اجازه می‌دهند مدل را در چند خط توصیف کنیم و خودکار از یک نمونه‌گیر پیشرفته، NUTS، استفاده کنیم. نمونه‌گیرهای دست‌سازِ هفته‌های ۱۱–۱۲ همان چیزی‌اند که این جعبه‌ی سیاه را برایتان شفاف می‌کنند.

این موضوع کجا به کار می‌رود؟

- **بیشتر مطالعه‌های امروزی مدل‌سازی شناختی با شرکت‌کننده‌های زیاد** مدل‌های سلسله‌مراتبی برازش می‌کنند: مدل‌های drift-diffusion سلسله‌مراتبی (بسته‌ی HDDM)، مدل‌های یادگیری تقویتی سلسله‌مراتبی در روان‌پزشکی محاسباتی، و SDT سلسله‌مراتبی در پژوهش حافظه.
- **مطالعه‌های بالینی و رشدی با جلسه‌های کوتاه:** کودکان و بیماران نمی‌توانند صدها trial انجام دهند، پس برآوردهای فردی پرنویزند؛ partial pooling آن‌ها را قابل استفاده می‌کند.
- **آموزش و علوم اجتماعی:** دانش‌آموزان درون کلاس‌ها درون مدرسه‌ها (مدل‌های چندسطحی) مثال کتاب‌درسی ساختار سلسله‌مراتبی است.
- **تحلیل ورزشی و پزشکی:** برآورد مهارت یک بازیکن یا نرخ موفقیت یک بیمارستان از چند مشاهده‌ی کم با کمک گرفتن از گروه، همین ایده است.

۴.۱.۱ جزوه‌ی درس

به زبان ساده وقتی هر نفر فقط کمی داده به ما می‌دهد، برآوردهای فردی پرنویزند و بعضی‌شان بی‌معنی از آب درمی‌آیند (نمره‌ی کامل یعنی $d' = \infty$). یک **مدل سلسله‌مراتبی** می‌گوید: هر نفر پارامتر خودش را دارد، ولی آدم‌ها به هم شبیه‌اند، پس پارامترهایشان از یک توزیع گروهی مشترک می‌آیند که میانگین و پراکندگی آن را هم برآورد می‌کنیم. نتیجه یک مصالحه‌ی معقول است: کسی که داده‌ی کم یا حدی دارد به سمت میانگین گروه کشیده می‌شود (shrinkage)، و کسی که داده‌ی زیادی دارد برآوردی نزدیک به برآورد خودش نگه می‌دارد. شدت این کشش به این بستگی دارد که آدم‌ها چقدر با هم فرق دارند، و این از روی داده یاد گرفته می‌شود. نوشتن نمونه‌گیر برای چنین مدلی با دست سخت است، پس از PyMC استفاده می‌کنیم: مدل را

تقریباً مثل ریاضی آن می‌نویسیم و PyMC یک نمونه‌گیر پیشرفته (NUTS) را برایمان اجرا می‌کند. بخش آخر هفته یک **گردش کار** (workflow) قدم‌به‌قدم برای انجام امن این کار است.

زمان‌بندی پیشنهادی (۶۰ دقیقه): برنامه‌نویسی احتمالاتی ۱۰ · مفاهیم HMC/NUTS ۱۰ · مدل‌های سلسله‌مراتبی ۲۰ · پارامترسازی و divergenceها ۱۰ · گردش کار بیزی ۱۰.

۱. برنامه‌نویسی احتمالاتی با PyMC

یک مدل PyMC رونویسی مستقیم مدل ریاضی است:

ریاضی	PyMC
$\mu_d \sim \mathcal{N}(1, 1)$	`mu_d=pm.Normal("mu_d",1,1)`
$\sigma_d \sim \mathcal{N}^+(0, 1)$	`sigma_d=pm.HalfNormal("sigma_d", 1)`
$d'_j = \mu_d + \sigma_d z_j$	`d=pm.Deterministic("d",mu_d+sigma_d*z_d)`
$H_j = \Phi(d'_j/2 - c_j)$	`H=Phi(d/2-c)` (یک عبارت که با `pm.math` ساخته می‌شود)
$\text{hits}_j \sim \text{Binomial}(n_s, H_j)$	`pm.Binomial("hits",n=n_s,p=H,observed=hits)`

بعد `pm.sample()` مدل را کامپایل می‌کند، گرادیان‌ها را خودکار حساب می‌کند و NUTS را اجرا می‌کند. نتیجه یک شیء `DataTree`/`InferenceData` در ArviZ است با گروه‌هایی مثل `posterior`، `sample_stats`، `prior_predictive` و `posterior_predictive` که ArviZ آن‌ها را خلاصه و تشخیص می‌کند (هفته‌ی ۱۲).

نکته‌های عملی: وقتی یک اسکریپت ساده‌ی `.py` را در Windows اجرا می‌کنید از `cores=1` استفاده کنید (یا کد را داخل `if__name__=="__main__":` بگذارید)؛ به هر متغیر یک نام یکتا بدهید؛ برای برچسب زدن شرکت‌کننده‌ها از `coords`/`dims` استفاده کنید.

۲. Hamiltonian Monte Carlo و NUTS (به‌طور مفهومی)

Metropolis گام تصادفی گام‌های کورکورانه پیشنهاد می‌دهد و در ابعاد بالا یا در امتداد ridgeهای همبسته بیشترشان را هدر می‌دهد (هفته‌های ۱۱–۱۲). Hamiltonian Monte Carlo (HMC) منفی لگاریتم پسین را یک منظره و بردار فعلی پارامتر را یک توپ بدون اصطکاک در نظر می‌گیرد. به توپ یک ضربه‌ی تصادفی (تکانه) بدهید، بگذارید مدتی با دنبال کردن گرادیان منظره بغلتد، و جایی را که به آن می‌رسد پیشنهاد دهید. پیشنهادها می‌توانند دور باشند و هنوز در نواحی پراحتمال، پس پذیرش بالا و خودهمبستگی پایین است. NUTS (No-U-Turn Sampler) زمان غلتیدن را خودکار تنظیم می‌کند. HMC به گرادیان نیاز دارد که PyMC برایتان حساب می‌کند.

Divergenceها. غلتیدن به‌صورت عددی در گام‌های کوچک شبیه‌سازی می‌شود. جایی که انحنای پسین ناگهان تغییر می‌کند (معمولاً در «قیف‌ها»، در ادامه)، شبیه‌سازی نادقیق می‌شود و NUTS یک divergence (divergent transition) را علامت می‌زند. حتی چند divergence یعنی پسین آنجا به‌طور قابل اعتماد کاوش نمی‌شود. نادیده‌شان نگیرید؛ reparameterize کنید.

پیشرفته: HMC دینامیک هامیلتونی با انرژی $H(\boldsymbol{\theta},\mathbf{p}) = -\ln\tilde{p}(\boldsymbol{\theta}) + \frac{1}{2}\mathbf{p}^\top M^{-1}\mathbf{p}$ را با انتگرال‌گیر leapfrog شبیه‌سازی می‌کند. دینامیک دقیق H را پایسته نگه می‌دارد، پس پیشنهادها همیشه پذیرفته می‌شدند. خطای leapfrog یک تصحیح Metropolis را لازم می‌کند، و یک divergence مسیری است که خطای انرژی‌اش منفجر می‌شود.

۳. مدل‌های سلسله‌مراتبی

ساختار (برای SDT با J شرکت‌کننده):

$$\begin{aligned}
&\text{Group level:} && \mu_d \sim \mathcal{N}(1,1),\ \ \sigma_d \sim \mathcal{N}^+(0,1),\ \ \mu_c \sim \mathcal{N}(0,1),\ \ \sigma_c \sim \mathcal{N}^+(0,1)\\
&\text{Individual level:} && d'_j \sim \mathcal{N}(\mu_d,\sigma_d),\ \ c_j \sim \mathcal{N}(\mu_c,\sigma_c),\quad j=1,\dots,J\\
&\text{Data:} && \text{hits}_j \sim \text{Binomial}\big(n_s,\Phi(d'_j/2-c_j)\big),\ \ \text{FAs}_j \sim \text{Binomial}\big(n_n,\Phi(-d'_j/2-c_j)\big)
\end{aligned}$$

سه راه ترکیب اطلاعات (مقایسه با هفته‌ی ۵):

رویکرد	مدل	فرضش چیست
complete pooling	یک d' و یک c برای همه	$\sigma_d=\sigma_c=0$: بدون تفاوت فردی
no pooling	d'_j و c_j جداگانه با پیشین‌های ثابت و مستقل	$\sigma\to\infty$: شرکت‌کننده‌ها هیچ چیزی درباره‌ی هم به ما نمی‌گویند
partial pooling	سلسله‌مراتبی؛ σ_d و σ_c برآورد می‌شوند	داده‌ها تصمیم می‌گیرند شرکت‌کننده‌ها چقدر شبیه هم‌اند

.shrinkage با یک تقریب نرمال، برآورد سلسله‌مراتبی شرکت‌کننده‌ی j میانگین وزنی (با وزن دقت) برآورد خودش $\hat{d}_j$ (با خطای استاندارد SE_j) و میانگین گروه است:

$$\mathbb{E}[d'_j \mid \text{data}] \approx \frac{\hat{d}_j/\text{SE}_j^2 + \mu_d/\sigma_d^2}{1/\text{SE}_j^2 + 1/\sigma_d^2}.$$

شرکت‌کننده‌هایی با داده‌ی **پرنویزتر** (SE_j بزرگ‌تر) **بیشتر** shrink می‌شوند. اگر آدم‌ها واقعاً خیلی با هم فرق داشته باشند (σ_d بزرگ)، shrinkage ضعیف است؛ اگر شبیه هم باشند، قوی است. این از روی داده یاد گرفته می‌شود.

چرا shrinkage خوب است، نه تحریف: در کل شرکت‌کننده‌ها، برآوردهای shrinkشده به‌طور میانگین به مقادیر واقعی نزدیک‌ترند تا برآوردهای فردی خام. این یک نتیجه‌ی معروف در آمار است (پارادوکس .(Stein برآوردهای خام حدی تا حدی از روی شانس حدی‌اند، و shrinkage این بازگشت به میانگین را جبران می‌کند.

سؤال‌های سطح گروه مستقیماً با پسین‌های μ_d (حساسیت معمول) و σ_d (تفاوت‌های فردی) جواب داده می‌شوند، و مقایسه‌ی گروه‌ها با افزودن اثرهای گروه یا شرط به سطح گروه انجام می‌شود.

خواندن ریاضی

- **دو سطح.** سطح گروه: μ_d (حساسیت معمول) و σ_d (آدم‌ها چقدر با هم فرق دارند). سطح فرد: $d'_j \sim \mathcal{N}(\mu_d,\sigma_d)$، یعنی حساسیت نفر j از توزیع گروه کشیده می‌شود. سطح داده: hitها و false alarmهای نفر j فقط به d'_j و c_j همان نفر بستگی دارند.

- $\mathcal{N}^+(0,1)$: توزیع «نیم‌نرمال» (half-normal)، یک منحنی نرمال که در ۰ تا شده و فقط مقدارهای مثبت در آن مانده‌اند (انحراف معیار نمی‌تواند منفی باشد).
- **فرمول** shrinkage یک میانگین وزنی با دقت است (مثل هفته‌ی ۱۲): برآورد خود فرد $\hat{d}_j$ دقت $1/\mathrm{SE}_j^2$ دارد و توزیع گروه دقت $1/\sigma_d^2$. مثال حل‌شده: $\mathrm{SE} = 0.40$ دقت ۲۵.۶ می‌دهد و گروه ۴، پس برآورد $= (6.25\times 2.4 + 4\times 1.3)/10.25$ 1.97 است: مقدار خام ۴.۲، ٪۴۰ راه را به سمت میانگین گروه یعنی ۳.۱ می‌رود.
- اگر آدم‌ها واقعاً خیلی با هم فرق داشته باشند (σ_d بزرگ)، دقت گروه کم و shrinkage ضعیف است. اگر شبیه هم باشند، shrinkage قوی است.

۴. پارامترسازی centered در برابر non-centered

نوشتن مستقیم $d'_j \sim \mathcal{N}(\mu_d, \sigma_d)$ (شکل centered) در پسین یک «قیف» می‌سازد: وقتی σ_d کوچک است همه‌ی d'_jها باید به هم فشرده شوند و وقتی بزرگ است می‌توانند پخش شوند. NUTS با این هندسه‌ی متغیر به زحمت می‌افتد و divergence تولید می‌کند، به‌خصوص با داده‌ی کم برای هر شرکت‌کننده. شکل non-centered انحراف‌های استانداردشده را نمونه‌گیری می‌کند و d'_j را به‌طور قطعی می‌سازد:

$$z_j \sim \mathcal{N}(0,1), \qquad d'_j = \mu_d + \sigma_d z_j.$$

همان مدل را توصیف می‌کند ولی هندسه‌ی خیلی دوستانه‌تری دارد. وقتی داده برای هر شرکت‌کننده کم است، به‌طور پیش‌فرض از آن استفاده کنید.

خواندن ریاضی $z_j \sim \mathcal{N}(0,1)$ و $d'_j = \mu_d + \sigma_d z_j$: به جای نمونه‌گیری مستقیم d'_j، یک نمره‌ی استانداردشده‌ی «این فرد چقدر غیرعادی است» یعنی z_j (بر حسب انحراف معیار گروه) را نمونه بگیر و d'_j را از روی آن بساز. هر دو نسخه دقیقاً یک مدل را توصیف می‌کنند. تفاوت فقط در چیزی است که نمونه‌گیر باید کاوش کند: در شکل centered، وقتی σ_d کوچک است، محدوده‌ی مجاز هر d'_j تقریباً به هیچ می‌رسد (یک قیف)؛ در شکل non-centered، z_jها همیشه روی یک مقیاس‌اند، پس اندازه‌ی گام نمونه‌گیر همه‌جا مناسب است.

۵. گردش کار بیزی

۱. مدل و پیشین‌ها را (با توجیه) **تعریف کنید**.
۲. **بررسی پیش‌بینی پیشین** (هفته‌ی ۹): آیا پیشین داده‌های معقولی نتیجه می‌دهد؟
۳. با چند زنجیره **برازش کنید**.
۴. **تشخیص دهید:** $\hat{R}$، ESS، divergenceها، trace plotها (هفته‌ی ۱۲).
۵. **بررسی پیش‌بینی پسین** (هفته‌ی ۱۰): آیا مدل برازش‌شده می‌تواند داده‌ها را بازتولید کند؟
۶. در صورت نیاز مدل‌ها را **مقایسه کنید** (LOO با ArviZ، Bayes factor؛ هفته‌های ۶، ۱۰).
۷. **تفسیر و گزارش کنید.**

برای یک مهندس

- **مدل سلسله‌مراتبی = تخمین با یک** prior **جمعیتی.** مثل این است که بهره‌ی کانال هر کاربر را از چند pilot تخمین بزنید و هم‌زمان توزیع بهره‌ها در سلول را یاد بگیرید و از آن به‌عنوان prior استفاده کنید: یک تخمین‌گر empirical Bayes / MMSE. shrinkage به سمت میانگین گروه همان پدیده‌ی تخمین‌گر James–Stein است که وقتی سه واحد یا بیشتر داریم، در مجموع خطای مربعی از تخمین‌های ML جداگانه بهتر است.

- HMC/NUTS دینامیک همیلتونی (یک ذره‌ی بدون اصطکاک روی سطح منفی لگاریتم (posterior را با یک انتگرال‌گیر عددی (leapfrog) شبیه‌سازی می‌کند، مثل شبیه‌سازی‌های فیزیکی. یک divergence یعنی انتگرال‌گیر ناپایدار شده چون اندازه‌ی گام برای انحنای محلی خیلی بزرگ است؛ مثل یک معادله‌ی دیفرانسیل سخت (stiff) که با گام خیلی بزرگ انتگرال‌گیری شود.
- **پارامتری‌سازی** non-centered یک تغییر متغیر است که متغیرها را به مقیاس واحد نرمال می‌کند، یعنی حالت (conditioning) مسئله را بهتر می‌کند؛ شبیه سفید کردن یا نرمال کردن ورودی‌ها پیش از یک الگوریتم تطبیقی.
- PyMC گرادیان‌ها را خودکار حساب می‌کند (automatic differentiation)، همان فناوری‌ای که شبکه‌های عصبی را آموزش می‌دهد.

برای مدرس

- shrinkage **را با یک مثال ورزشی یا امتحانی معرفی کنید.** دانشجویی که ۳ از ۳ سؤال را درست جواب داده احتمالاً «دانشجوی ٪۱۰۰» نیست؛ دانشجویی با ۹۵ از ۱۰۰ احتمالاً نزدیک ٪۹۵ است. از کلاس بپرسید اطلاعات فردی و کلاسی را چطور ترکیب می‌کنند: خودشان partial pooling را اختراع می‌کنند.
- **نمودار** shrinkage **بخش** D lab **را نشان دهید:** برآوردهای خام، برآوردهای سلسله‌مراتبی و میانگین گروه روی یک شکل، با پیکان. ایده را ماندگار می‌کند.
- **ریاضی** HMC **را عمیق درس ندهید.** یک تصویر (یک توپ که روی منفی لگاریتم posterior با یک ضربه‌ی تصادفی می‌غلتد) کافی است؛ مهارت عملی مهم، خواندن شاخص‌های تشخیصی است (divergence، $\hat{R}$، ESS).
- **اجرای** PyMC **در کلاس:** روی Windows در اسکریپت‌ها از `cores=1` استفاده کنید و نمونه‌گیری را زود شروع کنید (بخش (C، چون ممکن است چند دقیقه طول بکشد.
- **سؤال‌های رایج.**
  - «آیا *shrinkage* نتایج را سوگیر نمی‌کند؟» کمی، ولی خطای کل را کم می‌کند، پس برآوردها به‌طور میانگین به حقیقت نزدیک‌ترند.
  - «آیا مدل سلسله‌مراتبی همیشه بهتر است؟» وقتی افراد داده‌ی کافی دارند، نتایج شبیه برازش‌های جداگانه است؛ بیشترین سود وقتی است که برای هر نفر داده کم است.
  - *«divergence* برای نتایجم یعنی چه؟» یعنی بخشی از posterior به‌طور قابل اعتماد کاوش نشده. reparameterize کنید و دوباره اجرا کنید تا هیچ divergenceای نماند.

۵.۱.۱ مثال حل‌شده

shrinkage **با دست.** پسین گروه $\mu_d \approx 1.3$ و $\sigma_d \approx 0.5$ دارد (دقت گروه $1/0.5^2 = 4$). دو شرکت‌کننده هر دو برآورد خام $\hat{d}_j = 2.4$ دارند.

شرکت‌کننده	SE_j	دقت فردی $1/\mathrm{SE}_j^2$	برآورد سلسله‌مراتبی	انحراف معیار پسین
P1 (trial کم)	۴۰.۰	۲۵.۶	$(6.25 \times 2.4 + 4 \times 1.3)/(6.25 + 4) = 20.2/10.25 =$ **1.97**	$1/\sqrt{10.25} = 0.31$

شرکت‌کننده	SE_j	دقت فردی $1/\mathrm{SE}_j^2$	برآورد سلسله‌مراتبی	انحراف معیار پسین
P2 (trial زیاد)	۲۰.۰	۲۵	$(25\times 2.4 + 4\times 1.3)/(25+4) = 65.2/29 = \mathbf{2.25}$	$1/\sqrt{29} = 0.19$

تفسیر. هر دو شرکت‌کننده به نظر به یک اندازه حساس‌اند، ولی برآورد P1 بر داده‌ی کمتری تکیه دارد، پس مدل کمتر به آن اعتماد می‌کند و آن را ۴۳.۰ به سمت میانگین گروه جابه‌جا می‌کند. P2 فقط ۱۵.۰ جابه‌جا می‌شود. هر دو انحراف معیار پسین از SEهای خام کوچک‌ترند، چون توزیع گروه اطلاعات اضافه می‌کند. (در مدل کامل، μ_d و σ_d خودشان نامطمئن‌اند و هم‌زمان برآورد می‌شوند؛ این محاسبه برای توضیح آن‌ها را ثابت می‌گیرد.)

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. شبیه‌سازی یک آزمایش با ۱۲ شرکت‌کننده و محاسبه‌ی برآوردهای فردی (no pooling).
۲. نوشتن مدل SDT سلسله‌مراتبی در PyMC با پارامترسازی non-centered؛ اجرای یک بررسی پیش‌بینی پیشین.
۳. نمونه‌گیری با NUTS؛ بررسی $\hat{R}$، ESS و divergenceها.
۴. نمایش shrinkage و مقایسه‌ی برآوردها با مقادیر واقعی.
۵. اجرای یک بررسی پیش‌بینی پسین و تفسیر پارامترهای سطح گروه.

زمان‌بندی: بخش A ۱۰ دقیقه · بخش B ۲۰ دقیقه · بخش C ۲۵ دقیقه · بخش D ۳۰ دقیقه · بخش E ۲۰ دقیقه · بخش F ۱۵ دقیقه.

> **زمان اجرا:** نمونه‌گیری از کمتر از یک دقیقه (نصب conda-forge با compiler تا حدود ۲ تا ۳ دقیقه (بدون compiler طول می‌کشد. بخش C را زود شروع کنید.

بخش A: داده و برآوردهای no pooling (۱۰ دقیقه)

> Code · **کد:** `code/week13.py`، cell ۱ · سلول ۱

خروجی مورد انتظار:

```
    hits  fas  d_true  d_indiv  c_true  c_indiv
0     46    2    2.21     3.01    0.13     0.15
1     16   25   -0.24    -0.46    0.42     0.23
2     28    6    1.78     1.29    0.41     0.50
3     40   11    1.33     1.57    0.05    -0.03
4     43    9    1.96     1.94    0.09    -0.08
5     43   17    1.49     1.45   -0.34    -0.32
6     31    0    2.21     2.63    0.70     1.02
7     35   11    1.32     1.27    0.13     0.12
8     24    8    1.04     0.92    0.60     0.51
9     39    8    1.59     1.72    0.33     0.11
10    27    3    1.52     1.58    0.78     0.69
11    21    9    1.12     0.69    0.66     0.54
```

بخش B: مدل در PyMC، و یک بررسی پیش‌بینی پیشین (۲۰ دقیقه)

Code · کد: `code/week13.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
Share of prior-predictive rates exactly 0 or 1: 0.30
```

پیشین دامنه‌ی وسیعی از نرخ‌های hit و false alarm را نتیجه می‌دهد که بیشترشان بالای قطرند. حدود ۳۰٪ شرکت‌کننده‌های شبیه‌سازی‌شده شمارش hit یا false alarm دقیقاً ۰ یا ۵۰ دارند. این‌ها بیشتر شرکت‌کننده‌هایی‌اند که با حساسیت خیلی بالا و سوگیری قوی شبیه‌سازی شده‌اند و false alarm صفر تولید می‌کنند. این خیلی بهتر از ۹۶٪ پیشین «مبهم» هفته‌ی ۹ است، ولی هنوز کمی دست‌ودل‌باز است: تنگ‌تر کردن پیشین‌های `sigma_d` و `sigma_c` (مثلاً `HalfNormal(0.5)`) بیشترشان را حذف می‌کند. امتحانش کنید و ببینید آیا پسین تغییر می‌کند.

بخش C: نمونه‌گیری و تشخیص همگرایی (۲۵ دقیقه)

Code · کد: `code/week13.py`، cell ۳ · سلول ۳

خروجی مورد انتظار:

```
        ess_bulk ess_tail r_hat mcse_mean mcse_sd
mu_d        1303     1651  1.00    0.0075  0.0054
sigma_d     1639     2088  1.00    0.0055  0.0045
mu_c        1312     1474  1.00    0.0036   0.003
sigma_c     1203     1748  1.00    0.0034  0.0047
Number of divergent transitions: 0
Max R-hat over all individual d and c: 1.0023234826538692
```

بخش D: shrinkage و استنباط سطح گروه (۳۰ دقیقه)

Code · **کد:** `code/week13.py`، cell ۴ · سلول ۴

خروجی مورد انتظار:

```
RMSE vs. true d':  no pooling = 0.339,  hierarchical = 0.279
mu_d     posterior mean = 1.45, 95% interval = [0.90, 1.95]
sigma_d  posterior mean = 0.90, 95% interval = [0.56, 1.42]
mu_c     posterior mean = 0.29, 95% interval = [0.04, 0.55]
sigma_c  posterior mean = 0.38, 95% interval = [0.22, 0.65]
P(mu_c > 0 | data) = 0.987
```

تفسیر (در notebook بنویسید): ۱. کدام شرکت‌کننده‌ها بیشتر shrink می‌شوند و چرا؟ یکی را که برآورد خامش حدی است پیدا کنید و توصیف کنید مدل سلسله‌مراتبی با آن چه می‌کند. ۲. آیا برآورد سلسله‌مراتبی به‌طور میانگین به حقیقت نزدیک‌تر است؟ آیا برای هر شرکت‌کننده نزدیک‌تر است؟ چرا این لازم نیست؟ ۳. μ_d و σ_d درباره‌ی این جمعیت چه می‌گویند؟ σ_d را با انحراف معیاری که برای شبیه‌سازی داده استفاده شد (۵.۰) مقایسه کنید و تفاوت را توضیح دهید (راهنمایی: ۱۲ شرکت‌کننده).

بخش E: بررسی پیش‌بینی پسین (۲۰ دقیقه)

Code · **کد:** `code/week13.py`، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
Share of observed counts inside their 95% predictive interval: 1.00
```

بخش F: گزارش (۱۵ دقیقه)

یک پاراگراف روش‌ها و نتایج طبق چک‌لیست هفته‌ی ۱۲ بنویسید: مدل و پیشین‌ها (با کلمات و نمادها)، نمونه‌گیر و تنظیمات، تشخیص‌ها (بیشترین $\hat{R}$، کمترین ESS، divergenceها)، نتیجه‌ی PPC، و نتیجه‌گیری‌های سطح گروه (μ_d، σ_d، μ_c با بازه‌های ۹۵٪؛ $P(\mu_c > 0 \mid \text{data})$).

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. مدل complete pooling (یک d' و یک c برای همه) را در PyMC برازش کنید. برآورد d' آن را با μ_d مدل سلسله‌مراتبی، و بررسی پیش‌بینی پسینش را با بخش E مقایسه کنید. کدام شرکت‌کننده‌ها را نمی‌تواند پیش‌بینی کند؟

تمرین ۲ ⋆. بخش C را با پارامترسازی **متمرکز** (`d=pm.Normal("d",mu_d,sigma_d,dims="parti cipant")`) دوباره اجرا کنید. divergenceها، ESS و زمان اجرا را مقایسه کنید. بعد داده را به ۱۰ + ۱۰ trial برای هر شرکت‌کننده کم کنید و دوباره مقایسه کنید.

تمرین ۳ ⋆⋆ **(تعداد trial نابرابر).** به نیمی از شرکت‌کننده‌ها ۲۰ + ۲۰ trial و به نیمی دیگر ۲۰۰ + ۲۰۰ trial بدهید (داده‌ی جدید شبیه‌سازی کنید). نشان دهید shrinkage، مثل مثال حل‌شده، به تعداد trialها بستگی دارد.

تمرین ۴ ⋆⋆ **(مقایسه‌ی مدل با LOO).** لگاریتم درست‌نمایی را با `pm.compute_log_likelihood(idata)` حساب کنید. در ArviZ `loo` برای هر مشاهده به یک لگاریتم درست‌نمایی نقطه‌ای نیاز دارد: آرایه‌های لگاریتم درست‌نمایی `hits` و `fas` را در یک آرایه‌ی واحد برای هر شرکت‌کننده جمع کنید (مثلاً `idata.log_likelihood["obs"]` =`idata.log_likelihood["hits"]+idata.log_likelihood["fas"]`) و `az.loo(id ata,var_name="obs")` را صدا بزنید. مدل‌های سلسله‌مراتبی و complete pooling را با `az.compare` مقایسه کنید. تشخیص‌های k-Pareto را بررسی کنید و بگویید برای پیش‌بینی leave-one-participant-out چه معنایی دارند.

تمرین ۵ ⋆⋆⋆ **(پیشرفته: اثر گروه).** دو گروه ۱۲ نفره شبیه‌سازی کنید که حساسیت میانگینشان ۰.۴ فرق دارد. مدل را با یک اثر گروه β روی μ_d گسترش دهید ($d'_j = \mu_d + \beta \cdot \text{group}_j + \sigma_d z_j$)، β را برآورد کنید و $P(\beta > 0 \mid \text{data})$ را گزارش کنید. با یک آزمون t روی برآوردهای فردی d' مقایسه کنید.

lab check-off

نشان دهید: (۱) خروجی تشخیص‌ها (بدون divergence، $\hat{R}$، ESS)، (۲) نمودار shrinkage با مقایسه‌ی RMSE، و (۳) نمودار PPC همراه با پاراگراف بخش F.

گزارش پیشرفت پروژه (این هفته): یک گزارش وضعیت یک‌صفحه‌ای تحویل دهید (چه کارهایی انجام شده، یک نمودار برازش یا شبیه‌سازی اولیه، مسائل باز). نمره ندارد؛ بازخورد کتبی ظرف یک هفته داده می‌شود.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

benchmarkهای هوش مصنوعی برای partial pooling. benchmarkها به دسته‌های تکلیف تقسیم می‌شوند، و بعضی دسته‌ها فقط چند آیتم دارند. گزارش دقت خام برای هر دسته عددهای پرنویز و گاهی حدی می‌دهد، درست مثل برازش‌های فردی SDT با trialهای کم. یک مدل سلسله‌مراتبی دقت دسته‌ها را نمونه‌هایی از یک توزیع مشترک در نظر می‌گیرد و دسته‌های کوچک را به سمت میانگین کلی shrink می‌کند. کد پایین از یک نسخه‌ی سریع empirical-Bayes استفاده می‌کند: یک مدل beta-binomial که پارامترهای گروهش با بیشینه کردن marginal likelihood روی یک grid برآورد می‌شوند. در تمرین‌ها نسخه‌ی بیزی کامل را در PyMC برازش می‌کنید.

Code · کد: `code/week13.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
items   true    raw  shrunk
    5  0.72  0.80   0.71
    8  0.63  0.88   0.74
   10  0.64  0.50   0.63
   15  0.63  0.67   0.68
   25  0.76  0.88   0.80
   40  0.69  0.55   0.60
   60  0.80  0.78   0.76
   80  0.51  0.57   0.60
group mean = 0.69, concentration = 19.9;  RMSE raw = 0.125, shrunk =
↪  0.066
```

دسته‌ی ۸آیتمی (خام ۸۸.۰، واقعی ۶۳.۰) به‌شدت پایین کشیده می‌شود، و برآوردهای shrinkشده در مجموع حدود دو برابر دقیق‌ترند (RMSE برابر ۰۶۶.۰ در برابر ۱۲۵.۰).

امتحانش کنید (بدون نیاز به API**).** ⋆ کدام دسته‌ها بیشتر از همه جابه‌جا می‌شوند، و چرا؟ جوابتان را به فرمول shrinkage در جزوه‌ی درس این هفته ربط دهید. ⋆⋆ همین مدل را در PyMC برازش کنید: `mu~Beta(2,2)`، `kappa~Gamma` (shape `(2,0.1)` و rate)، `theta_j~Beta(mu*kappa,(1-mu)*kappa)`، `y_j~Binomial(n_j,theta_j)`. میانگین‌های پسین را با برآوردهای empirical-Bayes مقایسه کنید و تشخیص‌ها را بررسی کنید. ⋆⋆ بحث: یک جدول رتبه‌بندی «دسته‌ای که مدل X در آن ضعیف‌ترین است» را برجسته می‌کند، که یک دسته‌ی ۵آیتمی است. به نویسندگان چه می‌گویید؟

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. shrinkage» **نتایج را سوگیر می‌کند.»** کمی سوگیری را با کاهش زیاد واریانس معاوضه می‌کند و به‌طور میانگین برآوردهای دقیق‌تری می‌دهد. اصولی است، نه یک تصحیح موقت.

۲. **نادیده گرفتن** divergence**ها.** حتی چندتایشان نشانه‌ی کاوش غیرقابل اعتماد است. reparameterize کنید (non-centered)، پیشین‌های پارامترهای مقیاس را تنگ‌تر کنید، یا `target_accept` را بالا ببرید.

۳. **پارامترسازی** centered **با داده‌ی کم.** قیف و divergence می‌سازد. برای مدل‌های سلسله‌مراتبی با trialهای کم برای هر شرکت‌کننده، به‌طور پیش‌فرض از non-centered استفاده کنید.

۴. **پیشین‌های مبهم برای انحراف معیارهای گروه.** پیشین‌های خیلی پهن روی σ می‌توانند پیش‌بینی‌های پیشین نامعقول و مشکلات نمونه‌گیری بسازند. پیشین‌های نیم‌نرمال با مقیاس معقول معمولاً بهترند.

۵. **جادو دانستن جعبه‌ی سیاه.** PyMC از هر مدلی که بنویسید، از جمله مدل‌های غلط، نمونه می‌گیرد. گردش کار (بررسی پیش‌بینی پیشین، تشخیص‌ها، PPC) همچنان کامل لازم است.

۶. **اجرای نمونه‌گیری چندپردازشی از یک اسکریپت در** Windows **بدون** main guard**،** که خطاهای مبهم multiprocessing می‌دهد. از `cores=1` یا `if__name__=="__main__":` استفاده کنید.

۷. **گزارش فقط برآوردهای فردی.** پارامترهای سطح گروه اغلب به سؤال پژوهشی واقعی جواب می‌دهند.

۹.۱.۱ خودآزمایی

۱. سه راه ترکیب داده بین شرکت‌کننده‌ها کدام‌اند و هرکدام درباره‌ی تفاوت‌های فردی چه فرضی دارند؟ **پاسخ** complete pooling (همه یکسان‌اند، $\sigma = 0$)، no pooling (شرکت‌کننده‌ها بی‌ارتباط‌اند، پس هیچ اطلاعاتی به اشتراک گذاشته نمی‌شود)، و partial pooling/سلسله‌مراتبی (شرکت‌کننده‌ها از یک توزیع مشترک می‌آیند که پراکندگی‌اش از داده برآورد می‌شود).

۲. دو شرکت‌کننده برآورد خام d' یکسانی دارند. چرا ممکن است مدل سلسله‌مراتبی یکی را خیلی بیشتر shrink کند؟ **پاسخ** shrinkage به دقت هر برآورد فردی بستگی دارد. شرکت‌کننده‌ای که trial کمتری دارد (SE بزرگ‌تر) اطلاعات کمتری دارد و قوی‌تر به سمت میانگین گروه کشیده می‌شود.

۳. چرا پارامترسازی non-centered اغلب ترجیح دارد؟ **پاسخ** شکل centered پسینی قیفی‌شکل می‌سازد (پارامترهای فردی وقتی انحراف معیار گروه کوچک است باید به هم فشرده شوند) که NUTS بد کاوشش می‌کند و divergence می‌دهد. نمونه‌گیری استانداردشده و محاسبه‌ی $d'_j = \mu + \sigma z_j$ هندسه‌ای می‌دهد که کاوشش خیلی آسان‌تر است. z_j

۴. divergence چیست و باید با آن چه کرد؟ **پاسخ** مسیری در NUTS که شبیه‌سازی عددی‌اش شکسته است، معمولاً در ناحیه‌ای با انحنای زیاد؛ نشان می‌دهد بخشی از پسین به‌طور قابل اعتماد کاوش نمی‌شود. reparameterize کنید، برای پارامترهای مقیاس از پیشین‌های آگاهی‌بخش‌تر استفاده کنید، یا `target_accept` را بالا ببرید، و بعد بررسی کنید که divergenceها ناپدید شده باشند.

۵. چرا HMC معمولاً در ابعاد بالا خیلی بهتر از Metropolis گام تصادفی مخلوط می‌شود؟ **پاسخ** از اطلاعات گرادیان برای حرکت‌های بلند و جهت‌دار که شکل پسین را دنبال می‌کنند استفاده می‌کند، پس پیشنهادهای دور هم هنوز احتمال پذیرش بالایی دارند. پیشنهادهای گام تصادفی، مگر اینکه خیلی ریز باشند، تقریباً همیشه رد می‌شوند.

۶. در یک مدل SDT سلسله‌مراتبی، کدام پارامتر به «آدم‌ها چقدر در حساسیت با هم فرق دارند؟» و کدام به «حساسیت معمول چقدر است؟» جواب می‌دهد؟ **پاسخ** به ترتیب σ_d (انحراف معیار سطح گروه) و μ_d (میانگین سطح گروه).

۷. مراحل گردش کار بیزی را فهرست کنید. **پاسخ** تعریف مدل و پیشین‌ها ← بررسی پیش‌بینی پیشین ← برازش با چند زنجیره ← تشخیص ($\hat{R}$، ESS، divergenceها، traceها) ← بررسی پیش‌بینی پسین ← در صورت نیاز مقایسه‌ی مدل‌ها ← تفسیر و گزارش.

۱۰.۱.۱ تکلیف

- A5 (MCMC **از صفر**) در ابتدای درس هفته‌ی ۱۴ تحویل داده می‌شود.
- **گزارش پیشرفت پروژه** این هفته (بالا را ببینید).
- تکلیف نمره‌دار جدیدی نداریم: هفته‌های باقی‌مانده برای پروژه‌ی پایانی است.

۱۱.۱.۱ مطالعه‌ی بیشتر

- Wagenmakers & Lee **(۲۰۱۴)، فصل ۱۱.** نظریه‌ی تشخیص علامت، از جمله همان مدل SDT سلسله‌مراتبی‌ای که امروز پیاده‌سازی کردید. (منبع اصلی.)
- Kruschke **(۲۰۱۴)، فصل ۹.** مدل‌های سلسله‌مراتبی: partial pooling و shrinkage، قدم‌به‌قدم.
- Lewandowsky & Farrell **(۲۰۱۸)، فصل ۹.** مدل‌سازی چندسطحی یا سلسله‌مراتبی داده‌های شناختی.

- Lao & Martin, Kumar **(۲۰۲۱)، فصل‌های ۲ و ۱۰.** تشخیص با ArviZ، و زبان‌های برنامه‌نویسی احتمالاتی (PyMC در پشت صحنه چطور کار می‌کند).

پیش‌نمایش هفته‌ی ۱۴: با جعبه‌ابزار کامل، گشتی در مدل‌هایی از حوزه‌های مختلف علوم شناختی می‌زنیم؛ با دسته‌بندی (مدل exemplar یعنی (GCM و سازوکار سرعت–دقت مدل drift-diffusion شروع می‌کنیم.