مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۱۴: مدل‌سازی در علوم شناختی ۱: دسته‌بندی (GCM) و تصمیم‌گیری (Drift-Diffusion)

فهرست مطالب

۱ کاربردها در علوم شناختی ۱

۱.۱ هفته‌ی ۱۴: مدل‌سازی در علوم شناختی ۱: دسته‌بندی (GCM) و تصمیم‌گیری (Drift-Diffusion) . . . ۱

۱.۱.۱ واژه‌های کلیدی . . . ۱

۱.۱.۲ اهداف یادگیری . . . ۲

۱.۱.۳ مقدمه . . . ۳

۱.۱.۴ جزوه‌ی درس . . . ۳

۱.۱.۵ مثال حل‌شده . . . ۸

۱.۱.۶ lab (۲ ساعت) . . . ۹

۱.۱.۷ ارتباط با هوش مصنوعی و LLMها . . . ۱۲

۱.۱.۸ اشتباهات رایج و برداشت‌های نادرست . . . ۱۲

۱.۱.۹ خودآزمایی . . . ۱۳

۱.۱.۱۰ تکلیف . . . ۱۳

۱.۱.۱۱ مطالعه‌ی بیشتر . . . ۱۳

فصل ۱

کاربردها در علوم شناختی

۱.۱ هفته‌ی ۱۴: مدل‌سازی در علوم شناختی ۱: دسته‌بندی (GCM) و تصمیم‌گیری (Drift-Diffusion)

فصل ۶: نمونه‌هایی از مدل‌سازی در حوزه‌های مختلف علوم شناختی · درس ۱ ساعت · lab ۲ ساعت **داده‌ی اصلی:** داده‌ی دسته‌بندی شبیه‌سازی‌شده برای ساختار کلاسیک ۵-۴، و داده‌ی انتخاب–RT شبیه‌سازی‌شده از یک فرایند drift-diffusion در یک طرح سرعت/دقت × آسان/سخت.

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
categorization	دسته‌بندی	قرار دادن محرک در یک دسته
Generalized Context Model (GCM)	مدل بافت تعمیم‌یافته	مدل exemplar دسته‌بندی بر پایه‌ی شباهت
drift rate	نرخ رانش	سرعت میانگین جمع شدن شواهد؛ نشانه‌ی کیفیت شواهد
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
response time (RT)	زمان واکنش	فاصله‌ی ارائه‌ی محرک تا پاسخ
drift-diffusion model (DDM)	مدل drift-diffusion (رانش–انتشار)	انباشت پیوسته‌ی شواهد بین دو مرز
speed–accuracy trade-off	بده‌بستان سرعت و دقت	سریع‌تر پاسخ دادن به قیمت خطای بیشتر
accuracy	دقت	نسبت پاسخ‌های درست

English	فارسی	توضیح کوتاه
exemplar	نمونه (exemplar)	یک مورد ذخیره‌شده در حافظه از یک دسته
prototype	پیش‌نمونه (prototype)	خلاصه یا میانگین یک دسته
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
attention weight	وزن توجه	سهم توجه به هر بُعد محرک
sensitivity (d′)	حساسیت	فاصله‌ی توزیع علامت و نویز
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
EZ-diffusion	EZ-diffusion	برآورد ساده‌ی پارامترهای DDM از سه آماره
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند
evidence	شواهد	اطلاعاتی که برای تصمیم جمع می‌شود
stimulus	محرک	چیزی که به شرکت‌کننده نشان داده می‌شود
boundary separation	فاصله‌ی مرزها	مقدار شواهد لازم برای پاسخ؛ نشانه‌ی احتیاط
non-decision time	زمان غیرتصمیمی	زمان دیدن محرک و اجرای حرکت پاسخ
similarity	شباهت	نزدیکی دو محرک در فضای روان‌شناختی
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
embedding	embedding (بردار معنایی)	برداری که مدل برای یک کلمه یا متن می‌سازد

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. نظریه‌های نمونه‌محور (exemplar) و پیش‌نمونه‌ای (prototype) دسته‌بندی را **توصیف کنند** و آن‌ها را به‌صورت GCM و یک مدل prototype **صورت‌بندی کنند**.
۲. GCM و مدل prototype را با MLE روی داده‌ی دسته‌بندی **برازش کنند**، **مقایسه کنند**، و وزن‌های توجه و حساسیت را **تفسیر کنند**.
۳. مدل drift-diffusion (DDM) را به‌عنوان حد پیوسته‌ی random walk هفته‌ی ۱ **توصیف کنند** و پارامترهایش را به سازه‌های شناختی **نگاشت کنند**.

۴. پارامترهای DDM را با روش بسته‌ی EZ-diffusion (closed-form) **برآورد کنند** و آن را با بازیابی پارامتر **اعتبارسنجی کنند**.
۵. اثرهای آزمایشی را بر حسب پارامترهای مدل **تفسیر کنند** («این دست‌کاری احتیاط را تغییر داد، نه کیفیت شواهد را»).

۳.۱.۱ مقدمه

۱۳ هفته‌ی اول یک جعبه‌ابزار ساختند، بیشتر روی دو مثال کوچک (فراموشی و .(SDT فصل ۶ جعبه‌ابزار را روی مدل‌هایی به کار می‌گیرد که کل حوزه‌های پژوهشی را شکل داده‌اند. این هفته دو تا از تأثیرگذارترین‌ها را می‌بینیم.

دسته‌بندی. چطور تصمیم می‌گیریم که یک حیوان تازه سگ است؟ نظریه‌ی *prototype* می‌گوید آن را با یک خلاصه‌ی دسته، یعنی سگ میانگین، مقایسه می‌کنیم. نظریه‌ی *exemplar* می‌گوید آن را با خاطره‌های ذخیره‌شده‌ی همه‌ی سگ‌ها (و همه‌ی گربه‌ها)یی که دیده‌ایم مقایسه می‌کنیم. هر دو معقول به نظر می‌رسند و بحث‌های کلامی سال‌ها رفت و برگشت. مدل‌های فرمال بودند که فرق را ساختند: ساختار دسته‌ی ۵-۴ مدین و شیفر طوری طراحی شد که دو نظریه برای محرک‌های مشخصی **پیش‌بینی‌های متضاد** داشته باشند. **مدل بافت تعمیم‌یافته** (GCM) نوسوفسکی نظریه‌ی exemplar را به یک مدل دقیق و قابل برازش با وزن‌های توجه تفسیرپذیر تبدیل کرد.

تصمیم‌گیری. در هفته‌ی ۱ یک random walk ساختیم که شواهد را تا رسیدن به یک مرز جمع می‌کند. نسخه‌ی پیوسته‌اش، **مدل** drift-diffusion، احتمالاً موفق‌ترین مدل روان‌شناسی شناختی است: دقت و کل توزیع‌های RT پاسخ‌های درست و خطا را توضیح می‌دهد، با پارامترهایی برای کیفیت شواهد، احتیاط و .non-decision time برای مطالعه‌ی پیری، ADHD، افسردگی، یادگیری و اثر داروها از آن استفاده می‌شود. برازش DDM کامل از نظر محاسباتی سنگین است، ولی روش EZ-diffusion با معادله‌های بسته از سه آماره‌ی خلاصه برآوردهای خوبی می‌دهد.

این موضوع کجا به کار می‌رود؟

- **مدل‌های دسته‌بندی** توضیح می‌دهند آدم‌ها چطور مفهوم‌ها را یاد می‌گیرند (دانشجوی پزشکی که یاد می‌گیرد ضایعه‌های پوستی را تشخیص دهد، کودکی که کلمه یاد می‌گیرد)، و برای طراحی آموزش بهتر استفاده می‌شوند: کدام مثال‌ها را و با چه ترتیبی نشان دهیم.
- **ایده‌ی** exemplar **در یادگیری ماشین:** طبقه‌بندهای نزدیک‌ترین همسایه (nearest neighbor) و روش‌های kernel یک مورد جدید را بر اساس شباهتش به مثال‌های ذخیره‌شده طبقه‌بندی می‌کنند؛ همان اصل .GCM
- **مدل** drift-diffusion یکی از پرکاربردترین مدل‌ها در علوم اعصاب شناختی و پژوهش بالینی است: سالمندی، ADHD، افسردگی، اضطراب، اثر داروها و بی‌خوابی. در پژوهش مصرف‌کننده (اینکه آدم‌ها با چه سرعتی بین محصولات انتخاب می‌کنند) و در عصب‌اقتصاد هم استفاده می‌شود.
- EZ-diffusion محبوب است چون برای هر نفر فقط سه آماره‌ی خلاصه لازم دارد و به بهینه‌سازی نیاز ندارد، پس می‌شود آن را سریع روی داده‌های موجود اجرا کرد.

۴.۱.۱ جزوه‌ی درس

به زبان ساده این هفته دو مدل معروف داریم. **دسته‌بندی:** چطور تصمیم می‌گیریم یک حیوان تازه سگ است؟ یک نظریه می‌گوید آن را با یک «سگ ایده‌آل» میانگین مقایسه می‌کنیم (prototype). نظریه‌ی دیگر می‌گوید آن را با همه‌ی سگ‌ها و گربه‌هایی که به یاد داریم مقایسه می‌کنیم و می‌بینیم در مجموع به کدام گروه بیشتر شبیه است (exemplar**ها**). GCM ایده‌ی exemplar

را به ریاضی تبدیل می‌کند: فاصله‌ی آیتم جدید با هر مثال ذخیره‌شده را بسنج (با **توجه** بیشتر به بعضی ویژگی‌ها)، فاصله را به شباهت تبدیل کن (نزدیک‌تر = خیلی شبیه‌تر)، و دسته‌ی A را با احتمال «شباهت کل به A / شباهت کل به همه» انتخاب کن. یک مجموعه محرک هوشمندانه (ساختار ۵-۴) کاری می‌کند که دو نظریه برای بعضی آیتم‌ها پیش‌بینی‌های متضاد داشته باشند. **تصمیم‌گیری: مدل** drift-diffusion نسخه‌ی پیوسته‌ی random walk هفته‌ی ۱ است. شواهد با سرعت میانگین v (کیفیت شواهد) به سمت مرز درست می‌رود و هم‌زمان نویز آن را تکان می‌دهد؛ وقتی به مرز a (احتیاط) برسد پاسخ داده می‌شود؛ یک زمان ثابت T_{er} هم برای دیدن و زدن کلید اضافه می‌شود. EZ-diffusion یک میان‌بر است که v، a و T_{er} را فقط از سه عدد حساب می‌کند: دقت، و میانگین و واریانس زمان واکنش پاسخ‌های درست.

زمان‌بندی پیشنهادی (۶۰ دقیقه): نظریه‌های دسته‌بندی و ساختار ۵-۴ · ۱۰ GCM · ۱۵ مدل prototype و پیش‌بینی‌های کلیدی ۵ · مدل drift-diffusion · ۱۵ EZ-diffusion · ۱۰ تفسیر ۵.

۱. ساختار دسته‌ی ۵-۴

محرک‌ها روی چهار بعد دودویی فرق دارند (مثلاً شکل، رنگ، اندازه و موقعیت یک شکل هندسی در طرح مدین و شیفر؛ ویژگی‌های چهره در نسخه‌های بعدی). شرکت‌کننده‌ها یاد می‌گیرند ۹ محرک آموزشی را در دسته‌های A و B بگذارند، و بعد ۷ محرک **انتقال** (transfer) تازه را بدون بازخورد دسته‌بندی می‌کنند. مجموعه محرک رایج این است [با Schaffer, & Medin ۱۹۷۸ یا Smith & Minda, ۲۰۰۰ بررسی شود]:

دسته‌ی A	دسته‌ی B	انتقال
۱۱۱۰ A1	۱۱۰۰ B1	۱۰۰۱ T1
۱۰۱۰ A2	۰۱۱۰ B2	۱۰۰۰ T2
۱۰۱۱ A3	۰۰۰۱ B3	۱۱۱۱ T3
۱۱۰۱ A4	۰۰۰۰ B4	۰۰۱۰ T4
۰۱۱۱ A5		۰۱۰۱ T5
		۰۰۱۱ T6
		۰۱۰۰ T7

prototype دسته‌ی A برابر ۱۱۱۱ و prototype دسته‌ی B برابر ۰۰۰۰ است. مقایسه‌ی کلیدی: A1 **(۱۱۱۰)** سه ویژگی با prototype دسته‌ی A مشترک دارد، ولی A2 **(۱۰۱۰)** فقط دو تا. پس مدل prototype پیش‌بینی می‌کند A1 بهتر از A2 دسته‌بندی شود. اما A2 به دو exemplar دیگر A (یعنی A1 و A3) خیلی شبیه است و به هیچ exemplar از B شبیه نیست، در حالی که A1 به دو exemplar از B (یعنی B1 و B2) خیلی شبیه است. پس مدل exemplar می‌تواند پیش‌بینی کند که A2 دست‌کم به خوبیِ A1 دسته‌بندی شود، و در داده‌های تجربی A2 معمولاً بهتر دسته‌بندی می‌شود.

۲. مدل بافت تعمیم‌یافته (GCM)

فاصله بین محرک i و exemplar ذخیره‌شده‌ی e، با وزن‌های توجه $w_m \geq 0$ و $\sum_m w_m = 1$ (متریک city-block برای ابعاد جدایی‌پذیر):

$$\text{dist}_{ie} = \sum_{m=1}^{4} w_m \, |x_{im} - x_{em}|.$$

شباهت با فاصله به‌صورت نمایی کم می‌شود، با **حساسیت** c:

$$s_{ie} = \exp(-c \cdot \text{dist}_{ie}).$$

قاعده‌ی انتخاب (شباهت جمع‌شده، نسبت Luce):

$$P(A \mid i) = \frac{\sum_{e \in A} s_{ie}}{\sum_{e \in A} s_{ie} + \sum_{e \in B} s_{ie}}.$$

پارامترها: c (شباهت با فاصله چقدر تند کم می‌شود؛ c بزرگ یعنی فقط exemplarهای خیلی نزدیک مهم‌اند) و سه وزن توجه آزاد (چهارمی $۱ - $ بقیه است)، پس $k = 4$. (این همان c چندمعنایی جدول نمادگذاری هفته‌ی ۱ است؛ این هفته یعنی حساسیت، نه ملاک SDT.)

تفسیر وزن‌های توجه: w_m سهم توجهی است که به بعد m داده می‌شود. توجه بهینه روی ابعادی تأکید می‌کند که برای دسته تشخیصی (diagnostic) هستند. در ساختار ۵-۴، ابعاد ۱ و ۳ تشخیصی‌ترین‌اند.

مدل prototype: همان فاصله، شباهت و قاعده‌ی انتخاب، ولی هر دسته فقط با prototype خودش نمایش داده می‌شود: $P(A \mid i) = s_{i,P_A} / (s_{i,P_A} + s_{i,P_B})$. این هم $k = 4$ دارد، پس شمارش پارامترها روی مقایسه اثری ندارد.

درست‌نمایی: اگر محرک i به تعداد n_i بار دسته‌بندی شود و y_i بار «A» نامیده شود، $y_i \sim \text{Binomial}(n_i, P(A \mid i))$ است و با MLE و multi-start برازش می‌شود (هفته‌های ۳-۴). وزن‌ها بهتر است با یک reparameterization softmax (هفته‌ی ۳) برآورد شوند، $w = \text{softmax}(\eta_1, \eta_2, \eta_3, 0)$، و $c = e^{\gamma}$.

> **پیشرفته:** GCM کامل یک پارامتر سوگیری پاسخ b_A، یک توان شباهت (شباهت گاوسی در برابر نمایی)، یک پارامتر متریک r (city-block با $r = 1$ در برابر اقلیدسی با $r = 2$) و گاهی یک پارامتر قطعیت پاسخ (response determinism) γ (به توان رساندن شباهت‌های جمع‌شده) اضافه می‌کند. Lee & Wagenmakers (فصل ۱۷) یک GCM بیزی و سلسله‌مراتبی می‌سازند.

خواندن ریاضی

- **فاصله** $\sum_m w_m |x_{im} - x_{em}|$: ویژگی‌هایی را بشمار که آیتم جدید i و مثال ذخیره‌شده‌ی e در آن‌ها فرق دارند، ولی هر ویژگی را با توجه آن یعنی وزن w_m وزن بده. با ۴ ویژگی دودویی و وزن‌های برابر ۲۵.۰، یک ویژگی ناهمخوان فاصله‌ی ۲۵.۰ می‌دهد.
- **شباهت** $e^{-c \cdot \text{dist}}$: فاصله‌ی ۰ شباهت ۱ می‌دهد؛ با $c = 2$، فاصله‌ی ۲۵.۰ شباهت $e^{-0.5} = 0.61$ و فاصله‌ی ۱ شباهت $e^{-2} = 0.14$ می‌دهد. c بزرگ‌تر باعث می‌شود شباهت سریع‌تر کم شود، پس فقط مثال‌های خیلی نزدیک مهم‌اند.
- **قاعده‌ی انتخاب:** شباهت‌ها به همه‌ی مثال‌های A و همه‌ی مثال‌های B را جمع بزن و تقسیم کن. در مثال حل‌شده، T3 شباهت کل ۷۹.۲ به A و ۰۹.۱ به B دارد، پس $P(A) = 2.79/3.89 = 0.72$.

۳. مدل drift-diffusion (DDM)

random walk هفته‌ی ۱ را بگیرید و بگذارید اندازه‌ی گام و مدت گام با هم کوچک شوند. آن‌وقت شواهد $X(t)$ به‌طور پیوسته تغییر می‌کند:

$$dX = v\,dt + s\,dW(t), \qquad X(0) = z,$$

که در آن dW نویز سفید گاوسی (فرایند Wiener) است. وقتی X به a (درست) یا 0 (خطا) برسد پاسخ داده می‌شود؛ $\text{RT} = T_{\text{decision}} + T_{er}$.

پارامتر	معنا	دست‌کاری معمولی که تغییرش می‌دهد
v (drift rate)	کیفیت / نرخ انباشت شواهد	دشواری محرک؛ حساسیت ادراکی؛ توجه
a (فاصله‌ی مرزها)	احتیاط پاسخ (تنظیم سرعت–دقت)	دستورالعمل سرعت در برابر دقت
z (نقطه‌ی شروع)	سوگیری پیشینی به سمت یک پاسخ	نرخ‌های پایه، پاداش‌ها
T_{er} (non-decision time)؛ t_0 هم نوشته می‌شود)	زمان رمزگذاری + حرکتی	نوع پاسخ، تخریب محرک
s (نویز درون trial)	ثابت مقیاس	ثابت (طبق قرارداد $s = 0.1$ در EZ و $s = 1$ در جاهای دیگر)

DDM کامل تغییرپذیری بین trialها در drift، نقطه‌ی شروع و non-decision time را هم دارد. تمرین ۵ هفته‌ی ۱ نشان داد که تغییرپذیری drift خطاهای کند تولید می‌کند.

پیش‌بینی‌های شاخص: توزیع‌های RT چوله به راست؛ trade-off سرعت–دقت وقتی a تغییر می‌کند؛ محرک‌های آسان‌تر که پاسخ‌هایی هم سریع‌تر و هم دقیق‌تر می‌دهند (v بالاتر)؛ تغییر T_{er} که کل توزیع RT را بدون تغییر شکلش جابه‌جا می‌کند.

خواندن ریاضی $dX = v\,dt + s\,dW(t)$ این‌طور خوانده می‌شود: «در یک گام زمانی خیلی کوچک dt، شواهد به اندازه‌ی یک هل قطعی $v\,dt$ به‌علاوه‌ی یک ضربه‌ی تصادفی $s\,dW$ تغییر می‌کند». dW نویز گاوسی است که واریانسش متناسب با dt است (پس در یک گام به طول dt ضربه انحراف معیار $s\sqrt{dt}$ دارد). در شبیه‌سازی lab این دقیقاً همان random walk هفته‌ی ۱ با گام‌های کوچک است: `x+=v*dt+s*sqrt(dt)*randn()`. جدول پارامترها بخشی است که باید به خاطر سپرد: v = کیفیت شواهد، a = احتیاط، z = سوگیری، T_{er} = non-decision time.

۴. EZ-diffusion

Wagenmakers، van der Maas و Grasman (۲۰۰۷) برآوردهای بسته‌ی v، a و T_{er} را (با فرض $z = a/2$، بدون تغییرپذیری بین trialها، $s = 0.1$) از سه آماره به دست آوردند: نسبت پاسخ‌های درست P_c، **واریانس** RTهای درست V_{RT} (بر حسب s^2) و **میانگین** RTهای درست M_{RT} (بر حسب s):

$$L = \operatorname{logit}(P_c) = \ln\frac{P_c}{1-P_c}, \qquad x = \frac{L\,(LP_c^2 - LP_c + P_c - 0.5)}{V_{RT}},$$

$$v = \operatorname{sign}(P_c - 0.5)\; s\; x^{1/4}, \qquad a = \frac{s^2 L}{v},$$

$$y = -\frac{va}{s^2}, \qquad \mathrm{MDT} = \frac{a}{2v}\cdot\frac{1-e^{y}}{1+e^{y}}, \qquad T_{er} = M_{RT} - \mathrm{MDT}.$$

حالت‌های مرزی: فرمول‌ها در $P_c = 0.5$ (که آن‌وقت $v = 0$) و $P_c = 1$ (که آن‌وقت $L = \infty$) کار نمی‌کنند. برای $P_c = 1$ یک راه‌حل استاندارد استفاده از $P_c = 1 - 1/(2N)$ است، شبیه تصحیح‌های نرخ حدی هفته‌ی ۲.

نقاط قوت و محدودیت‌ها. EZ سریع است، به بهینه‌سازی نیاز ندارد و وقتی فرض‌هایش برقرارند پارامترها را خوب بازیابی می‌کند (بخش C lab). RT های خطا و شکل توزیع RT فراتر از میانگین و واریانس را نادیده می‌گیرد، و نمی‌تواند سوگیری یا تغییرپذیری‌های بین trialها را برآورد کند. برای این‌ها DDM کامل را با MLE یا روش‌های بیزی سلسله‌مراتبی برازش کنید (مثلاً بسته‌ی HDDM یا درست‌نمایی Wiener در PyMC/Stan).

خواندن ریاضی معادله‌های EZ ترسناک به نظر می‌رسند ولی یک دستور پخت‌اند؛ لازم نیست کسی آن‌ها را حفظ کند.

۱. $L = \ln(P_c/(1-P_c))$: logit دقت («لگاریتم بخت درست بودن»). $P_c = 0.8$ می‌دهد $L = \ln 4 = 1.39$.
۲. x دقت را با **واریانس** زمان واکنش پاسخ‌های درست ترکیب می‌کند: هرچه زمان‌های واکنش برای یک دقت مشخص پراکنده‌تر باشند، drift کمتر است.
۳. بعد v و a از L و x به دست می‌آیند؛ MDT میانگین زمان تصمیم پیش‌بینی‌شده است.
۴. $T_{er} = M_{RT} - \text{MDT}$: هر بخشی از میانگین زمان واکنش که زمان تصمیم نیست، non-decision time است.

از مثال حل‌شده (بخش ۲) برای نشان دادن هر قدم با عدد استفاده کنید؛ بعد بگذارید کامپیوتر انجامش دهد (تابع `ez_diffusion` در کد lab).

برای یک مهندس

- GCM یک طبقه‌بند مبتنی بر شباهت با کرنل نمایی و یک متریک L1 وزن‌دار (city-block) است، نزدیک به یک **طبقه‌بند کرنلی / پنجره‌ی Parzen**. وزن‌های توجه مثل وزن‌های یادگرفته‌شده‌ی ویژگی‌ها عمل می‌کنند؛ c معکوس پهنای کرنل است.
- DDM یک **فرایند Wiener با رانش** بین دو مرز جاذب است: مسئله‌ی کلاسیک زمان اولین عبور (first-passage time). SPRT پیوسته در زمان (کادر هفته‌ی ۱) دقیقاً همین فرایند است، با v متناسب با دامنه‌ی سیگنال و s سطح نویز.
- توزیع‌های زمان واکنش همان **توزیع‌های زمان اولین عبور** هستند و به همان دلیلی چوله به راست‌اند که تأخیرهای آشکارسازی یک آشکارساز ترتیبی.
- EZ-diffusion یک تخمین‌گر روش گشتاورها (method of moments) است: سه گشتاور نمونه (دقت، میانگین و واریانس زمان واکنش‌های درست) را با عبارت‌های بسته‌ی مدل برابر می‌گذارد، به جای اینکه درست‌نمایی را بیشینه کند.

برای مدرس

- **بگذارید دانشجوها خودشان شرکت‌کننده باشند.** پیش از GCM، ۹ محرک آموزشی ساختار ۵-۴ را به شکل نقاشی‌های ساده نشان دهید (مثلاً شکل‌هایی با ۴ ویژگی دودویی)، دسته‌ها را با بازخورد یاد بدهید و بعد A1 و A2 را آزمون کنید. داده‌ی خود کلاس اغلب الگوی exemplar را نشان می‌دهد.
- **DDM را با همان تصویر هفته‌ی ۱ و یک مسیر هموار و پرنویز بکشید.** بعد هر بار یک پارامتر را روی تخته تغییر دهید (مرزهای دورتر، drift تندتر، شروع دیرتر) و بپرسید دقت و زمان واکنش چه می‌شود.
- **EZ را اثبات نکنید.** آن را به‌عنوان یک «ماشین‌حساب» معرفی کنید و وقت را روی تفسیر بگذارید (بخش E lab: کدام دست‌کاری کدام پارامتر را تغییر داد.
- **سؤال‌های رایج.**
  - «*prototype* یا *exemplar*، کدام برنده شد؟» برای دسته‌های کوچک و کم‌ساختار معمولاً مدل‌های exemplar بهتر برازش می‌شوند؛ برای دسته‌های بزرگ و پرساختار prototype هم خوب کار می‌کند. هر دو ایده در مدل‌های امروزی زنده‌اند.
  - «چرا فقط میانگین زمان واکنش را مقایسه نکنیم؟» یک گروه کندتر ممکن است محتاط‌تر باشد، شواهد بدتری داشته باشد یا از نظر حرکتی کندتر باشد؛ فقط DDM این‌ها را جدا می‌کند.
  - «آیا پارامترهای *EZ* و *DDM* کامل یکی‌اند؟» همان کمیت‌ها را برآورد می‌کنند، ولی EZ فرض می‌کند سوگیری و تغییرپذیری بین trialها وجود ندارد.

۵.۱.۱ مثال حل‌شده

بخش ۱: یک پیش‌بینی GCM با دست

محرک T3 (۱۱۱۱)، توجه برابر $w_m = 0.25$، حساسیت $c = 2$.

Exemplar	ابعاد ناهمخوان	فاصله	شباهت $e^{-2\,\text{dist}}$
A1 ۱۱۱۰	۱	۲۵.۰	۶۰۷.۰
A2 ۱۰۱۰	۲	۵۰.۰	۳۶۸.۰
A3 ۱۰۱۱	۱	۲۵.۰	۶۰۷.۰
A4 ۱۱۰۱	۱	۲۵.۰	۶۰۷.۰
A5 ۰۱۱۱	۱	۲۵.۰	۶۰۷.۰
جمع A			**۷۹۴.۲**
B1 ۱۱۰۰	۲	۵۰.۰	۳۶۸.۰
B2 ۰۱۱۰	۲	۵۰.۰	۳۶۸.۰
B3 ۰۰۰۱	۳	۷۵.۰	۲۲۳.۰
B4 ۰۰۰۰	۴	۰۰.۱	۱۳۵.۰
جمع B			**۰۹۴.۱**

$$P(A \mid \text{T3}) = \frac{2.794}{2.794 + 1.094} = 0.719.$$

تفسیر. T3 خودِ prototype دسته‌ی A است، ولی مدل exemplar با این پارامترها فقط حدود ۷۲٪ پاسخ «A» پیش‌بینی می‌کند: دو exemplar از B (یعنی B1 و B2) فقط دو ویژگی فاصله دارند. یک c بزرگ‌تر (شباهت تیزتر) این احتمال را بالا می‌برد، چون نزدیک‌ترین همسایه‌ها (چهار exemplar از A در فاصله‌ی ۲۵.۰) غالب می‌شوند.

بخش ۲: EZ-diffusion با دست

یک شرکت‌کننده $P_c = 0.802$، $V_{RT} = 0.112$ s² و $M_{RT} = 0.723$ s دارد.

۱. $L = \ln(0.802/0.198) = 1.399$.
۲. $x = 1.399 \times (1.399 \times 0.643 - 1.399 \times 0.802 + 0.802 - 0.5)/0.112 = 0.998$.
۳. $v = 0.1 \times 0.998^{1/4} = 0.100$.
۴. $a = 0.01 \times 1.399/0.100 = 0.140$.
۵. $y = -0.100 \times 0.140/0.01 = -1.399$، پس $\text{MDT} = (0.140/0.200) \times (1 - e^{-1.399})/(1 + e^{-1.399}) = 0.423$ s.
۶. $T_{er} = 0.723 - 0.423 = 0.300$ s.

تفسیر. از میانگین RT درست ۷۲۳ میلی‌ثانیه، حدود ۴۲۳ میلی‌ثانیه صرف انباشت شواهد و ۳۰۰ میلی‌ثانیه صرف رمزگذاری و پاسخ می‌شود. drift ۱۰.۰ و مرز ۱۴.۰ (در واحدهای EZ با $s = 0.1$) مقادیر معمولی برای یک تکلیف با دشواری متوسط‌اند.

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. پیاده‌سازی GCM و مدل prototype برای ساختار ۵-۴؛ شبیه‌سازی داده از GCM.
۲. برازش هر دو مدل با MLE، مقایسه‌شان، و بررسی پیش‌بینی کلیدی A1 در برابر A2.
۳. بررسی بازیابی پارامتر برای GCM.
۴. شبیه‌سازی یک فرایند drift-diffusion، بازیابی پارامترهایش با EZ-diffusion، و تفسیر یک آزمایش ۲ × ۲.

زمان‌بندی: بخش A ۲۰ دقیقه · بخش B ۲۵ دقیقه · بخش C ۱۵ دقیقه · بخش D ۴۰ دقیقه · بخش E ۲۰ دقیقه.

بخش A: ساختار ۵-۴ و دو مدل (۲۰ دقیقه)

Code · **کد:** `code/week14.py`، cell ۱ · سلول ۱

خروجی مورد انتظار:

```
stimulus features  P(A) true  A responses / 20
      A1     1110       0.84                15
      A2     1010       0.88                18
      A3     1011       0.91                18
      A4     1101       0.60                10
      A5     0111       0.60                11
      B1     1100       0.47                10
      B2     0110       0.47                11
      B3     0001       0.16                 4
      B4     0000       0.12                 2
      T1     1001       0.58                11
      T2     1000       0.48                11
      T3     1111       0.87                20
      T4     0010       0.48                10
      T5     0101       0.26                 6
      T6     0011       0.58                12
      T7     0100       0.19                 4
```

بخش B: برازش و مقایسه (۲۵ دقیقه)

Code · **کد:** `code/week14.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
GCM       NLL =  28.36  AIC =  64.72  BIC =  79.79  c = 3.82  w = [0.397
↪  0.111 0.426 0.066]
prototype NLL =  30.02  AIC =  68.04  BIC =  83.11  c = 1.90  w = [0.435
↪  0.009 0.461 0.095]
stimulus  observed   GCM  prototype
      A1      0.75 0.842      0.822
      A2      0.90 0.884      0.818
```

تفسیر کنید: ۱. کدام مدل ترجیح دارد و شواهد چقدر قوی است؟ ($\Delta\text{AIC} = 3.3$، پس وزن‌های Akaike حدود ۸۴.۰ در برابر ۱۶.۰: ترجیحی متوسط، نه قاطع.) ۲. به A1 و A2 نگاه کنید. داده نشان می‌دهد A2 (۹۰.۰) بهتر از A1 (۷۵.۰) دسته‌بندی شده. GCM این ترتیب را پیش‌بینی می‌کند (۸۸.۰ در برابر ۸۴.۰)؛ مدل prototype نمی‌تواند (۸۲.۰ در برابر ۸۲.۰). چرا این مقایسه بین دو نظریه تیزتر از آماره‌ی برازش کلی تمایز می‌گذارد؟ ۳. وزن‌های توجه GCM را تفسیر کنید. شرکت‌کننده به کدام ابعاد توجه کرده، و آیا با ساختار دسته جور درمی‌آید؟

بخش C: آیا GCM در این طرح قابل بازیابی است؟ (۱۵ دقیقه)

کد: Code ‹ code/week14.py، cell ۳ ‹ سلول ۳

خروجی مورد انتظار (حدود ۱ دقیقه):

```
c: r(true, recovered) = 0.08
w1: r(true, recovered) = 0.91
w2: r(true, recovered) = 0.76
w3: r(true, recovered) = 0.89
w4: r(true, recovered) = 0.85
```

به چه دقت کنید: وزن‌های توجه خوب بازیابی می‌شوند (r = ۷۶.۰–۹۱.۰)، ولی حساسیت c در این طرح عملاً **قابل بازیابی نیست** (r = ۰۸.۰). با فقط ۱۶ محرک و ۲۰ trial برای هرکدام، یک c بزرگ و یک c متوسط می‌توانند نسبت‌های پاسخ خیلی شبیهی بدهند (وقتی c بزرگ شد، پیش‌بینی‌ها اشباع می‌شوند)، و c با میزان متمرکز بودن وزن‌ها trade-off دارد. پس باید وزن‌های توجه بخش B را تفسیر کنیم ولی مقدار $\hat{c} = 3.82$ را **نه**. trialهای بیشتر، دامنه‌ی محرک گسترده‌تر، یا یک پیشین بیزی روی c کمک می‌کند. این دقیقاً همان نوع نتیجه‌ای است که مطالعه‌ی بازیابی برایش ساخته شده (هفته‌ی ۷).

بخش D: drift-diffusion و EZ (۴۰ دقیقه)

کد: Code ‹ code/week14.py، cell ۴ ‹ سلول ۴

خروجی مورد انتظار (حدود ۳۰ ثانیه):

```
instruction difficulty    Pc   MRT  v_true  v_EZ  a_true  a_EZ  Ter_EZ
      speed       easy 0.870 0.423    0.25 0.243    0.08 0.078   0.304
      speed       hard 0.732 0.466    0.12 0.115    0.08 0.088   0.288
   accuracy       easy 0.975 0.572    0.25 0.261    0.14 0.140   0.317
   accuracy       hard 0.818 0.697    0.12 0.111    0.14 0.135   0.313
```

Code · **کد:** `code/week14.py`، cell ۵ · سلول ۵

بخش E: تفسیر آزمایش ۲ × ۲ (۲۰ دقیقه)

در notebook جواب دهید: ۱. کدام پارامتر EZ با دست‌کاری **دستورالعمل** تغییر می‌کند و کدام با **دشواری**؟ آیا هیچ‌کدام از دست‌کاری‌ها روی پارامتری که نباید اثر بگذارد اثر گذاشت؟ ۲. توصیف کنید توزیع RT از دستورالعمل سرعت به دقت چطور تغییر می‌کند (نمودار بخش D). کدام بخش توزیع بیشتر تغییر می‌کند: لبه‌ی جلویی یا دنباله؟ ۳. یک مطالعه‌ی بالینی نشان می‌دهد بیماران از گروه کنترل کندترند ولی به همان اندازه دقیق. دو تبیین مختلف DDM برای این نتیجه طرح کنید و بگویید کدام داده‌ها بین آن‌ها تمایز می‌گذارند.

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. $P(A \mid \text{A1})$ و $P(A \mid \text{A2})$ را برای وزن‌های برابر و $c = 2$ تحت هر دو مدل با دست حساب کنید. آیا پیش‌بینی کلیدی را بازتولید می‌کنند؟

تمرین ۲ ⋆. EZ را روی آماره‌های مثال حل‌شده و روی $P_c = 1.0$ با $N = 100$ trial (با تصحیح مرزی) اعمال کنید. بدون تصحیح چه اتفاقی می‌افتد؟

تمرین ۳ ⋆⋆ **(داده‌ی prototype).** داده را از مدل prototype تولید کنید و هر دو مدل را برازش کنید. آیا مقایسه‌ی مدل، مدل مولد را تشخیص می‌دهد؟ یک بازیابی مدل کوچک اجرا کنید (۲۰ مجموعه داده برای هر مدل مولد) و confusion matrix ۲ × ۲ را بسازید.

تمرین ۴ ⋆⋆ **(بازیابی و سوگیری).** برای EZ ۲۰۰ شرکت‌کننده‌ی شبیه‌سازی‌شده با (v, a, T_{er}) تصادفی و فقط ۱۰۰ trial برای هرکدام، برآوردهای EZ را با مقادیر واقعی مقایسه کنید. کدام پارامتر بدتر از همه بازیابی می‌شود؟ بعد تغییرپذیری بین trialها drift را به شبیه‌ساز اضافه کنید (تمرین ۵ هفته‌ی ۱) و ببینید کدام برآورد EZ سوگیر می‌شود.

تمرین ۵ ⋆⋆⋆ **(پیشرفته: GCM بیزی).** GCM را در PyMC با پیشین‌های $c \sim \text{Gamma}(2, \text{scale } 2)$ و $w \sim \text{Dirichlet}(1, 1, 1)$ برازش کنید. پسین وزن‌های توجه را با MLE مقایسه کنید و یک بررسی پیش‌بینی پسین روی تفاوت A1 و A2 اجرا کنید. (برای نسخه‌ی سلسله‌مراتبی، Wagenmakers & Lee فصل ۱۷ را ببینید.)

lab check-off

نشان دهید: (۱) جدول برازش و نمودار پیش‌بینی GCM در برابر مدل prototype همراه با جوابتان به سؤال ۲، (۲) جدول EZ برای طرح ۲ × ۲، و (۳) جوابتان به سؤال ۱ بخش E.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

مدل‌های exemplar در یک «فضای معنایی» یادگرفته‌شده. GCM به یک فضای روان‌شناختی نیاز دارد تا فاصله‌ها را در آن اندازه بگیرد. به‌طور سنتی این فضا از رتبه‌بندی‌های شباهت و مقیاس‌بندی چندبعدی (MDS) می‌آید. مدل‌های زبانی یک جایگزین پیشنهاد می‌کنند: هر کلمه یا جمله به یک **بردار** embedding نگاشت می‌شود، و فاصله‌ی بین بردارها اغلب به جای شباهت روان‌شناختی استفاده می‌شود. ترکیب embeddingها با GCM مدلی می‌دهد که می‌تواند هر کلمه‌ی تازه‌ای را بدون رتبه‌بندی شباهت اضافه دسته‌بندی کند. اینکه فاصله‌های embedding با شباهت انسانی جور درمی‌آیند یا نه یک سؤال تجربی است، و می‌توانید آن را با ابزارهای این درس بیازمایید.

Code · **کد:** `code/week14.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
P(fruit | tomato) = 0.902
P(fruit | knife) = 0.094
P(fruit | nutcracker) = 0.370
```

امتحانش کنید (بدون نیاز به API). ⋆ - c را به ۱ و به ۱۰ تغییر دهید. سه پیش‌بینی چطور عوض می‌شوند، و چرا «nutcracker» بیشتر از همه تغییر می‌کند؟ - ⋆⋆ فرض کنید ۲۰ شرکت‌کننده سه محرک آزمون را دسته‌بندی کرده‌اند، با ۱۹، ۱ و ۱۲ پاسخ «fruit». c را با MLE برازش کنید (درست‌نمایی دوجمله‌ای، هفته‌ی ۴) و یک آزمون G^2 اجرا کنید. آیا فضای embedding با یک پارامتر برازش خوبی دارد؟ - ⋆⋆ بحث: embeddingها از متن یاد گرفته شده‌اند، نه از ادراک. برای کدام دسته‌ها ممکن است شباهت مبتنی بر متن به‌طور نظام‌مند با شباهت انسانی فرق کند (به رنگ یا شکل فکر کنید)؟

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **وزن‌های توجه بدون قید.** بدون قید جمع‌برابر-یک، c و w کاملاً با هم trade-off دارند (non-identifiable). از reparameterization softmax استفاده کنید.

۲. **قضاوت درباره‌ی مدل‌های exemplar و prototype فقط با برازش کلی.** پیش‌بینی‌هایی که از نظر نظری تشخیصی‌اند (A1) در برابر (A2) اغلب آگاهی‌بخش‌تر از تفاوت‌های کوچک AIC هستند.

۳. **میانگین‌گیری داده‌ی دسته‌بندی روی شرکت‌کننده‌هایی** که به ابعاد مختلف توجه می‌کنند. این می‌تواند یک فرد exemplarگونه را prototypeگونه نشان دهد (و برعکس)؛ خطاهای میانگین‌گیری هفته‌ی ۵ را به یاد بیاورید.

۴. **استفاده از EZ با واحدهای غلط.** RTها باید بر حسب **ثانیه** و واریانس بر حسب s^2 باشد، با $s = 0.1$. قاطی کردن ms و s نتیجه‌ی بی‌معنی می‌دهد.

۵. **استفاده از EZ وقتی فرض‌هایش نقض شده‌اند** (سوگیری قوی، خطاهای کند یا سریع). RTهای خطا را بررسی کنید؛ در صورت نیاز از DDM کامل استفاده کنید.

۶. **«گروه کندتر drift rate پایین‌تری دارد.»** کندی می‌تواند از مرز بالاتر، drift پایین‌تر یا non-decision time طولانی‌تر بیاید. فقط مدلی که روی دقت و توزیع‌های RT برازش شده می‌تواند بگوید کدام.

۷. **فراموش کردن حالت‌های مرزی** $P_c = 1$ یا $P_c \leq 0.5$ در EZ.

۹.۱.۱ خودآزمایی

۱. تفاوت اصلی نظریه‌های exemplar و prototype را هرکدام در یک جمله بیان کنید. **پاسخ** :Exemplar یک دسته با همه‌ی نمونه‌های ذخیره‌شده نمایش داده می‌شود و دسته‌بندی به شباهت جمع‌شده با آن‌ها بستگی دارد. :Prototype یک دسته با یک خلاصه‌ی واحد (گرایش مرکزی) نمایش داده می‌شود و دسته‌بندی به شباهت با آن خلاصه بستگی دارد.

۲. در ساختار ۵-۴، چرا مقایسه‌ی A1 و A2 تشخیصی است؟ **پاسخ** A1 به prototype دسته‌ی A نزدیک‌تر است (۳ از ۴ ویژگی)، پس مدل prototype پیش‌بینی می‌کند بهتر از A2 دسته‌بندی شود. ولی A2 به exemplarهای دیگر A خیلی شبیه است و به هیچ exemplar از B شبیه نیست، در حالی که A1 به دو exemplar از B شبیه است، پس مدل exemplar می‌تواند A2 $\geq$ A1 را پیش‌بینی کند. دو نظریه پیش‌بینی‌های ترتیبی متضاد دارند.

۳. پارامترهای c و w_m در GCM چه چیزی را نشان می‌دهند؟ **پاسخ** c حساسیت است: شباهت با فاصله‌ی روان‌شناختی چقدر سریع کم می‌شود (c بزرگ یعنی فقط exemplarهای خیلی نزدیک مهم‌اند). w_m نسبت توجهی است که به بعد m داده می‌شود و فاصله‌ها را در امتداد ابعاد مورد توجه کش می‌دهد.

۴. انتظار دارید کدام پارامتر DDM تحت این موارد تغییر کند: (الف) دستورالعمل سرعت در برابر دقت، (ب) محرک‌های سخت‌تر، (ج) پاسخ حرکتی کندتر (مثلاً پا به جای انگشت)؟ **پاسخ** (الف) فاصله‌ی مرزها a. (ب) drift rate v. (ج) non-decision time T_{er}.

۵. EZ-diffusion به کدام سه آماره نیاز دارد و فرض‌های اصلی‌اش چیست؟ **پاسخ** نسبت پاسخ‌های درست، واریانس RTهای درست و میانگین RTهای درست. فرض می‌کند نقطه‌ی شروع بی‌سوگیر است ($z = a/2$)، پارامترها تغییرپذیری بین trialها ندارند، و مقیاس $s = 0.1$ است.

۶. DDM چه ارتباطی با مدل random walk هفته‌ی ۱ دارد؟ **پاسخ** حد زمان-پیوسته و شواهد-پیوسته‌ی random walk است: وقتی اندازه‌ی گام و مدت گام با هم به صفر میل کنند، random walk به یک فرایند انتشار Wiener با drift v و نویز s همگرا می‌شود.

۱۰.۱.۱ تکلیف

- A5 (MCMC **از صفر)** در ابتدای درس این هفته تحویل داده می‌شود.
- تکلیف جدیدی نداریم: روی **پروژه‌ی پایانی** کار کنید. اگر پروژه‌تان از GCM یا DDM استفاده می‌کند، کد امروز نقطه‌ی شروع خوبی است؛ به مواد درس ارجاع دهید و بگویید چه چیزی را تغییر داده‌اید.

۱۱.۱.۱ مطالعه‌ی بیشتر

- Wagenmakers & Lee **(۲۰۱۴)، فصل ۱۷.** مدل بافت تعمیم‌یافته که به روش بیزی (و سلسله‌مراتبی) روی داده‌ی یادگیری دسته برازش می‌شود. (منبع اصلی برای دسته‌بندی.)
- Lewandowsky & Farrell **(۲۰۱۸)**: فصل مدل‌های زمان پاسخ انتخابی [شماره‌ی فصل بررسی شود] برای مدل drift-diffusion و خویشاوندانش.
- Verguts **(۲۰۲۲)**: فصل‌های دسته‌بندی و تصمیم‌گیری [فصل‌ها بررسی شود].
- اختیاری، خارج از فهرست درس: Grasman, R. P. P. & Wagenmakers, E.-J., van der Maas, H. L. J., P. (۲۰۰۷). An EZ-diffusion model for response time and accuracy. *Psychonomic Bulletin & Review*

Schaffer, M. M. & Medin, D. L., (۱۹۷۸). Context theory of classification learning. *Psychological Review,* ۸۵، ۲۰۷–۲۳۸. *Review,* ۱۴، ۳–۲۲.

پیش‌نمایش هفته‌ی ۱۵: یادگیری از پاداش‌ها (یادگیری تقویتی)، ذهن به‌عنوان یک مشاهده‌گر بیزی، و اینکه مدل‌های شناختی و سیستم‌های هوش مصنوعی چطور به هم کمک می‌کنند.