مدل‌سازی شناختی

جزوه‌ی کامل درس

هفته‌ی ۱۵: مدل‌سازی در علوم شناختی ۲: یادگیری تقویتی، شناخت بیزی و هوش مصنوعی

فهرست مطالب

۱ کاربردها در علوم شناختی **۱**

۱.۱ هفته‌ی ۱۵: مدل‌سازی در علوم شناختی ۲: یادگیری تقویتی، شناخت بیزی و هوش مصنوعی ۱

۱.۱.۱ واژه‌های کلیدی ۱

۱.۱.۲ اهداف یادگیری ۲

۱.۱.۳ مقدمه ۳

۱.۱.۴ جزوه‌ی درس ۳

۱.۱.۵ مثال حل‌شده ۸

۱.۱.۶ lab (۲ ساعت) ۱۰

۱.۱.۷ ارتباط با هوش مصنوعی و LLMها ۱۳

۱.۱.۸ اشتباهات رایج و برداشت‌های نادرست ۱۳

۱.۱.۹ خودآزمایی ۱۴

۱.۱.۱۰ تکلیف ۱۴

۱.۱.۱۱ مطالعه‌ی بیشتر ۱۵

فصل ۱

کاربردها در علوم شناختی

۱.۱ هفته‌ی ۱۵: مدل‌سازی در علوم شناختی ۲: یادگیری تقویتی، شناخت بیزی و هوش مصنوعی

فصل ۶: نمونه‌هایی از مدل‌سازی در حوزه‌های مختلف علوم شناختی · درس ۱ ساعت · lab ۲ ساعت
داده‌ی اصلی: انتخاب‌های شبیه‌سازی‌شده در یک تکلیف bandit دوبازویی با یک وارونگی (reversal)؛ یک آزمایش شبیه‌سازی‌شده‌ی ترکیب نشانه‌های بینایی–لامسه‌ای (cue combination).

۱.۱.۱ واژه‌های کلیدی

واژه‌های مهم این درس با معادل فارسی‌شان (حتی اگر در درس‌های قبل آمده باشند).

English	فارسی	توضیح کوتاه
simulation	شبیه‌سازی	تولید داده‌ی مصنوعی با اجرای مدل
bandit task	تکلیف bandit	انتخاب مکرر بین گزینه‌هایی با پاداش احتمالی
cue combination	ترکیب نشانه‌ها (cues)	ترکیب اطلاعات چند حس برای یک برآورد
Q-learning	Q-learning	قاعده‌ی یادگیری ارزش گزینه‌ها
inverse temperature / softmax (β)	softmax / دمای معکوس	تبدیل ارزش‌ها به احتمال انتخاب
learning rate (α)	نرخ یادگیری	اندازه‌ی به‌روزرسانی بعد از هر خطا
temperature	دما (temperature)	پارامتر نویز در انتخاب token؛ $1/T = \beta$
trial	کوشش (trial)	یک بار انجام تکلیف توسط شرکت‌کننده
likelihood	درست‌نمایی	احتمال داده به‌عنوان تابعی از پارامترها

English	فارسی	توضیح کوتاه
fitting / fit	برازش	تنظیم پارامترها تا مدل با داده جور شود
parameter recovery	بازیابی پارامتر	آیا برازش، پارامترهای معلوم شبیه‌سازی را برمی‌گرداند
parameter	پارامتر	کمیت قابل تنظیم مدل که بین افراد یا شرایط فرق می‌کند
ideal observer	مشاهده‌گر ایده‌آل	مدل استنباط بهینه با اطلاعات موجود
cognitive model	مدل شناختی	توصیف دقیق و ریاضی یا محاسباتی از یک فرایند ذهنی
exploitation / exploration	کاوش / بهره‌برداری	امتحان گزینه‌های دیگر / انتخاب بهترین گزینه‌ی فعلی
prediction error	خطای پیش‌بینی	تفاوت پاداش گرفته‌شده و پاداش مورد انتظار
reinforcement learning (RL)	یادگیری تقویتی	یادگیری از پاداش و پیامد
noise	نویز	تغییرات تصادفی در شواهد یا در داده
estimator / estimate	برآورد / برآوردگر	مقدار به‌دست‌آمده برای پارامتر / روش به دست آوردن آن
reliability	پایایی (قابلیت اطمینان)	دقت یک نشانه؛ عکس واریانس آن
large language model (LLM)	مدل بزرگ زبانی	شبکه‌ی عصبی‌ای که کلمه‌ی بعدی متن را پیش‌بینی می‌کند
parameter trade-off	بده‌بستان پارامترها	تغییر یک پارامتر که با پارامتر دیگر جبران می‌شود
reward model / RLHF	RLHF / مدل پاداش	آموزش chatbot از روی ترجیحات انسانی
Bradley–Terry model	مدل Bradley–Terry	مدل انتخاب برای مقایسه‌های جفتی

۲.۱.۱ اهداف یادگیری

در پایان این هفته، دانشجویان می‌توانند:

۱. یادگیری از پاداش را با قاعده‌ی Rescorla–Wagner / Q-learning و قاعده‌ی انتخاب softmax **صورت‌بندی کنند** و نرخ یادگیری و inverse temperature را **تفسیر کنند**.
۲. درست‌نمایی trial به trial یک مدل یادگیری را **بنویسند**، آن را با MLE **برازش کنند**، و بازیابی پارامتر و بازیابی مدل را در برابر راهبردهای ساده‌تر **ارزیابی کنند**.
۳. پیش‌بینی‌های یک مشاهده‌گر ایده‌آل بیزی (Bayesian ideal observer) را برای ترکیب نشانه‌ها **استخراج کنند** و **بیازمایند** که آیا رفتار شبیه‌سازی‌شده بهینه است.
۴. مدل‌های بیزی شناخت (ادعایی درباره‌ی ذهن) را از تحلیل داده‌ی بیزی (روشی برای دانشمندان) **تمیز دهند**.

۵. درباره‌ی اینکه مدل‌های شناختی و سیستم‌های هوش مصنوعی چطور به هم کمک می‌کنند، و اینکه ابزارهای ارزیابی این درس چطور روی سیستم‌های هوش مصنوعی‌ای که به‌عنوان مدل شناخت پیشنهاد می‌شوند به کار می‌روند، **بحث کنند**.

۳.۱.۱ مقدمه

یادگیری از پیامدها. یک شرکت‌کننده بارها بین دو ماشین بازی انتخاب می‌کند که یکی بیشتر از دیگری پاداش می‌دهد. وسط کار، ماشین‌ها مخفیانه جایشان عوض می‌شود. شرکت‌کننده چقدر سریع متوجه می‌شود و خودش را تطبیق می‌دهد؟ چقدر کاوش (explore) می‌کند و چقدر بهره‌برداری (exploit)؟ یکی از موفق‌ترین مدل‌های کل روان‌شناسی و علوم اعصاب با یک معادله جواب می‌دهد: انتظارتان را به اندازه‌ی کسری از **خطای پیش‌بینی** (prediction error)، یعنی تفاوت چیزی که گرفتید و چیزی که انتظار داشتید، به‌روز کنید. همین قاعده‌ی خطامحور در شرطی‌سازی کلاسیک (Rescorla–Wagner)، در یادگیری پیوندگرا (قاعده‌ی دلتا)، در شلیک نورون‌های دوپامینی، و در الگوریتم‌های یادگیری تقویتی پشت سیستم‌های هوش مصنوعی امروزی دیده می‌شود. برازش آن روی داده‌ی انتخاب یکی از رایج‌ترین کاربردهای مدل‌سازی شناختی امروز است، مثلاً در روان‌پزشکی محاسباتی.

ذهن به‌عنوان آماردان. وقتی یک شیء را هم‌زمان می‌بینید و لمس می‌کنید، بینایی و لامسه هر دو برآوردی پرنویز از اندازه‌اش می‌دهند. یک مشاهده‌گر ایده‌آل بیزی آن‌ها را با وزن دادن به هر نشانه به نسبت پایایی‌اش ترکیب می‌کند، که برآوردی دقیق‌تر از هرکدام به تنهایی می‌دهد. آیا آدم‌ها این کار را می‌کنند؟ این کاربردی متفاوت از کلمه‌ی «بیزی» نسبت به هفته‌های ۹–۱۳ است: اینجا قاعده‌ی بیز یک **فرضیه درباره‌ی ذهن** است، در سطح محاسباتی Marr (هفته‌ی ۱).

مدل‌های شناختی ↔ هوش مصنوعی. خیلی از ایده‌ها در هر دو جهت بین مدل‌سازی شناختی و هوش مصنوعی رفت‌وآمد می‌کنند: یادگیری خطامحور، شبکه‌های عصبی، یادگیری تقویتی، استنباط بیزی. امروز خود سیستم‌های هوش مصنوعی، از جمله مدل‌های بزرگ زبانی (LLM)ها، به‌عنوان مدل شناخت انسان پیشنهاد می‌شوند. ابزارهای این درس (درست‌نمایی، مقایسه‌ی مدل، آزمون‌های تعمیم، بازیابی) دقیقاً همان چیزی‌اند که برای ارزیابی چنین ادعاهایی لازم است.

این موضوع کجا به کار می‌رود؟

- **روان‌پزشکی محاسباتی:** مدل‌های یادگیری تقویتی روی انتخاب‌های بیماران افسرده، معتاد، مبتلا به اسکیزوفرنی یا وسواس برازش می‌شوند تا آزموده شود که آیا از پاداش و تنبیه متفاوت یاد می‌گیرند (مثلاً نرخ یادگیری پایین‌تر بعد از ضرر).
- **علوم اعصاب:** خطای پیش‌بینی در قاعده‌ی دلتا با فعالیت نورون‌های دوپامینی جور درمی‌آید؛ یکی از شناخته‌شده‌ترین پیوندهای یک مدل شناختی با مغز.
- **آموزش و بازی:** سیستم‌های یادگیری تطبیقی و طراحی بازی از ایده‌های RL برای مدل کردن اینکه بازیکن‌ها و یادگیرنده‌ها چطور خودشان را با بازخورد تطبیق می‌دهند استفاده می‌کنند.
- **ادراک و رباتیک:** ترکیب بهینه‌ی نشانه‌ها توضیح می‌دهد آدم‌ها چطور بینایی، لامسه و شنوایی را ترکیب می‌کنند، و همین قاعده‌ی وزن‌دهی در ادغام حسگرها (sensor fusion) به کار می‌رود.
- **هوش مصنوعی:** یادگیری تقویتی امروزی و آموزش chatbotها از روی ترجیحات انسانی (RLHF) از همین مدل‌های انتخاب استفاده می‌کنند (بخش هوش مصنوعی و LLMها را ببینید).

۴.۱.۱ جزوه‌ی درس

به زبان ساده یادگیری از پاداش. هر گزینه (مثلاً هر کدام از دو دستگاه بازی) در ذهن شرکت‌کننده یک «ارزش» دارد: چقدر پاداش از آن انتظار دارد. بعد از انتخاب یک گزینه و دیدن نتیجه، ارزش کمی به سمت چیزی که واقعاً اتفاق افتاد جابه‌جا می‌شود: ارزش

جدید = ارزش قبلی + نرخ یادگیری × (پاداش − ارزش قبلی). عبارت داخل پرانتز **خطای پیش‌بینی** است، یعنی میزان غافلگیری. **نرخ یادگیری** α می‌گوید این جابه‌جایی چقدر بزرگ است. انتخاب‌ها کاملاً حریصانه نیستند: قاعده‌ی softmax گزینه‌ی باارزش‌تر را بیشتر انتخاب می‌کند و inverse temperature β تعیین می‌کند چقدر بیشتر (β پایین = کاوش تصادفی‌تر، β بالا = تقریباً همیشه بهترین). برازش این مدل یعنی پیدا کردن α و βای که دنباله‌ی واقعی انتخاب‌های شرکت‌کننده را محتمل‌ترین کند.
ذهن بیزی: وقتی دو حس تخمین‌های پرنویزی از یک چیز می‌دهند (دیدن و لمس کردن اندازه‌ی یک شیء)، بهترین حدس یک میانگین وزنی است که به حس قابل اعتمادتر بیشتر اعتماد می‌کند. آدم‌ها اغلب به این وزن‌دهی بهینه نزدیک‌اند؛ مدل این را بدون هیچ پارامتر آزادی پیش‌بینی می‌کند و همین آن را یک آزمون قوی می‌کند.

زمان‌بندی پیشنهادی (۶۰ دقیقه): یادگیری از پاداش ۲۰ · برازش مدل‌های یادگیری ۱۰ · مدل‌های بیزی شناخت ۱۵ · مدل‌های شناختی و هوش مصنوعی ۱۰ · جمع‌بندی درس ۵.

۱. یادگیری تقویتی: قاعده‌ی دلتا و Q-learning

قاعده‌ی دلتا / Rescorla–Wagner. بعد از انتخاب گزینه‌ی o در trial t و گرفتن پاداش $r_t \in \{0, 1\}$:

$$\delta_t = r_t - Q_t(o) \quad \text{(prediction error)}, \qquad Q_{t+1}(o) = Q_t(o) + \alpha\, \delta_t,$$

و ارزش گزینه‌های انتخاب‌نشده ثابت می‌ماند. **نرخ یادگیری** $\alpha \in [0, 1]$ تعیین می‌کند پیامدهای تازه چقدر قوی انتظارات قدیمی را بازنویسی کنند. α بالا سریع تطبیق می‌دهد ولی پرنویز است؛ α پایین پایدار است ولی وارونگی را دیر می‌فهمد.

قاعده‌ی انتخاب. softmax ارزش‌ها با inverse temperature $\beta \geq 0$ به احتمال انتخاب تبدیل می‌شوند:

$$P(\text{choose } o \text{ on trial } t) = \frac{\exp(\beta\, Q_t(o))}{\sum_{o'} \exp(\beta\, Q_t(o'))}.$$

$\beta = 0$ یعنی انتخاب تصادفی (کاوش محض)؛ β بزرگ یعنی همیشه گزینه‌ای که فعلاً بهترین است انتخاب شود (بهره‌برداری). برای دو گزینه این یک تابع لجستیک از تفاوت ارزش‌هاست: $P(o_1) = 1/(1 + e^{-\beta(Q_1 - Q_2)})$.

ارتباط‌ها: - این به‌روزرسانی همان **قاعده‌ی دلتا**ی شبکه‌های پیوندگراست (Verguts, ۲۰۲۲): یک شبکه‌ی تک‌لایه که با تصحیح خطا آموزش می‌بیند. - خطاهای پیش‌بینی δ_t شبیه پاسخ‌های فازیک نورون‌های دوپامینی مغز میانی‌اند، و همین مدل‌های RL را در علوم اعصاب محاسباتی محوری کرد. - Q-learning با خطاهای temporal-difference پایه‌ی یادگیری تقویتی مدرن در هوش مصنوعی است.

خواندن ریاضی

- $Q_t(o)$: ارزش گزینه‌ی o در trial شماره‌ی t (زیرنویس t شماره‌ی trial است).
- $\delta_t = r_t - Q_t(o)$: پاداش گرفته‌شده منهای پاداش مورد انتظار. مثبت = غافلگیری خوشایند، منفی = ناامیدی.
- $Q_{t+1}(o) = Q_t(o) + \alpha\, \delta_t$. **مثال:** $Q = 0.5$، $\alpha = 0.3$ و پاداش ۱: $\delta = 0.5$ و Q جدید $= 0.5 + 0.15 = 0.65$. بدون پاداش: $\delta = -0.5$ و Q جدید $= 0.35$.
- softmax **برای دو گزینه:** $P(\text{option 1}) = 1/(1 + e^{-\beta(Q_1 - Q_2)})$. با $Q_1 - Q_2 = 0.25$: $\beta = 0$ می‌دهد ۵۰.۰ (تصادفی)، $\beta = 3$ می‌دهد ۶۸.۰، و $\beta = 20$ می‌دهد ۹۹.۰ (تقریباً همیشه گزینه‌ی ۱).

۲. برازش یک مدل یادگیری

درست‌نمایی ترتیبی است. ارزش‌ها به انتخاب‌ها و پاداش‌های گذشته‌ی خود شرکت‌کننده بستگی دارند، پس مدل را روی دنباله‌ی واقعی trialهای شرکت‌کننده اجرا می‌کنیم و احتمال‌هایی را که به انتخاب‌های واقعاً انجام‌شده نسبت داده در هم ضرب می‌کنیم:

$$\ell(\alpha,\beta)=\sum_{t=1}^{T}\ln P\big(\text{choice}_t \mid Q_t(\cdot;\ \alpha,\text{history}_{<t}),\ \beta\big).$$

نکته‌های عملی: - reparameterize کنید: $\alpha=1/(1+e^{-\eta_\alpha})$ و $\beta=e^{\eta_\beta}$ (هفته‌ی ۳)، و از multi-start استفاده کنید. - β–α trade-off: انتخاب پرنویز (β پایین) و یادگیری کند یا نامنظم (α حدی) می‌توانند رفتارهای شبیه به هم بسازند، پس برآوردها در برازش‌های مختلف اغلب همبسته‌اند، و علامت همبستگی به طرح و دامنه‌ی پارامترها بستگی دارد. مشکل دیگر این است که برآورد مقادیر خیلی بزرگ β اصلاً سخت است (بخش C lab. مطالعه‌ی بازیابی در همان طرح واقعی ضروری است (هفته‌ی ۷). - **طرح مهم است:** برای برآورد α به وارونگی و trial کافی نیاز است؛ احتمال‌های پاداش ثابت اطلاعات کمی درباره‌اش می‌دهند. - **راهبردهای جایگزین** باید مقایسه شوند: مثلاً *win-stay/lose-shift* (WSLS: انتخاب پاداش‌گرفته را تکرار کن، بعد از بی‌پاداشی عوض کن، با نرخ لغزش ε)، یا یک مدل تصادفی سوگیر. برازش خوب RL معنای زیادی ندارد اگر WSLS هم به همان خوبی برازش شود.

خواندن ریاضی $\ell(\alpha,\beta)=\sum_t \ln P(\text{choice}_t \mid Q_t,\beta)$: مدل یادگیری را روی دنباله‌ی انتخاب‌ها و پاداش‌های خود شرکت‌کننده، trial به trial، اجرا کن. در هر trial احتمالی را که مدل به انتخابِ واقعی شرکت‌کننده داده حساب کن، لگاریتمش را بگیر و جمع بزن. مثال حل‌شده (بخش ۱) این کار را برای چهار trial انجام می‌دهد: $\ln 0.5+\ln 0.679+\ln 0.593+\ln 0.755=-1.884$. بهترین (α,β) این جمع را بیشینه می‌کنند. این همان درست‌نمایی هفته‌ی ۴ است، با این تفاوت که احتمال هر trial به تاریخچه‌ی پیش از آن بستگی دارد.

۳. مدل‌های بیزی شناخت

ترکیب نشانه‌ها. یک نشانه‌ی بینایی $x_V\sim\mathcal{N}(S,\sigma_V)$ و یک نشانه‌ی لامسه‌ای $x_H\sim\mathcal{N}(S,\sigma_H)$ هر دو اندازه‌ی واقعی S را می‌سنجند. با پیشین تخت، پسین S نرمال است با میانگین

$$\hat{S}=w_V x_V+w_H x_H,\qquad w_V=\frac{1/\sigma_V^2}{1/\sigma_V^2+1/\sigma_H^2},\quad w_H=1-w_V,$$

و انحراف معیار

$$\sigma_{VH}=\sqrt{\frac{\sigma_V^2\,\sigma_H^2}{\sigma_V^2+\sigma_H^2}}\ \le\ \min(\sigma_V,\sigma_H).$$

پیش‌بینی‌های آزمون‌پذیر (مثلاً آزموده‌شده توسط Banks, & Ernst ۲۰۰۲): (۱) وزن‌ها باید پایایی نشانه‌ها را دنبال کنند، که آزمایشگر می‌تواند با تخریب یک نشانه دست‌کاری‌اش کند؛ (۲) دقت دوحسی باید بهتر از بهترین نشانه‌ی تکی باشد، دقیقاً به اندازه‌ی بالا. انحراف معیارهای تک‌نشانه جداگانه اندازه‌گیری می‌شوند، پس پیش‌بینی‌های مشاهده‌گر ایده‌آل **هیچ پارامتر آزادی ندارند**. همین آن‌ها را آزمون‌هایی قوی و ابطال‌پذیر می‌کند.

یک مدل بیزی شناخت چه ادعایی دارد. اینکه رفتار، با توجه به نویز، پیشین و هدف‌های عامل، تقریبی از استنباط بهینه است: یک تبیین در **سطح محاسباتی** (Marr). درباره‌ی الگوریتم ساکت است: مغز ممکن است بیز را با نمونه‌گیری، heuristicها یا کدهای جمعیتی عصبی تقریب بزند.

نقدهایی که باید در ذهن داشت: با انتخاب آزادانه‌ی پیشین‌ها، درست‌نمایی‌ها و تابع‌های زیان، تقریباً هر رفتاری را می‌شود بعد از واقعه «بهینه» نامید (مسئله‌ی انعطاف‌پذیری هفته‌ی ۶). آزمون‌های قوی این اجزا را مستقل تثبیت می‌کنند، مثل ترکیب نشانه‌ها.

دو معنا، یک بار دیگر:

	مدل بیزی شناخت	تحلیل داده‌ی بیزی
چه کسی استنباط می‌کند؟	ذهن شرکت‌کننده (به‌طور فرضی)	دانشمند
پیشین نشان‌دهنده‌ی	باورهای شرکت‌کننده درباره‌ی جهان	دانش دانشمند درباره‌ی پارامترها
می‌تواند غلط باشد اگر...	آدم‌ها بهینه نباشند	مدل یا پیشین‌ها بد انتخاب شده باشند
نمونه‌ها در این درس	ترکیب نشانه‌ها (امروز)	هفته‌های ۹–۱۳

می‌توانید یک مدل بیزی شناخت را با بیشینه‌ی درست‌نمایی تحلیل کنید، و یک مدل غیربیزی (مثلاً Q-learning) را با تحلیل داده‌ی بیزی.

خواندن ریاضی

- $w_V = \frac{1/\sigma_V^2}{1/\sigma_V^2 + 1/\sigma_H^2}$: وزن بینایی برابر دقت آن (۱/واریانس) تقسیم بر دقت کل است. حسی که دو برابر دقیق‌تر باشد (نصف انحراف معیار، یک‌چهارم واریانس) چهار برابر وزن می‌گیرد.
- $\sigma_{VH} = \sqrt{\sigma_V^2\sigma_H^2/(\sigma_V^2+\sigma_H^2)}$: انحراف معیار ترکیبی که همیشه از بهترین حس تنها کوچک‌تر است. **مثال:** $\sigma_V = 1$ و $\sigma_H = 2$: $w_V = 1/(1+1/4) = 0.8$ و $\sigma_{VH} = \sqrt{4/5} = 0.894$، حدود ۱۱٪ بهتر از بینایی به‌تنهایی.
- **آزمون:** σ_V و σ_H را جداگانه اندازه بگیر (هر بار یک حس)، w_V و σ_{VH} را بدون هیچ پارامتر آزادی پیش‌بینی کن، و بعد داده‌ی دوحسی را بررسی کن.

برای یک مهندس

- **قاعده‌ی دلتا همان به‌روزرسانی LMS است.** $Q \leftarrow Q + \alpha(r - Q)$ یک LMS تک‌ضریبی است (یا یک میانگین متحرک با وزن نمایی و ضریب فراموشی $1-\alpha$): α بزرگ تغییرات را سریع دنبال می‌کند ولی پرنویز است، α کوچک هموار ولی کند است؛ همان trade-off آشنای ردیابی و خطای تنظیم (misadjustment).
- softmax همان توزیع Boltzmann/Gibbs است؛ β به معنای فیزیکی یک دمای معکوس است. نمونه‌گیری با دما همان روشی است که مدل‌های زبانی متن تولید می‌کنند (کادر هوش مصنوعی هفته‌ی ۱).
- **برازش α و β از روی انتخاب‌ها** یعنی شناسایی یک سیستم تطبیقی فقط از روی خروجی‌های دودویی آن: هرگز Q را نمی‌بینید، فقط تصمیم‌هایی را که تولید می‌کند. به همین دلیل α و β با هم trade-off دارند و بررسی بازیابی ضروری است.
- **ترکیب بهینه‌ی نشانه‌ها** دقیقاً از وزن‌های معکوس واریانس در **ترکیب با نسبت بیشینه** (MRC) و ادغام حسگرها در فیلتر کالمن استفاده می‌کند: واریانس تخمین ترکیبی $(1/\sigma_V^2 + 1/\sigma_H^2)^{-1}$ است. سؤال علمی این است که آیا مغز این ادغام را انجام می‌دهد.

۴. مدل‌های شناختی و هوش مصنوعی

	جهت	نمونه‌ها
علوم شناختی ← هوش مصنوعی		شبکه‌های عصبی (الهام‌گرفته از نورون‌ها و قاعده‌های یادگیری)؛ یادگیری تقویتی (از نظریه‌ی یادگیری حیوانی)؛ ایده‌های exemplar/prototype در طبقه‌بندهای یادگیری ماشین (روش‌های نزدیک‌ترین همسایه در برابر مرکزوار)

جهت	نمونه‌ها
هوش مصنوعی ← علوم شناختی	شبکه‌های عمیق به‌عنوان مدل قشر بینایی؛ عامل‌های RL به‌عنوان مدل تصمیم‌گیری؛ مدل‌های بزرگ زبانی که به‌عنوان مدل پردازش زبان و استدلال انسان‌گونه پیشنهاد می‌شوند
ریاضیات مشترک	درست‌نمایی‌ها و تابع‌های زیان؛ بهینه‌سازی مبتنی بر گرادیان (هفته‌ی ۳)؛ استنباط بیزی و MCMC؛ cross-validation و تعمیم (هفته‌ی ۶)

ارزیابی یک سیستم هوش مصنوعی به‌عنوان مدل شناختی دقیقاً از جعبه‌ابزار درس استفاده می‌کند: - آیا داده‌ی انسانی را فراتر از برازش پیش‌بینی می‌کند، مثلاً شرایط تازه و تفاوت‌های فردی را (تعمیم، هفته‌ی ۶)؟ - آیا در یک مقایسه‌ی منصفانه از مدل‌های شناختی ساده‌تر و تفسیرپذیر بهتر است (هفته‌های ۷، ۱۰)؟ - آیا می‌توانیم از روی داده بگوییم انسان و مدل از یک سازوکار استفاده می‌کنند، یا فقط خروجی‌های شبیه تولید می‌کنند (تقلید مدل و بازیابی، هفته‌ی ۷)؟ - آیا پارامترها یا حالت‌های درونی‌اش به‌عنوان سازه‌های روان‌شناختی تفسیرپذیرند (هفته‌ی ۱)؟

مدلی با میلیاردها پارامتر که رفتار را خوب برازش می‌کند به‌طور خودکار یک تبیین نیست: انعطاف‌پذیری، identifiability و تفسیرپذیری به اندازه‌ی برازش مهم‌اند.

۵. جمع‌بندی درس

در حوزه‌های خیلی متفاوت (فراموشی، تشخیص، دسته‌بندی، تصمیم‌گیری، یادگیری، ادراک)، گردش کار یکسان بوده است: **صورت‌بندی** ← **شبیه‌سازی** ← **برازش** ← **ارزیابی** ← **بازیابی** ← **تفسیر.** حوزه مدل را عوض می‌کند؛ منطق مدل‌سازی ثابت می‌ماند.

برای مدرس

- **بازی bandit را با کلاس اجرا کنید.** دو «دستگاه» (دو دانشجو با سکه‌ی پنهان یا یک اپلیکیشن عدد تصادفی؛ یکی ٪۸۰ مواقع پاداش می‌دهد و دیگری ٪۲۰)، و در وسط کار مخفیانه جایشان را عوض کنید. کلاس پیش از دیدن هر معادله‌ای کاوش، بهره‌برداری و وارونگی را تجربه می‌کند.
- **چهار trial Q-learning مثال حل‌شده را روی تخته انجام دهید** با یک جدول: ارزش قبل، انتخاب، پاداش، خطای پیش‌بینی، ارزش بعد. ده دقیقه وقت می‌گیرد و کد را رازگشایی می‌کند.
- **برای ترکیب نشانه‌ها آزادانه از شهود مهندسی‌تان استفاده کنید:** «ترکیب دو حسگر پرنویز» راه طبیعی ارائه‌ی آن است و برای دانشجوهای روان‌شناسی روشنگر است.
- **بحث هوش مصنوعی را روی زمین نگه دارید.** بخش ۴ می‌تواند بحث‌های طولانی راه بیندازد؛ از چهار سؤال ارزیابی (تعمیم، مقایسه‌ی منصفانه، تقلید، تفسیرپذیری) برای متمرکز نگه داشتن آن استفاده کنید.
- **سؤال‌های رایج.**
  - «چرا برآورد β سخت است؟» وقتی انتخاب‌ها تقریباً قطعی شدند، بیشتر کردن β درست‌نمایی را تقریباً تغییر نمی‌دهد.
  - «آیا مغز واقعاً *Q-learning* انجام می‌دهد؟» توصیف خوبی از بسیاری از داده‌های انتخاب است و با سیگنال‌های دوپامین جور درمی‌آید، ولی مدل‌های پیچیده‌تر (یادگیری مبتنی بر مدل یا model-based) هم پشتیبانی دارند.
  - «آیا آدم‌ها همیشه نشانه‌ها را بهینه ترکیب می‌کنند؟» اغلب نزدیک، ولی نه همیشه؛ شرکت‌کننده‌ی lab به لامسه بیش از حد وزن می‌دهد.

۵.۱.۱ مثال حل‌شده

بخش ۱: چهار trial Q-learning با دست

دو گزینه؛ $\alpha = 0.5$، $\beta = 3$؛ ارزش‌های اولیه $Q(1) = Q(2) = 0.5$.

trial	$Q(1)$	$Q(2)$	$P(\text{choose } 1)$	انتخاب	پاداش	δ	به‌روزرسانی
۱	۵۰.۰		۵۰۰.۰	۱		$1 - 0.5 = +0.5$	$Q(1) = 0.5 + 0.5 \times 0.5 = 0.75$
۲	۵۰.۰		$1/(1+e^{-3\times 0.25}) = 0.679$	۱		$0 - 0.75 = -0.75$	$Q(1) = 0.75 - 0.375 = 0.375$
۳	۳۷۵.۰	۵۰.۰	$1/(1 + e^{-3\times(-0.125)}) = 0.407$	۱		$1 - 0.5 = +0.5$	$Q(2) = 0.75$
۴	۳۷۵.۰	۷۵.۰	$1/(1 + e^{-3\times(-0.375)}) = 0.245$	۱		$+0.25$	$Q(2) = 0.875$

لگاریتم درست‌نمایی این چهار انتخاب: $\ln 0.5 + \ln 0.679 + \ln(1-0.407) + \ln(1-0.245) = -0.693 - 0.387 - 0.523 - 0.281 = -1.884$.

تفسیر. با $\alpha = 0.5$ یک بار بی‌پاداشی ارزش گزینه‌ی ۱ را نصف می‌کند و مدل یک تغییر انتخاب پیش‌بینی می‌کند، که شرکت‌کننده انجامش داد. درست‌نمایی به مقادیر پارامتری پاداش می‌دهد که دنباله‌ی انتخاب واقعی شرکت‌کننده را پیش‌بینی کنند.

بخش ۲: یک مشاهده‌گر ایده‌آل

انحراف معیار بینایی $\sigma_V = 1$ mm، انحراف معیار لامسه $\sigma_H = 2$ mm. وزن‌ها: $w_V = 1/(1+1/4) = 0.8$، $w_H = 0.2$. انحراف معیار ترکیبی پیش‌بینی‌شده: $\sqrt{(1\times 4)/(1+4)} = 0.894$ mm، حدود ۱۱٪ بهتر از بینایی به تنهایی. اگر $x_V = 50$ و $x_H = 54$ mm باشد، برآورد بهینه $0.8\times 50 + 0.2\times 54 = 50.8$ mm است.

تفسیر. مشاهده‌گری که نشانه‌ها را فقط میانگین بگیرد ($w = 0.5$) انحراف معیار $\sqrt{0.25\times 1 + 0.25\times 4} = 1.118$ mm دارد، یعنی بدتر از بینایی به تنهایی. وزن‌دهی بهینه است که ترکیب نشانه‌ها را ارزشمند می‌کند.

۶.۱.۱ lab (۲ ساعت)

اهداف

۱. شبیه‌سازی یک عامل Q-learning در یک تکلیف bandit با وارونگی.
۲. برازش (α, β) با MLE؛ اجرای بازیابی پارامتر و تشخیص trade-off α–β.
۳. مقایسه‌ی Q-learning با مدل‌های win-stay/lose-shift و تصادفی سوگیر.
۴. آزمودن اینکه آیا یک مشاهده‌گر شبیه‌سازی‌شده نشانه‌ها را بهینه ترکیب می‌کند.

زمان‌بندی: بخش A ۲۰ دقیقه · بخش B ۲۰ دقیقه · بخش C ۲۵ دقیقه · بخش D ۳۰ دقیقه · بخش E ۲۵ دقیقه.

بخش A: یک عامل Q-learning در تکلیف وارونگی (۲۰ دقیقه)

Code · **کد:** `code/week15.py`، cell ۱ · سلول ۱

خروجی مورد انتظار:

```
Total reward: 151 / 200;  chose the better option on 91% of trials
```

بخش B: درست‌نمایی و یک برازش MLE (۲۰ دقیقه)

Code · **کد:** `code/week15.py`، cell ۲ · سلول ۲

خروجی مورد انتظار:

```
MLE: alpha = 0.491 (true 0.3), beta = 3.80 (true 5.0), NLL = 51.77
Chance-level NLL (always p = 0.5): 138.63
```

بخش C: بازیابی پارامتر و α–β trade-off (۲۵ دقیقه)

Code · کد: `code/week15.py`، cell ۳ · سلول ۳

خروجی مورد انتظار (حدود ۳۰–۶۰ ثانیه):

```
alpha: r(true, recovered) = 0.90
beta: r(true, recovered) = 0.17
corr(recovered alpha, recovered beta) = 0.31 (true values were drawn
↪  independently: 0.03)
```

تفسیر کنید: با ۲۰۰ trial و یک وارونگی، α خوب بازیابی می‌شود (r = ۰.۹۰) ولی β تقریباً اصلاً نه (r = ۰.۱۷). این برازش بخش B را هم توضیح می‌دهد ($\hat{\beta} = 3.8$ برای مقدار واقعی ۰.۵). به ناحیه‌ی β بزرگ در نمودار β نگاه کنید. چرا دماهای معکوس بالا را به سختی می‌شود تعیین کرد؟ (راهنمایی: وقتی انتخاب‌ها تقریباً قطعی شدند، بالاتر بردن β درست‌نمایی را به‌زحمت تغییر می‌دهد.) α و β بازیابی‌شده هم همبسته‌اند (۳۱.۰) با اینکه مقادیر واقعی مستقل بودند: یک معاوضه. این برای مطالعه‌ای که β را با مثلاً یک پرسش‌نامه‌ی بالینی همبسته می‌کند چه معنایی دارد؟

بخش D: آیا واقعاً یادگیری تقویتی است؟ مقایسه‌ی مدل (۳۰ دقیقه)

Code · کد: `code/week15.py`، cell ۴ · سلول ۴

خروجی مورد انتظار (حدود ۱ دقیقه):

```
AIC for the Part A participant: {'Q-learning': 107.5, 'WSLS': 200.3,
↪  'bias': 278.9}

Model recovery (rows: generating, columns: selected by AIC):
            Q-learning  WSLS  bias
Q-learning          20     0     0
WSLS                 0    20     0
```

بخش E: یک مشاهده‌گر ایده‌آل برای ترکیب نشانه‌ها (۲۵ دقیقه)

یک شرکت‌کننده‌ی شبیه‌سازی‌شده اندازه‌ی اشیایی را که هم‌زمان دیده و لمس می‌شوند قضاوت می‌کند. سطح نویز تک‌نشانه را از بلوک‌های تک‌حسی می‌دانیم. آیا شرکت‌کننده نشانه‌ها را بهینه ترکیب می‌کند؟

Code · **کد:** `code/week15.py`، cell ۵ · سلول ۵

خروجی مورد انتظار:

```
Ideal observer: w_V = 0.80, predicted bimodal SD = 0.894 mm
Participant: empirical w_V = 0.56, bimodal SD = 1.006 mm
Best single cue SD = 1.000 mm;  simple average would give 1.118 mm
```

تفسیر کنید: آیا این شرکت‌کننده بهینه است؟ وزن بینایی تجربی (۵۶.۰) خیلی پایین‌تر از مقدار بهینه‌ی ۸۰.۰ است: شرکت‌کننده به نشانه‌ی لامسه‌ای کم‌پایاتر بیش از حد وزن می‌دهد. در نتیجه انحراف معیار دوحسی‌اش (۰۰۶.۱ mm) بهتر از بینایی به تنهایی (۰۰۰.۱ mm) نیست، به جای ۸۹۴.۰ mm که یک مشاهده‌گر ایده‌آل به آن می‌رسید. توجه کنید که پیش‌بینی مشاهده‌گر ایده‌آل **هیچ پارامتر آزادی** نداشت: همین آن را یک آزمون قوی می‌کند.

(این شرکت‌کننده را با وزن واقعی ۶۵.۰ شبیه‌سازی کردیم. برآورد ۵۶.۰ حدود ۳ خطای استاندارد فاصله دارد، یک نمونه‌ی غیرمعمول بدشانس ولی یادآوری مفید که وزن‌های تجربی هم خطای نمونه‌گیری دارند. تمرین ۴ بازه‌های bootstrap دورشان می‌گذارد.)

تمرین‌ها (به ترتیب سختی)

تمرین ۱ ⋆. چهار trial Q-learning مثال حل‌شده را با `nll_q` بازتولید کنید (راهنمایی: NLL را با `theta=(logit0, log3, log3, .5)` روی دنباله‌ی چهار trialی حساب کنید). آیا لگاریتم درست‌نمایی -۸۸۴.۱ به دست می‌آید؟

تمرین ۲ ⋆. بخش C را با ۵۰ trial (بدون وارونگی) و با ۴۰۰ trial (سه وارونگی) دوباره اجرا کنید. بازیابی α چطور تغییر می‌کند؟ این برای طراحی آزمایش چه معنایی دارد؟

تمرین ۳ ⋆⋆ **(دو نرخ یادگیری).** بسیاری از مطالعه‌ها نرخ‌های یادگیری متفاوتی برای خطاهای پیش‌بینی مثبت و منفی پیدا می‌کنند. مدلی با α^+ و α^- پیاده‌سازی کنید، یک عامل با $\alpha^+ = 0.4$ و $\alpha^- = 0.1$ شبیه‌سازی کنید، و با AIC/BIC و یک مطالعه‌ی بازیابی بیازمایید که آیا پارامتر اضافه در طرح بخش A identifiable است.

تمرین ۴ ⋆⋆ **(وزن‌های بهینه).** در بخش E، یک مشاهده‌گر با $w_V = 0.8$ (بهینه) و یکی با $w_V = 0.5$ (میانگین‌گیر)، هرکدام با ۱۰۰ trial دوحسی، شبیه‌سازی کنید. با bootstrap (هفته‌ی ۵) دور وزن‌ها و انحراف معیارهای تجربی بازه‌ی اطمینان بگذارید. با ۱۰۰ trial می‌توانید دو مشاهده‌گر را از هم تشخیص دهید؟

تمرین ۵ ⋆⋆⋆ **(پیشرفته: RL سلسله‌مراتبی).** ۲۰ عامل با (α_j, β_j) فردی و فقط ۸۰ trial برای هرکدام شبیه‌سازی کنید. آن‌ها را جداگانه با MLE و بعد با یک مدل بیزی سلسله‌مراتبی در PyMC برازش کنید. (راهنمایی: حلقه‌ی trialها را می‌شود با `pytensor.scan` نوشت؛ یا به جایش یک نمونه‌گیر Metropolis-within-Gibbs دست‌نویس پیاده کنید که از `nll_q` برای پارامترهای فردی و به‌روزرسانی‌های conjugate برای میانگین‌های گروه استفاده کند.) بازیابی α_j را بین دو رویکرد مقایسه کنید.

lab check-off

نشان دهید: (۱) برازش MLE و نمودارهای بازیابی همراه با تفسیرتان از نمودار β، (۲) جدول بازیابی مدل، و (۳) جوابتان درباره‌ی بهینه بودن مشاهده‌گر ترکیب نشانه‌ها.

۷.۱.۱ ارتباط با هوش مصنوعی و LLMها

قاعده‌ی انتخاب پشت آموزش chatbotها. chatbotهای امروزی با یادگیری تقویتی از بازخورد انسانی (RLHF) تنظیم دقیق (fine-tune) می‌شوند. آدم‌ها دو پاسخ را می‌بینند و می‌گویند کدام را ترجیح می‌دهند، یک **مدل پاداش** (reward model) روی این انتخاب‌ها برازش می‌شود، و بعد chatbot با یادگیری تقویتی آموزش می‌بیند تا پاداش یادگرفته‌شده را بیشینه کند (Christiano et al., ۲۰۱۷؛ Ouyang et al., ۲۰۲۲). مدل پاداش معمولاً مدل Bradley–Terry است، $P(i \succ j) = 1/(1+e^{-(r_i - r_j)})$. این همان قاعده‌ی انتخاب softmax این هفته با $\beta = 1$، و قاعده‌ی انتخاب Luce در GCM است. برازش آن یک مسئله‌ی MLE از هفته‌ی ۴ است. پس مدل‌های انتخاب انسانی در قلب شیوه‌ای قرار دارند که سیستم‌های هوش مصنوعی امروزی با ترجیحات انسانی همسو (align) می‌شوند، و مشکلاتشان هم همین‌جاست: انتخاب‌های پرنویز، identifiability (فقط تفاوت‌های r مهم‌اند، پس یک مقدار ثابت می‌شود)، و فاصله‌ی بین آنچه آدم‌ها انتخاب می‌کنند و آنچه واقعاً خوب است.

> Code · **کد:** `code/week15.py`، cell ۶ · سلول ۶

خروجی مورد انتظار:

```
304 comparisons; estimated rewards = [0.   0.56 0.5  1.61] (true [0.
↪  0.5 1.  2. ])
```

با حدود ۳۰۰ مقایسه‌ی پرنویز، ترتیب برآوردشده‌ی پاسخ‌های ۱ و ۲ حتی برعکس شده. یک مدل پاداش یک مدل شناختی برازش‌شده است، و مثل هر مدل دیگری به برآورد عدم قطعیت و بررسی بازیابی نیاز دارد.

امتحانش کنید (بدون نیاز به API). ⋆ - خطاهای استاندارد مبتنی بر Hessian را برای سه برآورد حساب کنید (هفته‌ی ۵). آیا برعکس شدن پاسخ‌های ۱ و ۲ در محدوده‌ی عدم قطعیت است؟ - ⋆⋆ یک بازیابی پارامتر اجرا کنید: چند مقایسه لازم است تا ترتیب هر چهار پاسخ در ۹۰٪ مجموعه داده‌های شبیه‌سازی‌شده درست بازیابی شود؟ - ⋆⋆ ارزیاب‌هایی را شبیه‌سازی کنید که جواب‌های طولانی‌تر را صرف‌نظر از کیفیت ترجیح می‌دهند (یک پاداش طول به پاداش واقعی اضافه کنید). مدل پاداش برازش‌شده چه یاد می‌گیرد، و بعد chatbot برای انجام چه کاری آموزش می‌بیند؟

مطالعه‌ی اختیاری: Christiano, P. F., et al. (2017). Deep reinforcement learning from human preferences. *NeurIPS*. Ouyang, L., et al. (2022). Training language models to follow instructions with human feedback. *NeurIPS*.

۸.۱.۱ اشتباهات رایج و برداشت‌های نادرست

۱. **برازش یک مدل یادگیری روی نسبت‌های انتخاب تجمیع‌شده.** درست‌نمایی باید دنباله‌ی trialهای خود هر شرکت‌کننده را دنبال کند، چون ارزش‌ها به تاریخچه‌ی خودش بستگی دارند.
۲. **تفسیر α بدون بررسی بازیابی.** α و β با هم trade-off دارند، و α بدون وارونگی یا trial کافی بد شناسایی می‌شود.
۳. **مقایسه نکردن با راهبردهای ساده.** win-stay/lose-shift یا پافشاری (perseveration) می‌توانند یادگیری را تقلید کنند. نشان دهید مدل RL در یک مقایسه‌ی منصفانه برنده است.
۴. **فراموش کردن اینکه softmax از تفاوت ارزش‌ها استفاده می‌کند.** افزودن یک ثابت به همه‌ی ارزش‌های Q چیزی را عوض نمی‌کند، در حالی که مقیاس ارزش‌ها و β با هم trade-off دارند.
۵. **«آدم‌ها بیزی‌اند» از روی یک برازش پس‌از-واقعه.** اگر پیشین و درست‌نمایی برای برازش رفتار انتخاب شده باشند، بهینگی فرض شده، نه آزموده. آزمون‌های قوی آن‌ها را مستقل تثبیت می‌کنند (ترکیب نشانه‌ها).

۶. **قاطی کردن دو نوع بیزی‌گرایی** (مدل ذهن در برابر روش تحلیل).
۷. **«یک مدل بزرگ هوش مصنوعی که داده‌ی انسانی را برازش می‌کند، مدل شناختی خوبی است.»** برازش تبیین نیست. مثل هر مدل دیگری درباره‌ی تعمیم، تقلید، identifiability و تفسیرپذیری بپرسید.

۹.۱.۱ خودآزمایی

۱. به‌روزرسانی قاعده‌ی دلتا را بنویسید و نقش خطای پیش‌بینی را توضیح دهید. **پاسخ** $Q \leftarrow Q + \alpha(r - Q)$. خطای پیش‌بینی $r - Q$ تفاوت پیامد و انتظار است: خطاهای مثبت ارزش را بالا می‌برند، خطاهای منفی پایین می‌آورند، و نرخ یادگیری اندازه‌ی تغییر را تعیین می‌کند.

۲. inverse temperature β چه چیزی را کنترل می‌کند؟ $\beta = 0$ و $\beta \to \infty$ چه رفتاری تولید می‌کنند؟ **پاسخ** حساسیت انتخاب‌ها به تفاوت ارزش‌ها (کاوش در برابر بهره‌برداری). $\beta = 0$: انتخاب تصادفی بدون توجه به ارزش‌ها. $\beta \to \infty$: همیشه گزینه‌ای با بالاترین ارزش فعلی انتخاب می‌شود.

۳. چرا درست‌نمایی یک مدل یادگیری باید trial به trial روی دنباله‌ی واقعی هر شرکت‌کننده حساب شود؟ **پاسخ** پیش‌بینی‌های مدل در trial t به انتخاب‌ها و پاداش‌های قبلی خود آن شرکت‌کننده (از طریق ارزش‌های Q) بستگی دارد، پس احتمال هر انتخاب مشاهده‌شده را فقط با اجرای مدل روی تاریخچه‌ی مشاهده‌شده می‌شود حساب کرد.

۴. trade-off β–α را توضیح دهید. **پاسخ** ترکیب‌های مختلف نرخ یادگیری و نویز انتخاب می‌توانند دنباله‌های انتخاب مشابهی تولید کنند. مثلاً تطبیق کُند می‌تواند از یادگیری کند (α پایین) یا از انتخاب پرنویز و بی‌حساس به ارزش (β پایین) بیاید. پس برآوردها همبسته‌اند و هرکدام به تنهایی نامطمئن؛ جهت همبستگی به طرح بستگی دارد. علاوه بر این، مقادیر بالای β ضعیف شناسایی می‌شوند، چون انتخاب‌های تقریباً قطعی برای بسیاری از βهای بزرگ یکسان به نظر می‌رسند.

۵. بینایی انحراف معیار ۲ و لامسه انحراف معیار ۲ دارد. وزن‌های بهینه و انحراف معیار ترکیبی پیش‌بینی‌شده چقدر است؟ **پاسخ** پایایی‌های برابر $w_V = w_H = 0.5$ می‌دهند، و انحراف معیار ترکیبی $\sqrt{4 \times 4/8} = \sqrt{2} = 1.41$ است، بهتر از هر نشانه به تنهایی (۲).

۶. برای هرکدام یک نمونه بزنید: ایده‌ای که از علوم شناختی به هوش مصنوعی رفته، و ایده‌ای که از هوش مصنوعی به علوم شناختی آمده. **پاسخ** علوم شناختی ← هوش مصنوعی: یادگیری خطامحور (Rescorla–Wagner / قاعده‌ی دلتا) که به آموزش شبکه‌های عصبی و یادگیری تقویتی منجر شد. هوش مصنوعی ← علوم شناختی: شبکه‌های کانولوشنی عمیق که به‌عنوان مدل جریان بینایی شکمی (ventral visual stream) استفاده می‌شوند، یا عامل‌های RL و مدل‌های زبانی که به‌عنوان مدل رفتار انسان پیشنهاد می‌شوند.

۷. یک پژوهشگر نشان می‌دهد پاسخ‌های یک مدل بزرگ زبانی در یک تکلیف استدلال همبستگی بالایی با پاسخ‌های انسانی دارد. پیش از پذیرفتنش به‌عنوان یک مدل شناختی چه شواهد دیگری می‌خواهید؟ **پاسخ** پیش‌بینی شرایط تازه و تفاوت‌های فردی (تعمیم)؛ یک مقایسه‌ی منصفانه با مدل‌های شناختی ساده‌تر؛ آزمون‌هایی که سازوکار مدل را از جایگزین‌هایی که همان خروجی‌ها را تولید می‌کنند تمیز دهند (تقلید)؛ و نوعی تناظر بین حالت‌های درونی‌اش و سازه‌های روان‌شناختی.

۱۰.۱.۱ تکلیف

تکلیف جدیدی نداریم: **ارائه‌های پروژه‌ی پایانی هفته‌ی آینده است**، و گزارش کتبی و کد پیش از امتحان پایانی تحویل داده می‌شوند. وقت lab این هفته را برای کار روی پروژه و جمع‌بندی درس استفاده کنید.

۱۱.۱.۱ مطالعه‌ی بیشتر

- Verguts **(۲۰۲۲)**: فصل‌های قاعده‌ی دلتا و یادگیری تقویتی (یادگیری خطامحور و پایه‌ی عصبی‌اش) [فصل‌ها بررسی شود]. (منبع اصلی برای بخش ۱.)
- Lewandowsky & Farrell **(۲۰۱۸)**: فصل‌های مدل‌های شبکه‌ی عصبی و مدل‌ها در علوم اعصاب [شماره‌ی فصل‌ها بررسی شود].
- Anderson **(۲۰۱۴)**: فصل‌های شبکه‌های عصبی و یادگیری، که مدل‌های شناختی و علوم اعصاب محاسباتی را به هم وصل می‌کنند [فصل‌ها بررسی شود].
- اختیاری، خارج از فهرست درس: Banks, M. S. & Ernst, M. O., (۲۰۰۲). Humans integrate visual and haptic information in a statistically optimal fashion. *Nature,* ۴۱۵، ۴۲۹–۴۳۳. Collins, A. G. E. & Wilson, R. C., (۲۰۱۹). Ten simple rules for the computational modeling of behavioral data. *eLife,* ۸، e49547 (مثال اصلی‌اش یک تکلیف bandit مثل تکلیف امروز است).

پیش‌نمایش هفته‌ی ۱۶: ارائه‌های پروژه‌ی پایانی، و یک جلسه‌ی پایانی درباره‌ی شیوه‌ی خوب مدل‌سازی.